

机器学习到底在学什么

第一讲 从几套房屋的记录走完一次学习过程

机器学习连贯自学教程 · 图解与纸笔实验

看到一套70平方米的房屋，你想粗略估计它可能卖多少钱。面积就在房源信息里，最终成交价却还不知道。假如你能查到附近几套已售房屋的面积和价格，能不能从这些记录里找出一种估计办法，再把它用到这套新房上？

这一讲始终追问同一个问题：**怎样从已有例子中得到一种预测办法，又怎样判断它对没见过的例子是否有用？**你会亲手选出一条规则，算出它的误差，把它冻结，再打开事先保留的答案。走完这一圈，数据、特征、标签、模型、训练和泛化就有了各自的位置。

你只需要纸、笔，以及加减乘除。字母、平均值、坐标图都会在用到时解释；不要求先学微积分、线性代数、概率论、Python或PyTorch。建议分两次阅读：第一次读到纸笔实验并动手完成，第二次继续读测试结果、练习与详解。能复述并重做实验，比一次看完更重要。

本讲所有房屋与价格均为人为构造的教学数据，不来自市场，不构成估价或投资建议。少量数据被刻意安排得便于计算；它们能演示方法，不能证明现实预测能力。我们先用面积一个因素把思路讲清，之后再讨论这种简化会遗漏什么。

一 先有一个任务 才谈得上学习

我们把任务说具体：在成交前，根据房屋面积，预测它的成交总价。这里三个容易被忽略的限定。预测发生在成交前；输入是当时已经知道的信息；输出是总价，单位为万元。若一会儿预测总价，一会儿预测每平方米价格，数据看起来都是数字，实际上却换了问题。


先不使用机器学习。你可以自己规定：“每平方米按2万元估计。”于是50平方米估计100万元，70平方米估计140万元。把这条规则写成计算程序，电脑就能快速重复执行。**规则是谁确定的，与规则是否由电脑执行，是两回事。**电脑执行很多次乘法，不等于它从经验中学会了单价。

假如你发现附近小房屋与大房屋不能用同一个单价准确描述，可能会继续补规则：不同地段加减多少钱，楼龄不同怎样调整。某些业务确实适合这样做，例如明确的税率计算、单位换算和合规限制。难点在于：影响价格的因素多而且会变化，所有例外未必能由人提前写全。


机器学习提供另一条路：我们仍然决定要解决什么问题、给它哪些信息、允许它采用哪类规则，但某些规则细节交给数据来确定。本讲允许的规则都是“面积乘一个数，再加一个数”。究竟乘多少、加多少，不先凭直觉拍板，而是比较它们解释已有成交记录的效果。

从“人写规则”到“用样本拟合模型”

人写规则



从样本中学习



人仍负责：定义任务、选择输入特征、模型形式与训练方法。

图1 机器学习改变的是规则如何得到。训练之后，使用模型做预测仍然是执行计算；任务、数据和学习方法仍需人来设计。

读图时分清两条时间线：上方是“给定规则后执行”，下方多了一个“先利用例子确定规则”的阶段。机器学习并没有消除程序，训练本身也由程序执行。它只是让某些可调的部分通过例子来确定，而不必全部由人逐项写死。

因此，本讲可以先采用一个朴素的理解：机器学习是一类利用数据或经验，按某种目标调整模型的办法，目的在于让它在所关心的任务上表现得更好。这里的“学会”需要可观察的证据，不表示电脑产生了人的理解或意识；训练过程也可能失败，并不保证每次调整都更好。

二 把生活记录变成可以学习的例子

假设我们有下面四条记录。每一行都是一套已经成交的房屋，称为一个样本。多条样本放在一起，组成数据集。表中的H1等编号只是帮助我们指认记录，并不意味着编号本身可以解释房价。

房屋编号	面积 平方米	成交总价 万元
H1	50	110
H2	60	130
H3	80	170
H4	90	190

我们选择输入模型的房屋描述，叫特征。这里的特征只有面积。我们希望模型预测的答案，叫标签；在这批已成交样本中，标签就是记录下来的成交总价。标签不一定是文字贴纸，也可以是110、130这样的数值。

一行数据里，什么是输入，什么是目标？

教学数据



训练时已有 x 和 y；真正预测新房时，y 往往正是我们还不知道的量。

图2 同一条记录中的信息承担不同任务。预测时能提供的是特征；训练时，已知标签帮助我们检查预测对不对。

现在暂时遮住H2的价格。你能把60平方米提供给一种估计办法，得到一个预测值；揭开130万元，才能判断刚才估得高还是低。这种“先预测，再与已知答案比较”的动作，是后面训练过程的核心。

特征必须是在预测时能够得到的信息

如果把“成交后缴纳的、由成交价决定的某项费用”也放进输入，模型可能看起来非常准确。但我们本来要在成交前预测，那个费用当时还不知道。这样的信息把未来答案的一部分偷渡进了输入，真实使用时无法获得相同帮助。这是数据泄漏的一种表现。


同样，若把成交价自己既当输入又当答案，程序当然很容易“预测正确”，但它没有解决原来的任务。挑选特征时，第一问不是“它与答案相关吗”，而是“到我要预测的那一刻，我真的知道它吗”。之后还要考虑记录是否可靠、是否有权限使用、成本是否合理。

标签也不是永远正确的真理。成交记录可能录错，价格可能混入装修款，面积也可能采用不同口径。模型按照错误记录学习，不会自动知道哪里错了。所以，机器学习从来不只是挑一种算法；把问题和记录说清楚，也是学习过程的一部分。

在坐标图上看见同一批记录

一张图可以让四行数字更直观。横轴表示面积，向右更大；纵轴表示成交总价，向上更高。H1对应的点位于横向50、纵向110的位置。一个点同时记录两个数，而不是两个房屋。

把 4 个训练样本放到坐标系里



横坐标是输入面积，纵坐标是已知成交价；这些数据专为教学构造。

图3 四个点来自上表。它们在这组教学数据里恰好呈直线关系；这是一种为了教学而作的安排，不能推广为真实房价规律。

从左向右看，面积变大时价格也变高。我们可以尝试用一条线概括这种关系，而不把四个样本永久当成四道互不相干的题。但是，请先把“看起来有趋势”与“已经找到可信规律”分开：四个点只能提出一个候选想法，还不足以证明它适用于新的房屋。

三 模型是一种把输入变成预测的办法

如果输入70，输出150，我们需要说清楚中间怎样算。这里试用这样一种形式：

预测总价 = 面积 × 一个可调的数 + 另一个可调的数

数学常用字母缩短表达。把面积记为 x ，把预测总价记为 $\hat{y}$ ，把两个可调的数分别记为 w 和 b ，就得到：

$$\hat{y} = w \times x + b$$

x 只是一个暂时放数值的位置。例如输入70平方米时，就把 x 换成70。 $\hat{y}$ 读作“y帽”，帽子提醒我们这是预测；真实记录的价格记为 y 。预测与记录可能相等，也可能不同，不要因为两个符号很像就把它们混在一起。

当 $w=2$ 、 $b=10$ 时，具体规则是“面积乘2，再加10”。于是：

输入 $x = 70$ 平方米

预测 $\hat{y} = 2 \times 70 + 10 = 150$ 万元

此处 w 的单位是万元每平方米， b 的单位是万元。面积乘 w 后已经变成总价，才能与 b 相加。公式不是脱离现实的符号游戏，单位能帮助我们检查是否把总价、单价和面积混用了。


直线模型：参数决定“怎么从面积算价格”

$$\hat{y} = w \times x + b$$


预测价格 = 参数 w $\times$ 面积 + 参数 b

$$2 \text{ 万元/m}^2 \times 70 \text{ m}^2 + 10 \text{ 万元} = 150 \text{ 万元}$$

改变 w ：直线变陡或变缓



改变 b ：整条直线上下移动



$\hat{y}$ 读作“y帽”，表示预测值；本例把 w 、 b 称为模型参数。小图只示意变化方向。

图4 x 随待预测的房屋而变； w 和 b 是规则自身的设置。给定 w 和 b 后，同一个模型就能接收不同面积。

为什么要区分模型形式和具体参数

“面积乘一个数，再加一个数”规定了允许采用的形式。在这个形式中， w 和 b 叫参数。 $w=2$ 、 $b=10$ 确定了一种具体模型； $w=1.5$ 、 $b=40$ 则确定了另一种。它们属于同一类形式，但对某些房屋会给出不同预测。

从图形上看，增大 w 会使线更陡：面积每增加1平方米，模型的预测增加得更多。改变 b 会把整条线向上或向下移。这里的 b 可以帮助整条线贴近记录，**不必解释为“现实中零平方米房屋值多少钱”**。我们的数据只覆盖50到90平方米，把公式延伸到0平方米时，已经离开了它得到支持的范围。

这种用直线关系预测数值的模型，是线性回归的一个简单例子。“回归”在这里指预测数值型结果，不要求事情发生在未来。估计一张照片里物体的长度也可以是回归任务，尽管照片已经拍好。第一讲先理解它做什么，后面再完整研究线性回归的求解。

模型也不一定长成一个公式。它可以是一串判断条件、一组相似样本的比较办法，或由许多层计算构成的网络。共同之处是：它规定了如何从输入得到输出。本讲先用最容易手算的形式，避免把工具复杂度误认成学习本身的复杂度。

四 没有比较标准 就无从判断学得怎样

我们已经会用一个模型做预测，接下来的问题是： w 和 b 应该取多少？先不尝试所有可能的数，而只比较三个事先列出的候选设置：

候选模型	计算规则	参数设置
A	预测总价 = $2 \times \text{面积}$	$w = 2, b = 0$
B	预测总价 = $2 \times \text{面积} + 10$	$w = 2, b = 10$
C	预测总价 = $1.5 \times \text{面积} + 40$	$w = 1.5, b = 40$


以H1为例，面积50平方米，记录价格110万元。A预测100，少了10；B预测110，恰好相同；C预测115，多了5。仅凭这一套房屋，B看起来最好。但只看一个样本，会忽略其余记录，所以需要把四套都算完。

对H2，A预测120，B和C都预测130。只看H2，我们根本分不出B和C。这个简单现象已经说明：模型评价不能只挑一两个对自己有利的例子。

预测误差：量价格方向的距离

同一个样本：面积 $x = 60 \text{ m}^2$ ，真实价格 $y = 130$ 万元

教学数据



误差沿价格方向量；不是沿面积方向量。

B、C 在这一个样本上打平，不代表它们在所有样本上都一样。

图5 预测误差比较的是同一套房屋的预测价与记录价，在面积不变时看纵向差距。一个样本上的相同表现，不能替代全体样本的比较。

先把高估和低估变成可相加的误差

如果只把“预测减记录”的差相加，高估10万元与低估10万元会抵消为0，好像什么也没错。这显然没有反映预测有多偏。第一讲使用一个直观办法：不管方向，只取差距的大小。这叫绝对误差。

绝对误差 = 预测价与记录价之间的距离

A在H1上的绝对误差 = $|100 - 110| = 10$ 万元

C在H1上的绝对误差 = $|115 - 110| = 5$ 万元

两边竖线表示取绝对值，也就是看离0有多远。负10与正10的绝对值都是10。现在，各个样本的误差都不会相互抵消。把它们相加，再除以样本数4，就得到平均绝对误差，常缩写为MAE。

A的四次预测都是“面积乘2”，依次得到100、120、160、180万元。与110、130、170、190比较，每次都差10万元，因此：

A的平均绝对误差 = $(10 + 10 + 10 + 10) \div 4$
= 10 万元

C的四次预测依次是115、130、160、175万元。差距分别为5、0、10、15万元，因此：

$$\begin{aligned}\text{C的平均绝对误差} &= (5 + 0 + 10 + 15) \div 4 \\ &= 7.5 \text{ 万元}\end{aligned}$$

B在四个样本上都恰好预测正确，平均绝对误差是0。这个结果来自本讲的教学安排，不是机器学习通常都能把价格预测得分毫不差。

比较候选模型：把 4 个误差一起算

平均绝对误差 MAE = 所有绝对误差相加 ÷ 样本数

教学数据

候选模型	50 m ²	60 m ²	80 m ²	90 m ²	MAE
A: $\hat{y} = 2x$	10	10	10	10	10
B: $\hat{y} = 2x + 10$	0	0	0	0	0
C: $\hat{y} = 1.5x + 40$	5	0	10	15	7.5

表中所有误差与 MAE 的单位都是“万元”。

B 在这 4 个训练样本上最好；这还不能证明新房也预测得好。

图6 将每个候选都放到同样的四个样本上，并使用同一个评分办法。B在这个有限候选集合中的训练平均绝对误差最小。

MAE是“平均一次偏了多少”的概括，不保证每套房屋都偏同样多。例如误差0和20的平均值是10，误差10和10的平均值也是10。平均值相同，错误分布却不同。以后我们会同时检查极端错误、不同人群与不同场景的表现。

把模型预测有多差量化成一个数的办法，通常称为损失函数。训练时，希望按约定把损失降下来。本讲用MAE承担这项工作，评价时也继续用MAE以方便理解；真实项目的训练损失和最终评价指标可以不同，而且选哪一个应由任务后果决定。

五 训练就是利用已有例子确定可调部分

现在可以准确描述刚才做的事：我们选定模型形式和三个候选参数设置，用四个已知答案的样本分别计算损失，最后选出损失最小的设置 $w=2$ 、 $b=10$ 。这已经是一次极简的训练。

这里把可选参数限制在三个预先给定的组合中，是为了让你能用纸笔看见完整过程。我们只证明B在这三个候选里训练损失最小，并没有完成对所有实数 w 、 b 的搜索，更没有证明它在现实中最佳。以后遇到参数很多的模型，就需要更高效的求解办法。

一种常见方法会从初始参数出发，反复做预测、计算损失，再按损失提供的线索调整参数。调整的具体方法叫训练算法。模型是最后用来预测的计算规则，训练算法是获得其参数的程序，两者不能混成一个词。有些方法直接算出参数，也不必都进行同样的循环。

训练会改参数；使用时先固定参数




图7 训练需要反馈来调整参数；预测只需输入与已经确定的模型。本讲训练结束后，预测阶段不再改变 w 和 b 。

请对照上下两部分回答：真实价格在什么地方出现？它在训练时用于比较预测与标签；等模型要估计一套尚未成交的新房屋时，真实价格恰恰还不知道。若运行时必须先提供答案才能输出预测，它就没有完成我们的任务。

预测一次 并不等于又学习了一次

训练完成后，输入70得到150；接着输入75得到160。变化的是输入和输出， w 仍为2， b 仍为10。在本讲这种固定模型的使用方式中，预测动作不会自动更新参数。

如果以后收集到更多成交记录，可以设计重新训练的流程。但“新记录到了”“程序执行了预测”和“模型参数已经更新”是三件不同的事。只有系统确实执行了更新步骤，才能说这一次数据参与了训练。

也正因为模型只是根据给定信息与学习规则做计算，它不知道你的目标是否选错。假如你把错误记录当答案，它可能越来越贴合错误；假如损失只关心平均值，它也未必主动照顾少数特别困难的情况。人必须负责定义任务、检查数据、选择目标并验证结果。

六 做一次不偷看答案的纸笔实验

到目前为止，我们一直在训练用过的四套房屋上检查表现。现在要回答主问题的后半句：对没见过的例子，模型还能不能用？先暂停往下读。拿一张纸，把下面的步骤实际做一遍；测试答案在下一节才揭开。

第一步，写下任务与单位：“根据成交前知道的面积，预测成交总价；面积用平方米，总价用万元。”把这句话写出来，是为了防止计算过程中悄悄换目标。

第二步，重新画出四行训练记录：50对应110，60对应130，80对应170，90对应190。训练数据就是允许你据此调整参数的那部分数据。这里的训练集只有四行，不代表真实项目只需四个例子。

第三步，分别写出A、B、C的四个预测值，计算它们的MAE。暂时不看前文答案，检验自己能否独立完成。根据训练损失选择参数，写下：“我选择的模型是____， w =____， b =____。”


在打开测试答案以前，还可以先约定一个简单比较对象，叫基线。只根据训练价格计算平均数： $(110+130+170+190) \div 4 = 150$ 万元。把“不管面积，始终预测150万元”固定为基线，后面检查我们的模型是否比它更有用。这里的150只来自训练数据，不会在看到测试答案后调整。

第四步，把选出的模型和这个基线都圈起来，在旁边写“已冻结”。接下来不能因为测试答案不理想而偷偷改它。冻结不是按某个软件按钮，而是一个实验约定：从这个时间点开始，用来做最终评价的规则已经确定。

第五步，只给你两套新房屋的面积：T1是65平方米，T2是85平方米。它们没有参与前三步的计算。用已冻结的规则写下两个预测值，且暂时不要看下一节的真实标签。

测试记录	已知面积 平方米	先写下你的预测 万元	记录价格
T1	65	留待你填写	下一节揭晓
T2	85	留待你填写	下一节揭晓

先训练并冻结，再揭开测试答案



测试标签封存期间不参与拟合；评估结束也不回头用测试集调这个模型。

图8 测试集承担独立检查的角色。先用训练集确定参数，再冻结规则、写下测试预测，最后打开测试标签。

第六步，再写下一句预判：“即使两个测试误差都很小，我仍然不能由此证明模型能用于真实估价，因为_____。”这不是扫兴，而是学习把一个计算结果与一个可信结论分开。

如果第三步算不出来，回到上一节核对一个样本就好。先把“输入代入规则得到预测”和“预测与标签比较得到误差”分成两行写，通常就能看见问题出在哪里。不要一上来把四个样本和所有模型挤进一个心算步骤。

请在纸上留下选择与预测后，再翻到下一节。若你已经先看到了答案，也没有关系；但要诚实地把这次练习记为“理解流程”，而不是一次真正未接触答案的独立测试。

七 打开测试答案 结果能说明多少

本节公开教学测试标签：T1的记录价格为144万元，T2为174万元。按照前面选定并冻结的B模型，两个预测是：

$$T1: 2 \times 65 + 10 = 140 \text{ 万元}$$

$$T2: 2 \times 85 + 10 = 180 \text{ 万元}$$

因此，T1低估4万元，T2高估6万元。绝对误差分别为4与6，而不是把负4和正6直接平均。测试集MAE为：

$$\begin{aligned} \text{测试MAE} &= (|140 - 144| + |180 - 174|) \div 2 \\ &= (4 + 6) \div 2 = 5 \text{ 万元} \end{aligned}$$

冻结后的模型，在两套新房上表现怎样？

固定模型 B: $\hat{y} = 2x + 10$ ；此时不再修改 w 、 b 。

教学数据

编号	面积 / m^2	真实 / 万元	预测 / 万元	绝对误差/万元
T1	65	144	140	4
T2	85	174	180	6

$$\text{测试 MAE} = (4 + 6) \div 2 = 5 \text{ 万元}$$

只有 2 个教学测试样本，不能据此判断真实房市中的可靠性。

图9 训练MAE为0，测试MAE为5万元。本讲在打开标签后只报告固定模型的表现，不根据这个结果回头改选A或C。

这一次计算说明的范围很窄：模型B在这两条指定的教学测试记录上，平均绝对误差是5万元。它不说明每一次都只错5万元，不说明最大只错5万元，也不说明未来所有房屋都能达到这个水平。

对没有见过的样本有用 叫作泛化

我们希望从有限例子获得的办法，能在任务所关心的新样本上继续有效。这种能力叫泛化。训练损失描述模型对已经用来调整它的数据贴合得怎样；独立测试提供关于泛化的证据。这两个问题相关，却不能互相替代。

先看一个极端的逻辑例子。模型M记住四个面积与价格的配对：输入50就返回110，输入60就返回130，输入80就返回170，输入90就返回190；如果遇到任何别的面积，一律返回999万元。它在四条训练记录上的误差同样为0。

我们不需要通过测试集反复试错才知道：仅凭“训练误差为0”这一条信息，无法区分B和M。一个使用了可延续的简单关系，另一个只为列出的情况写了答案，而对其余输入随意处理。这个反例的目的，是推翻“训练零误差就足够”的推论，并不是把M当作认真推荐的建模方法。

训练误差为 0，也可能只是“记住了答案”

两种规则，在已见过的 4 个输入上完全一致。

教学数据


面积/m ²	直线/万元	记忆/万元
50	110	110
60	130	130
80	170	170
90	190	190

直线规则

$\hat{y} = 2x + 10$

故意脆弱的记忆规则

面积恰好是 50、60、80、90：
查表输出已记住的价格；
其他面积：一律输出 999。



这是逻辑示例，不是训练方法对比，也不是用测试结果来挑模型。

图10 两种规则可以同样贴合训练样本，却在新的输入上给出很不同的结果。训练表现本身不能决定你该相信哪一个。

过拟合指模型对训练样本中的特有细节甚至偶然波动贴得过紧，以至于在相关的新数据上表现较差。M是一个故意夸张的提醒，真实的过拟合通常没有这么显眼。它可能是一条弯折过多的曲线，也可能是我们反复修改流程、逐渐迎合了某批评价数据。

反过来，模型太受限制，也可能连训练数据中的重要关系都学不到。这常被称为欠拟合。比如所有房屋不管面积都预测相同价格，就可能错过明显的面积差异。不过，“复杂必然过拟合”“简单必然更好”都不成立；需要合适的数据和评价来判断。

两个测试样本为什么远远不够

第一，两个样本很容易碰巧简单或碰巧困难。第二，它们都是虚构数据，不能证明我们在现实世界中的取样方式是否可靠。第三，面积65与85都落在训练面积50到90的范围内；即便这里预测还行，也无法保证300平方米的房屋同样适用。

在已见输入范围内进行估计，常称为插值；越过范围向外估计，称为外推。两者都可能失败，外推尤其需要额外依据。把 $w=2$ 、 $b=10$ 代入300得到610万元，只说明算式能运行，不能因此认定现实价格就可靠。

还有更根本的问题：我们打算在什么地方、什么时间、什么类型房屋上使用模型？一个城市普通住宅的记录，未必能代表另一个城市的别墅；市场环境变化后，过去的价格关系也可能改变。测试数据应服务于实际使用场景，而不只是从手边资料中方便地抽几条。

八 需要不断改进时 怎样保护最后一次检查


你可能会问：“如果测试结果不理想，难道不能改模型吗？”当然可以改进，但改进之后，就不能继续把同一批已经指导过你修改的数据，当作完全独立的最终证据。

想象一种过程：看T1与T2的误差，换一组参数；再看同样两题，修改特征；反复这样做，直到两题都答得不错。虽然程序没有把T1与T2直接放进训练表，人却把它们的反馈带进了设计。流程已经适应了这两道题，最终得分就会过于乐观。

因此，在需要比较许多方案的项目中，常把数据分成三种角色。训练集用于拟合参数；验证集用于比较方案、调整设置；测试集保留到方案确定后，评价固定的最终选择。验证集参与了开发决策，所以它不能再冒充全新、完全独立的证据。

训练、验证、测试：分清三份数据的职责

需要比较不同模型设计时，再留出验证集。



验证集也会影响选择，所以最终测试集仍需要保持独立。

图11 反复改进的反馈来自训练与验证阶段；最终测试不向当前开发循环回传调参指令。没有一个分割百分比适用于所有任务。

本讲只比较预先给定的三个参数组合，并根据训练MAE完成这次受限的参数拟合，不再进行额外设计搜索，所以纸笔演示采用训练与测试两部分。图11展示的是进一步开发时应增加的隔离。真实项目的数据量、时间顺序和重复记录都会影响怎样划分；不能机械照抄“四行训练、两行测试”。

例如，同一套房屋的重复发布记录不应分散到训练和测试两侧，让模型在测试时几乎重见旧题。若目标是预测未来月份，测试应尊重时间先后；随机打乱后把未来记录放进训练，可能制造现实中不存在的信息优势。

计算平均值、填补缺失值、把文字转换成编码等数据处理，也会从数据中提取信息。涉及从数据估计设置的步骤，应在训练部分拟合，再按固定规则应用于验证与测试。下一讲开始研究数据时，我们会把这条原则展开，不要求你此刻记住每一种处理方法。[2][3]

比漂亮分数更先问基准与代价

一个分数是否值得高兴，还要看与什么比较。假如一套昂贵系统的MAE是5万元，而一个事先约定的简单办法只错4万元，复杂并没有带来收益。我们称这种用于比较的简单办法为基线。

在第六节打开测试答案以前，我们已用训练价格的平均数，固定了“不管面积，始终预测150万元”的基线。现在检查它在两条测试记录上的绝对误差： $|150-144|=6$ 万元， $|150-174|=24$ 万元，测试MAE= $(6+24) \div 2=15$ 万元。B在这两条教学记录上优于这个基线；这个比较仍不能扩展成真实市场结论，基线的数值也没有根据测试分数调整。

更重要的是，5万元的偏差在具体任务中是否可接受？给普通学习者演示趋势，与据此签署合同，是完全不同的后果。正确的实验计算只是使用决策的一个条件，还需要数据范围、误差分布、风险与人工复核等判断。

九 房价只是入口 其他机器学习任务在学什么

现在我们已有完整经验，可以给这条路线一个名字：训练样本同时提供输入和期望输出，并利用这些配对进行学习，称为监督学习。“监督”指可供比较的目标，不要求一个人坐在电脑旁逐步看着它算。

本讲的输出是价格这样的数值，所以是监督学习中的回归。如果输出换成“垃圾邮件”或“正常邮件”这样的类别，就成为分类。类别即便编码成0和1，任务仍然是分类；不能只因为文件里保存的是数字，就把它叫回归。

假如只有房屋的面积、楼龄、位置等描述，没有想预测的价格标签，但希望发现相似房屋是否会形成几个群体，这可能是无监督学习任务。聚类就是一种寻找分组结构的方法。分出来的组不自动等于社会或业务中的真实类别，仍需要解释和验证。

另一类问题中，系统要行动，行动会影响后续处境，再从结果中获得奖励反馈。例如一个模拟机器人要决定往哪里移动，不能只评价眼前一步，还要考虑一连串行动后的结果。利用与环境交互的经验学习决策策略，是强化学习的基本思路。奖励可以延迟出现，也不等于每一步都有唯一正确动作的标准答案。

三类学习：学习信号从哪里来？

监督学习



无监督学习



强化学习

从行动后的反馈中学习



学习信号不同，问题的组织方式也不同；现实系统可以组合多种学习方式。

图12 三类路线的关键差异之一，是学习获得什么样的反馈。它们可以组合使用，并不是互不相通的三个软件盒子。

这不是要求你现在背术语大全，而是帮助你遇到新论文时先问：“这里的数据是什么，目标是什么，反馈从哪里来？”监督学习关心配对目标，无监督学习寻找未直接给出目标标签的结构，强化学习关心交互与长期结果。很多实际方法会跨越这些简单边界。

机器学习 深度学习与大语言模型的关系

人工智能是更宽的研究与应用领域；机器学习是其中一大类方法。深度学习使用多层神经网络学习表示与预测规则，是机器学习的一部分。现代大语言模型大多采用深度学习方法。它们的规模与任务形式虽然复杂，仍要面对数据、目标、训练、评价和泛化这些基本问题。

语言模型训练经常让文本本身提供目标，例如遮住或预测接下来的词元。词元可以先理解为模型处理文字时使用的片段。用数据自身构造学习目标，常称为自监督学习；没有逐条人工写标签，不等于没有训练目标。后面我们会在需要时讲清词元和语言模型，不在第一讲提前展开网络结构。

概念地图：AI、机器学习、深度学习与 Agent




图13 这是方法范围的简化关系图，不是全部人工智能路线图。Agent描述一种与环境交互、组织行动的系统方式，不是另一个与监督学习并列的标签类型。

如果将来研究Agent系统，本讲也会直接派上用场。假如用历史任务训练一个工具选择模块，先要明确输入、正确工具标签、损失以及未见任务的评价。若你只修改了提示词、工具流程或记忆内容，则要准确说明究竟改变了哪个系统部件，不能仅凭表现变化就声称底层模型参数被训练了。

这条联系暂时保留到这里。先把一个小模型的证据链看清，之后再研究由模型、工具、状态和行动组成的复杂系统，才更容易分清改进发生在哪里，以及哪些实验真正支持结论。

十 回到开头 用自己的话解释整个过程

最初我们问，一套70平方米的房屋可能卖多少钱。现在可以给出一个完整而有边界的回答：在这组人为构造的训练记录与三个候选参数设置中，用训练MAE选择了“面积乘2再加10”，所以70平方米的预测是150万元。这个数是模型输出，不是已经知道的成交事实。

随后，我们冻结规则，在未参与拟合的两条教学测试记录上得到5万元的MAE。这演示了怎样评价未见样本，却不足以说明模型可以真实估价。要把它用于现实，还需重新明确目标场景，取得合适数据，处理遗漏因素与重复记录，建立独立评价，并分析错误后果。

机器学习到底在学什么？在本讲中，学的是一个输入到输出的关系里的可调参数；它靠训练例子与损失比较来确定，而我们真正关心的是，这种关系能否在合适的新例子上继续有用。**训练的成功与结论的可信，是相连但不同的两项工作。**

合上讲义，试着不用术语解释五件事：为什么四条记录可以帮助估计第五条；面积与成交价分别扮演什么角色；两个参数是怎样确定的；为什么训练时答对不等于以后答对；为什么测试答案不能反复用来挑选方案。如果你能沿一个例子把它们连起来，第一讲的骨架就已经建立了。

十一 练习 先保留自己的答案

1. 同一套待售房屋有面积、楼龄、卖方手机号、最终成交价、由最终成交价计算出的成交后费用。我们要在成交前估计总价。哪些信息可以作为候选特征，哪些不应进入输入？为什么“当时知道”还不是唯一筛选标准？
2. 某模型的规则为“预测总价= $1.8 \times \text{面积} + 20$ ”。输入75平方米时，预测是多少万元？这套房屋的记录总价为161万元，带方向的差“预测减记录”是多少，绝对误差又是多少？在这次预测中，哪些量改变了，哪些参数没有改变？
3. 有三套房屋，一个模型的预测分别为100、150、200万元，记录价格分别为110、130、220万元。先求三个带方向的差，再求MAE。为什么不能用带方向的差的平均值来表示典型偏差大小？
4. 模型P在训练集上的MAE为0，模型Q为2万元。小李说：“P一定更值得部署。”请指出他的推理缺了什么。再回答：如果P的独立测试MAE为12万元，Q为4万元，是否就可以从此对所有未来场景断言Q更好？
5. 一位研究者每次训练后都查看同一测试集，直到找到在它上面得分最高的特征组合；论文里再把这个得分称为“从未参与开发的最终测试成绩”。哪里出了问题？请给出更可靠的开发与评价安排。

6. 分别判断下列任务更接近回归、分类、聚类还是强化学习，并说明反馈是什么：估计一封快递还有多少小时送达；判断图片是猫还是狗；把没有类别标签的文章按相似内容分组；让模拟机器人根据行动后的奖励学习到达目标。
7. 一份房屋数据中，同一套房屋在三个平台各有一条记录。研究者把所有行随机分成训练和测试，并得到特别好的测试结果。请解释为什么“测试行没在训练表里出现过”仍然不够，以及划分前应考虑怎样识别独立样本。
8. 把本讲纸笔实验重新写成一段实验记录。必须包含任务与单位、训练集、候选参数、损失、选定模型、测试前冻结、测试预测、测试结果、结论边界。最后补一句：如果允许增加一个新特征，你想加什么，为什么它在预测时可以获得？不用重新拟合。

十二 练习详解 从错误中检查概念

第1题 面积与楼龄可以成为候选，因为在成交前通常可以取得，也可能帮助解释价格差异。这里的“通常”需要落实为真实数据流程，而不是假定每条记录都完整准确。最终成交价是要预测的标签，在预测时尚未知道；由它计算出的成交后费用也携带未来信息，不能作为这个任务的输入。

卖方手机号即使能获得，也不因此自动适合作为特征。它主要是个人联系信息，本身没有合理的房价测量含义；使用还涉及必要性、隐私、权限和潜在的错误关联。候选特征需要同时考虑可获得性、任务相关性、数据质量与使用边界。“相关”不是收集一切的理由。

第2题 先代入面积： $1.8 \times 75 + 20 = 135 + 20 = 155$ 万元。带方向的差为 $155 - 161 = -6$ 万元，表示低估6万元；绝对误差为6万元。输入 x 换成了75，输出随之算成155，参数 $w=1.8$ 与 $b=20$ 没有改变。拿新房屋来算一次，不会自动把参数调整得更准确。

第3题 三个带方向的差依次是-10、20、-20万元。绝对误差是10、20、20万元，所以 $MAE = (10 + 20 + 20) \div 3 = 50 \div 3$ ，约16.67万元。带方向的平均差为 $(-10 + 20 - 20) \div 3$ ，约-3.33万元。后一个数可以帮助描述整体偏高或偏低的倾向，却因正负抵消，不能替代每次误差大小的概括。

这里还有一个检查技巧：MAE一定不小于0。若你把平均绝对误差算成负数，就说明绝对值的步骤被跳过了。MAE也不等于最坏误差；本题最坏绝对误差是20万元，而平均值约为16.67万元。

第4题 P只是在用于拟合的记录上更贴合，可能利用了偶然细节或泄漏信息。部署前还缺与目标场景相关的独立评价，以及对错误成本、数据质量和使用范围的检查。给出测试结果后，可以说“在这批独立测试记录、这个指标和当前实验条件下，Q更好”，但不能推到全部未来场景。

还应询问测试样本是否足够、是否与使用情境匹配、是否有重复或泄漏、优势是否稳定。即使最后选择Q，也应持续关注现实输入或环境是否变化。这不是拒绝下结论，而是让结论范围与证据范围相称。

第5题 测试集虽然没有直接用于拟合参数，却影响了特征组合的选择，因此参与了开发。继续称它“从未参与开发”是不准确的。更可靠的办法是先隔离最终测试数据；用训练数据拟合参数，用验证数据比较方案；固定整套流程以后，才用保留测试集作最后评价。

已经反复查看过的那批数据，可以承认它承担了验证角色；若还需要新的独立证据，应取得适当的未参与开发的数据。不能只把同一批记录改名为“新测试集”，或把它们重新排序，就声称独立性恢复了。复杂研究还需要更细致的验证设计，后续课程再展开。

第6题 预测送达小时数属于回归，监督目标是从当次预测时点到签收的实际剩余时长，可在签收后回填。不能用全程运输时长替代这里的剩余时长。猫狗判断属于分类，监督目标是类别。无标签文章分组属于聚类，算法依据内容相似性等结构，而非给定每篇文章的标准组别。模拟机器人属于强化学习情境，反馈包括行动后的奖励与新处境，目标往往涉及一连串行动的累计效果。

时长即使按整数小时记录，通常仍是数值估计；类别即便写成0和1，仍是类别判断。决定任务性质的是输出的含义与比较方式，不只是文件中保存的数据类型。

第7题 同一套房屋的三条平台记录可能高度相似，并共享同一个价格形成过程。即使行号不同，测试集也可能含有训练时已见过的房屋，只是换了来源。模型看起来在回答新题，实际上可能在重复熟悉的对象。

应先理解数据怎样产生，并尽可能识别同一房屋及其重复记录，按房屋实体分组划分，使同一对象不跨越训练与测试边界。若预测目标涉及未来，还要同时考虑时间。原则是独立性要按真实任务中的对象与时序判断，不能只按电子表格的行号判断。

第8题 一份合格记录可以这样写：“任务是在成交前根据面积预测总价，面积单位平方米，价格单位万元。训练记录为(50,110)、(60,130)、(80,170)、(90,190)。预先比较A的(2,0)、B的(2,10)、C的(1.5,40)，以MAE为损失；训练MAE依次为10、0、7.5万元，选择B。测试前冻结参数。对65与85平方米，先预测140与180万元；揭开144与174万元后，测试MAE为5万元。数据为教学构造，测试只有两条，不证明真实估价能力。”

新增特征可以提出楼龄、楼层或地段等，但要解释如何在成交前可靠取得。不要只写“再加真实价格”，也不要说“加得越多就一定越好”。新增特征意味着重新设计与验证，不能在看过测试答案之后继续调到这两题最满意，再沿用原来的独立测试说法。

十三 学完这一讲 接下来学什么

下一讲将把注意力放到数据上：一行究竟代表谁，一个空白值可能是什么意思，为什么看起来很多的记录未必等于很多独立经验。我们会继续用可画、可算的小数据，补齐平均数、分布、图表与简单统计直觉，再逐步引入代码。

你现在不必记住全部英文缩写，也不必急着安装深度学习框架。先把纸笔实验与第2、3、5、8题独立完成。如果能说明每个数从哪里来、模型何时被确定、测试何时被打开，就已经具备进入下一讲所需的起点。

参考资料与进一步阅读

[1] Google Machine Learning Crash Course, Linear regression。用于核对特征、标签、线性模型和参数等基本概念。本讲数据、图示、例题与叙述为独立教学设计。[打开官方资料](#)

[2] Google Machine Learning Crash Course, Datasets Dividing the original dataset。关于训练、验证和测试的不同角色，以及重复使用评价数据的问题。[打开官方资料](#)

[3] scikit-learn官方文档, Common pitfalls and recommended practices。关于数据泄漏与先分割再拟合数据处理步骤。暂不需要运行其中代码。[打开官方资料](#)

上述网页于2026年10月3日核对。它们用于查证和后续阅读；本讲所需前提已在正文解释，无须先读英文资料才能完成练习。