

任务定义与数据生成详解

一 练习详解

练习一 样本单位是一笔订单，因为每次付款都产生一次预测。分别报告 15 条导出记录、12 笔不同订单、8 位不同顾客。同一顾客的不同订单是不同事件，不应只凭顾客相同合并；同一订单被重复导出则应核查是否为副本。若之后想评价新顾客，才需要在划分时进一步检查顾客编号重叠。

练习二 $A \cap B = \{H03\}$ ， $|A| = 3$ ， $|B| = 2$ 。H03 同时出现在两边，不能据此声称完全检验了未见房屋。如果是旧房屋未来再次挂牌的任务，是否保留这种重复身份要结合时间与任务说明决定。错误答案“编号不一样就不重叠”往往只检查了行号而没有检查房屋编号。

练习三 $1800000/10000 = 180$ 万元； $180/90 = 2$ 万元每平方米。若把元直接当成万元，金额含义放大 10000 倍。注意单价的单位里有“每平方米”，不能拿这个 2 与总价 180 不加解释地比较大小。

练习四 从 6 月 1 日到 6 月 18 日只过了 17 天，尚未完整观察三十天，因此缺少剩余窗口的证据。若已可靠确认 6 月 12 日成交，可以判 1，因为“窗口内发生过成交”已经成立；这依赖本题没有撤销、更正或最终确认延迟等额外条件。若现实任务要求最终不可撤销成交，必须补上确认规则。

练习五 截止 6 月 20 日不能使用 6 月 25 日才到达的记录。到了 6 月 25 日之后，可以把它作为历史事件的标签证据，但仍不能把成交价作为 6 月 1 日预测的输入。训练发生得晚，只使标签有机会成熟，不会使过去预测时点拥有未来信息。这是把预测时点与训练日期混同的典型错误。

练习六 复制一个正例后是 $6/9 \approx 66.7\%$ ；复制两个负例后是 $5/10 = 50\%$ 。未经约定的重复改变了各事件在统计中的权重。差异恰好小不代表流程正确：其他指标、其他重复组成或更大文件可能受影响不同；跨越训练测试的重复还可能改变评价含义。正确做法是核查身份与来源，而非只看结果变化是否顺眼。

练习七 可支持的有限说法是“在按所述规则收集、已成交且保留到测试中的记录上，这一预测规则获得了该误差”。不能直接推出它对所有挂牌、其他平台、其他时间或未成交对象同样可靠。给未成交价格填 0 会把“未发生可观察价格”误定义为“成交总价零”，从而改变任务和损失含义。若想研究每次挂牌的结果，可以另行定义成交发生与否或其他有明确含义的目标。

练习八 挂牌时不能使用三十天浏览统计，因为当时尚不可得。改在第 30 天预测时，至少要重新定义预测时点、未来标签窗口、仍符合资格的样本集合、所用浏览统计何时可读，以及早已成交或退出者怎样处理。还要重新构建历史回放，不能沿用原来的“挂牌起点预测”成绩。

练习九 房屋集合没有交集，楼栋集合的交集为 $\{B01, B02\}$ 。这个划分可以帮助研究同类已见楼栋内的新房屋，但不能直接证明对未见楼栋的能力。即使楼栋也分开，还需要检查时间、采样渠道和标签可用性等条件。答案不应把“按楼栋隔离”写成任何项目都必须采用的唯一规则。

练习十 一份示范是：一次预测针对图书馆的一次借阅；预测在借书办理结束时发生；目标是在约定归还期限后七天内是否仍未归还；输入来自当时已登记的书籍类别和借阅期限；标签根据后续归还记录及完整核实窗口确定；结论仅限该模拟馆的合成借阅流程。潜在未来字段是最终逾期罚款，潜在重复来源是同一借阅扫描两次。不要用真实读者姓名、身份证号或其他敏感资料完成练习。

二 实验标准标签及解释

E01 为 1。1 月 1 日到 1 月 10 日相差 9 天，1 月 11 日已登记，窗口内成交证据充分。R02 是同一事件的副本，不再计一次。

E02 为 1。1 月 2 日到 1 月 20 日相差 18 天，登记在截止日前，满足窗口条件。

E03 为 0。没有提供成交记录，但已有完整核实到 2 月 2 日的证据；这恰好是挂牌后第 30 天。

E04 为 0。1 月 4 日后第 30 天是 2 月 3 日；实际成交在 2 月 10 日，第 37 天。完整窗口已经核实，所以三十天标签为 0，而不是“从未成交”。

E05 为 1。1 月 5 日到 1 月 25 日相差 20 天，登记也在截止日前。

E06 为 0。完整核实到 2 月 5 日，窗口内没有成交。面积在挂牌次日才可读，是另一个输入问题，不会自动使已充分证实的标签失效。

E07 为 1。4 月 1 日到 4 月 15 日相差 14 天，4 月 16 日登记；虽然第 30 天还没到，已确认“窗口内发生过成交”足够判 1。

E08 未知。4 月 2 日到 4 月 20 日只观察了 18 天，未取得成交记录，也没有完整窗口证据。

E09 未知。4 月 10 日实际成交，但 4 月 22 日才登记；在本次截止日 4 月 20 日尚不可用。资料中的完整核实只覆盖到 4 月 9 日。到了 4 月 23 日，登记已可用，按同一规则可以判 1。

E10 为 1。3 月 10 日到 4 月 9 日恰好 30 天，窗口含结束端点，4 月 10 日已登记。

三 数据字典示范

以下每项都用于本讲合成设定。真实来源不明时不能照抄成真实来源证明。

raw_row_id: 每次导出写入的行编号，无数量单位，由合成导出流程提供；只能用于指认原始行，不能为空，原始文件中应唯一。它不是样本身份，不作特征。

event_id: 一次挂牌的稳定编号，由模拟平台生成，不能为空。它定义本讲样本单位；同一事件多个导出版本需要核查一致性。用于去重和追溯，不作特征。

house_id: 房屋实体编号，同一房屋可对应多次挂牌，不能为空。用于检查同实体关系、评价新房屋时的交集；不能仅凭重复房屋编号删除事件。

building_id: 楼栋编号，多套房屋可以共享，不能为空。用于检查组间重叠和界定对新楼栋的评价。它不代替房屋编号或事件编号。

listed_at: 挂牌接收日期, 也是本讲预测日期, 格式为年-月-日, 日期精度为天。窗口终点从这一天加 30 天; 本例假定同日已接收的挂牌信息在预测发生前可读。

area_sqm: 建筑面积, 单位平方米, 来自合成挂牌资料。空白将表示面积未提供, 不能填成 0; 在本文件没有空白, 但 E06 在预测当日尚不可读。候选输入, 要求数值大于 0 且可用日期不晚于预测日期。

area_available_at: 系统最早能读取该面积的日期, 由合成记录过程给出; 不是房屋建成日。没有此日期就无法证明当时可用。作为时间审计元数据, 不作预测答案。

list_price_wan: 当次挂牌的公开总要价, 单位万元, 来自挂牌时资料。它不是实际成交价。候选输入; 本文件均非空且大于 0; 仍需对应可用日期通过检查。

list_price_available_at: 挂牌总价最早可读日期。本例都与挂牌日相同, 并约定在预测前接收, 因而十次都通过当前日期精度下的检查。

sale_at: 符合本例成交定义的发生日期, 空白表示资料包没有提供这项事件, 不自动等同于“永不成交”。作为标签证据的一部分, 需与登记日期、窗口和完整随访结合。

sale_recorded_at: 该笔成交进入系统可供读取的日期, 应不早于 sale_at。截止日前不可读的记录不能参与该次历史重建; 它本身不是模型的挂牌起点特征。

sale_price_wan: 后来成交记录中的总价, 单位万元, 空白表示没有提供成交价格, 不表示 0。可用于另一个明确限定的价格任务作标签; 不能用于本讲挂牌起点的输入。可用时间按成交登记日期解释。

fee_wan: 合成设定的成交后费用, 单位万元, 恰为成交价的百分之一。不是任何真实税费或收费规则。空白为未提供。仅用来演示非法信息捷径, 不允许用作当前预测输入。

fee_available_at: 模拟费用最早可读日期, 晚于挂牌。本资料中七条非空费用均在未来; 未提供费用时对应日期也为空。

views_30d: 挂牌后完整三十天窗口累计浏览次数, 单位次, 非负整数。材料包回顾性提供它, 不代表过去能读到。本任务只能审计它, 不能在挂牌时使用。

views_available_at: 完整三十天浏览统计的可读日期, 本例设为窗口结束日。这是为日期级教学所作简化; 真实系统可能还存在计算延迟, 必须另行记录。

observed_through: 已经完整核实事件状态到的日期, 来源为合成核实过程。本例明确假定核实证据在该日期即可读; 若修改资料截止日, 只能使用不晚于它的核实范围。本值不能自动延长到新的截止日。它帮助确定负例, 不能替代未成熟窗口的未来证据。

四 特征审计与划分结果

面积的未来列表只有 E06; 挂牌价的未来列表为空。十个事件的三十天浏览统计全部在预测之后。七个非空费用都在预测之后, 分别是 E01、E02、E04、E05、E07、E09、E10; E03、E06、E08 没有费用。非空且数值正确, 不意味着符合预测时点要求。

坏划分没有相同 event_id，却共享 H01。楼栋交集是 B01、B02、B03。按楼栋隔离后，事件、房屋、楼栋交集均为空；测试侧只有 E10 已知标签。因此报告必须同时给出隔离结果与可评价数据量，不能只挑有利部分。

一月历史事件与三四月后续事件按时间分开，仍共享 H01。对未来已见房屋的再次挂牌，这可以属于真实使用情形；对全新房屋，这不符合宣称。决定是否允许共享需要任务说明，而不能仅用一个通用拆分函数代替思考。

五 一段合格的实验结论示范

本实验审计挂牌时预测三十天内成交的合成任务。十一行导出对应十次挂牌、九套房屋；R02 为 E01 的重复副本。去重后五个正例、三个负例、两个未知，已知标签中的正例比例为 62.5%。E06 面积晚到，完整窗口浏览量与成交后费用均不能作为挂牌时输入。坏划分共享 H01 及三栋楼；按楼栋隔离虽无交集，测试只剩一条已知标签。以上结果说明审计规则在指定例子上运行正确，不证明真实预测能力或总体成交比例。

这份结论交代了任务、对象、发现、处理和限制。你自己的表达不必相同，但应当包含足够信息，让读者无需猜测每个数字的分母和适用范围。