

读表清洗与可视化 习题详解

使用方式

先写自己的答案再核对。程序输出相同数字只完成一半；还要能解释每一步保留的是哪些事件、哪些列存在缺失，以及哪些假设来自数据字典。以下金额单位均为万元，面积单位均为平方米，数据均为课程合成。

第一题 三种计数

原始CSV有16条数据记录，不计表头。L003和L009分别在末尾完整复制了一次，因此去掉两条复制后是14次不同挂牌。H01对应L001和L013，H02对应L002和L014，这两套房屋各挂牌两次，所以14次挂牌只来自12套不同房屋。

事件数与房屋数不同不是质量错误。研究单位是挂牌事件时应保留复挂牌。可以用`len(raw)`、`clean.event_id.nunique()`、`clean.property_id.nunique()`分别核对三种计数，但不要认为三个计数必须相等。

第二题 一列数与一列表

`small["area_sqm"]` 返回Series，三条记录时形状为(3,); `small[["area_sqm"]]`返回DataFrame，形状为(3,1)。第二种写法中的内层列表说明“选择这些列”，即使列表只含一个列名，也仍保留表结构。

`iloc[0]`是当前第一位置，不是固定身份。按价格降序排序后，第一条就不再是L001。若把`event_id`设置为唯一索引，可用`loc["L001"]`按身份取行。若没有设置索引，也可用`clean.loc[clean.event_id.eq("L001")]`明确筛选。

第三题 读入约定

把001读成整数会变成1，丢掉前导零。如果编号是固定长度标识，前导零属于身份表示，不能为了看起来像数字就删掉。编号通常无需求均值，应按字符串保存。

本讲先保留空白与“未知”，是为了能指出两种原始缺失标记分别出现在L004与L010。随后按照字典统一为缺失。若一开始自动解释后又覆盖原文件，就难以回查原文。其他经过严格约定的数据也可以直接设置`dtype`与`na_values`读入；本题不是要求所有CSV永远先读成字符串。

第四题 来源行号不参与判重

`source_csv_line`每行都不同。若把它也放进判重列集合，哪怕六个原始字段完全一样，七列整体也不相同，两个复制就检查不出来。

原始CSV第1行是表头，L003复制在第16行，L009复制在第17行。它们对应从零开始的DataFrame位置14、15。位置编号、CSV行号、事件身份不能互换。正确做法是在新增来源行号之前保存原始列名，并以这些原始列作为subset。

第五题 错误的房屋去重

按property_id保留文件顺序中的第一条，会移出L013与L014。它们价格分别是110与118，总和少了228；新总和为 $2888-228=2660$ ，行数12，均价为 $2660/12 \approx 221.67$ 。

这个数描述“每套房屋按当前文件顺序保留一条”的价格，不再是十四次挂牌事件的均价。若真正要研究首次挂牌，应按确认过的时间规则排序并处理并列，不可把当前文件顺序默认为时间顺序。本例文件还刻意把一月复挂牌放在二月事件之后。

第六题 缺失不能当零

十四次挂牌中只有十二个已观测面积。面积和1220来自这十二个观测，所以其已观测均值为 $1220/12 \approx 101.67$ 。若计算缺失比例，分母才应使用全部十四次挂牌，即 $2/14 \approx 14.29\%$ 。这两个分母针对不同问题。

填零后求平均变成 $1220/14 \approx 87.14$ 。这个计算把缺失当作测得零面积，既没有新证据，也没有恢复真实值。探索表应保留缺失。若后续方法要求填补，应另列保存规则和填补标志。

第七题 合并行数

一个键在左侧出现a次、右侧出现b次，两边都有匹配时产生 $a \times b$ 个组合。N产生 $5 \times 2=10$ 个组合。其余S、E、W各有唯一右条目，对应3、3、2行；X没有匹配，但left保留它一行，因此总数为 $10+3+3+2+1=19$ 。

validate="many_to_one"要求右键唯一，候选片区表中N重复，应抛出MergeError。正确反应是核查右表冲突，不是删除validate以便让代码继续。右表存在多条记录可能是合法的一对多业务关系，但那时应承认输出行的含义已经改变。

第八题 合并改变均值

N的五个原始挂牌价为100、120、240、110、118，和为688。错误左合并将每个再计一次，于是总和为 $2888+688=3576$ ，分母19，均价 $3576/19 \approx 188.21$ 。

正确登记册的inner只保留有右表匹配的记录。L012代码X无匹配，其价格600被排除，于是总和 $2888-600=2288$ ，分母13，均价 $2288/13=176$ 。前者错误增加了权重，后者缩小了记录范围，二者都不能直接称为原来十四次事件的均价。

第九题 S组的三个分母

S包含L003、L004、L010，共3次事件，所以size=3。只有L003面积80已知，另外两条缺失，所以面积count=1，缺失数2，缺失比例 $2/3 \approx 66.67\%$ 。三个挂牌价160、180、260都已知，因此价格count=3、价格均值200。

面积均值80来自一个观测，只能概括这个已观测面积，不能说“南片区三套房屋平均面积80”。报告应并列给出总事件数、面积有效数和缺失数，必要时进一步核查缺失来源。本例片区和事件都是合成，也不能推广到真实地域。

第十题 线性插值逐步手算

四个面积已经排序，位置为0、1、2、3。规则为 $h=(n-1)q$ 。q=0.25时，h=0.75，在50与60之间走75%，得到 $50+0.75 \times (60-50)=57.5$ 。

q=0.5时，h=1.5，在60与100中间，得到 $60+0.5 \times 40=80$ 。q=0.75时，h=2.25，在100与130之间走25%，得到 $100+0.25 \times 30=107.5$ 。三个值都不是靠随机选择某个样本得到。

十四个挂牌价排序为100、110、118、120、140、160、180、180、200、220、240、260、260、600。q=0.25时h=13×0.25=3.25，位置3和4对应120、140，结果125。这里位置从0开始；若用中文的第几个数，应该说第4与第5个。

其他分位数定义可能给不同结果，不能只因不同就认定某一个软件错误。应核对是否采用了相同插值约定、相同已观测记录和相同排序值。

第十一题 直方图边界

七个箱依次是[40,80)、[80,120)、[120,160)、[160,200)、[200,240)、[240,280)、[280,320]。右圆括号表示不包含右端，最后一个箱右方括号表示包含320。

第一箱有50、60、70、50、60，计数5；第二箱有80、100、90、110，计数4；第三箱有120、130，计数2；第四、第五、第六箱都是0；最后箱有300，计数1。总数 $5+4+2+0+0+0+1=12$ 。

80属于第二箱，不属于第一箱。320如果出现，归最后箱。若范围外再出现350，它不会计入这些箱，应扩大边界或明确记录范围外数量。箱计数总和与有效样本数的检查可以抓住这个问题。

第十二题 散点图的缺席者

散点需要同时有横坐标面积与纵坐标价格。L004、L010面积缺失，因此十二条能画，另外两条不能画成普通观测点。把它们放在x=0会假造面积观测。

横轴范围40至140会把L012的面积300放在视窗外。正确图注可以写：“面积40至140平方米的局部放大图，L012（300平方米、600万元）位于视窗外；完整散点图含12个可画事件，另2个事件缺面积。”局部视窗不是删除记录，前提是你明确保留全体说明。

图中正向排列只说明这些合成观察存在关联；它没有控制位置、楼龄等因素，也没有改变同一房屋面积的实验，不能用于证明因果关系。

第十三题 极端值核查

至少应核查：原始录入是否有多余零；面积和价格单位是否一致；面积口径是否同为建筑面积；是否属于同一种研究对象；事件是否复制或键错位；源文件及生成说明是否确认这个记录。

本题数据说明明确保留L012，因此正确主分析应纳入。它影响均值较大只是在告诉我们均值对该观测敏感，不能成为“它错误”的证据。可以同时报告含它和不含它的描述对比，但要说明后者改变了事件集合。主结论不得悄悄切换为更好看的子集。

第十四题 训练范围与填补列

训练十个事件有九个已观测面积： $50+60+80+100+70+90+110+50+60=670$ 。训练填补参数为 $670/9 \approx 74.44$ 。L004属于训练、L010属于测试，但二者都应使用这个已经由训练确定的参数。

测试已观测面积120、130、300之和550。若混入测试，均值变成 $(670+550)/(9+3)=1220/12 \approx 101.67$ ，测试信息就参与了规则确定。即使没有测试标签，也违背本例封存测试的预处理约定。

保留area_sqm原列，新建area_imputed_sqm和area_was_missing。填补数字不应伪装成真实测量。这只是教学演示，没有训练或评估模型，因此不能声称哪一种填补提高了预测性能。

第十五题 报告参考与验收

参考开头：“本报告描述课程合成的十四次挂牌事件，来自十二套房屋，不代表真实市场。原始十六条记录中的L003、L009各有一次完全复制，移出复制后保持事件唯一。复挂牌L013、L014继续保留。”

质量段可写：“十四个挂牌价完整，十二个面积已观测、两个缺失。S片区三次事件中只有一个面积。以确认登记册作多对一左合并后仍为十四行，十三行匹配，L012代码X未匹配。极端面积300经教学说明确认，保留并标明。”

描述段可写：“挂牌价中位数180，按线性插值得到25%分位125、75%分位235。面积直方图采用40至320、步长40的边界，频数为5、4、2、0、0、0、1。散点图含十二个面积与价格都已知的事件。”

至少附直方图和散点图，写清横纵轴、单位、样本量和缺席记录。结尾说明合成来源、小样本、未知面积及未匹配登记等限制，不做真实房价或因果推断。最后列出版本和运行方式，让读者能用原始文件重算。

验收不是逐字复制上述参考，而是检查：三种身份计数是否分开；每个均值或比例的分母是否明确；合并关系与未匹配是否交代；图是否忠实显示范围；所有处理是否有依据且可回查。满足这些要求，即使报告用词和图形样式不同，也可以是合格答案。