

读表清洗与可视化 实验指南

本次实验要交什么

你将从随包的合成CSV开始，完成一份可复核的探索报告。重点是确认16条原始记录如何变成14次挂牌、为什么仍对应12套房屋，检查一次故意错误的合并，并画出带单位和样本量的图。实验不访问网络、不需要账号或付费服务，也不训练模型。

最终保留五样东西：运行过且保留输出的experiment.ipynb、原始data/raw文件夹、生成的outputs文件夹、自己的报告，以及你对至少一处故意错误的解释。不要用衍生表覆盖原始CSV。

一 找到正确文件夹

下载并解压第006讲文件包。你应看到experiment.ipynb、experiment.py、lecture.md、answers.md、data和figures。进入data/raw，应有listings.csv、district_candidates.csv、district_registry.csv、split_manifest.csv。文件名和层级要保持一致，不能只拷一个Notebook到空文件夹。

建议在自己的课程目录里建一个006_table文件夹，把本讲全部文件放入。路径可以有中文，但初次排错时较短路径更容易核对。不要把文件夹压缩包本身当作工作目录，也不要直接在电子邮件预览窗口里打开代码文件。

二 用Anaconda打开Notebook

如果前几讲已经创建课程环境，继续使用它。打开Anaconda Navigator，在对应环境中启动JupyterLab或Jupyter Notebook，在文件浏览器中进入本讲文件夹，再打开experiment.ipynb。若使用命令行，可先激活课程环境，切换到本讲文件夹，然后运行jupyter lab。

本讲参考版本为Python 3.12、Pandas 2.2.3、NumPy 2.3.5、Matplotlib 3.10.8。你不必为一个小版本差异立刻重装环境，但应记录自己的版本。代码会输出版本；若行为或错误与说明不同，先把版本和完整错误文本一起保存。

若出现ModuleNotFoundError，通常是当前Notebook内核缺少库，或者Navigator启动的不是你准备好的课程环境。先检查右上角内核名称，再在Anaconda中确认这个环境有pandas、numpy和matplotlib。不要把“在一个终端安装过”当成“当前内核一定可用”。按课程公共环境说明处理依赖，不需要安装新的付费工具。

本包已在独立Python进程启动的真实ipykernel进程内内核中按顺序执行全部代码单元并保存输出。构建环境没有实际操作你的Anaconda安装，也没有测试浏览器Jupyter界面和外进程套接字传输，因此本说明不把这些界面步骤描述为已替你验证。你的本地操作仍应以屏幕实际状态为准。

三 先学会三个按钮

点击一个代码单元，按Shift+Enter运行它并移到下一个单元。单元左边出现执行编号，表示它执行过；星号通常表示尚未结束。Markdown文字单元用于说明，不会像Python语句那样运算。

从上向下执行，不要先跳到画图单元。后面的代码需要前面建立的raw、clean、merged变量。看到NameError并不表示数据坏了，常见原因是尚未运行定义变量的单元。

要验证Notebook能独立复现，使用“Restart Kernel and Run All”或相近名称的菜单。它清掉旧变量后从头执行。只在一个已经运行很久的内核里单独点最后一格，可能借用了忘记记录的旧变量，不能算完整复现。

四 第一个检查点 读入原样文本

依次执行环境和路径检查单元。预期看到四个原始CSV均存在，然后读入listings.csv。首次读入使用dtype="string"和keep_default_na=False，目的是看见原始空白、中文缺失标记与空格。

你应看到shape为(16,6)。若出现(16,1)，可能分隔符与文件不一致；若列名异常，可能下载或保存方式改变了CSV结构；若FileNotFoundError，先确认Notebook与data文件夹同层，不要立即修改数据内容。

在tail输出中找L014、末尾L003和L009。用repr查看L014的原始area_sqm，首尾空格会被明确显示。再回答：如果只看head的五行，能否发现末尾的这些问题？

五 第二个检查点 行标签不是事件身份

运行选列、筛选和索引单元。单列Series形状为(16,)，单列表形状为(16,1)。这一步还在原始表上，所以有16条。随后在整理后表中按价格降序排序，比较iloc[0]与按event_id取得L001的结果。

不要只看两次打印都输出一行。写出它们各自代表什么：当前位置第一条，还是编号固定为L001的事件。用自己的话解释排序为什么会改变前者却不改变后者。

Notebook也有一个两列顺序相反的Series相除例子。计算是按L001、L002标签对应，而非盲目按显示顺序。这是Pandas与纯数组操作的重要区别。可以先手算两个比值再运行。

六 第三个检查点 只移出确认完全复制

运行重复检查单元。新增source_csv_line只用于追踪，判重字段限定原始六列。预期被移出的事件是L003、L009，CSV行号是16、17。

去掉这两条后，事件编号必须唯一，表应为14行。房屋编号仍有重复：H01、H02各出现两次。查看L001与L013的日期和价格，写出为什么它们不能跟完全复制一起删掉。

Notebook会演示给重复L003改一个价格会怎样。为了避免停止后续教学，预期异常被捕获并打印说明；真正清洗函数对这种冲突会抛出错误。成功拦住错误是检查通过，不是建议你关闭检查。

七 第四个检查点 解释缺失与类型

先去首尾空格，再把声明过的空白、“未知”变为缺失，最后转换面积、价格与日期。检查dtypes，并找到L004、L010两条缺面积记录。预期面积有效数12、缺失2、价格有效数14。

手算面积和为1220，已观测均值 $1220/12 \approx 101.67$ 。再运行填零反例，看均值变成约87.14。这个反例只创建临时结果，不修改clean的原始面积列。

若to_numeric遇到不认识的文本报错，不要把errors改成coerce后直接继续。先找出异常文本与来源行，判断数据字典是否允许它表示缺失。Notebook的故意非法文本示例展示了为什么需要这个停顿。

八 第五个检查点 合并前先猜行数

打开候选片区资料，找出N有两条，距离不同。纸上写下五个N事件与两个右条目如何配对，先猜总行数，再运行无约束合并反例。预期19行，均价约188.21。

下一格使用validate="many_to_one"，预期捕获MergeError。之后才加载题目提供的确认登记册，做带indicator的left合并。输出应为14行，both有13行，left_only有1行。找出L012，确认它没有消失。

再运行inner对比：剩13行，平均挂牌价176。把这些数字与正确14行的206.29对比，写两句话解释变化来自不同的记录权重和范围，并非市场变化。

九 第六个检查点 分组分母与手算

执行groupby摘要。N、S、E、W、X的事件数分别为5、3、3、2、1。面积有效数分别为5、1、3、2、1。分组后默认显示顺序可能按代码字母排序，不影响这组对应关系。

检查各组事件数相加是否等于14，面积有效数相加是否等于12。对S手算缺失率 $2/3$ 。价格均值需要价格count，面积均值需要面积count，不能因为在同一张表里就共用一个分母。

运行分位数单元前，先对50、60、100、130写出 $h=(4-1)q$ 。三个结果应是57.5、80、107.5。完整价格分位数的结果是100、125、180、235、600。本讲明确使用linear，不把其他插值方法的差异当作程序错误。

十 第七个检查点 先核计数再画图

面积边界固定为40、80、120、160、200、240、280、320。直方图计数应为5、4、2、0、0、0、1。总数是12；报告另两条缺面积。把边界改成40、180、320，计数变为11、1。数据没变，表示方法改变了。

Notebook绘图使用英文坐标文字，避免本地未安装中文字体。Area是建筑面积，单位平方米；List price以万元计；Observed event count是已观测挂牌事件数。随包figures里有讲义中文图，运行核心实验不要求你安装中文字体。

散点图只画面积与价格都已知的12条。仔细看L012的大面积点。若想放大其余点，另开一个明确标注的局部视图，保留完整图，不要覆盖全图后写“全部记录”。不要用散点图证明因果关系。

十一 第八个检查点 训练均值只来自训练

通过event_id与split_manifest做一对一合并。预期训练10个事件、测试4个，房屋编号没有交集。训练已观测面积9个，总和670，均值约74.44。测试缺失的L010使用同一个数，不重新计算测试均值。

检查新表的三列：area_sqm仍有两个缺失；area_was_missing标明它们；area_imputed_sqm把二者替代为训练均值。反例展示全数据均值约101.67，但不把这个反例当作正式输入规则。

本讲公开整份教学数据是为了手算核验，没有正式盲测或模型性能比较。请在报告里保留这个限制，不把两种填补值的差别写成预测效果差别。

十二 运行完整脚本再做交叉检查

所有探索步骤理解以后，再执行Notebook最后的完整流程验证单元。它调用experiment.py中的函数，生成审计与结果文件，并把关键结果与前面逐步计算的结果比较。当前包有43项脚本断言；Notebook还核对独立步骤结果。

你也可以在本讲文件夹打开Anaconda Prompt或终端运行：

```
python experiment.py
```

预期看到status为passed、test_count为43，以及关键摘要。脚本以自己的位置寻找输入，从其他当前目录调用也应能运行。不要改raw文件以使断言通过；如果故意练习修改数据，先复制整个实验文件夹，并记录你的改动及新的预期。

outputs中clean_events.csv是整理后事件；verified_join.csv含匹配状态；group_summary.csv含分组分母；cleaning_audit.csv记录字段修改和复制移出；district_conflicts.csv保存冲突；imputation_demo.csv区分原始与填补面积；summary.json保存数字；decisions.json写明保留和选用依据；raw_hashes.json记录输入摘要值。

同一个输出目录重复运行会重写这些衍生文件，不会覆盖data/raw。想保留一次试验，可先给输出目录换名字，或者运行python experiment.py --output-dir another_outputs。原始文件始终单独保存。

十三 常见问题排查

- 找不到文件：先核对相对层级，再核对文件名后缀是否真的为.csv或.ipynb。不要把下载自动添加的“副本”忽略掉。
- NameError：从顶部运行，或重启内核后Run All；确认不是跳过前面的变量定义。
- MergeError：本讲第一处候选合并故意触发，Notebook会解释并捕获；正式合并若仍报错，应检查右键重复，不要移除validate。
- 图中中文方框：核心代码可用英文标签；中文讲义图已提供。重画中文图需要中文字体，README列出可选说明。
- 数字相近但末尾小数不同：保留原始浮点结果，显示时可四舍五入；用合理容差比较，不要要求二进制小数完全逐位相等。
- 结果不同：先核对raw有16条、事件14个、价格总和2888、面积总和1220，再核对筛选、合并方式和当前内核。定位最早发生差异的一步，比反复重画最后的图有效。

十四 完成标准

提交前重启内核从头运行，保存输出。检查原始文件未变，核对16、14、12三个计数，能在日志中找到两个被移出的复制，能解释19行错误合并，能说明每张图的样本量与单位。报告至少含直方图、散点图、分组缺失说明和训练填补边界。

最后用一句话回答本讲核心问题：我怎样保证清洗后的数字仍在描述原先约定的事件？如果你的回答包含“身份、分母、合并行数、来源证据和审计记录”，说明你已经超越了只会调用函数的阶段。