

多元导数与链式法则

第十四讲 沿每条计算路径追踪局部变化

第十三讲研究一个参数：输入变一点，函数值怎样响应？现在一个预测器有两个参数，一次改动也可能同时经过多条计算路径。仅给一个“斜率”已经不够。我们需要区分每个坐标的变化率、任意方向的变化率，以及一整组输出对一整组输入的局部线性关系。

本讲从同一个两参数预测器出发，依次建立偏导数、梯度、全微分、方向导数与 Jacobian，再推导多元链式法则。手算的三条记录会贯穿图、代码和有限差分。最后故意制造漏路径、形状错误、定义域越界和“所有方向导数存在但仍不全微分”的情形，说明为什么算出一个数字还不是合格的导数结论。

直接先修是第九至十讲的向量、内积、矩阵形状与乘法，以及第十三讲的一元导数和局部余量。这里不使用 Hessian、特征值、SVD 或自动微分框架。所有数据无量纲且为原创合成记录；实验核查数学计算，不声称评估真实任务的预测能力。

一 先说清哪些数固定 哪些数在变

固定三条记录，输入依次为0、1、2，目标为1、2、2。记录编号为 $i = 1, 2, 3$ ，记录总数记为 $N = 3$ 。我们允许的预测形式是

$$p_i(a, b) = ax_i + b^2.$$

参数 a 控制输入项的比例，参数 b 通过平方进入共同偏移。写成向量为

$$\theta = \begin{pmatrix} a \\ b \end{pmatrix}, \quad p(\theta) = \begin{pmatrix} b^2 \\ a + b^2 \\ 2a + b^2 \end{pmatrix}.$$

这里 θ 是二维参数向量， p 是三维预测向量， x_i, y_i 是固定数据。对参数求导时，记录数量、输入与目标都不随参数改变。我们定义预测减目标的残差为 $r_i = p_i - y_i$ ，使用平均平方误差

$$L(a, b) = \frac{1}{3} [(b^2 - 1)^2 + (a + b^2 - 2)^2 + (2a + b^2 - 2)^2].$$

L 接受两个数，输出一个数； p 接受两个数，输出三个数。它们的导数对象不会有相同形状。先明确映射的输入输出，比先记住某个求导公式更重要。

为何不用自由截距 c ，而让偏移为 b^2 ？因为这样一个很小的模型就有真正的非线性内层，能看见链式法则中的 $2b$ 。代价是模型偏移只能非负，且 b 与 $-b$ 给出相同预测。它是一个特定参数化，不是所有线性预测器的通用写法。




图1 两个共享参数影响三条预测，预测再共同决定一个平均损失。数据在求导时保持固定，输出的个数决定后面导数矩阵的行数。

二 在同一个参数点建立手算基准

取起点

$$\theta_0 = \begin{pmatrix} 1 \\ 1/2 \end{pmatrix}.$$

此时 $b^2 = 1/4$ ，三条预测为 $(1/4, 5/4, 9/4)^T$ ，目标为 $(1, 2, 2)^T$ ，所以

$$r(\theta_0) = \begin{pmatrix} -3/4 \\ -3/4 \\ 1/4 \end{pmatrix}, \quad L(\theta_0) = \frac{1}{3} \left(\frac{9}{16} + \frac{9}{16} + \frac{1}{16} \right) = \frac{19}{48}.$$

这一步尚未求导，只是明确当前状态。损失 $19/48$ 是一个标量，不能告诉我们两个参数各应该怎样动。即使损失相同，不同起点的局部变化率也可能不同。

我们在图上用横轴 a 、纵轴 b 表示参数平面。某一点对应一整套共同参数，不对应一条数据记录。这个空间和左图中输入 x 、输出 p 所在的预测图是不同对象，不要把“沿参数 a 的方向”误认为沿某条样本的横轴移动。

三 偏导数只放开一个坐标

在 (a_0, b_0) 附近，若只改变 a 而保持 b 固定，得到一元函数 $a \mapsto L(a, b_0)$ 。它在 a_0 的导数叫 L 对 a 的偏导数：

$$\frac{\partial L}{\partial a}(a_0, b_0) = \lim_{h \rightarrow 0} \frac{L(a_0 + h, b_0) - L(a_0, b_0)}{h}.$$

类似地，

$$\frac{\partial L}{\partial b}(a_0, b_0) = \lim_{h \rightarrow 0} \frac{L(a_0, b_0 + h) - L(a_0, b_0)}{h}.$$

符号 ∂ 提醒我们函数有多个自变量，此次只让其中一个变化。每个偏导数在固定点是一个数；它不同时包含所有方向的变化率。求偏导时，把另一个独立参数当作常量，是在说明这次实验的约束，不是声称它在模型里不重要。[R1]

例如 $p_i = ax_i + b^2$ 中， $\partial p_i / \partial a = x_i$ ，因为 x_i 固定且 b^2 不随 a 变； $\partial p_i / \partial b = 2b$ ，因为 ax_i 不随 b 变。后一个结果随当前位置 b 改变。在主点 $b = 1/2$ 时是1，在 $b = 0$ 时是0，在 $b = -1/2$ 时是-1。




图2 固定 b 或固定 a 得到两条不同的一元切片。主点两个偏导数都是负数，但绝对值不同；每条切线只回答该坐标单独改变时的问题。

四 从增量分别推出两个损失偏导

不要先把整条公式背下来。固定 b ，将 a 改为 $a + h$ ，第 i 个残差变为 $r_i + hx_i$ 。因此

$$L(a + h, b) - L(a, b) = \frac{1}{3} \sum_{i=1}^3 (2hr_i x_i + h^2 x_i^2).$$

除以非零 h 并取极限，得到

$$\frac{\partial L}{\partial a} = \frac{2}{3} \sum_{i=1}^3 r_i x_i.$$

现在固定 a ，将 b 改为 $b + h$ 。由于 $(b + h)^2 - b^2 = 2bh + h^2$ ，每个残差都增加同一个数 $q = 2bh + h^2$ 。逐项平方展开并平均：

$$L(a, b + h) - L(a, b) = \frac{2}{3} q \sum_{i=1}^3 r_i + q^2.$$

除以 h 后，第一项变成 $\frac{2}{3} (2b + h) \sum r_i$ ；第二项为 $h(2b + h)^2$ ，随 h 趋零而消失。故

$$\frac{\partial L}{\partial b} = \frac{4b}{3} \sum_{i=1}^3 r_i.$$

因子2来自平方误差，因子 $2b$ 来自内层平方，除以3来自平均，而不是求导器凭空选择的常数。

在主点, $\sum r_i = -5/4$, $\sum r_i x_i = 0 - 3/4 + 2/4 = -1/4$ 。所以

$$L_a(\theta_0) = -\frac{1}{6}, \quad L_b(\theta_0) = -\frac{5}{6}.$$

下标 L_a, L_b 是偏导数的简写。有限步长会留下上述余量；只在极限中得到这两个准确局部系数。

五 梯度把偏导按参数次序排列

本课程采用列梯度约定：

$$\nabla_{\theta} L = \begin{pmatrix} \partial L / \partial a \\ \partial L / \partial b \end{pmatrix}.$$

符号 ∇ 读作梯度。它在固定点是一个二维向量，不是当前损失，也不是把两个偏导相加后的一个总斜率。主点梯度为

$$g = \nabla_{\theta} L(\theta_0) = \begin{pmatrix} -1/6 \\ -5/6 \end{pmatrix}.$$

给出小位移 $\Delta\theta = (\Delta a, \Delta b)^T$ ，我们希望线性部分为

$$g^T \Delta\theta = L_a \Delta a + L_b \Delta b.$$

左边是 1×2 乘 2×1 ，输出一个数，正好与损失变化的形状一致。若直接把梯度当标量加到损失上，形状已经不对；若只写 $L_a + L_b$ ，则暗中选择了速度 $(1, 1)^T$ ，不是任意方向的变化率。

例如 $\Delta a = 0.01, \Delta b = -0.02$ ，线性预测变化为 $-0.01/6 + 0.10/6 = 0.015$ 。虽然两个偏导都负，但这次 b 往负方向移动，而且幅度更大，总变化反而被预测为正。看梯度的符号，必须同时看实际位移。

六 全微分要求所有小位移都由同一个线性式控制

偏导只检查坐标轴方向。要合理使用 $g^T \Delta\theta$ 解释同时改变参数，需更强条件。设函数 f 在点 θ_0 的一个开放邻域有定义。若存在一个固定向量 g ，使

$$f(\theta_0 + h) = f(\theta_0) + g^T h + R(h), \quad \frac{|R(h)|}{\|h\|_2} \rightarrow 0 \quad (h \rightarrow 0, h \neq 0),$$

就称 f 在该点可微，也称全微分存在。这里 h 是向量， $\|h\|_2$ 是整个改变量的长度。要求覆盖所有足够小的合法 h ，而不是先挑几条路径验证。

线性映射 $h \mapsto g^T h$ 叫全导数或微分。常写 $df = g^T d\theta$ ； $d\theta$ 是交给这张线性映射的位移， df 是线性预测值。实际有限变化 Δf 还包含 R ，不应把 $df = \Delta f$ 当作一般精确等式。

若可微，沿坐标轴取 $h = te_j$ ，其中 e_j 的第 j 个分量为1，其余为0，即得第 j 个偏导数是 g_j 。因此全导数唯一，而且其系数必然是偏导；反过来，仅有偏导存在尚不足以保证统一线性近似。[R2]

我们的预测器可以直接验证：

$$p_i(a + h_a, b + h_b) - p_i(a, b) = x_i h_a + 2b h_b + h_b^2.$$

余量为 h_b^2 ，而 $|h_b| \leq \|h\|_2$ ，所以 $h_b^2 / \|h\|_2 \leq \|h\|_2 \rightarrow 0$ 。这说明每个预测分量都可微。下一节也将对损失本身给出余量控制，而不以“看起来平滑”代替证明。




图3 青色损失曲面附近的橙色切平面同时使用两个偏导。右图沿一个固定单位方向缩短步长，线性余量除以步长逐渐缩小；图提供核查，余量不等式提供一般结论。

七 主模型的局部线性式为何成立

在任意固定参数点，令 $r_i = ax_i + b^2 - y_i$ 。把参数改为 $(a + h_a, b + h_b)$ 后，残差改变量为

$$q_i = x_i h_a + 2b h_b + h_b^2.$$

平均平方误差的真实变化是

$$\Delta L = \frac{2}{3} \sum_i r_i q_i + \frac{1}{3} \sum_i q_i^2.$$

将第一项中的线性部分分离：

$$\Delta L = L_a h_a + L_b h_b + R(h), \quad R(h) = \frac{2}{3} \left(\sum_i r_i \right) h_b^2 + \frac{1}{3} \sum_i q_i^2.$$

令 $t = \|h\|_2$ ，只考虑 $0 < t \leq 1$ 。因为 $|h_a|, |h_b| \leq t$ 且 $h_b^2 \leq t^2 \leq t$ ，有

$$|q_i| \leq (|x_i| + 2|b| + 1)t.$$

于是

$$|R(h)| \leq \left[\frac{2}{3} \left| \sum_i r_i \right| + \frac{1}{3} \sum_i (|x_i| + 2|b| + 1)^2 \right] t^2.$$

中括号对固定点和固定数据是一个有限常数 C 。因此 $|R(h)|/\|h\|_2 \leq Ct \rightarrow 0$ 。这个不等式不挑方向，所以确实证明了本模型 L 在每个实参数点可微。它使用代数展开和长度界，没有提前调用二阶 Taylor 定理。

在较一般的计算中，一个常用充分条件是：各一阶偏导在该点某邻域内存在，并在该点连续，则函数在该点可微。这个定理很有用，但“偏导存在”不能替换“偏导在邻域有定义且连续”。本例还提供了独立的直接余量证明，避免把全部可信度寄托于一句性质名称。

八 偏导齐全仍可能没有全微分

考虑另一个用于检查定义的函数：

$$f(x, y) = \begin{cases} \frac{x^3}{x^2 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

它在原点连续，因为 $|f(x, y)| \leq |x| \leq \sqrt{x^2 + y^2} \rightarrow 0$ 。沿 x 轴， $f(h, 0) = h$ ，故 $f_x(0, 0) = 1$ ；沿 y 轴， $f(0, h) = 0$ ，故 $f_y(0, 0) = 0$ 。

如果全微分存在，线性部分必为 h_x 。沿对角线 (h, h) ，实际函数值为 $h/2$ ，所以与该线性式的余量为 $-h/2$ 。除以位移长度 $\sqrt{2}|h|$ ，其绝对值恒为 $1/(2\sqrt{2})$ ，不会趋于0。因此它在原点不可微。

这个例子甚至比“两轴检查不够”更强。沿任意非零方向 $d = (d_x, d_y)^T$ ，

$$\frac{f(td) - f(0)}{t} = \frac{d_x^3}{d_x^2 + d_y^2} \quad (t \neq 0).$$

所有这样的方向导数都存在，但它们对方向 d 的依赖不是同一个线性函数。对单位对角方向 $d = (1, 1)^T/\sqrt{2}$ ，实际导数为 $1/(2\sqrt{2})$ ，而把偏导向量 $(1, 0)^T$ 与 d 内积，会得到错误的 $1/\sqrt{2}$ 。




图4 反例在两条坐标轴上完全符合候选线性式，但在对角路径上留下与位移同阶的差。所有方向导数存在，也不能取代一个统一的线性近似条件。

因此后面使用“方向导数等于梯度内积”时，要先确认函数可微，或已满足足够的条件。不能先在不可微点把偏导排成一个向量，再把所有可微函数的几何结论自动贴上去。

九 方向导数回答沿给定方向每单位距离怎么变

给定单位向量 d ，即 $\|d\|_2 = 1$ ，定义

$$D_d L(\theta_0) = \lim_{t \rightarrow 0} \frac{L(\theta_0 + td) - L(\theta_0)}{t},$$

只要这个两侧有限极限存在。 t 是沿所选方向的带符号行进距离； d 只负责方向。因此要求单位长度不是装饰，而是让不同方向的速度比较有同一个尺度。

若 L 可微，代入全微分表达式：

$$L(\theta_0 + td) - L(\theta_0) = tg^T d + R(td).$$

因为 $\|td\|_2 = |t|$ ，余量除以 t 的绝对值趋零，所以

$$D_d L(\theta_0) = g^T d.$$

主点取 $d = (3/5, 4/5)^T$ ，长度平方为 $9/25 + 16/25 = 1$ ，得到

$$D_d L = -\frac{1}{6} \frac{3}{5} - \frac{5}{6} \frac{4}{5} = -\frac{23}{30}.$$

因此沿这个单位方向走足够小的正距离，损失会下降。步长0.01时，线性预测变化为 $-23/3000 \approx -0.00766667$ ，实际变化约为 -0.00749820 。二者接近但不相等。

若直接用向量 $v=(3,4)$ ，参数化路径的速度长5， $dL(\theta_0 + tv)/dt|_{t=0} = g^T v = -23/6$ 。这个数是对路径参数 t 的变化率，是单位方向变化率的5倍。它本身没有算错，错的是把不同速度的数叫作每单位距离的比较。[R4]

十 梯度方向 最陡变化与坐标尺度

对非零梯度 g 和单位 d ，由内积的 Cauchy-Schwarz 不等式，

$$-\|g\|_2 \leq g^T d \leq \|g\|_2.$$

取 $d = g/\|g\|_2$ 达到最大值，取 $d = -g/\|g\|_2$ 达到最小值。所以在当前欧氏长度定义下，正梯度是局部一阶上升最快方向，负梯度是下降最快方向。若 $g=0$ ，每个方向的一阶变化率都是0，不能据此判断最小值。

主点 $\|g\|_2 = \sqrt{26}/6$ ，单位下降方向为 $(1, 5)^T/\sqrt{26}$ 。方向 $(5, -1)^T/\sqrt{26}$ 与梯度垂直，内积为0，只表示该方向的一阶项消失，并非有限移动后函数值完全不变。




图5 参数平面的等损失线与局部方向。梯度垂直于经过该点的光滑等值线切向；负梯度给出相同欧氏长度预算下最负的一阶变化率，不保证大步移动一定下降。

这个“最陡”还依赖坐标尺度。若把第二坐标改记为 $c = 100b$ ，同一函数写成 $\tilde{L}(a, c) = L(a, c/100)$ ，则 $\partial \tilde{L} / \partial c = (1/100)L_b$ 。向量分量和坐标里的欧氏单位球都改变了，不能在未统一单位时比较谁的梯度数值更大就宣布谁更重要。

本讲研究无量纲参数，并固定当前坐标下的欧氏长度。如何选择优化步长、缩放或更一般几何属于后续问题；导数提供局部系数，不替代这些建模决定。

十一 多输出函数需要 Jacobian

对一般向量函数 $F: \mathbb{R}^d \rightarrow \mathbb{R}^m$ ， F 有 m 个输出分量，输入有 d 个坐标。若各分量可微，线性近似写为

$$F(\theta + h) = F(\theta) + J_F(\theta)h + R_F(h), \quad \frac{\|R_F(h)\|_2}{\|h\|_2} \rightarrow 0.$$

J_F 叫 Jacobian 矩阵，采用“输出为行、输入为列”的约定：

$$(J_F)_{ij} = \frac{\partial F_i}{\partial \theta_j}, \quad J_F \in \mathbb{R}^{m \times d}.$$

第 j 列表示只改变第 j 个输入时，所有输出的一阶变化；第 i 行表示第 i 个输出对所有输入的偏导。它是整个局部线性映射在坐标中的矩阵，而不是一个额外需要取平均的统计量。有限个分量的余量各自除以位移长度都趋零时，余量向量的欧氏长度除以位移长度也趋零，所以分量可微能组成这一向量可微结论。[R5]

对标量函数 L ，输出只有一个，因此 J_L 是 $1 \times d$ 行矩阵。在我们采用的列梯度约定下，

$$J_L = (\nabla L)^T.$$

全导数这个线性映射用行矩阵作用于位移；梯度是与它通过欧氏内积对应的列向量。二者含相同分量但方向和角色不同。其他文献可能采用行梯度，但一份推导中不能前后换约定。

Jacobian 矩阵也不等于 Jacobian 行列式。我们的 3×2 预测 Jacobian 连方阵都不是，不能取普通行列式。这里研究的是变化率映射，不涉及积分换元中的面积或体积系数。

十二 把预测 Jacobian 写成可检查的三行两列

对当前模型，

$$J_p(a, b) = \begin{pmatrix} 0 & 2b \\ 1 & 2b \\ 2 & 2b \end{pmatrix}.$$

第一列是固定输入向量 $(0, 1, 2)^T$ ，第二列每个数都是 $2b$ ，因为共同偏移影响所有记录。在主点

$$J_p(\theta_0) = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 2 & 1 \end{pmatrix}.$$

它的3行是三条预测，2列是参数a和b。损失平均中的1/3还没有出现，因为此处只求预测函数的导数，没有求平均损失。




图6 Jacobian 中每个位置都有输出行与输入列的含义。主点第二列全为1来自 $2b$ ，而不是把所有参数导数都设成1。

取位移 $h = (0.01, -0.02)^T$ ，线性预测变化为

$$J_p h = \begin{pmatrix} -0.02 \\ -0.01 \\ 0 \end{pmatrix}.$$

实际变化还要为每一行加上 $h_b^2 = 0.0004$ ，所以为 $(-0.0196, -0.0096, 0.0004)^T$ 。第三个预测的一阶项为0，实际有限变化仍非零。这是局部线性与精确变化之间最直接的三项核对。




图7 同一参数位移经 3×2 Jacobian变为三维预测改变量。每条输出的精确改变量都比线性值多出0.0004，这是 b^2 内层的已知余量。

十三 先区分坐标偏导与路径上的总变化率

假设参数同时随一个新变量 t 变化： $a = a(t)$ 、 $b = b(t)$ 。外层 L 仍是二元函数，沿路径的复合函数则为一元函数 $\ell(t) = L(a(t), b(t))$ 。在 L 可微、路径在该点可导且复合附近有定义时，

$$\ell'(t) = L_a(a(t), b(t))a'(t) + L_b(a(t), b(t))b'(t).$$

例如 $a(t) = 1 + t$ 、 $b(t) = 1/2 - 2t$ 。在 $t=0$ ，速度为 $(1, -2)^T$ ，所以 $\ell'(0) = -1/6 + 10/6 = 3/2$ 。这里 L 对 a 的偏导仍是 $-1/6$ ； $3/2$ 是沿整条指定路径的总变化率。不能把二者都含糊称为“对 a 求导”。

如果 b 本来就是 a 的函数，例如 $b = 2a$ ，那么沿这一约束关系求 $L(a, 2a)$ 的一元导数要包含 b 路径： $dL(a, 2a)/da = L_a + 2L_b$ ，并在 $(a, 2a)$ 处求值。把 b 当常量得到的是另一个问题的偏导。

这也解释了图5的等值线关系：若一条可导路径上 L 保持常值，则沿路径的导数为0，所以 $g^T \theta'(t) = 0$ 。当切向速度非零时，它与梯度垂直；这里说的是当前位置的切向，不是整条曲线必须是一条直线。

路径公式本质上是 1×2 的 J_L 乘 2×1 的路径速度。这为一般多元链式法则提供了第一个尺寸清楚的例子。

十四 多元链式法则就是局部线性映射复合

设 $F: \mathbb{R}^d \rightarrow \mathbb{R}^m$ ， $G: \mathbb{R}^m \rightarrow \mathbb{R}^q$ 。要求 F 在 θ_0 可微， G 在 $z_0 = F(\theta_0)$ 可微，并且附近的复合 $G(F(\theta))$ 有定义。则

$$J_{G \circ F}(\theta_0) = J_G(F(\theta_0))J_F(\theta_0).$$

维度是 $(q \times m)(m \times d) = q \times d$ 。矩阵乘法的次序对应实际计算：输入位移先经内层 J_F ，再经外层 J_G 。外层矩阵还必须在内层输出 $F(\theta_0)$ 处求值，不能随便在原参数点取值。[R3, R5]

本节向量范数均指欧氏长度。下面从余量说明为什么这个公式合法，而不是把偏导符号当成普通分数约掉。记 $A = J_F(\theta_0)$ 、 $B = J_G(z_0)$ ，有

$$F(\theta_0 + h) - F(\theta_0) = Ah + r_F(h) = k,$$

$$G(z_0 + k) - G(z_0) = Bk + r_G(k).$$

代入第一式后得到

$$G(F(\theta_0 + h)) - G(F(\theta_0)) = BAh + Br_F(h) + r_G(k).$$

关键是后两项除以 $\|h\|$ 后都趋零。固定有限矩阵 B 总存在常数 C_B 使 $\|Bv\| \leq C_B\|v\|$ ：对每行使用内积不等式再将平方相加，便可取 $C_B = \sqrt{\sum_{i,j} B_{ij}^2}$ 。于是 $\|Br_F(h)\|/\|h\| \rightarrow 0$ 。

同时， F 可微保证 $\|k\|/\|h\|$ 在足够近处有有限上界，因为 $k = Ah + r_F(h)$ 。当 $k \neq 0$ 时，

$$\frac{\|r_G(k)\|}{\|h\|} = \frac{\|r_G(k)\|}{\|k\|} \frac{\|k\|}{\|h\|} \rightarrow 0.$$

当 $k = 0$ 时，外层余量 $r_G(0) = 0$ ，该项本来就是零，无需除以 $\|k\|$ 。因此余量符合可微定义，主线性映射就是 BA 。这个证明也适用于内层导数为零的情形，不需要假设每次中间变量都有非零增量。

图中最右下角的1只是损失对自身的导数 $\partial L/\partial L = 1$ 。从这个恒等关系逐次使用已证明的链式法则，就能整理出其他变量的敏感度；这里没有假设额外的自动求导算法。

形状说明为何变化量正向传递 梯度使用转置组合




图8 输入到中间量再到输出的三段形状。变化量沿正向相乘时，右边先作用；转成列梯度时要按转置后的次序组合。

十五 用分量把求和路径看出来

当外层是标量函数 $G(z_1, \dots, z_m)$ ，内层各输出为 $F_i(\theta)$ 时，固定第 j 个参数，有

$$\frac{\partial(G \circ F)}{\partial \theta_j} = \sum_{i=1}^m \frac{\partial G}{\partial z_i} \frac{\partial F_i}{\partial \theta_j}.$$

每一项都对应从参数 θ_j 经过一个中间分量 z_i 再到输出的路径。沿一条路径变化率相乘，存在多条路径时贡献相加。这里加的是带符号贡献，抵消可能完全合法。

这正是矩阵乘法第j列的展开，而不是另一个独立规则。若只挑一条“看上去最直接”的路径，通常会漏项；若同一个共享中间量在两处使用，还必须收集它两处使用产生的贡献。

对我们的损失，外层写成 $G(p) = \frac{1}{3} \sum_i (p_i - y_i)^2$ ，其列梯度为

$$\nabla_p G = \frac{2}{3} (p - y).$$

因而

$$\nabla_\theta L = J_p^T \nabla_p G.$$

为什么是 J_p^T ？标量链式法则先给行矩阵 $J_L = J_G J_p$ ，两边转置，得到 $\nabla_\theta L = J_p^T \nabla_p G$ 。或者从 $\Delta L \approx (\nabla_p G)^T \Delta p$ 与 $\Delta p \approx J_p \Delta \theta$ 出发，整理成 $\Delta L \approx (J_p^T \nabla_p G)^T \Delta \theta$ 。两条解释都无需求逆。

十六 逐项算出 J 转置乘输出梯度

主点的输出梯度为

$$\nabla_p G = \frac{2}{3} \begin{pmatrix} -3/4 \\ -3/4 \\ 1/4 \end{pmatrix} = \begin{pmatrix} -1/2 \\ -1/2 \\ 1/6 \end{pmatrix}.$$

它是 3×1 ，因为现在关注的是三个预测分量各自变化时，损失怎样响应。再乘 2×3 的 J_p^T ：

$$\nabla_\theta L = \begin{pmatrix} 0 & 1 & 2 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1/2 \\ -1/2 \\ 1/6 \end{pmatrix} = \begin{pmatrix} 0 - 1/2 + 2/6 \\ -1/2 - 1/2 + 1/6 \end{pmatrix} = \begin{pmatrix} -1/6 \\ -5/6 \end{pmatrix}.$$

第一行收集每条预测经过比例参数a的贡献；第二行收集每条预测经过共同偏移参数b的贡献。第二行各系数恰好都是1，只因为主点 $2b = 1$ 。如果换到 $b = 0$ ，第二行会全为0，但输出残差未必为0。




图9 主点三个预测的损失敏感度被 J 转置合成为两个参数的敏感度。对参数 a 的第三条贡献为正，与第二条负贡献部分抵消；损失仍是一个非负标量。

梯度是损失在当前坐标下的一阶系数，不是每条样本各配一个独立参数。输出梯度与参数梯度长度不同，是正常的；错误地要求二者长度相同，会破坏整条形状链。

十七 用独立代数展开再次核对

仅把同一个链式公式复制成两段代码，不能算强独立核验。我们把损失完全展开：

$$L(a, b) = \frac{5}{3}a^2 + 2ab^2 - 4a + b^4 - \frac{10}{3}b^2 + 3.$$

各项来源可逐条检查：三个 a^2 系数之和为 $0^2 + 1^2 + 2^2 = 5$ 再除以 3；交叉项 $2ab^2$ 来自 $2ab^2(0 + 1 + 2)/3$ ；线性 a 项来自 $-2a(0 \cdot 1 + 1 \cdot 2 + 2 \cdot 2)/3 = -4a$ ；目标平方平均为 $(1 + 4 + 4)/3 = 3$ 。

按一元规则逐项求偏导：

$$L_a = \frac{10}{3}a + 2b^2 - 4,$$

$$L_b = 4ab + 4b^3 - \frac{20}{3}b.$$

代入 $(1, 1/2)$ 得到 $-1/6$ 与 $-5/6$ ，和增量推导及 $J_p^T \nabla_p G$ 完全一致。配套程序将这三条解析路线分开实现，再与只调用损失值的有限差分比较。三者不是逻辑上互不相关的定理，但独立表达能帮助发现漏因子、错平均或转置错误。

十八 共享节点的分支不能少算一次

再看一个刻意有分支的小标量计算：

$$s = a + b, \quad t = a - b, \quad z = s^2 + st.$$

s 被使用了两次，一次进入平方，一次进入乘积； a 和 b 又都通过 s 与 t 影响 z 。因此计算图不是单链。将外层看成两个中间量的函数 $K(s, t) = s^2 + st$ ，在 s 与 t 暂作独立坐标时， $K_s = 2s + t$ ， $K_t = s$ 。

内层 Jacobian 是

$$J_{(s,t)} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$


所以外层行导数乘内层矩阵：

$$J_z = (2s + t \quad s) \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = (3s + t \quad s + t).$$

主点 $a = 1, b = 1/2$ 给出 $s = 3/2, t = 1/2$ ，因而 $z = 3, \nabla z = (5, 2)^T$ 。

若按完整路径逐条数，对 a 的三条贡献是： a 到 s 再到平方给 $2s = 3$ ； a 到 s 再到乘积给 $t = 1/2$ ； a 到 t 再到乘积给 $s = 3/2$ 。相加为5。对 b ，前两条同样为3和1/2，第三条因为 $\partial t / \partial b = -1$ 而给 $-3/2$ ，相加为2。

共享 s 节点同时通向平方与乘积



局部系数只固定当前节点的其他输入；原参数的总影响要走全部路径

图10 共享节点 s 有两个后续用途，每个都贡献局部变化。线条交叉处不是额外节点。边上标注局部系数，沿路径相乘后求和；主点 a 的三条贡献为3、1/2、3/2， b 的最后一条为负。

直接展开 $z = (a + b)^2 + (a + b)(a - b) = 2a^2 + 2ab$ ，可再得到 $z_a = 4a + 2b$ 、 $z_b = 2a$ 。若只留下 s 的平方路径，就会错得很稳定，甚至可以把错误公式写成运行无异常的代码。

这里是在手工组织链式法则，不默认你已经学会任何自动微分框架。之后学习计算图求导时，仍需依靠本节的求和、乘积、求值点和形状约定判断结果。

十九 定义域与可微条件必须沿整个复合检查

主模型是多项式，数学定义域为整个 $\mathbb{R}^2$ 。这让我们能够在每个有限参数点从所有足够近方向考虑变化；程序浮点范围有限，是另一层数值限制。

若改成 $H(a, b) = \ln(a - b^2)$ ，就必须先要求

$$D = \{(a, b) : a > b^2\}.$$

在这个开放区域中，内层 $z = a - b^2$ 为正，外层实对数可导，所以

$$\nabla H = \begin{pmatrix} 1/z \\ -2b/z \end{pmatrix}.$$

例如 $(2, 1/2)$ 给出 $z = 7/4$ ，梯度为 $(4/7, -4/7)^T$ 。边界 $a = b^2$ 处，对数没有定义，不能只把分母写成0然后继续谈该点梯度。

差分采样也必须留在定义域内。点 $(0.26, 0.5)$ 合法，因为 $z = 0.01$ ；但沿 a 使用步长0.1的中心差分会采到 $a = 0.16$ ，内层为负，不能把此处报错当成解析梯度错误。

链式法则给出充分条件，不是所有复合函数可微的必要条件。例如外层绝对值在0不可导，内层 $a^2 + b^2$ 处处非负，复合 $|a^2 + b^2| = a^2 + b^2$ 却在原点可微。条件失败时需要重新分析原函数，不能盲套链式公式，也不能直接断言复合必不可微。

二十 梯度为零与一次移动的有限效果

在 $\theta_* = (6/5, 0)^T$ ，主模型两个偏导都为0。但这不是损失最小点。只改变 b 为一个小数 t ，有

$$L(6/5, t) - L(6/5, 0) = t^4 - \frac{14}{15}t^2,$$

对足够小的非零 t 为负。只改变 a 为 $6/5 + t$ 、保持 $b = 0$ ，则

$$L(6/5 + t, 0) - L(6/5, 0) = \frac{5}{3}t^2 > 0.$$

同一点附近有上升和下降方向；一阶项全部为0，只说明一阶近似暂时看不见这些差异。程序在 $t = 0.1$ 时得到起点损失0.6，改变 b 后的损失约0.59076667，改变 a 后的损失约0.61666667。这个判断来自精确多项式差，不需要先学二阶导数判别法。

同样，当梯度非零时，负梯度只保证充分小的正向步长存在下降趋势。它没有给出“任意步长均下降”的承诺。第十五讲将研究更高阶局部变化，后面的优化课程再讨论怎样选择步长。本讲先把局部一阶结论的边界说清楚。

二十一 有限差分怎样核对多元公式

对第 j 个参数，令 e_j 为相应坐标单位向量，中心差分为

$$\hat{g}_j(h) = \frac{L(\theta + he_j) - L(\theta - he_j)}{2h}, \quad h > 0.$$

每次只扰动一个坐标，其他坐标保持不变，依次组成梯度估计。若输出是向量 p ，使用同样两次调用后得到一整列：

$$\hat{J}_{:,j}(h) = \frac{p(\theta + he_j) - p(\theta - he_j)}{2h}.$$

冒号表示取所有输出行。若把这些结果误按行堆叠，会得到转置后的形状。使用3个输出、2个参数而不是全是2的正方形例子，能让形状错误更容易暴露。


还可以沿单位方向 d 做一次方向差分，比较 $[L(\theta + hd) - L(\theta - hd)]/(2h)$ 和 $g^T d$ 。它能核对梯度对组合方向的预测，但单个方向仍不能检验所有分量。若错误向量恰好与 d 正交，这一次投影就可能看不见错误。

本实验在25个固定参数点分别比较求和梯度、展开梯度、链式梯度、损失中心差分，以及预测 Jacobian 的逐列差分；不使用随机数。通过意味着实现与已知解析例子一致，不构成对所有实参数的证明。

二十二 步长不是越小越可信

本例沿 a 的损失是二次式，精确实数中心差分恰好等于 L_a ；沿 b 的损失含 b^4 ，中心差分的精确误差为 $4bh^2$ 。在 $b = 1/2$ 时等于 $2h^2$ 。这个事实来自将 $(b + h)^4$ 和 $(b - h)^4$ 相减后的直接展开，不需要预先知道一般高阶误差公式。

沿主例单位方向 $d = (3/5, 4/5)^T$ ，将整条一元路径的多项式展开后，中心差分与方向导数之差精确为 $(224/125)h^2$ 。Fraction 单元在 $h=1/100$ 时核查这一等式；浮点差分还会叠加表示和消减误差。



h=1e-16 与 1e-20：采样点无法分辨，明确拒绝，未当作零误差

图11 扫描步长时，中心差分先接近解析梯度，过小后因浮点误差反而变差。不可分辨的采样步长被拒绝，没有画成“零误差”。

实际NumPy 2.3.5运行中，主点中心差分最大分量误差在 $h=10^{-2}$ 时约 2×10^{-4} ，在 $h=10^{-6}$ 时约 5.01×10^{-11} ，在 $h=10^{-12}$ 时约 5.56×10^{-5} 。再缩至 10^{-16} ，至少一个参数的加法不再产生可辨认的新浮点点，程序明确拒绝。

这些误差数值是当前环境与当前例子的观测，不能当作任何函数的最佳步长表。代码同时记录名义 h 和实际浮点采样位移，避免误把“写了 h ”当成“计算机真的移动了 h ”。差分核查应看一段合理步长区间的相符情况，也要独立检查定义域与可微性。

二十三 从数学列向量到 NumPy 数组

数学中我们将梯度写成 2×1 列向量。程序遵循前面数组课程的简洁约定，单向量储存为一维数组，梯度形状为 $(2,)$ ，预测和输出梯度为 $(3,)$ ，Jacobian为 $(3,2)$ 。一维数组没有独立的行轴与列轴， $g.T$ 仍是 $(2,)$ ，不能把它当成显示的 1×2 行矩阵。

因此常用代码 `J.T @ output_gradient` 返回 $(2,)$ ，而显式列形式 `J.T @ output_gradient[:, None]` 返回 $(2,1)$ 。两者的两个数应一致，但尺寸契约不同。[R6] 先说明约定，再使用省略，不要让NumPy的维度提升规则替你决定数学含义。

广播是另一个陷阱。如果预测 p 为 $(3,)$ ，目标 y 误写成 $(3,1)$ ， $p-y$ 会产生 3×3 结果，每条预测与每条目标都配了一次，而不是三个逐记录残差。本实验在计算前严格拒绝这种形状，不用`squeeze`无条件压缩来隐藏错误。单样本 $N=1$ 仍保持预测 $(1,)$ 和Jacobian $(1,2)$ ，不能意外掉成标量。




图12 三条正确残差与广播产生的九项差异不是同一个目标。形状检查需要先于数值比较；`allclose`允许广播，因此返回`True`也不能代替尺寸核验。

核心接口在转成浮点数前检查原始叶子，拒绝布尔值、数字字符串、复数和`object`数组，混合Python列表也检查。CSV读取是显式文本解析边界，允许把数值字段解析为实数；它与数学函数偷偷接受任何字符串是不同的接口约定。

差分数值比较采用公开的绝对与相对容差，且先比较形状。NumPy的`allclose`比较约为 $|\hat{g}_j - g_j| \leq \text{atol} + \text{rtol}|g_j|$ ，在零附近绝对容差尤其重要；它还允许广播，所以只能作为数值检查的一部分。[R7]

二十四 一份可复核的多元导数说明

看到一个新模型，不必立刻寻找整页矩阵求导表。先列出真正自变量、固定数据、每个中间输出的形状，以及可用定义域。然后识别一阶局部映射：标量输出的列梯度、向量输出的Jacobian、单条路径的速度，分别对应不同对象。

写复合公式时要回答四个具体问题：外层导数在哪个中间值求值？每条从参数到输出的路径是否都被计入？输入列与输出行的乘法是否对齐？当前点是否满足全微分和定义域条件？这些问题比看到代码能执行就放心更有帮助。

本讲主例以同一组分数贯穿：损失 $19/48$ ，梯度 $(-1/6, -5/6)^T$ ，预测Jacobian为 3×2 ，沿单位方向 $(3/5, 4/5)^T$ 的变化率为 $-23/30$ 。分支例用三条路径得到梯度 $(5, 2)^T$ ；反例则提醒我们，坐标偏导和所有方向导数的存在仍可能缺少统一线性近似。

配套实验让精确分数、独立代数表达与浮点差分相互核对，并保留失败条件。完成后，你能从一个小计算图独立写出正确形状的变化率，解释每个乘法与求和为何存在，而不是只抄一个名叫gradient的输出。

参考与核验

核查日期为2026年10月4日。以下一手作者教材和官方文档用于核验定义、条件、矩阵方向与接口，正文推导安排、数据与图为原创。参考材料中的例题未被复制。

- R1 OpenStax, Calculus Volume 3, 4.3 Partial Derivatives
- R2 OpenStax, 同书4.4 Tangent Planes and Linear Approximations, 核验全微分余量定义与连续偏导的充分条件
- R3 OpenStax, 同书4.5 The Chain Rule, 核验复合的可微条件与多路径求和
- R4 OpenStax, 同书4.6 Directional Derivatives and the Gradient, 核验单位方向与梯度内积
- R5 Bjorn Poonen, MIT 18.02 Lecture Notes, 2021, 8.4至8.5及10.2节, 核验输出为行的全导数矩阵与一般链式次序
- R6 NumPy 2.3, `numpy.matmul`, 核验矩阵与一维数组乘法形状
- R7 NumPy 2.3, `numpy.allclose`, 核验容差表达、参考值方向与广播条件