

曲率与局部近似

第十五讲 斜率相同的地方 为什么优化难度仍可能不同

梯度说明当前位置往哪里走会最先下降，但没有说明坡度随后变化得多快。两处的函数值与梯度可以完全相同，同样长的一步却可能在一处降低损失、在另一处升高损失。本讲要补上的信息是二阶变化：用 Hessian 描述梯度怎样改变，用二次型读出方向曲率，再用有余项的 Taylor 展开判断这些信息能支持多大的结论。

直接先修是第十二讲的特征值、特征向量与对称矩阵，以及第十四讲的多元导数、Jacobian 和链式法则。正文会重新说明需要的符号，但不会重新证明实对称矩阵的谱定理。全篇先讨论开放定义域内的无约束问题；边界与约束会改变极值判据。

我们继续使用第十四讲的四条无量纲合成记录和同一预测模型。它们足够让每个导数、驻点与余项都能独立核查。小实验只演示数学机制，不评价任何真实任务的预测能力，也不以曲面图代替证明。

一 相同切线容许不同的下一步

先看两个一元函数，参数 $\lambda > 0$ 决定弯曲程度：

$$q_\lambda(t) = t + \frac{\lambda}{2}t^2.$$

无论 λ 是1还是12，都有 $q_\lambda(0) = 0$ 、 $q'_\lambda(0) = 1$ 。在起点向负方向动，最初的变化率都为负。如果直接取相同位移 $t = -1/4$ ，结果却是

$$q_1(-1/4) = -\frac{7}{32} = -0.21875, \quad q_{12}(-1/4) = \frac{1}{8} = 0.125.$$

原因不是梯度算错了。共同的线性项都是 $-1/4$ ；二次项分别为 $1/32$ 与 $3/8$ ，后者足以抵消下降。对于这个精确二次函数，负向步长 $t = -\alpha$ 能降低原点值，当且仅当 $0 < \alpha < 2/\lambda$ 。曲率越大，可容许的一步越短。




图1 两条函数在原点有相同函数值与斜率。相同负向位移使蓝色函数下降，却使橙色函数上升；有限步的结果还受二阶变化影响。

本讲说的“方向曲率”是沿指定坐标和单位方向的二阶导数。它并非把曲线当几何对象后计算的另一种曲率公式。若更换参数单位，数值和“相同步长”的含义都会改变，比较时须固定坐标尺度。

二 固定数据和当前点

固定输入 $x = (0, 1, 2)^T$ ，目标 $y = (1, 2, 2)^T$ ，记录总数 $N = 3$ 。预测、残差与损失仍是

$$p_i(a, b) = ax_i + b^2, \quad r_i = p_i - y_i, \quad L(a, b) = \frac{1}{3} \sum_{i=1}^3 r_i^2.$$

参数列向量 $\theta = (a, b)^T \in \mathbb{R}^2$ ，损失 $L: \mathbb{R}^2 \rightarrow \mathbb{R}$ 。对参数求导时，输入、目标与记录数全部保持不变。平方偏移使 b 与 $-b$ 给出同一预测，且共同偏移不能为负。

在主点 $\theta_0 = (1, 1/2)^T$ ，前讲已算出

$$r = (-3/4, -3/4, 1/4)^T, \quad L_0 = \frac{19}{48}, \quad g = \nabla L(\theta_0) = \begin{pmatrix} -1/6 \\ -5/6 \end{pmatrix}.$$

本讲会重新核算这些数，而不把旧答案当作不可检查的输入。将损失完全展开，可得到另一条独立路径：

$$L(a, b) = \frac{5}{3}a^2 + 2ab^2 - 4a + b^4 - \frac{10}{3}b^2 + 3.$$

这不是任意数据的通用公式。系数 $5/3$ 来自三条输入平方的平均，其他系数也依赖固定记录。若更改 CSV，就必须重推展开式和所有已知答案。

三 从一阶近似到二阶近似

令 h 为从当前位置出发的参数位移，不是新参数本身。先定义一阶 Taylor 多项式

$$P_1(h) = f(\theta_0) + g^T h.$$

“多项式”是指关于位移 h 的表达式。它在 $h = 0$ 处与原函数有相同值与相同一阶导数。若 f 在 θ_0 可微，则

$$f(\theta_0 + h) = P_1(h) + R_1(h), \quad \frac{|R_1(h)|}{\|h\|_2} \rightarrow 0.$$

余项 R_1 是实际值减去近似值。记号 $R_1 = o(\|h\|_2)$ 表示余项除以位移长度趋零，不表示任何有限位移上的余项恰为零。也不能把这一阶条件自行加强为二次误差界。

二阶 Taylor 多项式增加一项：

$$P_2(h) = f(\theta_0) + g^T h + \frac{1}{2} h^T H h.$$

这里 H 是在同一个中心点计算的 Hessian。二阶多项式还与原函数共享该点的二阶导数。图2把两种近似放到同一条直线路径上：小范围内二阶项补上了切线遗漏的弯曲，远处高阶项仍能占据主要部分。




图2 在主点沿单位方向 (3/5, 4/5) 比较真实损失与两种 Taylor 近似。右图仅扩大位移范围，近似中心和模型均不改变。二阶近似的局部优势不等于全局准确。

四 Hessian 是梯度的局部变化矩阵

对标量函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，采用列梯度约定。Hessian 定义为梯度映射的 Jacobian：

$$H_f(\theta) = J_{\nabla f}(\theta), \quad (H_f)_{ij} = \frac{\partial}{\partial \theta_j} \left(\frac{\partial f}{\partial \theta_i} \right).$$

行 i 对应哪个梯度分量，列 j 对应改变哪个参数。 H 的形状是 $d \times d$ ； g 与 h 都是 $d \times 1$ ； $g^T h$ 与 $h^T H h$ 都是标量。 H 不是逐元素平方的梯度，也不是单个二阶导数。

若梯度映射在该点可微，则

$$\nabla f(\theta_0 + h) = \nabla f(\theta_0) + H_f(\theta_0)h + o(\|h\|_2).$$

这使 H 有可操作的含义：它把一个小参数位移映射成梯度变化的线性预测。 H 的对角项检查同一坐标的坡度变化，非对角项检查“改变一个参数会怎样改变另一个参数的坡度”。

本讲采用一个清楚的充分条件： f 在中心的开放邻域内属于 C^2 ，即一阶和二阶偏导数都存在且连续。此时混合偏导相等， $H = H^T$ 。不能只知道某一点的混合偏导存在，就自动断言可交换求导顺序。

为什么连续性能给出对称性？考虑一个小坐标矩形四角值的交错和。先沿第一坐标作差、再沿第二坐标作差，用两次一元中值定理，可把“交错和除以两边长之积”写成矩形内某点的一个混合偏导；反过来作差得到另一混合偏导。两种顺序的交错和本来相同。当矩形缩向中心，连续性保证两个中间点的导数分别趋向中心的两个混合偏导，因此它们相等。这是混合偏导交换定理的证明思路；完整高阶推广见 [R1]。




图3 主点 Hessian 的每个元素说明一个梯度分量对一个坐标的变化率。右图扫描全部平面单位方向，两条坐标轴的二阶导数虽然均正，某些斜向曲率仍为负。

五 一步一步算出主模型的 Hessian

前讲给出的两个一阶分量为

$$L_a = \frac{2}{3} \sum_i r_i x_i, \quad L_b = \frac{4b}{3} \sum_i r_i.$$

再次求导时，残差仍依赖参数。因为 $\partial r_i / \partial a = x_i$ 、 $\partial r_i / \partial b = 2b$ ，得到

$$L_{aa} = \frac{2}{3} \sum_i x_i^2, \quad L_{ab} = L_{ba} = \frac{4b}{3} \sum_i x_i.$$

对于 L_{bb} ，外面的 b 与里面的残差都要用乘积法则：

$$L_{bb} = \frac{4}{3} \sum_i r_i + \frac{4b}{3} \sum_i 2b = \frac{4}{3} \sum_i r_i + 8b^2.$$

固定三条数据后，可写成

$$H_L(a, b) = \begin{pmatrix} 10/3 & 4b \\ 4b & 4a + 12b^2 - 20/3 \end{pmatrix}.$$

在 θ_0 , $\sum r_i = -5/4$, 故

$$H_0 = \begin{pmatrix} 10/3 & 2 \\ 2 & 1/3 \end{pmatrix}.$$

这里最容易漏掉的不是复杂技巧, 而是 L_b 中残差对 b 的依赖。只对外面的 b 求导会漏 $8b^2$; 只对残差求导又会漏 $\frac{4}{3} \sum r_i$ 。

还可以把结果拆成两部分。记 J_p 为 3×2 的预测 Jacobian。对 $g = \frac{2}{3} J_p^T r$ 再求导可得

$$H_L = \frac{2}{3} J_p^T J_p + \frac{2}{3} \sum_i r_i H_{p_i}.$$

第一项半正定, 因为任意 h 满足 $h^T J_p^T J_p h = \|J_p h\|_2^2 \geq 0$ 。第二项保留预测模型本身的二阶变化, 可能产生负曲率。主点两项分别为

$$\frac{2}{3} J_p^T J_p = \begin{pmatrix} 10/3 & 2 \\ 2 & 2 \end{pmatrix}, \quad \frac{2}{3} \sum_i r_i H_{p_i} = \begin{pmatrix} 0 & 0 \\ 0 & -5/3 \end{pmatrix}.$$

若静默删除第二项, 就改变了 Hessian。非负损失函数完全可能在某些位置具有负方向曲率; “函数值非负”与“Hessian 半正定”是不同的陈述。

六 二次型把矩阵变成方向信息

对称矩阵 H 与向量 h 给出二次型 $h^T H h$ 。二维时令 $h = (h_a, h_b)^T$, 直接乘开:

$$h^T H h = H_{aa} h_a^2 + 2H_{ab} h_a h_b + H_{bb} h_b^2.$$

交叉项出现两次, 因为矩阵乘法同时包含 $H_{ab} h_a h_b$ 和 $H_{ba} h_b h_a$ 。Taylor 式外面的 $1/2$ 把它们合并成一个 $H_{ab} h_a h_b$ 。若忘掉 $1/2$, 所有二阶修正都会扩大一倍。

给定单位方向 $\|u\|_2 = 1$, 定义直线路径 $\phi(t) = f(\theta_0 + tu)$ 。连续使用链式法则:

$$\phi'(0) = g^T u, \quad \phi''(0) = u^T H u.$$

因此 $u^T H u$ 就是沿 u 每单位距离的二阶变化率, 沿该路径的二次项为 $\frac{1}{2} t^2 u^T H u$ 。 u 不归一化时, 改变的不只是方向, 还有移动速度; 若改用 $2u$, 二阶系数扩大4倍。

这条公式使用直线路径。如果参数沿弯曲路径 $\theta(t)$ 移动, 再求一次导数还会出现 $g^T \theta''(t)$ 。本讲所有方向扫描都固定为直线, 不能把结论直接套到任意弯曲轨迹上。

七 特征方向揭示椭圆和狭长谷地

由第十二讲的实对称矩阵谱定理, $H = Q \Lambda Q^T$, 其中 $Q^T Q = I$, Λ 的对角元为实特征值 λ_j 。令 $z = Q^T h$, 便有

$$h^T H h = z^T \Lambda z = \sum_{j=1}^d \lambda_j z_j^2.$$

变换到特征坐标后，交叉项消失。每个特征向量都是一个独立弯曲方向，对应特征值就是该单位方向的二阶变化率。谱定理在这里作为先修结果使用，不从“画起来像椭圆”反推它。

若所有特征值都正，称 H 正定；都负则称负定；既有正数又有负数则称不定；全非负为半正定，全非正为半负定。零矩阵同时半正定与半负定，但并不正定或负定。对于单位 u ，把 u 展开到特征基得到权重平方和为1，因此

$$\lambda_{\min} \leq u^T H u \leq \lambda_{\max}.$$

考虑一个独立的精确二次例子 $q(h) = \frac{1}{2} h^T A h$ ， A 的特征值为1与16，特征轴相对原坐标旋转30度。在特征坐标内， $q = \frac{1}{2}(z_1^2 + 16z_2^2)$ 。等高线 $q = c > 0$ 满足

$$\frac{z_1^2}{2c} + \frac{z_2^2}{2c/16} = 1.$$

两个半轴分别是 $\sqrt{2c}$ 与 $\sqrt{2c/16}$ ，长短轴比为4，不是16。后者是正定二次型的最大最小特征值比 $\kappa = 16$ 。这个比值描述各向异性，不能直接当作迭代次数或运行秒数。




图4 旋转后的正定二次型构成椭圆等高线。曲率大的方向允许的同等高度位移更短；特征值比16对应半轴长度比4。

八 二阶展开为什么成立

现在把公式的条件与余项补齐。设 f 在 θ_0 的开放邻域为 C^2 ，取 h 足够小，使整条线段 $\theta_0 + th$ ， $0 \leq t \leq 1$ 留在邻域内。定义 $\psi(t) = f(\theta_0 + th)$ ，注意此处 t 走到1，而 h 已包含全部位移。

链式法则给出

$$\psi'(0) = g^T h, \quad \psi''(t) = h^T H_f(\theta_0 + th) h.$$

我们只需一个一元结果：对 C^2 的 ψ ，存在 $\xi \in (0, 1)$ ，使

$$\psi(1) = \psi(0) + \psi'(0) + \frac{1}{2}\psi''(\xi).$$

这个中间点的存在可用 Rolle 定理证明。令 $A = \psi(1) - \psi(0) - \psi'(0)$ ，构造 $F(t) = \psi(t) - \psi(0) - t\psi'(0) - At^2$ 。有 $F(0) = F(1) = 0$ 且 $F'(0) = 0$ 。第一次应用 Rolle 定理得到某个 $c \in (0, 1)$ 满足 $F'(c) = 0$ ，第二次在 $[0, c]$ 应用得到 $F''(\xi) = 0$ ，从而 $A = \psi''(\xi)/2$ 。Rolle 定理本身是本段接受的一元基础定理；这里不偷偷引入尚未建立的积分公式。[R2]

代回并加減 $\frac{1}{2}h^T H_f(\theta_0)h$ ，得到

$$f(\theta_0 + h) = f(\theta_0) + g^T h + \frac{1}{2}h^T H_f(\theta_0)h + R_2(h),$$

$$R_2(h) = \frac{1}{2}h^T [H_f(\theta_0 + \xi h) - H_f(\theta_0)]h.$$

这里 ξ 依赖 h ，不是可以随意设成 $1/2$ 的固定点。设 $\|B\|_{\text{op}} = \max_{\|v\|_2=1} \|Bv\|_2$ 为算子范数，则由内积不等式

$$|R_2(h)| \leq \frac{1}{2}\|h\|_2^2 \|H_f(\theta_0 + \xi h) - H_f(\theta_0)\|_{\text{op}}.$$

H 在中心连续，且 $\|\xi h\|_2 \leq \|h\|_2$ ，所以最后的矩阵差趋零，对所有趋向中心的小位移都成立。这就证明

$$R_2(h) = o(\|h\|_2^2).$$

同时 H 在足够小的邻域有界，一阶余项由一个有界二次项加上更小项构成，故在这个更强的 C^2 条件下可以写 $R_1(h) = O(\|h\|_2^2)$ 。

九 小 o 和大 O 不是同一承诺

$R(h) = O(\|h\|^k)$ 意味着存在固定常数 C 和半径 $\rho > 0$ ，使 $0 < \|h\| < \rho$ 时 $|R(h)| \leq C\|h\|^k$ 。小 o 则要求比值趋零。两者都描述趋近中心的行为，不会自动给出半径到底有多大。

尤其要区分以下三种信息：可微保证一阶余项为 $o(\|h\|)$ ；邻域 C^2 保证二阶余项为 $o(\|h\|^2)$ ；要进一步使用统一的 $O(\|h\|^3)$ 界，需更强的控制。

例如，若同一邻域还满足 Hessian 的 Lipschitz 条件

$$\|H_f(\theta_0 + v) - H_f(\theta_0)\|_{\text{op}} \leq M\|v\|_2,$$

上节已经证明的余项式立即给出 $|R_2(h)| \leq (M/2)\|h\|_2^3$ 。这是有效但未追求最优常数的界。连续三阶偏导在更小闭邻域有界，是获得这类控制的一个充分条件；本讲不需要构造高阶张量。

只假设 C^2 时不能保证三阶界。一元反例 $f(t) = |t|^{5/2}$ 在零点满足 $f(0) = f'(0) = f''(0) = 0$ ，其二阶导数连续，因为 $f''(t) = \frac{15}{4}|t|^{1/2}$ 在 $t \neq 0$ 时趋零。但余项就是 $|t|^{5/2}$ ，除以 t^2 趋零，除以 $|t|^3$ 却发散。因此“二阶 Taylor”不等于“误差必然严格为三次”。

十 主模型有一个可直接验证的精确余项

多项式模型允许比一般定理更具体的回答。令 $h = (\Delta a, \Delta b)^T$ ，把 $(a + \Delta a, b + \Delta b)$ 代入完全展开式。按总次数收集，常数项、一阶项与二阶项恰为 $P_2(h)$ ，剩下

$$R_2(h) = 2\Delta a \Delta b^2 + 4b \Delta b^3 + \Delta b^4.$$

这是对固定三条数据成立的精确恒等式，不是只在极限中成立的写法。它含三次与四次项，没有把 b 换成新点的 b 。对于一般固定输入集合，第一项系数应为 $2\bar{x}$ ；本讲 $\bar{x} = 1$ 。

在主点 $b = 1/2$ ，若 $\|h\|_2 = r \leq \rho$ ，利用每个分量绝对值不超过 r ，有

$$|R_2(h)| \leq 2r^3 + 2r^3 + r^4 \leq (4 + \rho)r^3.$$

这是覆盖全部方向的上界，比仅检查一个方向更强。在 $r \leq 0.1$ 的范围内，可用 $4.1r^3$ 作保守界；并不承诺真实误差会恰好等于它。

沿单位方向 $u = (3/5, 4/5)^T$ ，令 $h = tu$ 。逐项代入后得到

$$L(\theta_0 + tu) = \frac{19}{48} - \frac{23}{30}t + \frac{5}{3}t^2 + \frac{224}{125}t^3 + \frac{256}{625}t^4.$$

这四个系数同时检验梯度、Hessian、混合项与余项。例如 $t = 0.1$ 时，一阶误差约为 0.0184996267，二阶误差约为 0.00183296； $t = 0.01$ 时分别约为 0.000168462763 和 0.000001796096。两种误差都是实际函数减去各自近似的绝对值。

但方向可使低阶项抵消。沿 $v = (-1, 1)^T / \sqrt{2}$ ，主点的三次系数 $2v_a v_b^2 + 2v_b^3$ 正好为零，二阶余项只剩 $t^4/4$ ；沿 $(1, 0)^T$ 则二阶近似完全精确。看到四阶误差不代表一般定理错误，也不代表其他方向都具有四阶误差。

十一 先确认驻点 再讨论极值形状

在开放定义域内部，若 f 可微且在 θ_* 有局部极小或局部极大，则每条坐标直线的一元限制都在原点有局部极值。因此每个偏导都为零， $\nabla f(\theta_*) = 0$ 。梯度为零的点叫驻点。这个必要条件不适用于任意边界点，也不是充分条件。[R3]

“局部极小”要求存在某个半径，在这个邻域内没有更小的函数值；“严格局部极小”还要求每个其他点的函数值严格更大。全局极小则比较定义域中的全部点。一个驻点如果每个邻域内都有比它大和比它小的值，本讲称其为鞍点。

回到主模型，解两个驻点方程：

$$\frac{10}{3}a + 2b^2 - 4 = 0, \quad 4b \left(a + b^2 - \frac{5}{3} \right) = 0.$$

不能直接除以 b ，否则会漏掉 $b = 0$ 。分情况求解：当 $b = 0$ ，第一式给出 $a = 6/5$ ；当 $b \neq 0$ ，由第二式 $a + b^2 = 5/3$ ，与第一式联立得 $a = 1/2$ 、 $b^2 = 7/6$ 。所以全部驻点只有

$$\left(\frac{6}{5}, 0 \right), \quad \left(\frac{1}{2}, \sqrt{\frac{7}{6}} \right), \quad \left(\frac{1}{2}, -\sqrt{\frac{7}{6}} \right).$$

主点 $(1, 1/2)$ 不在这个列表，且已知梯度非零。因此，无论其 Hessian 有什么符号，都不能把它叫作本讲定义下的驻点鞍点。




图5 同一模型有一个驻点鞍点和两处对称的极小点。橙色主点的 Hessian 不定，但它的梯度非零，不能由不定曲率直接命名为驻点鞍点。

十二 二阶判据以及它的证明

设 θ_* 是开放定义域内的精确驻点， f 在邻域为 C^2 。Taylor 展开中的一阶项消失，故

$$f(\theta_* + h) - f(\theta_*) = \frac{1}{2} h^T H_* h + o(\|h\|_2^2).$$

若 H 正定，最小特征值 $m > 0$ 。二次型满足 $h^T H h \geq m \|h\|_2^2$ ，而小 o 条件保证 h 足够小时 $|R_2(h)| \leq (m/4) \|h\|_2^2$ 。于是每个非零小位移都有

$$f(\theta_* + h) - f(\theta_*) \geq \frac{m}{4} \|h\|_2^2 > 0.$$

这证明严格局部极小，不只是“图像看起来像碗”。若 H 负定，对 $-f$ 使用同样论证即得严格局部极大。

若 H 不定，存在单位特征向量 u_+, u_- ，对应 $\lambda_+ > 0$ 、 $\lambda_- < 0$ 。沿 $h = tu_+$ ，二次主项为正；沿 $h = tu_-$ ，二次主项为负。对于各方向充分小的非零 t ，余项不会改变符号。因此每个邻域中都有更高与更低的值，驻点是鞍点。即使其他方向还有零特征值，只要确有一正一负，这个结论仍成立。

反过来，若 C^2 函数在内部有局部极小，任意方向的一元二阶导都不能为负，所以 H 必须半正定。正定是严格局部极小的充分条件，半正定是局部极小的必要条件，两者不能倒置。二维判别式 $D = f_{aa}f_{bb} - f_{ab}^2$ 是这些结论在两个变量下的快捷检查：D 小于零意味着一正一负；D 大于零时再看一个对角元的符号；D 等于零时不作结论。[R4]




图6 三个精确二次函数的原点都满足梯度为零。正定、负定与不定分别给出严格极小、严格极大和鞍点；判据同时依赖驻点条件与邻域光滑条件。

十三 零特征值留下了尚未回答的方向

考虑 $f_+(x, y) = x^2 + y^4$ 与 $f_-(x, y) = x^2 - y^4$ 。二者在原点的梯度均为零，Hessian 均为 $\text{diag}(2, 0)$ ，二阶多项式均为 x^2 。然而 f_+ 的原点是严格极小，因为除原点外两项之和严格正； f_- 的原点是鞍点，因为 x 轴上为正、 y 轴上为负。

二阶式在 y 方向完全看不见差别，高阶项才决定这个方向的符号。再看 x^2 ：同一 Hessian 却给出一整条非严格极小点集合 $x = 0$ 。零特征值不等于函数真的平坦，更不等于“这一参数不重要”。

甚至零矩阵也不决定形状。原点处 $x^4 + y^4$ 是严格极小， $-x^4 - y^4$ 是严格极大， $x^4 - y^4$ 是鞍点，它们的梯度与 Hessian 全相同。在这些例子里要回到原函数或更高阶项；不能为了强行分类而把计算出的零改成一个微小正数。




图7 左图两函数共享半正定 Hessian， y 方向的四阶项决定极小或鞍点。右图展示零 Hessian 下的不同结果。曲线重合处本来就应重合，不能靠二阶信息区分。

十四 主点的不定曲率与真正的驻点鞍点

主点 H_0 的特征值为 $13/3$ 与 $-2/3$ ，对应单位特征向量可以取

$$u_+ = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad u_- = \frac{1}{\sqrt{5}} \begin{pmatrix} -1 \\ 2 \end{pmatrix}.$$

矩阵两个对角元都是正数，仍有负特征值。只检查坐标切片会漏掉交叉项造成的向下弯曲。图8故意先减去切平面，再看剩余量的正负曲率；它并未声称实际函数值沿两个方向都由二次项主导。




图8 从实际函数减去主点的函数值和一阶项，才能单独观察二阶形状。原点附近两条特征方向分别向上弯和向下弯，但主点本身的梯度非零。

真正的驻点 $\theta_s = (6/5, 0)$ 满足

$$L(\theta_s) = \frac{3}{5}, \quad \nabla L(\theta_s) = 0, \quad H_L(\theta_s) = \begin{pmatrix} 10/3 & 0 \\ 0 & -28/15 \end{pmatrix}.$$

这里沿 a 的二阶变化正、沿 b 的二阶变化负，所以可应用驻点鞍点判据。还能直接验证：沿 a 方向 $L(6/5 + t, 0) - 3/5 = \frac{5}{3}t^2 > 0$ ；沿 b 方向 $L(6/5, t) - 3/5 = -\frac{14}{15}t^2 + t^4$ ，当 $0 < t^2 < 14/15$ 时严格负。

两处其他驻点的 Hessian 对角元为 $10/3$ 与 $28/3$ ，行列式为 $112/9 > 0$ ，因此都正定，得到两处严格局部极小。这一步本身尚未证明它们全局最优。

十五 全局最优需要另一份证据

对主模型，恰好可以给出独立的全局证据。把自由截距记为 $c = b^2 \geq 0$ ，再记 $A = a - 1/2$ ， $C = c - 7/6$ 。直接完成平方，得到恒等式

$$L(a, b) = \frac{1}{18} + \frac{5}{3} \left(A + \frac{3}{5}C \right)^2 + \frac{2}{5}C^2.$$

右边两个平方项处处非负，所以整个参数平面上的损失都至少为 $1/18$ 。等号成立当且仅当 $C = 0$ 且 $A = 0$ ，即 $a = 1/2$ 、 $b = \pm\sqrt{7/6}$ 。这才把“严格局部极小”升级为“两处全局极小”。这个证明连接第十一讲的带截距最小二乘，但结论来自这里展示的代数证书，而非偷偷假设非线性参数化是凸的。

作为对照， $F(x, y) = x^2 + y^2 - 2x^4$ 在原点梯度零、Hessian 为 $2I$ 。当 $|x| < 1/2$ ，有 $x^2 - 2x^4 \geq x^2/2$ ，所以原点是严格局部极小。但 $F(1, 0) = -1 < F(0, 0)$ ，它不是全局极小；原点二阶模型 $x^2 + y^2$ 在远处给出了相反印象。




图9 同一个函数的小邻域和大范围切片。正定 Hessian 正确证明了原点严格局部极小，却不能证明全局最优；远处的四次项改变了结论。

更一般的边界警告也很简单：在限制 $x \geq 0$ 上， $f(x) = x$ 的最小点是0，导数却为1。因为可行方向不再包括所有正负小位移，开放邻域里的驻点必要条件不适用。

十六 如何把近似误差变成可检查的实验

实验固定中心与单位方向，只改变位移长度 t ，分别计算 P_1 、 P_2 和真实损失。直接相减得到 $E_1 = |L - P_1|$ 、 $E_2 = |L - P_2|$ ；另一路由精确余项多项式计算同样的量。两条实现适合相互核对，也能暴露浮点相减的限制。




图10 普通方向的一阶和二阶误差分别约按二次和三次缩小，抵消方向的二阶误差约按四次缩小。右图中极小位移的直接相减受浮点舍入影响；代数余项仍非零。

若 t 缩小10倍，非零二次主项的误差约缩小100倍，三次主项约缩小1000倍。用相邻数据估计阶数时，可计算 $\log(E(t_1)/E(t_2))/\log(t_1/t_2)$ ，但只对正误差和未进入舍入主导区的数据解释。某一位移处误差偶然为零、三次项抵消或数值下溢，都不允许直接宣称得到“无限阶精度”。

在普通方向， E_1/t^2 应趋向 $5/3$ ， E_2/t^3 应趋向 $224/125$ 。这比只看双对数直线更具体。有限个点符合这些趋势，核查的是实现与推导相符；覆盖所有方向的数学依据仍是第八节的余项论证和第十节的统一界。

十七 为什么狭长曲面让统一步长难选

这里只对第七节的精确正定二次函数做一个小型预览。定义重复更新 $h_{k+1} = h_k - \alpha \nabla q(h_k)$ ，其中 $\alpha > 0$ 是固定步长。因为 $\nabla q(h) = Ah$ ，在特征坐标里

$$z_{k+1,j} = (1 - \alpha \lambda_j) z_{k,j}.$$

这条式子完全是矩阵乘法，不需要提前使用优化算法的收敛定理。要让每个方向的绝对值都缩小，应有 $|1 - \alpha \lambda_j| < 1$ ，等价于 $0 < \alpha < 2/\lambda_{\max}$ 。等号处的某一模式可能只翻转符号而不缩小。

当特征值为1和16，步长0.1使两个因子为0.9与-0.6：慢方向仍缓慢缩小，快方向每步翻转但幅度缩小。步长0.15使快方向因子变为-1.4，幅度反而增长。这里展示的是确切二次函数的机制；一般非线性函数的 Hessian 会随位置变化，不能只用起点的特征值保证整条轨迹稳定。




图11 相同的正定二次曲面中，统一步长同时面对慢方向与快方向。左图出现折返，右图解释其来自负但绝对值小于1的因子；过大步长则使快方向发散。

因此本讲中心问题的回答是：梯度只给当前位置的线性倾向，Hessian 描述坡度接下来怎样改变。方向间曲率差异会压缩可用步长，并造成某些方向慢、某些方向反复跨越谷底。这个局部机制很重要，但它不是完整的优化难度指标，也不包含数据噪声、非光滑性或计算成本的全部影响。

十八 计算审计比漂亮图像更重要

脚本从残差求 Hessian，再用独立多项式式子与梯度的中心差分核对。第 j 列差分写作

$$\hat{H}_{:,j} = \frac{\nabla L(\theta + \varepsilon e_j) - \nabla L(\theta - \varepsilon e_j)}{2\varepsilon}.$$

步长过大会截断误差，过小则相减与舍入误差放大；小到浮点数无法表示新采样点时，程序明确拒绝。它不先把差分结果强制对称，因为那会掩盖实现错误。测试覆盖25个固定参数点，还包括零位移、单样本、非有限输入、布尔或复数、错误形状、溢出与不可分辨步长。

特征分解用 NumPy 的 `eigh`，因为对象是实对称矩阵。它返回升序特征值与按列排列的单位特征向量；特征向量的整体符号可以改变，不应逐元素硬比某个符号约定。应检验 $Hv_j \approx \lambda_j v_j$ 与 $V^T V \approx I$ 。官方接口可只读取一个三角区域，所以程序在调用前独立检查对称性，避免一个错误三角区被静默忽略。[R5]




图12 中心差分误差不会随步长单调降低。数值审计依次检查输入、矩阵关系与结论前提，尤其保留近零特征值对应的不确定性。

数值梯度落入容差只是“驻点候选”，不是精确驻点的证明。特征值接近零时，分类程序返回“不确定”，然后要求检查原函数、高阶项或更可靠误差界。数学上的正负分类与有限精度下的容差分类应分别陈述。

学完后，应能从一个明确函数和固定中心出发，写出 g 与 H ，核对每一项形状，构造 P_1, P_2 ，说明余项条件，再决定是否资格使用驻点判据。若要全局结论，还必须给出覆盖整个定义域的独立理由。详细练习在单独的练习详解中，动手步骤在实验指南中。

来源与进一步阅读

- R1 Brian Conrad, Stanford Math 396, Higher derivatives and Taylor's formula via multilinear maps。实际核对第3节的混合偏导与 Hessian，以及第5节的 Taylor 余项条件。本讲另用两次 Rolle 的路径论证解释二阶情形，不要求读者预先掌握多重线性映射或积分余项
- R2 OpenStax, Calculus Volume 2, 第6.3节 Taylor and Maclaurin Series。核对一元 Taylor 余项的中间点与光滑条件；本讲只用有限阶近似，不假设无限级数收敛
- R3 OpenStax, Calculus Volume 3, 第4.7节 Maxima Minima Problems。核对内部极值必要条件、局部与全局定义及二阶判别的驻点前提
- R4 Bjorn Poonen, MIT 18.02 Lecture Notes, Fall 2021, 第9.9节。核对二次型、二维行列式判别、退化情形与约束警告
- R5 NumPy Developers, NumPy 2.3, numpy.linalg.eigh。核对对称矩阵要求、三角区参数、升序特征值和按列特征向量约定

正文、手算、反例组合和全部12幅图均为本讲独立编写或程序生成。参考资料用于核对定义、条件与接口，没有复制其中的图或例题。所用数据为原创合成数据，并明确延续第十四讲。