

随机变量与期望 实验指南

实验目标与起点

本实验回答一个贯穿问题：知道一次随机结果的分布后，怎样给它计算平均损失，并用有限模拟核对而不混淆两者？你将从六个等概率状态出发，分别计算PMF、CDF、矩、条件均值和平方预测风险，再比较连续密度积分与样本估计。直接先修第017至018讲；本指南单独给出数据、运行步骤、预期答案和常见失败的含义。

所有数值都是无量纲合成教学量。模型状态并不是六位真实用户，也没有任何实际设备或人群隐私。实验只在CPU本地运行，不访问网络、不需要GPU或付费API。

一 文件与环境

先读lecture.pdf，再运行experiment.ipynb；答案见answers.pdf。experiment.py提供同一组可复用计算函数。data/scenarios.csv是不可随意修改的已知模型；source-checks.json列出已核查的一手来源。

脚本核心只用Python标准库。在终端进入本单元目录，运行：

```
python experiment.py
```

默认生成outputs/report.json。运行成功时终端给出均值、方差、交叉核对数和边界检查数。脚本按自身位置读取CSV，因此也可以从别的目录通过脚本路径运行。若要改结果目录，使用：

```
python experiment.py --output my_results
```

Notebook需要Matplotlib、IPython和Jupyter。已有适用环境可安装requirements.txt；或用environment.yml创建独立环境：

```
conda env create -f environment.yml
conda activate ml-course-019
jupyter lab experiment.ipynb
```

依赖安装可能需要网络，实验本身不需要。脚本已在Python3.12.14执行，绘图使用Matplotlib3.10.8。实际Notebook验收使用新Python进程中的真实ipykernel InProcessKernel逐格执行。学习者本机Anaconda安装、浏览器Jupyter界面和外进程socket传输未实际测试；这些限制不等于Notebook内容没有执行。

打开Notebook后选择重启内核并运行全部。不要只运行最后一格来复用旧变量。先确保同目录下有experiment.py和data，再保留第一次完整运行结果。如果出现ModuleNotFoundError，先核对当前Notebook位置和环境，而不是修改数学公式。

二 读懂六状态输入

CSV每行包含scenario_id、probability_numerator、probability_denominator、loss_units、group。六个概率均为1/6，损失依次为0、0、1、1、2、4。A和B属于quiet，其余属于active。分子与分母保留整数，是为了能用Fraction精确重算，避免把0.166667误当作精确1/6。

请先不看代码，在纸上填出四种不同损失值的概率。关键是相同取值要合并：X=0和X=1各占两个状态，X=2和X=4各占一个状态。理论PMF应为1/3、1/3、1/6、1/6，不能对去重后的四个数使用等权平均。

程序会检查列名、状态ID、概率比值、精确总质量和固定教学模型。随意修改CSV应报错，且不会用新结果替换已存在的有效报告。若要研究另一个模型，应另建文件并同步改实验的理论答案与生成器，不要把当前程序的参考数当成普适答案。

三 先区分映射、质量与累计量

在Notebook调用pmf，再查询CDF在-1、0、1、2、4、5处的值，预期为0、1/3、2/3、5/6、1、1。函数cdf的include=False计算严格小于阈值的质量，所以可以比较：

```
e.cdf(x, p, 1) - e.cdf(x, p, 1, include=False)
```

结果应为1/3，即X=1的点质量。再求 $P(1 < X \leq 2) = 1/6$ 与 $P(1 \leq X \leq 2) = 1/2$ 。请解释为什么两个区间只差一个端点，却差了1/3。此步骤不是微小浮点误差，而是两种不同事件。

观察Notebook的PMF和CDF图。PMF柱高表示概率，柱宽只为阅读方便；CDF的跳跃大小表示点质量。不要用柱形的视觉面积解释本离散图。

四 用两条独立路径重算矩

一条路径用六状态加权，另一条按合并PMF计算。应得到：

$$E[X] = 4/3, \quad E[X^2] = 11/3, \quad \text{Var}(X) = 17/9.$$

先手算 $E[(X - 4/3)^2]$ ，再与 $E[X^2] - E[X]^2$ 比较。两条精确计算必须相等，但浮点结果可能有末位差异。用math.isclose配合事先指定的小容差比较浮点数；不要为了通过检查而随意放大容差。

将每个X平方后求平均，结果11/3；把平均4/3平方，结果16/9。请保留这两个输出，并用“在哪一步丢掉了分布信息”解释差异。把X平移3，方差保持17/9；把X乘2，方差变成68/9。这些关系都是定义的代数结果，不依赖模拟。

五 用期望比较预测规则

在不知道组别时，把预测值 a 取为0、1、4/3、2、4。用square_risk计算每个预测的期望平方误差，并与 $17/9 + (a - 4/3)^2$ 比较。最小值发生在4/3，虽然真实 X 不会取这个值。

然后用condition分别选择quiet与active。结果为：quiet质量1/3、均值0；active质量2/3、均值2。把组均值简单平均得到1，这不是总体均值。按组质量加权得到4/3，才是全期望公式。

已知组别时预测quiet为0、active为2。六个平方误差依次为0、0、1、1、0、4，平均风险为1。与最佳常数风险17/9相比，改善8/9。请说明这是一张已知合成模型里的可用信息比较，没有训练步骤，也不是实际泛化性能证明。

六 记录所有模拟 不挑“最好看”的一次

离散生成器先验证全部六态的数值和组标签，再创建随机数生成器并从六态等概率选择。即使坏状态恰好未被本次抽中，也必须在抽样前报错。每个样本量 $n=30$ 、300、3000、30000运行24个种子，种子规则为 $190000+100n+r$ ，其中 $r=0$ 至23。报告保留全部96次结果、组计数、组均值、样本均值、按 n 归一化的经验方差，以及经验全期望重组值。

观察散点图：每个点代表一次完整模拟，不是一个原始样本。比较不同 n 下的散布，但不要要求每条路径逐次更接近4/3。有限实验不证明一般大数定律，也没有构造置信区间。

对同一批样本，用“该批组计数/ n ”乘“该批组均值”求和，应还原该批总体样本均值。不能一边用经验组均值，一边偷偷换回模型权重1/3与2/3；那是另一个估计量，不再满足逐样本恒等式。

额外用 $n=2$ 、种子199000至199063运行64次。实际有6次完全没观察到active，其该批条件样本均值记录为null，对应Python的None。理论active质量仍为2/3、理论条件均值仍为2。这两种“没有”必须分开解释。重组经验均值时，空组贡献以计数0处理，不执行0乘undefined。

七 连续概率的三个积分要分别检查

连续模型 $f(t) = (1+t)/4$ 支持集为 $[0,2]$ 。分别积分 f 、 tf 、 t^2f ，理论答案是1、7/6、5/3。用4、16、64、256个梯形网格比较误差。由于 f 为线性，总质量的梯形积分恰好准确到浮点舍入； tf 是二次， t^2f 是三次，它们不会因此自动准确。

对 n 个等长网格，可独立推出：

$$Q_1 = 7/6 + 1/(3n^2), \quad Q_2 = 5/3 + 4/(3n^2).$$

将这两条公式与程序输出比较，比只看“接近1”更有诊断力。由近似矩相减构造方差还会组合两个误差，不能默认所有误差同号或自动抵消。

反CDF法使用 $t = 8u/(\sqrt{1+8u} + 1)$ ，其中 u 由random.Random(190777)生成30000个 $[0,1]$ 浮点数。先检查多个确定性 u 的 $F(F^{-1}(u)) \approx u$ ，再查看样本均值与按 n 归一化的经验方差。样本值是近似核对，不应被写成精确7/6或11/36。

八 两个不能忽略的模型边界

混合模型在0处有1/3点质量，区间(0,1)内密度为2/3。画CDF时要保留跳跃。其连续部分导数的积分只有2/3，不能拿它独自冒充整个分布的PDF；均值为1/3。

重尾模型在 $w \geq 1$ 有密度 $1/w^2$ 。报告列出不同截断B下总质量 $1-1/B$ 和一阶矩 $\log B$ 。前者趋1，后者不断增长，说明归一化不保证有限期望。这里不需要随机抽样就能判定发散；任何有限的模拟均值都不能推翻解析结论。

九 数值稳定和明确拒绝

给六个损失统一加上10的12次方，直接用二阶原始矩减均值平方，可能出现严重消减。moments用第一个正质量状态作参考，先算较小偏移的中心，再计算偏移的离均值平方。报告保留直接公式与参考平移公式的实际结果；参考精确方差仍为17/9。

再加上10的18次方，当前浮点输入只剩一个不同值。数据在进入方差程序之前已经失去差别，此时不能指望任何算法找回17/9。须区分算法运算不稳定与输入精度先丢失。

接口拒绝bool、文本、复数、非有限数、嵌套或空序列、错误形状、负概率和不正确总质量。浮点概率要求 $\text{math.fsum}(p) == 1.0$ ，不自动归一化；这是明确的计算契约，不是对无限精度模型的判定。

Fraction输入可先精确检查，但转换成浮点后的算法仍有限精度。

本实现保守拒绝所有非零subnormal值，以及已识别的乘积下溢或中间溢出，可能拒绝某些经过特殊缩放本来可计算的问题。回调输入先完成检查，回调结果也须有限；回调内部自己做出的消减或下溢不一定能从结果识别。例如回调把极小数直接平方成0，外层不能知道原本应非零，回调应使用product或自己检查。这是教学实现的范围限制。

脚本内置1120项交叉核对：160组精确有理数模型各检查5条恒等式，并各与浮点均值、方差做2项比较；另有49个预期拒绝案例和7项端点或哨兵检查。全部采用显式异常检查，python -O不会删除。有限测试不是任意输入正确性的证明。

十 提交自检与延伸问题

保留完整report.json、四组模拟的散点图，以及你对以下问题的短答：为什么去重后均匀抽样错了？为什么总体期望不等于一次样本平均？为什么空样本组不等于零概率模型事件？为什么连续密度归一化检查不能替代矩检查？为什么稳定算法也不能恢复已被舍入抹去的输入？

详解中的14题进一步要求推导、构造反例与解释数值失败。第020讲将给常见命名分布及其建模假设，第021讲将系统讨论联合分布、协方差和全方差，第022讲再讨论抽样极限定理。不要提前把尚未证明的统计结论当成本实验的验收标准。