

常见分布与建模假设练习详解

一 判断支持范围

题目：一次报警、8次检测中的报警数、互斥原因A/B/C、每小时到达数、未截断的测量误差，各应先考虑哪类支持范围？为什么不能先看均值？

解答：分别为 $\{0,1\}$ 、 $\{0,1,\dots,8\}$ 、 $\{A,B,C\}$ 、非负整数、实数轴。均值可能都接近1，但第一类只有两个结果，第二类有上限，第三类没有自然数值距离，第四类没有预设上限，第五类是连续有符号误差。只比较均值会抹去这些结构。分布名是下一步：Bernoulli、满足独立同概率条件的Binomial、Categorical、可考虑的Poisson和可考虑的Gaussian。支持合法是必要检查，仍不是模型正确的充分条件。

二 从定义计算Bernoulli矩

题目：Y以1/4概率取1，以3/4概率取0。求均值、方差和标准差，并解释为什么均值不是可能结果。

解答： $E[Y]=0 \times 3/4 + 1 \times 1/4 = 1/4$ ；因为 $Y^2=Y$ ， $E[Y^2]=1/4$ 。方差为 $1/4 - (1/4)^2 = 3/16$ ；标准差为 $\sqrt{3/16}$ 。直接中心化也得到 $(0 - 1/4)^2(3/4) + (1 - 1/4)^2(1/4) = 3/16$ 。取值只能是0或1，1/4是概率加权平均，不是第三种结果。 $p=0$ 或 1 时方差为0；用 $p(1-p)=1/4 - (p-1/2)^2$ 还可看出最大方差为1/4。

三 四次试验为什么出现组合数

题目：4次独立试验，每次成功概率1/4。恰好2次成功的概率是多少？若只计算排列1100，漏掉了什么？

解答：任一恰好两个1的排列概率为 $(1/4)^2(3/4)^2=9/256$ 。这样的排列是1100、1010、1001、0110、0101、0011，共6个，彼此互斥。因此总质量 $54/256=27/128$ 。只计算1100仅得到其中一种有序结果。组合数 $4!/(2!2!)=6$ 是在同一总数下合并排列，不能替代“每种排列概率可相乘”所需的独立性。

四 八次二项试验的矩与一个精确概率

题目： $S \sim \text{Binomial}(8, 1/4)$ 。求均值、方差和 $P(S=2)$ ，并写明方差推导里独立性出现在哪一步。

解答：均值 $8 \times 1/4 = 2$ 。展开 S^2 后，8个平方项各期望1/4，28个交叉对各期望1/16并乘2，所以 $E[S^2]=2+56/16=11/2$ ；减去 2^2 得3/2。独立性使 $E[Y_i Y_j] = P(Y_i = 1, Y_j = 1) = 1/16$ ，这一等式在相关试验下可能不成立。 $P(S=2)=28 \times (1/4)^2 \times (3/4)^6=5103/16384$ ，约0.3114624。程序的浮点数应和Fraction的5103/16384一致到规定容差。

五 同步报警为何不再二项

题目：8个部件每批一起报警或一起不报警，报警概率 $1/4$ 。每个部件的边际分布是什么？总数与上题比较怎样？

解答：每个部件仍为Bernoulli($1/4$)，但所有结果等于同一个 Y 。 $S=8Y$ 只取0和8，概率 $3/4$ 、 $1/4$ ；均值 $8 \times 1/4=2$ ，方差 $64 \times 3/16=12$ 。上题方差是 $3/2$ ，相差8倍。已知每个单次分布仍不足以决定总数分布，必须知道共同发生的关系。增加批次数量不会把这个真实依赖机制变成独立二项。

六 独立但不等概率也会改变总数分布

题目：两次试验独立， $p_1=1/10$ 、 $p_2=9/10$ 。总数能否当作Binomial($2, 1/2$)？

解答：总数0的概率 $(9/10)(1/10)=9/100$ ；总数2的概率 $(1/10)(9/10)=9/100$ ；总数1的概率为 $1/100+81/100=82/100$ 。均值1，二阶矩 $82/100+36/100=118/100$ ，方差 $18/100$ 。Binomial($2, 1/2$)同样均值1，却有质量 $1/4$ 、 $1/2$ 、 $1/4$ 和方差 $1/2$ 。因此仅把不同成功概率平均后套二项会改变分布；差异来自同概率假设，不是独立性失败。

七 类别编号与指标变量

题目：类别A、B、C的概率为 $1/2$ 、 $3/10$ 、 $1/5$ 。按0、1、2编码与0、10、100编码时，编号均值分别是多少？指标 I_A 和 I_B 能否独立？

解答：前者均值 $0+3/10+2/5=7/10$ ，后者 $0+3+20=23$ 。编码变了但类别事件没变，因此编号均值没有不依赖编码的含义。 I_A 和 I_B 各有均值 $1/2$ 、 $3/10$ ，但乘积始终为0。若独立，两者同时为1的概率应为 $3/20>0$ ，矛盾。互斥分类的各指标通常不是独立Bernoulli。若任务允许同时多个标签，则应另建多标签模型。

八 用移位求和推导Poisson方差

题目： $X \sim \text{Poisson}(\lambda)$ ， $\lambda>0$ 。为什么先求 $E[X(X-1)]$ 比直接求 $E[X^2]$ 更方便？

解答：PMF分母是 $k!$ ，乘上 $k(k-1)$ 后恰好抵消为 $(k-2)!$ 。所以从 $k=2$ 开始求和，令 $j=k-2$ ，可提出 λ^2 并得到归一化级数，故 $E[X(X-1)]=\lambda^2$ 。由 $X^2=X(X-1)+X$ ， $E[X^2]=\lambda^2+\lambda$ ，减均值平方得 $\text{Var}(X)=\lambda$ 。这里使用指数幂级数和非负项求和的合法移位。 $\lambda=0$ 应先单独定义恒为0，矩也全为0，而不是先对0取log再试图修补。

九 暴露量不能直接混合

题目：发生率每小时2次，分别观测半小时和两小时。若给定时长的次数为Poisson，两个 λ 是多少？若两种窗口各占一半，混合均值与方差是多少？

解答： $\lambda=rt$ ，故分别1和4。混合均值 $(1+4)/2=5/2$ 。组二阶矩分别2和20，平均11；总体方差 $11-(5/2)^2=19/4$ ，即4.75。它不是Poisson(2.5)，后者方差2.5。也可用 $\text{Var}(\Lambda)=((1-2.5)^2+(4-2.5)^2)/2=2.25$ ，得到 $2.5+2.25=4.75$ 。把计数除以暴露时长可得到率估计，但该商未必再是Poisson变量，不能机械沿用计数支持与方差公式。

十 过度离散的精确混合例

题目：等权混合Poisson(1)与Poisson(7)。求均值、方差和零值概率，并与Poisson(4)比较。

解答：均值4；二阶矩为 $(2+56)/2=29$ ；方差13。零值概率 $(e^{-1} + e^{-7})/2$ 约0.18439566，而Poisson(4)的零值概率 e^{-4} 约0.01831564，相差约十倍。两者均值相同但分布差异显著。有限样本方差/均值较大只是线索：可能由混合造成，也可能由依赖或未记录暴露量造成。没有给定生成机制时，不能凭这个比值唯一诊断原因。

十一 Gaussian的密度高度与概率

题目： $R \sim N(0, 0.01)$ 。标准差与 $r=0$ 的密度是多少？密度超过1是否合法？ $v=0$ 能否直接代入公式？

解答：标准差 $\sqrt{0.01}=0.1$ ； $f(0)=1/(0.1 \sqrt{(2\pi)})$ 约3.9894228。密度的单位是“误差单位的倒数”，不是单点概率；任何有限区间概率要积分，单点概率为0。密度高于1是合法的，只要总面积为1。 $v=0$ 不能代入，因为会除以0；极限对应0处点质量，应使用退化分布描述，不是普通PDF。

十二 支持错误和条件错误

题目：有人因为长度直方图像钟形就拟合 $N(1, 1)$ ，又因为两个仪器的原始测量合并后双峰就断言每台仪器的误差不正态。指出两处逻辑问题。

解答： $N(1, 1)$ 对负长度给约0.158655概率。如果物理长度严格为正，这个模型不是精确支持匹配；是否作为近似可接受，需要任务误差标准。第二个推断忽略条件：两台仪器可能测量不同真值，原始值是不同位置Gaussian的混合；减去各自真值后的误差仍可以服从同一正态。先确认建模对象是原始值、给定条件的值还是残差，再检查分布。直方图不能直接证明独立性、同方差或因果机制。

十三 相同两阶矩不等于相同尾部

题目： D 等概率取 ± 1 ； Q 以3/4概率取0、各1/8概率取 ± 2 。证明二者均值0、方差1，求 $P(|X| > 1.5)$ 。

解答：由对称性，两个均值都为0。 D^2 恒为1； Q^2 均值 $4 \times 1/8 + 4 \times 1/8 = 1$ 。因此方差均为1。 D 不可能超过阈值，尾部概率0； Q 的 ± 2 均超过阈值，尾部概率1/4。标准正态也有同样均值方差，但相同尾部概率约0.1336144。检查均值方差只能检验部分模型限制，不能恢复完整分布。

十四 检查Bernoulli指数族分解

题目： $\eta = \log(p/(1-p))$, $0 < p < 1$ 。写出 h 、 T 、 A ，计算 A' 和 A'' ，并解释 $p=0$ 的情况。

解答：支持 $\{0,1\}$, $h=1$, $T(y)=y$, $A(\eta) = \log(1+e^\eta)$ 。求导得 $A' = e^\eta / (1+e^\eta) = p$ ；再求导 $A'' = e^\eta / (1+e^\eta)^2 = p(1-p)$ 。这是有限支持情况下均值与方差恒等式的直接检验。 $p=0$ 需要 η 趋负无穷，不存在等价的有限实数 η ；概率模型 $p=0$ 仍合法，只是不在这个内部自然参数化中。遗漏 A 时，两点权重相加为 $1+e^\eta$ ，不是1。

十五 Gaussian自然参数的合法范围

题目：取 $h=1$ 、 $T_1(x)=x$ 、 $T_2(x)=x^2$ 。求 $N(\mu, \nu)$ 的自然参数和 A ，并说明为什么 $\eta_2=0$ 不能允许。

解答：展开指数 $-(x-\mu)^2/(2\nu)$ ，得到 $\eta_1 = \mu/\nu$ 、 $\eta_2 = -1/(2\nu)$ 。完整常数为 $A = \mu^2/(2\nu) + \log(2\pi\nu)/2$ ，换成自然参数为 $-\eta_1^2/(4\eta_2) + \log(\pi/(-\eta_2))/2$ 。合法范围 $\eta_1 \in \mathbb{R}$ 、 $\eta_2 < 0$ 。 $\eta_2=0$ 时指数为 $\eta_1 x$ ； η_1 正或负都会在某一端发散， $\eta_1=0$ 时为常数，整条实轴积分仍无限。因此没有正有限归一化常数。负号不是记忆技巧，而是可积性条件。

十六 数值失败不是支持外概率

题目：Poisson(1000)在0点的数学质量是什么？为什么程序的logpmf可返回-1000，而pmf应拒绝返回0？再说明如何验证“非法输入不调用回调”。

解答：数学质量 e^{-1000} 严格为正，但小于本程序支持的普通float正数范围。返回0会把数值下溢误称为模型不可能事件；对数概率-1000是可表示的有限数，保留了信息。对于回调，创建一个记录每次调用参数的列表，传入支持 $[0, \text{NaN}]$ 和合法概率 $[1/2, 1/2]$ 。期望函数应先检查整个支持，发现NaN报错，列表保持空。若已经调用了第一个点后才发现第二个点非法，检查顺序不符合合同。这类测试需用显式if/raise保证python -O下仍有效。