

常见分布与建模假设实验指南

目标与先修

这个实验回答三个可以核验的问题：生成器是否遵守支持范围；有限样本均值和经验方差如何围绕已知模型量变化；一个平均数相同的分布为何仍可能是不合适的模型。先完成第十九讲，能区分PMF、PDF、模型期望和样本平均，再读本讲正文。整个实验在CPU离线运行，不需要付费API、GPU或真实数据。

交付文件experiment.py是可复用模块，也是命令行入口；experiment.ipynb按教学顺序调用同一接口并保留实际输出与图像。data目录记录生成参数，不是私有数据下载器。正文中的12图用相同模型制作，Notebook另生成可重跑的经验图。

一 创建环境与确认入口

推荐用Anaconda Prompt或支持conda的终端，进入本单元文件夹，然后执行：

```
conda env create -f environment.yml
conda activate ml-course-020
python experiment.py
jupyter lab experiment.ipynb
```

已有Python环境可按requirements.txt安装教学依赖，但不要在不清楚环境来源时全局混装。代码实际核验版本见test-result.json。环境文件中的Python与NumPy、Matplotlib版本固定；Jupyter前端由环境求解器安装。浏览器界面、socket通信和读者机器上的Anaconda安装尚未实际测试；已执行的是独立新Python进程中的真实ipykernel，所有单元格按顺序运行并保留输出。

脚本默认把结果写在自身旁的outputs目录，因此当前终端在别的文件夹也不影响数据路径。也可以选择输出位置：

```
python /完整路径/020/experiment.py --out /你选择的结果目录
```

路径中的“完整路径”要换成你保存课程的位置。程序先完成全部生成与核验再写文件；它不会下载文件或访问网络。结果包含experiment_report.json和synthetic_samples.csv。默认每种模型12000条，总计约束规模适合普通CPU。不要通过修改种子挑选最贴近理论的一次结果。

二 先在纸上预测输出

五种数值模型的理论均值、方差依次为：Bernoulli(1/4)对应1/4、3/16；Binomial(8,1/4)对应2、3/2；Poisson(4)对应4、4；Gaussian(1,4)对应1、4；等权Poisson(1)/Poisson(7)混合对应4、13。

Categorical的三类概率为1/2、3/10、1/5，分别记录类别频率和指示变量方差。任意编号0、1、2只用于存储，不代表连续大小。理论指示方差分别为1/4、21/100、4/25。先写出这些目标，再运行代码；运行后只修改你对有限波动的认识，不修改理论量使它迁就样本。

解释混合方差13时，先写两组二阶矩2和56，再按各1/2平均得29，减总体均值平方16。只把组内方差平均得到4，会漏掉组间平均值差异。

三 核对支持范围与参数边界

在Notebook设置部分导入experiment为e。以下调用都是边界模型，不应失败：

```
e.binomial_pmf(0, 0, 0.25)
e.binomial_pmf(8, 8, 1.0)
e.poisson_pmf(0, 0.0)
e.categorical_sample([0.0, 1.0, 0.0], 10, 20)
```

前3个返回1，最后一个只生成类别索引1。另一个合法查询e.binomial_pmf(9,8,0.25)返回0，因为9是支持外的整数。e.binomial_pmf(2.7,8,0.25)会报错，本教学接口不把非整数偷偷截断。NumPy底层binomial接受浮点n并截断，本模块的n只接受明确的整数，避免用户输入8.9却运行8次试验。

用try/except捕获预期错误并打印错误类型。不要让一个预期报错中断整个Notebook，也不要捕获后的失败隐藏为0。对p=-0.1、p=1.1、v=0、文本"0.25"、True、复数、二维列表或NaN均应明确拒绝。bool在Python里有整数继承关系，因此不能只用isinstance(x,int)判断本任务合法数值。

四 生成六组记录并比较样本矩

运行data=e.generate_data()。种子为20001至20006，依次用于Bernoulli、Binomial、Categorical、Poisson、Gaussian和混合分组；混合的两个独立候选计数流另外使用20106和20206。生成器显式使用PCG64。读取每列前5条只是了解格式，不把前几条当成分布核验。

运行e.moments(data["poisson"]), 确认n为12000。variance_n中的n表示分母是样本量。数学上，经验分布为每条记录分配1/n质量，所以该分母适合描述当前这批数据；它不同于常用于无偏估计的n-1。

本次保留运行的结果如下，末位差异需结合依赖版本判断：

- Bernoulli: 均值0.2500833333, 经验方差0.1875416597
- Binomial: 均值1.992, 经验方差1.4831026667
- Poisson: 均值3.99225, 经验方差3.9325232708
- Gaussian: 均值1.0092375135, 经验方差3.9134480633
- 混合Poisson: 均值3.9585833333, 经验方差12.9813679931
- Categorical计数为5986、3589、2425, 总数12000

这些是实际有限模拟值，不能把它们改写成理论精确值。混合样本均值接近4并不能使它成为Poisson(4)，因为它的零值频率、尾部与方差结构不同。

五 画经验质量与经验密度

离散变量使用整数点上的频率柱，再叠加理论PMF。Binomial的全部支持只有0到8，可以完整画出；Poisson无限支持的图只展示有限范围，因此还要报告图外频率。若只画0到18，仍把柱高除以全部12000条，而不是除以落在图内的条数。

Gaussian使用密度直方图，箱宽为 Δ 时，高度为箱内计数/ $(n\Delta)$ 。与理论PDF叠加时纵轴单位相同。换两种不同箱宽观察峰高变化，判断哪个变化属于绘图分箱，哪个属于生成模型。区间概率应该比较直方图面积与密度积分，不能把峰高直接叫作概率。

Notebook第一幅图同时展示二项和Poisson经验质量；第二幅图比较Gaussian密度直方图与理论密度。每幅图都标注样本规模、轴含义与生成参数。若你改动参数，应该重新运行全部单元格并更新图题，不能留下旧图配新文字。

六 用反例挑战模型

把混合样本与Poisson(4)画在同一整数轴。计算零值经验频率，再比较理论值：混合模型为 $(e^{-1} + e^{-7})/2$ ，Poisson(4)为 e^{-4} 。这里出现明显差别是已知生成机制的课堂演示，不是自动选择分布的通用检验。

再构造8个部件完全同步的批次：先生成Bernoulli(1/4)，然后乘8。每个部件的边际报警率没变，但总数方差变为12。这个反例告诉我们，选择了每列的分布以后，仍然必须检查列之间或重复观测之间的关系。不要把重复测量当成额外独立样本。

最后计算 $N(1,1)$ 落到负值的概率约0.158655。假如 X 是严格正长度，这不是采样误差，而是模型把质量分到不可能区域。若任务只需要一个近似，写下容许误差和具体评估标准；不要用“看上去像钟形”省略这一决定。

七 固定重复实验而非挑选成功曲线

脚本对Poisson(4)执行每种规模40、400、4000各40次，共120批。第 r 次种子规则为 $202000+100 \times$ 样本量 $+r$ ，其中 r 从0到39。报告保存每一批的种子、均值和经验方差。

比较三组均值的散布，不删掉偏离理论值的批次。本次实验能展示样本规模不同下的有限波动；它不证明大数定律，不提供已校准置信区间，也不保证每次增加 n 后某条路径的误差都单调下降。Notebook第四幅图直接保留全部重复点，横轴使用对数刻度但标签明确是样本量。

八 检查独立参考答案

`e.exact_checks()`包括1533项检查：有理数二项归一化与矩、每个质量的Fraction精确参考、80位Decimal的Poisson参考，以及标准正态有限网格上的3个积分诊断。它们的职责不同：Fraction结果是所列有理数输入的精确代数核验；Decimal是高精度数值参考；网格仍有截断与离散化误差。

二项参考采用整数`math.comb`与有理数幂，核心接口采用对数组合数与浮点对数，避免同一浮点表达式自我作证。Poisson参考使用Decimal指数和整数阶乘，核心接口使用`math.lgamma`；两条路径的共同数学定义仍应由正文推导核验。

`e.adversarial_checks()`保留74组检查，含62个预期拒绝和12个合法边界。实际总数以本版本`test-result.json`为准。错误输入不应触发用户回调；坏的回调返回也必须拒绝。使用`python -O`运行仍保留这些检查，因为它们都是显式`if/raise`，不依赖被优化器移除的`assert`。

九 极端数值需要诚实失败

比较`e.poisson_logpmf(0,1000)`与`e.poisson_pmf(0,1000)`。前者为-1000，后者拒绝把真正质量 e^{-1000} 下溢成0。模型中的0和数值计算丢掉的正数必须区分。类似地，`e.normal_pdf(100,0,1)`报错，但可用对数密度表示这个极小值。

本程序刻意采用保守范围：n最大10000、生成量最大200000、Poisson λ 最大1000000，实数非零次正规输入拒绝。概率列表用`math.fsum`必须恰为1，不提供自动归一化；某些合法实数模型因float表示或累计概率吞掉小质量而无法在本接口运行。报错表示超出实现合同，不能当成数学分布不存在。

十 交付前自查

保留脚本运行结果、全部120批重复、Notebook有序执行输出和至少三幅生成图。说明你采用的支持集、条件与独立性假设；各举一个二项、Poisson、Gaussian不合适的原因；解释Categorical编号为何不是自然连续尺度；能展开一个指数族表达式并恢复原PMF或PDF。

最后把同一个脚本从两个无关工作目录启动，并加做一次`python -O`。对比报告与CSV的字节摘要，确保路径不依赖当前目录。脚本成功、Notebook成功和PDF可读是不同验收项；任何未测试的环境都应保留为限制，不能从一次本地执行推断所有机器都能运行。