

联合分布与相关结构实验指南

第二十一讲 用精确账本 线性代数和有限模拟交叉核验

本实验回答三个问题：同样的边缘分布可以隐藏什么联合关系；协方差为什么必须半正定；条件高斯的简化依赖哪些假设。先读正文第一至十一节，再做有限模型；读完高斯与全方差部分后完成其余实验。无需GPU、账号或付费API，安装依赖之后运行不访问网络。

所有数据是无量纲合成模型。输入的六个状态是完整的有限概率模型，不是用来估计真实总体的六条观测。主实验每个模型生成12000条样本，所有种子固定并公开；模拟仅核验这次实现，没有现实性能、因果、独立性检验或极限定理证明的含义。

一 配置与运行

把整个021目录保存到同一个位置，保留data子目录。终端进入该目录后，可用独立Conda环境：

```
conda env create -f environment.yml
conda activate ml-course-021
python experiment.py
python test_experiment.py
jupyter lab experiment.ipynb
```

已有合适Python环境时，也可运行`python -m pip install -r requirements.txt`。核心脚本只需要NumPy及标准库；Notebook另需Matplotlib、IPython和Jupyter。requirements.txt记录本次使用的计算与绘图版本，environment.yml给出环境约束；并不声称已经在所有操作系统完成Anaconda安装。

脚本默认把结果放在脚本自身旁的outputs中，而不是把当前工作目录误当成数据目录。可以在任意目录用脚本的绝对路径运行，并用--out指定结果目录。默认结果含一份experiment_report.json与八份样本CSV；再次运行会替换这些同名结果，保留其他文件。输入文件、参数与全部待序列化结果先验证，之后才写输出；每个文件使用临时文件替换，但多文件之间不构成操作系统故障下的整批事务。

Notebook按顺序运行全部16个代码单元，保留6幅实际生成的PNG。正文figures目录的12幅图与Notebook图承担不同任务：正文解释机制，Notebook图由当次计算生成，用于复核输出。Notebook默认只在内存生成样本，不写这八份完整CSV。

二 输入与输出的含义

joint_states.csv每行含scenario_id、probability_numerator、probability_denominator、x、z。整数分子与正分母表示精确概率，文件中的分数必须恰好加成1。A至F各1/6，X依次为0、0、1、1、2、4；Z依次为0、0、1、1、1、1。

gaussian_model.csv按x、y顺序给均值1、-2和协方差两行[4,3]、[3,9]。协方差的对角线是方差，非标准差；非对角的3也不是相关系数。gaussian_sample_preview.csv只保留固定高斯实验的前20行，用于看格式，不能拿20行预览冒充12000条实验。

结果名	坐标顺序	种子	生成机制
finite	X, Z	2101	从六态概率抽样
gaussian	X, Y	2102	均值加下三角因子乘独立标准正态
triangle	X, Y	2103	两个独立均匀数排序，X较大
nonlinear	U, U ²	2104	U等概率取-1、0、1
normal_marginals	G, SG	2105	G标准正态，S为独立公平符号
independent_normal	G, H	2106	两个独立标准正态
conditional_x5	Y	2107	直接从精确条件分布生成
singular	X, 2X	2108	一维独立噪声经2×1因子映射

样本CSV列名coordinate_0、coordinate_1按此表解释。所有经验协方差默认ddof=0，即分母n。报告里的theory或model表示理论模型，empirical表示这次有限样本，不能互换。每个随机流的样本量在report中记录；相同种子在同一版本下复现，不承诺不同NumPy实现逐个样本一致。

三 第一次核验先不用随机数

把相同数对的质量合并，应得到(0,0):1/3、(1,1):1/3、(2,1):1/6、(4,1):1/6。沿Z求和得到X边缘；固定Z=1后除以2/3得到X在1、2、4处的条件质量1/2、1/4、1/4。

调用finite_moments后均值应为(4/3,2/3)，协方差应为：

$$\Sigma = \frac{1}{9} \begin{pmatrix} 17 & 4 \\ 4 & 2 \end{pmatrix}.$$

不要先用同一个函数生成“参考答案”再与自己比较。test_experiment.py用Fraction按原始矩E[UV]-E[U]E[V]独立计算；实现按中心乘积累积。脚本还检查60个另外生成的有理数模型、各坐标元素与直接投影后的方差。改变CSV会改变模型；固定课程CLI会拒绝与正文参考不一致的数据。要探索新模型，请导入可复用函数并同步重算理论。

```
from experiment import finite_moments, conditional_finite
rows = [[0,0],[0,0],[1,1],[1,1],[2,1],[4,1]]
p = [1/6] * 6
print(finite_moments(rows,p)["covariance"])
print(conditional_finite(rows,p,1,1)["mean"])
```

条件函数返回两个坐标的矩，已知的Z坐标方差为0。它不会自动把恒定列删除。条件查询按状态坐标精确匹配；模型概率为0的组会报错，不能把无样本或零概率都偷偷换成全0结果。

四 矩阵形状与协方差变换

将D看作 $n \times d$ ， $C=D$ 减去每列均值。计算 $C.T@C/n$ ，应得到 $d \times d$ ； $C@C.T/n$ 得到 $n \times n$ ，是另一种Gram矩阵。NumPy核对必须明确rowvar=False、ddof=0。改成ddof=1后六行例子应整体乘6/5，这是不同统计对象的分子约定。

取 $A=[[1,1],[1,-1]]$ 。linear_moments返回 $X+Z$ 和 $X-Z$ 的协方差 $[[3,5/3],[5/3,11/9]]$ 。另一路把每个原状态先变成 $(x+z, x-z)$ ，直接重算精确矩；这条路径不重复使用 $A\Sigma A^T$ 公式。平移b只改变均值，不改变协方差。

检验 $[[1,2],[2,1]]$ 时应拒绝，因为方向 $(1,-1)$ 给“方差”-2。再试三维对角全1、非对角0.9、0.9、-0.9的候选，最小特征值为-0.8。最后测试 $[[1,2],[2,4]]$ ：它半正定且奇异，可以由显式因子构造，但不能送给本讲的普通密度或严格正定条件接口。

五 高斯生成与条件分布

主模型的下三角因子为：

$$L = \begin{pmatrix} 2 & 0 \\ 3/2 & \sqrt{27/2} \end{pmatrix}, \quad LL^T = \begin{pmatrix} 4 & 3 \\ 3 & 9 \end{pmatrix}.$$

以 $n \times 2$ 独立标准正态矩阵E为输入，行样本应为 $E@L.T+\mu$ 。若误用 $E@L$ ，协方差变成 L^TL ，通常不同。先做因子重构，再看经验协方差，再看散点；三种检查提供不同证据。

本次种子2102、 $n=12000$ 得到经验均值约 $(1.01684, -1.98733)$ ，经验协方差约 $[[3.99825, 3.02973], [3.02973, 9.04068]]$ 。它们不等于理论值 $(1, -2)$ 及 $[[4, 3], [3, 9]]$ 。不按看起来“更漂亮”的结果更换种子。

```
from experiment import gaussian_conditional, sample_gaussian
condition = gaussian_conditional([1, -2], [[4, 3], [3, 9]], [0], [5])
print(condition["mean"], condition["covariance"])
sample = sample_gaussian(condition["mean"], condition["covariance"], 12000, 2107)
```

结果是均值1、方差27/4，标准差为 $\sqrt{27/2}$ 。此代码直接生成精确条件模型；从联合样本筛选 $4.5 < X < 5.5$ 得到的是一个有限宽条件事件，会额外混合区间内不同均值。不可把两种样本混为一谈。

分块接口把observed_indices指定的坐标视为B，其余坐标按原顺序返回为A。系数 $\Sigma_A B \Sigma_B B^{-1}$ 通过solve求解；Schur修正通过白化后的Gram乘积对称地计算，不显式求逆、不静默补jitter。返回残差与已知坐标的交叉协方差，供核对理论的零矩阵。

六 两个不能靠相关系数发现的反例

对 U 等概率取 -1 、 0 、 1 且 $V=U^2$ ，精确协方差为 0 ，但 $P(U=0,V=0)=1/3$ ，不等于 $1/9$ 。应先写事件分解失败，再展示图；看到弯曲散点只是辅助。

对 G 标准正态、 S 独立公平取 ± 1 ，令 $H=SG$ 。两个边缘均正态、理论协方差为 0 ，但 $|G|=|H|$ 。Notebook直接检验所有生成行的绝对值恒等式，并与真正独立的高斯点云对照。本次有限相关约 -0.0153 与 -0.0131 ，二者都接近 0 ，但不能据此把第一种判成独立。

本次实验没有统计独立性检验的显著性或检验效能声明。依赖来自构造与精确事件计算；有限样本图用于展示，不提供“任意未知数据是否独立”的判决规则。

七 三角模型与全方差

三角区域 $0 \leq Y \leq X \leq 1$ 内密度为 2 。边缘分别为 $2x$ 和 $2(1-y)$ ，均值为 $2/3$ 、 $1/3$ ；两个方差均 $1/18$ ，协方差 $1/36$ 。给定 $0 < x \leq 1$ ， Y 均匀分布在 $[0, x]$ ，条件方差 $x^2/12$ 。接口拒绝 $x=0$ ，因为简单密度比值为 $0/0$ 。

六态全方差的三项应是 $17/9$ 、 1 、 $8/9$ 。组内项按组概率加权，不能把 0 与 $3/2$ 等权平均。三角模型的对应等式为 $1/18=1/24+1/72$ 。平均关系不意味着逐组关系：90%质量放在恒为 0 的组、10%放在 ± 10 组，总方差 10 ，后一组的条件方差却是 100 。

八 密度积分要拆开截断与网格误差

Notebook把高斯积分域取为 $\mu+L[-6,6]^2$ 。对标准噪声坐标积分时，面积因子为 $\det(L)=\sqrt{27}$ 。域内解析质量为 $\text{erf}(6/\sqrt{2})^2$ ，约 0.9999999960536494 ；因此域外截断质量约 3.94635×10^{-9} 。

每轴60和120个小区间的梯形积分分别约 0.9999999955779859 与 0.9999999959327955 。它们与域内解析值的绝对差约 4.76×10^{-10} 和 1.21×10^{-10} ，才是这两张网格的误差。不能把“积分小于1”全归因于实现错误，也不能把粗细网格之差无条件当作严格误差上界。这里使用`math.erf`，不依赖SciPy。

九 可复用接口与数值拒绝契约

`finite_moments`、`conditional_finite`与`total_variance`处理有限概率模型；`sample_covariance`专门处理按行的样本。`covariance_matrix`、`correlation`与`linear_moments`处理矩阵对象；`sample_gaussian`、`gaussian_logpdf`、`gaussian_pdf`与`gaussian_conditional`要求数值上良好的正定输入。`sample_gaussian_factor`接收显式因子 B ，可以构造奇异分布；`triangle_density`、`triangle_conditional`、`sample_triangle`处理三角模型。

所有数值输入在强制转换前逐项检查。Python混合列表中的`bool`、字符串、复数、`None`，以及`object`或`complex`型数组均拒绝。CSV文本属于明确的解析边界：先按已知字段解析，再对全文件数值与模型检查；这不意味着数值API接受任意字符串。错误形状、空数组、非有限数和不支持的索引也拒绝。未被条件选中的行及零权重状态仍完整检查，采样不能躲过非法状态。

浮点实现有意小于数学定义域：一般输入绝对值不超过 10^{100} ，非零输入不接受float64次正规数；每个非零协方差元素至少 10^{-100} ，维数不超过32，总数组元素不超过200万，采样数在1至20万之间。乘积、除法与累积检查非有限值及有意义的下溢；远尾普通PDF若将下溢或成为次正规数，应使用logpdf。高斯采样还拒绝均值尺度相对于非零标准差大于 10^{12} 的情形，以免假装能解析已丢失的噪声。

输入协方差要求完整数组精确对称。计算特征值出现任何负值时不自动修复；正定接口另要求 $\lambda_{\min}/\lambda_{\max} > 10^{-12}$ ，因此可能保守拒绝数学上有效但数值困难的矩阵。显式因子接口允许生成某些在特征值算法中数值难判的退化模型。输出Gram矩阵每个对称位置从同一求和结果赋值，这是计算对称公式，不是把不合法输入矩阵平均成合法矩阵。

概率列表采用统一容差8个float64机器精度，约 1.78×10^{-15} 。只有每项在[0,1]且math.fsum与1之差不超过此容差才接受；接受后按实际总和作一次浮点标准化，并返回input_total、used_total、maximum_adjustment及tolerance记录。非法总质量不被“修好”。测试覆盖总和1+一个舍入单位、重复传入结果、全1条件事件与极小正概率复用。输入CSV的有理数概率仍要求精确和为1。

这些守卫保证明确的实现范围，不是任意尺度下正确舍入的通用数值库。输入在传入前已经舍入丢失的信息无法恢复；严重抵消、极高条件数或跨平台浮点细节需要专门分析。失败时应先看类型、形状、量纲与尺度，再决定重设实验；不要删除检查或加任意jitter让代码“通过”。

十 验收与局限

先确认精确矩、方向方差、变换矩、条件均值方差、三角积分及全方差；再检查拒绝样例确实在随机数生成之前失败；最后核对固定种子模拟与Notebook实际输出。test_experiment.py包含1358个数值检查、115个拒绝检查，其中65个使用替换随机流工厂的方式证明错误在创建RNG前被发现。

制作时另从两个无关工作目录启动新Python进程运行，并运行python -O；对JSON与八份CSV逐字节比较。非法CSV输入时核对旧结果文件不变，且失败不会创建新结果目录。详细证据见test-result.json。以上检查使用显式异常，非可被优化模式移除的assert语句。

Notebook已在新进程的真实IPython InProcessKernel中从头顺序执行；六幅保留PNG逐幅查看。浏览器Jupyter界面、socket传输、读者本地Anaconda安装和跨版本逐位复现没有测试。正文与实验不能因为文件存在就视为结论正确，图形也不能替代独立手算。

一手接口依据见NumPy cov、Cholesky和eigh；完整来源阅读范围见source-checks.json。