

第二十二讲 练习完整详解

1. 单项方差与均值标准误

X 只取0或1, 故 $E[X] = 1/4$, 且 $X^2 = X$, 所以 $E[X^2] = 1/4$, 方差 $1/4 - (1/4)^2 = 3/16$ 。独立同分布时不同观测的协方差为0, 均值方差为 $n(3/16)/n^2 = 3/(16n)$ 。

$n=64$ 时方差3/1024, 标准误 $\sqrt{3}/32 \approx 0.0541266$ 。标准误描述每批均值的变化, 单个 X 的标准差仍为 $\sqrt{3}/4$ 。只有 n 增加为四倍, 标准误才减半。

2. 四个实际观察数

样本 $(0, 0, 0, 1)$ 的均值为1/4, 离差为 $-1/4, -1/4, -1/4, 3/4$ 。平方和为 $3/16 + 9/16 = 3/4$ 。 n 分母的经验方差为 $(3/4)/4 = 3/16$; s^2 为 $(3/4)/3 = 1/4$; $s=1/2$; 估计SE为 $(1/2)/2 = 1/4$ 。

真实总体Bernoulli(1/4)下, $n=4$ 的真实SE为 $\sqrt{3}/8 \approx 0.216506$ 。当前样本估计0.25与真值不同, 属于有限样本估计误差。若四个观察全为0, $s=0$, 也不能推出真实 $p=0$ 。

3. n 减一与无偏性

恒等分解为

$$\sum_i (X_i - \mu)^2 = \sum_i (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

它对任意数据成立, 交叉项为 $2(\bar{X} - \mu) \sum_i (X_i - \bar{X}) = 0$ 。在共同均值、共同有限方差且两两不相关时, 左侧期望 $n\sigma^2$, 最后一项期望 $n \text{Var}(\bar{X}) = \sigma^2$ 。因此平方离差和的期望是 $(n-1)\sigma^2$, 除以 $n-1$ 给 $E[s^2] = \sigma^2$ 。iid是满足上述要求的一组充分条件。

独立不是恒等分解的条件, 而是这里把平均值方差变成 σ^2/n 的充分条件。相关样本一般不能使用这一期望步骤。也不能把平方根拿出期望。直接看 $n=2$ 、 $p=1/2$ 的反例: 两个结果相同的概率为1/2, 此时 $s=0$; 两个结果不同的概率为1/2, 此时 $s = 1/\sqrt{2}$ 。因此 $E[s] = 1/(2\sqrt{2}) \approx 0.353553$, 不等于总体标准差1/2。

4. 三步证明链

第一步, W 非负且 $a>0$ 时, 逐点 $W \geq a \mathbf{1}_{\{W \geq a\}}$, 期望单调性给 $E[W] \geq aP(W \geq a)$, 得到Markov。需要 W 可积, 不能对正负相抵的任意 W 直接使用。

第二步, 令 $W = (Y - E[Y])^2$ 、 $a=\epsilon^2$, 要求 Y 有有限方差且 $\epsilon>0$, 得到 $P(|Y - E[Y]| \geq \epsilon) \leq \text{Var}(Y)/\epsilon^2$ 。

第三步，iid有限方差样本满足均值方差 σ^2/n ，故尾概率上界 $\sigma^2/(n\epsilon^2)$ 随 n 趋向0，证明依概率收敛。这个证明没有覆盖只有有限一阶绝对矩、二阶矩无限的情况；更一般大数定律是另一个已接受的定理。

5. 充分样本量

要求 $\frac{3/16}{n(1/10)^2} \leq 1/20$ ，即 $75/(4n) \leq 1/20$ ，整理得 $n \geq 375$ 。取整数 $n=375$ 就满足这个充分条件。

Chebyshev只利用方差，没有利用完整Bernoulli结构，通常较松。真正最小 n 需要指定同一尾事件，再对二项分布逐个检查；离散端点还可能使尾概率非单调变化。375不是由此证明的最小值。若采样偏差或相关，这个iid界本来就不能直接使用。

6. 完整五点分布

$k=0$ 至 4 时质量分别为 $81/256$ 、 $108/256$ 、 $54/256$ 、 $12/256$ 、 $1/256$ ，均值取 $k/4$ 。五个质量相加为1。

偏离 $1/4$ 至少 $1/10$ 时，只有 $k=1$ 不满足，故概率为 $(81 + 54 + 12 + 1)/256 = 148/256 = 37/64$ 。若一般 n 下 k/n 恰好落在容差端点， $\geq$ 与 $>$ 会产生不同概率；用Fraction(1,10)保存数学容差避免浮点二进制表示把端点移动。显示成0.578125只是这个分数的十进制形式。

7. LLN与CLT

LLN考察固定 ϵ 的偏差概率是否趋于0。CLT考察误差按其典型规模标准化后的CDF，正确公式为

$$Z_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} = \frac{S_n - n\mu}{\sigma\sqrt{n}}.$$

经典版本要求iid及正的有限方差。 X_i 始终只取0和1；即使 n 很大，原始Bernoulli也不变为正态。有限 n 的样本均值仍是离散的，只是标准化CDF渐近接近连续正态CDF。 $\sigma^2=0$ 时标准化未定义，但均值本身已无随机变化。

8. 稀有事件

30次独立试验都不报警的概率为 $(1 - 0.01)^{30} = 0.99^{30} \approx 0.7397003734$ 。标准化后仍有同样大的跳跃质量。一条连续CDF在跳跃点不可能同时贴近左右两侧：最大差至少为该跳跃的一半，约0.36985。

所以 $n=30$ 对这个模型不足以得到处处很小的CDF近似误差。此结论来自精确质量，不靠直方图观感。有限方差CLT没有失败；它从未承诺所有分布在 $n=30$ 都达到某种精度。

9. 复制不创造独立信息

设 $G=8$ ，组内复制 $m=8$ ， $n=Gm=64$ 。整体均值严格等于 G 个独立群组值的均值，因此方差 $p(1-p)/G = 3/128$ 。错误iid公式用 n 给 $3/1024$ ，比值 $m=8$ ；标准误比为 $\sqrt{8}$ 。

若把m从8改成80而G仍为8，名义n变成640，但每批均值完全不变，实际方差仍为3/128。错误iid公式却会变成3/10240，从而把错误继续放大。组内相关不是由打乱行顺序消失的。

10. 等相关公式

方差求和包含n个 σ^2 和n(n减一)个有序协方差 $\sigma^2\rho$ ，因此均值方差为 $\sigma^2[1 + (n-1)\rho]/n$ 。n=64、 $\rho=1/5$ 给膨胀 $1 + 63/5 = 68/5 = 13.6$ 。

若 $\sigma^2=1$ ，均值方差 $13.6/64 = 17/80 = 0.2125$ ；有效样本量 $64/13.6 = 80/17 \approx 4.70588$ 。它匹配的是该均值方差，不等于实际删除了数据，也不是对中位数、回归系数的统一结论。等相关矩阵必须半正定，rho下界随n改变。固定正rho时，方差极限为 $\sigma^2\rho$ ，不能使用iid的零极限。

11. 不放回修正与带身份的总体

令总体中心化值 b_j 的和为0。不放回的不同位置等概率对应N(N减一)个有序不同单位对，因此协方差为 $[(\sum b_j)^2 - \sum b_j^2]/[N(N-1)] = -\sigma_N^2/(N-1)$ 。代入一般方差展开，得到 $\sigma_N^2(N-n)/[n(N-1)]$ 。

A=0、B=0、C=1、D=1时，六对AB、AC、AD、BC、BD、CD对应均值0、1/2、1/2、1/2、1/2、1。

总体均值1/2，六种样本均值的方差为 $[(1/2)^2 + (1/2)^2]/6 = 1/12$ 。公式同样给 $(1/4)/2 \times (4-2)/(4-1) = 1/12$ 。

不能去重的是数值相同但身份不同的单位。只保留0和1两个数再抽两项，会错误地让均值总为1/2；那已是另一个总体与抽样设计。

12. Pareto的两个矩

对 $\alpha=3/2$ ，密度是 $(3/2)x^{-5/2}$ 。一阶矩

$$\int_1^B \frac{3}{2} x^{-3/2} dx = 3(1 - B^{-1/2}) \rightarrow 3.$$

二阶矩为 $\int_1^B (3/2)x^{-1/2} dx = 3(\sqrt{B} - 1) \rightarrow \infty$ 。X非负，所以一阶绝对矩也为3，一般iid大数定律适用。经典有限方差CLT的前提不满足，没有有限 σ 可代入标准化公式。

NumPy的pareto产生支持从0开始的Lomax，必须加1才是这里的X。不加1生成的变量均值2；不能把生成器名字直接当作参数化完全相同的证据。

13. Cauchy与有限样本矩

正部期望的截断积分为 $\log(1 + B^2)/(2\pi)$ ，随B增大无界；负部绝对值同样无界。通常期望需要正、负部至少不出现无穷减无穷，故不能定义为0。对称截断积分等于0只是另一个操作，不满足本讲使用的可积条件。

有限样本的每个机器数有限时，样本矩通常能算出来；这只是对有限列表的运算，不是对总体尾部积分的结论。模拟得到一个有限样本标准差，不会创造总体标准差；删去极端值则改变了数据机制。

14. 偏选后的目标变化

总体报警概率 $1/4$ ，报警保留率 1 ，不报警保留率 $1/3$ 。保留概率 $1/4 + (3/4)(1/3) = 1/2$ ；条件报警概率 $(1/4)/(1/2) = 1/2$ 。

n 个独立保留记录的均值 T 满足 $E[T]=1/2$ ， $\text{Var}(T)=1/(4n)$ 。对目标 $p=1/4$ ，偏差为 $1/4$ ， $\text{MSE}=1/(4n)+1/16$ 。交叉项因 $E[T - E[T]] = 0$ 消失。 n 趋大只减少第一项，留下偏差平方 $1/16$ 。

15. 数组轴的含义

形状 $(4000,64)$ 的一行是一批 64 次结果。 $\text{axis}=1$ 得到 4000 个均值，这是固定 $n=64$ 下的模拟抽样分布。 $\text{axis}=0$ 得到 64 个数，每个数是 4000 批在同一位置上的跨批均值；它研究的是不同的统计量。

全部拉平后只有一个总体平均数，合并了 256000 次结果。若原始生成真为完全独立，这个数是更大样本的均值，但它仍不能让你直接观察固定 $n=64$ 的批均值波动。正确轴不仅是形状问题，也是实验定义问题。

16. 一个完整但有边界的示例

可以选择“评估一个已经固定的模型对未来新用户的平均错误率”。目标总体是规定地区与时段的未来新用户，抽样单位是用户；每个用户事先规定只取一次预测， X 记录是否预测错误。统计量为 n 个用户的平均错误指示。

重复流程是重新从同一目标用户机制抽取 n 个用户，再用同一个固定模型评估。风险包括同一家庭或组织的相关、重复用户、只有活跃用户被记录、时间漂移，以及利用本次测试结果修改模型。不能验证真实独立或代表性时应说明证据不足，而不是只写iid。

若实际上每个用户保留多条记录，就应重新定义目标是“平均用户”还是“平均记录”，并处理群组结构。本讲复制例子提示问题，但没有给出所有真实场景通用的标准误估计器。