

第二十五讲 区间估计与Bootstrap

1. 一个点估计还没有回答的问题

第二十三讲用似然选择参数，第二十四讲在明确先验之后得到后验分布。现在假设我们用四次独立测量得到9、10、11、10，平均值是10。只报告“均值估计为10”，还缺一条重要信息：如果重新收集四次测量，结果通常会变多少？一个由这批数据算出的区间，可以把抽样不稳定性表达出来，但区间上的“95%”必须有明确的概率对象。

本讲围绕一个问题展开：**怎样为估计的不稳定性构造区间，并验证这个区间程序是否具有声称的表现？**我们先完成一个可以精确证明覆盖率的Gaussian例子，再看靠近边界的Bernoulli反例。随后用Bootstrap近似抽样分布，比较参数重采样、非参数重采样、配对重采样和分组重采样。最后把这些方法放进已知真值的合成世界，测量实际覆盖率及其Monte Carlo误差。

直接先修是第21至24讲：期望、方差与协方差；抽样分布和中心极限定理；似然与点估计；先验、后验与Beta-Bernoulli更新。我们会重写关键公式，不要求已经学过假设检验、Student t分布或Bootstrap的一般一致性定理。所有图和数据均为原创合成教学例子，不作为真实产品或真实人群的效果证据。




图1 同一个估计问题有三个概率层次。真实重复采样产生新数据；Bootstrap固定已观察数据再抽；贝叶斯后验固定数据并对参数作条件推断。

2. 先分清对象和形状

本讲主要估计标量参数，记为 $\theta \in \mathbb{R}$ 。Gaussian均值中它叫 μ ，Bernoulli成功概率中它叫 p 。

$X = (X_1, \dots, X_n)$ 是采样前的随机向量，形状为 $(n,)$ ； $x = (x_1, \dots, x_n)$ 是这次已经观察到的数值向量。点估计量是 $\hat{\theta} = T(X)$ ，观察后得到 $T(x)$ 。区间程序是两个统计量构成的集合

$$C(X) = [L(X), U(X)], \quad L(X) \leq U(X).$$

L 、 U 是下端点和上端点。采样前它们随机，观察后 $C(x)$ 是固定集合。若参数单位是秒，端点也必须是秒；方差单位则是平方秒。一个区间不只由“中心加减某个数”定义，还由采样模型、统计量和抽样单位共同定义。

写 P_θ 时，下标表示“使用真实参数为 θ 的数据生成分布计算概率”。频率学派覆盖率定义为

$$c(\theta) = P_{\theta}\{L(X) \leq \theta \leq U(X)\}.$$

这是关于随机数据 X 的概率， θ 在这个表达式中固定。所谓名义95%表示设计目标是0.95；实际 $c(\theta)$ 可能等于、略高于或远低于0.95。声称“至少95%置信水平”通常需要在所声称的整个参数空间证明 $\inf_{\theta} c(\theta) \geq 0.95$ 。只在几个参数上模拟，不能证明这个全称命题。

3. 从四次测量手算一个区间

先把模型写完整： $X_1, \dots, X_n$ 相互独立且同服从 $N(\mu, \sigma^2)$ ； μ 未知， $\sigma > 0$ 已知。已知标准差来自题设，不是偷偷把这四个数的样本标准差当成已知真值。第22讲给出

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad E_{\mu}(\bar{X}) = \mu, \quad \text{Var}_{\mu}(\bar{X}) = \frac{\sigma^2}{n}.$$

于是均值估计量的标准差，也叫标准误，是 $\text{SE}(\bar{X}) = \sigma/\sqrt{n}$ 。这里的SE衡量反复抽取 n 个观测后均值的变化，不是单条观测的波动，也不是已经计算出的均值本身的误差真值。

取 $n=4$ 、观测 (9, 10, 11, 10)、已知 $\sigma = 2$ 。样本均值为 $40/4=10$ ，标准误为 $2/2=1$ 。记标准正态分布的累积分布函数为 $\Phi(z) = P(Z \leq z)$ ，其中 $Z \sim N(0, 1)$ 。令

$z_{0.975} = \Phi^{-1}(0.975) \approx 1.9599639845$ 。下标0.975是左侧累计概率，不是置信水平本身；两侧各留0.025才得到中间0.95。

区间为

$$[10 - z_{0.975} \cdot 1, 10 + z_{0.975} \cdot 1] \approx [8.0400360, 11.9599640].$$

中心是10，半宽约1.96，总宽约3.92。如果独立样本数增加到16而同样已知标准差保持2，半宽减为约0.98。这里缩小的是标准误；增加重复抄写的数据行数不会产生这种收益。




图2 已知标准差时，从观察值到均值、标准误、区间端点的完整计算。右侧的样本量曲线只适用于增加真正独立的观测。

4. 精确95%覆盖率的逐步证明

本节明确接受两个前置数学结果：独立Gaussian随机变量的线性组合仍是Gaussian；标准正态CDF及其反函数的性质。Gaussian闭合性可在后续概率论中由特征函数证明，本讲不把它冒充为已经推导的结论。因为上一节已算出均值和方差，闭合性给出

$$\bar{X} \sim N(\mu, \sigma^2/n), \quad Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

标准化的分母严格为正，因此不等号方向不变。由标准正态分布对称性和分位数定义，

$$P_\mu\{-z_{0.975} \leq Z \leq z_{0.975}\} = \Phi(z_{0.975}) - \Phi(-z_{0.975}) = 0.975 - 0.025 = 0.95.$$

把Z代回去，乘以正数 $s = \sigma/\sqrt{n}$ ，得到 $-z_{0.975}s \leq \bar{X} - \mu \leq z_{0.975}s$ 。左半句等价于 $\mu \leq \bar{X} + z_{0.975}s$ ，右半句等价于 $\bar{X} - z_{0.975}s \leq \mu$ 。合并便得到

$$P_\mu\left\{\mu \in \left[\bar{X} - z_{0.975}\frac{\sigma}{\sqrt{n}}, \bar{X} + z_{0.975}\frac{\sigma}{\sqrt{n}}\right]\right\} = 0.95.$$

这个等式对任意实数 μ 和任意整数 $n \geq 1$ 成立，不需要“ n 足够大”，因为模型本身就是Gaussian。它是关于理想实数运算和精确分位数的数学结论；程序中的分位数和端点以float64近似计算。有限模拟接近0.95是数值核验，不能替代上述证明。

如果数据并非Gaussian，而只知道iid且方差有限，中心极限定理可在一定条件下支持大样本近似，却不能把上式继续称为有限 n 的精确等式。如果 σ 未知，直接把 s 样本标准差塞进分母，标准化量也不再精确服从标准正态。在Gaussian模型下应使用自由度 $n-1$ 的 t 分位数；这个 t 分布结论本讲只标记为后续理论，不在实验中混用。

5. 看见区间后应该怎样说

正确的简短报告可以是：“按独立Gaussian、标准差已知为2的模型，均值的95%置信区间为[8.04,11.96]。”如果解释95%的意思，应说：“在相同模型下反复抽样并按同一规则构造区间，覆盖固定真均值的比例趋向95%。”一次实现的区间要么包含这个固定参数，要么不包含；上述频率模型没有自动给参数分配一个后验概率。

这并不是说不能用概率表达对未知参数的不确定性，而是那需要另一个明确的概率模型。例如第二十四讲通过先验与似然构造参数的后验分布，条件于已观察数据后，可以说一个可信区间拥有95%的后验概率质量。两种表述的条件不同，不能仅凭端点相似就交换解释。

还要避免第三种混淆：均值的95%区间不是“95%的个体观测落入这里”。 n 很大时均值区间可以极窄，但单条观测的标准差仍是 σ 。预测一个未来观测需要包括新观测自身的噪声；预测区间与参数区间是不同问题。




图3 重复抽样时真均值是固定竖线，区间随样本变化。图中红色线段漏掉真值；某一幅图的漏失比例不必恰好等于5%。

6. 可信区间接上上一讲的后验

继续第二十四讲的八次三成功数据，取已明确的主先验 $p \sim \text{Beta}(2, 2)$ ，独立Bernoulli似然给出

$$p \mid x \sim \text{Beta}(2 + 3, 2 + 5) = \text{Beta}(5, 7).$$

$a=5$ 、 $b=7$ 是后验形状参数，都是正数。密度与 $p^{a-1}(1-p)^{b-1}$ 成比例，归一化后记为 $\pi(p \mid x)$ 。令 $F_{5,7}(t) = \int_0^t \pi(p \mid x) dp$ ，等尾95%可信区间取

$$[q_{0.025}, q_{0.975}] = [F_{5,7}^{-1}(0.025), F_{5,7}^{-1}(0.975)] \approx [0.1674880941, 0.6920952850].$$

因为这个后验连续且CDF严格递增，端点之间的后验概率为 $0.975 - 0.025 = 0.95$ 。合法的解释是：“在 $\text{Beta}(2, 2)$ 先验和iid Bernoulli模型下，给定这八次观察， p 落在该区间内的后验概率为95%。”这句话必须保留模型与先验的条件；它不是不依赖假设的现实保证。

该可信区间是否在每个固定 p 处都有95%的重复抽样覆盖？不能从后验质量直接推出。一个简单反例是 $p=0$ ：使用正形状Beta后验的等尾区间，下端点总大于0，因此在边界真实 $p=0$ 时覆盖率为0。若先从给定先验随机抽参数，再抽数据，后验95%集合在这个联合模型下的平均覆盖为95%，可由全期望公式推出；这个“按先验平均”的结论与“对每个固定 p ”不同。




图4 Beta(5,7)后验密度中间着色部分的质量为0.95，左右尾部各0.025。它描述给定数据后的参数不确定性，不是Bootstrap复制的分布。

7. 可信端点怎样数值核验

本讲不以一个黑箱分位数函数的输出作为唯一证据。对于正整数 a, b ，令 $M = a + b - 1$ ，Beta CDF 可写为有限和

$$F_{a,b}(t) = \sum_{j=a}^M \binom{M}{j} t^j (1-t)^{M-j}, \quad 0 \leq t \leq 1.$$

为什么这个式子成立？对每项求导，用 $j \binom{M}{j} = M \binom{M-1}{j-1}$ 和 $(M-j) \binom{M}{j} = M \binom{M-1}{j}$ ，相邻项正负抵消，只剩

$$F'_{a,b}(t) = \frac{M!}{(a-1)!(b-1)!} t^{a-1} (1-t)^{b-1}.$$

这正是整数形状Beta的归一化密度；原式在 $t=0$ 为0，所以它与密度积分得到的CDF相同。这个有限和不需要带负号的高阶多项式相消，对本课的5、7形状十分方便。我们没有由此提供任意实数形状Beta的通用求值器。

在 $[0,1]$ 区间二分：中点CDF小于目标 q 就向右移动下界，否则向左移动上界。由于CDF连续严格递增，真分位数始终留在夹逼区间内；理想算术下60步后区间宽为 2^{-60} ，但float64约在第53步之后可能因舍入不再缩小。因此报告精度由数值误差共同限制，不能把60步说成60位精度。

作者核验用三条路线：教学有限和与二分；对Beta(5,7)密度用独立数值积分并求根；SciPy的Beta PPF作为另一路参考。Notebook显示端点CDF残差，测试还用高精度Decimal和有理数有限和检验多个形状。库版本与检查范围记录在验收证据中。极端尾部或很大形状参数不在本课接口范围。

8. Bernoulli边界让Wald区间失灵

Bernoulli(p)样本的均值 $\hat{p} = K/n$ 是成功比例， K 为成功总数。若用正态近似并把未知 p 替换为 $\hat{p}$ ，得到常见的Wald区间

$$\hat{p} \pm z_{0.975} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

这是近似方法，不是前面已知方差Gaussian证明的直接延伸。问题在边界尤其明显：当 $K=0$ 时 $\hat{p} = 0$ ，估计标准误为0，区间坍缩为 $[0,0]$ 。但若真实 $p=0.02$ 、 $n=20$ ，出现全零样本的概率是 $0.98^{20} \approx 0.667608$ 。在这些样本上，区间全部漏掉真实的0.02。

甚至不用模拟，就可以把 $n+1$ 种 K 枚举出来。令 I_k 是成功数 k 时的Wald区间，实际覆盖率为

$$c(p) = \sum_{k=0}^n \mathbf{1}\{p \in I_k\} \binom{n}{k} p^k (1-p)^{n-k}.$$

$\mathbf{1}\{\cdot\}$ 是指示函数，条件成立为1，否则为0。对于 $n=20$ 、 $p=0.02$ ，只有 $k=1, 2, 3$ 时区间覆盖，精确二项求和为约0.3317923493，远低于0.95。这是有限离散枚举的概率值，只有浮点舍入误差，没有Monte Carlo抽样误差。

把负端点裁到0、把超过1的端点裁到1，并不能修复这个失败。对真实 p 位于 $[0,1]$ 的情形，区间与参数空间求交不改变“是否包含 p ”这个事件； $K=0$ 时仍是 $[0,0]$ 。Wilson分数区间或反演二项尾概率有不同性质，但需要新的推导，不能在图上画一条更漂亮的线就声称问题已经解决。




图5 $n=20$ 时Wald区间的精确覆盖率随真实 p 显著变化。离散台阶与边界失败是真实方法性质；不是模拟次数太少造成的抖动。

9. Bootstrap到底复制了什么

当统计量复杂、抽样分布难以写出时，Bootstrap的想法是用一个可构造的分布代替未知生成分布，模拟同样大小、同样结构的新样本，然后重新计算统计量。这里用星号表示“条件于当前数据的重采样世界”： X^* 是复制样本， $\hat{\theta}^* = T(X^*)$ 是复制估计量。

参数Bootstrap先拟合一个参数模型 $P_{\hat{\eta}}$ ，再从这个拟合模型产生数据。这里 η 是用于生成数据的全部模型参数，不一定只有目标参数 θ 。例如本课Gaussian标准差已知，估计均值为 $\bar{x}$ 后，可以从 $N(\bar{x}, \sigma^2)$ 抽 n 个值，再取平均。新数值可以不在原样本中；模型形状完全由Gaussian假设规定。

非参数Bootstrap用经验分布 $\hat{F}_n$ 代替未知分布 F ：给原样本的每一条索引各 $1/n$ 质量。从 $\hat{F}_n$ 独立抽 n 次，等价于从索引 1 至 n 中**有放回**抽 n 次，然后读取对应数值。相同数值的不同记录仍是不同索引，其总概率质量相加。若无放回抽 n 条，对样本均值来说只是排列原数据，均值完全不变，无法模拟抽样不确定性。

B 表示复制次数，复制结果是形状 $(B,)$ 的数组 $(\hat{\theta}_1^*, \dots, \hat{\theta}_B^*)$ 。 B 变大主要减少我们对Bootstrap条件分布的计算近似误差；它不增加原始样本量 n ，也不能让有偏数据代表总体。Bootstrap没有从数据之外发现未观察到的人群或尾部。




图6 参数Bootstrap从拟合Gaussian产生新数值；非参数Bootstrap抽原样本的索引。两种过程都需要重新计算目标统计量，并保持原采样结构。

10. 两个数就能完全枚举Bootstrap

令观察样本 $x=(0,2)$ ，估计目标是总体均值，点估计 $\bar{x} = 1$ 。每次从两个索引有放回抽两个，一共有 $2^2 = 4$ 个等概率有序索引结果：

索引结果	复制数值	复制均值	条件概率
(1,1)	(0,0)	0	1/4
(1,2)	(0,2)	1	1/4
(2,1)	(2,0)	1	1/4
(2,2)	(2,2)	2	1/4

合并相同均值后，0、1、2的概率分别为1/4、1/2、1/4。因此 $E_*(\bar{X}^*) = 1$ ， $\text{Var}_*(\bar{X}^*) = (0 - 1)^2/4 + 0/2 + (2 - 1)^2/4 = 1/2$ ，Bootstrap标准误为 $\sqrt{1/2} \approx 0.7071$ 。下标星号表示“固定这次观察样本后”的条件期望和方差。

本讲统一使用逆经验CDF分位数：对概率 q ，选累计质量首次达到 q 的最小支持点。因0的质量已经是1/4，2.5%分位数是0；97.5%分位数是2，百分位区间为[0,2]。没有必要抛4000次硬币去近似这四个结果，完全枚举给出无Monte Carlo误差的Bootstrap条件分布。

但“条件分布算得精确”不等于“总体均值区间覆盖率精确95%”。例如真实分布是以0.99概率取0、以0.01概率取100的总体，均值为1。两条原始观察全为0的概率高达0.9801；非参数Bootstrap只会复制0，百分位区间是[0,0]，会漏掉均值1。精确求出了错误近似模型的结果，也仍可能是很差的推断。




图7 样本(0,2)的四种有序复制合并为三个均值支持点。B次Monte Carlo只近似这份已知离散分布；图中文字给出其精确条件标准误。

11. 均值Bootstrap方差可以直接推导

固定任意观察样本 x ，非参数Bootstrap单次抽取 X_j^* 的均值为 $\bar{x}$ ，方差为 $n^{-1} \sum_i (x_i - \bar{x})^2$ 。n次复制抽取在条件世界中独立，所以

$$\text{Var}_*(\bar{X}^*) = \frac{1}{n} \left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right] = \frac{n-1}{n^2} s^2,$$

其中 $s^2 = (n-1)^{-1} \sum_i (x_i - \bar{x})^2$ 是n至少为2时的样本方差。对比常见的均值方差估计 s^2/n ，非参数Bootstrap条件方差多了因子 $(n-1)/n$ 。小n时这个差别并不小，n=2时恰好是1/2。

若我们只有B个Monte Carlo复制值，可以用它们的样本标准差估计条件标准误：

$$\widehat{\text{SE}}_* = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2}, \quad \bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

分母B-1是对复制分布方差的估计，不是把前面n与n-1的差别消除了。层次要分清：原始有限样本对总体的近似误差，与有限B对条件分布的Monte Carlo误差，来源不同。

对均值的常规非参数Bootstrap，一般有效性需要iid、足够规则的统计量与分布条件，例如有限且非零的总体方差。本讲只给均值条件矩的直接计算和反例，不证明一般Bootstrap一致性，不把它推广到样本最大值、无限方差重尾分布、依赖时序或模型选择后的任意统计量。

12. 从复制分布到区间还有方法选择

令 q_a^* 是Bootstrap估计量条件分布的a分位数，百分位区间定义为

$$C_{\text{pct}}(x) = [q_{0.025}^*, q_{0.975}^*].$$

它把复制估计值中间95%的范围当作参数区间。这个步骤依赖Bootstrap近似和统计量的分布形状，不来自“复制值有95%在中间”这个事实本身。若点估计偏差大、分布强烈不对称或参数在边界，百分位区间可能严重失准。

另一种叫基本区间。其想法是用 $\hat{\theta}^* - \hat{\theta}$ 的分布近似 $\hat{\theta} - \theta$ 的分布。假设两个误差分位数为a、b，事件 $a \leq \hat{\theta} - \theta \leq b$ 等价于 $\hat{\theta} - b \leq \theta \leq \hat{\theta} - a$ 。由于复制误差在任一概率水平的分位数，等于复制估计量的相应分位数减去 $\hat{\theta}$ ，得到

$$C_{\text{basic}}(x) = [2\hat{\theta} - q_{0.975}^*, 2\hat{\theta} - q_{0.025}^*].$$

这里端点次序反转，是移项导致的，不是排版习惯。Bootstrap-t、偏差校正与加速区间BCa又是其他方法；它们有各自计算要求和失败情形。本课实验固定使用百分位方法，不把所有方法混称为“Bootstrap95%区间”，也不声称某个软件默认方法必然适合当前样本。

对于已知方差Gaussian均值，参数Bootstrap的复制均值条件分布正好是 $N(\bar{x}, \sigma^2/n)$ 。如果使用这个分布的精确分位数，百分位区间恰好等于第4节的精确区间。但如果只取B=399个复制均值的经验分位数，端点还带额外Monte Carlo随机性，其有限B覆盖不必恰好0.95。这个特例不支持任意参数Bootstrap的精确覆盖主张。

13. 分位数约定也会改变答案

把B个复制值排序为 $t_{(1)} \leq \dots \leq t_{(B)}$ 。本课逆经验CDF约定在 $0 < q \leq 1$ 时取 $t_{(\lceil Bq \rceil)}$ ，q=0时取最小值。B=399时，2.5%分位数取第10个，97.5%分位数取第390个。代码的数组从0开始，所以对应索引9和389。

有些软件默认在线性插值后报告分位数，所得端点可能不在复制值里。这不是必然错误，但必须报告约定，尤其在离散统计量和很小B时。例如复制数组(0,1,1,2)的逆CDF百分位区间为[0,2]；线性插值的2.5%和97.5%分位数分别为0.075与1.925。方法描述中只写“调用quantile”不够可复现。教学分位数接口按q的最短十进制表示做有理数秩计算，避免 0.14×50 浮点舍入略大于7而错选下一项；主模拟固定使用0.025与0.975以及整数B，在支持的B范围另做秩一致性检查。

加权逆CDF也有细节：零权重支持点不应影响q=0的最小正质量支持点，但所有输入仍须先验证。一个权重为0、值为NaN的记录不能被默默忽略；它可能代表上游数据损坏。本课接口先检查每一个值、每一个权重和q，再开始排序与累计。负权重、全零权重、长度错位均报错。

14. 配对数据必须一起抽

现在估计同一个体的平均变化 $\Delta = E(Y - X)$ 。每个独立个体提供一对 (X_i, Y_i) ，不同个体独立，但同一个体前后测量通常相关。令 $D_i = Y_i - X_i$ ，点估计为 $\bar{D}$ 。若方差存在，

$$\text{Var}(Y - X) = \text{Var}(Y) + \text{Var}(X) - 2 \text{Cov}(X, Y).$$

因此 $\text{Var}(\bar{D}) = \text{Var}(D)/n$ 。配对Bootstrap每次抽个体索引 i ，把同一个 i 的前后两列一起带走。等价做法是先算 D ，再对 D 有放回抽样。分别独立抽两列会破坏协方差，变成模拟两个独立边际样本的均值差。

手算例子是before=(1,2,4,8)，after=(2,3,5,9)，四个差值都等于1。因此每一份合法配对复制的平均差都是1，条件标准误严格为0。若独立抽列，可能拿到before=(8,8,8,8)、after=(2,2,2,2)，复制均值差为-6；也可能出现反向极端。这些变化不是原配对采样设计里的不稳定性。

这个例子中的零Bootstrap标准误只表示“当前经验分布的所有差值相同”。它没有证明总体变化毫无异质性，也没有证明因果效果为1。若前后相关为正，独立抽列通常夸大变化估计的方差；若为负，则可能低估。不能笼统说“忽略相关总让区间过窄”。




图8 同一个体两列必须共享索引。四个恒定增量在配对复制下保持1；独立抽列创造了原配对设计中不存在的差异。

15. 分组数据的独立单位不等于行

设有 G 个独立组，每组 m 条观察，形成形状 (G, m) 的矩阵。教学生成模型为

$$X_{gj} = \mu + A_g + \varepsilon_{gj}, \quad A_g \sim N(0, \tau^2), \quad \varepsilon_{gj} \sim N(0, \sigma^2).$$

g 从1到 G ， j 从1到 m ；所有组效应和所有噪声相互独立，同组所有行共享一个 A_g 。于是单行方差为 $\tau^2 + \sigma^2$ ，同组不同行协方差为 τ^2 ，不同组协方差为0。目标是新组总体的平均水平 μ 。因为各组等大，总行均值与组均值的平均相同：

$$\hat{\mu} = \frac{1}{G} \sum_{g=1}^G \bar{X}_g, \quad \bar{X}_g = \frac{1}{m} \sum_{j=1}^m X_{gj}.$$

将生成式代入， $\hat{\mu} = \mu + G^{-1} \sum_g A_g + (Gm)^{-1} \sum_{g,j} \varepsilon_{gj}$ 。两部分独立，故

$$\text{Var}(\hat{\mu}) = \frac{\tau^2}{G} + \frac{\sigma^2}{Gm}.$$

若错误地把 Gm 行当成iid，则会用 $(\tau^2 + \sigma^2)/(Gm)$ ，漏掉组内共享效应带来的协方差。两者比值为 $1 + (m-1)\rho$ ，其中 $\rho = \tau^2/(\tau^2 + \sigma^2)$ 是组内相关系数。 ρ 为0才退回iid情形； ρ 接近1时，同组增加行数远不如增加独立组数。

正确的简单组Bootstrap每次从G个组索引有放回抽G次，每个抽中的组完整带走m行；同一组被抽中两次要保留两份，不能去重。本课计算总均值时可先算G个组均值，再重采样这些均值，结果与完整搬运各组完全相同。行Bootstrap则把矩阵摊平后抽Gm行，破坏了相关结构。




图9 三组每组两条且组内相同的手算样本。按组抽取保留同色的整组，按行抽取拆散相关结构；右侧是默认模型的真方差与错误iid方差。

16. 组大小不等时必须先说目标是谁

如果某组有2个人、另一组有100个人，“平均组水平”与“平均人水平”不一定相同。设第g组大小 m_g ，组均值 $\bar{x}_g$ ，则平均组估计是 $G^{-1} \sum_g \bar{x}_g$ ，平均行估计是 $\sum_g m_g \bar{x}_g / \sum_g m_g$ 。前者每组权重相同，后者大组权重重大。

极小例子：A组只有1条，值0；B组有3条，值都为10。平均组水平为 $(0+10)/2=5$ ，平均行水平为 $30/4=7.5$ 。这个差异来自目标与权重，不是随机种子。若组大小本身也是随机且与组水平相关，平均行目标通常涉及总体比值 $E(\text{组总和})/E(\text{组大小})$ ，不能直接当成 $E(\text{组均值})$ 。

所以本课对“按组与按行”覆盖对照明确限制为等组大小，保证比较的点估计与目标一致。公开接口发现组大小不等时直接报错，而不是自动填空、丢行或偷偷换估计目标。现实数据的分层、多阶段、不等概率抽样或有限总体设计，需要据采样方案决定权重与重采样层次，本讲没有给出通用调查抽样方案。

17. 用两层循环检查覆盖率

模拟覆盖率必须知道真参数。外层第r次实验，从真实生成模型重新抽一份数据 $X^{(r)}$ ，再按待测方法得到区间 $[L_r, U_r]$ 。记录 $H_r = \mathbf{1}\{L_r \leq \theta_0 \leq U_r\}$ ，r从1到R，其中 θ_0 是我们在合成世界设定的真值。

$$\hat{c}_R = \frac{1}{R} \sum_{r=1}^R H_r.$$

对Bootstrap方法，每个外层样本内还有B次重采样。外层R控制“覆盖率测量”的精度；内层B控制“给定样本的Bootstrap端点”的计算精度。把同一批原样本Bootstrap十万次，只得到一个区间程序在这份样本上的端点近似，不能当作十万次独立覆盖试验。

默认Gaussian实验为 $\mu = 3, \sigma = 0.5, n = 20, R = 3000, B = 399$ ；组实验为 $G = 24, m = 6, \tau = 2, \sigma = 0.5, R = 1000, B = 399$ ，目标也为 $\mu = 3$ 。使用PCG64和种子25025，外层数据与内层重采样分成独立随机流。所有区间采用闭区间包含规则；连续模型中等于端点的概率为0，离散数据中这个细节则可能影响结果。

模拟里不同方法使用同一批外层数据，便于公平比较，所以同一行的“命中”结果可能相关。单方法Monte Carlo标准误可以直接算；若要给两个覆盖率之差作误差条，应对每次实验的命中差 $H_{r,A} - H_{r,B}$ 估计方差，而不能假设两个覆盖率独立。本课只报告各方法的边际误差，不进行方法差异的显著性检验。

18. 有限模拟的结果与误差分开报告

理想情况下外层各次独立，则 H_r 是成功概率 c 的Bernoulli变量，覆盖比例方差为 $c(1 - c)/R$ 。用 $\hat{c}_R$ 替代 c 得到Monte Carlo标准误估计

$$\widehat{SE}_{MC} = \sqrt{\hat{c}_R(1 - \hat{c}_R)/R}.$$

它是“测得的覆盖率”的计算不确定性，不是均值估计的标准误，更不是端点的标准误。若命中全为0或1，插件标准误会是0，仍不表示我们已知道 c ；所以报告另外提供针对Monte Carlo命中率的Wilson分数区间。该辅助区间也是有限样本近似，不把它宣称为精确95%保证。

场景与方法	命中次数 / 外层次数	覆盖比例	MC标准误	平均区间宽
Gaussian 已知 σ 公式	2867 / 3000	0.955667	0.003758	0.438261
Gaussian 非参数百分位	2797 / 3000	0.932333	0.004586	0.423795
Gaussian 已知 σ 参数百分位 B=399	2866 / 3000	0.955333	0.003771	0.442073
组模型 按行百分位	590 / 1000	0.590000	0.015553	0.658888
组模型 按组百分位	936 / 1000	0.936000	0.007740	1.566620

已知 σ 公式的数学覆盖率恰为0.95，但本次有限模拟给出0.955667，差异约为1.51个估计MC标准误，完全不能据此把理论改成95.5667%。组Bootstrap明显改善行Bootstrap的严重漏盖，却没有在这个有限设计中达到一个已经证明的精确95%性质。按组结果的MC Wilson区间约为[0.91910,0.94956]，提醒我们有限组数、百分位近似和有限B都还在起作用。

默认组模型真方差为 $4/24 + 0.25/144 = 0.16840278$ ；错误iid方差为 $4.25/144 = 0.02951389$ 。真实标准误约0.41037，iid估算约0.17180。错误区间更窄并不是更高精度，而是遗漏了共享误差。这里的解析方差与覆盖实验是两条相互印证但不等价的证据。




图10 默认有限模拟的覆盖比例及针对Monte Carlo命中率的Wilson误差条。虚线为名义0.95；按组修复抽样单位仍不构成有限样本精确性证明。

19. 数值与输入边界也是统计方法的一部分

公开脚本在任何随机数生成、重采样或输出文件创建之前，验证所有输入文件及全部参数。数值接口拒绝bool、文本、复数、NaN和无穷；数据数组先逐元素检查再转为float64。最后一项、这次没有抽中的记录、当前分支未用的sigma、权重为0的记录都要检查。CSV是文本格式，只有专门的CSV解析器允许符合十进制语法的数字字符串；它还拒绝溢出和解析为0的非零下溢文本。

实现采用保守教学域：一般数值绝对值至多 10^6 ，非零绝对值至少 10^{-100} ；均值和方差只在这个有限范围演示。非恒定数据的非零中心化离差若小于 10^{-100} ，标准差接口要求先明确换单位。相同float64数值的标准差在完整验证后精确返回0，包括0.1重复多次；不能用减去一个已经舍入偏移的均值制造虚假的极小方差。

输入域之外的实数并非数学上非法，只是本课程程序不支持。已经被上游转成float的文本“1e-400”只剩0，数值接口无法恢复其丢失的原始信息；CSV解析器能因为保留了原始字符串而拒绝它。同样，若上游先把bool与整数混在NumPy整数数组中，类型来源已丢失，后续函数无法知道哪个1原来是True。

默认实验有明确CPU预算，不用付费API、不下载数据。它检验方法机制，不检验大规模性能。作者以新Python进程、两个无关工作目录和优化模式运行，并逐格执行保留输出的Notebook。Notebook使用真实IPython InProcessKernel；Anaconda安装、浏览器Jupyter界面和socket内核传输没有在此环境实测，不能写成“所有平台完整通过”。

20. 从这一讲带走的工作顺序

先问估计目标是谁，再问哪一层对象独立，然后写区间程序。能精确推导时先推导；使用近似时写明条件；使用Bootstrap时说明模型、统计量、抽样单位、B和分位数约定。对合成数据可以测覆盖率，但必须把有限Monte Carlo误差与统计近似误差分开。

遇到失败时，先找结构原因：参数边界、样本遗漏稀有尾部、配对被拆开、组内相关被当成独立、组大小改变估计目标、只增加B却没有新数据。一次区间端点看起来合理，不是有效性证据；一张模拟图接近95%，也不是所有参数、所有分布和所有样本量上的保证。

下一讲将讨论如何把数据与一个明确的假设联系起来。区间与检验可以建立关系，但这不会改变本讲的中心区别：随机的是哪个对象、条件是什么、错误概率对什么重复机制定义。

21. 自测题与阅读线索

不看答案，完成以下核心任务。全部18题及推导在单独的answers.pdf；lab.pdf给出独立操作路线。

1. 对 $x=(9,10,11,10)$ 、已知 $\sigma=2$ ，写均值、标准误和95%区间，逐步证明覆盖率。
2. 用自己的话解释置信区间、可信区间和未来观测的预测范围。
3. 完全枚举 $x=(0,2)$ 的Bootstrap均值分布，求条件方差和百分位端点。
4. 推导均值Bootstrap条件方差与 s^2/n 的差别。
5. 为什么配对恒定变化得到精确零条件标准误，而独立抽列却不为零？
6. 推导组模型的均值方差，并说明增加 m 与增加 G 的差别。
7. 解释为何按组覆盖93.6%不能直接改写成“按组Bootstrap是93.6%方法”。

来源只用于术语核查、定义与方法背景，本文手算、证明、图和实验独立撰写。NIST的均值置信限说明重复抽样解释；Shalizi的Bootstrap作者讲义讨论拟合模型与重采样；NumPy分位数文档用于明确inverted_cdf约定；SciPy Bootstrap文档核对配对与区间术语；SciPy Beta文档说明独立参考PPF接口。Efron的1979年原始论文作为历史延伸阅读；本次出版方页面只返回入口框架，未据它声称已逐页检查全文。完整访问与适用范围记录在source-checks.json。