

第二十六讲 练习详解

本文件逐题回答正文的十八道练习。先写随机对象与模型，再算数值，最后说明结论边界。全部数据是合成教学分；数值计算并不证明真实实验满足模型。配对方向统一为B-A，显著性水平在看数据前设为.05。

1. 实验单位与总体参数

实验单位是一个被同时赋予A、B读数的独立配对单位，不是一个单独分数，也不是两列共16个互相独立的观测。令第*i*个单位的随机读数为 A_i 、 B_i ，随机差值 $D_i=B_i-A_i$ 。其总体平均差 $\delta=E[D_i]$ 是未知参数；样本平均差是对 δ 的估计量，读到数据后其实现值为2。

主例差值为3、2、4、1、-1、0、2、5，总和16，除以 $n=8$ 得到2分。双侧问题为 $H_0:\delta=0$ ，对 $H_1:\delta\neq 0$ 。零假设没有声称每个单位都没有差异；即使 $\delta=0$ ，也可以有正负个体差异。若目标是改善超过1.5分，零假设必须相应改写，而不是继续让零差异检验代答。

2. 两种错误与功效

第一类错误事件为“在零模型下拒绝 H_0 ”。简单零假设的概率写为 $P_0(\text{拒绝})$ ；复合零假设必须对每个允许零参数控制，不能只挑容易控制的一点。第二类错误是在某个真实 $\delta\neq 0$ 时不拒绝，记为 $\beta(\delta)=P(\text{不拒绝}|\delta)$ 。功效为 $1-\beta(\delta)$ 。

功效必须指定 δ ，因为离零很近与很远的生成分布，落入拒绝域的机会不同。对已知 σ 、独立Gaussian样本，相同 n 与 α 下， $|\delta|$ 增大通常提高双侧功效； σ 增大则降低信噪比。不能把单次不显著解读为 $\delta=0$ ，也不能把 α 说成已发表结论错误的概率。

3. 从混合模型算条件概率

在题设虚构总体中，抽到零题目的概率为.9，抽到非零题目的概率为.1。联合概率为 $P(\text{零且拒绝})=.9\times .05=.045$ ， $P(\text{非零且拒绝})=.1\times .8=.08$ 。两类互斥，因此总拒绝概率为.125。使用条件概率定义，得到

$$P(\text{零} | \text{拒绝}) = \frac{.045}{.045 + .08} = .36.$$

以10000个题目理解：期望有9000个零题目，其中450个误拒；1000个非零题目，其中800个被发现；1250个拒绝中450个来自零题目。这个期望计数只解释给定模型，不是实际观测计数，也不是从一个 p 值估计出的后验。改变题目比例或功效，36%就会变化。

4. 尾部、并列与条件方向

本讲先定义数值越大越极端的统计量 T ，再用 $P_0(T \geq t_{\text{观测}})$ 。有限枚举时，每个原始标号结果有概率质量；若观察值处有并列，所有并列都要算入尾部。主例用严格大于16会只保留±18，而漏掉±16，给出错误的更小 p 值。

连续情形单点概率为0， $\geq$ 与 $>$ 概率相同；这不允许把结论推广到离散情形。 p 值是给定零模型后，某个数据事件的概率。 $P(H_0|\text{数据})$ 是把假设当作随机对象后的另一种条件概率，需要假设权重与替代模型等额外信息。频率学派检验规则自身没有提供这些信息。

5. 已知 σ 的 z 计算

设 D_i 独立同服从 $\text{Gaussian}(\delta, 4)$ ， $\sigma=2$ 是外部预先知道的总体标准差。均值为 $\text{Gaussian}(\delta, 4/8)$ ，所以在 $\delta_0=0$ 下， $Z=(\text{平均差}-0)/(2/\sqrt{8})$ 是标准正态。代入平均差2，标准误 $1/\sqrt{2}$ ， $z=2\sqrt{2} \approx 2.828427$ 。

双侧 $p=2P(Z \geq 2\sqrt{2}) \approx .004677734981$ ；.05双侧临界值 $c \approx 1.959963985$ 。95%区间半宽为 $c/\sqrt{2} \approx 1.385903824$ ，区间为 $[-.614096176, 3.385903824]$ 。区间不含0，符合检验拒绝的结论。

样本标准差碰巧也等于2并不能让“外部已知 σ ”成立。若2只是从这8条估计的，应该用未知 σ 的参考分布。代码用sf尾函数计算小尾概率，避免1减去接近1的CDF丢失精度；超出本实现范围时明确报错。

6. 区间与检验的边界

记正标准误为 s_e ，临界值 $c>0$ 。由绝对值定义， $|\text{估计}-\delta_0| \leq cs_e$ 等价于 $-cs_e \leq \text{估计}-\delta_0 \leq cs_e$ ；移项得到估计 $-cs_e \leq \delta_0 \leq \text{估计}+cs_e$ 。因此闭区间内参数对应不超过临界绝对统计量。

本脚本拒绝规则取 $p \leq \alpha$ ，在恰好等于临界值时拒绝，而闭区间仍包含那个端点。严格逐点反演时， $p \leq \alpha$ 应配开区间； $p < \alpha$ 应配闭区间。连续模型下恰好等于边界的概率为0，所以通常称二者等价而不影响覆盖率或错误率。离散问题则不能忽略端点，须完整声明规则。

上述代数只对同一统计量、分布与 α 成立。随意挑Bootstrap区间与某个 t 检验，并没有自动建立反演关系。

7. 学生化与自由度

差值均值为2，离差为1、0、2、-1、-3、-2、0、3。平方和为 $1+0+4+1+9+4+0+9=28$ 。估计均值消耗一个线性自由度，所以样本方差定义为 $28/(8-1)=4$ ，样本标准差 $s=2$ ，估计标准误 $2/\sqrt{8}=1/\sqrt{2}$ 。

统计量 $t=(2-0)/(1/\sqrt{2})=2\sqrt{2}$ ，与 z 数值相同。但分母 s 是随机量，在独立Gaussian差值、真实 $\sigma>0$ 的模型下， T 服从 t_7 。小自由度的 t 尾部更厚，因此相同观察统计量对应更大 $p \approx .025463562$ 。 t_7 双侧.05临界值约2.364624252，区间半宽1.672041843，得到 $[-.327958157, 3.672041843]$ 。

本讲接受Gaussian均值与残差平方和独立及精确Student定理，不假装由这道手算证明定理。若全部差值相等，则 $s=0$ ，脚本返回结构化退化状态，不给NaN或 $p=0$ 贴上“检验成功”。

8. 配对方差的展开

令中心化随机变量 $A' = A - E[A]$, $B' = B - E[B]$ 。差值的中心化量为 $B' - A'$ ，平方后取期望： $E[(B' - A')^2] = E[B'^2] + E[A'^2] - 2E[A'B']$ 。这就是 $\text{Var}(B - A) = \text{Var}(B) + \text{Var}(A) - 2\text{Cov}(A, B)$ 。样本版本使用相同分母 $n-1$ ，逐项展开同样成立。

本例A均值11.5，A离差平方和42，所以 $s_A^2 = 6$ ；B均值13.5，B离差平方和22，所以 $s_B^2 = 22/7$ ；交叉离差总和18，所以样本协方差 $18/7$ 。于是 $s_D^2 = 6 + 22/7 - 36/7 = 4$ ，差值均值方差估计为 $4/8 = 1/2$ 。

错误忽略配对会给 $(6 + 22/7)/8 = 8/7$ 。这个量大于 $1/2$ 来自本例正协方差；不是配对永远更精确的普遍定理。重排B列会改变协方差与差值分布，即使两列各自均值都没变，也已经改变了设计。

9. 符号翻转需要什么

一种设计条件是零假设下每一对A、B可独立等概率交换，条件于未标号的对，所有 2^n 个标签一样可能。另一种总体条件是差值独立且分别关于0对称，条件于绝对值的非零符号公平。零差值的两个符号产生相同数值，但可以作为两个标签保留。

反例：令D以 $2/3$ 概率取1，以 $1/3$ 概率取-2。均值为 $2/3 - 2/3 = 0$ ，但 $P(D > 0) = 2/3$ ，正负取值幅度也不对称。条件于 $|D|=1$ 时符号一定为正，不是公平硬币。因此不能仅凭零均值就枚举公平符号，并声称得到适用于该分布的精确检验。

此外，各差值边际对称也不自动给独立符号。如果所有差值都由同一个随机符号驱动，其联合符号结构就不等于 2^n 个独立交换。

10. 手数十二个标签

绝对值为3、2、4、1、1、0、2、5，总和18。从全正开始，翻转一个绝对值为 w 的位置会让总差减少 $2w$ ，因此达到正尾总差 ≥ 16 要求被翻的绝对值之和 ≤ 1 。

在七个非零位置中，有三种可能：不翻任何位置；翻第一个绝对值1；翻第二个绝对值1。零位置可任意选择正负标签，乘以2，所以正尾6个。整体反号给负尾6个，两尾互斥，总计12个。分母保持 $2^8 = 256$ ，故 $p = 12/256 = 3/64 = .046875$ 。

更细看，+18有2个标签，+16有4个；-18有2个，-16有4个。若只保留19个不同总差值并给它们同样权重，就破坏了原始标签概率。全零向量时所有标签都与观察一样极端， $p=1$ ，而不是0。

11. 三个模型与随机枚举

z模型把 σ 当外部已知；t模型估计 σ 并使用Gaussian样本定理；符号翻转模型依赖交换或零对称，参考分布条件于观察到的绝对值。它们检验的程序不同，p值不应当被当作一组三个可自由挑选的备选输出。

如果看完三个结果后选最小者，实际规则变成“任何方法过线就报告显著”。原先每项的控制不自动控制这个新选择事件。应先按设计确定主要方法，再透明地把其他方法作为明确条件下的敏感性分析，而非筛选最有利的一个。

若只随机抽B个置换且b个至少同样极端，“b=0”只表示有限样本没抽到，不能证明精确 $p=0$ 。适当的随机化方案会把观察数据纳入参考集合，用 $(b+1)/(B+1)$ 等修正。该表达式也依赖有效的抽样构造，不是任意自制采样器都可盲用的护身符。本讲完整枚举，无Monte Carlo p 误差。

12. 两分、一个标准差与实用判断

原始平均效应为2教学分。配对标准化效应 $d_z = \text{平均差}/sD = 2/2 = 1$ 。它用差值的标准差作单位，不用均值标准差；若错误除以 $1/\sqrt{2}$ ，会得到 $2\sqrt{2}$ ，那是本例零假设下的检验统计量而不是 d_z 。

事先实用阈值1.5落在 t 区间 $[-.32796, 3.67204]$ 内。该区间排除0，仍然包含未达到1.5的效应，因此拒绝零差异不足以建立超过1.5。如果预先问 $\delta > 1.5$ ，单侧统计量是 $(2-1.5)/(1/\sqrt{2}) = 1/\sqrt{2}$ ，参考 t_7 右尾，不能沿用 $\delta_0=0$ 时的双侧 p 。

$d_z=1$ 也没有自动行业含义。量表、成本、风险和可接受改善应在科学或实际背景里解释；本讲阈值只是教学选择。

13. 功效公式的来源与方向检查

在真实 δ 下， $Z = (\text{平均差} - 0)/(\sigma/\sqrt{n})$ 服从 $N(\lambda, 1)$ ， $\lambda = \delta\sqrt{n}/\sigma$ 。拒绝区域由零模型事先固定为 $Z \geq c$ 或 $Z \leq -c$ 。令 $W = Z - \lambda$ ，则 W 服从标准正态，所以

$$P_\delta(\text{拒绝}) = P(W \geq c - \lambda) + P(W \leq -c - \lambda) = 1 - \Phi(c - \lambda) + \Phi(-c - \lambda).$$

$\delta=0$ 时 $\lambda=0$ ，两尾之和为 α 。对 $\lambda \geq 0$ ，功效对 λ 的导数为 $\phi(c-\lambda) - \phi(c+\lambda) \geq 0$ ，因为 $|c-\lambda| \leq c+\lambda$ ；因此固定非零 δ 与 σ ，增加 n 会增加 $|\lambda|$ 并提高功效。降低 α 会使 c 增大，拒绝域收缩，在任何固定替代分布下拒绝概率不会增加。

$\delta=1$ 、 $\sigma=2$ 时， $n=8$ 、32、128理论功效约.292989、.807430、.999891。它们是规划模型下的概率，不是这次观察结论的可靠程度。模拟得到.2999、.8073、.9998，与理论接近但不要求完全相等；其计算误差与原始实验抽样误差不同。

14. 至少一次不是错误比例

20个独立真零假设各有连续有效 p 值，每项拒绝概率.05。全部不拒绝的概率为 $(.95)^{20}$ ，故至少一次误拒为 $1 - (.95)^{20} \approx .641514$ 。使用补事件，是因为“至少一次”直接枚举所有非空拒绝组合很繁琐。

这个数不是20项中64%会被误拒。误拒项数的期望为 $20 \times .05 = 1$ ；期望错误比例仍为.05。约64%讲的是重复整组研究时，有多少组至少出现一个误拒。若比较相关，乘积公式一般不成立；极端完全相同的20个检验，至少一次误拒仍只有.05。

15. Bonferroni的完整逻辑

设真零假设集合为 I_0 ，各真零p值满足任意 u 下 $P(p_j \leq u) \leq u$ 。用每项 α/m 作为拒绝阈值，家族误拒事件是这些真零拒绝事件的并。并集上界给

$$P\left(\bigcup_{j \in I_0} \{p_j \leq \alpha/m\}\right) \leq \sum_{j \in I_0} P(p_j \leq \alpha/m) \leq |I_0| \alpha/m \leq \alpha.$$

证明从未使用独立性，因此在有效单项p值任意相关时也成立。它甚至允许家族中一部分零假设不成立，这些不计入误拒集合。 $m=20$ 、 $\alpha=.05$ 时阈值.0025；独立全部真零时精确家族率 $1-(.9975)^{20} \approx .048830$ ，与上界.05不同但相容。

若单项p值已经因伪重复或错误模型而无效，第一步概率不等式可能不成立。若实际试了20项却只把喜欢的3项当家族，所称控制范围也不真实。校正p值 $\min(1, mp)$ 仅是同一规则的另一表达。

16. 事后选单侧方向

设零模型下连续统计量 Z 关于0对称，右尾 p_R 与左尾 p_L 相加为1。看到数据后选择更小的尾部，再用.05拒绝，拒绝事件为 $\{p_R \leq .05\}$ 并 $\{p_L \leq .05\}$ 。连续零模型下两事件互斥，各概率.05，因此并的概率为.10。

在标准正态例中，规则等价于 $|Z| \geq z_{.95} \approx 1.644854$ ，而正确预设双侧.05临界值是 $z_{.975} \approx 1.959964$ 。事后选方向把更靠近中心的结果也纳入拒绝域。若方向确实事先固定为改善，右侧.05检验是另外一个合法设计；问题在于数据驱动的方向选择没有被计入错误控制。

17. 多次查看与共享前缀

每个固定 n 的检验只有自己的错误控制。查看 $n=8, 16, \dots, 64$ 且任意一次过线就拒绝时，整体拒绝事件为八个时点事件的并；它包含最终时点事件，还可能包含“前面过线但最后回去”的路径。

这些统计量共享同一条数据前缀。例如标准正态增量下， $n < s$ 时两个标准化累计和的相关为 $\sqrt{n/s}$ ，并非0，因此不能套 $1-.95^8$ 作为精确答案。该相关式来自共有前 n 项累计和的协方差 n ，再除以 $\sqrt{n} \sqrt{s}$ 。

本实验10000条路径中，只看最终拒绝514条，比例.0514；任意时点过线拒绝1742条，比例.1742，Wilson区间约[.16689, .18176]。这些是这一具体设计的有限模拟结果，不是普遍序贯错误率定理。合法中途决策需要事先合适的序贯规则或错误预算。

18. 一份完整报告及其不允许的跳跃

可以写：“预先以 $B-A$ 比较8个独立配对教学单位。平均差2分，差值样本标准差2。在独立同分布Gaussian差值、未知 σ 模型下，配对 $t_7=2.8284$ ，双侧 $p=.02546$ ，95%区间[.32796, 3.67204]。区间包含事先实用阈值1.5，对是否超过该阈值仍有不确定性。主要比较与停止规则预先设定；另两种模型仅用于教学条件对照，不按最小 p 筛选。”

若确实试过多个终点、版本或中途时点，应补充完整历史和相应控制，不能虚构“预先指定”。未显著结果需要同样保留。p值、区间和点估计各承担不同角色，删掉任何一类都会降低报告可解释性。

不显著不证明完全相等；等效需要事先指定可忽略范围并用相应程序。显著不证明效应足够大，也不证明因果。配对控制某些共同背景，但因果解释仍依设计、混杂、缺失与干扰等条件。最后，这组教学成分不支持任何真实产品或人群结论。

复算与进一步检查

详解中的常数由experiment.py与独立Fraction及高精度参考核对。学习者可先运行python experiment.py --self-test，再在Notebook重做枚举和模拟。完整来源及实际检查范围见source-checks.json；正文给出各模型的适用条件。答案无需联网或付费服务。