

# 第二十六讲 实验指南

## 1. 本次要交付什么

完成一个预先设定的配对比较报告：保留8个原始配对，手算均值与方差，分别解释外部已知 $\sigma$ 的z、未知 $\sigma$ 的配对t、条件符号翻转三套模型；随后模拟功效、多项比较与中途查看的错误率。最后报告原始效应、区间、p值、实用阈值和方法条件。

本实验只有CPU上的小型合成数据。它不会证明真实模型改进，也不会生成真实产品结论。不要把三种p值排序后选最小者；它们是教学对照，主要方法须由设计与假设先决定。直接先修为第22与25讲，协方差计算用到第21讲。

## 2. 文件与运行准备

将本讲完整目录保留在一起。data/paired\_scores.csv每行一个配对单位，列为pair\_id、score\_a、score\_b。model\_spec.json冻结种子、重复次数、 $\alpha$ 、外部 $\sigma$ 、功效网格、家族大小与实用阈值。figures/是正文原创机制图，Notebook重新计算其自己的图，不读取旧report.json。

推荐Python 3.12。学习依赖为NumPy 2.3.5、SciPy 1.17.0、Matplotlib 3.10.8、nbformat 5.11.1、ipykernel 7.4.0及JupyterLab。可以在自选独立环境内安装requirements.txt，或用environment.yml创建Anaconda环境。作者没有实际测试Anaconda安装流程，版本声明不是安装成功证据。

```
python -m pip install -r requirements.txt
python experiment.py --self-test
python experiment.py --output-dir outputs
jupyter lab experiment.ipynb
```

在Jupyter中Restart Kernel，再Run All。作者已经在新的Python进程里用真实IPython InProcessKernel顺序执行并保留文本与PNG；浏览器交互及socket内核传输没有在制作环境测试。遇到ModuleNotFoundError时，先确认Notebook内核与安装依赖的Python是同一个环境。

脚本按自身路径找到默认输入，与当前工作目录无关。也可从其他目录执行python /你的目录/026/experiment.py --output-dir /你的目录/results026。成功运行会替换指定输出目录内的report.json，因此不同实验使用不同输出目录。

## 3. 第一步 冻结对象和规则

在运行前写下：实验单位是什么；差值是B-A还是A-B；零值为多少；哪种分布或随机化条件可信；主要问题是双侧差异还是事先改善方向； $\alpha$ 、实用阈值、比较家族和停止规则是什么。

默认教学配置为 $\alpha=.05$ 、 $\delta_0=0$ 、外部 $\sigma=2$ 、实用阈值1.5。差值t模型的 $\sigma$ 未知；外部 $\sigma$ 只属于z基准。所有对照共享数据但不共享全部模型信息。ID必须唯一且保持原行配对；不要分别排序A和B。

验收：用一句话区分总体参数 $\delta$ 与已经观察的样本均值2；解释为何读到均值为正以后再改为单侧会改变程序。

## 4. 第二步 先做可以完全核查的手算

差值为3、2、4、1、-1、0、2、5。总和16、均值2；离差平方和28、样本方差4、样本标准差2、估计标准误 $1/\sqrt{2}$ 。先在纸上完成，再调用函数核查。

```
from experiment import read_pairs, paired_summary, ROOT
ids, a, b = read_pairs(ROOT / 'data' / 'paired_scores.csv')
paired = paired_summary(a, b)
print(ids, paired['values'])
print(paired['difference'])
```

进一步核对：A、B样本均值为11.5、13.5；样本方差6、22/7；协方差18/7。保留配对后的均值方差估计1/2，错误忽略配对后8/7。解释协方差项的符号，不能只写“配对一定更好”。

验收：Fraction精确运算给出SSE28与协方差18/7；代码输出应与手算一致。Notebook包含可顺序运行的Fraction检查。

## 5. 第三步 看同一个统计量如何使用不同参考分布

```
from experiment import known_sigma_test, paired_t_test
z = known_sigma_test(paired['values'], sigma=2)
t = paired_t_test(paired['values'])
print(z)
print(t)
```

两次观察统计量同为 $2/\sqrt{2}$ 。z双侧p约.004677735，95%区间[.614096,3.385904]。t使用7个自由度，双侧p约.025463562，95%区间[.327958,3.672042]。已知 $\sigma$ 的区间较短不是选择它的正当理由；先证明信息来源与模型条件合适。

SciPy配对检验按第一数组减第二数组，独立核对应调用stats.ttest\_rel(b,a)，不是(a,b)。改变顺序会改变t符号；双侧p可能不变，仍不能忽略报告方向。不要用nan\_policy='omit'自动删行。

验收：写出Student精确零分布的条件，并明确它在本讲作为定理接受。对常量差值[2,2,2]，paired\_t\_test返回退化状态、p与区间为None；不能把它改成p=0。外部正 $\sigma$ 的z仍有定义。

## 6. 第四步 完整枚举符号标签

```
from experiment import exact_signflip
flip = exact_signflip(paired['values'])
print(flip['label_count'], flip['tail_count'], flip['p_fraction'])
print(flip['counts'])
```

每个位置有±标签，共256个。观察绝对总差16。±18各2个标签，±16各4个；尾部总数12， $p=3/64=.046875$ 。sum(sums的频数)必须等于256。零位置有两个标签，但两个统计量数值一样；保留重复正是对标签等概率的正确计重。

请手动解释“全正或只翻两个1之一”为什么产生正尾6个，再用反号得到另一侧6个。全零输入应得到 $p=1$ 。公共接口为避免浮点并列歧义，只接受整数值差值且 $n \leq 16$ ；.5不是可以偷偷四舍五入的整数输入。

验收：举出 $P(D=1)=2/3$ 、 $P(D=-2)=1/3$ 这个均值为零但不对称的反例，解释为什么它不能使用公平符号枚举。此检验需要独立交换或独立零对称，不能只说“不要求Gaussian”。

## 7. 第五步 效应与功效分开记录

原始效应2教学分，标准化配对效应 $d_z=2/2=1$ 。t区间横跨实用阈值1.5，所以排除零差异不足以确认超过1.5。先写这段解释，再去看模拟，避免让显著性标签替代实际问题。

已知 $\sigma$ 模型理论功效由两侧尾部相加得到。固定 $\delta=1$ 、 $\sigma=2$ 、 $\alpha=.05$ ， $n=8$ 、32、128理论分别约.292989、.807430、.999891。默认10000批模拟对应2999、8073、9998次拒绝；比例.2999、.8073、.9998，MC标准误约.004582、.003944、.0001414。

```
from experiment import gaussian_power, read_spec, simulations
spec = read_spec(ROOT / 'data' / 'model_spec.json')
print(gaussian_power(1, 2, 32))
sim = simulations(spec)
print([(v['delta'], v['n'], v['observed']['rate'])
       for v in sim['power']])
```

脚本直接抽标准化均值Z，而非为每批再生成n个观测；Gaussian条件下两者分布完全相同，节约CPU但没有创造额外证据。真实效应为0时理论拒绝率就是 $\alpha$ ，有限模拟不必恰好等于 $\alpha$ 。

当10000批全部拒绝时，插件MC标准误为0，但真实概率仍可能小于1。report还保留Wilson频率区间。极高功效可能因float64舍入显示1，单独保留的type\_II仍是正数；不要把1减去已舍入的功效当精确漏检概率。

## 8. 第六步 把选择过程也当成程序

默认全部真零的20项独立比较，未校正理论家族率约.641514，模拟6441/10000=.6441。Bonferroni每项阈值.0025，独立模型理论约.048830，模拟504/10000=.0504。有限模拟超过.05并不反驳理论上界，因为模拟比例也会波动；相应Wilson区间约[.04628,.05486]。

证明Bonferroni时使用并集上界，而不是独立乘积。它能处理相关有效p值，但不能修复错误单项模型、伪重复或漏记比较家族。家族错误率是至少一次误拒，不是发现中假发现比例。

随后查看同一条零效应路径n=8、16、...、64。默认只看最后拒绝514条，任何时点过线拒绝1742条，即.0514与.1742。这里共享前缀，不能用独立重复公式代替模拟。事后选更小单侧尾再按.05拒绝的理论错误率.10，默认模拟.1012。

验收：把三个机制分别写成明确事件：“任一比较”“任一时点”“任选单侧方向”，说明究竟哪一步改变了原来的错误控制。不要把.1742说成所有中途查看计划的通用常数。

## 9. 第七步 故意输入坏数据

输入检查应在完整数据读取后、RNG创建前、写输出前执行。先复制CSV或JSON进行破坏，保留原始教学数据。可以试重复ID、未行NaN、多一列、漏一列、true混入JSON列表、最后一个样本量为浮点数8.0、最后一个效应超范围、差值非整数等。

```
from experiment import moments, paired_t_test
for bad in ([1, 1, float('nan')], [1, True], [1, '2']):
    try:
        moments(bad)
    except ValueError as error:
        print(type(error).__name__, str(error))
print(paired_t_test([0, 0]))
print(moments([-1, 1, 1e-100])['mean'])
```

最后一个输出应为1e-100/3，而不是0。均值从原始值用补偿求和计算；先减一个锚点再相加可能把很小的非零残差丢掉。数值API刻意拒绝Fraction、Decimal、object数组、扩展浮点、bool、文本与复数；CSV则有专门十进制解析器检查原文字面量。完整三检验CLI要求CSV分数可被float64精确表示（如整数、.5、1.25），并且差值为整数；.1或在转换中消失的末位会明确拒绝。JSON原始浮点文字先检查非零下溢，普通.05等参数允许常规舍入；重复键与NaN/Infinity常量拒绝。若上游已经把True变成了1.0，当前接口无法恢复被丢弃的类型信息。

保护检查：先记录已有report.json字节或SHA-256，再用坏CSV运行同一输出目录。程序应失败且旧文件完全不变。不要把失败后悄悄留下的旧报告误当作新结果。新进程和python -O都应保留同样的显式ValueError检查。

## 10. 数值范围和输出解释

通用输入为有限实数，绝对值 $\leq 1e6$ ，非零绝对值 $\geq 1e-100$ ；普通向量长度2..10000，符号枚举1..16。标准化z与t要求绝对值 $\leq 30$ ；功效非中心参数绝对值 $\leq 12$ 。显著性水平在 $[\cdot0001, \cdot2]$ ， $\sigma$ 等参数有另列界限，详见README和函数。它们是保守教学实现范围，不是统计理论的定义域。

所有非零平方离差必须为正常浮点数，非恒定方差不得塌缩为0；应为正的尾概率若下溢为0或次正规值就报错。真正零输入与概率端点另按语义处理。输出不会声称支持任意高精度输入或所有实数。

report.json记录确定性结果、256个标号总差、每类模拟比例、计数、MC标准误、Wilson区间、种子偏移和前12条查看路径。成功计算后以临时文件原子替换报告；输入错误不会修改旧报告。相同程序和固定版本的本地新进程结果已交叉核验，但不保证任意NumPy版本随机流逐比特相同。

## 11. 最终提交与检查表

提交一份简短报告及Notebook：说明配对单位与 $\delta$ ，列出效应2分、sD=2、d\_z=1、主要t区间与p；用一段文字区分另两种模型；展示精确标签尾计数与一张模拟误差图；解释1.5阈值、不显著、等效与因果的边界。

还需写明比较家族与停止规则，解释模拟有限误差，列出至少三个坏输入检查和旧输出保护结果。数值匹配只是必要条件，不能替代模型说明。全部18题推导详解在answers.pdf；完整正文、原始数据字典、来源记录和运行限制都随包提供。