

第二十六讲 假设检验与效应大小

1. 均值提高两分，究竟说明了什么？

我们已经会估计参数，也会用区间表示抽样波动。现在做一个事先约定的比较：同一个教学实验单位上测A、B两种方案，分数越大越好，差值定义为B减A。八个合成差值是3、2、4、1、-1、0、2、5，平均提高两分。

如果只写“B比A好两分”，还没回答样本波动。如果只写“ p 小于0.05”，又没有回答两分是否值得行动。**本讲要把效应大小、抽样不确定性与错误控制放回同一份报告。**它们各自回答一个具体问题，不能让一个阈值替所有判断。

直接先修为第二十二讲的抽样分布与第二十五讲的区间和重采样。会用第二十一讲的协方差更容易理解配对。本讲不是现实产品评测，也没有真实用户成绩；数据和实用阈值都为教学构造。我们会先用一个可精确分析的Gaussian模型，再用八对数据的全部符号翻转构造有限零分布，最后模拟反复比较怎样制造假阳性。

效应、抽样不确定性、检验条件一起报告




图1 一份比较报告同时保留原始配对、差值、效应区间与检验条件。均值、 p 值和实用判断各有对象。

2. 比较对象先于公式

用 $i=1, \dots, n$ 标记独立的实验单位， A_i 、 B_i 是一对读数， $D_i=B_i-A_i$ 。目标参数为总体平均差 $\delta=E[D_i]$ ，估计量为样本平均差。抽样前 D_i 是随机变量，读到数据后 d_i 是固定数；检验的概率计算针对“如果重新执行同一设计，会生成什么统计量”。

把零假设写成 $H_0:\delta=0$ ，双侧备择写成 $H_1:\delta \neq 0$ 。它们是关于总体参数的陈述，不是“这八个差值的平均数是否恰好为0”。后者已经知道答案是2，不需要概率检验。

模型还必须写出独立性、分布、单位、缺失值处理和比较方向。 H_0 与这些辅助条件共同决定零分布。拒绝时，说明观测与整套零模型不相容；不能仅凭一个尾部概率判断到底是哪条条件出了问题。

若科学问题事先明确只关心改善，可设置单侧 $H_0: \delta \leq 0$ 、 $H_1: \delta > 0$ 。在下面的Gaussian位置模型中，最不利零假设在边界 $\delta=0$ ，因而用该边界计算右尾可控制整个 $\delta \leq 0$ 范围。不能看到均值为正才把原本双侧问题改为右侧。

3. 什么是检验统计量和拒绝域？

检验统计量 $T=T(D_1, \dots, D_n)$ 是事先规定的样本摘要。它把原始数据映射为一个数，便于在零模型下比较。例如标准化均值、绝对均值或正差值个数，都会产生不同的敏感方向。

拒绝域 R 是一组被视为足够不相容的统计量值。程序最终作的是判断 T 是否属于 R ；“拒绝 H_0 ”只是按事先规则作出这个决定，不是宣告 H_1 已被逻辑证明。没有进入拒绝域称为不拒绝，不能自动改写成证明完全相等。

显著性水平 α 是预先允许的第一类错误上界。简单零假设下要求 $P_0(T \in R) \leq \alpha$ ；复合零假设下要求对每个允许的零参数都成立，也可以写成这些概率的上确界不超过 α 。离散问题常常不能恰好达到 α ，保守的小于号完全合法。

4. 第一类错误、第二类错误与功效

H_0 为真却拒绝，是第一类错误。 H_0 为假却没有拒绝，是第二类错误。前者必须在零模型下算，后者必须说明哪个真实替代参数 δ 。功效是该 δ 下拒绝的概率，等于1减去对应第二类错误概率。

$\alpha=0.05$ 不是“这次结论错误的概率是5%”，也不是“全部研究中恰好5%结论会错”。它描述的是一套程序在零模型成立时的长期错误控制。真实效应越小、噪声越大或样本量越少，程序可能更难发现差异；因此不显著可以来自信息不足。

做一个只用于澄清条件方向的概率模型：假设研究题目中90%没有效应，10%有某种效应；零情形拒绝率0.05，非零情形功效0.8。随机抽一个题目且检验拒绝之后，来自零情形的条件概率是

$$\frac{0.9 \times 0.05}{0.9 \times 0.05 + 0.1 \times 0.8} = 0.36.$$

这个36%需要额外的题目比例与功效假设，绝不能从单个 p 值直接读出。它重现第十八讲中条件概率方向不同的问题，并不是当前真实研究的错误率估计。

相同拒绝域，概率在不同模型下计算（ $n=8$ ，已知 $\sigma=2$ ）




图2 零模型下的误拒与具体替代模型下的漏检使用不同概率分布。降低一个错误可能牺牲另一个，需要说明效应与样本量。

5. p值是在零模型下看“至少这么极端”

先规定数值越大越不相容的统计量 T 。观察 t 后，简单零模型的上尾 p 值可写为 $p=P_0(T \geq t)$ 。若方向是两侧偏离，则先定义 $T=|Z|$ ，再计算 $P_0(|Z| \geq |z_{\text{观测}}|)$ 。这里的概率始终在零模型下，不是在给定数据后给假设分配概率。

“至少”很重要。连续数据的一个精确点概率通常为0，但很多附近与更极端的结果共同组成尾部事件，因而有非零概率。离散分布必须包含与观察值同样极端的质量，不能把 $\geq$ 随意改成 $>$ 。

p 值随观察而变化， α 是事先固定的程序门槛。常用拒绝规则是 $p \leq \alpha$ 。对连续分布，端点等号发生概率为0；对离散分布，端点约定可能实际改变拒绝率，必须与代码一致。

为什么这条规则能控制错误？如果连续 T 的零分布函数 F_0 严格递增，则 $F_0(T)$ 在 $(0,1)$ 均匀，故 $1-F_0(T) \leq \alpha$ 的概率为 α 。有限等概率零样本的版本更直观：把统计量按从最极端到最不极端排队， p 是当前位置及更极端位置的总比例；若有并列，同一组都使用该组末尾累计比例，因此满足 $p \leq \alpha$ 的样本比例不超过 α 。这个保守秩论证也说明了为何并列必须一起计算。




图3 同一条零分布上的拒绝门槛与观察后的 p 值尾面积。两个阴影有联系，但不是同一个事先指定的量。

6. 已知总体标准差的完整Gaussian例子

为得到一个完全可算的基准，暂时假设 D_i 相互独立且同服从 $\text{Gaussian}(\delta, \sigma^2)$ ，总体标准差 $\sigma=2$ 由实验外部事先给定。这个 σ 不是由当前八条估计的。线性Gaussian组合给样本均值分布为 $\text{Gaussian}(\delta, \sigma^2/n)$ ，所以在 $H_0: \delta = \delta_0$ 下

$$Z = \frac{\bar{D} - \delta_0}{\sigma/\sqrt{n}} \sim N(0, 1).$$

我们沿用第二十至二十二讲的标准正态CDF Φ 。双侧 $p=2[1-\Phi(|z|)]$ 。令 c 满足 $\Phi(c)=1-\alpha/2$ ，则 $|Z| \geq c$ 时拒绝，零模型下两侧尾概率共为 α 。

主数据 $n=8$ ，平均差2， $\delta_0=0$ ， $\sigma=2$ ，于是标准误为 $1/\sqrt{2}$ ， $z=2/\sqrt{2} \approx 2.828427$ 。双侧 $p \approx 0.004677735$ 。 $\alpha=0.05$ 时 $c \approx 1.959964$ ，因此在这套已知 σ 的Gaussian模型里拒绝零均值差。

与之配套的95%区间是平均差加减 $c\sigma/\sqrt{n}$ ，数值约 $[0.614096, 3.385904]$ 。它不包含0，与双侧检验相容。数值计算用尾函数或erfc避免先算接近1的CDF再相减；尾部正概率的浮点下溢要显式处理，不能把机器零当成数学绝对不可能。

7. 区间与检验的代数对应

对同一模型、同一个 α 和同一种双侧构造，

$$\left| \frac{\bar{d} - \delta_0}{\sigma/\sqrt{n}} \right| \leq c \iff \bar{d} - c \frac{\sigma}{\sqrt{n}} \leq \delta_0 \leq \bar{d} + c \frac{\sigma}{\sqrt{n}}.$$

这只是移项与乘正数，清楚说明为何区间内部的零参数不会被对应检验排除。连续模型边界是否用严格拒绝不影响名义概率；实现仍应选定约定。不同方法产生的区间与 p 值未必自动互为反演，不能任取一个Bootstrap区间再配另一个检验声称严格等价。

区间比单一 p 值多保留了效应可能的规模。它仍然不是“这条固定区间内 δ 有95%概率”的频率学派陈述，也不能担保独立性或Gaussian假设真实。




图4 已知 σ 区间、未知 σ 的 t 区间与零差异线。图中的两种区间使用不同信息，不能只挑较短者报告。

8. σ 未知时，为什么不能把s直接当已知常数？

现实中总体波动通常未知。用样本标准差s替代 σ 之后，分母也变随机，统计量不再有上述标准正态分布。在独立同分布Gaussian差值、 $n \geq 2$ 、 $\sigma > 0$ 条件下，

$$T = \frac{\bar{D} - \delta_0}{s_D / \sqrt{n}} \sim t_{n-1}, \quad s_D^2 = \frac{1}{n-1} \sum_i (D_i - \bar{D})^2.$$

这里称Student t分布，v是自由度。可以定义为Z除以 $\sqrt{U/v}$ ，其中Z是标准正态、U是v个独立标准正态平方和，且Z与U独立。Gaussian样本均值与残差平方和独立、上述学生化量服从t的定理在本讲明确作为已知结果接受；我们不把一次模拟当作证明。其标准密度及尾积分由官方数值库计算，小自由度时尾部比标准正态更重。

主例离差为1、0、2、-1、-3、-2、0、3，平方和28，所以 $s^2=28/7=4$ ， $s=2$ 。这里恰好等于前节外部 σ ，但它仍是另一种信息来源。观察到的t数值也为2.828427；参考分布改为 t_7 后，双侧p约0.025463562，95%区间约[0.327958, 3.672042]。三个输入数字看起来相同，并不意味着参考分布可以随意互换。

配对t检验就是对差值作这一单样本检验。若用SciPy的ttest_rel，函数按第一数组减第二数组计算，想报告B-A，应传B、A并检查符号。任何数据中出现NaN时，本课程先拒绝整个输入，不自动删行改变配对。

若所有差值相同，完整验证后得到 $s=0$ ，学生化比值没有通常定义。不要让0/0变为NaN再贴一个成功标签，也不要把常量非零时的浮点无穷直接当作稳健的显著性证据。脚本应明确报告退化状态。已知正 σ 的基准检验与全零的符号翻转可以仍有各自合法答案，不能一概混为同一边界。

9. 保留配对究竟保留了什么？

同一个实验单位的A与B常有共同背景。差值的方差是 $\text{Var}(B) + \text{Var}(A) - 2\text{Cov}(A, B)$ 。先配对再求差可以抵消共同变化；如果错误地当成两组独立样本，就丢掉协方差项。

主例A均值11.5、B均值13.5；样本方差分别6和22/7，样本协方差18/7。故差值样本方差为 $6 + 22/7 - 2 \times 18/7 = 4$ ，均值方差估计为 $4/8 = 1/2$ 。错误忽略配对时得到 $(6 + 22/7)/8 = 8/7$ ，描述的是另一种抽样计算。

本例正协方差让配对减少噪声；若协方差为负，方向可能相反，所以不能口号式断言配对永远减小方差。真正的原则是尊重设计与统计单位。把同一单位重复测量当成多个独立单位，或者把不同随机种子的同一测试集得分当成独立总体样本，也可能夸大信息量。




图5 左边连接同一对A、B，右边显示八个差值与均值。配对不是排序后重新配上最相近的两个数。

10. 不用Gaussian形状，也能建立一个精确零分布

换一组明确条件：在零假设下，每对A、B的标签可以独立等概率交换；或在总体模型里，各差值独立且关于0对称，使给定绝对值后的非零符号像独立公平硬币。**仅仅总体均值为0不够。** 一个高度偏斜但均值为0的分布，不一定允许翻转符号。

保持每个差值的绝对值不变，为n个位置分别选±号，构成 2^n 个等概率标号结果。统计量取绝对总差 $|\sum d_i|$ ，与绝对均值只差一个固定正因子。零差值翻成正负仍是0；可以保留两个标签并相应计重，也可以一致地约去这一倍，不能把数值相同的结果去重后当等概率。

对主例绝对值3、2、4、1、1、0、2、5，全部256个标号结果的总差位于-18至18的偶数格点。观察总差为16。满足 $|\text{总差}| \geq 16$ 的标签有12个，因此精确双侧 $p = 12/256 = 3/64 = 0.046875$ 。

可以再手算尾部计数：最大正和18；达到至少16，负号绝对值总和只能为0或1。去掉零位置后的七个非零绝对值中，有两个1，因此有“全正”与“只翻其中一个1”共3种，零符号再乘2，正尾6种，负尾对称再乘2，总计12种。




图6 256个带权标签产生有限零分布。阴影包含±16与±18；同样极端的并列质量不能删掉。

11. 为什么三个p值不同，却不互相推翻？

同一数据在已知 σ Gaussian模型下 p 约0.00468，在未知 σ Gaussian模型的配对 t 检验下约0.02546，在符号交换模型下为0.046875。它们的零分布、已知信息和条件都不同。选择方法必须依实验设计与可辩护的假设事先决定，而不能看到结果后拿最小那个。

符号翻转使用的是零假设下对称或交换不变性，不声称对所有均值为0的分布有效。配对 t 检验的小样本精确性使用Gaussian差值；大样本近似还需要恰当的独立、矩和渐近条件。把一个假设改得更弱并不自动让任何旧的 p 值仍然合法。

本讲用完整枚举， p 不是Monte Carlo近似。若今后仅随机抽部分置换，需要说明随机置换方案与有限次数修正，常见有效随机化构造使用分子分母都加1的计数，不能因为没有抽到更极端结果就报告精确 $p=0$ 。双侧定义也并不唯一；本讲明确采用绝对统计量尾部，不能默默替换成另一个软件的默认定义。

12. 效应量先报告原始单位

本例估计 δ 为两教学分。可辅助报告标准化配对效应 $d_z = \text{平均差}/s_D = 1$ ；它把效应放在差值的样本标准差单位下。其分母是差值的标准差，不是A、B两组标准差的随意平均，也不是均值标准误。因为 s 也随机， d_z 本身有抽样不确定性，不是天然无偏量。

标准化方便跨尺度描述，但未必直接对应实践价值。我们在看数据前为教学设定最低有意义改善 $\Delta = 1.5$ 分。当前95% t 区间包含比1.5小与大的值，因此“排除了0”并不等于“已经清楚证明超过1.5分”。如果真正问题是是否超过该阈值，就应事先检验 $H_0: \delta \leq 1.5$ ，或报告相应单侧下界。

两个研究可以有同一个 p 值却有完全不同的原始效应与样本量；一个很大的样本也可能把极小差异检测得很显著。反过来，小样本下不显著的点估计可能仍对应实践上重要但尚不确定的差异。至少同时报告估计、单位、区间、样本单位、方法条件和完整 p 值。




图7 相同效应随样本量变化时，区间宽度和 p 值改变；实际重要阈值不因 p 值跨过0.05自动移动。

13. 从公式看功效，而不是事后套一个标签

回到已知 σ 的双侧Gaussian基准，真效应为 δ 、零值为0。令 $\lambda = \delta \sqrt{n}/\sigma$ ，则 Z 服从Gaussian($\lambda, 1$)。拒绝域仍是 $|Z| \geq c$ ，因此

$$\text{Power}(\delta) = P_{\delta}(Z \geq c) + P_{\delta}(Z \leq -c) = 1 - \Phi(c - \lambda) + \Phi(-c - \lambda).$$

这一步把 $Z - \lambda$ 标准化为 $N(0, 1)$ ，分别算左右尾。 $\delta=0$ 时 $\lambda=0$ ，功效退化为 α ，也就是零假设下拒绝率。固定 δ 、 σ 时增大 n 使分布相对门槛分离；如果降低 α ， c 变大，通常会牺牲对既定效应的功效。

取 $\delta=1$ 、 $\sigma=2$ 、 $\alpha=.05$ ， $n=8$ 、32、128时理论功效分别约0.292989、0.807430、0.999891。功效必须附带这些假设和特定效应，不是“这份数据有80%可靠性”。规划时应围绕有意义的效应与合理噪声范围做敏感性分析；只把观察效应原样代回所谓事后功效，不能生成新的独立证据。




图8 同一拒绝域下，替代分布的均值位置随效应和样本量改变。功效曲线的每一点都对应一个明确生成模型。

14. 多试二十次再挑最好的一次，会发生什么？

假设20个预先固定、相互独立的比较全部满足零假设，每个有效连续 p 值在 $(0, 1)$ 均匀。如果每项都按0.05拒绝，全部不误拒的概率为 0.95^{20} ，所以至少一次误拒的概率为

$$1 - (1 - 0.05)^{20} \approx 0.641514.$$

这叫家族错误率：一组被共同考虑的比较里，发生至少一个假阳性的概率。它不是“20项中64%都错”，也不是单项错误率从5%神秘变成64%。改变的是“至少一次”的事件。

相互独立是这个精确乘积公式的条件。若比较共享样本、指标或模型，它们往往相关，不能机械套这个数。但不相关也不是唯一风险：试多个终点、子群、清洗方案、特征版本或停止时点，若只公布最小 p 值，都可能改变实际选择程序。




图9 全部零假设成立时，比较数增加会提高未校正的至少一次误拒率。显示理论曲线与有限模拟，不只展示选中的赢家。

15. Bonferroni为何不需要独立性

设预先指定家族有 m 个检验，每个有效 p 值在其零假设成立时满足 $P(p_j \leq u) \leq u$ 。每项改用门槛 α/m 。若 I_0 是真零假设的索引集合，由并集概率上界，

$$P(\text{至少误拒一个真零假设}) \leq \sum_{j \in I_0} P(p_j \leq \alpha/m) \leq |I_0| \alpha/m \leq \alpha.$$

这里没有把联合概率拆成独立乘积，所以不需要检验之间独立；但每个 p 值自身必须有效，不能用校正补救坏的独立性或错误采样单位。还需要家族定义涵盖所声称控制的比较，不能只把最终喜欢的三项放进去。

也可以报告校正 p 值 $\min(1, mp_j)$ ，再与 α 比较。 $m=20$ 时门槛为0.0025。在相互独立、全部为真的特殊模型中，实际家族错误率是 $1-(1-0.0025)^{20} \approx 0.048830$ ，小于0.05。它可能保守并降低功效；这是一种透明的权衡，不意味着多重比较问题可以忽略。

本讲只建立家族错误率基础，不混用“至少一次误拒”与“发现中假发现比例”的不同指标。更高级的错误率和序贯方法需要另外的条件与设计。

16. 看一次、再看一次不是原来的固定样本程序

如果预先打算收 $n=64$ 个独立差值，却在 $n=8, 16, \dots, 64$ 每次都计算固定样本 p 值，看到第一次小于0.05就停止，那么拒绝事件是多个时点拒绝事件的并集。每个单独时点有效，不保证这个整体程序仍只有5%误拒。

这些时点共享前缀数据，通常相关，不能把它们当独立20次套上节公式。实验可以在完全零效应下生成多条长度64的路径，比较“只看最终一次”和“任何预设时点过线”的频率，明确这是有限模拟证据。若需要中途决策，应事先使用适合的序贯边界、分配错误预算或独立确认；本讲不把事后删掉中途查看记录当作修复。

同理，看完数据后挑单侧方向也会扩大拒绝事件。在对称连续零分布中，若每次挑更小的单侧尾再按0.05拒绝，等价于用双侧0.10规则，实际第一类错误是10%。方向不是一个可以免费事后选择的参数。




图10 同一零效应路径在多个时点被查看。最终固定样本门槛不能自动控制“任一时点过线”的程序。

17. 不显著、等效与因果结论都需要自己的条件

不拒绝 $\delta=0$ 可能因为数据不足，不等于证明 δ 恰好为0。要支持“差异小到可忽略”，应事先定义可忽略范围并使用针对等效问题的程序；简单检查一个95%区间包含0并不够。本讲不展开等效检验的误差分配，只明确问题不能偷换。

小p值也不证明因果关系。配对去掉了某些共同变化，但不能自动消除时间趋势、选择偏差或其他同时变化的因素。随机化设计可以支持特定因果解释，仍要说明实施、缺失、干扰与目标人群。我们的合成数值只用于解释统计机制，不授权对真实产品、个体或群体作效果判断。

18. 一次透明实验怎样运行

先冻结差值方向、零假设、双侧或单侧、显著性水平、实用阈值、比较家族和停止规则。然后读完整CSV、验证唯一ID、有限数值及配对长度；不悄悄舍入、删除NaN或打乱B列。每个模拟参数和完整列表要在创建RNG前检查。

实验先用Fraction精确核对均值2、SSE28、样本方差4、配对协方差18/7、256个标签中12个尾部结果。再用独立高精度积分核对正态与t尾部、临界点与区间；数值库相互调用不等于独立数学核验。最后模拟已知 σ 模型的零拒绝率、功效、家族错误率和中途查看风险。

重复R批得到误拒比例 $\hat{r}$ 时，Monte Carlo标准误约为 $\sqrt{[\hat{r}(1-\hat{r})/R]}$ ，它描述这张模拟图自身的误差，不是原始 δ 估计的标准误。极端频率0或1时这个插件标准误会给0，不能据此声称真实概率已精确为0或1；可以同时给一个有限二项频率区间或增加重复次数。

所有失败检查使用不会被python -O关闭的显式判断。完整常量向量在完整验证后精确识别，未知 σ 的t比值按退化状态报告，坏末项不得被常量分支跳过。输入或数值范围无效时，已有输出报告应保持字节不变。




图11 理论错误率、有限模拟频率与Monte Carlo误差分开显示。更多模拟改善计算精度，不增加原始实验的信息。

19. 报告不能只剩“显著”两个字

一份最小但完整的报告可写：预先比较B-A，八个独立配对单位，平均差2教学分，差值样本标准差2；在独立Gaussian差值、未知 σ 的配对t模型下， $t_7 \approx 2.8284$ ，双侧 $p \approx 0.02546$ ，95%区间[0.32796, 3.67204]。事先实用阈值1.5位于区间内，对是否超过它仍有不确定性。若做过其他比较或中途查看，也要交代。

这比“B显著更好”多写了一些条件，却让读者知道证据支持到哪里。原始点、区间、方法选择、全部计划比较与失效条件都应该保留；没有进入拒绝域的结果也属于完整实验。

让每个结论能回到它的设计与计算

1 明确对象

单位、参数、配对方向
来源与完整数据

2 冻结规则

模型、 α 、方向、家族
实用阈值、停止时点

3 核验计算

手算、精确枚举、尾积分
坏输入先拒绝

4 完整报告

效应 + 区间 + p + 条件
包括未显著与比较历史

图12 从设计到报告的核查路径。先写对象与规则，再计算，最后同时解释效应、不确定性和错误控制。

20. 自测与后续

1. 对八对读数定义实验单位、差值方向、估计量与总体参数，写出双侧零假设。
2. 解释第一类与第二类错误各在哪个模型下计算，为什么功效必须指定 δ 。

3. 在90%零题目、 $\alpha=.05$ 、非零功效.8的教学混合模型里推导拒绝后仍为零的概率。
4. p值为什么包括同样极端的结果？为什么它不是 $P(H_0|\text{数据})$ ？
5. 从Gaussian均值分布推导主例z、双侧p和95%区间，明确 σ 来源。
6. 通过代数说明同一双侧检验与相应区间的关系，并指出边界约定。
7. 手算主例SSE、 s^2 、t与自由度，解释为何t尾部与z尾部不同。
8. 完整推导配对差值方差关系，核对本例忽略配对后的8/7。
9. 写出符号翻转有效性的条件，并举一个均值为0却不对称的分布反例。
10. 不靠程序，数出主例|总差| ≥ 16 的12个标签，处理零差值与并列。
11. 为什么不能算三种p值后只报告最小者？若随机置换零次超过观察值，能否说精确 $p=0$ ？
12. 计算原始效应与 d_z ，说明实用阈值1.5与拒绝零差异的关系。
13. 推导已知 σ 的双侧功效公式，检查 $\delta=0$ 、增加n和降低 α 三个方向。
14. 推导20个独立零检验至少一次误拒概率；它是否表示64%的单项结论为假？
15. 用并集上界证明Bonferroni，不假设独立；解释家族与单项有效性。
16. 在对称连续零分布中，证明事后挑单侧方向再按.05拒绝实际有.10错误率。
17. 解释中途反复查看为何改变程序，以及为什么不能套独立比较乘积式。
18. 写出包含效应、区间、条件、p值与比较历史的报告；说明不显著、等效与因果各不能自动推出什么。

逐题完整详解与实验另有文件。下一讲将把估计量的偏差、方差与均方误差系统分开，进一步解释一次样本上的好结果为何不能代替长期性能。

来源与核查范围

- MIT 18.05统计讲义 Class17–18：错误类型、功效与z/t条件；Student定理作为已知结果接受。
- NIST 检验与区间与均值区间：已知 σ 与未知 σ 的计算及频率学派解释。
- NIST Bonferroni：有限预设家族与并集上界；正文独立证明。
- Berkeley 配对比较：独立对内交换、条件公平符号与零值；本讲不使用Wilcoxon秩和。
- SciPy 1.17配对t与t分布：数组顺序、自由度、尾函数与分位数。
- SciPy置换检验：完整枚举、随机修正与双侧约定。该API未实际调用。
- ASA p值声明：p值解释、效应重要性与透明报告；正文例子独立构造。

所有来源的实际检查范围另见source-checks.json。本讲数据、数值枚举、推导文字和图表独立制作，未复用文献实验数据。