

第二十七讲 估计误差与偏差方差解答

本解答沿用正文记号。 μ 或 θ 是真实但未知的固定参数； T 是数据到估计的整条规则； n 是一批观测数； R 是模拟中独立完整数据集的数量。平方风险存在需要有限二阶矩，模拟风险标准误还需要平方损失有有限方差。先尝试推导，再用这里核对。

1. 随机的是什么

估计量 $T(X)$ 在观察数据之前是随机变量；观察到 x 后， $t=T(x)$ 是具体数值。 $E\theta$ 固定 θ 及其对应分布，再对全部可能的数据集平均。算法若另有随机性 U ，应写 $T(X,U)$ 并说明是否对 U 也取期望。本讲四个规则给定数据后都是确定的；PCG64种子用于有限模拟，不把真实 θ 随机化。后验的随机参数解释属于另一个条件世界，不能混入本题。

2. 完整推导MSE分解

记 $a=E\theta T$ ，加减 a 后， $T-\theta=(T-a)+(a-\theta)$ 。平方并取期望：第一项为 $\text{Var}\theta T$ ，第二项为 $(a-\theta)^2$ ，交叉项为 $2(a-\theta)E\theta(T-a)=0$ 。因此 $\text{MSE}=\text{方差}+\text{偏差平方}$ 。要求 $E\theta T^2$ 有限， θ 有限，保证各项有意义。若参数单位为米，两项和MSE都是平方米；标准误和RMSE才是米。一般 $\sqrt{v+b^2}$ 不等于 $\sqrt{v}+|b|$ 。

3. 本次误差与常数规则

本次误差 $t-\theta$ 只来自一个样本，不能估计整个规则的长期中心。一个无偏估计器本次可以错得很大。 $T=0$ 在 $\theta=0$ 处零误差，但在 $\theta=2$ 处偏差-2、方差0、MSE4。称规则“无偏”一般要求指定参数空间中每个 θ 均成立，不能只挑选一个有利真值。

4. 八个有序样本与权重

符号序列是---、--+、-+-、+-+、-++、+-+、++-、+++。独立且等概率使每行概率 $(1/2)^3=1/8$ 。正号个数0、1、2、3分别对应1、3、3、1行。均值是 $\mu+(2K-3)/3$ ，主例支持为-1/2、1/6、5/6、3/2。四个支持值不等概率。把八行随机抽样八次也不构成枚举，因为可能重复和遗漏。

5. 两条无偏规则的不同风险

独立零均值噪声的和方差为3，因此平均噪声方差为1/3，均值无偏， $\text{MSE}=1/3$ 。奇数三个观察的中位数由多数符号决定，低值 $\mu-1$ 与高值 $\mu+1$ 各占1/2，所以期望 μ 、方差1、 $\text{MSE}1$ 。

总体中位数的定义为两侧累积概率均至少1/2。在两个等权质量点之间的任意位置都满足这个定义，故不唯一。对任何奇数 n ，样本中位数依然以一半概率在两个端点；对 $0<\varepsilon<1$ ，有 $P(|\text{中位数}-\mu|>\varepsilon)=1$ ，不会趋零。这个反例缺少唯一中位数条件，不反驳连续密度在唯一中位数附近为正时的常见一致性结论。

6. 直接算半均值平方误差

$K=0, 1, 2, 3$ 时, 半均值是 $-1/4, 1/12, 5/12, 3/4$; 相对 $\mu=1/2$ 的误差为 $-3/4, -5/12, -1/12, 1/4$ 。
直接加权:

$$\frac{1}{8} \frac{9}{16} + \frac{3}{8} \frac{25}{144} + \frac{3}{8} \frac{1}{144} + \frac{1}{8} \frac{1}{16} = \frac{7}{48}.$$

独立地, 期望 $1/4$ 、偏差 $-1/4$ 、方差 $1/12$, 分解给 $1/16+1/12=7/48$ 。前一种方法没有引用风险分解, 适合作为独立数值核验。

7. 固定收缩何时更好

$T_c=c$ 平均, 偏差 $(c-1)\mu$, 方差 $c^2\sigma^2/n$, $MSE=(1-c)^2\mu^2+c^2\sigma^2/n$ 。取 $c=.5, n=3, \sigma^2=1$, 风险 $\mu^2/4+1/12$ 。与 $1/3$ 比较, 严格更小等价于 $\mu^2<1$; $\mu=\pm 1$ 相等; $\mu=2$ 时为 $1+1/12=13/12$ 。这是点态改善, 不是全参数占优。收缩中心改变时相应偏差也改变, 不能只平移图标题而不改公式。

8. oracle与数据选择

对固定 c 的风险求导, 得到 $2c(\mu^2+v)-2\mu^2$, 其中 $v=\sigma^2/n>0$; 二阶导 $2(\mu^2+v)>0$, 所以唯一最小 $c=\mu^2/(\mu^2+v)$ 。代回得到 $\mu^2v/(\mu^2+v)$, 主例 $c=3/7, MSE=1/7$ 。算法不能知道未知 μ , 故这只是oracle下界式对照。

若 c 依赖数据, $T=c(X)$ 平均, $E[T]$ 通常不等于 $E[c]E[\text{平均}]$ 。实验扩展规则 $c=1\{|\text{平均}|>1\}$ 在主例只有 $++$ 一行取1, 其余为0, 所以 T 以 $1/8$ 概率为 $3/2$, 其余为0。期望 $3/16$ 、偏差 $-5/16$; MSE 为 $(7/8)(1/4)+(1/8)(1)=11/32$, 大于均值的 $1/3$ 。挑选步骤必须包含在规则内部重新评估。

9. 无偏但不一致

$T_n=X_1$ 不使用新增样本, $E\mu T_n=\mu$, 对每个 n 无偏。然而两点模型下 $|T_n-\mu|$ 恒等于1, 所以对 $\varepsilon=.5$, 概率始终为1, 不趋于0。方差始终1说明风险不下降, 但概率计算才直接验证不一致; 仅说“图看起来不收敛”不是证明。

10. 有偏且一致的渐消收缩

固定 $\kappa>0, c_n=n/(n+\kappa)$ 。偏差 $-\kappa\mu/(n+\kappa)$, 方差 $n\sigma^2/(n+\kappa)^2$ 。MSE为两者之和, 偏差平方按 n^{-2} 数量级趋零, 方差按 n^{-1} 数量级趋零。由Markov, $P(|T_n-\mu|>\varepsilon)\leq MSE/\varepsilon^2$ 趋零。有限 n 可有偏而一致。固定 $c=.5$ 的偏差则为 $-\mu/2$, 不随 n 消失; 除 $\mu=0$ 外不一致。

11. 依概率收敛却MSE发散

目标0, U 均匀于 $(0,1)$, $T_n = n1\{U < 1/n\}$ 。固定 $\varepsilon > 0$, 当 $n > \varepsilon$ 时 $P(|T_n| > \varepsilon) = 1/n \rightarrow 0$, 故依概率收敛到0。但 $E[T_n^2] = n^2/n = n \rightarrow \infty$; 其期望也恒为1, 没有趋于0。罕见的大值阻止矩收敛。此例不是实用估计器, 只说明单靠概率集中不能交换极限与二阶矩。

12. 单点敏感性与共同目标

数据为 $(-1, 0, 0, 1, t)$, $t \geq 1$ 时排序不改变中间位置, 所以中位数恒0; 均值为 $t/5$ 。这是替换一条观测的确定性敏感性分析, 不含概率抽样。

两种模拟总体都关于 μ 对称, 连续密度在 μ 两侧为正, 所以均值与唯一中位数都是 μ 。中位数在这些模型中比较的是同一目标。单侧污染会破坏这条共同目标性质, 需分别定义混合均值、混合中位数或未污染中心, 再判断哪一个任务是目标。

13. 混合方差与理论风险

令 C 表示成分, 两个条件均值都为 μ 。全方差公式给 $\text{Var}(X) = E[\text{Var}(X|C)] + \text{Var}(E[X|C]) = .9 \times 1 + .1 \times 100 + 0 = 10.9$ 。iid均值方差 $10.9/n$ 且无偏, 所以MSE同值。代码normal的scale是标准差, 高波动成分用10, 不是100。若污染均值与普通均值不同, 第二项不再为0, 目标均值也会移动。

14. 相对效率的对象

明确以 A 为基准、比较 B 时定义 $\text{Var}(A)/\text{Var}(B)$ 。数值大于1表示 B 方差更小; 取倒数会反转解释, 必须标分子分母。主例 A 为均值、 B 为中位数, 比例 $1/3$ 。效率在这里不表示运行速度。两者必须针对相同模型、目标与样本量。若方法有偏, 只比较方差会把“永远输出错误常数”的零方差误认成最好, 应比较完整风险。

15. 标量信息下界的条件推导

假设固定支持、密度对 μ 可微、相关导数和积分可交换、 T 不含未知 μ 、 $E_\mu T^2$ 有限, 且 $0 < I(\mu) < \infty$ 。分数 $S = \partial \log f_\mu / \partial \mu$ 。对积分 $f_\mu = 1$ 求导得 $E_\mu S = 0$; 若 T 在 μ 邻域内无偏, 对 $E_\mu T = \mu$ 求导得 $E_\mu(TS) = 1$, 所以 $\text{Cov}(T, S) = 1$ 。Cauchy-Schwarz给 $1 \leq \text{Var}(T)\text{Var}(S) = \text{Var}(T)I$, 因此 $\text{Var}(T) \geq 1/I$ 。

Gaussian已知 σ^2 下 $S = \sum (X_i - \mu)/\sigma^2$, 期望0、方差 n/σ^2 。因此 $I = n/\sigma^2$, 下界 σ^2/n , 样本均值达到。结论是相应无偏类中的有效性; 有偏收缩不属于此下界的前提。支持随参数移动、不可交换积分或矩不存在时, 上述推导不能照搬。

16. 参数风险、独立预测与训练复用

令 $Y = \mu + \varepsilon_{\text{新}}$, $\varepsilon_{\text{新}}$ 独立于训练数据, 均值0、方差 σ^2 。展开 $(Y - T)^2$, 交叉项 $2E[(\mu - T)\varepsilon_{\text{新}}] = 0$, 因此预测风险 $= \text{MSE}(T) + \sigma^2$ 。两点主例分别为4/3、2、55/48, 也可对八个训练样本和两个新符号共16种等概率联合情形直接求和。

若使用训练点 X_i , $\text{Cov}(X_i, \text{平均}) = \sigma^2/n$, 故 $E[(X_i - \text{平均})^2] = \sigma^2 + \sigma^2/n - 2\sigma^2/n = (1 - 1/n)\sigma^2$ 。平均 n 项后同值。独立新点的协方差为0, 风险 $(1 + 1/n)\sigma^2$ 。二者差 $2\sigma^2/n$, 来自数据依赖和评估对象变化。

17. 有限经验恒等式与MCSE

令 $\bar{t} = \sum t_r / R$ 。把 $t_r - \theta$ 分成 $(t_r - \bar{t}) + (\bar{t} - \theta)$, 交叉求和因 $\sum (t_r - \bar{t}) = 0$ 消失, 得到经验 $\text{MSE} = (\bar{t} - \theta)^2 + \sum (t_r - \bar{t})^2 / R$ 。若用样本方差 s^2 , 乘 $(R - 1)/R$ 。例 $t = (0, 1, 2)$ 、 $\theta = .5$: $\text{MSE} = (.25 + .25 + 2.25)/3 = 11/12$, 偏差平方 $1/4$, 方差 $2/3$, 样本方差1。

定义平方损失 L_r , 模拟风险 L 的标准误差用 $s_L / \sqrt{R}$ 估计, 依赖各批独立和 $\text{Var}(L)$ 有限。方法在同一批数据计算时彼此配对; 比较差值风险应分析每批损失差, 而不是盲加两个独立方差。

18. 诚实的整条规则实验

每个外层重复先独立生成一份完整训练数据, 再执行预处理、选择 c 、拟合和估计, 必要时另生成独立验证或测试数据。统计每批最终输出的误差, 不能只重复已选模型的最后一步; 不同 n 和模型保持目标与说明一致。真实 μ 只参与数据生成与评分, 不能进入被评价算法, oracle 必须单列。

三种失效分别是: 用未知 μ 选 c 造成泄漏; 重尾平方损失方差不存在却照用 MCSE; 极小正平方项下溢为0后伪称规则无波动。还应检查将 (R, n) 展平造成样本单位错误、误用 $R - 1$ 破坏有限恒等式、先把 bool 转数值再验证、重复 JSON 键掩盖非法原值。完整报告同时保留理论、精确枚举、有限模拟与数值边界证据。