

第二十七讲 估计误差与偏差方差实验

1. 目标与提交结果

本实验让你把“这次误差”“重复抽样偏差”和“模拟估计误差”分开。你将手工枚举一个完整样本空间，再比较均值、中位数、固定收缩和渐消收缩，最后检查估计均值与预测一个新观察为什么不同。先修为第十九、二十一至二十三、二十五讲；先读正文第四至九节再写代码。预计纸笔和解释需要90至120分钟，CPU计算本身通常更短。

提交一份有解释的短报告、顺序执行的Notebook和你修改过的配置。报告需要包含：八个有序样本的精确表；三个规则的偏差、方差与MSE； μ 敏感性曲线；Gaussian与对称污染两种机制下的经验风险、MC标准误和理论可核对量；至少四个被正确拒绝的失效输入。不能只交一张低MSE截图。

数据全部为明确指定的合成机制。默认任务无需外网、账号、密钥或付费API。结论针对给定分布，不代表现实任务准确率。

2. 建立可重复的运行起点

在本单元目录启动：

```
python experiment.py --output-dir outputs
jupyter lab experiment.ipynb
```

脚本总是先执行八个核心检查，再读取两个输入文件，完成全部模拟，最后写outputs/report.json。默认数据路径由脚本位置确定，不依赖终端当前目录。Notebook重新导入核心函数并自行运行模拟；不需要先手工生成报告，也不依赖文件里旧的输出。

普通Python环境可安装requirements.txt。若你使用Anaconda，提供了environment.yml：

```
conda env create -f environment.yml
conda activate ml-course-027
```

验收环境实际运行Python 3.12.14、NumPy 2.3.5、Matplotlib 3.10.8。Notebook在独立新Python进程中的真实IPython InProcessKernel顺序执行并保留图像。Anaconda安装、浏览器Jupyter界面和socket内核传输没有在制作环境实测，不能把这些不同层次混称为已经验证。遇到导入失败，先核对依赖与Notebook工作目录，不要删掉数学检查。

3. 用纸笔列全八种可能

固定 $\mu=1/2$ ，单次噪声取 ± 1 各一半， $n=3$ 且相互独立。先写八个有序符号三元组。每行依次计算观测、平均值、中位数、半均值，以及三者相对 μ 的平方误差。每一行权重是 $1/8$ 。

按正号个数K汇总时，四种K的权重变成1/8、3/8、3/8、1/8。不要把去重后的四行等权。核验代码如下：

```
from fractions import Fraction
import experiment as e
exact = e.exact_two_point(Fraction(1, 2), 3, Fraction(1, 2))
for row in exact['rows']:
    print(row)
print(exact['statistics'])
```

通过条件：均值MSE=1/3，中位数MSE=1，半均值MSE=7/48。后者偏差-1/4、方差1/12。请用直接平均八个平方误差核验一次，再用偏差平方加方差核验一次，避免两条代码都依赖同一个错误公式。

思考：均值取5/6的那次样本上，三个规则各离 μ 多远？这个本次排序能否代替长期风险排序？再解释这个两点总体的中位数为什么不唯一。不能把此例推广成所有中位数估计都不一致。

4. 把有利真值改掉

固定 $n=3$ 、 $\sigma=1$ 、 $c=.5$ ，纸笔求风险函数 $\mu^2/4+1/12$ 。用 $\mu=0$ 、.5、1、2分别计算，并与均值风险1/3比较。接着绘制 μ 从-2到2的曲线。

```
for mu in [0, .5, 1, 2]:
    print(mu, e.shrinkage_risk(mu, 1, 3, .5))
print(e.oracle_risk(.5, 1, 3))
```

通过条件：交点为 ± 1 ； $\mu=2$ 时半均值MSE=13/12。oracle系数3/7、风险1/7需要未知真值 μ 。请把“允许看见真值的理论对照”写在图注中，不能将其作为实际算法成绩。

扩展任务：考虑数据选择系数 $c(x)=1\{\text{样本均值}>1\}$ 。它在每一批数据上重新选择0或1。对八个样本逐一计算完整规则，而不是先算平均 c 再代入固定 c 公式。列出规则输出与风险，解释随机 c 与样本均值的依赖关系。

5. 检查有限模拟的分母

先不用随机数，只给估计值列表 $t=(0,1,2)$ ，目标 $\theta=.5$ 。手算平均估计1、经验偏差.5、经验方差2/3和MSE11/12。若用 $R-1$ 为分母，样本方差是1，必须乘2/3才能回到风险恒等式。

```
s = e.risk_summary([0, 1, 2], .5)
print(s)
e.require(abs(s['mse'] - 11/12) < 1e-14, 'finite MSE')
e.require(abs(s['identity_residual']) < 1e-14, 'finite identity')
```

risk_mcse 是平方损失平均的模拟标准误；它与估计器标准误 $\sqrt{\text{variance_R}}$ 的对象不同。前者回答“这次用 R 批估计的风险有多精确”，后者回答“单次估计规则随数据变化多少”。在真实风险未知时，前者仍只是有限模拟估计，并依赖平方损失方差有限。

6. 按完整数据集重复模拟

读取data/model_spec.json，默认每个模型、每个n有R=10000个独立样本批次，n为3、15、63。数组形状(R,n)，行是一份训练数据。四种规则在同一行上计算，所以方法比较是配对的，不能把它们当成四组彼此独立的实验。

```
spec = e.load_spec()
result = e.simulation(spec)
for row in result['rows']:
    print(row['model'], row['n'], row['rule'],
          row['bias'], row['variance_R'], row['mse'], row['risk_mcse'])
```

两种总体都以 $\mu=.5$ 为均值和唯一中位数。Gaussian的 $\sigma=1$ ；污染机制每个观测独立以.1概率使用标准差10，其余使用1。混合方差是10.9，均值MSE为 $10.9/n$ 。NumPy `scale`表示标准差，传10，不能传100。

默认运行的Gaussian $n=15$ 均值经验MSE约.0675728，中位数约.1016626，固定半均值约.0805226； $n=63$ 时均值约.0159761，固定半均值约.0661508。污染 $n=15$ 下均值约.7236205，中位数约.1254564。主例表明方法排序依赖分布和样本量。它没有证明任何有限次模拟中的排序必然成立，也没有证明中位数对任意污染都估计同一个目标。

通过条件：每一行的经验偏差平方加经验方差与经验MSE在浮点误差内相容；均值理论风险在Gaussian为 $1/n$ ，在混合为 $10.9/n$ 。理论风险与经验风险无需完全相等，请同时报告MCSE，不要修改种子直到误差条恰好看。±2 MCSE是直观模拟误差条，不被当作小样本严格95%区间。

7. 区分固定收缩与渐消收缩

固定 $c=.5$ 不会随着n增加而回到1。另一个规则使用 $c_n=n/(n+3)$ 。当 $n=3$ 时两者相同； $n=15$ 时 $c_n=5/6$ ， $n=63$ 时为21/22。对每个n画完整理论风险，并用模拟结果覆盖对应点。

通过条件：固定半均值在 $\mu=.5$ 时MSE极限为 $1/16$ ；渐消收缩的偏差和方差都趋零。有限模拟曲线可能上下浮动，不要求每个相邻样本量的经验误差都下降。再用 $T_n=X_1$ 说明无偏不保证一致，用罕见事件反例说明一致不保证MSE趋零。

8. 预测一个真正的新观察

脚本在每批训练数据之外独立产生Y，再计算 $(Y-T)^2$ 。均值等线性规则的理论预测风险等于参数MSE加总体噪声方差；中位数的参数风险没有本实验使用的闭式，所以相应理论预测字段为空，而不是填一个模拟值冒充定理。

默认两点精确例子可核对：均值新点风险4/3，中位数2，半均值55/48。Gaussian $n=3$ 均值预测风险应为4/3。有限预测模拟可能波动，尤其在宽尾混合下，因此不要要求一次预测误差恰好等于参数经验风险加10.9。

额外核验：枚举原样本和独立新符号的16个联合情形，直接求预测风险。然后将Y换成训练样本第一点，看看交叉项为什么不再为0。请标注评估目标的这次改变。

9. 失败输入应先被拦住

数值API先检查完整列表和全部配置。包括未用来画图的风险_centers、最后一个样本量、Gaussian分支暂不使用的污染尺度。支持范围和预算在README中；不要靠隐式转换把True变成1。

```
bad_calls = [
    lambda: e.risk_summary([0, 1, True], 0),
    lambda: e.mean([0, float('nan')]),
    lambda: e.shrinkage_risk(.5, 1, 3, '0.5'),
    lambda: e.risk_summary([0, 1e-200], 0),
    lambda: e.exact_two_point(.5),
]
for call in bad_calls:
    try:
        call()
    except ValueError:
        print('rejected')
    else:
        raise RuntimeError('invalid input accepted')
```

JSON解析保留原始小数token检查，1e-400不能先变成0再通过；重复键一律拒绝，包含相同值的重复。真正0e-400可以表示零。测试一份最后一行分母为0的CSV、一份重复center键的JSON，并确认运行失败后已有report.json的原始字节不变，也没有新输出目录。所有输入验证应发生在RNG构造和文件写入之前。

浮点实现不等于所有实数上的数学公式。特别小的非零离差平方或平方损失方差不能表示时应报错并建议换单位，不能返回0再宣布估计器稳定。已变成普通float的0无法恢复来源中被丢失的信息。

10. 最终解释清单

写明目标参数、分布模型、独立采样单位、n、R、规则与选择步骤、损失函数、方差分母、随机种子、理论对照和数值限制。分别解释：为什么有偏规则可能改善小样本MSE；为什么改变 μ 会逆转排序；为什么中位数在两点模型与连续对称污染中不能套用同一句一致性结论；为什么一张经验风险图不足以证明普遍优越。

正文18道题的完整解答在answers.pdf。实验的核心不是找到一个永远最好的估计器，而是学会把比较对象、假设和误差来源说清楚。