

第二十七讲 估计误差与偏差方差

1. 平均来说正确，为什么一次仍可能很差？

想用三个读数估计一个固定总体均值。规则A取平均，规则B取中位数，规则C把平均缩到原来一半。有人说A与B“无偏”，所以必然比C好；也有人只看一份数据上C碰巧最接近真值，就宣布收缩总有用。这两种推论都跳过了重复抽样。

本讲用一个只有八种可能样本的完整例子，逐项算出每条规则的偏差、方差和均方误差，再到有限模拟中检查Gaussian与对称污染机制。核心问题是：**为什么低偏差的方法，也可能在小样本上不可靠？**

直接先修是第十九、二十一至二十三、二十五讲：期望、方差、条件独立、抽样分布、估计量和区间。这里的偏差是统计估计偏差，不是在讨论社会偏见；这里的方差是估计规则跨完整数据集的变化，不是某一数据集里原始读数的散布。




图1 固定同一个真实均值，重复抽取完整样本，再对每批运行同一估计规则。偏差方差属于右边的估计量分布。

2. 固定参数、随机数据、固定规则

写 $X=(X_1, \dots, X_n)$ 为随机样本，真实参数 θ 固定，数据生成分布为 P_θ 。估计量 $T=T(X)$ 必须只使用可观察数据与事先规定的信息，不可以偷用未知 θ 。读到一份具体样本 x 后， $t=T(x)$ 是一个已经确定的估计值。

E_θ 和 Var_θ 表示在真实参数 θ 下，对所有可能数据集取期望与方差。如果算法另有随机种子，需要说明把算法随机性一起平均，还是固定种子只讨论数据变化。本讲主要规则是确定函数，模拟种子只用于生成可复现的样本批次。

同一组读数可以服务不同目标。总体均值、总体中位数、某个未受污染群体的中心未必相同；在比较误差前必须固定目标。把对均值有偏的方法改称中位数估计后，又拿它与均值真值比较，是在偷换任务。

3. 偏差不是本次误差

定义偏差 $b_\theta = E_\theta[T] - \theta$ 。若对参数空间中的每个 θ 都为0，称这条规则无偏。一次误差 $t - \theta$ 可以分解为

$$T - \theta = (T - E_{\theta}T) + (E_{\theta}T - \theta).$$

第一项是围绕规则长期中心的随机波动，其期望为0；第二项是偏差，是固定 θ 下的确定数。一次输出高于真值不证明估计量有正偏，正偏规则也可能在某次样本上低于真值。

无偏要求相对于指定目标、分布模型和整个参数范围。一个常数规则 $T=0$ 在 $\theta=0$ 这一点上恰好无误差，并不因此成为对所有 θ 都无偏的估计量。发现某个参数处表现好，不能自动声称全局优越。

4. 方差、标准误、MSE与单位

估计量方差为 $\text{Var}_{\theta}(T) = E_{\theta}[(T - E_{\theta}T)^2]$ ，标准误为它的平方根。均方误差是 $\text{MSE}_{\theta}(T) = E_{\theta}[(T - \theta)^2]$ 。均方根误差RMSE是MSE的平方根，与参数具有相同单位；方差与MSE的单位是参数单位的平方。

标准误只看相对自身中心的散布。一个固定输出错误常数的规则方差为0，却可能总是离目标很远。小方差并不等于小总误差，窄区间也不自动意味着目标正确。

把上一节的分解平方，交叉项期望为0，得到

$$\text{MSE}_{\theta}(T) = \text{Var}_{\theta}(T) + b_{\theta}^2.$$

这个等式需要相关二阶矩有限；不是说任何重尾规则都可以给出有限的两个数。本讲每个精确与模拟模型都满足有限矩。 $\text{RMSE} = \sqrt{\text{方差} + \text{偏差}^2}$ ，一般不等于标准误加偏差绝对值。




图2 三种估计量分布：无偏但分散、有偏但集中、固定错误输出。MSE同时计算中心偏离和自身散布。

5. 一个能够完整枚举的总体

令 $X_i = \mu + \varepsilon_i$ ， ε_i 相互独立，各以1/2概率取-1或+1。目标是 μ ，单次均值 μ 、方差1。主例固定真实 $\mu=1/2$ ，每次只抽 $n=3$ 个观测。八个有序符号序列各占1/8，不是去重后的四个成功个数各占1/4。

设 K 为三个正号的个数。 $K=0, 1, 2, 3$ 的概率分别为1/8、3/8、3/8、1/8，样本均值为 $\mu + (2K-3)/3$ 。主例四种均值为-1/2、1/6、5/6、3/2。

规则A是样本均值，规则B是三个观测的中位数，规则C是样本均值乘1/2。下面每条公式都会在全部八个有序样本上复核。不要把随机生成八批数据当成这里的“完整八种可能”；随机抽样可能重复，也可能漏掉某些序列。

有序符号序列	概率	均值	中位数	半均值
---	1/8	-1/2	-1/2	-1/4
--+	1/8	1/6	-1/2	1/12
-+-	1/8	1/6	-1/2	1/12
+++	1/8	5/6	3/2	5/12
+-+	1/8	1/6	-1/2	1/12
++-	1/8	5/6	3/2	5/12
+++	1/8	5/6	3/2	5/12
+++	1/8	3/2	3/2	3/4

图3 八个等概率符号序列及三条估计规则。按K汇总时需要1、3、3、1的权重，不能把四个汇总行等权。

6. 两条无偏规则仍可以差很多

样本均值的期望为 μ ，独立性使方差为 $1/3$ ，所以MSE也为 $1/3$ 。中位数则由符号多数决定：至少两个正号时为 $\mu+1$ ，否则为 $\mu-1$ 。两种结果各占 $1/2$ ，期望仍为 μ ，但方差为 1 ，MSE也为 1 。

两者都无偏，却有三倍的MSE差异。无偏只约束长期中心，没有保证每次都稳定。这里并不是否定中位数，而是说明比较必须相对于具体分布与损失。

这个两点总体还有一个重要条件：从 $\mu-1$ 到 $\mu+1$ 之间的任何点都可满足总体中位数定义。中位数不唯一。对任意奇数 n ，样本中位数仍以相同概率取两个端点，因此不会收敛到中间的 μ 。通常关于样本中位数的一致性结论需要唯一中位数和CDF在目标两侧确实穿过 $1/2$ 等条件；不能只看到“分布对称”就忽略这个缺口。

7. 有偏规则反而降低主例MSE

规则C取 $T_{1/2}$ =样本均值/2，主例期望为 $1/4$ ，偏差 $-1/4$ ；方差为 $(1/2)^2 \times (1/3) = 1/12$ 。因此

$$\text{MSE}_{\mu=1/2}(T_{1/2}) = \frac{1}{12} + \frac{1}{16} = \frac{7}{48} < \frac{1}{3}.$$

偏差确实增加了，但方差减少得更多，所以总平方误差降低。八个样本逐一计算 $(T-1/2)^2$ 再取平均，也得到 $7/48$ ；这提供不借助分解公式的独立核验。

若恰好观察到两个高值、一个低值，均值为 $5/6$ ，中位数 $3/2$ 、半均值 $5/12$ ；三者本次误差分别 $1/3$ 、 1 、 $-1/12$ 。这只是一个具体样本；即便该次排序与长期MSE一致，也不能把这种巧合当作规则比较的证明。




图4 主例三条规则的偏差平方和方差以相同单位堆叠。半均值有偏，但其总高度7/48最小。

8. 收缩到零何时会失败？

一般设样本均值无偏、方差 $v=\sigma^2/n$ ，用固定 $c\in[0,1]$ 定义 $T_c=c$ 样本均值。它的偏差为 $(c-1)\mu$ ，方差 c^2v ，故

$$\text{MSE}_\mu(T_c) = (1-c)^2\mu^2 + c^2v.$$

对 $n=3$ 、 $\sigma^2=1$ 、 $c=1/2$ ， $\text{MSE}=\mu^2/4+1/12$ 。与均值的 $1/3$ 比较，只有 $|\mu|<1$ 时半均值更好； $|\mu|=1$ 相等， $|\mu|>1$ 更差。真值 $\mu=2$ 时，半均值 $\text{MSE}=13/12$ ，反而大于 $1/3$ 。

收缩中心0是一个建模选择，不是自然法则。若目标附近有可信的先验中心，可以减少小样本波动；若中心严重不相容，就可能引入更大的偏差。不能只展示 $\mu=1/2$ 那张漂亮图，再宣布规则C在所有参数上占优。




图5 固定 n 时，MSE随真实 μ 变化。曲线相交于 ± 1 ，显示“某处更好”和“处处更好”是不同结论。

9. 最优系数的公式为什么不能直接作为算法？

把上式对 c 求导，得到 $2c(\mu^2+v)-2\mu^2$ 。因为 $\mu^2+v>0$ ，唯一最小点为

$$c_{\star} = \frac{\mu^2}{\mu^2 + v}, \quad \text{MSE}(T_{c_{\star}}) = \frac{\mu^2 v}{\mu^2 + v}.$$

主例 $\mu=1/2$ 、 $v=1/3$ 时， $c^*=3/7$ ，最小风险 $1/7$ ，比固定半均值 $7/48$ 略低。但这个系数偷看了未知 μ ，称为oracle对照，只能用于理论解释，不能当成可部署的已知算法。

如果把未知 μ 换成样本估计， c 就变成数据的函数，偏差与方差必须对整个新规则重新计算。不能把随机 c 塞进只为固定 c 推导的公式后宣称风险不变。若用验证数据选择强度，也需要把选择步骤纳入重复实验，并保护最终测试数据。

10. 一致性是样本量增加时的另一种性质

估计量序列 T_n 一致，是指对每个 $\varepsilon>0$ ，当 $n \rightarrow \infty$ 时， $P(|T_n - \theta| > \varepsilon)$ 趋于0。它说的是概率集中到目标，不要求有限 n 无偏，也不等于某一条随机路径上的误差必然单调下降。

iid有限方差下，样本均值偏差0、方差 σ^2/n 。Chebyshev给 $P(|\text{平均} - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2)$ ，所以一致。相反，规则 $T_n = X_1$ 始终无偏，但完全不用后面的数据，在本例方差一直为1，因而不一致。

固定半均值通常趋于 $\mu/2$ ，而非 μ ，所以除 $\mu=0$ 外不一致。若改成 $c_n = n/(n+\kappa)$ ，其中 $\kappa>0$ 固定，偏差为 $-\kappa\mu/(n+\kappa)$ ，方差为 $n\sigma^2/(n+\kappa)^2$ ；两者都趋于0，MSE趋于0，再由Markov用于平方误差即可推出一致。它每个有限 n 可能有偏，却能一致。




图6 固定半均值、渐消收缩与均值的风险随 n 变化。更多数据不能消除固定比例造成的目标偏移。

11. MSE趋零比依概率收敛更强

若 $\text{MSE}(T_n)$ 趋0，则 $P(|T_n - \theta| > \varepsilon) \leq \text{MSE}/\varepsilon^2$ 也趋0，这是直接的非负变量上界。反过来，仅一致性不够保证平方误差期望趋0，因为非常罕见但越来越大的失误可能主导期望。

给一个纯数学反例：目标0，取 U 在 $(0,1)$ 均匀， $T_n = n$ 当 $U < 1/n$ ，否则为0。对固定 ε 和足够大 n ，误差超过 ε 的概率为 $1/n$ ，趋0；但 $\text{MSE} = n^2 \times (1/n) = n$ ，反而发散。这个序列用于解释矩条件，不是建议的估计程序。

因此研究重尾方法或极端数值时，不能仅用“多数运行很好”替代期望平方风险。实际比较还可能关心中位绝对误差、尾部风险或其他损失，本讲始终明确所用平方损失。

12. 稳健估计在什么模型里比较？

中位数对少量极端观测更不敏感，可以用一个确定性改动看到：将五个数 $(-1, 0, 0, 1, t)$ 中的 t 从1增大到100，均值随 t 线性增大，而在 $t \geq 1$ 时中位数始终为0。这是一个替换点敏感性例子，不是所有抽样风险的证明。

为公平地比较均值与中位数估计同一个目标，模拟两个关于 μ 对称且有唯一中位数的模型。模型一是Gaussian($\mu, 1$)；模型二是 $0.9\text{Gaussian}(\mu, 1) + 0.1\text{Gaussian}(\mu, 100)$ ，第二个参数为方差。两种模型的均值与中位数都为 μ ，因此没有更换目标。

第二个模型每条观察先独立选择普通或高波动成分，高波动成分标准差为10。总体方差 $0.9 \times 1 + 0.1 \times 100 = 10.9$ ，所以均值MSE精确为 $10.9/n$ 。中位数的有限样本风险由重复模拟观察，不宣称有同一个闭式数。Gaussian下均值常更高效，对称污染下中位数可能以牺牲部分Gaussian效率换取抗极端值表现；结论必须附带 n 、混合概率和成分尺度。

若污染是单侧偏移，混合均值、中位数与未污染中心可以不同，必须重新指定目标。不能继续把“偏离未污染中心”称为对混合总体均值的偏差。




图7 单点替换敏感性与两个对称总体形状分开显示。稳健性机制不等于某个有限模拟下所有方法的统一排序。

13. 相对效率先把比较类说清楚

当两条规则估计同一 θ 且都无偏时，它们的MSE就是方差，可以用方差比衡量相对效率。若以规则A作基准，可明确报告 $\text{Var}(A)/\text{Var}(B)$ ；比例大于1表示B在这个模型和样本量下方差较小。不同文献可能取倒数，所以必须写清分子分母。

主例均值与中位数都无偏， $\text{Var}(\text{均值})/\text{Var}(\text{中位数})=1/3$ 。说中位数在此比较下相对效率1/3，不等于说中位数运行速度只有三分之一，也不等于任何分布下都如此。对有偏规则，直接用方差比会忽略偏差，应比较完整风险。

“有效估计”有时特指在给定模型中达到一个方差下界。下一节给最简单Gaussian均值例子，展示这个词需要哪些限制，而不是把它作为泛泛赞美。

14. 一个有条件的效率下界

只考虑单个实参数 μ 、参数无关的固定支持、可对密度求导，且可以把求导移入相关积分；估计量 T 本身不能含未知 μ ， $E_\mu T^2$ 有限。定义分数函数 $S_\mu(X) = \partial \log f_\mu(X) / \partial \mu$ ，并假定 $0 < I(\mu) = E_\mu[S_\mu^2] < \infty$ 。这些是推导条件，不适用于支持随参数移动等任意模型。

由密度归一化求导， $E_\mu S_\mu = 0$ 。若 T 在邻域内无偏， $E_\mu T = \mu$ ，两侧求导，交换导数与积分得到 $E_\mu[TS_\mu] = 1$ 。因此 $\text{Cov}_\mu(T, S_\mu) = 1$ 。对随机变量的Cauchy-Schwarz不等式给

$$1 \leq \text{Var}_\mu(T) \text{Var}_\mu(S_\mu) = \text{Var}_\mu(T) I(\mu), \quad \text{Var}_\mu(T) \geq 1/I(\mu).$$

这就是此处的标量Cramér-Rao下界。我们给出了在声明可交换条件下的证明；没有证明任意函数都满足这些技术条件，也没有将此无偏下界套给有偏收缩规则。

在iid Gaussian(μ, σ^2)、已知正 σ 模型里， $S_\mu = \sum (X_i - \mu) / \sigma^2$ ，所以 $I(\mu) = n / \sigma^2$ ，得到方差下界 σ^2 / n 。样本均值正好达到，因而在该无偏比较类里有效。它既无偏又达到下界，仍不排除有偏规则在某些 μ 附近取得更小MSE；第八节已给出具体反例。




图8 Gaussian模型中的无偏方差下界与均值方差重合。收缩曲线另画完整MSE，避免把不同评价对象放进同一个下界结论。

15. 估计误差与预测误差相差什么？

现在目标从估计均值 μ 改为预测一个全新观察 $Y = \mu + \varepsilon_{\text{new}}$ 。假设新噪声与训练数据独立，均值0、方差 σ^2 ；估计规则 T 只用训练数据。展开得到

$$E[(Y - T)^2] = E[(\mu - T)^2] + E[\varepsilon_{\text{new}}^2] + 2E[(\mu - T)\varepsilon_{\text{new}}] = \text{MSE}_\mu(T) + \sigma^2.$$

交叉项为0依赖独立性与零均值。最后一项噪声是预测一个新读数本身的变化；它不是估计器的偏差，也不是把原始观测方差重复算错。主两点模型 $\sigma^2=1$ ，所以均值预测MSE为4/3，半均值为55/48，中位数为2。

如果Y正是用来构造T的训练数据之一，独立条件不成立，交叉项不能直接删掉。比如用同一n个样本算均值，再平均训练残差平方，期望为 $(1-1/n)\sigma^2$ ；用该均值预测独立新点，风险为 $(1+1/n)\sigma^2$ ，两者相差 $2\sigma^2/n$ 。训练误差偏低不是“方差不存在”，而是评估对象和依赖关系改变了。




图9 估计固定 μ 与预测独立新Y的平方风险相差噪声项；训练点复用破坏这条独立推导。

16. 在模拟结果里准确分解，不混用分母

固定一个真值与n，独立重复R次完整采样，每次计算 t_r 。记经验均值 $\bar{t}$ ，经验偏差 $\hat{b}=\bar{t}-\theta$ ，使用分母R定义经验方差 $\hat{v}_R=\sum (t_r-\bar{t})^2/R$ 。直接展开有限求和就有

$$\frac{1}{R} \sum_{r=1}^R (t_r - \theta)^2 = \hat{b}^2 + \hat{v}_R.$$

这是对这批模拟数字的代数恒等式，不是极限近似。如果方差改为无偏样本版本 $s^2_R=\sum (t_r-\bar{t})^2/(R-1)$ ，右边必须写成 $\hat{b}^2+[(R-1)/R]s^2_R$ 才能与左边相等。

有限模拟的 $\hat{b}$ 即使对应理论无偏规则也不会恰好为0。模拟MSE也是随机估计：令 $L_r=(t_r-\theta)^2$ ，均值L估计真实MSE，模拟标准误可用 L_r 的样本标准差除 $\sqrt{R}$ ，前提是平方损失本身方差有限。这个误差条衡量模拟计算精度，不是原始参数估计的标准误。





图10 同一批模拟用分母R得到精确风险分解；误用R-1会留下可预测的差额。

17. 实验必须让整条规则重复，而不只重复最后一步

实验先完整枚举八种符号序列，再模拟Gaussian与对称污染下 $n=3$ 、15、63各10000批。数组形状为 (R,n) ，每行是一份完整训练样本。均值、中位数和收缩都沿行计算，不能把全部 $R \times n$ 个观测混成一份大样本。

若模拟算法还选择超参数，就要每批重新执行选择步骤。只在第一批选一个最有利系数，再在同一批上报告最小误差，会混入选择偏差。oracle曲线必须与可观察规则分开标注，不能用真实 μ 计算系数后假装没有泄漏。

固定随机种子使当前实现可复现，但不是数学证明；更换种子会改变有限曲线。理论风险、经验风险和Monte Carlo标准误都保留。对主例与Gaussian均值能算出的理论量应先核对，再对没有闭式的中位数有限风险保持适当限定。

图11 多个 n 与两个生成模型下完整规则的重复实验。图注明确真值、污染机制、 R 和误差条对象。

18. 数值验收也是统计结论的一部分

风险函数先验证所有数据、真值、样本量、收缩系数和模型参数，再构造RNG或写报告。拒绝bool、文本、复数、NaN和超出声明精度范围的标量。对真正常量数组可以在完整验证后返回精确零方差；对非恒定但极小的残差，不能让平方下溢后伪装成确定性规则。

混合尺度还可能在移位时丢掉小均值，例如原值-1、1、一个很小正数的补偿求和与“先减去-1再加回来”并非总在浮点上等价。独立Fraction或高精度检查应覆盖这些边界，不只测试正常的整齐小数。

验收需要新进程、无关工作目录、python -O和Notebook新内核顺序执行。坏CSV应让旧输出保持不变。图像中若偏差和方差用不同尺度，就不应假装柱高能直接相加；所有风险标签的单位与分母要一致。



图12 理论分解、精确枚举、有限模拟与数值边界构成不同层次的检查。任何一层失败都不能由一张漂亮曲线掩盖。

19. 自测与后续

1. 定义估计量、估计值、真实参数和 $E\theta$ 各固定了什么，说明算法随机性如何纳入。
2. 从加减 $E\theta T$ 出发完整推导MSE分解，写出有限矩条件和单位。
3. 为什么本次误差不等于偏差？常数规则在某个真值上正确意味着什么？
4. 枚举 $n=3$ 的八个等概率符号样本，求均值的四点分布，解释权重1、3、3、1。
5. 推导主例均值与中位数均无偏但MSE分别 $1/3$ 和 1 ；说明总体中位数非唯一的影响。
6. 不借助风险分解，直接平均八个半均值平方误差，得到 $7/48$ 。
7. 对固定 c 推导完整风险，确定半均值在哪些 μ 比均值好，并核对 $\mu=2$ 。
8. 求oracle系数 c^* ，说明把未知 μ 替成数据估计后为什么必须重新分析整条规则。
9. 举出无偏但不一致的估计量，并用概率而非图像说明。
10. 推导 $c_n=n/(n+\kappa)$ 的偏差、方差与MSE极限，说明有限有偏与一致可共存。
11. 用 $T_n=n \cdot 1\{U < 1/n\}$ 说明依概率收敛不保证MSE趋零。
12. 比较单点替换敏感性，说明为什么对称污染模型让均值和中位数仍估计同一目标。
13. 计算混合方差 10.9 与均值风险 $10.9/n$ ；解释单侧污染为何需要重新定义目标。
14. 写清相对效率的分子分母，以及为何有偏方法不能只比较方差。

15. 在声明的可交换与有限矩条件下推导标量Cramér–Rao下界，并核对Gaussian均值。
16. 推导新点预测风险与参数MSE关系，再解释训练复用时交叉项为何不能删。
17. 证明有限模拟的经验风险恒等式，处理方差分母 R 与 $R-1$ 的区别。
18. 为一个含调参步骤的估计器设计诚实重复实验，列出真值泄漏、矩不存在与数值下溢三种失效。

完整实验和逐题答案见独立文件。下一讲进入一元线性回归，从同一个平方误差目标推导可学习直线；这里建立的估计与预测误差区分将继续使用。

来源与核查范围

- [MIT 18.650参数推断](#)：核对估计量、偏差与二次风险定义。本讲的八样本枚举与收缩例子独立构造。
- [Berkeley 参数估计说明](#)：核对偏差、标准误与MSE的对象区别；本讲明确限定自己的iid设计，不套用其不放回公式。
- [MIT 18.655无偏估计与风险不等式](#)：核对支持不随参数、可交换求导、分数函数和Cauchy–Schwarz下界条件；本讲仅推标量版本。
- [NIST稳健位置估计](#)：核对抗极端值与效率权衡的区分；不使用其中数据或实现biweight。
- [NumPy中位数与NumPy正态生成器](#)：核对轴、奇偶样本约定与标准差参数；正文理论不由软件命名替代。