

第028讲 练习详解

以下解答对应正文第21节的12题。所有精确等式按实数或有理数运算理解；计算机实现使用有限精度时需注明容差。主例为 $x = (0, 1, 2, 3, 4)$ 、 $y = (1, 2, 2, 4, 6)$ ，输入单位 N、输出单位 V。

1 两次配平方与唯一性

先令 $u_i = x_i - \bar{x}$ 、 $v_i = y_i - \bar{y}$ 、 $c = a + b\bar{x} - \bar{y}$ 。残差为 $v_i - bu_i - c$ ，故

$$\begin{aligned}\sum_i e_i^2 &= \sum_i (v_i - bu_i)^2 - 2c \sum_i (v_i - bu_i) + nc^2 \\ &= S_{yy} - 2bS_{xy} + b^2S_{xx} + nc^2.\end{aligned}$$

中心化使交叉项中的和为零。固定 b 后， $n > 0$ 保证 nc^2 唯一在 $c = 0$ 处最小，于是 $a = \bar{y} - b\bar{x}$ 。

如果 $S_{xx} > 0$ ，斜率部分等于

$$S_{xx}(b - S_{xy}/S_{xx})^2 + S_{yy} - S_{xy}^2/S_{xx}.$$

两个非负平方项给出全局下界，且可以同时达到。严格正系数分别是 n 与 S_{xx} 。后者要求至少存在两个不同横坐标。只要如此，必须 $b = S_{xy}/S_{xx}$ 且 $a = \bar{y} - b\bar{x}$ ，参数唯一。若 $S_{xx} = 0$ ，不能除以它，必须转到第3题的参数族。

这个证明没有利用误差分布，也没有假定数据真由直线产生。数据可以来自二次函数，结论仍然是“所有候选直线中哪条平方误差最小”。

2 手算主例与损失差

$\bar{x} = 10/5 = 2$ ， $\bar{y} = 15/5 = 3$ 。中心化输入为 $(-2, -1, 0, 1, 2)$ ，中心化输出为 $(-2, -1, -1, 1, 3)$ 。因此

$$S_{xx} = 4 + 1 + 0 + 1 + 4 = 10, \quad S_{xy} = 4 + 1 + 0 + 1 + 6 = 12.$$

斜率为 $6/5$ V/N，截距为 $3 - 12/5 = 3/5$ V。预测为 $(3, 9, 15, 21, 27)/5$ V，残差为 $(2, 1, -5, -1, 3)/5$ V。SSE 为 $(4 + 1 + 25 + 1 + 9)/25 = 8/5$ V²；MSE 为 $(8/5)/5 = 8/25$ V²。

对候选 $(a, b) = (0, 6/5)$ ，斜率偏移为零，均值点偏移为 $0 + (6/5)2 - 3 = -3/5$ 。因此多出的损失是 $5(3/5)^2 = 9/5$ V²，总 SSE 为 $17/5$ V²。也可逐行重算残差 $(1, 4/5, -2/5, 2/5, 6/5)$ ，其平方和同为 $17/5$ 。

对另一候选 $a = 1, b = 1$ ，均值点偏移为0，斜率偏移为 $-1/5$ ，多出 $10(1/5)^2 = 2/5$ ，所以 SSE 为 2。这也解释了为什么比较 MSE 不会改掉候选排序：所有值都除以同一个正数5。

3 常数横坐标的全部解

输入都为2时，任意候选直线在三个训练点的预测都等于 $t = a + 2b$ 。输出均值为 $7/3$ ，因此最优条件是

$$a + 2b = 7/3, \quad a = 7/3 - 2b, \quad b \in \mathbb{R}.$$

最小 SSE 为

$$(1 - 7/3)^2 + (2 - 7/3)^2 + (4 - 7/3)^2 = 16/9 + 1/9 + 25/9 = 14/3.$$

参数 $(-5/3, 2)$ 、 $(7/3, 0)$ 、 $(13/3, -1)$ 都满足最优条件。对新输入3，预测为 $a + 3b = 7/3 + b$ ，随 b 任意变化，所以无法从这些训练数据得到唯一预测。

代码选择零斜率作为代表是输出约定，不是数据证明零斜率。即使三个输出恰好相同、训练 SSE 为零，也不会让 x 的影响变得可辨识。

4 强制过原点后的新答案

模型改为 $\hat{y}_i = bx_i$ ，目标为

$$Q_0(b) = \sum_i y_i^2 - 2b \sum_i x_i y_i + b^2 \sum_i x_i^2.$$

本例 $\sum_i x_i y_i = 0 + 2 + 4 + 12 + 24 = 42$ ， $\sum_i x_i^2 = 30$ ，所以 $b_0 = 42/30 = 7/5$ 。残差为

$$(1, 3/5, -4/5, -1/5, 2/5).$$

残差和为 $1 - V$ ，不为零；但 $\sum_i x_i e_i = 0$ 仍成立，这是唯一斜率方向的正规方程。SSE 为 $1 + 9/25 + 16/25 + 1/25 + 4/25 = 11/5 V^2$ ，比自由截距模型的 $8/5$ 多 $3/5$ 。

注意第2题固定斜率为 $6/5$ 且截距为0的 SSE 是 $17/5$ ；本题允许斜率重新优化，因此降至 $11/5$ 。两者不能混淆。限制模型后，剩余参数仍需要重新拟合。

5 正交与平方和分解

令 $z_i = \hat{y}_i - \bar{y} = b^*(x_i - \bar{x})$ 。因为 $y_i - \bar{y} = z_i + e_i$ ，展开得

$$S_{yy} = \sum_i z_i^2 + 2 \sum_i z_i e_i + \sum_i e_i^2.$$

中间的交叉和为 $b^* \sum_i (x_i - \bar{x}) e_i = 0$ ，故分解成立。主例的 $z_i = (-12, -6, 0, 6, 12)/5$ ，其平方和为 $(144 + 36 + 0 + 36 + 144)/25 = 72/5$ ；加上残差平方和 $8/5$ 正好为16。

训练 $R^2 = 1 - (8/5)/16 = 9/10$ 。若 y 全相同，则 $S_{yy} = 0$ ，自由截距模型可得到 $SSE=0$ ，但 $1 - 0/0$ 没有定义。不能从“零残差”推出普通公式下 $R^2 = 1$ ；若软件返回1，那是额外约定，必须清楚区分。

残差正交并不是统计独立。特别是高斯模型拟合后，残差向量受到两条线性约束，其分量通常相关；与未知真实误差项的 iid 假设并不矛盾。

6 高斯似然与方差边界

在固定 x 、独立同分布 $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ 且 $\sigma > 0$ 的模型下，密度乘积为

$$L(a, b, \sigma) = (2\pi\sigma^2)^{-n/2} \exp[-SSE(a, b)/(2\sigma^2)].$$

对数似然为 $-n \log(2\pi)/2 - n \log \sigma - SSE/(2\sigma^2)$ 。若 σ 已知，它的前两项与参数无关，故最大似然与最小平方和等价。因为输入不是全相同， a 、 b 唯一；若设计退化，最大化参数也是一个族。

若方差 v 未知且最小 SSE 为 $R > 0$ ，固定 v 时仍先最小化 SSE 。随后对 $g(v) = n \log v/2 + R/(2v)$ 求导：

$$g'(v) = \frac{nv - R}{2v^2}.$$

分母正，导数在 $v < R/n$ 为负，在 $v > R/n$ 为正，因此唯一最优方差为 R/n 。如果采用不用微分的验证，令 $t = v/(R/n)$ ，再令 $z = 1/t$ ，目标差为 $n(z - 1 - \log z)/2$ 。利用对所有 $z > 0$ 成立的 $\log z \leq z - 1$ ，可得非负且仅在 $z = 1$ 相等。

本例方差 MLE 是 $8/25 V^2$ 。 $R/(n - 2) = 8/15 V^2$ 是另一个估计量；它的无偏性来自损失两个拟合自由度的期望关系，不能把 n 与 $n-2$ 视为四舍五入差异。

如果 $R = 0$ ， $g(v) = n \log v/2$ 随 $v \downarrow 0$ 趋向负无穷，似然无界。因此在正方差正态族内部没有最大值。程序返回 null 与边界标签最能忠实表达这件事；返回0并继续除以方差，会制造新的数值错误。完美直线场景 $y = 1 + 2x$ 演示的正是这个例外。

7 仿射单位变换

从 $x' = 60x + 10$ 得 $x = (x' - 10)/60$ 。把原拟合 $y = 3/5 + (6/5)x$ 代入 $y' = 1000y + 100$ ：

$$\begin{aligned} y' &= 600 + 100 + 1200 \frac{x' - 10}{60} \\ &= 500 + 20x'. \end{aligned}$$

因此 $a' = 500, b' = 20$ 。输出残差扩大1000倍， SSE 扩大 10^6 倍，变成 1.6×10^6 个新输出单位的平方。输入平移的10必须进入截距；若误写 $a' = 700$ ，便忘记了代回 x 时的偏移。

原均值点 $(2, 3)$ 对应 $(130, 3100)$ ，新直线在130处预测 $500 + 20 \times 130 = 3100$ ，是一个简短的检查。变回原单位后，每个样本的预测完全对应。此时输出单位改变可理解为带零点偏移的标度，不能把新数值直接与原 V 数值比较。

8 曲线残差为何仍满足正交

对 $x = -3, -2, -1, 0, 1, 2, 3$, $\bar{x} = 0$, $\sum x_i^2 = 28$ 。因为奇数幂在对称输入上抵消， $\sum x_i = \sum x_i^3 = 0$ 。输出 $y_i = 1 + x_i + x_i^2/2$ 的均值为 $1 + (28/7)/2 = 3$ ，交叉和为

$$S_{xy} = \sum_i x_i(y_i - 3) = \sum_i (-2x_i + x_i^2 + x_i^3/2) = 28.$$

故最优直线为 $3 + x$ 。残差 $x_i^2/2 - 2$ 依次为 $(2.5, 0, -1.5, -2, -1.5, 0, 2.5)$ ，总和为0；乘以 x 后成为奇函数，在对称位置也抵消。SSE 为 $2 \times (2.5)^2 + 2 \times (1.5)^2 + (-2)^2 = 21$ 。

这里所有残差都是被遗漏的二次项造成的确定结构，不是独立随机噪声。正交只限制两个内积，远远不能规定一整个残差数列没有模式。这是“最优化成功”与“模型足够好”不同的具体证据。

9 远端点的参数与杠杆

新增 $(20, 0)$ 后， $n = 6$, $\sum x_i = 30$ 、 $\sum y_i = 15$ ，所以 $\bar{x} = 5$ 、 $\bar{y} = 5/2$ 。原始平方和 $\sum x_i^2 = 430$ 、交叉乘积和 $\sum x_i y_i = 42$ ，故

$$S_{xx} = 430 - 6 \times 25 = 280, \quad S_{xy} = 42 - 6 \times 5 \times \frac{5}{2} = -33.$$

因此 $b = -33/280$, $a = 5/2 + 165/280 = 173/56$ 。远端点预测为

$$173/56 - 20 \times 33/280 = 41/56,$$

所以残差为 $-41/56$ 。它的杠杆为

$$h = \frac{1}{6} + \frac{(20 - 5)^2}{280} = \frac{1}{6} + \frac{45}{56} = \frac{163}{168}.$$

完整新 SSE 为 $5491/280 \approx 19.6107$ 。注意新增样本后的 SSE 与原 SSE 不在相同行数上，但斜率符号改变已经清楚说明敏感性。远端点的残差小于 $x=4$ 那个点的残差，因为拟合已经向远端点靠拢。

删点需要额外证据，例如确认录入错误、单位错置或不属于目标总体。高杠杆只依赖 x ，不等同于错误；比较删除前后参数是敏感性分析，不是自动清洗许可。

10 预测权重与未被覆盖的风险

由 $b^* = \sum_i (x_i - \bar{x})Y_i / S_{xx}$ 和 $\hat{\mu}(x_0) = \bar{Y} + b^*(x_0 - \bar{x})$ ，可得

$$w_i = \frac{1}{n} + \frac{(x_0 - \bar{x})(x_i - \bar{x})}{S_{xx}}, \quad \hat{\mu}(x_0) = \sum_i w_i Y_i.$$

中心化和为0, 所以 $\sum_i w_i = 1$ 。平方求和后, 一次交叉项为0, 二次项用 S_{xx} 抵消一个分母:

$$\sum_i w_i^2 = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}.$$

在独立同方差且固定设计的条件下, 线性组合方差为 $\sigma^2 \sum_i w_i^2$ 。预测一个独立的新 Y 时, 估计均值的随机误差与新噪声独立, 因此预测误差方差再加 σ^2 。

本例 $\sigma = 1$ 。 $x_0 = 2.5$ 时均值标准误为 $\sqrt{1/5 + (1/2)^2/10} = \sqrt{9/40} \approx 0.47434$ V; 新观测预测标准差为 $\sqrt{49/40} \approx 1.1068$ V。 $x_0 = 6$ 时分别为 $\sqrt{9/5} \approx 1.34164$ V 与 $\sqrt{14/5} \approx 1.67332$ V。

这些公式没有包括“真实均值在 $x > 4$ 后开始饱和”之类的模型偏差。两个函数只要在训练区间相同、区间外不同, 就能产生相同训练证据而给出不同外推。故不能将模型内标准误当成所有风险的总量。

11 关联与因果的反例

令隐藏变量 Z 非退化, 自然生成 $X = Z, Y = 2Z$ 。观测上严格有 $Y = 2X$, 带截距 OLS 会得到截距 0、斜率 2 和零残差。现在明确干预机制: 外部改变 X 的值, 但保留 $Y = 2Z$ 这条生成方程不变。由于 Y 方程没有 X , 改变 X 不会改变 Y 。

这个例子说明, 观测关系不能独自确定干预关系。另一个机制 $Y = 2X$ 对观测数据可能给出同样直线, 却对干预作出不同预测。需要设计、领域知识或额外识别假设, 才能在两者之间作判断。

如果现实里 X 确实被随机操纵, 回归有可能参与估计因果效应; 但这依赖实验设计, 而不是最小二乘公式自动创造的性质。因此本题也不能反向误读成“回归永远不能用于因果分析”。

12 程序反例与文件完整性

第一组检查原始类型。给 `fit_line` 的最后一个 `x` 写入 `False`, 必须在 `float` 转换前拒绝, 否则布尔值会变成 0, 数据被悄悄改变。还应检查包含 `bool` 的列表、`bool` 数组、对象数组、复数、NaN、Infinity、Decimal、Fraction、扩展浮点与二维数组。

第二组检查词元。JSON 的 `1e-400` 与 CSV 的 `1e-400` 都是非零十进制数, 但直接 `float` 后会得到 0。应先读取原始词元, 用 `Decimal` 检查有限性和非零范围, 再转换; 真正的 `0e-400` 应被接受。重复 JSON 键、非标准 NaN/Infinity、额外字段与末行坏数据都应显式拒绝。

第三组检查小均值。输入 `[-1, 1, 10-100]`, 独立高精度核算的均值为 `10-100/3`。直接对原值用 `math.fsum` 可以保留它; 先减去 -1 再恢复的实现可能返回 0。检验时绝对容差不能随意设为 `10-12`, 否则 0 与正确小值都会被认为“相同”。此测试应使用相对容差或与已计算的浮点基准精确比较。

相邻浮点数还要核对完整诊断，而不只检查斜率。对 $x=[1, \text{nextafter}(1,2)]$ 、 $y=[0, x[1]-1]$ ，应得到 $\text{SSE}=0$ 、 $R^2=1$ 、杠杆 $[1,1]$ ； $\text{sigma}=1$ 时两个训练点的均值标准误都为1。仅修正中心化平方和却保留未修正偏差会破坏这些结果，必须统一均值余项、中心化偏差与预测口径。

第四组检查退化解释。常数 x 且非恒定 y 必须返回参数非唯一；精确完美直线必须返回未知正方差似然没有有限最大值。计算得到零 SSE 不能无条件充当完美拟合证书，应避免乘积或平方下溢，并对存储数值的共线性另行核验。

第五组检查副作用时序。在临时目录先写入固定字节的旧报告，再故意损坏没有被选中的 CSV 最后一行。调用应失败，旧报告逐字节不变。把局部随机生成器替换成一调用就报错的桩，确认坏输入在创建它之前被拒绝。对所有候选参数、所有预测点和所有配置字段也作末项破坏测试。

这些检查需在正常解释器和 `python -O` 下都成立。`assert` 适合开发期诊断，但会被优化模式去掉，不能作为本实验外部输入的唯一门槛。通过一组有限测试也不能证明程序支持任意尺度；README 中保守的数值合同仍然有效。