

第028讲 一元线性回归的完整推导

给定一些横坐标和纵坐标，怎样选出一条直线，使它对这些点的预测尽量准确？本讲把这件事从头做完：先定义预测与误差，再只用代数证明全局最优解，随后用五个点手算核验。最后才加入概率模型，解释在什么条件下同一条直线也是最大似然估计，并检查图、单位与外推能暴露哪些错误。

本讲的结论是有条件的。对有限的实数数据、包含截距的直线和未加权平方误差，只要横坐标不全相同，最优斜率等于中心化交叉和除以中心化平方和，截距让直线通过样本均值点。这是一个确定性的优化结论，不需要正态噪声，也不意味着这条直线能预测任何新环境，更不意味着横坐标的改变会导致纵坐标改变。

1 学习路线与先修

直接先修为第008讲函数代数与数学表达、第013讲导数与梯度。主推导只使用求和、展开、配平方和非负性；导数提供第二条交叉检查路线，不作为第一条路线的捷径。学过第023讲最大似然后，再读第11至13节的概率解释。第009讲的内积概念有助于理解正交，但这里会把所需等式直接写出。

建议按三个问题阅读。第一，什么量被最小化，参数的取值范围是什么？第二，为什么写出的参数确实是全局唯一最优，而非仅使某个导数为零？第三，数学上成功拟合之后，什么仍然不知道？能完整回答这些问题，才算掌握一元线性回归，而非只记住两个公式。

读完后应能独立完成五件事：从平方和推出截距和斜率；准确说明常数横坐标的例外；手算残差与平方和；把高斯似然的假设逐项写清；在残差图和预测说明中明确单位、训练范围与因果边界。独立实验在 lab.pdf，练习的全部推导在 answers.pdf。

2 一行数据与一个预测规则

令数据为有索引的样本对 (x_i, y_i) ，其中 $i = 1, \dots, n$ ， $n \geq 1$ 。本讲先把所有观测值看成已经给定的有限实数。重复横坐标允许存在；重复记录是否该保留则是数据生成问题，不能靠本讲的公式决定。

用带截距的规则预测纵坐标：

$$\hat{y}_i = f_{a,b}(x_i) = a + bx_i, \quad (a, b) \in \mathbb{R}^2.$$

a 是截距， b 是斜率。带帽的 $\hat{y}_i$ 表示预测值，不是第二次观测。这里的“线性”通常指对参数线性；作为从 x 到 y 的映射， $a \neq 0$ 时严格说是仿射函数。本讲只研究一个原始解释变量的一条直线，不将多项式、多特征或非线性参数模型混在一起。[NIST 对线性最小二乘的定义](#)也强调参数线性这一含义。

为了让单位始终可见，把后面的五个点想象成完全合成的传感器标定示例： x 为施加的载荷，单位 N； y 为读数，单位 V。它们不来自真实仪器，也没有计量认证含义。如果 x 用 N， y 用 V，那么 a 的单位为 V， b 的单位为 V/N，乘积 bx 才能与 a 相加。截距描述 $x = 0$ 的拟合读数；若 0 不在观测范围内，截距的物理解释本身也是外推。

符号	含义	单位
$x_i, \bar{x}$	输入与输入均值	N
$y_i, \bar{y}, \hat{y}_i$	观测、均值、预测	V
e_i	观测减预测的残差	V
S_{xx}	输入的中心化平方和	N ²
S_{xy}	输入与输出的中心化交叉和	N·V
S_{yy}	输出的中心化平方和	V ²
SSE, MSE	残差平方和、均方误差	V ²

3 为什么使用竖直残差与平方和

任意候选直线的残差定义为

$$e_i(a, b) = y_i - a - bx_i.$$

正残差表示观测在直线上方，负残差表示在下方。残差不是点到直线的垂直几何距离，而是固定输入处的纵向差。这样定义，对应“输入已知，用它预测输出”的任务。若横坐标也有不可忽略的测量误差，纵向平方损失可能不符合科学问题，需要另建误差变量模型。

把残差直接相加会让正负抵消，甚至让很差的直线看起来很好。因此定义残差平方和和均方误差：

$$\text{SSE}(a, b) = \sum_{i=1}^n e_i(a, b)^2, \quad \text{MSE}(a, b) = \frac{1}{n} \text{SSE}(a, b).$$

平方既去掉符号，又对大残差施加更大代价：残差扩大到两倍，其平方扩大到四倍。这是一项损失选择，不是自然界强制规定的唯一标准。绝对误差、加权平方误差有各自用途，但一般不会给出本讲同一套闭式解。

因为 $n > 0$ 且对所有候选参数相同，比较两条直线的 SSE 与比较它们的 MSE 得到完全相同的大小关系。因此二者最小化解相同；使用 $\text{SSE}/(2n)$ 也一样。常数因子会影响梯度的数值和某些迭代步长，却不会改变这里的最优位置。这个结论不能推广为“随便给每一行乘不同权重也不改变结果”。




图1 五个合成点的纵向残差。蓝线为最优直线，橙色竖线连接每个观测及其预测；右图保留正负方向。残差平方和最小不要求每个残差都为零。

4 把数据围绕均值重新表达

定义均值以及中心化变量：

$$\bar{x} = \frac{1}{n} \sum_i x_i, \quad \bar{y} = \frac{1}{n} \sum_i y_i, \quad u_i = x_i - \bar{x}, \quad v_i = y_i - \bar{y}.$$

从均值的定义直接得到 $\sum_i u_i = 0$ 与 $\sum_i v_i = 0$ 。再定义三个不除以 n 的和：

$$S_{xx} = \sum_i u_i^2, \quad S_{xy} = \sum_i u_i v_i, \quad S_{yy} = \sum_i v_i^2.$$

这些量不是新的观测，而是把所有数据压缩成对拟合有用的几个数。 $S_{xx} \geq 0$ ，并且等于零当且仅当所有 x_i 相同。 S_{xy} 可以为正、为负或为零；它记录两个中心化变量是否趋向同号。若用相同分母定义样本协方差与样本方差，它们的比值仍为 S_{xy}/S_{xx} ，但本讲直接使用和，避免在 $n = 1$ 时误用 $n - 1$ 。

为了把截距与斜率分开，引入

$$c = a + b\bar{x} - \bar{y}.$$

c 是候选直线在 $x = \bar{x}$ 处相对 $\bar{y}$ 的竖直偏移。由 $x_i = \bar{x} + u_i$ 与 $y_i = \bar{y} + v_i$ ，残差可重写为 $v_i - bu_i - c$ 。这个改写没有近似，也没有新增分布假设。

5 先消去截距

展开平方，并明确交叉项为什么消失：

$$\begin{aligned} \text{SSE}(a, b) &= \sum_i (v_i - bu_i - c)^2 \\ &= \sum_i (v_i - bu_i)^2 - 2c \sum_i (v_i - bu_i) + nc^2 \\ &= \sum_i (v_i - bu_i)^2 + nc^2. \end{aligned}$$

最后一步使用 $\sum_i v_i - b \sum_i u_i = 0$ 。此时把 b 固定，第一项不随 a 变化；第二项非负且仅在 $c = 0$ 时达到零。由于 $n > 0$ ，对应的截距唯一：

$$a(b) = \bar{y} - b\bar{x}.$$

因此，对于每一个斜率，最好的截距都会让直线经过 $(\bar{x}, \bar{y})$ 。这不是画图经验，而是非负平方项给出的证明。也不能倒过来说“所有经过均值点的直线都同样好”：它们只是各自斜率下的最佳竖直位置，斜率还要继续优化。




图2 同一斜率的直线竖直移动时，SSE 多出 n 倍的中心偏移平方。先把 c 调到零，再沿右图寻找最佳斜率；图中的损失数值来自五点手算数据。

6 再对斜率配平方

把最佳截距代回去，目标只剩一个未知量：

$$Q(b) = \sum_i (v_i - bu_i)^2 = S_{yy} - 2bS_{xy} + b^2S_{xx}.$$

先处理 $S_{xx} > 0$ 。提取二次项系数，再配平方：

$$\begin{aligned} Q(b) &= S_{xx} \left(b^2 - 2b \frac{S_{xy}}{S_{xx}} \right) + S_{yy} \\ &= S_{xx} \left(b - \frac{S_{xy}}{S_{xx}} \right)^2 + S_{yy} - \frac{S_{xy}^2}{S_{xx}}. \end{aligned}$$

第一项非负，且因为系数严格为正，仅在括号为零时取最小。于是

$$b^* = \frac{S_{xy}}{S_{xx}}, \quad a^* = \bar{y} - b^*\bar{x}.$$

把两次配平方合并，得到对任意实数 a, b 成立的全局恒等式：

$$\text{SSE}(a, b) = \text{SSE}_{\min} + n(a + b\bar{x} - \bar{y})^2 + S_{xx}(b - b^*)^2,$$

$$\text{SSE}_{\min} = S_{yy} - \frac{S_{xy}^2}{S_{xx}}.$$

这条恒等式同时证明三件事：候选解能达到最小值；不存在更低的局部盆地；在 $S_{xx} > 0$ 时，两个新增平方项必须同时为零，因此参数唯一。最小值非负也随之成立，因为它等于真实残差的平方和。实践中直接用最后一个差值计算最小 SSE 可能出现消减误差，代码会从残差重新平方求和。

“完整推导”的重要部分就在这几个量词：对所有候选参数成立；输入不全相同时唯一；输入全相同的情况必须另行讨论。只写“令导数为零，得公式”并没有交代这些条件。

7 横坐标全相同与无截距模型

若每个 $x_i = c_0$ ，则 $S_{xx} = 0$ 且 $S_{xy} = 0$ 。此时所有预测都等于同一个数 $t = a + bc_0$ 。目标变成

$$\sum_i (y_i - t)^2 = S_{yy} + n(t - \bar{y})^2.$$

因此全部最优参数为

$$\{(a, b) : a + bc_0 = \bar{y}\}.$$

训练点上的最优预测是唯一的 $\bar{y}$ ，参数却不唯一。不能把 $0/0$ 设为零并声称得到唯一斜率。程序返回 $b = 0, a = \bar{y}$ 只是一种明确标注的代表，并设置 `unique_parameters` 为 `false`。若新输入不等于 c_0 ，这族直线会给出不同预测，数据无法选择哪条才正确。




图3 三个点都位于 $x=2$ 时，无数条经过均值点的直线有相同训练损失。右图显示它们在其他横坐标处迅速分开；这种差异来自不可辨识性，不是计算器精度问题。

另一个不同问题是主动去掉截距、强制预测为 bx 。展开目标可得，当 $\sum_i x_i^2 > 0$ 时，最优斜率为 $\sum_i x_i y_i / \sum_i x_i^2$ 。这里没有中心化，也不保证残差和为零。它只有在科学问题确实要求经过原点时才合理，不能因为“少一个参数更简单”就悄悄改掉本讲的模型。

8 用导数复核而不代替证明

第013讲提供另一条检查路线。对 SSE 分别求偏导：

$$\frac{\partial \text{SSE}}{\partial a} = -2 \sum_i (y_i - a - bx_i), \quad \frac{\partial \text{SSE}}{\partial b} = -2 \sum_i x_i (y_i - a - bx_i).$$

驻点满足两条正规方程：

$$na + b \sum_i x_i = \sum_i y_i, \quad a \sum_i x_i + b \sum_i x_i^2 = \sum_i x_i y_i.$$

第一式给出 $a = \bar{y} - b\bar{x}$ ，代入第二式便得到 $bS_{xx} = S_{xy}$ 。这与代数路线一致。对任意参数扰动 $(\Delta a, \Delta b)$ ，二次项为 $\sum_i (\Delta a + \Delta b x_i)^2$ ；当至少两个不同横坐标存在时，只有零扰动才能使其为零。因此曲面严格凸。没有这个设计条件，凸性仍在，严格性却消失。

导数也给出两个核验信号：拟合残差满足 $\sum_i e_i^* = 0$ 与 $\sum_i x_i e_i^* = 0$ 。计算机结果通常只在浮点容差内满足，而不是每位小数恰好为零。接下来用有理数手算，先建立无需容差的答案。

9 五个点的完整手算

数据为 $(0, 1), (1, 2), (2, 2), (3, 4), (4, 6)$ 。先计算 $\sum_i x_i = 10$ 、 $\sum_i y_i = 15$ ，所以 $\bar{x} = 2 \text{ N}$ ， $\bar{y} = 3 \text{ V}$ 。

i	x_i	y_i	u_i	v_i	u_i^2	$u_i v_i$
1	0	1	-2	-2	4	4
2	1	2	-1	-1	1	1
3	2	2	0	-1	0	0
4	3	4	1	1	1	1
5	4	6	2	3	4	6
和	10	15	0	0	10	12

因此 $S_{xx} = 10 \text{ N}^2$ ， $S_{xy} = 12 \text{ N} \cdot \text{V}$ ， $S_{yy} = 4 + 1 + 1 + 1 + 9 = 16 \text{ V}^2$ 。最优参数为

$$b^* = \frac{6}{5} \text{ V/N}, \quad a^* = 3 - \frac{6}{5} \cdot 2 = \frac{3}{5} \text{ V}.$$

不要在这一步就停下。逐行代入，计算预测与残差，才能检查公式、索引和符号是否一起正确。

x_i	y_i	$\hat{y}_i = (3 + 6x_i)/5$	$e_i^* = y_i - \hat{y}_i$	$(e_i^*)^2$
0	1	3/5	2/5	4/25
1	2	9/5	1/5	1/25
2	2	15/5	-1	1
3	4	21/5	-1/5	1/25
4	6	27/5	3/5	9/25

平方和为 $40/25 = 8/5$ V^2 , MSE 为 $8/25$ V^2 。两条约束也能手算：残差和为 $(2 + 1 - 5 - 1 + 3)/5 = 0$; $\sum_i x_i e_i^* = (0 + 1 - 10 - 3 + 12)/5 = 0$ 。最小值公式给出 $16 - 144/10 = 8/5$, 是第三条独立核验。

候选直线 $1 + x$ 的 SSE 为 2, 比最优直线多 $2/5$; 常数预测 3 的 SSE 为 16; 保持最优斜率但把截距改成 0, SSE 为 $17/5$ 。最后一个差值为 $9/5 = 5(3/5)^2$, 正好是截距偏移项。这个例子同时检查了截距、斜率和平方和的缩放。

10 残差正交与平方和分解

最优残差可写为 $e_i^* = v_i - b^* u_i$ 。利用中心化和斜率定义：

$$\sum_i e_i^* = 0, \quad \sum_i u_i e_i^* = S_{xy} - b^* S_{xx} = 0.$$

“正交”在这里就是两个数列的逐项乘积之和为零。它不意味着每一个乘积都为零, 也不意味着残差与输入统计独立。由 $x_i = u_i + \bar{x}$, 还可推出 $\sum_i x_i e_i^* = 0$ 。

将 $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i^*$ 平方后求和, 中间项消失, 因为 $\hat{y}_i - \bar{y} = b^* u_i$ 。于是

$$S_{yy} = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i (e_i^*)^2 = (b^*)^2 S_{xx} + \text{SSE}_{\min}.$$

在手算例中, 这正是 $16 = 72/5 + 8/5$ 。三项都用 V^2 计量, 因此可以相加。图4显示总变动被分成拟合部分与残差部分; 它是带截距的训练集代数分解, 不是因果机制的分解。




图4 带截距时的平方和分解。五点例子的总平方和为16, 拟合部分为14.4, 残差部分为1.6。右侧列出交叉项逐点正负抵消, 解释为什么可以相加。

若 $S_{yy} > 0$, 训练集 $R^2 = 1 - \text{SSE}_{\min}/S_{yy}$, 本例为 0.9。若所有 y_i 相同, 分母为零, 这个定义不成立; 软件有时采用约定值, 必须披露。高 R^2 不保证残差没有结构, 不保证测试集误差小, 也不表示“90% 的变化由载荷因果造成”。去掉截距后, 上面的中心化分解一般不再成立。

11 从固定数据走向概率模型

到这里为止，我们没有假定数据如何产生。现在把已设置的横坐标 $x_1, \dots, x_n$ 视为固定设计，假定重新做实验时输出变化：

$$Y_i = a_0 + b_0 x_i + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2), \quad \sigma > 0.$$

a_0, b_0 是假定存在的真实机制参数； a^*, b^* 是从这次观测计算出来的估计值。噪声 $\varepsilon_i = Y_i - a_0 - b_0 x_i$ 无法直接观测，因为真实参数未知。残差用估计参数计算，因此不能直接当成一组独立噪声：残差和被约束为零，残差之间一般相关。

这个模型包含四件不同的事。均值函数确为直线；每个噪声条件均值为零；噪声相互独立；噪声共享同一个正方差且呈正态分布。最小二乘的代数解不需要这些假设，后面的高斯似然解释却需要明确说明它们。若每个样本有不同已知方差，似然通常对应加权平方误差；若误差有关联，则二次型中会出现协方差结构。

如果横坐标本身来自随机抽样，也可以建立条件模型 $Y_i | X_i = x_i \sim \mathcal{N}(a_0 + b_0 x_i, \sigma^2)$ ，并在观测到的输入上计算条件似然。此时必须说明样本对的独立性及 $E(\varepsilon_i | X_i) = 0$ 等条件，而不能只说“误差总体平均为零”。条件均值要求比无条件均值强。带截距的 OLS 在样本里强制残差和为零，也不能验证这个生成假设。




图5 固定设计的重复实验。每次仍使用相同的五个横坐标，而输出由直线均值加新的独立正态噪声生成。右图是600次小型模拟的斜率分布，仅用于核验已声明的机制。

12 已知正方差时的最大似然

设已经观测到 $y_1, \dots, y_n$ ，并暂时把正的 σ 当作已知。每个观测的条件密度为

$$p(y_i | x_i, a, b, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(y_i - a - bx_i)^2}{2\sigma^2} \right].$$

这里 σ 是标准差、单位为 V ， σ^2 是方差、单位为 V^2 ；归一化因子不能把这两者混淆。指数中的比值没有单位。连续变量在某个精确点的概率为零，似然使用的是密度在观测处的值，不是“这些精确读数出现的概率”。密度以及它的数值会随单位约定改变，但在固定单位下参数的比较有意义。

独立性允许将条件密度相乘。取自然对数：

$$L(a, b; \sigma) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{\text{SSE}(a, b)}{2\sigma^2} \right],$$

$$\ell(a, b; \sigma) = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{\text{SSE}(a, b)}{2\sigma^2}.$$

前两项对 a, b 是常数，最后一项的系数严格为负。因此最大化对数似然，与最小化 SSE 完全等价。当 $S_{xx} > 0$ 时，两者拥有同一个唯一参数解。这个推理是“假定同方差独立高斯模型，推出最小二乘”，不是“我做了最小二乘，所以数据一定高斯”。Stanford CS229 的原始课程讲义提供了高斯误差与平方损失联系的课程来源；这里的标量推导独立展开。




图6 已知 $\sigma=1$ 时，负对数似然只是 SSE 乘以 $1/2$ 再加一个常数。图中每个斜率都采用其最佳截距，二者最低点完全一致。

13 未知方差与完美拟合的边界

若 σ^2 也未知，令 $v = \sigma^2 > 0$ 。对固定 v ，最优直线依然最小化 SSE。记最小 SSE 为 R ，负对数似然中随 v 变化的部分为

$$g(v) = \frac{n}{2} \log v + \frac{R}{2v}.$$

当 $R > 0$ 时， $g'(v) = (nv - R)/(2v^2)$ ，在 $v < R/n$ 时为负，在 $v > R/n$ 时为正；因此存在全局最小值 $\hat{v}_{\text{MLE}} = R/n$ 。也可不用导数：令 $t = v/(R/n) > 0$ ，则目标差为 $\frac{n}{2}(\log t + 1/t - 1)$ ，它仅在 $t = 1$ 时为零，其余为正。

手算数据给出方差 MLE 为 $8/25 V^2$ 。不要把它与经典无偏残差方差估计 $R/(n-2)$ 混为一谈。后者在设计满秩、同方差零均值独立误差、 $n > 2$ 等条件下估计噪声方差，本例为 $8/15 V^2$ ；它使用自由度修正，优化的不是同一个似然准则。MIT 的高斯线性模型课程讲义可用于进一步连接一般线性模型、估计量分布和残差自由度。

关键例外是 $R = 0$ 。此时沿任意完美拟合直线， $L \propto \sigma^{-n}$ ，当 $\sigma \downarrow 0$ 时无界增大。在参数空间 $\sigma > 0$ 内没有有限的最大似然解；不能把 $\hat{\sigma}^2 = 0$ 当作这个正方差正态密度族内部合法的 MLE。若允许退化点质量分布，那已改变了模型和密度参考测度。




图7 未知方差的负对数似然剖面。SSE>0时有正的内点最优方差；SSE=0时向更小正方差移动可持续降低负对数似然。横轴为对数刻度，左端不是合法的 $\sigma=0$ 点。

本讲代码额外检查所存二进制数值是否精确共线，以免把四舍五入得到的零 SSE 当作数学证据。对于精确共线的数据，`variance_mle` 留为空并给出边界状态。拟合参数和计算残差仍为浮点近似，数值 SSE 可能留下舍入痕迹；精确共线证书说明的是这些已存数值的数学最小 SSE，不是原始测量毫无噪声。

14 改单位时哪些数应当改变

设输入输出重新表达为 $x' = px + q$ 、 $y' = ry + s$ ，其中 $p \neq 0, r \neq 0$ 。把 $x = (x' - q)/p$ 代入拟合规则，可得

$$y' = \left(ra + s - \frac{rbq}{p} \right) + \frac{rb}{p} x'.$$

因此 $b' = rb/p$ ， $a' = ra + s - rbq/p$ 。中心化输入满足 $u'_i = pu_i$ ，输出满足 $v'_i = rv_i$ ；所以 $S'_{xx} = p^2 S_{xx}$ 、 $S'_{xy} = pr S_{xy}$ ，与同一结论一致。残差变成 $e'_i = re_i$ ，SSE 和 MSE 乘以 r^2 。对于非恒定输出， R^2 不变。单独平移输入会改变截距，不会改变预测对应关系。

例如把 N 改成 mN，取 $p = 1000, q = 0$ ，斜率从 1.2 V/N 变为 0.0012 V/mN。把 V 改成 mV，取 $r = 1000$ ，截距变为 600 mV，SSE 变为 $1.6 \times 10^6 \text{ mV}^2$ 。原始数值突然变大并不表示拟合变差，比较误差必须先统一单位。




图8 同一物理对应关系用不同单位表达。点与线的关系保持一致，轴刻度和参数数值发生确定变换。比较模型时应报告单位，不能只比较斜率数字的大小。

这些是仿射变换的结论。把输出取对数、裁剪负值或标准化时使用不同训练范围，都可能改变误差含义；不应把所有预处理都叫作“只换单位”。尤其先拟合对数输出再指数还原，并不自动给出原输出尺度的条件均值。

15 残差图必须回答模型是否遗漏结构

闭式解保证你找到指定目标的最小值，却不保证目标背后的模型足够好。考虑另一个完全合成的数据集： $x = -3, -2, \dots, 3$, $y = 1 + x + x^2/2$ 。它没有随机噪声，生成规则故意弯曲。因为横坐标对称， $\bar{x} = 0$ ；输出均值为 3， $S_{xx} = 28$ 、 $S_{xy} = 28$ ，所以最佳直线为 $3 + x$ 。

残差依次为 2.5, 0, -1.5, -2, -1.5, 0, 2.5。它们和为零，与横坐标的内积也为零，但图9中的 U 形非常明显。训练 SSE 为 21。两个正交条件只是拟合算法完成其工作后的约束，并不能排除二次结构。若只打印最优参数和一项损失，就会错过这个可修正的模型缺陷。




图9 直线拟合一个已知二次机制。左右两端为正残差、中间为负残差，构成系统形状。正交条件成立仍不表示残差随机，更不证明真实关系线性。

实际分析至少应结合原始散点图、残差对输入或预测值的图、按采集顺序排列的残差图。弯曲形状提示均值函数可能不足；张开的扇形提示条件变异可能不同；时间段整片偏移提示漂移或遗漏批次因素。这些是调查线索，不是仅凭图就确认的原因。五个点的图也无力证明正态或独立。[NIST 的模型核验章节](#)明确强调，单个拟合优度数值不能替代残差诊断。

发现结构后，应返回任务和采样过程，提出可验证的修订，再用未参与选择的数据检查。不能在测试集上轮流加项、删点，直到图看起来漂亮，再报告它为独立验证。

16 高杠杆点与影响不能只看残差大小

向五点数据增加一行 (20, 0)，横坐标远离原来的 $[0, 4]$ 。重新计算得到

$$a^* = \frac{173}{56} \approx 3.08929, \quad b^* = -\frac{33}{280} \approx -0.117857.$$

仅增加这一行，斜率从正变负。新点的残差为 $-41/56 \approx -0.732$ ，反而不如 $x = 4$ 那个点的残差 $947/280 \approx 3.382$ 大。原因是这条直线已经为远端点作了很大转动。不能只检查“拟合以后谁的残差最大”，就认定谁最影响参数。

固定输入时，把 y_j 改变 Δ ，由 $S_{xy} = \sum_i (x_i - \bar{x})y_i$ 可直接得到

$$\Delta b^* = \frac{x_j - \bar{x}}{S_{xx}} \Delta.$$

拟合值在同一个点的改变量为 $h_j \Delta$ ，其中

$$h_j = \frac{1}{n} + \frac{(x_j - \bar{x})^2}{S_{xx}}.$$

h_j 是此模型的杠杆值，度量该点输出改变时自身拟合值的敏感性，完全由输入布局决定。在满秩带截距模型中 $\sum_j h_j = 2$ 。新增远端点的杠杆值为 $163/168 \approx 0.9702$ 。杠杆高表示有影响的潜力；如果它恰好延续原来直线，删除它未必显著改变参数。[NIST 的杠杆说明](#)也区分了高杠杆与实际影响。




图10 增加远端点后最优直线发生明显转动。右图同时画出各点残差与杠杆，显示远端点可以有较小的拟合残差和很高的杠杆。删点前必须核查来源与研究对象。

合理处理是检查录入、仪器范围、单位和样本来源，并把包含与不包含该点的敏感性分析明确报告。若它是真实且属于目标总体的一部分，机械删掉它可能使模型更偏。若它来自另一机制，则问题可能是分组或模型设定，而不是“异常点太讨厌”。

17 外推误差有两种来源

本例观测范围是 $[0, 4]$ N。输入 2.5 N 的拟合读数为 3.6 V，是插值；输入 6 N 的预测为 7.8 V，是外推。代数公式对这两个数都能运算，但数据对二者的支持不同。

在固定设计、正确直线均值、独立同方差噪声的模型下，令 $d = x_0 - \bar{x}$ ，预测均值可以写成观测的加权和：

$$\hat{\mu}(x_0) = \sum_i w_i(x_0) Y_i, \quad w_i(x_0) = \frac{1}{n} + \frac{d(x_i - \bar{x})}{S_{xx}}.$$

权重和为1。利用 $\sum_i (x_i - \bar{x}) = 0$ 展开平方可得 $\sum_i w_i^2 = 1/n + d^2/S_{xx}$ ，所以

$$\text{Var}(\hat{\mu}(x_0) | x) = \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right).$$

如果预测的是独立的新观测，还需加上新噪声的方差 σ^2 。这区分了均值估计不确定性与单次观测的预测不确定性。已知 $\sigma = 1 \text{ V}$ 时，本例在 $x_0 = 2.5$ 的均值标准误约0.474 V，在 $x_0 = 6$ 约1.342 V。它们来自明确假设，不是对未知真实世界给出的保证。




图11 左图为假设直线机制始终正确时的均值标准误，离中心越远越大。右图的两种合成机制在训练范围内完全相同，范围外却分开，说明模型内标准误不能覆盖未知机制改变。

第二类风险是模型失配：仪器可能饱和、响应可能转弯、群体可能变换。图11人为构造两个函数，在 $[0, 4]$ 内完全相同、在范围外不同；任何只观察这一区间的数据都无法区分它们。上面的方差公式不包含这种未建模的偏差。外推报告必须同时说明距离训练范围多远、为何有科学理由延伸、需要什么新数据验证，而不能只附上一看似精确的误差带。

18 相关斜率不等于干预效果

即使拟合很精确，斜率也只是当前数据与模型下的关联描述。一个简单反例是隐藏因素 Z 同时影响观测输入和输出：自然状态下 $X = Z$ 、 $Y = 2Z$ 。观察数据会落在 $Y = 2X$ 上，OLS 斜率为2。若实验者单独改变记录中的 X ，而生成 Y 的机制仍只依赖 Z ，那么改变 X 不会让 Y 跟着改变。这两个问题需要不同的信息。

真实传感器标定中，输入可能确实由实验者控制；但能否把结果解释为因果效应，还要依赖操纵方式、混杂控制、测量过程和目标范围。回归计算本身不能补齐这些设计事实。做预测时也不能忽视它们：如果训练中输入只是某个隐藏因素的替代指标，环境变化后这种关联可能消失。

因此合格的表述是“在这批合成数据上，每增加1 N，拟合读数增加1.2 V；该结论描述拟合关系”。不合格的表述是“增加1 N 必然导致增加1.2 V，因此可无条件改变实际系统”。本讲没有真实干预数据，不能对任何实际仪器或人群作这样的承诺。

19 让计算忠实于推导

代码先验证原始标量，再转换为二进制浮点。布尔值、文本、复数、非有限值、对象数组、扩展浮点和外部 Fraction 或 Decimal 不会被偷偷当成普通实数接受。这样做不是否定高精度类型，而是避免超出此教学实现的数值承诺。CSV/JSON 的十进制数字在转换前检查原始词元；例如非零的 $1e-400$ 不能先变成浮点零再混入数据。

均值使用原始数值的 `math.fsum` 求和。为什么不一律先减第一个数作为锚点？对于 $[-1, 1, 10^{-100}]$ ，原始和保留 10^{-100} ，均值约为 3.333×10^{-101} ；若先减去 -1，极小项可能在加1时丢失，最终错误得到零。可靠的程序应保留这个小均值，同时承认浮点数仍会舍入。




图12 一个数值核验反例。原始数值补偿求和保留非零均值，先减锚点再恢复的路径可能丢失它。右图强调程序应拒绝非零数字的静默下溢，真正的零仍然是有效输入。

本讲的小型实现把实际存储的二进制值临时转成精确有理数，核对其真实均值与原值 `fsum` 均值之间的舍入余项，并由真实均值求中心化偏差，再转回浮点。输出均值仍保留原值 `fsum` 结果，余项单独报告。中心化偏差贯穿参数、残差、解释平方和、杠杆、查询标准误与模拟；只修正平方和，却继续使用未修正偏差，会使相邻浮点输入的杠杆严重失真。平方和及交叉和另作小的残余求和修正，仍不保证任意尺度都能高精度计算。

实现保守限制每个外部数值绝对值不超过 10^6 ，非零绝对值至少 10^{-100} ；每组1至2000行；拟合系数绝对值不超过 10^{12} 。中间非零乘积、平方、非恒定离差和以及 MSE 不能静默成为零或次正规数。超出范围会报错，不会自动把问题当作常数或完美拟合。已经在外部转换时丢失的精度无法从现有数组反推恢复。

可靠性也包括文件行为。程序检查配置的所有字段和数据文件的所有行，包括未被 `focus_case` 选中的数据，再创建局部随机生成器；报告完整生成且能序列化后，才原子替换输出文件。畸形的最后一行不能破坏已有报告。输入验证不用 `assert`，所以 Python 的 `-O` 模式不会关闭这些检查。README 给出确切的运行环境、测试方式及实际验证限制。

20 从拟合结果到可检查的结论

完成一次分析应保留数据定义和单位、模型与损失、设计是否满秩、估计参数、逐行预测与残差、至少一种残差诊断、训练范围、概率假设和边界状态。本讲输出 `report.json` 将这些数值拆开保存，Notebook 则按手算、恒等式、图、失败例的顺序逐格核验。

拟合结果可以精确回答“在这份数据和这项损失下，哪条直线最好”。对“下一次会怎样”，需要数据生成与泛化检查；对“主动改变输入会怎样”，还需要因果设计；对“远离训练范围会怎样”，需要机制依据或新观测。把这几类问题分开，才能既信任闭式解提供的确定性，又不让它替没有证据的结论背书。

本讲的核心等式值得最终再从头默写一遍：先中心化，消去截距偏移，再对斜率配平方，最后将剩余误差写成残差平方和。记住公式当然有用，但更重要的是能说明每一步为什么成立、在哪种输入下失效，以及程序怎样告诉你它无法可靠完成计算。

21 自检题

1. 从 $e_i = v_i - bu_i - c$ 开始，不用导数写出两次配平方；标出每个严格正系数需要的条件。
2. 重算五点数据的参数、逐行残差、SSE、MSE，以及任意候选 $a = 0, b = 6/5$ 比最优解多出的损失。
3. 设所有输入为2，输出为1、2、4。写出全部最优参数，并说明在 $x = 3$ 时为什么无法得到唯一预测。
4. 对五点数据强制截距为零，求新最优斜率，并检查残差和是否仍为零。
5. 写出 $S_{yy} = SSR + SSE$ 的交叉项及其消失原因。所有输出相同时， R^2 的普通公式为何失效？
6. 给定独立同方差正态噪声，推导已知方差的似然与未知方差的 MLE，分别处理最小 SSE 正和为零的情况。
7. 若 $x' = 60x + 10, y' = 1000y + 100$ ，求本例新参数及 SSE，解释所有变化的单位意义。
8. 手算二次机制的残差，解释为什么残差正交不能排除曲线结构。
9. 增加 $(20, 0)$ 后核验新参数及远端点杠杆。为何不能凭残差绝对值直接决定删掉谁？
10. 推导 $w_i(x_0)$ 与预测均值方差，并指出它没有计入的外推风险。
11. 给出一个完全线性的观测关系却没有对应干预效果的生成机制。
12. 设计能发现布尔值混入、末行极小非零词元、锚点均值丢失和完美拟合边界误报的程序测试。

22 一手来源与阅读边界

以下来源用于交叉核查；正文、数据和图独立撰写，条件与边界以本讲推导为准。NIST：线性最小二乘、残差诊断、杠杆与影响。概率解释：Stanford CS229讲义、MIT18.655高斯线性模型。计算接口：`math.fsum`、JSON解码、`Fraction`存储值、`NumPy` `lstsq`。实际核查记录见 `source-checks.json`。