

第二十九讲 练习完整解答

这些解答使用正文同一列顺序、同一损失定义和同一合成数据。先写条件，再比较计算结果。若只抄软件给出的三个系数，没有解释秩、阈值和残差，仍没有回答本讲的问题。

1. 模型、对象与形状

单个观察的预测是 $\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_d x_{id}$ 。把截距列纳入A后， $p = d + 1$ ，A的形状是 (n, p) ， β 是 $(p,)$ ， y 、 $\hat{y}$ 、 r 均是 $(n,)$ 。矩阵乘法 $A\beta$ 每一行做一次内积，所以输出长度 n 。

$J = \|A\beta - y\|^2 / (2n)$ 是标量，梯度形状 $(p,)$ ，Hessian形状 (p, p) 。Python的一维数组没有严格“行向量/列向量”之分，书面列向量的转置需要结合矩阵乘法解释。代码中的 $A.T @ r$ 先用 (p, n) 乘 $(n,)$ ，结果是 $(p,)$ 。特征顺序和单位属于这些形状之外的语义，不能由shape自动保证。

2. 广播错误

设预测 $[10, 20]$ 形状 $(2,)$ ，把响应 $[11, 19]$ 写为 $(2, 1)$ 。相减会产生 $[[1, -9], [9, -1]]$ ，形状 $(2, 2)$ ，而合法逐行残差只有 $[1, -1]$ 。前者把第一个响应分别减去两个预测，不再对应同一行样本。

安全做法是明确规定单输出 y 只能是 $(n,)$ ，在入口检查ndim和长度；如果确实接收 $(n, 1)$ ，应在专门接口中有意识转换，而不是在任意输入上无条件flatten。本讲选择拒绝 $(n, 1)$ ，让错误在求解前出现。

3. 梯度与比例

此题按0至d编号设计列， $A_{i0} = 1$ ，其余列为特征。对 $J = (1/2n) \sum_i (\sum_{j=0}^d A_{ij} \beta_j - y_i)^2$ 和 $k = 0$ 至 d ，内层对 β_k 求导是 A_{ik} ，所以

$$\frac{\partial J}{\partial \beta_k} = \frac{1}{n} \sum_i A_{ik} (A_i \beta - y_i).$$

把这些分量叠起来是 $A^T(A\beta - y)/n$ 。再次求导得到 $A^T A/n$ 。若损失改为SSE，没有 $1/(2n)$ ，梯度变为 $2A^T(A\beta - y)$ ，恰好是前者的 $2n$ 倍。梯度为0的位置相同，梯度下降的一步却不同；不能在改变损失归一化后照搬原学习率。

4. 正交与全局最优

正规方程 $A^T A \beta = A^T y$ 等价于 $A^T \hat{r} = 0$ 。对任意 h ,

$$\|\hat{r} - Ah\|^2 = \|\hat{r}\|^2 - 2h^T A^T \hat{r} + \|Ah\|^2 = \|\hat{r}\|^2 + \|Ah\|^2.$$

最后一项非负，故 β 是全局最小点。这不是仅凭“梯度为0”断言一般函数全局最优，而是利用平方损失的具体展开。若含截距，正交关系给 $\sum \hat{r}=0$ ；每个残差仍可以非零。这个条件只谈训练表上的投影，不能推出测试误差为零。

5. 参数唯一与预测唯一

若A满列秩， $Ah=0$ 只可能 $h=0$ ，因此上式在任何非零 h 处严格增加，系数唯一。反之若存在非零 h 且 $Ah=0$ ， β 和 $\beta+h$ 具有同一训练预测和同一损失，参数不唯一。

若 β 和 γ 都是最小解，把 $h=\gamma-\beta$ 代入上一题的恒等式，左右损失相同，必有 $\|Ah\|^2=0$ ，因此 $A\beta=A\gamma$ 。这证明训练预测唯一，不需要系数唯一。对于训练矩阵之外的新行 a ，未必有 $ah=0$ ，所以不能保证新点预测相同。

6. 四行主例完整答案

A的四行依次是(1,0,0)、(1,1,0)、(1,0,1)、(1,1,1)。逐项求内积得到

$$A^T A = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{pmatrix}, \quad A^T y = \begin{pmatrix} 8 \\ 7 \\ 4 \end{pmatrix}.$$

解为 $\beta=(1/2, 3/4, 1/4)$ 。预测分别是1/2、7/4、1/2、7/4；残差 $y-\hat{y}$ 是1/2、-1/2、-1/2、1/2。

SSE=4×1/4=1，MSE=1/4，J=1/8。

截距正交汇总是1/2-1/2-1/2+1/2=0； x_1 汇总是-1/2+1/2=0； x_2 同样为0。若 $a \cdot 1 + b \cdot x_1 + c \cdot x_2 = 0$ ，第一行给 $a=0$ ，第二行给 $b=0$ ，第三行给 $c=0$ ，故满列秩。这个证明同时排除了“正规方程恰好有别的解”的可能。

7. 逆公式与求解路线

满列秩下 $A^T A$ 可逆，所以 $(A^T A)^{-1} A^T y$ 是正确的数学表达式。实现时先求完整逆矩阵再相乘，做了不必要的运算；求解 $G\beta=q$ 即可直接得到需要的向量。

然而 $\text{solve}(A.T@A, A.T@y)$ 仍然形成Gram矩阵，数值困难并未消失。直接QR/SVD通常更合适。本实验的前三个二进制近共线例中，正规方程求解恰好返回精确系数，不能隐去这些结果来营造某算法每次都更差的故事；后面的奇异失败和巨大误差才显示其局限。

8. QR分解与形状

$n \geq p$ 且A满列秩时，薄QR为 $Q(n, p)$ 、 $R(p, p)$ 。 $Q^T Q = I_p$ ， R 可逆， QQ^T 是 R^n 中投向列空间的投影。把 y 拆成 $QQ^T y + (I - QQ^T)y$ ，两项正交，得到

$$\|QR\beta - y\|^2 = \|R\beta - Q^T y\|^2 + \|(I - QQ^T)y\|^2.$$

第二项不随 β 改变，第一项可取零，于是解 $R\beta=Q^Ty$ 。若 $n>p$ ， QQ^T 只有秩 p ，不可能等于 n 维单位矩阵。秩亏时 R 不可逆；本讲代码报告`not_applicable`，不把强行求解得到的巨大数字当成可靠结果。QR分解本身由库的Householder实现提供，实验只组织求解链。

9. SVD与最小范数

非零奇异值对应的解为 $\beta_{\min}=\sum_j(u_j^Ty/\sigma_j)v_j$ 。其训练预测是 $\sum_ju_ju_j^Ty$ ，即把 y 投到 A 列空间。所有其他OLS解都可写为 $\beta_{\min}+h$ ， h 位于 A 零空间。

右奇异向量的可识别子空间与零空间正交，所以 $\|\beta_{\min}+h\|^2=\|\beta_{\min}\|^2+\|h\|^2$ 。只有 $h=0$ 使范数最小。这是一个额外选解标准；数据并没有给每个零空间方向提供信息。NumPy返回 $Vh=V^T$ ，代码必须按这个方向使用，不能把 Vh 当 V 。若按数值阈值截掉非零奇异值，应另称截断解，不混同原矩阵精确OLS。

10. 重复列与新点分歧

$A=[1,x,x]$ 时，只能识别 $\beta_1+\beta_2$ 。若拟合线为 $1+3x$ ，所有解满足 $\beta_0=1$ 、 $\beta_1+\beta_2=3$ 。令 $\beta_2=3-\beta_1$ ，平方范数中与斜率有关的部分是 $\beta_1^2+(3-\beta_1)^2$ ，其导数 $4\beta_1-6$ 为0时 $\beta_1=\beta_2=1.5$ 。

$(1,3,0)$ 、 $(1,1.5,1.5)$ 、 $(1,0,3)$ 在训练行上都输出 $1+3x$ 。但新行 $(1,0,1)$ 输出分别是1、2.5、4，因为该行不满足 $x_2=x_1$ 。这不是软件自相矛盾，是新点打破了训练数据只支持的特征关系。

11. 单位影响最小范数

改成 $A=[1,x,100x]$ 后，约束是 $\beta_1+100\beta_2=3$ 。先消去 $\beta_1=3-100\beta_2$ ，需最小化

$(3-100\beta_2)^2+\beta_2^2=10001\beta_2^2-600\beta_2+9$ 。对 β_2 求导得到 $20002\beta_2-600$ ，唯一零点 $\beta_2=300/10001$ ；二次项系数正，配平方也证明这是全局最小点。代回可得 $\beta_1=3/10001$ 。这只使用已学过的一元二次函数，不需要约束乘子理论。

换回原 x 单位后第二项的有效斜率是 $100\beta_2=30000/10001$ ，仍与第一项加起来为3，但与原来的各1.5不同。范数依赖参数坐标，不是天然客观的“贡献大小”。对一般缩放 s ，公式为 $\beta_1=3/(1+s^2)$ 、 $\beta_2=3s/(1+s^2)$ 。

12. 近共线族的精确验证

x 各项求和为0； z 各项求和 $1-1-1+1=0$ ； w 各项求和 $1-2+1+1-2+1=0$ 。直接点乘得到 $x^Tz=x^Tw=z^Tw=0$ ，平方范数依次28、4、12。

$A\delta=[1,x,x+\delta z]$ 与 $\beta=(1,2,1)$ 相乘得到 $1+3x+\delta z$ ，故残差正好为 $w/16$ 。 w 与三列都正交，满足正规方程； $SSE=12/256=3/64$ 。 $\delta>0$ 时若 $a+b\quad x+c(x+\delta z)=0$ ，利用1、 x 、 z 彼此非零正交，可得 $a=0$ 、 $b+c=0$ 、 $c\delta=0$ ，故三个系数都为0，满列秩且解唯一。

实验不止核对公式，还把每个实际存储的float64转成其精确Fraction值，与上述二进制构造逐项比较。 $\delta=2^{-48}$ 虽很小，仍没有让这组矩阵的两列在精确存储意义下变成相同列。

13. 响应扰动与两种误差

响应变为 $y+\varepsilon z$ 后，设截距不变，参数变化为 $(0, -\varepsilon/\delta, +\varepsilon/\delta)$ 。乘A得到 $-(\varepsilon/\delta)x + (\varepsilon/\delta)(x+\delta z) = \varepsilon z$ ，正好拟合新增分量；残差仍是 $w/16$ 。

参数变化范数是 $\sqrt{2}|\varepsilon|/\delta$ ，训练预测变化范数是 $|\varepsilon| \cdot \|z\| = 2|\varepsilon|$ 。固定 $\varepsilon=2^{-20}$ ，在 $k=48$ 时两个斜率变化达到 $\pm 2^{28}$ ，而训练预测变化范数仍只有 2^{-19} 。这个精确关系展示问题敏感性；浮点求解器偏离这组新精确系数则是算法和舍入误差，两者要分开报告。

14. 条件数平方关系

满列秩时 $A^T A = V \Sigma^2 V^T$ ，其最大、最小特征值是 $\sigma_{\max}^2$ 、 $\sigma_{\min}^2$ 。所以 $\kappa_2(A^T A) = \sigma_{\max}^2 / \sigma_{\min}^2 = \kappa_2(A)^2$ 。

这是精确算术中同一个A的关系。实际计算 $A.T@A$ 时内积已舍入，形成的浮点矩阵可能奇异；再调用`cond`得到的比值不必精确等于平方。条件数大说明一些方向敏感，不直接等于统计预测误差，更不能精确宣布本次已经丢失多少有效数字而不看扰动方向和残差。

15. 三种秩与rcond

数学构造的秩是针对公式 $A\delta$ 而言；存储后精确秩是把已有浮点值当作精确有理数再求秩；有效数值rank由奇异值与截止线比较得到。三者可以不同，但本讲七组二进制构造的前两者都等于3。

NumPy 2.3默认相对阈值为机器精度乘 $\max(n,p)$ 。显式`rcond= $\rho$` 时，通常只保留大于 $\rho\sigma_{\max}$ 的方向。若截掉了真实非零且 $u^T y$ 非零的方向，会改变可拟合分量与损失，因此不能说仍然精确解了原始OLS。把`rcond`设得更小只改变保留规则，不会自动创造稳定的统计信息或恢复浮点计算精度。

16. 公平比较scikit-learn

路线一：给原始 $X=[x_1, x_2]$ ，设置`fit_intercept=True`，比较`intercept_`、`coef_`与显式A解。路线二：给 $A=[1, x_1, x_2]$ ，设置`fit_intercept=False`，直接比较`coef_`三个分量。主例满列秩，两种路线的预测和残差都应与手算相符。

默认截距路线报告的`rank_`和`singular_`属于中心化后的X；显式增广路线对应A，不能机械比较为同一对象。秩亏时中心化与是否惩罚截距范数还可能改变系数约定，应先比较预测。本实验使用scikit-learn 1.8.0，对稠密输入改变`tol`不控制SVD截止线；`positive=True`则改变为非负约束问题，也不属于这个公平对照。

17. 空residuals反例

取七行 $A=[1, x, x]$ 、 $y=1+3x+w/16$ 。精确秩2小于列数3，NumPy `lstsq`返回`residuals=[]`；但实际残差是 $w/16$ ，平方和 $3/64$ ，明显非零。

接口还会在 $n \leq p$ 时返回空residuals。稳妥做法是始终重算预测 $A\beta$ 、残差 $y - \text{预测}$ 和SSE，并保存rank、奇异值、阈值及求解状态。遇到奇异异常应保留失败状态，不填入0损失，因为0会被误读为完美拟合。

18. 嵌套模型与结论边界

若新设计矩阵包含旧列，旧参数在新增列取0时仍可实现原预测，所以新问题的可行预测集合包含旧集合。对同一个训练 y 最小化同一个平方损失，新最优SSE不可能更大。

主例增加 x_1x_2 后， $\beta=(1,2,-1,2)$ 逐行输出1、3、0、4，训练SSE=0。四行上插值成功没有提供独立泛化证据，也没有排除噪声或错误模型。一个加性系数为0不等于没有交互效应，更不等于不存在因果作用。应另做与任务一致的验证设计，不能把训练损失比较包装成现实结论。