

第二十九讲 实验指南：多元回归的数值解与可识别性

实验目标与验收问题

这次实验围绕一个问题展开：同一训练预测背后，系数能否被数据稳定地确定？完成后应能用分数手算验证一个小型平面，组织lstsq、SVD和QR求解路线，报告残差与条件数，并解释秩亏、近共线、单位变化和数值截断之间的区别。

先修是第十一、十二、十四和二十八讲。先阅读正文第2至6节，再执行实验第一部分；理解QR和SVD后继续后三部分。没有网络请求、账号、付费API或GPU任务。数据全部为原创合成数值，不代表现实模型表现。

1. 文件与环境

将本讲目录完整下载，保留data和figures子目录。lecture.pdf是正文，answers.pdf是十八题完整解答，experiment.ipynb是顺序教学Notebook，experiment.py是对应可执行脚本。data目录提供四行主例、七行正交向量和JSON参数。requirements.txt列出实际验收版本，environment.yml提供可选Conda环境文件。

建议建立独立环境后安装依赖，再启动Notebook：

```
python -m venv .venv
python -m pip install -r requirements.txt
python experiment.py --output-dir outputs
python -m jupyterlab
```

在终端中先按自己操作系统激活.venv。使用Conda的读者可运行conda env create -f environment.yml，再激活ml-unit-029。环境文件是可复现配置，不代表已经在真实Anaconda图形界面中实测安装。

本次实际测试使用Python 3.12.14、NumPy 2.3.5、scikit-learn 1.8.0。Notebook在新Python进程中用真实InProcessKernel顺序执行，保留文字与PNG输出；受环境传输限制，没有验证浏览器Jupyter界面、独立进程socket传输或真实Anaconda安装。你在本地应选择新内核后Run All，不依赖旧变量。

2. 先手算四行平面

打开hand_regression.csv，按列顺序构造 $A=[1, x_1, x_2]$ ， $y=(1, 3, 0, 4)$ 。不要先看软件系数，先计算 $A^T A$ 和 $A^T y$ 。解出 β 后逐行求预测和残差，再计算SSE、MSE和J。写出满列秩的行方程证明，不能只凭det的浮点值。

标准锚点是 $\beta=(1/2, 3, 0)$ ，预测 $(1/2, 7/2, 1/2, 7/2)$ ， $SSE=1$ ， $MSE=1/4$ ， $J=1/8$ 。Notebook先用Fraction核对这些等式，再调用浮点方法。比较时把形状(n,)写进记录，额外构造 $y[:, None]$ 与预测相减的广播错误，确认那不是逐行残差。

3. 自己组织三条数值路线

阅读solve_ols的实现。lstsq路线直接调用`np.linalg.lstsq`，再重新计算 $A@ \beta$ 与残差；SVD路线自行使用U、s和Vh，保留声明阈值以上的方向，再构造最小范数参数；QR路线先检查 $n \geq p$ 和数值满列秩，调用库薄QR，再解 $R\beta=Q^T y$ 。

这里“自行组织”指理解并实现这些数组组合与检查，不是从零写LAPACK或Householder分解。正规方程`solve(A.T@A, A.T@y)`只作为对照，不使用显式逆矩阵。对主例逐项比较系数、预测、SSE和梯度范数。若只得到相近系数，却没检查预测形状和残差，就没有完成验收。

为每条路线记录method、status、rank、singular_values、absolute_cutoff、condition_estimate、beta、prediction、residual、sse和gradient。condition_estimate来自浮点奇异值比值，数学秩需另由精确结构确定。

4. 完全重复列：有多个系数方案

从七行x构造 $A=[1, x, x]$ ，响应 $y=1+3x+w/16$ 。比较 $(1, 3, 0)$ 、 $(1, 1.5, 1.5)$ 、 $(1, 0, 3)$ 的训练预测，确认完全相同。然后用新行 $(1, 0, 1)$ 预测，观察1、2.5、4的分歧。

这个新行破坏了训练时 $x_1=x_2$ 的关系，所以分歧不能归咎于软件错误。把一列改为100x，再观察最小范数分配 $3/10001$ 、 $300/10001$ 。换回原单位后总斜率仍为3，单列“贡献”却改变。

同时查看NumPy原始residuals字段：它是空数组，而重算SSE为 $3/64$ 。把这对结果写进实验记录，解释空字段只是接口约定。QR路线应明确报告条件不满足，不强行输出一个“唯一解”。

5. 二进制近共线族

使用x、z、w彼此正交的七行数据。对于 $k=0, 8, 16, 24, 32, 40, 48$ ，令 $\delta=2^{-k}$ ， $A\delta=[1, x, x+\delta z]$ ， $y=1+3x+\delta z+w/16$ 。先验证实际存储的每个float64值与对应Fraction完全相同，再求存储矩阵的精确秩。七组都应是3。

精确 $\beta=(1, 2, 1)$ 、 $SSE=3/64$ 是由正交结构得到的参照，不由待比较求解器自己产生。分别报告：系数相对这一参照的误差、训练预测相对精确预测的误差、实际SSE、有效数值rank、奇异值和条件数。不要把这些量混成一个“准确率”。

本次环境默认lstsq的有效rank序列是3、3、3、3、3、3、2。k=32和40时，系数误差分别约 1.51×10^3 和 4.25×10^7 ，但SSE仍接近0.046875。SVD/lstsq并不保证在巨大条件数下仍准确恢复系数。正规方程前三组恰好算准，k=24出现明显误差，后三组求解失败；跨平台不要求每个误差数字逐位相同。

6. 单独展示问题敏感性

给响应加固定 εz , $\varepsilon=2^{-20}$ 。先推导精确系数变化 $(0, -\varepsilon/\delta, +\varepsilon/\delta)$ ，再运行求解器。画两张不同的图：精确系数变化范数 $\sqrt{2}|\varepsilon|/\delta$ 和精确训练预测变化范数 $2|\varepsilon|$ 。

第一张随 k 增加而剧增，第二张保持不变。这是问题本身的敏感性。再比较计算参数与扰动后的精确参数，才是数值算法误差。不能直接拿“扰动前后软件输出不同”作为算法不稳定的唯一证据，因为真实最优参数本来就应改变。

在 $k=48$ 时斜率变化达到 2^{28} 。代码允许有限的大系数输出，并记录不稳定性，不用一个随意的 $1e6$ 系数上限把这个已声明实验删除。输入规模和计算范数另有明确安全范围。

7. 截断与scikit-learn交叉核对

保持同一个 $A\delta$ 和 y ，对 $rcond=10^{-15}$ 、 10^{-8} 、 10^{-3} 分别求解，记录秩与SSE。改变 $rcond$ 可能截掉一个真实非零方向，从而改变可拟合分量。阈值更小不会自动提高系数精度，阈值更大也不是无代价修复。

使用两种scikit-learn写法核对主例：原始 X 搭配 $fit_intercept=True$ ；显式 A 搭配 $fit_intercept=False$ 。两者都应预测 $(0.5, 3.5, 0.5, 3.5)$ 。默认截距路线的 $rank_$ 属于中心化 X ，不能当成 A 的秩。固定版本1.8.0中稠密路径的 tol 不影响求解；改变 tol 仅是接口观察，不是改变本次SVD截止线的方法。

8. 故障实验与输出保护

浮点输入只接受有限的普通Python实数或不超过64位的NumPy实数，拒绝bool、复数、文本、Fraction、Decimal及扩展精度。非零输入绝对值至少 $1e-100$ ，普通矩阵元素不超过 $1e6$ ；矩阵最多128行、16列。这个范围服务教学，不能外推为通用数值库。

检查最后一个矩阵元素为NaN、响应是 $(n,1)$ 、混合bool、空列、长度不符、错误方法和末尾非法 $rcond$ 。每个参数都必须先验证，不能因某路线没有使用它就跳过。JSON加载还检查原始非零数字下溢、NaN/Infinity以及重复键；例如 $1e-400$ 不能先变成0再蒙混过关，真正的 $0e-400$ 仍作为0处理，再交由字段范围判断。

CSV只接受有界的普通十进制文本，而且必须在binary64中精确表示。主例可用同样满足条件的小数据修改；七行向量CSV固定为声明模型，变更必须重新设计实验。示例0.1被拒绝，0.125可精确表示；这只是本讲精确存储实验的合同，不是说一般机器学习不能使用0.1。

先在输出目录已有report.json的情况下放入错误CSV或JSON，再运行脚本。应看到异常，旧文件内容保持原样；若目标目录不存在，错误输入不得创建它。若求解失败，报告保留失败状态和原因，不写0误差冒充成功。输出先完整构造为合法JSON，再用临时文件替换，避免半写报告。

9. 提交什么结果才算完成

提交一份自己的实验记录，至少包括：四行精确手算；三条主求解路线与正规方程对照；重复列的新点分歧；单位变化后的参数；七组近共线系数误差、预测误差、SSE、秩和条件数；响应扰动的两个精确范数；rcond扫描；scikit-learn截距对齐；两种非法输入和输出保护证据。

最后用自己的话回答三句话：为什么训练预测唯一不意味着所有参数唯一？为什么训练残差很小仍可能有巨大系数误差？为什么数值求解成功不等于泛化或因果结论？完整自测十八题与解答分别在正文末尾和answers.pdf。

10. 一段合格实验解释的示范

以 $k=40$ 这行报告为例： $\delta=2^{-40}$ 严格大于0，存储值有理秩仍为3；默认lstsq也报告rank=3，但系数误差范数约 4.25×10^7 ，训练SSE仍接近3/64。合格结论是“这份输入下，数值解的系数偏离精确参照很大，而训练残差指标未显著揭示该偏离”。不能改写成“真实模型系数就是几千万”或“有了小SSE，参数已准确”。

再看 $k=48$ ：默认rank降为2，接近最小范数拆分的结果与原来数学满秩 $\beta=(1,2,1)$ 不同。这时系数误差比上一行小，并不表示条件数突然改善，而是求解器换成了截断约定。比较曲线时，先识别rank是否变化，再解释系数误差上升或下降。




图 两个并列检查：左侧是计算条件数及理想平方关系；右侧是真实系数误差，缺失点代表求解失败。

建议把自己的报告分为三段：先报精确参照与实际存储条件；再报本机版本、方法、阈值和观察数值；最后说明可以推出什么、还缺什么证据。这个分工防止用待评估的算法输出证明算法自身正确，也防止把小型数值实验扩展为现实预测结论。