

第二十九讲 多元线性回归与数值求解

1. 多放一列特征，问题发生了什么变化

上一讲从平方误差推出一条直线。现在同一条观察有两个或更多特征，我们希望它们共同预测一个数值响应。表面上只是把斜率变成多个系数，真正新增的问题却是：列与列可能重复，一点微小扰动可能大幅改变某些系数，而训练预测几乎不变。

本讲的核心问题是：多个特征怎样共同解释响应，系数何时不稳定？我们把设计矩阵、梯度、正规方程、QR与SVD接成同一条计算链，同时区分数学解、浮点数值解和对新数据的预测。求解器返回数组并不意味着系数具有唯一含义；训练残差很小也不意味着因果关系或外推可靠。

直接先修是第十一、十二、十四和二十八讲：线性方程与最小二乘、正交分解与SVD、向量梯度、一元回归。这里从单输出、实数、等权平方损失开始，不使用稀疏数据、样本权重、非负约束或正则化。那些设置会改变计算或目标，不能悄悄混入对照。

同一组参数，三种不同问题




图1 从逐行预测到矩阵乘法，再分开检查系数、训练拟合与新点预测。三种检查不是同一个问题。

2. 先把每个数组的形状写清楚

设有 n 行数据、 d 个原始特征。第 i 行特征为列向量 $x_i \in \mathbb{R}^d$ ，响应 $y_i \in \mathbb{R}$ 。含截距模型为 $\hat{y}_i = \beta_0 + \sum_{j=1}^d \beta_j x_{ij}$ 。把常数1放在每行首位，得到设计矩阵 $A \in \mathbb{R}^{n \times p}$ ，其中 $p = d + 1$ ； $\beta \in \mathbb{R}^p$ ； y 和 $\hat{y}$ 均为 $\mathbb{R}^n$ 中的向量。

$$A = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1d} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nd} \end{pmatrix}, \quad \hat{y} = A\beta, \quad r = y - A\beta.$$

A 的行对应同一批观察，列对应约定好的特征及顺序。训练时第二列是温度、预测时却把湿度放进去，形状仍可能正确，但语义已经错了。列顺序、单位和预处理参数都是模型的一部分。

本讲Python把单输出 y 存为形状 $(n,)$ ； β 为 $(p,)$ ；矩阵乘法 $A@ \beta$ 得到 $(n,)$ 。若把 y 写成 $(n,1)$ 而预测仍为 $(n,)$ ，减法可能广播成 (n,n) ，导致每个预测减每个响应。代码应明确拒绝或显式转换，而不是只看最终得到一个数字就继续。




图2 含截距的四行三列设计矩阵与各对象形状。广播错误把一对一残差变成所有两两差值。

3. 一个四行、两特征的完整手算例子

使用完全合成的数据： $x_1=(0,1,0,1)$ ， $x_2=(0,0,1,1)$ ， $y=(1,3,0,4)$ 。每行只是一个教学观察，不带现实人物或因果解释。于是

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \end{pmatrix}, \quad y = \begin{pmatrix} 1 \\ 3 \\ 0 \\ 4 \end{pmatrix}.$$

这四个角点把截距和两列特征区分开；A的三列线性独立。目标是找到一个平面，使四个竖直响应残差的平方和最小，不是让每个点到平面的最短几何距离最小。因为我们只预测 y ， x 被当作给定输入，平方损失沿响应方向定义。

后面将得到 $\beta=(1/2,3,0)$ ，预测 $(1/2,7/2,1/2,7/2)$ ，残差 $(1/2,-1/2,-1/2,1/2)$ 。先把这些数保留为分数，避免一开始就用小数误差掩盖代数结构。

4. 从分量导数到向量梯度

定义 $J(\beta)=||A\beta-y||^2/(2n)$ 。本节将A的列编号记作0至 d ，与 β_0 至 β_d 对应： $A_{i0}=1$ ， $A_{ij}=x_{ij}$ ($j \geq 1$)。对 $k=0$ 至 d ，偏导是

$$\frac{\partial J}{\partial \beta_k} = \frac{1}{n} \sum_{i=1}^n A_{ik} \left(\sum_{j=0}^d A_{ij} \beta_j - y_i \right).$$

把p个分量排成列向量，得到 $\nabla J = A^T(A\beta - y)/n$ ，形状为(p,)。Hessian为 $A^T A/n$ ，形状(p,p)。这里的1/2消掉平方导数中的2，1/n来自平均。若用SSE而非J，梯度乘2n，最小点不变，但以后梯度下降的学习率不能不变地照搬。

从方向变化也能复核：把 β 换成 $\beta+h$ ，目标变化等于 $h^T A^T(A\beta - y)/n + \|Ah\|^2/(2n)$ 。线性项给梯度，二次项非负。这个展开会在证明全局最优和唯一性时再次使用。




图3 残差经A转置汇总到每个参数方向。特征列决定该参数对哪几行预测有影响。

5. 正规方程为何是最优条件

令梯度为0，得到 $A^T A \beta = A^T y$ ，称为正规方程。它的等价形式是 $A^T \hat{r} = 0$ ：最优残差与A的每一列都正交。若首列是全1，这给 $\Sigma \hat{r}_i = 0$ ；其他列给 $\Sigma x_{ij} \hat{r}_i = 0$ 。

正交条件不是“每个残差为0”，而是正负残差与各列的相关汇总为0。它也不是证明模型对新数据没有误差；只是在给定列空间中实现了这个训练目标的最优拟合。

任取h，展开 $SSE(\beta+h) = \|\hat{r} - Ah\|^2$ 。交叉项因 $A^T \hat{r} = 0$ 消失，得到

$$\|y - A(\hat{\beta} + h)\|^2 = \|\hat{r}\|^2 + \|Ah\|^2.$$

因此满足正规方程的 β 一定是全局最小点。若A满列秩， $Ah=0$ 只允许 $h=0$ ，最小点唯一；若存在非零零空间方向h，沿这个方向移动不改变任何训练预测，系数可以不唯一。

6. 手算正规方程与残差核验

主例直接乘得

$$A^T A = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{pmatrix}, \quad A^T y = \begin{pmatrix} 8 \\ 7 \\ 4 \end{pmatrix}.$$

把 $\beta=(1/2, 3, 0)$ 代入，第一行 $2+6=8$ ，第二行 $1+6=7$ ，第三行 $1+3=4$ ，全部成立。残差四项平方都是 $1/4$ ，所以 $SSE=1$ ， $MSE=1/4$ ， $J=1/8$ 。残差和为0；与 x_1 的内积 $-1/2+1/2=0$ ，与 x_2 同样为0。

为确认唯一性，若 $a \cdot 1 + b \cdot x_1 + c \cdot x_2 = 0$ ，第一行立即给 $a=0$ ，第二、三行分别给 $b=c=0$ ，三列独立。因此正规方程解唯一，不需要通过“数值库没有报错”推断这一点。

这里 x_2 系数为0不意味着 x_2 在任何模型或总体中都没有作用。四行数据里的 x_2 效应在不同 x_1 水平上相反，简单加性平面没有交互项；仅凭一个拟合系数不能作因果判断或删除科学问题。




图4 手算预测与残差逐行显示；三项正交汇总均为0，但每行残差仍非零。

7. 满列秩时的逆公式只是一种数学表示

当 A 满列秩， $A^T A$ 正定，因为对任何非零 v ， $v^T A^T A v = \|Av\|^2 > 0$ 。因此可以写 $\beta = (A^T A)^{-1} A^T y$ 。这个公式说明解的形式，不要求程序真的先形成逆矩阵。

在实际数值计算中，若决定使用正规方程，也应求解线性系统 $G\beta=q$ ，例如`solve(G,q)`，而不是`inv(G)@q`。两者仍都形成 $G=A^T A$ ，因而都继承Gram矩阵的数值困难；去掉显式求逆不是已经解决了所有不稳定性。

更推荐直接在 A 上做QR或SVD。不能用一次干净小数据上四种结果相同来证明所有求解路线等价稳定，也不能声称每个样本上显式逆必定误差最大。数值对比需要说明输入、尺度、条件数和真实可核对答案。

8. QR怎样把问题化成三角系统

假设 $n \geq p$ 且 A 满列秩。薄QR分解写 $A=QR$ ， $Q \in \mathbb{R}^{n \times p}$ 满足 $Q^T Q = I_p$ ， $R \in \mathbb{R}^{p \times p}$ 是可逆上三角矩阵。把 y 分成 $QQ^T y$ 和 $(I - QQ^T)y$ 两块，两者正交，便有

$$\|A\beta - y\|^2 = \|R\beta - Q^T y\|^2 + \|(I - QQ^T)y\|^2.$$

第二项不随 β 变化，最小化第一项只需解 $R\beta = Q^T y$ 。用回代或通用solve处理三角系统即可，不需要显式 R^{-1} 。这里 Q 通常不是方阵， QQ^T 是投影矩阵，不是 n 维单位阵；把 $Q^T Q = I$ 误写成 $QQ^T = I$ 会错误地声称所有残差都能消掉。

本讲用库的Householder QR分解，再自己组织 $Q^T y$ 与三角求解路线。没有声称从零实现可靠的Householder分解。若列秩不足，基本薄QR的 R 不可逆，不能照着full-rank路径硬解；应报告条件不成立并转向合适的秩揭示分解或SVD。




图5 y被分成列空间内可拟合分量与正交残差；QR在正交坐标下处理前一块。

9. SVD直接暴露哪些方向难以确定

设 A 的秩为 r ，其非零奇异分解为 $A = U_r \Sigma_r V_r^T$ 。 $U_r \in \mathbb{R}^{n \times r}$ 、 $V_r \in \mathbb{R}^{p \times r}$ 列正交， Σ_r 对角线是正奇异值 $\sigma_1 \geq \dots \geq \sigma_r$ 。注意这里 σ_j 是矩阵的奇异值，不是上一讲噪声标准差。

把参数在右奇异向量上展开，每个可识别方向的系数由 $(u_j^T y) / \sigma_j$ 决定。最小范数解为

$$\hat{\beta}_{\min} = \sum_{j=1}^r \frac{u_j^T y}{\sigma_j} v_j.$$

若存在零空间方向，可加任意 $h \in \text{Null}(A)$ 而不改变残差。 V_r 方向与零空间正交，所以 $\|\hat{\beta}_{\min} + h\|^2 = \|\hat{\beta}_{\min}\|^2 + \|h\|^2$ ， $h=0$ 给唯一的最小欧氏范数系数。训练预测 $U_r U_r^T y$ 则是唯一的，哪怕系数不唯一。

NumPy的svd返回 $Vh = V^T$ ，而不是 V ；用full_matrices=False时列/行数以 $\min(n, p)$ 为准。程序应核对 U 、 s 、 Vh 的形状和重建残差，再组织伪逆求解。不是把几个数组依次相乘到恰好不报形状错误就结束。

10. 完全共线时，预测唯一但系数不唯一

令A的后两列完全相同，都是 x ，并保留截距。模型只通过 $\beta_1 + \beta_2$ 乘 x 。若最优线为 $1 + 3x$ ，全部最小二乘解都满足 $\beta_0 = 1$ 、 $\beta_1 + \beta_2 = 3$ 。向量 $(0, 1, -1)$ 在零空间里。

在这条解直线上， $\beta_1^2 + \beta_2^2$ 最小时两者各为 $3/2$ 。SVD最小范数解因而选 $(1, 1.5, 1.5)$ ，而 $(1, 3, 0)$ 和 $(1, 0, 3)$ 得到同样训练拟合。最小范数是额外的选解约定，不是数据已经告诉我们两个作用恰好一样大。

对于遵守相同列关系 $x_2 = x_1$ 的新行，两种系数仍给同一预测。若新行变成(截距1, $x_1 = 0, x_2 = 1$)，它已经离开训练时的特征关系，三个系数方案可以给不同输出。不能从训练预测唯一推断任意外部点上的预测都唯一。




图6 系数平面上的一条等价解直线，及其中离原点最近的点。数据约束总和，范数约定选择一个拆分。

11. 最小范数还依赖你采用的单位

继续完全重复列的例子，把第二个特征改写成 $100x$ ，对应系数约束变成 $\beta_1 + 100\beta_2 = 3$ 。最小化新坐标里的 $\beta_1^2 + \beta_2^2$ 得到 $\beta_1 = 3/10001$ 、 $\beta_2 = 300/10001$ 。将后一项换回原 x 的系数是 $30000/10001$ ，与原单位下两项各1.5明显不同。

训练拟合没有变化，选出的参数拆分却变化了。原因是欧氏范数把不同单位的参数当作同一个几何尺度；改变坐标后，“最小”的含义也改变。不要把软件返回的最小范数参数当作自然唯一的科学归因。

满列秩且使用精确算术时，对可逆特征重参数化，只要正确还原参数，预测函数保持一致。秩亏、数值阈值、正则化或有限精度会引入额外约定，需要分别讨论，不能统称“标准化总是无害”。

12. 近共线为什么放大系数变化

完全相同的两列会出现零奇异值；非常接近的两列往往出现很小但非零的奇异值。公式中的除以 σ_j 会放大 y 沿 u_j 方向的一点扰动。设 $\delta y = \epsilon u_j$ ，满秩时系数变化 $\delta \beta = (\epsilon / \sigma_j) v_j$ ，而训练预测变化 $\Delta \delta \beta = \epsilon u_j$ 。

因此系数变化可以很大，训练拟合变化仍很小。这不是求解器必然算错，而是问题本身对该方向的信息很弱。当然有限精度还可能进一步加重误差，必须把固有敏感性与算法误差分开。

本讲用一个可精确构造的族说明。取七维 $x=(-3,-2,-1,0,1,2,3)$ ， $z=(1,0,-1,0,-1,0,1)$ ， $w=(1,-2,1,0,1,-2,1)$ 。三者与全1向量正交，且 x 、 z 、 w 彼此正交。令 $A\delta=[1,x,x+\delta z]$ ， $y=1+3x+\delta z+w/16$ 。 $\delta>0$ 时 $\beta=(1,2,1)$ ，残差 $w/16$ ， $SSE=3/64$ 。

再给响应加 εz 。精确系数变化是 $(0,-\varepsilon/\delta,+\varepsilon/\delta)$ ，预测变化 εz 的范数只有 $2|\varepsilon|$ 。实验用2的整数负幂，使这些数据在声明范围内能由float64精确表示，再用存储值的高精度参考核对，避免把输入舍入当成求解器误差。




图7 近共线族中，固定小响应扰动带来随 $1/\delta$ 放大的系数变化；训练拟合变化保持同一个尺度。

13. 条件数说明什么，不说明什么

满列秩时，2范数条件数 $\kappa_2(A)=\sigma_{\max}/\sigma_{\min}$ 。它衡量线性映射不同方向的尺度差，是敏感性的一个重要指标；不等于模型预测误差，也不是一个可以跨单位随意比较的固定质量分数。

对满列秩 A ，在精确算术中 $A^T A$ 的特征值是 σ_j^2 ，所以 $\kappa_2(A^T A)=\kappa_2(A)^2$ 。形成正规方程可能丢失相近大数之差中的有效信息；这解释了为什么直接QR/SVD通常更稳健。浮点形成的Gram矩阵可能已经受到舍入，其实际计算条件数不必恰好等于理想平方关系。

不应把“大条件数”直接写成“已知损失了若干位且结果完全不可用”。实际误差还取决于扰动方向、响应向量、残差角度、求解算法与缩放。最小二乘在 A 和 y 都变化时的完整扰动分析比方阵求解的简单界更细，本讲只严格推导前节固定 A 、沿指定奇异方向改变 y 的机制。




图8 A条件数与理想Gram平方关系，及两条求解路线的实际系数误差；缺失点表示求解失败，不是零误差。

14. 数学秩与软件报告的有效秩

数学上，任何 $\delta > 0$ 的上述 $A\delta$ 都满列秩。浮点求解器却通常把小于相对阈值的奇异值视作零。NumPy 2.3的lstsq默认阈值系数是机器精度乘 $\max(n, p)$ ，也可明确给rcond。于是同一个数学非零方向可能在不同阈值下被保留或丢弃。

丢弃小但非零的方向，相当于使用截断SVD。它可能改善扰动敏感性，也可能引入拟合偏差；若丢弃的方向与 y 有非零投影，得到的结果不再是原始满秩矩阵的精确最小二乘解，而是截断后的数值约定。报告rank时必须带上阈值、奇异值和版本。

在近共线实验里，我们同时保留 δ 的精确构造、存储后矩阵的有理数秩、默认数值rank和显式rcond的rank。若默认阈值把秩报为2，不能反过来宣布原本两列在数学上完全相等。反之，硬设极小rcond保留方向，也不自动让噪声信息变可靠。




图9 同一奇异值谱与不同截止线。有效秩是数据、精度与数值约定共同决定的报告。

15. 与scikit-learn比较时先对齐问题

核心路线使用显式含截距的A，直接求 β 。scikit-learn的通常用法是把不含常数列的特征矩阵X交给LinearRegression(fit_intercept=True)，由库估计截距。主例满列秩时，两条路线应给相同截距、系数、预测和残差，只允许浮点误差。

也可以给完整A并设置fit_intercept=False，把常数系数当作普通参数。这两种写法不能同时再添加一个默认截距而不说明冗余。对比rank_、singular_时尤其要注意库内部可能使用中心化后的特征矩阵，而你的SVD分析的是含截距A，形状与秩对象不同。

秩亏时，默认带截距实现与显式增广矩阵的最小范数约定也未必对同一个联合参数范数取最小。预测在同一训练列空间里可以一致，系数却可能因中心化和选解约定不同。先比较训练预测与残差，再解释参数差异，不应机械要求所有秩亏路线系数逐位相等。

本实验固定scikit-learn 1.8.0。其LinearRegression的tol用于稀疏lsqr路径，对本讲稠密输入不生效；不要把改变tol当成已经控制了本次稠密SVD阈值。不同版本需重新核对官方文档。positive=True则改为非负约束，已经不再是本讲的无约束OLS。

16. 返回的residuals为空不等于残差为零

NumPy lstsq返回解、residuals、rank和奇异值。residuals字段在秩亏或 $n \leq p$ 时可以是空数组，即便真正的 $\|y - A\beta\|^2$ 不为0。这个字段只是接口的返回约定，不是数学对象不存在或误差恰好为零。

所以无论哪条求解路线，都重新计算 $\hat{y} = A\beta$ 、 $r = y - \hat{y}$ 和 $SSE = \sum r_i^2$ ；同时核对形状、有限值、 $A^T r$ 的大小、相对残差和数值秩。对真正秩亏的最小二乘解， $A^T r$ 仍应在合理容差内接近0；对截断但原矩阵满秩的近似解，应按已声明的截断解释剩余梯度。

科学报告至少保留：n和p、列名与单位、截距约定、求解方法、rank和阈值、奇异值或条件数、训练SSE、残差摘要、系数和预测。一次没有抛出LinAlgError不等于所有这些条件都已经核对。

空接口字段不是“完美拟合”

NumPy原始字段
residuals = []
rank = 2 < p = 3




图10 将库的空residuals字段与手工重算的非零SSE对照，防止把接口约定当作统计结论。

17. 加一列为什么总能降低训练误差，却未必更好

若新模型的列空间包含旧模型列空间，旧预测仍然可选，因此精确最小训练SSE不会增加。这是嵌套可行集合的结论，不需要假设新特征真的有用。增加无关或高度相关特征也可能降低训练残差，却让系数更不稳定或新数据误差增大。

主例加入交互列 x_1x_2 后，四参数可以在这四行上精确插值： $\beta=(1,2,-1,2)$ 。训练SSE为0，但四行已经用完所有自由变化，无法从这一点证明对未见组合、带噪新观察或现实任务更好。需要与目标一致的独立验证设计，而不是在同一个训练表里选择最低SSE后宣布成功。

“控制其他特征”的系数解释也是模型内的条件变化，不自动代表干预一个特征的因果效应。强相关特征下，所谓其他特征不变的组合可能根本没有出现在数据支持中；此时外推和可识别性问题尤其需要明确。

18. 本次实验的求解与验收顺序

先用Fraction手算主例正规方程、解、残差和SSE。然后组织NumPy `lstsq`、薄QR三角求解与SVD伪逆三条路线，用相同输入比较。正规方程`solve`只作为条件数示例中的对照，绝不把显式`inverse`写成推荐路线。

接着构造完全重复列与近共线族，对每个案例分别记录系数误差、训练预测差、SSE、奇异值、数学秩和数值rank。增加固定 εz 扰动时，按完整规则重新求解，并与精确 $(0, -\varepsilon/\delta, +\varepsilon/\delta)$ 关系比较。允许某条路线报告不适用或`LinAlgError`，不把异常伪装成0误差。

最后用scikit-learn核对主例和明确对齐的预测任务。所有输入包含最后一个元素、未选择路线的参数和数值阈值，都应在求解或写文件前完整验证。JSON原文非零下溢与重复键必须被拒绝；矩阵NaN、混合bool、空列、长度不符、错误形状及不支持的精度类型都要有失败证据。

三段验收链：计算正确仍需解释范围



图11 从精确手算到三求解器，再到秩亏、近共线和软件交叉核对。每一步回答不同的验收问题。

19. 数值误差与统计误差需要分别处理

数值误差是在同一份存储数据、同一个数学目标下，有限精度计算偏离精确解。统计误差来自随机数据与未知总体，即使算术完全精确也可能存在。特征遗漏、目标定义错误与分布变化又属于不同层次。

QR比正规方程稳定，不能使错误标签变正确；SVD返回最小范数解，不能提供原本缺失的可识别信息；训练残差正交，不能保证测试数据来自同一机制。每个补救措施都只解决它对应的那一层问题。

本讲实验是离线CPU上的小矩阵，不为大规模吞吐、分布式求解、稀疏矩阵或现实预测性能背书。环境版本、实际执行方式和未测试的Anaconda/browser Jupyter条件会在实验说明中明确。

每种证据只回答自己的问题




图12 模型设定、统计信息和数值算法三层问题分别定位。一个成功的求解状态不能替代另外两层证据。

20. 自测与后续

1. 写出含截距模型的逐行形式及 A 、 β 、 y 、 r 、梯度和Hessian的形状。
2. 构造 $(n,1)$ 减 $(n,)$ 的广播错误，解释为什么它不是合法逐行残差。
3. 从分量导数推出 $J = \|A\beta - y\|^2 / (2n)$ 的梯度，说明使用SSE时的比例变化。
4. 从正规方程推出残差正交，并用平方展开证明全局最优。
5. 证明满列秩恰好保证参数唯一；解释秩亏时为什么训练预测仍唯一。
6. 手算四行主例 $A^T A$ 、 $A^T y$ 、 β 、预测、残差、SSE、MSE和 J 。
7. 解释逆公式与数值求解路线的区别，为什么solve正规方程仍可能不稳定。
8. 写出薄QR各矩阵形状，推导三角系统，说明 QQ^T 与 $Q^T Q$ 区别。
9. 从SVD推最小范数解，并证明加入零空间分量会增加系数范数。
10. 对重复列例子列出全部最小解、最小范数解及一个离开列关系的新点分歧。
11. 将重复列之一变为100x，推导新的最小范数系数，解释单位效应。
12. 核对 x 、 z 、 w 正交关系，推导近共线族的精确系数、残差与SSE。

13. 给 y 加 ϵz , 求参数变化与训练预测变化的范数, 区分敏感性和算法误差。
14. 从奇异值解释 $\kappa_2(A^T A) = \kappa_2(A)^2$ 的条件与浮点限制。
15. 区分数学秩、存储后精确秩与有效数值rank, 说明rcond截断改变了什么。
16. 设计与scikit-learn公平比较的两种截距路线, 并说明秩对象和tol限制。
17. 为什么residuals为空不能当SSE=0? 请给出秩亏、非零残差的反例。
18. 证明加入特征不会增加最优训练SSE, 说明为什么仍不能自动作泛化或因果结论。

完整实验与逐题解答另有文件。下一讲把两参数回归写成损失曲面, 再进入优化算法; 本讲获得的解析解会成为后续优化实验的可靠参照, 而不是由优化器自己的成功状态为自己证明。

来源与核查范围

- [Boyd与Vandenberghe作者公开讲义](#): 核对第12章满列秩条件、残差正交与QR路线; 本讲数据、近共线族、文字与推导组织独立构造, 不复用书中例题或图片。
- [NumPy 2.3 lstsq](#): 核对最小范数选解、默认rcond与空residuals约定。
- [NumPy 2.3 QR与SVD](#): 核对薄分解形状、Vh方向和库分解边界。本讲不沿用文档示例中的显式逆实现。
- [NumPy 2.3 cond](#): 核对2范数与奇异值条件数口径。
- [scikit-learn 1.8 LinearRegression](#): 核对截距、稠密rank_/singular_与tol在稀疏路径的作用, 版本与实验环境一致。
- [SciPy 1.17 lstsq](#): 核对有效秩、求解驱动与返回字段, 不把不同驱动结果视作独立数学证明。