

第030讲 损失曲面与优化问题

求参数为什么是一个几何和计算问题？第028讲已经找到一条最好的直线，现在我们把所有候选直线同时放到一张地图上：地图上的一个点表示一组参数，点的高度表示这组参数在给定数据上的损失。寻找参数于是变成寻找低处。地图能解释方向、弯曲、唯一性和约束；计算程序则必须在有限次数、有限精度下给出可核验的结果。

本讲始终保留一个独立答案：五个合成点的最优参数是截距 $3/5$ 、斜率 $6/5$ ，目标值为 $4/25$ 。我们先证明这个答案为什么是整个参数平面的最低点，再用曲面、等高线、梯度场和有限步轨迹逐一验证。图看起来像碗不是证明；程序显示成功也不是关于真实世界的结论。

1 先修 目标与本讲边界

直接先修是第014至015讲和第028讲。需要知道偏导数、方向导数、Hessian、二次型，以及一元回归的配平方恒等式。第029讲把这些对象推广到设计矩阵；本讲即使不借助 QR 或 SVD，也能从两个参数完整推导。矩阵写法只压缩已经解释过的标量关系。

读完应能独立回答：优化变量是什么；图的两个横轴是什么；损失的单位 and 归一化是什么；某点的梯度能说明多远范围内的变化；怎样区分驻点、局部最小值和全局最小值；为什么需要计算预算和独立参照；什么证据不足以说明泛化。

学习路线是先读第2至7节并手算，再读第8至12节的形状与计算，最后完成第13至16节的边界判断。第031讲会系统推导一维学习率，第032讲会深入多维谱与缩放，因此本讲的有限步更新只是读懂地图的探针。约束优化及优化误差、统计误差会在后续再次讨论，这里先建立不混淆它们的语言。所有数据和图均为原创合成教学例，不对应真实仪器测量或任务效果。

2 三个不同空间 不能把坐标混在一起

固定训练数据 $D = \{(x_i, y_i)\}_{i=1}^n$ ，其中 $n \geq 1$ ，输入输出均为有限实数。规则为 $f_{a,b}(x) = a + bx$ 。先在数据空间中画 (x_i, y_i) 和候选直线；然后在参数空间中画 (a, b) ；最后给参数点添上高度 $J(a, b)$ ，得到三维曲面。

这三个图并不是同一张图的缩放。一条预测直线在数据空间里有无限多个点，但在参数空间里只有一个点。参数空间中的一条曲线通常表示一族不同预测直线，而不是一条弯曲的预测函数。损失曲面的高度也不是某个样本的标签，它已经汇总全部训练样本的误差。

沿用第028讲的单位： x 用 N， y 用 V，物理截距用 V，物理斜率用 V/N。本讲计算、梯度图、欧氏范数和特征值均作用于选定这些单位之后的数值坐标 a, b 。坐标数值可以组成二维向量，但不同物理单位不能被当成同一种量直接相加。更换单位后地图的形状和“同样长的一步”会改变；必须同时变换参数和计算约定。




图1 同一候选模型的三种表示。左边是数据与预测直线，中间每个点代表一条直线，右边给该参数点附上汇总损失。颜色相同表示同一候选，不表示同一个坐标系。

把参数写成列向量 $\theta = (a, b)^T \in \mathbb{R}^2$ 。程序为了方便使用长度为2的一维数组；它在数学上代表列向量，并不意味着可以任意广播成二维数组。数据 x, y 的形状为 $(n,)$ ，预测和残差也必须保持 $(n,)$ 。

3 一个优化问题需要哪些组成部分

本讲选择目标函数

$$J(a, b) = \frac{1}{2n} \sum_{i=1}^n (a + bx_i - y_i)^2.$$

损失非负，单位为 V^2 ；分母中的2只是为了求导方便。第028讲使用观测减预测的残差，这里令 $r_i = a + bx_i - y_i$ ，即预测减观测。两者互为相反数，平方损失相同；导数的符号必须与当前残差定义一起改变。

完整问题应写成 $\min_{\theta \in \Theta} J(\theta)$ 。这里 $\Theta = \mathbb{R}^2$ ，表示没有参数约束。数据在一次优化中固定；参数是可调变量；损失形式和可行域是研究者事先指定的问题。样本数也固定，因此 SSE 、 MSE 和 $J = MSE/2$ 有同一组最优解。若乘以正数 c ，梯度和 Hessian 都乘 c ；如果仍用原来的数值步长，轨迹一般改变。

“最优参数”和“最优值”是两种对象。用 $\operatorname{argmin}_{\theta \in \Theta} J(\theta)$ 表示最优参数集合，用 $J_* = \min_{\theta \in \Theta} J(\theta)$ 表示最低数值。集合可能有一个、多个或无限多个元素。一般问题甚至只有下确界而没有达到它的参数，例如 e^t 在实轴上的下确界为0，却在每个有限 t 处严格大于0。因此不能默认每个光滑目标都存在最小值。

目标函数也不是算法。闭式解、网格搜索和迭代更新是寻找结果的不同计算方式；它们不应在运行途中悄悄改变训练数据、损失归一化或可行域。换成绝对误差或删除截距都定义了新问题。

4 把五点回归展开成一张地图

五个点为 $(0, 1), (1, 2), (2, 2), (3, 4), (4, 6)$ 。直接求和得

$$n = 5, \quad \sum x_i = 10, \quad \sum x_i^2 = 30, \quad \sum y_i = 15, \quad \sum x_i y_i = 42, \quad \sum y_i^2 = 61.$$

展开每一项 $(a + bx_i - y_i)^2$ 后相加，得到

$$J(a, b) = \frac{5a^2 + 20ab + 30b^2 - 30a - 84b + 61}{10}.$$

交叉项 $20ab$ 是倾斜等高线的来源之一：改变斜率会改变全部预测，截距可以补偿其中在样本均值位置的移动。只看 a^2 和 b^2 两项，会漏掉这种联动。

第028讲给出 $\bar{x} = 2$ 、 $\bar{y} = 3$ 、 $S_{xx} = 10$ 、 $b_* = 6/5$ 、 $a_* = 3/5$ 、 $SSE_* = 8/5$ 。代入配平方形式，可以写成更容易读懂的几何表达式：

$$J(a, b) = \frac{4}{25} + \frac{1}{2}(a + 2b - 3)^2 + \left(b - \frac{6}{5}\right)^2.$$

这条恒等式对每一组实数参数成立，绝非只在最优解附近成立。后两项都非负，并且同时为零仅当 $b = 6/5$ 、 $a = 3/5$ 。因此最低值为 $4/25$ ，最优参数唯一。不需要先运行任何优化器，也不需要假定噪声正态。




图2 五点数据的损失曲面与俯视等高线。红星来自闭式解，并非网格搜索猜到的最低点。三维透视图能显示高度，但倾斜和遮挡使精确比较更适合右边的等高线。

5 手算几个位置再相信整张图

先从几组简单坐标检查地图，避免坐标轴交换或少除样本数后仍画出漂亮图。

参数 (a, b)	预测向量	SSE	$J = SSE/10$
(0, 0)	(0, 0, 0, 0, 0)	61	6.1
(1, 1)	(1, 2, 3, 4, 5)	2	0.2
(3/5, 6/5)	(3/5, 9/5, 3, 21/5, 27/5)	8/5	4/25
(3, 0)	(3, 3, 3, 3, 3)	16	1.6
(0, 6/5)	(0, 6/5, 12/5, 18/5, 24/5)	17/5	17/50

例如 $(1, 1)$ 的预测减观测残差为 $(0, 0, 1, 0, -1)$ ，平方和为2。另一条 $(0, 6/5)$ 已经使用最佳斜率，却把整条直线向下移了 $3/5$ ，使损失增加 $\frac{1}{2}(3/5)^2 = 9/50$ ；所以总损失为 $4/25 + 9/50 = 17/50$ 。

从表格不能直接证明全局最优，因为只检查了五组候选；全局证明来自上一节对所有参数成立的配平方恒等式。另一方面，公式证明不能替代程序核验：代码可能根本没有计算公式中定义的那个函数。两种证据各有职责。

最优损失仍大于零，说明没有一条直线穿过全部五点。继续优化同一个直线模型不可能消除这一事实。把程序跑得更久不会使正的数学下界变成0。

6 等高线 怎样读出损失与方向

给定高度 c ，等高线是集合 $\{(a, b) : J(a, b) = c\}$ ；次水平集则为 $\{(a, b) : J(a, b) \leq c\}$ 。在本例中， $c < J_*$ 时二者为空； $c = J_*$ 时只有一个点； $c > J_*$ 时等高线是椭圆，次水平集包括椭圆内部。

令 $h = \theta - \theta_*$ ，则

$$J(\theta) - J_* = \frac{1}{2} h^T H h, \quad H = \begin{pmatrix} 1 & 2 \\ 2 & 6 \end{pmatrix}.$$

如果沿同一条等高线移动，训练损失不变，但参数和逐点预测通常改变。这不是“所有点拟合效果逐点相同”，而是平方误差汇总相同。对于某些候选，一行误差下降、另一行误差上升，恰好保持总值。

等高线的疏密只有在相同的高度间隔、相同坐标尺度和相同绘图范围下才有明确比较意义。用不等间隔的高度或拉伸坐标轴，会改变视觉密度。颜色越深也不一定越差，取决于色标方向；图必须写出色标和高度值。




图3 等高线与次水平集。左图阴影是 J 不超过0.66的参数集合；右图展示同一条等高线上的两组参数及其不同预测线。汇总损失相同并不意味着每个预测相同。

程序使用 `meshgrid` 的 `xy` 约定，得到形状为 (N_b, N_a) 的数组。列索引改变 a ，行索引改变 b ，高度数组每个位置必须对应同位置参数。官方 [NumPy meshgrid 文档](#)明确区分 `xy` 和 `ij`；[Matplotlib contour 文档](#)要求坐标和高度的尺寸相容。画图前检查几个角点，比图出来后靠肉眼猜转置更可靠。

7 从残差推梯度 不只记矩阵公式

对单个平方项应用链式法则， $\partial r_i / \partial a = 1$ ， $\partial r_i / \partial b = x_i$ 。分母中的2与求平方导数产生的2约去：

$$\frac{\partial J}{\partial a} = \frac{1}{n} \sum_i r_i, \quad \frac{\partial J}{\partial b} = \frac{1}{n} \sum_i x_i r_i.$$

梯度是二维列向量。用设计矩阵 $A \in \mathbb{R}^{n \times 2}$ 表示，每行是 $(1, x_i)$ ， $y \in \mathbb{R}^n$ ，则

$$r = A\theta - y \in \mathbb{R}^n, \quad \nabla J(\theta) = \frac{1}{n} A^\top (A\theta - y) \in \mathbb{R}^2.$$

在五点例上，梯度变成

$$\nabla J(a, b) = \begin{pmatrix} a + 2b - 3 \\ 2a + 6b - 42/5 \end{pmatrix}.$$

代入 $(0, 0)$ 得 $(-3, -42/5)^\top$ ，代入 $(1, 1)$ 得 $(0, -2/5)^\top$ ，代入 $(3/5, 6/5)$ 得零。 $(1, 1)$ 处第一分量为零只意味着固定斜率、仅竖直平移直线不能一阶降低损失；斜率方向仍可改进。检查一个偏导为零远远不够。

对单位数值方向 $d \in \mathbb{R}^2$ ， $\|d\|_2 = 1$ ，方向导数为 $D_d J = \nabla J^\top d$ 。根据 Cauchy-Schwarz 不等式，当梯度非零时，在这些等长方向中， $d = -\nabla J / \|\nabla J\|_2$ 使方向导数最小。这里的“最陡”是固定坐标和欧氏长度下的一阶结论。改变坐标尺度或距离定义，会改变最陡方向。

8 梯度为什么垂直等高线

设一条可微曲线 $\theta(t)$ 沿同一高度移动，即 $J(\theta(t)) = c$ 。对 t 求导，链式法则给出

$$0 = \frac{d}{dt} J(\theta(t)) = \nabla J(\theta(t))^\top \theta'(t).$$

因此在梯度非零、曲线切向非零的正常位置，梯度与等高线切向垂直。梯度指向局部升高方向，负梯度指向局部下降方向。在最优点梯度为零，零向量没有可画出的特定方向，不能把自动绘图的微小箭头当成理论方向。




图4 梯度场与切线。左图画归一化后的负梯度箭头，只编码方向；右图在参数点(1,1)画梯度和等高线切线。坐标等比例，否则图上看见的夹角可能失真。

这里的箭头经过归一化，只表示方向，不表示梯度大小或某个算法实际走的步长。若画未经归一化的场，较大的梯度箭头可能遮挡整张图，需要明确比例尺。Matplotlib quiver 文档区分数据坐标方向与显示坐标方向；本讲用 `angles='xy'`，并保持等比例坐标。

“负梯度指向下降”也不能被解释成“沿这个方向走任意远都下降”。在 $(0,0)$ ，若取步长 $\eta = 1/5$ ，一次更新给出 $(3/5, 42/25) = (0.6, 1.68)$ ，损失从6.1降到0.8512，但已经越过最佳斜率1.2。方向描述局部变化，步幅决定落点，这正是后续学习率课程要解决的问题。

9 曲率给出的全局证据

再次求导得到 Hessian：

$$\nabla^2 J = \frac{1}{n} \sum_i \begin{pmatrix} 1 & x_i \\ x_i & x_i^2 \end{pmatrix} = \frac{1}{n} A^\top A.$$

对任意二维方向 $v = (v_a, v_b)^\top$,

$$v^\top \nabla^2 J v = \frac{1}{n} \sum_i (v_a + v_b x_i)^2 \geq 0.$$

因此本讲的最小二乘曲面总是凸的。若至少有两个不同的输入，等号同时要求两条不同 x_i 对应的线性式都为0，相减得到 $v_b = 0$ ，再得 $v_a = 0$ ，所以 Hessian 正定、目标严格凸。这个论证来自数据设计，不来自绘图分辨率。

对任意当前位置 θ 和扰动 h ，二次目标满足精确展开：

$$J(\theta + h) = J(\theta) + \nabla J(\theta)^\top h + \frac{1}{2} h^\top H h.$$

一般光滑函数的二阶展开带有余项；本例的三阶及更高阶导数为零，所以展开在整个参数空间精确成立。若 $\nabla J(\theta) = 0$ ，新增项非负，立刻证明它是全局最优。正定时，所有非零 h 都严格增加损失，于是最优参数唯一。

五点矩阵的特征多项式为 $\lambda^2 - 7\lambda + 2$ ，所以两个特征值为 $(7 - \sqrt{41})/2$ 和 $(7 + \sqrt{41})/2$ ，约为 0.298438 与 6.701562。沿单位特征向量移动长度 t ，损失增加 $\lambda t^2/2$ 。大曲率方向移动一点就涨得快；小曲率方向可以走更远才达到同一高度。不同方向的损失代价不一样，这就是椭圆而不是圆的原因。




图5 两条穿过最优点的特征方向切片。横轴是选定数值坐标中的位移长度，两条曲线使用相同纵横尺度；陡的方向对应较大特征值，不是更多数据点。

在选定坐标下，令 μ 、 L 为最小和最大特征值，则 $\mu\|h\|^2/2 \leq J - J_* \leq L\|h\|^2/2$ 。这让损失差和参数距离发生有条件的联系；如果 μ 很小，同样的损失差仍可能容许较大的参数偏差。小梯度也类似，只有掌握正曲率下界等条件后才能转化为有意义的误差界。Boyd 与 Vandenberghe 的无约束最优化讲义讨论了这种条件与停止判据的联系。

10 坐标变化让谷地看起来不同

定义均值输入处的预测 $m = a + 2b$ ，使用新坐标 (m, b) 。注意第028讲的 $c = a + 2b - 3$ 是相对样本均值的偏移，本节的 m 则是预测本身，两个记号不要混用。逆变换为 $a = m - 2b$ ，因此这只是同一族直线的重新标记，没有改变任何可实现预测。

在新坐标中目标为

$$\tilde{J}(m, b) = \frac{4}{25} + \frac{1}{2}(m - 3)^2 + (b - 6/5)^2, \quad \nabla^2 \tilde{J} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}.$$

交叉项消失，椭圆与坐标轴对齐。再令 $q = \sqrt{2}(b - 6/5)$ ，并以 $m - 3$ 为另一个坐标，等高线就可以画成圆。圆不意味着数据变容易了或模型变真实了，它首先说明我们改变了坐标与长度约定。




图6 同一预测族在原参数与均值参数下的等高线。左图的谷地倾斜，右图的交叉项消失。坐标变换后最优预测相同，但直接采用相同数值步长的梯度法不再是同一条物理参数轨迹。

如果 $\theta = T\phi$ ，链式法则给出 $\nabla_{\phi} J = T^T \nabla_{\theta} J$ 。在 ϕ 中做一步 $\phi^+ = \phi - \eta \nabla_{\phi} J$ ，映射回去是 $\theta^+ = \theta - \eta T T^T \nabla_{\theta} J$ 。除非变换满足特殊条件，这不是原坐标的普通梯度一步。这里的含义是算法依赖坐标约定，不是任意特征缩放都没有代价。训练和部署必须用同一套预处理规则。

11 平谷 不唯一与看不见的参数方向

如果所有 $x_i = 2$ ，数据是 $(2, 1), (2, 2), (2, 4)$ ，则 $\bar{y} = 7/3$ 。配平方得到

$$J(a, b) = \frac{7}{9} + \frac{1}{2}(a + 2b - 7/3)^2.$$

所有满足 $a + 2b = 7/3$ 的参数都达到最低值 $7/9$ 。Hessian 为 $\begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$ ，特征值为 0 与 5。零曲率方向例如 $(-2, 1)$ ：把 a 减少 $2t$ 、 b 增加 t ，全部训练预测都不变。曲面是一条有底部的平谷，没有唯一最低参数点。




图7 常数输入的平谷。左边最优集合是一条直线，右边几组最优参数在训练位置 $x=2$ 预测相同，却在其他输入处分开。零曲率方向是数据无法识别的变化，不是“已经学会所有方向”。

这种退化不会产生虚假的局部低谷：目标仍然凸，局部最优也是全局最优，只是最优集合不再是单点。程序选择 $(7/3, 0)$ 作为可展示代表，同时明确报告 `unique_parameters=false`，不能把代表误称为唯一答案。

从这里可以分清参数误差和预测误差。若两个参数相差 $t(-2, 1)$ ，参数距离随 $|t|$ 增大，但训练预测距离始终为0。对于训练位置之外的 x_0 ，预测差为 $t(x_0 - 2)$ ，却可以任意大。要谈“参数接近”，必须先判断参数是否可识别。

12 局部最优 全局最优与驻点

可行点 θ_* 是全局最优，如果对所有可行 θ 都有 $J(\theta_*) \leq J(\theta)$ ；它是局部最优，如果只需要某个足够小邻域内的可行点满足这一不等式。严格局部最优还要求邻域内其他点都严格更高。驻点只表示梯度为零，定义本身没有提到大小比较。

对无约束可微函数，内点局部最优必为驻点：若存在非零梯度，沿负梯度足够小的一步会下降，与局部最优矛盾。但反过来不成立。 $u^2 + v^2$ 的原点是严格全局最小； $-u^2 - v^2$ 的原点是严格全局最大； $u^2 - v^2$ 的原点是鞍点；它们的梯度都为零。

再看 $F(u, v) = (u^2 - 1)^2 + v^2 + u/5$ 。两个谷底高度不等，较高谷底仍是局部最小，却不是全局最小。还要区分“不凸”与“一定很多坏局部最小”：例如 u^4 是凸的且在0处 Hessian 为0，却仍有唯一全局最小。因此 Hessian 正定是充分条件，不是所有严格最小值的必要条件；Hessian 半正定一般不能单独下结论。




图8 几种驻点和不等高的局部谷底。前三图强调零梯度的不同含义，右图是非凸函数在 $v=0$ 的切片，两个谷底的高度不同。本讲的线性平方损失并不具有右图那样的坏局部谷底。

对凸函数，如果一个局部最小点不是全局最小，就存在更低点；沿连接二者的线段走一点，根据凸性就能在任意小邻域找到更低点，与局部最小矛盾。因此凸问题局部最优必为全局最优。唯一性则还需要额外条件，平谷已经给出反例。不能把“凸”“严格凸”“可微”“存在最小值”当成同义词。

13 为什么还需要有限计算

这道二参数问题有闭式答案，适合当实验的真值参照。更复杂模型未必有闭式解，常用迭代方法生成 $\theta_0, \theta_1, \dots$ 。本讲用最简单的更新探针 $\theta_{k+1} = \theta_k - \eta \nabla J(\theta_k)$ ，目的不是提前穷尽梯度下降理论，而是观察同一个几何目标上不同计算过程会发生什么。

在五点例中，从 $(0, 0)$ 开始， $\eta = 0.2$ 的第一步为 $(0.6, 1.68)$ ；第二步为 $(0.408, 1.104)$ 。相应梯度在第一步处为 $(0.96, 2.88)$ ，所以第二步减去 $(0.192, 0.576)$ 。这组轨迹在谷地两侧移动，随后沿较平缓方向靠近最优点。

把这两轮拆开检查：原点预测全为0，残差 $(-1, -2, -2, -4, -6)$ ，平方和61，梯度由每行 $r_i/5$ 和 $x_i r_i/5$ 分别相加，得到 $(-3, -42/5)$ 。更新到 $(3/5, 42/25)$ 后必须重新前向，预测为 $(3/5, 57/25, 99/25, 141/25, 183/25)$ ，残差为 $(-2/5, 7/25, 49/25, 41/25, 33/25)$ ，平方和1064/125，故 $J=532/625$ ；新梯度为 $(24/25, 72/25)$ 。用这个新梯度更新到 $(51/125, 138/125)$ ，再前向得到残差 $(-74/125, -61/125, 77/125, -7/25, -147/125)$ ，平方和7592/3125， $J=3796/15625$ 。每个样本贡献的两列梯度、每个平方以及两次参数代入，均在练习详解第11题逐行列出，Notebook也按同一流程打印，不能跳过中间计算只记住两个终点。




图9 有限步更新在同一曲面上的行为。左边显示适中步长的前若干步，右边比较独立闭式参照下的二次损失差。过大步长达到保护上限后明确停止，较短预算停下并不等于收敛。

默认脚本的三条路径分别叫 moderate、short_budget 和 too_large。它们都有事先指定的最大更新次数，没有无界 while 循环。moderate 的梯度范数到达 10^{-8} 时停止；short_budget 只允许20次更新；too_large 的候选参数超过数值保护范围时停止。这三种状态分别是“达到约定阈值”“预算耗尽”“保护性终止”，不能统一翻译为“得到正确模型”。

每步都检查有限数值，输出最终梯度范数、参数和损失，而不是把非数值 NaN 当作“小于阈值”。计算完成之后用闭式解检查，而不是把更长的一次迭代当成真值。严格停止规则也不是现实精度保证：数据误差、模型失配和分布改变仍然存在。

数值上直接计算 $J(\theta) - J_*$ 会在二者非常接近时发生抵消，甚至得到微小负值。本讲画收敛图时优先使用 $\frac{1}{2}(\Delta a + 2\Delta b)^2 + (\Delta b)^2$ 。这避免两个近似相等总值相减，但计算机中参照参数本身仍有舍入；程序称其 quadratic_gap，不声称任意病态输入下都是精确证书。

14 网格与停止阈值都是有限观察

二维网格把参数矩形切成有限个点，然后计算每个点的损失。网格上最低点未必是连续目标的最低点；即使图像最深颜色覆盖真最优附近，也不能证明最优已经达到。若网格范围没有包含真最优，图的边缘反而会看起来最低。




图10 两种网格的最低采样点。红星是同一闭式真最优，空心圆是网格最低点。增加分辨率能改善采样定位，但“所有网格点都比较过”仍不是连续问题的全局证明。

二维每轴取 m 个点需要 m^2 次目标评估；如果有 d 个参数，朴素每轴网格需要 m^d 个组合。比如每轴 100 点，二维是一万点，十维是 10^{20} 点。这个计数解释了网格可视化适合低维教学，却不等于高维训练方案。它不是对某台 CPU 性能的实测断言。

梯度阈值也与目标缩放有关。若把目标乘以 10^{-6} ，梯度也乘以 10^{-6} ，相同参数会更容易满足原先的绝对阈值，但预测并没有变化。报告阈值时必须同时报告目标定义、坐标约定和度量。若已知严格正的最小曲率 μ ，二次例中可得 $J - J_* \leq \|\nabla J\|^2 / (2\mu)$ ；不知道这些条件时，单独“梯度很小”不足以说明误差小。

15 约束边界会改变最优条件

现在只允许斜率 $b \leq 1$ ，截距仍任意。原来的 $(3/5, 6/5)$ 不可行。对每个可行斜率，最好的截距依旧为 $a = 3 - 2b$ ；剩余损失为 $4/25 + (b - 6/5)^2$ 。在 $b \leq 1$ 上，离 $6/5$ 最近的斜率是 1，因此新的最优为 $(1, 1)$ ，目标为 $1/5$ 。

此处梯度为 $(0, -2/5)$ ，不是零。负梯度会试图增加斜率，恰好指向不可行区域。因此“最优点梯度为零”只适用于之前的无约束内点条件，不能直接套在边界上。




图11 加入 $b \leq 1$ 的可行域后，最优点移到边界(1,1)。原无约束最优在阴影外；边界处负梯度指向不可行方向。新损失更高是约束改变问题的结果，不是求解器失败。

对任意可行方向 d ，在这个边界必须有 $d_b \leq 0$ ，所以 $\nabla J^\top d = -(2/5)d_b \geq 0$ 。不存在可行的一阶下降方向。在本例的凸集合和凸目标上，这个条件能支持全局结论；完整的约束资格、乘子和 KKT 理论留待后续。不能由这一个半平面例子推出“所有约束问题只要把参数裁剪一下就能解”。

程序 `constrained_reference` 根据闭式消元得到这个答案，没有假装运行通用约束优化器。若输入本身没有可识别的斜率，本节函数明确拒绝套用该唯一解公式。

16 优化误差小 为什么仍可能预测不好

一次训练固定了样本，优化关心的是当前参数相对于该样本最优解的损失差： $J_D(\theta) - \min_{\vartheta} J_D(\vartheta)$ 。统计问题还关心新样本的期望风险 $R(\theta) = \mathbb{E}[(f_\theta(X) - Y)^2]/2$ 。这两个函数定义在同一参数空间，却一般不是同一张地图。

作一个完全指定的教学总体： X 在 0、1、2、3、4 上等概率取值， $Y = 1 + X + \varepsilon$ ，其中 $\mathbb{E}[\varepsilon | X] = 0$ 、 $\mathbb{E}[\varepsilon^2 | X] = 1/4$ 。则展开平方并消去条件均值为 0 的交叉项，有

$$R(a, b) = \frac{1}{8} + \frac{1}{10} \sum_{x=0}^4 [(a-1) + (b-1)x]^2.$$

总体最优是 $(1, 1)$ ，最低风险为 $1/8$ 。五点训练最优是 $(3/5, 6/5)$ ，其总体风险为 $1/8 + 1/25 = 33/200 = 0.165$ 。训练最优在训练表上的损失是 0.16，比总体最优参数的训练损失 0.20 更低；但在已指定的总体中，它的风险反而更高。这是可以逐项核算的反例，不需要靠一句“可能过拟合”代替解释。




图12 两张不同地图的最低点。训练目标最低点与指定教学总体的风险最低点不同。右图中的changed_sample改变了观测值，再精确优化也会得到另一组参数；两组样本只是确定性示例，不是统计保证或真实效果评估。

把标签改成 changed_sample 的 (1, 2, 3, 5, 6)，最优参数变为 (4/5, 13/10)。这次差异来自观测改变，而不是优化器没收敛。所谓“统计误差”在不同理论中有不同的精确定义；本讲只区分样本最优和总体目标，并不把参数距离、超额风险、有限样本偏差混成一个可直接相加的标量。

模型失配又是另一层问题：即使能精确最小化总体直线风险，真实均值可能是一条曲线；可用的直线族本身有限。目标设置错误、数据泄漏、样本不代表部署环境、关联误当因果也不会被更低训练损失修好。研究报告应分别交代问题定义、数值求解证据和新数据评估证据。Bottou、Curtis 与 Nocedal 的作者论文从大规模学习背景讨论计算与统计两方面，但本讲没有用小型实验外推其系统性能。

17 把实验做成可以检查的证据

Notebook 的任务是重新计算这些地图，而非只显示预制图片。先读取并验证所有 CSV 行和 JSON 字段；再独立计算闭式参照、目标、梯度和 Hessian；最后构造网格、画图、运行有限步路径。无效末行或未选中的场景不能被跳过，否则相同文件会因选择不同而偶尔“可用”。

接口先检查原始类型，再转为 float。布尔值、文本、复数、扩展精度、非有限值与可能消失的极小正数不能被默默改成合法参数。CSV 和 JSON 数字从原始十进制词元检查，1e-400 会被拒绝，真正的 0e-400可以接受；重复 JSON 键也拒绝。输入检查不能依赖会被 python -O 移除的 assert。

算法状态与数值结果共同保留。程序对每条路径保留有限历史和最后状态，对不支持的溢出、下溢或范围明确报错。输入无效时，旧输出必须保持原字节不变，且不能创建一个新报告装成成功。正常运行把完整结果序列化之后才原子替换输出文件。

本版提供真实执行过的 Notebook 输出和验证记录，但不把它们当成你本地环境一定可用的保证。Anaconda 的环境文件和浏览器 Jupyter 使用方法是复现路线；制作验证采用新的 Python 进程和真实 ipykernel InProcessKernel，未实际测试 Anaconda 安装或浏览器界面。完整操作与数值合同见独立 lab.pdf 和 README.md。

18 自检练习与后续连接

1. 对五点例区分数据空间、参数空间和损失曲面各坐标的含义。为什么参数空间的一条线通常不代表一条预测直线？

2. 从六个原始求和量展开 J ，再验证配平方式，说明唯一性条件。
3. 手算 $(1, 1)$ 和 $(0, 6/5)$ 的残差、SSE、目标与梯度。
4. 把目标从 J 改为 SSE。最优解、梯度、Hessian、同一步长的更新分别怎样变化？
5. 在 $(1, 1)$ 写一个等高线切向方向和一个下降方向，验证内积关系。为何必须声明坐标尺度？
6. 证明 $H = A^T A/n$ 半正定，并给出正定的充要条件。
7. 求五点 Hessian 的两个特征值，写出损失差和参数距离的上下界。
8. 推导 (m, b) 坐标的目标、梯度与 Hessian。为什么它与原坐标采用相同步长时不是同一算法轨迹？
9. 完整求解三个常数输入点的最优集合、最低损失和零曲率方向。
10. 分别用定义判断 $u^2 + v^2$ 、 $-u^2 - v^2$ 、 $u^2 - v^2$ 、 $u^4 + v^2$ 在原点的性质，解释 Hessian 判别的边界。
11. 手算从原点使用步长0.2的两次更新及每次损失；核对程序没有漏除5。
12. 设网格未包含真最优，怎样从边界最低点诊断这个问题？十维每轴100点需要多少组合？
13. 当路径预算为0、初值正好最优时，应报告什么？若初值非最优呢？说明停止检查的顺序。
14. 求解约束 $b \leq 1$ 的问题，解释为什么最优点梯度不为零以及为什么不能推广成通用裁剪法。
15. 从指定的条件噪声模型推出 R ，比较 $(1, 1)$ 与 $(3/5, 6/5)$ 的训练损失和总体风险。
16. 设计输入失败测试，使最后一个未使用候选、最后一行 CSV 和重复 JSON 键分别被拒绝。说明为什么旧报告不能先被清空。

完整解答在 [answers.pdf](#)。接下来第031讲会把一步中的“方向”和“步幅”分开，对一维二次函数严格推导收敛、震荡与发散区间；第032讲再回到这里的倾斜椭圆，解释多维更新怎样受不同曲率影响。此刻最重要的收获是：一个最优结论必须对应明确的问题、适用条件和可核验证据，不能只对应一张好看的曲面或一行成功状态。

来源与进一步阅读

本文数据、推导组织、图和练习均独立编写，没有复制教材章节或习题答案。以下一手材料用于核验标准定义与软件接口，详细实际访问记录见 [source-checks.json](#)。

- Stephen Boyd 与 Lieven Vandenbergh, [作者教材主页及无约束最优化讲义](#)：凸二次目标、方向、强凸性和停止条件。教材公开阅读不等于可复制其图文或解答。
- NumPy 2.3, [eigvalsh](#)与[meshgrid](#)：对称特征值、数组形状和网格索引约定。
- Matplotlib, [3.10.8 contour](#)与[quiver](#)：等高线和向量场的坐标、尺寸及缩放。[quiver](#) 查询使用稳定文档站，版本与本版实际运行版本不同；使用的核心参数在本地3.10.8执行核验。
- Léon Bottou、Frank E. Curtis、Jorge Nocedal, [Optimization Methods for Large-Scale Machine Learning](#)：计算优化与统计学习背景。该文不是本讲小型实验的外部效果背书。