

第三十一讲 一维梯度下降与学习率

1. 已经知道最优点，为什么还要一步一步走

第28讲用配平方直接求出了最优直线，第30讲把参数变成损失曲面上的位置。现在先只留下一个可动参数，研究一条最简单的更新规则：看当前导数，往相反方向移动一小步。这个步骤看似直观，却没有告诉我们步子多大才合适，更没有自动保证最后能到最优点。

本讲的核心问题是：为什么沿负导数走，以及一步究竟该走多远？我们选择有精确闭式解的一维二次函数，把每轮参数误差写成一个乘法递推。这样既能严格证明收敛范围，也能完整描述不跨过最优点、交替跨越、来回循环和发散。纸笔得到的公式会作为程序的独立参照，而不是让程序用自己的“成功”标签证明自己。

直接先修是第13、28讲的导数、局部近似和回归配平方。需要第8讲的幂、对数和序列记号。这里只研究确定性的全梯度、一维参数与固定学习率；随机梯度、多维曲率和学习率计划将在后面分别处理。小规模CPU实验不说明大模型训练速度或现实预测准确率。

一轮更新必须回答三个不同问题




图1 先知道目标和闭式解，再比较不同学习率产生的路径。正确方向、合适步长、可靠停止是三个问题。

2. 参数、导数、步长各是什么

设目标函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ ，待选择的实数参数为 w 。 w_0 是初始位置， w_t 是完成 t 次更新后的参数， $f(w_t)$ 是该位置的目标值。 t 是非负整数索引，不是样本编号，也不是实际经过的秒数。

梯度下降在一维的规则是

$$w_{t+1} = w_t - \eta f'(w_t), \quad t = 0, 1, 2, \dots$$

η 通常取正数，称学习率或步长系数。真正的参数位移是 $\Delta w_t = -\eta f'(w_t)$ ，不是 η 本身；即使 η 固定，导数变小也会使每轮位移变小。若 w 有单位， f 也有单位， η 的单位需要让 $\eta f'$ 与 w 一致，所以跨目标或跨单位比较“同一个学习率数字”通常没有意义。

这一讲也保留 $\eta=0$ 作为故障对照：它完全不移动。负 η 通常沿上升方向移动，不属于默认下降算法，但会在理论分类里指出其后果。模型参数 w 由优化选择， η 和停止阈值由实验设计事先指定，二者角色不同。

3. 从一阶近似解释负导数

在 f 于 w 可微且 $f'(w) \neq 0$ 时，对足够小的位移 h 有 $f(w+h)=f(w)+f'(w)h+o(|h|)$ 。选 $h=-\eta f'(w)$ ， $\eta>0$ ，则

$$f(w - \eta f'(w)) = f(w) - \eta [f'(w)]^2 + o(\eta), \quad \eta \rightarrow 0^+.$$

主导的一阶变化为负。由于余项除以 η 趋于0，存在某个足够小的正步长范围，使真正目标也下降。这是局部结论：它没有告诉我们任意 η 都能下降，也没有给出从每个位置出发都适用的统一阈值。

负导数不是指向已知最优点的一根完整距离箭头。导数给局部斜率；曲线可能很快弯转，大步走完后的的一阶近似已不准确。若 $f'(w)=0$ ，一阶项为零，这个论证也失效：该点可能是最小点、最大点或其他驻点，必须另看函数结构。




图2 切线预测只控制局部小位移。负导数方向可以正确，大步后的真实函数值仍可能变大。

4. 从五点回归得到唯一的一维主问题

沿用第28讲合成数据 $x=(0,1,2,3,4)$ 、 $y=(1,2,2,4,6)$ 。已知 $\bar{x}=2$ 、 $\bar{y}=3$ 、 $S_{xx}=10$ 、 $S_{xy}=12$ 。对每个斜率 b ，先把截距取到该斜率下的最佳值 $a(b)=3-2b$ 。

把截距消去后， $SSE(a(b),b)=8/5+10(b-6/5)^2$ 。我们本讲使用 $J=SSE/(2n)$ ， $n=5$ ，因此一维目标为

$$f(b) = \frac{4}{25} + \left(b - \frac{6}{5}\right)^2.$$

其导数 $f'(b)=2(b-6/5)$ ，二阶导数恒为2，精确最小点 $b=6/5$ ，最小值 $f=4/25$ 。这里每轮更新 b 后，都用 $a(b)=3-2b$ 配回截距；这叫先消去截距后优化斜率，不等同于把截距固定为0，也不等同于同时对两个参数做梯度下降。

主例的 $b_0=0$ 对应 $a_0=3$ ，是水平线3。所有学习率从同一初始模型出发，目标、数据和损失归一化相同。这样观察到的路径区别才可归因于步长，而不是悄悄换了问题。

把这一步拆到每一行。预测是 $\hat{y}_i(b)=3+b(x_i-2)$ ，残差 $r_i=\hat{y}_i-y_i$ ，单行损失 $\ell_i=r_i^2/(2n)$ 。链式法则逐个节点给出 $\partial \ell_i / \partial r_i=r_i/n$ 、 $\partial r_i / \partial \hat{y}_i=1$ 、 $\partial \hat{y}_i / \partial b=x_i-2$ ，所以每行对共享参数 b 的贡献为 $r_i(x_i-2)/n$ 。五行都依赖同一个 b ，必须把五个贡献相加。这也解释了为什么消去截距后，局部导数是 x_i-2 ，而不是固定截距时的 x_i 。

在 $b_0=0$ 处，五个预测都是3；残差为 $(2,1,1,-1,-3)$ ，平方为 $(4,1,1,1,9)$ ，平方和16，完整目标 $16/10=8/5$ 。五个未除 n 的梯度贡献为 $(-4,-1,0,-1,-6)$ ，合计-12，除5得到 $f'(0)=-12/5$ 。取 $\eta=1/4$ ，位移 $-\eta f'=3/5$ ，因此 $b_1=3/5$ ，再配回 $a_1=3-2b_1=9/5$ 。

这时必须重新前向计算，不能沿用旧残差。新预测为 $(9/5, 12/5, 3, 18/5, 21/5)$ ，新残差 $(4/5, 2/5, 1, -2/5, -9/5)$ ，平方和 $26/5$ ，目标 $13/25=0.52$ 。新梯度的五项分子为 $(-8/5, -2/5, 0, -2/5, -18/5)$ ，合计-6，除5为 $-6/5$ 。下一轮位移 $3/10$ ，得到 $b_2=9/10$ 、 $a_2=6/5$ ；再前向得到预测 $(6/5, 21/10, 3, 39/10, 24/5)$ ，残差 $(1/5, 1/10, 1, -1/10, -6/5)$ ，平方和 $5/2$ ，目标 $1/4$ 。完整链条是“预测→残差→损失与各行局部导数→共享梯度求和→更新→重新预测”，每一轮都重新计算。




图3 先沿每个斜率找到最佳截距，再在一维剖面上更新。主目标曲率为2，最小值不是0。

5. 先推广到可完全求解的二次函数

把主例写进一般形式

$$f(w) = c + \frac{q}{2}(w - w_*)^2, \quad q > 0.$$

w 是唯一最小点， c 是最小值， q 是曲率。它们都是定义问题的固定常数，本讲用它们构造已知答案的教学模型；实际未知问题不能偷偷读取 w 指导求解，再声称只用了梯度。

主例对应 $w=b$ 、 $w=6/5$ 、 $c=4/25$ 、 $q=2$ 。导数为 $q(w-w^*)$ 。令参数误差 $e_t=w_t-w^*$ ，代入更新式可得

$$e_{t+1} = (1 - \eta q) e_t.$$

定义 $\rho=1-\eta q$ ，这个无量纲数同时决定是否跨越最优点以及距离如何变化。所有后续结论都建立在固定 $q>0$ 、固定 η 、精确算术和同一个二次目标之上，不能直接推广到任意函数。

6. 把一轮递推变成任意轮的闭式式子

第一轮 $e_1=\rho e_0$ ，第二轮 $e_2=\rho e_1=\rho^2 e_0$ 。数学归纳给出 $e_t=\rho^t e_0$ ，因此

$$w_t = w_* + \rho^t (w_0 - w_*), \quad f(w_t) - c = \frac{q}{2} \rho^{2t} (w_0 - w_*)^2.$$

目标超额是 $f(w_t)-c$ ，表示尚未消除的优化损失；它与完整目标 $f(w_t)$ 不同。主例有不可消除的训练残差 $c=4/25$ ，所以即使参数无限接近最优点， f 也不会趋于0。

若 w_0 恰好等于 w^* ， $e_0=0$ ，任意有限 η 下都保持在最优点。学习率区间的必要性因此应表述为“对所有初值都收敛”或“对非最优初值”。漏掉这个例外，会把一个带条件的定理写成错误的绝对结论。

7. 不跨越最优点的收敛区间

若 $0<\eta q<1$ ，则 $0<\rho<1$ 。 e_t 保持原符号，绝对值逐轮缩小。起点在最优点左侧，就从左侧靠近；起点在右侧，就从右侧靠近，不会越过最优点。

主例 $\eta=1/4$ 时 $\rho=1/2$ 。由 $b_0=0$ 、 $e_0=-6/5$ ，得到 $b_1=3/5$ 、 $b_2=9/10$ 、 $b_3=21/20$ 、 $b_4=9/8$ 。对应截距 $a=3-2b$ ，依次为3、9/5、6/5、9/10、3/4。每轮参数误差减半，目标超额则乘1/4。

这不意味着“参数每轮都减少”。主例 b 从0增加到1.2附近，因为导数为负。应该说离最优点的误差缩小，而不是把参数大小本身当成进展指标。




图4 $\eta=1/4$ 时误差保持负号并减半；目标超额每轮变为原来的四分之一。

8. 跨越最优点也可以收敛

若 $1 < \eta q < 2$ ，则 $-1 < \rho < 0$ 。误差符号逐轮交替，但绝对值仍按 $|\rho|$ 缩小，参数会从最优点两侧交替逼近。

主例 $\eta = 3/4$ 时 $\rho = -1/2$ ， b 的前五个值为0、9/5、9/10、27/20、9/8。对比 $\eta = 1/4$ ，两条路径的误差绝对值逐轮完全相同，因此目标超额和完整目标也完全相同；一条不跨越，另一条交替跨越。

所以“参数在震荡”不等于“损失在增加”。这组震荡幅度几何缩小，损失单调下降。反过来，只看下降的损失曲线，也无法判断参数有没有跨越最优点。参数路径、误差绝对值与目标值需要分开画。




图5 $\eta = 1/4$ 与 $3/4$ 参数路径不同，目标超额却完全相同。不要把参数震荡和损失震荡混为一谈。

9. 一步到位、两点循环与发散边界

若 $\eta q = 1$ ， $\rho = 0$ 。无论初值如何，一次更新就得到 w^* 。主例 $\eta = 1/2$ 时 $b_1 = 6/5$ 。这是已知恒定曲率的一维二次函数的特殊性质，不是所有可微损失都能凭一个固定 η 一步到位。

若 $\eta q = 2$ ， $\rho = -1$ 。非最优初值在 w_0 和 $2w^* - w_0$ 之间来回，距离不缩小，目标值也不变。主例 $\eta = 1$ 使 b 在0与 $12/5$ 之间循环，目标都等于 $8/5$ ；“每一步都朝负导数方向”仍然不能带来进步。

若 $\eta q > 2$ ， $\rho < -1$ 。对 $e_0 \neq 0$ ，误差绝对值几何增长，并交替越过最优点。主例 $\eta = 5/4$ 时 $\rho = -3/2$ ， b 依次为0、3、 $-3/2$ 、 $21/4$ 、 $-39/8$ ，越来越远。 $\eta = 0$ 使 $\rho = 1$ ，停在起点； $\eta < 0$ 使 $\rho > 1$ ，也会远离最优点。

合起来：对任意非最优初值，固定步长梯度下降在该正曲率二次函数上收敛，当且仅当 $0 < \eta < 2/q$ 。端点不包含在内。程序可以设置范围保护而在发散数值溢出前终止，但这个“保护停止”不能叫收敛。




图6 三个边界或越界对照： $\eta=0$ 停滞， $\eta=1$ 两点循环， $\eta=5/4$ 交替发散。虚线标记同一个最优优点。

10. 不用闭式轨迹也能核对单步损失变化

对本二次函数，设 $g=f'(w)=q(w-w^*)$ ，精确展开得到

$$f(w - \eta g) - f(w) = -\eta \left(1 - \frac{\eta q}{2}\right) g^2.$$

当 $g \neq 0$ 且 $0 < \eta < 2/q$ 时，右侧严格为负； $\eta = 2/q$ 时为0； $\eta > 2/q$ 时为正。它与误差递推给出的区间完全一致，是另一条代数交叉核验路线。

与第3节的一阶近似相比，这里补上了确切的二阶修正项 $\eta^2 q g^2 / 2$ 。 η 变大时，一阶预计收益与二阶代价竞争；到 $\eta = 2/q$ 刚好抵消。这也解释了为什么只看 $-\eta g^2$ 会把过大步长误判为持续有利。

本节是一个具体二次函数的等式，不是对一般函数无条件成立的下降引理。一般的梯度变化上界、L-smooth条件和收敛界留到第33讲；提前知道它们的名字，不能省去条件。

11. “线性收敛”并不是直线速度

若 $0 < |\rho| < 1$ ，误差绝对值是 $|e_0| |\rho|^t$ ，目标超额是初始超额乘 $|\rho|^{2t}$ 。这通常称几何收敛，也常称线性收敛；意思是相邻误差之比固定，不是每轮减去相同数量。

在普通坐标中，曲线先降得快、后降得慢；对正的误差取对数后， $\log |e_t| = \log |e_0| + t \log |\rho|$ ，才是一条直线。主例 $\eta = 1/4$ 或 $3/4$ 的误差每轮减半； $\eta = 1/10$ 的 $\rho = 4/5$ ，下降更慢；接近 $2/q$ 的稳定步长也可能很慢，因为 $|\rho|$ 又接近1。

η 越大不一定越快。一维恒定 q 已知时， $\eta = 1/q$ 让 $|\rho|$ 最小且为0；从这个点继续增大 η 会重新减慢，最后越过稳定边界。高维不可能通常用一个 η 把所有曲率方向同时消掉，下一讲会解释。




图7 左图用 $\rho=1-\eta q$ 显示收缩区间；右图显示精确单步损失变化的符号。学习率越大不一定越快。

12. 需要多少轮：先定义你要的误差

假设 $0 < |\rho| < 1$ ，目标是 $|e_t| \leq \varepsilon$ ， $\varepsilon > 0$ 。若起始误差已经满足要求，最少0轮；否则由 $|\rho|^t |e_0| \leq \varepsilon$ ，取对数得到

$$t \geq \frac{\log(\varepsilon/|e_0|)}{\log |\rho|}.$$

分子和分母都为负，除以负数时不等号方向需要正确处理。最少整数轮数应向上取整，并用原不等式复核边界，避免浮点log的末位误差多算或少算一轮。 $\rho=0$ 需要单独处理：非最优初值1轮到位； $|\rho| \geq 1$ 时，这个收敛轮数公式不适用。

主例 $|e_0|=6/5$ ， $\eta=1/4$ 或 $3/4$ ，若要求参数误差 $\leq 10^{-6}$ ，20轮还不够，21轮满足。若要求梯度绝对值 $\leq 10^{-10}$ ，因为 $|g|=2|e|$ ，需要35轮。不同停止指标对应不同要求，不能把“21轮”当作算法的固定属性。

本实验用Fraction分别检查第t轮满足且第t-1轮不满足，再与浮点计数比较。最大迭代预算是资源保护，不是这个数学最少轮数的替代。

13. 目标乘常数，最小点不变，学习率却应改变

若把目标换成 $\tilde{f}=\kappa f$ ， $\kappa > 0$ ，则最小点不变，但导数变为 $\kappa f'$ ，曲率变为 κq 。要让同一初值产生完全相同的精确参数路径，应取 $\tilde{\eta}=\eta/\kappa$ ，使 $\tilde{\eta}\kappa=\eta$ 。

主例若把 $J=\text{SSE}/(2n)$ 换成SSE， $\kappa=2n=10$ 。原 $\eta=1/4$ 稳定；若错误地继续对SSE用1/4，乘子变成 $1-(1/4) \times 20 = -4$ ，立即发散。把步长改成1/40后，才恢复原来乘子1/2的路径。

加上一个常数与乘上一个常数也不同： $\tilde{f}=f+C$ 不改变导数、参数更新或精确超额，却可能让浮点显示的目标差值更难分辨。报告学习率时应同时报告目标定义和归一化，单独给 η 数字不完整。




图8 同一最小点，目标乘10后若不把学习率除10，稳定轨迹会变成发散。

14. 参数改单位，又是另一种缩放

设新坐标 $v=s \cdot w$ ， $s \neq 0$ ，把同一个目标写成 $g(v)=f(v/s)$ 。链式法则给 $g'(v)=f'(v/s)/s$ ，曲率变为 q/s^2 。在 v 坐标中一步更新，再换回 w ，得到

$$w_{t+1} = w_t - \frac{\eta_v}{s^2} f'(w_t).$$

所以要匹配原坐标学习率 η_w ，必须取 $\eta_v=s^2\eta_w$ 。主例若把斜率数值放大100倍，等价坐标路径需要把学习率乘10000，而不是乘100。若在新旧坐标使用同一个数字 η ，实际上改变了原坐标中的更新幅度。

这不是说任意标准化都应该如此做，而是在明确的一维线性重参数化下推导精确关系。目标乘 κ 导致 η 除 κ ；参数坐标乘 s 导致匹配的 η 乘 s^2 。二者经常被混在一句“改单位”里，本讲把链式法则展开以免记错。

15. 停止准则只能说明它检查的量

对这一个已知 $q>0$ 的二次函数，有 $|g|=q|e|$ ，且 $f-c=g^2/(2q)$ 。因此梯度阈值 $|g|\leq\tau$ 能够换算成参数误差 $\leq\tau/q$ 和目标超额 $\leq\tau^2/(2q)$ 。换算依赖已知正曲率，不是一般函数里的免费保证。

若只检查位移 $|w_{t+1}-w_t|$ ，极小 η 会让位移很小，即使还离最优解很远。 $\eta=0$ 时位移恒为0，却完全没有学习。若只检查目标变化， $\eta=2/q$ 的两点循环每次目标变化为0，也会被误判为完成。

本实验至少保存参数、导数、完整目标、由误差直接计算的目标超额、更新位移和停止原因。达到梯度阈值、预算耗尽、两点循环、浮点停滞与增长保护应使用不同状态。每轮的计数也要说明： w_0 是0轮状态，更新 T 次后才是 w_T 。




图9 小位移、小目标变化和小梯度并不自动等价。两个简单反例就能骗过过于单一的停止规则。

16. 精确收敛与浮点运行不是同一句话

精确数列可以永远保持非零并继续收敛，浮点数却只有离散的可表示位置。接近 w^* 时，一次理论位移可能小于当前位置的一个浮点间隔，减法就返回原值；这时程序停滞，不应把“参数没变”直接当成精确导数为零。

另一个问题是目标差值消失。即使超额 $q e^2/2$ 为正，把它加到较大的常数 c 上也可能舍入为 c ，再做 $f-c$ 得到0。为了教学核对，本实验另外按 $q e^2/2$ 直接计算超额，与减法结果并列，不用后者宣称误差精确为零。

Python的`math.ulp`和`nextafter`可查看附近可表示数；`Fraction.from_float`读取的是已经存储的二进制值，不是原先脑中想要的十进制分数。精确理论轨迹使用CSV里的整数分子/分母，浮点轨迹使用它们明确转换后的值，两种参照必须标明。求解器不应在每轮偷偷用闭式子替代实际更新，再声称测到了累积舍入行为。程序因此保留两套精确参照：原始有理数模型的 $6/5$ 与 $4/25$ ，以及实际存储的float中心、曲率和常数在精确算术下的递推。后者隔离了系数存储误差，但仍不包含每轮乘法、减法的舍入；实际trace才包含这些舍入。

17. 不是二次函数时，刚才的常数区间不能照搬

考虑 $h(w)=w^4$ 。它处处可微且有全局最小点0，但曲率 $12w^2$ 随位置变化，没有全实数范围内的有限曲率上界。在 $w_0=1$ 、 $\eta=1$ 时，梯度为4，更新到-3，目标从1升到81。负导数方向没有错，步长太大使局部预计失效。

再看 $h(w)=-w^2$ ，在 $w=0$ 导数为0却是最大点； $h(w)=w^3$ 在0也有零导数，却不是局部极值。它们说明“梯度为0”需要结合结构解释。这里不是要完整分析这些函数上的全轨迹，只用可手算的反例界定本讲证明的适用范围。

对于一般函数，可能需要控制梯度变化、回溯选步、处理定义域或采用别的算法。后面的课会逐步增加这些工具。现在最重要的习惯是：写清楚证明究竟用了固定曲率、凸性、极小点存在还是其他假设，而不是把一张下降曲线当成定理。




图10 四次函数的一步反例与零导数的非最小点。二次函数的完整结论有明确边界。

18. 纸笔、代码与图如何互相核验

先从五点数据独立计算 $\bar{x}$ 、 $\bar{y}$ 、 S_{xx} 、 S_{xy} 、 SSE_{min} ，得到 $q=S_{xx}/n=2$ 、 $w^*=6/5$ 、 $c=4/25$ 。用分数纸笔计算至少前四轮，再运行直接使用导数的浮点更新。每轮检查理论 $e_t = \rho^t e_0$ ，不能仅核对最后一个打印值。

用 $\eta=0$ 、 $1/10$ 、 $1/4$ 、 $1/2$ 、 $3/4$ 、 1 、 $5/4$ 覆盖主要区间。至少画参数路径、误差绝对值、目标超额与步长分类四种视图。0误差不能直接取log；应明确标记一步到位或在图注中说明显示下限，不让0变成缺失后被误读为失败。

随后比较目标乘10且步长补偿、参数坐标乘100且步长补偿，检查换回原单位的路径；再故意不补偿，展示差异。最后验证坏CSV、末尾非法学习率、JSON非零下溢和重复键等失败输入，在迭代和输出前就被拒绝。

三条参照与实际执行，不能相互冒充




图11 从数据精确剖面到分数轨迹、浮点更新、失效状态与缩放对照，形成可追溯验证链。

19. 为什么优化更准确仍不等于模型更好

把 b 算得更接近 $6/5$ ，只说明更准确解决了这五行数据上的既定平方目标。若直线模型不合适、标签错误或新数据来自另一机制，优化到更多小数位不会自动改善真实预测。

同样，选择某个学习率让20轮训练损失最低，是一个计算选择；若进一步用测试集挑学习率、停止轮数或模型，就涉及验证设计，不能再把同一测试结果当独立证据。这里没有进行真实任务模型选择，也没有声称一维最优学习率可直接用于神经网络。

本讲把优化误差、数值表示误差和统计/模型误差放在不同层次。精确递推解决第一层的理论，浮点对照检查第二层，第三层需要新的数据和假设。把这三层分开，才能知道某个错误应该调整步长、改善计算，还是重新思考任务。



图12 三类误差对应不同证据；梯度下降的停止状态不是模型有效性的证明。

20. 自测与完整验收

1. 写出 w_t 、 η 、 f 和实际位移的含义，说明 η 固定为什么不等于每轮移动距离固定。
2. 从可微的一阶近似严格解释负导数方向的局部下降条件，并说明 $f'=0$ 的例外。
3. 从五点回归的SSE配平方推出本讲的一维 $f(b)$ ，说明截距如何随 b 变化。
4. 对 $c+q(w-w^*)^2/2$ 推导误差递推及任意 t 的参数、目标超额闭式子。
5. 分类 $0<\eta q<1$ 与 $1<\eta q<2$ 的参数行为，解释为什么两者都可有单调下降的损失。
6. 用Fraction写出 $\eta=1/4$ 和 $3/4$ 各前四次更新，比较两条路径每轮目标超额。
7. 分析 $\eta q=0$ 、1、2和大于2的行为，同时写清楚初值已在最优点的例外。
8. 从精确二次展开推导单步目标变化，独立得到稳定学习率范围。
9. 解释“线性收敛”的含义，以及参数误差与目标超额的倍率。
10. 计算主例 $\eta=1/4$ 下达到参数误差 10^{-6} 和梯度 10^{-10} 各需多少轮，并核对前一轮。
11. 目标乘10后，怎样改变学习率才能保持路径？把 J 换为SSE时为什么尤其容易出错？
12. 参数新坐标 $v=100w$ 时，推导匹配原坐标轨迹的学习率，而不是凭直觉猜100倍。
13. 构造小位移却未优化好的例子，以及目标变化0却仍两点循环的例子。
14. 对本二次函数由梯度阈值推出参数误差和超额损失界，说明这些换算的假设。
15. 解释浮点参数停滞和 $f-c$ 变为0的两种机制，以及为什么要单独记录直接计算的超额。

16. 手算 w^4 从1以 $\eta=1$ 更新一步，解释它为什么不反驳二次函数结论。
17. 给出零导数不是最小点的反例，区别驻点和最优点。
18. 设计一组包含区间边界、初值例外、迭代预算与损坏输入的验收测试，解释每种停止状态。

实验指南、可执行Notebook与十八题详解各自独立成文件。下一讲将误差乘子推广到多个曲率方向，解释为什么一维中能一步到位的选择，在多维往往会变成缓慢的之字形路径。

来源与核查范围

- [MIT 6.390 一维梯度下降讲义](#)：核对更新、学习率与实际位移的区别及不同停止指标。本讲回归剖面、分数轨迹和边界证明独立构造，不复制其例题或图。
- [Boyd与Vandenberghe 无约束优化课件](#)：核对下降方向、步长选择、停止准则的角色和相关假设；本讲只证明具体一维二次模型，不借用一般收敛保证。
- [Cornell CS4787 梯度下降讲义](#)：核对曲率限制与驻点不等于全局最优的边界。所有本讲公式由自己的二次展开复核，后续课程再讨论一般下降引理。
- [Python 3.12 math](#)：核对ulp、nextafter、有限值与近似比较接口。
- [Python 3.12 Fraction与浮点表示说明](#)：核对从整数分数与从已存储float建立精确参照的差别。