

032 实验指南 多维梯度下降与尺度

1. 要完成什么以及用什么证据判断

本实验从零实现整批梯度下降，回答“相同目标为何在不同坐标里产生不同的优化路径”。先用四行数据把前两轮预测、残差、损失和三个分量梯度手算清楚，再运行NumPy更新；随后比较原始和标准化坐标的Hessian谱、路径、停止轮数以及映回原单位后的闭式解误差。最后故意制造相关特征、零方差、漏除n和错误预处理，确认哪些结论不成立。

直接先修第014至015、029、031讲。需要Python 3.12、NumPy和Matplotlib；无需GPU、账号、网络数据或训练框架。合成数据不用于真实任务表现论证。建议顺序是纸笔两轮、脚本、Notebook，最后再修改数据。无需先阅读正文也能按照本指南完成实验；推导扩展见lecture.pdf，十八道题逐题解答见answers.pdf。

成功的证据包括：逐样本手算一致，精确有理数参照与NumPy输出一致到合理容差，所有图来自实际更新，原/新坐标比较使用同一单位，错误输入在计算和输出前失败。看到loss变小或程序退出码0，不足以单独验收。

2. 文件与安装

下载本讲完整目录并保持相对结构。experiment.py实现数据验证、训练统计、坐标映射、谱和整批更新；experiment.ipynb含保存的实际计算结果。data/cases.csv有三个四行教学场景，data/query.csv有两条新特征，data/model_spec.json给出完整默认配置。正文的十二幅图在figures/。依赖分别列于environment.yml和requirements.txt。

使用Anaconda或Miniconda时，在本讲目录运行：

```
conda env create -f environment.yml
conda activate ml-course-032
python experiment.py
jupyter lab
```

也可在已有Python 3.12环境运行python -m pip install -r requirements.txt。脚本默认输出outputs/report.json；不需要先建目录。安装依赖可能需要网络，数据已经随包提供，实际计算离线完成。

本版实际运行环境为Python 3.12.14、NumPy 2.3.5、Matplotlib 3.10.8、nbformat 5.11.1、ipykernel 7.4.0。Notebook经新Python进程中的真实InProcessKernel逐格执行。没有实际测试conda创建、浏览器Jupyter界面或套接字内核传输；不要把复现命令理解为这些路径均已测试。

3. 先确认目标和默认数据

目标固定为 $J=SSE/(2n)$ ，残差固定为预测减观测。 $A=[1, x_1, x_2]$ ， $\beta=[a, b_1, b_2]$ 。 A 形状 $(n, 3)$ ， y 、 r 形状 $(n,)$ ， β 和梯度形状 $(3,)$ ， H 形状 $(3, 3)$ 。严禁让 $(n, 1)$ 和 $(n,)$ 自动广播后继续计算。

主例四行 (x_1, x_2, y) 依次是 $(-1, -10, -1.5)$ 、 $(-1, 10, 3.5)$ 、 $(1, -10, 1.5)$ 、 $(1, 10, 8.5)$ 。它来自 $x_1=u$ 、 $x_2=10v$ 、 $y=3+2u+3v+uv/2$ ， u 、 v 取 ± 1 。最优参数 $\beta=(3, 2, 0.3)$ ， $J=0.125$ ， $H=\text{diag}(1, 1, 100)$ 。这些值要用原始求和独立得到，不能把梯度下降终点当真值。

correlated场景把特征换成 $(u, u+v/8)$ ，标签保持不变；constant场景改成 $(u, 7)$ 。它们用于展示标准化仍可能保留相关性或秩缺失。query两行为 $(2, 20)$ 、 $(-2, 30)$ ，仅用于展示复用训练统计和预测，不含测试标签，不承担测试集性能估计。

4. 在运行前完成两次纸笔更新

取 $\beta_0=(0, 0, 0)$ 、 $\eta=1/64$ 。先画四行工作表，每行填预测、残差、 $r^2/8$ 以及 $r(1, x_1, x_2)/4$ 。初始残差为 $(3/2, -7/2, -3/2, -17/2)$ ，四条样本损失为 $(9, 49, 9, 289)/32$ ，总损失 $89/8$ 。梯度贡献按行是：

- 第1行： $(3/8, -3/8, -15/4)$
- 第2行： $(-7/8, 7/8, -35/4)$
- 第3行： $(-3/8, -3/8, 15/4)$
- 第4行： $(-17/8, -17/8, -85/4)$

沿样本相加为 $g_0=(-3, -2, -30)$ 。一次同步更新得到 $\beta_1=(3/64, 1/32, 15/32)$ 。新预测为 $(-299, 301, -295, 305)/64$ ，新残差为 $(-203, 77, -391, -239)/64$ 。逐项平方除8，总和 $64285/8192$ 。

第二轮梯度贡献三列的和为 $(-189/64, -63/32, 135/8)$ ，得到 $\beta_2=(381/4096, 127/2048, 105/512)$ 。新预测为 $(-8273, 8527, -7765, 9035)/4096$ ，新残差为 $(-2129, -5809, -13909, -25781)/4096$ ，总损失 $224099341/33554432$ 。现在再检查 b_2 的两次方向为何相反，以及两个损失为何都下降。

验收时，必须逐行对照prediction与residual数组；“最后参数差不多”不能发现样本顺序错误或中间导数被覆盖的问题。

5. 执行脚本并读懂报告

首次在本讲目录执行python experiment.py。再从另一个当前目录用绝对路径运行脚本，并将--output指向一个新报告路径。默认数据相对脚本位置查找，用户显式传入的--data、--query、--config、--output相对当前工作目录解释。

报告cases含原始/缩放后的Hessian、特征值、条件数、精确秩和闭式参照；paths含六条真正更新的history。每条history从iteration=0开始，长度必须等于updates_completed+1。状态的theta在该路径工作坐标，theta_raw统一映回原坐标。prediction、residual、loss、gradient来自同一状态。

以下停止次数是本版默认输入的实际结果，不能当作一般性能常数：

路径	步长	完成更新	最终状态
raw_dyadic	1/64	1252	达到工作坐标梯度容差
raw_minimax	近似2/101	1092	达到工作坐标梯度容差
scaled_same_rate	1/64	1268	达到工作坐标梯度容差
scaled_half	1/2	29	达到工作坐标梯度容差
scaled_one	1	1	达到工作坐标梯度容差
raw_unstable	1/32	19	下一候选超过参数保护上限

默认梯度阈值 10^{-8} 、预算4000、参数绝对值上限 10^6 。保护发生在提交候选之前，所以raw_unstable最后记录的是已经完成的第19轮，不能写成第20轮已计算成功。success仅在gradient_tolerance_met时为true。

6. 核对谱递推而不替代实际更新

由 $H=\text{diag}(1,1,100)$ ，原坐标 $\eta=1/64$ 的误差倍率为 $(63/64, 63/64, -9/16)$ 。独立参照为 $a_t=3[1-(63/64)^t]$ 、 $b_{1t}=2[1-(63/64)^t]$ 、 $b_{2t}=(3/10)[1-(-9/16)^t]$ 。先用Fraction算前几轮，再与history对照。

程序必须实际先前向、再求残差和梯度、再更新；不能每轮直接代入这些公式后声称验证了数值迭代。Notebook的精确手算单元只作为独立检查。其lstsq单元又用另一条数值解法核验最优参数，并自行重算SSE，不依赖可能为空的residuals返回字段。

$\kappa=100$ 时，所有初值的稳定步长为 $0<\eta<0.02$ 。最坏方向固定步长选择为2/101。JSON不能精确表示无限循环小数2/101，本实验明确存储最近的普通双精度近似；精确数值核验使用该实际float的Fraction，而理论公式仍写2/101。两者不能偷偷混用来指责末位舍入。

7. 重新选步长与共同精度指标

先只用训练数据拟合 $\mu=(0,0)$ 、 $s=(1,10)$ ，得到标准化设计 $[1,u,v]$ 、 $H_s=I$ 。旧步长1/64使所有方向慢慢乘63/64；改成1/2后每轮误差减半；改成1后一次到 $\theta=(3,2,3)$ ，映回 $\beta=(3,2,0.3)$ 。

比较迭代数时至少画两种图：工作坐标梯度的停止计数；共同原单位指标 $E_{\text{pred}}=\|A(\beta-\beta^*)\|/\sqrt{n}$ 首次 $\leq 10^{-8}$ 的计数。后者各路径实际为1252、999、1268、29、1；不稳定路径未达到。用同一个指标后，raw_minimax的999和其梯度停止1092有所不同，这不是矛盾。

再报告最终原参数误差 $\|\beta-\beta^*\|$ ，默认约为 9.86×10^{-9} 、 1.18×10^{-9} 、 7.69×10^{-9} 、 6.74×10^{-9} 、0、不适用为收敛结果。raw_unstable误差约 4.98×10^5 ，必须与失败状态一起展示。

用对数轴时真实0不能取对数。图将目标差显示下限设为 10^{-20} 、参数误差为 10^{-12} 并明确标注；数值报告仍保留真实0。直接用二次差，而不是loss-0.125，避免后者因消去变0后伪造精确收敛。图的显示下限不是误差保证。

8. 四个必须做的反例

第一，漏除 n 。把原 $g=A^T r/n$ 临时改为 $A^T r$ ，仅在Notebook临时变量演示，不覆盖正式脚本。有效步长放大4倍， b_2 方向倍率变为 $-21/4$ 。随后复制全部训练样本一次，正确平均梯度不变，错误求和梯度再翻倍。

第二，相关性。读取correlated场景，确认原条件数约258.012，标准化后约257.996。单位方差不意味着列正交。用 $\rho=8/\sqrt{65}$ 独立算 $1\pm\rho$ 及比值，和数值结果比较。

第三，零方差。constant的第二列全为7，fit_scaler返回均值7、尺度1、zero_variance=true；transform后训练列全为0。精确秩2，条件数记null，不伪造有限 κ 。数值极小负特征值不是非凸证据。

第四，L2坐标改变。 $\lambda=1$ 、截距不惩罚，原坐标普通L2得到(3,1,30/101)，标准化普通L2映回(3,1,3/20)。比较四条预测；再把标准化惩罚权重改为(1,1/100)，确认恢复原解。解释每种实验究竟换了优化路径还是目标本身。

9. 训练预处理不能看未来

对query调用transform(query, train_scaler)，结果应为[[2,2],[-2,3]]。用闭式原系数预测13和8。作为反例，另建一个临时scaler在“训练+query”上fit，观察训练特征和统计量如何变化；不能把这个临时结果当作正确训练流程。

不要只因预处理不读 y 就认定无泄漏。交叉验证也应逐折fit；预测时连同模型保存训练均值和尺度。常数训练列在新样本上不同，依然使用旧均值和尺度，不能现场重拟合。本实验没有测试标签，更不能依据query两行宣称预测精度。

10. 输入合同与失败保护

外部实数仅接受Python int/float、NumPy普通整数与float16/32/64；bool、文本、复数、Decimal/Fraction、object及扩展浮点被拒绝。检查发生在转换前。外部非零量绝对值至少 10^{-100} ，一般最大 10^6 。通用矩阵接口2至200行、最多8列；加载距时最多7个特征。文件实验固定两个特征、三个具名场景；query至少两行。

学习率0至2、梯度容差0至1、预算0至10000、参数保护1至 10^6 、路径1至12条。0步长允许用于停滞反例，0预算允许检查初值；0容差不代表浮点必能达到精确驻点。学习率和其他参数仍需满足非零输入下限。计算中非零乘积、平方及正方差若下溢为0或次正规值会报错，浮点超范围也会拒绝。该范围是保守教学合同，不是通用优化器的性能边界。

JSON拒绝重复键、NaN、Infinity和非零下溢词元；CSV也检查原始文本。1e-400须失败，0e-400是真实零可通过。已经在调用前变成0的Python表达式1e-400，函数无法复原它的原意；这正是从原始文件检查的重要性。

分别修改“最后一条路径”与“未用于GD的constant场景”后运行，确认仍在求谱、标准化和迭代前拒绝。为输出预写sentinel内容，再用坏输入运行，原输出不得变化；指向不存在的新目录时，失败不得创建目录。指定包内源文件作为--output也应拒绝。所有验证必须在python -O下同样生效，不能依赖assert。

11. Notebook顺序执行与交付检查

重启内核并从首格顺序执行。第一格导入模块、核对cases.csv、query.csv、model_spec.json三个完整文件哈希，然后验证所有输入，之后才打印版本和数据。若更改输入，即使只变一条未画图的路径，也会在固定手算结论出现前失败。要做自定义实验可用脚本，或复制Notebook并同步修改讲解、手算及基准合同。

Notebook保留八张实际计算的PNG图，分别检查前向/导数、路径、谱、缩放映回、共同误差、相关性、预处理以及惩罚变化。图不是正文PNG文件的重贴，也不是运行前预存结果。重新执行后确认没有error输出、执行编号连续、每张图的标签与数值一致。

最终自检：两次手算逐项一致；谱与条件数合理；六条停止状态如实；共同指标比较使用原单位；标准化没有用query拟合；常数列不假装满秩；L2变换明确；正常与-O新进程结果一致；坏文件没有任何新输出。满足这些证据后，再进入下一讲的一般光滑函数理论。