

第033讲 下降条件与收敛分析

1 一张下降曲线还欠缺什么

第031讲把一个一维二次函数的误差写成乘法递推，第032讲把同一思想推广到多个曲率方向。现在不再假设函数恰好是二次式。我们要回答：什么时候能够证明下降，证明依赖什么，最后证明的是目标差、梯度小，还是参数接近？

本讲直接先修是第015至016讲的Hessian、范数、极限和基本证明，以及第031至032讲的梯度更新。需要能读懂向量内积和一元微积分基本定理。每条结论都会列出假设、受控量和迭代索引；不能仅因某张图看起来像下降，就宣布一般函数都收敛到全局最优。

贯穿全讲的可手算主例为 $f(u,v)=(u^2+4v^2)/2$ ，从(2,1)开始。我们逐个中间量计算两轮，再把它与一般上界比较。另用一个凸但不全局强凸的函数、一个光滑非凸函数，以及破坏假设的例子，检查哪些结论还能留下。全部是确定性合成数学实验，不评价真实预测或大模型训练速度。




图1 每一级假设增加不同证据；下降、驻点和全局最优不是一个结论。

2 先固定符号 形状与三个误差量

设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微，参数列向量 $w \in \mathbb{R}^d$ ，梯度 $g(w) = \nabla f(w) \in \mathbb{R}^d$ 。内积 $g^T h$ 为标量，欧氏范数 $\|h\|_2 = \sqrt{\Sigma h^2}$ 。更新 $w_{t+1} = w_t - \eta g_t$ ，其中 $\eta > 0$ 固定， $g_t = \nabla f(w_t)$ 。 w_0 是初始状态，完成 T 次更新得到 w_T 。

若最小值达到，记某个最优点 w 和最小值 $f = f(w)$ 。目标差 $\delta_t = f(w_t) - f$ 是非负标量；梯度范数 $\|g_t\|$ 说明当前位置是否近似驻点；距离 $d_t = \|w_t - w^*\|$ 说明参数离选定最优点多远。三者单位也不同，不能把同一个阈值数字直接互换。

如果最小值不一定达到，仍可能有有限下界 f_{low} ，满足所有 w 都有 $f(w) \geq f_{\text{low}}$ 。后面的非凸梯度界只需这个下界，不必假设存在 w ；凸目标差界则明确要求最优点存在。若最优点不唯一，“到哪个 w 的距离”要说明，不能自动理解成唯一参数误差。

3 L光滑究竟约束什么

本讲称 f 为 L 光滑，指在全空间有

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2, \quad x, y \in \mathbb{R}^d, \quad L > 0.$$

它限制梯度随位置变化的速度，不限制梯度本身一定小，也不等于函数值对距离是 L -Lipschitz。

$f(w)=w^2/2$ 的梯度差满足 $L=1$ ，但函数值差随位置增大，没有全实数范围内统一的函数值Lipschitz常数。

若 f 二阶连续可微，在凸区域中，Hessian算子范数处处 $\leq L$ 可推出上述条件。非凸时要控制所有特征值的绝对值，而不只是最大特征值的上界。例如 $-100w^2$ 的Hessian是 -200 ，虽然“二阶导数 ≤ 1 ”成立，梯度却不是 1 -Lipschitz。若 f 凸，Hessian半正定，才可以用 $0 \leq H \leq LI$ 简洁表示。

一个有效 L 不必是最小的。主例 $H=\text{diag}(1,4)$ ，最小全局 L 为 4 ， $L=8$ 也有效但较保守； $L=1$ 不是有效证书。有限网格上的最大曲率只核对这些点，不能自动升级成全域上界。




图2 光滑限制梯度变化；非凸Hessian必须控制绝对特征值，而不只看正向上界。

4 下降引理 第一步把多维线段变成一维函数

固定两个点 x, y ，令 $h=y-x$ ，沿连接线段定义 $\phi(s)=f(x+sh)$ ， $0 \leq s \leq 1$ 。链式法则给 $\phi'(s)=\nabla f(x+sh)^T h$ 。由微积分基本定理，

$$f(y) - f(x) = \int_0^1 \nabla f(x + sh)^T h \, ds.$$

在积分中加上并减去 $\nabla f(x)$ ，常量部分积分后就是 $\nabla f(x)^T h$ 。因此

$$f(y) - f(x) - \nabla f(x)^T h = \int_0^1 [\nabla f(x + sh) - \nabla f(x)]^T h \, ds.$$

这一步没有忽略余项，而是把一阶近似的误差准确写成积分。只说“泰勒近似”却不控制余项，不能证明有限步长的下降。

5 下降引理 第二步逐项控制余项

用Cauchy-Schwarz不等式，积分被积项绝对值至多是两个向量范数的乘积。再用L光滑性，梯度差至多 $L\|sh\|=Ls\|h\|$ 。于是

$$\begin{aligned} |f(y) - f(x) - \nabla f(x)^\top h| &\leq \int_0^1 Ls \|h\|_2^2 ds \\ &= \frac{L}{2} \|h\|_2^2. \end{aligned}$$

取其中的上侧界，得到下降引理

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|_2^2.$$

到这里尚未使用凸性。它给一个“当前切平面加二次弯曲”的上界，控制沿一整段有限位移的一阶误差；它不保证函数在切平面上方，那是凸性提供的另一方向的不等式。

The remainder is controlled, not discarded

Exact line integral

$$f(y) - f(x) = \int_0^1 \nabla f(x + sh)^\top h \, ds$$



Subtract tangent

$$R = \int_0^1 [\nabla f(x + sh) - \nabla f(x)]^\top h \, ds$$



Cauchy + L-smooth

$$|R| \leq \int_0^1 Ls \|h\|^2 \, ds = L \|h\|^2 / 2$$



Choose $h = -\eta g$

$$f(w^+) \leq f(w) - \eta(1 - L\eta/2) \|g\|^2$$

图3 从精确积分余项到二次上界，逐行指出链式法则、内积不等式和光滑假设的位置。

6 把实际更新代进去 何时严格下降

在下降引理中令 $x=w_t$ 、 $y=w_t-\eta g_t$ ，位移为 $-\eta g_t$ 。线性项等于 $-\eta \|g_t\|^2$ ，二次项等于 $L\eta^2 \|g_t\|^2/2$ ，因此

$$f(w_{t+1}) \leq f(w_t) - \eta \left(1 - \frac{L\eta}{2}\right) \|g_t\|_2^2.$$

若 $0 < \eta < 2/L$ 且 $g_t \neq 0$ ，右侧严格小于旧目标，所以真实目标必下降； $g_t=0$ 时更新不动。 $\eta=2/L$ 只得到不增加的上界，不能保证严格下降或收敛。超过 $2/L$ 时，这个上界不再保证下降，不意味着每个具体初值都一定上升。

为方便后续证明，选择更保守的 $0 < \eta \leq 1/L$ 。此时 $1 - L\eta/2 \geq 1/2$ ，有

$$f(w_{t+1}) \leq f(w_t) - \frac{\eta}{2} \|g_t\|_2^2.$$

不要把“可证明严格下降的区间”和“本讲用来推简单收敛界的步长区间”混为一谈。 $\eta=1/L$ 不是一般所有问题中的最优步长，只是结构清楚的安全选择。

7 主例完整走两轮 并检查上界的松紧

主例 $f(u,v)=(u^2+4v^2)/2$ ，梯度 $(u,4v)$ ，Hessian diag(1,4)，最优(0,0)， $f^*=0$ ， $L=4$ ， $\mu=1$ 。取 $\eta=1/4$ 。从 $u_0=2$ 、 $v_0=1$ 开始：两个平方中间量为4和1，两个目标贡献为2和2，合计 $f_0=4$ 。局部链式法则给 $\partial(u^2/2)/\partial u=u=2$ ， $\partial(4v^2/2)/\partial v=4v=4$ ，所以梯度(2,4)，平方范数 $4+16=20$ 。

两个参数同时更新： $u_1=2-(1/4)\times 2=3/2$ ， $v_1=1-(1/4)\times 4=0$ 。重新前向， $u_1^2=9/4$ 、 $v_1^2=0$ ，目标贡献 $9/8$ 与0，总目标 $9/8$ 。新的梯度是(3/2,0)，不是继续使用旧(2,4)；新平方范数 $9/4$ 。

把局部计算图明确写成 $a=u^2$ 、 $b=v^2$ 、 $c=a/2$ 、 $d=2b$ 、 $f=c+d$ ，局部导数依次 $2u$ 、 $2v$ 、 $1/2$ 、 2 以及两个相加端的1；沿各分支连乘后组成同一目标的梯度 $(u,4v)$ 。 $t=1$ 时这些局部导数变成3、0、 $1/2$ 、 2 、1、1，故总梯度必须重新得到(3/2,0)。

第二轮更新 $u_2=3/2-(1/4)\times(3/2)=9/8$ ， $v_2=0$ 。再前向， $u_2^2=81/64$ ，目标 $81/128$ ，梯度(9/8,0)，梯度平方 $81/64$ 。因此三个状态的目标依次4、 $9/8$ 、 $81/128$ ，距离平方依次5、 $9/4$ 、 $81/64$ 。

第一步下降引理给上界 $f_1\leq 4-(1/8)\times 20=3/2$ ，而真实 $9/8$ 更低，差为 $3/8$ 。第二步给 $f_2\leq 9/8-(1/8)\times 9/4=27/32$ ，而真实 $81/128$ 更低。有效界不必每次取等号；观测到更快下降不等于定理错误。




图4 两轮实际值与每步下降上界并列；上界高于真实值是保证留出的余量。

8 只需光滑和下有界 可以证明什么

假设 f 全局 L 光滑、有有限下界 f_{low} ，固定 $0<\eta\leq 1/L$ 。把上一节每步下降式从 $t=0$ 到 $T-1$ 相加， $T\geq 1$ 。左边是 $\eta/2$ 乘梯度平方和；右边相邻函数值抵消，留下

$$\frac{\eta}{2} \sum_{t=0}^{T-1} \|g_t\|^2 \leq f(w_0) - f(w_T) \leq f(w_0) - f_{\text{low}}.$$

最小的一项不大于平均，故

$$\min_{0 \leq t < T} \|g_t\|^2 \leq \frac{2[f(w_0) - f_{\text{low}}]}{\eta T}.$$

取 $\eta=1/L$ 后右侧为 $2L(f_0-f_{\text{low}})/T$ 。这个 $1/T$ 界控制的是“前 T 个被求梯度的状态中最小梯度平方”，不是直接控制最终目标差，也不是直接控制最后一个参数距离。要让某个梯度范数 $\leq \varepsilon$ ，需要 $T \geq 2L(f_0-f_{\text{low}})/\varepsilon^2$ ，注意平方导致 ε^{-2} ，而不是 ε^{-1} 。

在全局假设和无限精确迭代下，梯度平方和有限还推出 $\|g_t\| \rightarrow 0$ ；但这仍不证明参数序列一定收敛到唯一点，更不证明到全局最小。有限浮点程序还会受预算、停滞和数值范围影响。

9 一个完全光滑却停在最大点的例子

取 $f(w)=1+\cos w$ 。导数 $-\sin w$ ，二阶导数 $-\cos w$ ，绝对值 ≤ 1 ，因此全局 $L=1$ ；函数下界0在奇数倍 π 处达到。但是从 $w_0=0$ 开始，梯度恰为0，所有更新都停在0，函数值一直为2，这是局部及全局最大值。

非凸梯度界没有被违背：左边最小梯度平方就是0，确实 $\leq 4/T$ 。它从来没有承诺函数值趋于0。这个例子比“某个随机初值没训练好”更明确，因为每一步和界都能独立计算。

再从 $w_0=1$ 、 $\eta=1$ 开始做有限更新，可以看到另一条下降路径，但不能凭这条路径把该非凸函数改称凸，也不能从某次成功推出任意初值都全局成功。程序将0初值与1初值都保留，区分状态与理论保证。




图5 同一个L光滑非凸函数，两种初值；零梯度在最大点也可出现。

10 凸性增加一条全局下界

f 凸意味着任意两点连线上的函数值不高于端点函数值的线性插值。可微凸函数满足

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

取 $y=w$ ，整理得 $\delta_t \leq g_t^\top (w_t - w)$ 。它把当前函数差与朝最优点方向的内积联系起来。注意这是对全部点成立的全局结构，不是某个位置的Hessian恰好半正定。

仅有凸性并不保证最优点存在，例如 $\exp w$ 在全实数上凸且下界0，但没有有限 w 达到0；它也不保证最优点唯一，例如恒零函数处处最优。后续凸收敛界明确增加“存在一个最优点 w^* ”，强凸部分再讨论唯一性。

凸与光滑是不同性质： $|w|$ 凸但在0不可微； $1+\cos w$ 光滑但非凸；主例兼具凸与光滑。它们分别提供下方切平面与上方二次包络，两个方向都要保留。




图6 凸性下方切平面与光滑性上方二次包络，共同夹住函数。

11 凸光滑的关键一步 用距离做账

假设 f 凸、 L 光滑、最优点存在， $0 < \eta \leq 1/L$ 。先由下降式 $\delta_{t+1} \leq \delta_t - \eta \|g_t\|^2/2$ ，再用凸性 $\delta_t \leq g_t^\top e_t$ ，其中 $e_t = w_t - w^*$ ，得到

$$\delta_{t+1} \leq g_t^\top e_t - \frac{\eta}{2} \|g_t\|^2.$$

把更新后的距离平方完整展开，不省略交叉项：

$$\|e_t - \eta g_t\|^2 = \|e_t\|^2 - 2\eta g_t^\top e_t + \eta^2 \|g_t\|^2.$$

移项并除 2η ，右侧刚好成为

$$g_t^\top e_t - \frac{\eta}{2} \|g_t\|^2 = \frac{\|e_t\|^2 - \|e_{t+1}\|^2}{2\eta}.$$

因此 $\delta_{t+1} \leq (d_t^2 - d_{t+1}^2)/(2\eta)$ 。这不是声称函数差等于距离差，而是用一个可相消的距离量给它记上界；非负 δ 还意味着到该最优点的距离在这组条件下不增加。

12 相加得到O—比T 必须看清最终索引

从 $t=0$ 到 $T-1$ 相加上一式，得到 $\sum_{t=0}^{T-1} \delta_{t+1} \leq (d_0^2 - d_T^2)/(2\eta) \leq d_0^2/(2\eta)$ 。由于本步长保证函数值不增加， δ_T 不大于 δ_1 到 δ_T 中的每一项，所以 $T\delta_T \leq$ 该和。最终得到

$$f(w_T) - f_* \leq \frac{\|w_0 - w_*\|^2}{2\eta T}$$

这里最后的公式只写一个实际界：当 $\eta=1/L$ 时，它等于 $Ld_0^2/(2T)$ 。T必须至少1；T=0只能报告初始状态，不能除0或伪造界。界控制最后一次目标差，而上一节非凸式控制一批梯度平方的最小值，两者对象不同。

为了观察“凸但不全局强凸”，取 $h(w)=\sqrt{1+w^2}-1$ 。 $h'=w/\sqrt{1+w^2}$ ， $h''=(1+w^2)^{-3/2}$ ，始终正且 ≤ 1 ，所以凸、 $L=1$ 、唯一最优0；但 h'' 随 $|w|$ 增大趋0，没有全实数范围内正 μ 。用 $\eta=1$ 、初值4检验 $\delta_T \leq 8/T$ 。特定轨迹可能远快于这个全局界，不能仅凭快曲线推断全局强凸。




图7 凸但非全局强凸的函数与实际目标差，和 $8/T$ 上界分开显示。

13 强凸究竟多增加了什么

μ 强凸是指存在 $\mu>0$ ，对所有 x 、 y 满足

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

在二阶连续可微全空间情形，这相当于Hessian处处 $\geq \mu I$ 。比凸性多出一个严格正的二次下界。若两个不同点都最优，强凸对它们中点给严格更小目标，矛盾，因此最优点至多一个。存在性也可解释：固定 $x=0$ ，强凸下界为 $f(0) + \nabla f(0)^\top y + \mu \|y\|^2/2$ ；二次项最终压过线性项，所以 $\|y\| \rightarrow \infty$ 时 $f(y) \rightarrow \infty$ 。连续函数的非空闭子水平集于是有界且紧，极小值在其中达到。这才得到本讲全空间条件下唯一最优点存在。

把 x 换成最优点 w ，梯度为0，得到 $\delta(w) \geq \mu \|w - w\|^2/2$ 。这时目标差终于能上界参数距离：距离 $^2 \leq 2\delta/\mu$ 。若只知道凸而没有正 μ ，不能随意沿用这个换算。

主例 $\mu=1$ 有效，任何 $0<\mu \leq 1$ 也有效但更保守；声称 $\mu=2$ 则在 u 方向失败。 L 和 μ 必须与同一目标、同一欧氏坐标和同一归一化对应。目标乘 κ 会使 L 与 μ 同时乘 κ ，条件数 L/μ 不变，但安全步长要除 κ ；改变参数坐标一般也改变条件数。

14 从强凸推出梯度与目标差的关系

固定 x ，把强凸右侧看成位移 $h=y-x$ 的二次函数。配方得

$$f(x) + g^\top h + \frac{\mu}{2} \|h\|^2 = f(x) - \frac{\|g\|^2}{2\mu} + \frac{\mu}{2} \left\| h + \frac{g}{\mu} \right\|^2.$$

最后一项非负，所以所有 y 都有 $f(y) \geq f(x) - \|g\|^2/(2\mu)$ 。对 y 取最小，得到 $f^* \geq f(x) - \|g\|^2/(2\mu)$ ，整理为 $\|g\|^2 \geq 2\mu\delta$ 。这一步既指出了用了强凸，也指出“最小化右侧二次式”的具体位置 $h=-g/\mu$ ，不依赖只报一个定理名字。

另一方面，光滑上界取 $h=-g/L$ 给 $f(x-g/L) \leq f(x) - \|g\|^2/(2L)$ ，而 $f^* \leq f(x-g/L)$ ，故 $\|g\|^2 \leq 2L\delta$ 。合起来 $2\mu\delta \leq \|g\|^2 \leq 2L\delta$ 。对主例，这两端通常不同时取等号；只沿 u 轴或只沿 v 轴时分别能达到一个端点。

15 强凸光滑目标的几何收敛界

把 $\|g_t\|^2 \geq 2\mu\delta_t$ 代入下降式，得到 $\delta_{t+1} \leq \delta_t - \eta\mu\delta_t = (1-\eta\mu)\delta_t$ 。在 $0 < \eta \leq 1/L$ 且 $0 < \mu \leq L$ 下，系数落在 $[0,1)$ ，重复递推给

$$\delta_T \leq (1 - \eta\mu)^T \delta_0.$$

取 $\eta=1/L$ ，倍率 $1-\mu/L=1-1/\kappa$ ， $\kappa=L/\mu$ 为条件数。使用 $1-z \leq e^{-z}$ 还得到 $\delta_T \leq e^{-T/\kappa} \delta_0$ 。因此在 $\delta_0 > \varepsilon > 0$ 时， $T \geq \kappa \log(\delta_0/\varepsilon)$ 是一个充分预算；上取整后仍应用原始不等式检查，不能把最坏界所需轮数当成具体轨迹首次达标轮数。

主例 $\kappa=4$ ，一般界 $\delta_T \leq 4(3/4)^T$ 。实际 $T \geq 1$ 后只有 u 方向残留， $\delta_T = 2(3/4)^{2T}$ ，更快。若 $\mu=L$ 且 $\eta=1/L$ ，一般界倍率0，至少一步后的目标差为0，应单独处理，不能对 $\log 0$ 做普通计算。初始已满足目标也应记0次，而非强行套正轮数公式。




图8 同一主例同时画实际目标差、凸 $1/T$ 界与强凸几何界。定理界不等于实际收敛曲线。

16 怎样破坏假设 并准确解释失败

第一类是步长过大。主例从(0,1)沿高曲率方向开始， $\eta=1/2$ 时 v 在 ± 1 循环，目标 2 不变； $\eta=3/4$ 时 v 乘 -2 ，目标每轮乘 4 。有效 $L=4$ 没变，失败来自 η 超出所用条件，而非 L 光滑突然消失。

第二类是假常数。对同一主例宣称 $L=1$ ，在 $x=(0,0)$ 、 $y=(0,1)$ 时，真实 $f(y)=2$ ，而所谓二次上界只有 $1/2$ ，立刻失败。声称 $\mu=2$ ，在 u 轴从 0 到 1 时，真实目标 $1/2$ 低于强凸下界 1 ，也失败。应该把假证书单独标成不满足假设，不能让代码因为用户填了一个数字就宣布定理适用。

第三类是没有全局 L 。 w^4 的二阶导数 $12w^2$ 无全域上界；从 1 以 $\eta=1$ 一步到 -3 ，损失 $1 \rightarrow 81$ 。若只给一个局部区域的 L ，必须确保整个更新线段都在该区域，不能只检查起点曲率后跨出区域。

第四类是不可微。 $|w|$ 在 0 没有通常导数，给它随意指定一个“导数”再套本讲证明是不合法的；次梯度方法有自己的定理，后续另学。破坏某个假设并不意味着算法必定失败，而是这条证明不再提供保证。




图9 过大步长、假的 L 或 μ 、区域外更新和不可微，分别在哪一步切断证明。

17 数值检验如何不冒充数学证明

程序同时输出 f_t 、梯度范数、距离、下降式右侧、所检界的差值和假设标签。对二次主例用Fraction独立核对完整路径、下降余量、凸界和强凸界；对含根号函数用高精度Decimal作独立参照；三角函数的浮点轨迹用已证明的全局曲率与有限误差核验，不把网格采样当作证明全域性质。

接近最优时 f 可能很小，直接用“允许误差 $1e-8$ ”会把比 $1e-8$ 小很多的错误全部盖住。比较必须结合数量级，尽可能保存非负分量或高精度差值。 $h(w)=\sqrt{1+w^2}-1$ 在小 w 会抵消，可等价写成 $w^2/(\sqrt{1+w^2}+1)$ ，但乘方自身下溢时仍要明确失败。

下降式右侧也会抵消。根号函数记 $r=\sqrt{1+w^2}$ ，可把 $h-g^2/2$ 等价写成 $w^4(2r+1)/[2r^2(r+1)^2]$ ；程序采用这个正量，同时保留直接相减值作为诊断。默认凸轨迹只实际完成9步，最后目标仍约 2.504×10^{-267} ；下一次非零数学更新超出浮点可保留范围，明确停止而不添加假零。非凸初值 1 实际完成5步后在存储 π 处舍入停滞，此处梯度和目标均非精确 0 。

每个界都有前提。T=0不输出1/T界；不满足凸性的函数不输出凸目标差保证；没有正 μ 就不输出强凸几何保证；数字超界不应生成“成功”报告。输入全部验证后才计算，最后才原子写出结果；Notebook若叙述固定主例，须完整校验默认输入字节。

Different evidence answers different questions

Mathematics

Global assumptions + proof $\rightarrow$ uniform conclusion



Independent references

Fraction trajectories; Decimal stable values + derivatives



Finite implementation

Type/range checks $\rightarrow$ updates $\rightarrow$ explicit stop reason



Delivery evidence

Fresh script + real kernel + every rendered page

图10 实验分别核对公式、数值实现与停止状态；有限采样从不替代全域证明。




图11 前向和下降上界的稳定代数式能延后抵消，但无法消除有限数值范围。

18 自测与完整验收

1. 定义目标差、梯度范数与参数距离，说明非凸梯度界为何只需有限下界。
2. 区分梯度Lipschitz与函数值Lipschitz，并给出二次反例。
3. 解释非凸Hessian为何必须控制算子范数，不能只写 $H \leq LI$ 。
4. 沿线段定义 ϕ ，完整推出一阶余项的精确积分表示。
5. 逐步用内积不等式和L光滑性推出下降引理，标明所有假设。
6. 代入更新，分别解释 $0 < \eta < 2/L$ 与 $0 < \eta \leq 1/L$ 两个区间。
7. 完整手算主例两次更新、三次前向、梯度平方和以及每步下降上界。
8. 逐项写出函数值相消，推出前T个梯度平方最小值的界。
9. 为什么梯度范数 ε 的充分复杂度包含 ε^{-2} ？最小值索引是哪几个状态？

10. 用 $1+\cos w$ 从0出发说明小梯度不等于全局最优。
11. 写出凸性的一阶下界，并解释凸性不自动保证存在或唯一最优点。
12. 展开更新后的距离平方，推出凸光滑的单步距离记账式与最终 $1/T$ 界。
13. 证明 $\sqrt{1+w^2}-1$ 凸、1光滑，却不全局强凸；给出初值4的界。
14. 用配平方从强凸定义推出 $\|g\|^2 \geq 2\mu\delta$ ，再从光滑性推出另一侧界。
15. 推导强凸几何率、指数松界和充分预算，分别处理 $\mu=L$ 与初始达标。
16. 给出错误 $L=1$ 和错误 $\mu=2$ 的具体反例点，并手算越界步长轨迹。
17. 说明局部 L 需要什么区域条件，并区分不可微与曲率无界两种失败。
18. 设计包括 $T=0$ 、浮点抵消、非法尾字段与输出保护的验收，说明哪些检验只提供有限证据。

实验指南、完整解答、实际执行的Notebook和脚本各自独立成文件。下一讲把确定性全梯度换成随机或小批量估计，届时逐步下降可能消失，需要在随机性和条件期望下重新建立论证。

来源与核查范围

- [Boyd与Vandenberghe无约束优化课件](#)：核对强凸、梯度条件与停止界的假设；本讲证明与数值例子独立编写。
- [Cornell CS4787 2025 Lecture5](#)：核对 L 光滑、下降引理、梯度和与强凸递推的概念。本讲保留自己的索引、存在性条件和完整中间步骤，不复制来源图像。
- [MIT6.390梯度下降讲义](#)：核对更新、学习率和停止量的角色。
- [Python math、Fraction、Decimal](#)：核对有限值检查、存储浮点的有理参照和高精度运算接口。