

第034讲完整练习解答

1 三类更新与同一点平均

$F = \Sigma \ell_i / n$, full-batch梯度 $\Sigma \nabla \ell_i / n$ 。SGD只取随机 I 的 $\nabla \ell_I$ ；mini-batch用 $\sum_j \nabla \ell_{I_j} / B$, 再做 $w^+ = w - \eta G$ 。每个分项必须使用同一旧 w 。如果第一行后立即更新，第二行的导数位置已经变了，所得是两个连续SGD步骤。若漏掉 $1/B$, 更新大小乘 B , 不能继续说学习率保持不变。

2 直接平均出无偏

固定 w , 索引 i 的概率 $1/n$, 因此 $E[G] = \Sigma_i (1/n) \nabla \ell_i(w) = \nabla F(w)$ 。主例 $w=0$ 时四个值2、0、-1、-5, 平均-1, 与 $w=1$ 一致。这是可能结果的概率平均; 没有声称某一次梯度等于-1或一定使 F 下降。

3 条件比边际多了什么

令 $\mathbf{F}_t$ 包括过去索引和由其决定的 w_t 。若新索引给定历史仍均匀, 则 $E[G_t | \mathbf{F}_t] = g(w_t)$ 。这样 e_t 等历史可测量可以提出条件期望, $E[e_t \xi_t | \mathbf{F}_t] = e_t$, $E[\xi_t | \mathbf{F}_t] = 0$ 。仅知道每个位置边际均匀, 却不知道该位置与已形成参数的联合关系, 不能完成此步骤。

4 四行目标与噪声

标签和4, 均值1。中心化值-3、-1、0、4, 平方和26。展开 $\Sigma (w - y_i)^2 = 4(w-1)^2 + 26$, 因为交叉项含 $\Sigma (y_i - 1) = 0$ 。因此 $F = 13/4 + (w-1)^2/2$, 最优 $w=1$, $F=13/4$, $g=w-1$ 。单样本 $g_i = w - y_i$ 与 g 之差为3、1、0、-4, 方差 $26/4 = 13/2$ 。分母4描述已知有限抽样总体, 不用无偏估计样本方差的分母3。

5 同一数据完整两轮

以下每行的预测都是当前 w 。 $r = \text{预测} - \text{标签}$, $\ell = r^2/2$; 局部链为 $\partial \ell / \partial r = r$ 、 $\partial r / \partial \text{预测} = 1$ 、 $\partial \text{预测} / \partial w = 1$ 。完整目标的梯度分项是 $r/4$, 所选单样本SGD梯度是 r 而非 $r/4$ 。

初始 $w=0$ 的全部前向:

行与标签	预测	残差 r	单行损失 ℓ	完整梯度分项 $r/4$
1 -2	0	2	2	1/2
2 0	0	0	0	0
3 1	0	-1	1/2	-1/4
4 5	0	-5	25/2	-5/4

四行损失和15，除4给 $F=15/4$ ；梯度分项和-1。第一步选第4行，所以实际梯度是 $(-5) \times 1 \times 1 = -5$ 。
 $\eta=1/4$ ， $w_1=0-(1/4)(-5)=5/4$ 。不能把全梯度-1替代本次选中梯度。

第一次更新后的全部前向：

行与标签	预测	残差 r	单行损失 ℓ	完整梯度分项 $r/4$
1 -2	5/4	13/4	169/32	13/16
2 0	5/4	5/4	25/32	5/16
3 1	5/4	1/4	1/32	1/16
4 5	5/4	-15/4	225/32	-15/16

损失和 $420/32=105/8$ ，除4给 $F=105/32$ ；完整梯度 $1/4$ 。第二步选第1行，当前残差 $13/4$ ，单行损失 $169/32$ ，局部链 $(13/4) \times 1 \times 1 = 13/4$ 。 $w_2=5/4-(1/4)(13/4)=20/16-13/16=7/16$ 。

第二次更新后的全部前向：

行与标签	预测	残差 r	单行损失 ℓ	完整梯度分项 $r/4$
1 -2	7/16	39/16	1521/512	39/64
2 0	7/16	7/16	49/512	7/64
3 1	7/16	-9/16	81/512	-9/64
4 5	7/16	-73/16	5329/512	-73/64

损失和 $6980/512=1745/128$ ，除4得 $F=1745/512$ ；完整梯度 $-9/16$ 。第二步的选中行损失从 $169/32=2704/512$ 降至 $1521/512$ ，但全目标从 $1680/512$ 升至 $1745/512$ 。所有数都来自同一数据、同一参数更新，没有切换例子。

full-batch的两轮则使用-1与-3/4， w 依次0、1/4、7/16。最后巧合重合不等于路径相同：full每步4个样本梯度，SGD每步1个。

6 全目标上升的样本方向

若初始选第1行， $g_1=2$ ， $w^*=-1/2$ 。 $F=13/4+(-3/2)^2/2=35/8$ ，大于初始 $30/8$ 。其余可能方向的概率平均仍是-1。无偏约束梯度的期望，不约束每条随机路径的目标单调性。

7 独立放回小批量的协方差

令 $\xi_j = \nabla \ell_{I_j} - g$ ， $E\xi_j=0$ ， $\text{Cov}\xi_j=\Sigma$ 。平均噪声的协方差是 $B^{-2} \sum_{j,k} E[\xi_j \xi_k^T]$ 。 $j=k$ 有 B 项 Σ ； $j \neq k$ 因独立， $E\xi_j E\xi_k^T=0$ 。因此 $\text{Cov}=\Sigma/B$ ，平方范数期望为 $\text{tr}\Sigma/B$ 。标准差是方差平方根，除 $\sqrt{B}$ 。 B 从1变4，方差 $13/2$ 变 $13/8$ ，标准差减半。

8 不放回子集的有限总体修正

零和噪声满足 $\sum_{i \neq j} \xi_i \xi_j^T = (\sum_i \xi_i)(\sum_j \xi_j)^T - \sum_i \xi_i \xi_i^T = -n\Sigma$ 。均匀有序不同索引共 $n(n-1)$ 个，所以交叉矩为 $-\Sigma/(n-1)$ 。B项均值协方差为 $B^{-2}[B\Sigma - B(B-1)\Sigma/(n-1)]$ ，化简得 $(n-B)\Sigma/[B(n-1)]$ 。

$n=4$ 、 $B=2$ 时乘系数 $1/3$ ，方差 $13/6$ ； $B=4$ 时为 0 。只有每一步都重新从全部数据独立抽子集，才能把此固定位置结果用于本讲相应条件递推。

9 重排的历史反例

标签 $0, 2$ ，初始 $w=0$ 。给定第一行已选 0 的历史，第一步梯度 0 ，参数仍 0 。剩余必为 2 ，下一梯度 -2 ；完整梯度 $[0+(-2)]/2=-1$ 。因此给定历史的期望 -2 不等于 -1 。虽然随机排列每个位置在未观察历史前边际均匀，也不能消除参数与剩余集合的依赖。

10 带噪声的下降界

L 光滑给 $F(w-\eta G) \leq F(w) - \eta g^T G + L\eta^2 \|G\|^2/2$ 。固定历史后， w 与 g 不再随机。条件无偏令 $E[g^T G | \mathcal{F}] = \|g\|^2$ 。展开 $\|G\|^2 = \|g\|^2 + 2g^T(G-g) + \|G-g\|^2$ ，交叉项条件期望 0 。若条件方差 $\leq \sigma^2/B$ ，便得到

$$E[F(w^+) | \mathcal{F}] \leq F(w) - \eta(1 - L\eta/2)\|g\|^2 + L\eta^2\sigma^2/(2B).$$

L 光滑、条件无偏、方差界分别用于不同步骤，不能少写。接近最优时 $\|g\|^2$ 小，噪声项可能占优。

11 误差均值与二阶矩

设批均标签 $= 1 + \zeta_t$ ， $e_t = w_t - 1$ ，更新 $e_{t+1} = (1-\eta)e_t + \eta\zeta_t$ 。给定历史， $E\zeta_t = 0$ 且 $E\zeta_t^2 = V$ 。因此 $Ee_{t+1} = (1-\eta)Ee_t$ 。

平方后为 $(1-\eta)^2 e_t^2 + 2\eta(1-\eta)e_t\zeta_t + \eta^2\zeta_t^2$ 。中项先取条件期望， e_t 可提出而 $E[\zeta_t | \mathcal{F}_t] = 0$ ；再取总期望得 $m_{t+1} = (1-\eta)^2 m_t + \eta^2 V$ 。这里 $m = E[e^2] = \text{Var}(e) + (Ee)^2$ ，不只是方差。

12 固定步长平台

设 $r = (1-\eta)^2$ 。先把前两次递推完整展开：

$$\begin{aligned} m_1 &= r m_0 + \eta^2 V, \\ m_2 &= r(r m_0 + \eta^2 V) + \eta^2 V \\ &= r^2 m_0 + \eta^2 V(1+r). \end{aligned}$$

继续代入可归纳得到

$$m_T = r^T m_0 + \eta^2 V \sum_{k=0}^{T-1} r^k.$$

因为 $0 < \eta < 2$ ，所以 $0 \leq r < 1$ 。有限几何和与分母分别是

$$\sum_{k=0}^{T-1} r^k = \frac{1-r^T}{1-r}, \quad 1-r = 1-(1-2\eta+\eta^2) = \eta(2-\eta).$$

把它们代入并约去一个 η ，得到

$$m_T = r^T m_0 + \frac{\eta V}{2-\eta} (1-r^T), \quad \lim_{T \rightarrow \infty} m_T = \frac{\eta V}{2-\eta}.$$

当 $\eta=1/4$ 时， $\eta/(2-\eta)=(1/4)/(7/4)=1/7$ ，平台为 $V/7$ 。B=1， $V=13/2$ ，MSE平台 $13/14$ ，超额目标平台 $13/28$ ；B=2放回分别 $13/28$ 、 $13/56$ 。不放回新子集B=2的 $V=13/6$ ，平台 $13/42$ 、 $13/84$ 。没有噪声的full为0。这不是重排或一般非线性网络的精确公式。

13 递减步长的归纳

第一步 $w_1=(3w_0+Y_0)/4$ 。若 $(T+3)w_T=3w_0+\sum_{t<T} Y_t$ ，则 $(T+4)w_{T+1}=(T+3)w_T+Y_T$ ，恰为多一项，归纳成立。

令初值误差 e_0 ， $w_{T-1}=[3e_0+\sum \zeta_t]/(T+3)$ 。新抽样独立且 ζ 均值0，所以均值 $3e_0/(T+3)$ ，方差 $TV/(T+3)^2$ ；再加均值平方， $MSE=(9e_0^2+TV)/(T+3)^2$ 。共享固定/递减索引流用于配对比较，不影响每一种方法单独的边际公式。

14 顺序终点逐步展开

正向标签-2、0、1、5： $w_0=0$ ； $w_1=-1/2$ ； $w_2=-3/8$ ； $w_3=-1/32$ ； $w_4=157/128$ 。每步使用 $w^+=(3/4)w+y/4$ 。

反向5、1、0、-2： $w_1=5/4$ ； $w_2=19/16$ ； $w_3=57/64$ ； $w_4=43/256$ 。展开一般递推得

$w_n = (1-\eta)^n w_0 + \eta \sum_{j=1}^n (1-\eta)^{n-j} y_j$ 。早到项乘更多个 $3/4$ ，所以权重更小。不能把这种不同位置梯度的和换成同一点完整平均。

15 同成本与真实epoch

160次样本梯度预算下，full=160/4=40次更新，SGD=160次，B=2=80次。若预算161且停在完整批，full和B=2均消耗160、剩余1，B=1消耗161。full处理4行一次等于一次真实遍历；放回SGD累计4次只是等效遍历量1，可能漏行重复。reshuffle每完整4步才是每行恰好一次的一轮。另计完整目标诊断，不能把绘图代价隐藏成免费训练。

16 四种不同的统计量

10%至90%分位带包含经验中间80%运行结果；它不是均值80%置信区间。均值标准误为运行标准差/ $\sqrt{R}$ ，描述估计均值的不确定性。主例平均目标= $F+E[e^2]/2$ ，平均参数的目标= $F+(Ee)^2/2$ ，二者差 $\text{Var}(e)/2$ 。

若两方法共享索引，比较每次重复的差 D_r ，再用 $s_D/\sqrt{R}$ 估计均值差标准误。不能把相关的两组均值当独立，简单相加方差。标准误和z诊断也不是跨所有时间点的同时保证。

17 非均匀抽样修正

直接梯度期望 $\sum p_i g_i$ 是加权目标梯度。修正 $G_i = g_i / (np_i)$ 后， $\sum p_i G_i = \sum g_i / n$ ，要求每个需要的 $p_i > 0$ 。主例 $w=0$ ， $p=(1/8, 1/8, 1/4, 1/2)$ ，未修正期望 $1/4 - 1/4 - 5/2 = -5/2$ ；修正梯度为4、0、-1、-5/2，加权和 $1/2 - 1/4 - 5/4 = -1$ 。

$p_i=0$ 意味着该行永不出现，不能靠除法恢复它的非零贡献；极小 p_i 产生大权重，可能增大方差。无偏与低方差是两个命题。本实验没有把此概率机制加入主随机训练。

18 验收设计

第一层独立Fraction枚举4个单样本、16个放回二元组、6个不放回子集与24个排列。第二层枚举短路径：B=1最多6步、B=2最多3步，每个最长问题4096条路径，直接汇总终点矩而非复用理论递推。第三层对随机二进制可精确输入逐个核查实际减法、平均与更新，再以Decimal高精度核对矩公式。

第四层多独立流检查均值、波动和理论偏差，用标准误解释有限抽样，不硬凑等式。第五层把非法字段放在最后一个batch、概率或CSV行，确认创建RNG前失败；坏CLI保留旧结果且不创建新目录。第六层新进程normal与-O、不同cwd、真实新内核Notebook逐格执行并比较完整JSON摘要。最后阅读全部图和PDF页面，确认符号、机制、图例、标题与结论一致。