

第034讲 随机与小批量梯度下降

1 少算几行 为什么不是随便走

第033讲用真实全梯度证明了下降。但训练目标通常是许多样本损失的平均，每算一次全梯度都要处理所有样本。若一次只看一行或一小批，计算更少，方向却带上随机性。新的核心问题是：只看部分数据，为什么仍可能朝合理方向更新，什么时候这个解释又会失效？

直接先修是第022至023讲的条件期望、方差与独立性，第032至033讲的梯度更新、平均因子与下降条件。本讲不会假设读者已经知道“无偏”如何用于迭代，而会先固定当前位置，对可能抽到的样本逐个求平均，再把历史放回条件里。

我们选一个可完全算清的常数回归：四个标签-2、0、1、5，用同一个参数 w 预测全部样本。简单模型让随机抽样的影响不被复杂曲率遮住。所有算法优化同一目标，比较相同样本梯度计算预算，再用多条独立随机流观察均值与波动。CPU合成实验只解释机制，不说明真实任务泛化或大模型吞吐性能。




图1 固定同一目标，只改变每步怎样估计梯度；节省计算与增加噪声同时发生。

2 全梯度 单样本梯度与小批量平均

训练集有 n 行，单行损失 $\ell_i(w)$ ，参数 $w \in \mathbb{R}^d$ 。总体训练目标定义为 $F(w) = \sum_i \ell_i(w)/n$ ，梯度 $g(w) = \sum_i \nabla \ell_i(w)/n \in \mathbb{R}^d$ 。full-batch GD每次使用这个完整平均。

SGD在第 t 步抽一个索引 I_t ，使用 $G_t = \nabla \ell_{I_t}(w_t)$ 。mini-batch使用 B 个索引 $I_{t,1}$ 到 $I_{t,B}$ ，按

$$G_t = \frac{1}{B} \sum_{j=1}^B \nabla \ell_{I_{t,j}}(w_t), \quad w_{t+1} = w_t - \eta_t G_t.$$

这里各样本梯度在同一个旧参数 w_t 计算，先平均，再更新一次。若每看一行就更新参数，下一行已经在另一个位置计算，那是连续SGD步骤，不是一个小批量梯度。分母是实际批量大小 B ，不是总样本数 n ；不要为了省事漏除 B 却继续沿用同一个学习率。

“batch”一词有时指全量，也有时指一批。报告应写清full-batch或实际 B 、是否平均、抽样是否放回以及一次参数更新处理多少行，而不是只给一个含糊名称。

3 固定当前位置 逐个平均出无偏性

先把 w 看成固定数值，并均匀抽 $I \in \{1, \dots, n\}$ 。因为每个索引概率 $1/n$,

$$\mathbb{E}[\nabla \ell_I(w)] = \sum_{i=1}^n \frac{1}{n} \nabla \ell_i(w) = \nabla F(w).$$

无偏说的是在同一位置重复随机选择后，向量的平均等于全梯度。它没有说每次选出的向量都接近全梯度，也没有说每次负随机梯度都使完整训练目标下降。单行梯度甚至可能方向相反。

令 $\xi_i(w) = \nabla \ell_i(w) - g(w)$ ，则 $\sum \xi_i/n = 0$ 。定义单次均匀抽样的协方差 $\Sigma(w) = \sum \xi_i \xi_i^T/n$ ，是 $d \times d$ 矩阵；总方差 $\sigma^2(w) = \text{tr} \Sigma(w) = \sum \|\xi_i\|^2/n$ 。这里分母 n 定义的是有限抽样总体方差，不是估计未知方差时的 $n-1$ 。


4 参数由历史决定 为什么要条件期望

真实 w_t 已经依赖以前抽到的样本，不能把它当作与全部随机变量独立。记 $\mathcal{F}_t$ 为第 t 次抽样前的历史，包括初值、过去索引和已形成的 w_t 。如果新索引在给定历史后仍独立均匀放回抽取，那么 w_t 在这个条件下固定，有

$$\mathbb{E}[G_t \mid \mathcal{F}_t] = \nabla F(w_t).$$

因此误差 $\xi_t = G_t - g(w_t)$ 满足 $\mathbb{E}[\xi_t \mid \mathcal{F}_t] = 0$ 。与历史已确定的任何向量 a_t 相乘，都有 $\mathbb{E}[a_t^T \xi_t \mid \mathcal{F}_t] = 0$ 。这正是后面平方递推中交叉项消失的理由；只写“噪声均值0”却不说明条件，容易把错误的独立性带进证明。

如果抽样规则依赖当前损失、反复抽容易样本，或一轮不放回的剩余样本已经被历史改变，上式需要重新检查。某个位置上的边际均匀分布，不足以自动证明给定已观察历史后的条件无偏。

Condition first, average the NEW sample second

A shuffled epoch has a remaining set that depends on history.
Marginally uniform positions do not imply this conditional identity.

图2 先把历史和当前位置固定，再平均本轮新抽样；交叉项为何为0取决于这个条件。

5 四行主问题的精确目标与噪声

取标签 $y=(-2,0,1,5)$ ，模型预测 $\hat{y}_i=w$ ，单行损失 $\ell_i=(w-y_i)^2/2$ 。均值 $\bar{y}=1$ ，中心化标签 $(-3,-1,0,4)$ ，平方和26，所以

$$F(w) = \frac{1}{8} \sum_{i=1}^4 (w - y_i)^2 = \frac{13}{4} + \frac{1}{2}(w - 1)^2.$$

全局最优 $w^*=1$ ，最小训练目标13/4，曲率1，全梯度 $g=w-1$ 。这个非零最小值来自四个标签无法被同一个常数同时精确拟合，不是优化还没收敛。

单样本梯度 $g_i=w-y_i$ 。其相对全梯度的噪声为 $1-y_i$ ，即 $(3,1,0,-4)$ ，均值0，方差 $(9+1+0+16)/4=13/2$ ，恰好与 w 无关。这个特征使主例的均值和二阶矩能完全推导；一般问题的噪声方差可能随参数变化。

在 $w=0$ ，四个梯度依次2、0、-1、-5，全梯度-1。均匀抽一次有可能得到正梯度2，负梯度方向便向左，而全目标此时需要向右。方向偶尔相反与无偏没有矛盾。




图3 四个单样本梯度、它们的平均和方差；同一位置下的方向可能互相冲突。

6 完整走两轮 看见单样本与全目标的区别

取 $w_0=0$ 、 $\eta=1/4$ ，第一步明确抽到第4行 $y=5$ 。当前预测0，残差 $r=0-5=-5$ ，单行损失 $25/2$ 。局部导数 $\partial \ell / \partial r = r = -5$ ， $\partial r / \partial \hat{y} = 1$ ， $\partial \hat{y} / \partial w = 1$ ，所以该样本梯度-5。更新 $w_1 = 0 - (1/4)(-5) = 5/4$ 。

更新后先重新对全部四行前向。预测都为 $5/4$ ，残差为 $(13/4, 5/4, 1/4, -15/4)$ ，平方为 $(169, 25, 1, 225)/16$ ，合计 $420/16 = 105/4$ ，再除8得到完整目标 $105/32$ 。也可由 $13/4 + (1/2)(1/4)^2$ 得到同样值。此时完整梯度 $1/4$ ，但下一步实际样本梯度不必等于它。

第二步抽第1行 $y=-2$ ，必须在新参数 $5/4$ 处重算：预测 $5/4$ ，残差 $13/4$ ，单行损失 $169/32$ ，局部链给梯度 $13/4$ 。更新 $w_2 = 5/4 - (1/4)(13/4) = 7/16$ 。再对全部样本前向，残差 $(39/16, 7/16, -9/16, -73/16)$ ，平方和 $(1521+49+81+5329)/256 = 1745/64$ ；除8得到完整目标 $1745/512$ 。

于是完整目标从初始 $15/4$ 降到 $105/32$ ，又升到 $1745/512$ 。第二步使所抽样本的损失下降，却让全目标上升。若第一步一开始就抽第1行， w 会变成 $-1/2$ ，完整目标升到 $35/8$ ，更直接证明“无偏”不是“逐步下降”。

作为对照，全梯度前两次是 -1 和 $-3/4$ ，参数 $0 \rightarrow 1/4 \rightarrow 7/16$ 。它与上面第二轮终点恰好相同只是这两个指定索引和步长的巧合，第一轮路径、用到的数据和成本都不同，不能由终点巧合判断算法相同。

7 小批量为什么降低方差 必须说明独立抽样

固定 w ，若 B 次索引独立、均匀、放回， $G_B - g = (\xi_1 + \dots + \xi_B)/B$ 。均值为0。展开外积后，对角项有 B 个相同协方差，交叉项因独立且均值0而消失，得到

$$\text{Cov}(G_B | w) = \frac{\Sigma(w)}{B}, \quad \mathbb{E}[\|G_B - g\|^2 | w] = \frac{\sigma^2(w)}{B}.$$

方差除 B ，标准差才除 $\sqrt{B}$ 。把 B 扩大4倍，只让单步随机误差的标准差减半，不是减成 $1/4$ 。平均 B 个样本梯度同时需要大约 B 次样本梯度计算；方差与计算成本要同时看。

主例 $B=1, 2, 4$ 的放回梯度方差分别 $13/2, 13/4, 13/8$ 。即使 $B=n=4$ ，只要放回抽样，仍可能重复某行、漏掉某行，所以方差不为0。只有确实使用每行一次的完整平均才是full-batch梯度。




图4 方差与标准差对batch大小的倍率不同；B等于n也不自动表示全梯度。

8 同批不放回与整轮重排 是两个层次

若每一步都从全部 n 行重新均匀抽一个大小 B 的不放回子集，固定 w 时仍无偏。但同批索引相关，协方差变为

$$\text{Cov}(G_B | w) = \frac{n-B}{B(n-1)} \Sigma(w), \quad 1 \leq B \leq n.$$

可以用零和噪声证明交叉项：两个不同索引的 $E[\xi_i \xi_j^T] = -\Sigma/(n-1)$ 。展开 B 项平均的协方差，得到 $(\Sigma/B)[1 - (B-1)/(n-1)]$ ，化简即上式。主例 $n=4, B=2$ ，方差 $13/6$ ； $B=4$ 时为0。

这与“整轮先生成一个随机排列，再按顺序依次用完”不同。后者下一步从剩余样本中抽，给定历史后的剩余平均一般不是全数据平均。每一轮排列的每个位置边际均匀，但 w_t 本身受之前位置影响，不能照搬独立放回的条件证明。

一个具体例子： $n=2$ 、标签0与2，初始0，先抽到0并按SGD更新后仍在0；剩余必为2，下一梯度-2，而当前位置全梯度-1。因此整轮重排的第二步在给定这个历史后不是全梯度的无偏估计。重排仍可能是有效算法，只是需要相应分析，而不是错误套用这条证明。

9 在期望里改写下降式

第033讲的下降引理对实际位移 $-\eta G$ 仍给

$$F(w^+) \leq F(w) - \eta g^\top G + \frac{L\eta^2}{2} \|G\|^2.$$

给定历史后取期望，使用 $E[G | \mathcal{F}] = g$ 和 $E\|G\|^2 = \|g\|^2 + E\|G - g\|^2$ 。如果放回batch的条件方差 $\leq \sigma^2/B$ ，得到

$$\mathbb{E}[F(w^+) | \mathcal{F}] \leq F(w) - \eta \left(1 - \frac{L\eta}{2}\right) \|g\|^2 + \frac{L\eta^2 \sigma^2}{2B}.$$

最后多出一个非负噪声项。在离最优很近、全梯度很小时，下降项可能不足以抵消它，因此固定步长不保证每步甚至每步条件期望都继续下降。这里需要条件无偏、方差界和L光滑，任何一个都不是单靠画图确认的。

如果是一般自适应抽样，必须把真实 $\mathbb{E}[G|\mathbf{f}]$ 代入内积项，不能直接换成g。若方差随w变化，也应使用对应条件方差或已证明的全域界。




图5 确定性下降项与随机噪声项的竞争，解释接近最优后仍会抖动。

10 主例的误差递推 把交叉项写出来

令 $e_t = w_t - 1$ 。对放回batch，令批均标签 $Y_t = 1 + \zeta_t$ ，条件均值 $\mathbb{E}[\zeta_t | \mathbf{f}_t] = 0$ 、方差 $V_B = (13/2)/B$ 。随机梯度 $G_t = w_t - Y_t = e_t - \zeta_t$ 。更新变成

$$e_{t+1} = (1 - \eta)e_t + \eta\zeta_t.$$

首先取条件均值， $\mathbb{E}[e_{t+1} | \mathbf{f}_t] = (1 - \eta)e_t$ ，再取总期望，得到 $\mathbb{E}[e_t] = (1 - \eta)^t e_0$ 。均值可以趋0，即许多独立轨迹的平均趋近最优，单条轨迹仍可能持续波动。

再平方： $e_{t+1}^2 = (1 - \eta)^2 e_t^2 + 2\eta(1 - \eta)e_t \zeta_t + \eta^2 \zeta_t^2$ 。给定历史后 e_t 固定，交叉项期望为0，最后一项期望 $\eta^2 V_B$ 。因此二阶矩 $m_t = \mathbb{E}[e_t^2]$ 满足

$$m_{t+1} = (1 - \eta)^2 m_t + \eta^2 V_B.$$

这是二阶矩而非仅方差；因为 $m_t = \text{Var}(e_t) + (\mathbb{E}[e_t])^2$ 。把平均参数先平方，会丢掉方差，错误地把仍在抖动的算法看成完美收敛。

11 固定学习率的噪声平台

令 $r=(1-\eta)^2$ 。在 $0<\eta<2$ 时 $0\leq r<1$ ，把递推展开： $m_T=r^T m_0+\eta^2 V_B \sum_{k=0}^{T-1} r^k$ 。几何求和给

$$m_T = r^T m_0 + \frac{\eta V_B}{2-\eta} (1 - r^T).$$

所以 $T\rightarrow\infty$ 时二阶矩趋 $\eta V_B/(2-\eta)$ ，目标超额 $E[F(w_T)-F^*]=m_T/2$ 。主例 $\eta=1/4$ 、 $B=1$ ，参数二阶矩平台 $13/14$ ，目标超额平台 $13/28$ ； $B=2$ 分别 $13/28$ 和 $13/56$ 。full-batch没有抽样噪声， $V=0$ ，因此这个平台为0。

平台公式只针对本主例的同曲率标量模型、独立新抽样和固定步长。它不是所有神经网络的精确噪声底，也不是“batch越大总是越好”的证明。 η 很小时平台较低，但初始误差的收缩也更慢；有限预算下要同时考虑两项。

新抽不放回子集每步若独立，仍可用同一递推，但 V_B 应换成有限总体修正后的方差。例如 $n=4$ 、 $B=2$ 时 $V=13/6$ ，二阶矩平台 $13/42$ ，超额平台 $13/84$ 。整轮重排不能直接把这个 V 塞进公式，因为历史条件结构不同。




图6 真实多轨迹二阶矩与精确理论曲线并列；均值趋近与单条轨迹噪声平台是不同现象。

12 一个能完全求解的递减学习率

采用 $\eta_t=1/(t+4)$ ，从 $t=0$ 开始，所以第一步仍是 $1/4$ 。主例更新 $w_{t+1}=[(t+3)w_t+Y_t]/(t+4)$ 。把两侧乘 $t+4$ ，逐步归纳得到

$$w_T = \frac{3w_0 + \sum_{t=0}^{T-1} \bar{Y}_t}{T+3}.$$

这像给初值放了3份权重，再不断加入新抽样批均值。 $E[e_T]=3e_0/(T+3)$ ， $\text{Var}(e_T)=TV_B/(T+3)^2$ ，因此

$$\mathbb{E}[e_T^2] = \frac{9e_0^2 + TV_B}{(T+3)^2}.$$

它确实趋0，通常为1/T量级，但这是本例的完整闭式证明，不是“任意递减步长都好”。如果步长衰减得太快，总移动量有限，可能过早冻结在偏离最优的位置；如果下降太慢，噪声可能长时间保留。一般随机逼近还需结合目标和噪声假设讨论步长和、平方和等条件。

本实验在同一随机索引流上同时比较固定与递减计划，以减少“抽样恰好不同”对差值的干扰；同时保留多次独立重复。共享流是有意的配对比较，不应把两条轨迹称为相互独立。

13 不同顺序为什么产生不同终点

即使每轮都完整看过全部数据，连续SGD是在不断变化的参数上计算梯度。对主例固定 η ，给定顺序 y_1 到 y_n ，一轮后

$$w_n = (1 - \eta)^n w_0 + \eta \sum_{j=1}^n (1 - \eta)^{n-j} y_j.$$

靠后的样本权重重大，因为较早的贡献经历了更多次衰减。因此同一轮的“每行一次”不能简单等同于一次全梯度平均。主例 $\eta=1/4$ 、 $w_0=0$ ，顺序 $(-2,0,1,5)$ 的终点157/128，反向 $(5,1,0,-2)$ 的终点43/256。两者都用4次单样本梯度，却相差很大。

随机重排每轮换顺序，避免长期固定某种排列结构，但它与独立放回采样的理论不同。实际实验要记录顺序机制和每轮边界，而不只写“设置了seed”。如果数据按标签或时间排序，直接不打乱可能形成系统性模式；是否允许打乱还取决于任务的时间/序列结构。




图7 同一四行数据按不同顺序经过不断变化的参数，终点不必相同。

14 公平比较 先把横轴的成本说清

一次full-batch更新处理 n 行，一次SGD更新处理1行，一次mini-batch更新处理 B 行。若都跑100次更新，它们消耗的样本梯度数分别 $100n$ 、 100 、 $100B$ ，不能仅凭谁的100步目标最低来比较计算效率。

本实验首要横轴是累计样本梯度评估数 C ，保留更新次数作为另一坐标。对于 $n=4$ 、预算 $C=160$ ，full-batch可做40次更新，SGD做160次， $B=2$ 做80次。每种方法在自己的更新时间点评估完整训练目标，绘图若做插值必须标明；不要假装某方法在未更新的点也产生了新参数。

定义等效数据遍历量 C/n 有助于对齐成本，但对放回抽样它不是“已经不重不漏看过每行”的真实epoch。随机重排的一轮才明确包含每行一次。预算不是 B 的整数倍时，要说明停止在完整批还是使用一个较小尾批；不能静默多用数据或错误沿用分母 B 。

样本梯度数是算法工作量代理，不等于墙钟时间。矩阵向量化、设备并行、内存和数据加载会影响实际耗时。本讲不据微型Python计时宣布哪个方法在GPU或大型任务更快。

15 多种子曲线 画的究竟是哪种波动

一次随机轨迹可能偶然很好或很差。固定模型、初值、预算、算法参数和抽样机制，运行许多独立随机流，分别记录每个更新时间的 w 、目标超额和已用样本数。至少画均值与10%–90%分位带，并标明重复次数。

分位带描述随机运行结果的分布，不是均值的置信区间。均值的Monte Carlo标准误大致为样本标准差除 $\sqrt{R}$ ，其中 R 为独立重复数，但当比较方法共享随机流时，应对配对差值计算不确定性，而不是假定两个均值独立。

还要区分“平均轨迹的目标 F (平均 w)”与“各轨迹目标的平均”。平方目标满足后者比前者多半个参数方差。实验报告应保留mean_error、mean_squared_error、variance和mean_excess；不能只画平均 w 接近1就忽略运行波动。




图8 固定与递减计划的400次运行均值、10%至90%分位带及最终参数经验分布；分位带不是均值置信区间。

16 非均匀抽样与修正权重

若索引 i 被抽到的概率 p_i 不再都是 $1/n$ ，直接使用 $\nabla \ell_i$ 的平均变成 $\sum p_i \nabla \ell_i$ ，通常优化了另一个加权目标。为了估计原来的均匀目标，可以用 $G = \nabla \ell_i / (np_i)$ ，前提每个需要的 $p_i > 0$ 。则 $E[G] = \sum p_i \nabla \ell_i / (np_i) = g$ 。

修正无偏不代表方差更小。很小 p_i 对应很大权重，可能带来罕见但很大的更新；如果 $p_i=0$ 却对应非零目标贡献，无法用这个公式恢复未被抽到的项。重要性抽样要同时考虑概率、权重、方差和数值范围。

本讲主实验仍使用明确均匀机制。非均匀一节只做有限枚举的梯度平均核验，不把未经检验的自适应概率加入主训练后沿用原来的噪声平台公式。

17 实现中最常见的几种悄悄换题

把batch梯度求和而非求平均，会把有效学习率乘B；逐样本更新后说“本轮batch平均”，则改变了梯度评估位置。抽样 $B=n$ 却有放回，仍非全梯度；整轮重排的索引序列不能被当成各步独立。测试集也不能参与选batch大小、学习率或停止预算后再被当作独立测试证据。

随机数也需要可复现合同。完整记录NumPy版本、位生成器、根种子、方法标识和重复编号；用明确的SeedSequence派生或整数序列种子，不要让绘图额外抽一次随机数就改变后续训练。所有输入检查应在创建第一条随机流前完成，包括最后一项非法batch、预算、种子和学习率计划。

为了检查代码，不能只依赖某个固定seed跑通。还需独立枚举主例的全部单样本、全部放回二元组合与全部不放回子集，检验均值和方差；手工索引轨迹用Fraction重做；多种子结果再与二阶矩理论对照。理论是随机重复的期望，不应要求有限Monte Carlo平均逐位等于它，也不能把超出容差的差异全推给运气。

Validation layers answer different questions

Exact enumeration

4 / 16 / 6 samples
short complete paths

Fixed-index chains

old forward > gradient
update > new forward

Independent streams

mean / variance / MSE
Monte Carlo uncertainty

Failure protection

bad LAST fields
no RNG or output mutation

Fresh-process CLI + fresh-kernel Notebook + full-page visual review

图9 从精确枚举、固定索引手算到独立随机重复，逐层检查实现与解释。

18 自测与完整验收

1. 写出全梯度、SGD与mini-batch更新，解释小批量应在同一个旧参数处计算。
2. 固定 w ，直接枚举索引证明均匀单样本梯度无偏。
3. 定义抽样历史，说明条件无偏与边际无偏的区别。
4. 从主例四行数据算出 F 、 w 、单样本梯度与 σ^2 。

5. 按索引4、1完整重算两轮前向、局部导数、更新和每轮全目标。
6. 构造单样本更新使完整目标增大的例子，解释为何不违背无偏。
7. 展开协方差推独立放回batch的 $1/B$ 方差关系，并区分标准差。
8. 推出新抽不放回子集的有限总体修正，核对 $n=4$ 、 $B=2$ 和 $B=4$ 。
9. 用两行数据反例说明整轮重排不能直接照搬每步条件无偏。
10. 从下降引理推出带噪声项的条件期望界，逐项标明使用的条件。
11. 推主例误差均值与二阶矩递推，解释交叉项如何消失。
12. 求固定 η 的二阶矩与目标超额平台，代入 $\eta=1/4$ 和 $B=1、2$ 。
13. 对 $\eta_t=1/(t+4)$ 归纳出加权平均表达式并计算均值、方差和均方误差。
14. 手算正向与反向一轮终点，解释后出现的样本为何权重更大。
15. 在160次样本梯度预算下比较full-batch、SGD和 $B=2$ 的更新数，说明epoch含义。
16. 区分分位带、均值标准误、平均参数的目标和目标均值。
17. 推出非均匀抽样的无偏修正，并分析零概率与小概率的风险。
18. 设计枚举、固定索引、多种子、坏尾字段和输出保护的完整验收。

实验指南与完整解答会逐项展开。下一讲在同一基础上加入历史方向形成动量；动量改变了状态与更新规则，不能只把本讲学习率结论原封不动套过去。

来源与核查范围

- [Bottou Curtis Nocedal作者公开综述](#)：核对随机梯度的条件矩、固定/递减步长与计算工作量的讨论，尤其区分独立新抽样和整轮不放回的分析条件。本文四行数据和精确轨迹独立构造，不复制论文图例。
- [Cornell CS4787 Lecture6](#)：核对随机二次递推与小批量方差概念。本讲独立保留平方损失的 $1/2$ 归一化，不照抄来源中个别显示式的遗漏。
- [NumPy2.3 choice、permutation、随机流文档](#)：核对放回参数、排列和可复现独立流的接口与边界。