

035 动量与加速方法练习详解

本答案沿用同一四行数据、残差“预测减标签”、目标 $F=\sum r^2/8$ 。除题目另行指定外， $\theta_0=(0,1)$ 、 $d_0=0$ 、 $\eta=1/16$ 、 $\beta=1/2$ 。记 $\theta=(a,b)$ ， a 是第一特征系数而不是截距。每个更新都同时使用两个旧梯度分量。

1 从数据推导目标与曲率

令 $u=a-1$ ，则四个残差为 $u+4b$ 、 $u-4b$ 、 $-u+4b$ 、 $-u-4b$ 。前两个平方相加为 $2u^2+32b^2$ ，后两个也相同，总和 $4u^2+64b^2$ 。除8得到 $F=u^2/2+8b^2$ 。

对 a 求导， u 对 a 的导数为1，得到 $a-1$ ；对 b 求导得到 $16b$ 。因此 $g=(a-1,16b)$ ， $H=\text{diag}(1,16)$ 。最优点 $(1,0)$ 、 $F^*=0$ ；最小与最大曲率是 $\mu=1$ 、 $L=16$ ， $\kappa=16$ 。

$1/2$ 抵消平方求导的2， $1/n=1/4$ 使梯度按样本平均。若目标改为 $\text{MSE}=\sum r^2/4$ ， H 变成 $\text{diag}(2,32)$ ，不改变最优点，却把相同稳定范围所允许的 η 减半。

2 初始前向与梯度累积

在 $\theta_0=(0,1)$ ，预测为 $(4,-4,4,-4)$ ，标签为 $(1,1,-1,-1)$ ，残差为 $(3,-5,5,-3)$ 。损失贡献为 $(9,25,25,9)/8$ ，总目标 $68/8=17/2$ 。

局部导数 $r/4$ 为 $(3/4,-5/4,5/4,-3/4)$ 。残差对预测导数为1，预测对 (a,b) 导数等于各行特征，所以四行梯度贡献依次为 $(3/4,3)$ 、 $(-5/4,5)$ 、 $(-5/4,5)$ 、 $(3/4,3)$ 。 a 列相加 -1 ， b 列相加 16 。每项已除4，不能把 $(-1,16)$ 再除4。

3 HB的两轮完整链

第一轮用题2的全部旧前向和 g_0 ， $d_1=\beta d_0-\eta g_0=(1/16,-1)$ ，同步更新 $\theta_1=(1/16,0)$ 。新预测为 $(1/16,1/16,-1/16,-1/16)$ ，残差为 $(-15/16,-15/16,15/16,15/16)$ 。每行损失 $225/2048$ ，合计 $225/512$ 。

现在进入第二轮。旧点的局部损失导数为 $(-15/64,-15/64,15/64,15/64)$ 。 a 梯度贡献每项 $-15/64$ ； b 梯度贡献为 $(-15/16,15/16,15/16,-15/16)$ 。累积 $g_1=(-15/16,0)$ 。

位移的 a 分量为 $1/32+15/256=23/256$ ， b 分量为 $-1/2$ 。把整个位移加到旧 θ 得到 $\theta_2=(39/256,-1/2)$ 。新预测为 $(-473/256,551/256,-551/256,473/256)$ ，新残差为 $(-729/256,295/256,-295/256,729/256)$ 。四行损失贡献为 $(531441,87025,87025,531441)/524288$ ，合计 $309233/131072$ 。

新局部导数为 $(-729,295,-295,729)/1024$ 。新 a 梯度贡献为 $(-729,295,295,-729)/1024$ ，合计 $-217/256$ ；新 b 梯度贡献为 $(-729,-295,-295,-729)/256$ ，合计 -8 。 F 从 $225/512$ 升到 $309233/131072$ ，发生在第二次更新。惯性将 b 从0带到 $-1/2$ ，所以零当前 b 梯度不意味着下一位移为0。

4 NAG旧点与预看点不能混用

第一轮 $d_0=0$ ，预看点 $z_0=\theta_0$ ，故题2的逐行前向、梯度和题3的第一轮更新全部相同。新主点仍为 $\theta_1=(1/16,0)$ ，新前向仍有 $F=225/512$ 、 $g=(-15/16,0)$ 。这是第二轮的旧点记录。

第二轮先预看 $z_1=\theta_1+\beta d_1=(3/32,-1/2)$ 。它的四行预测是 $(-61/32,67/32,-67/32,61/32)$ ，残差是 $(-93/32,35/32,-35/32,93/32)$ 。损失贡献为 $(8649,1225,1225,8649)/8192$ ，总损失 $4937/2048$ 。

局部损失导数为 $(-93,35,-35,93)/128$ ；a梯度贡献为 $(-93,35,35,-93)/128$ ，合计 $-29/32$ 。b梯度贡献为 $(-93,-35,-35,-93)/32$ ，合计 -8 。这才是NAG第二轮使用的梯度。

$d_2=(1/32+29/512,-1/2+1/2)=(45/512,0)$ ，同步更新 $\theta_2=(77/512,0)$ 。新预测为 $(77/512,77/512,-77/512,-77/512)$ ，残差为 $(-435/512,-435/512,435/512,435/512)$ ，各行损失 $189225/2097152$ ，总损失 $189225/524288$ 。

新a梯度贡献每项 $-435/2048$ ，合计 $-435/512$ ；新b贡献为 $(-435/512,435/512,435/512,-435/512)$ ，合计0。用旧点的零b梯度就会做出HB的 $-1/2$ 位移，不再是本题NAG。

5 历史响应的有限与极限形式

反复代入 $d_{t+1} = \beta d_t - \eta g_t$ 得到

$$d_{t+1} = \beta^{t+1} d_0 - \eta \sum_{k=0}^t \beta^{t-k} g_k.$$

若 $d_0=0$ 且 $g_k=g$ ，则和为 $g(1-\beta^{t+1})/(1-\beta)$ ，所以极限位移为 $-\eta g/(1-\beta)$ 。它是冻结梯度输入的稳态，不是实际随 θ 变化的梯度下的全程恒定步长。

未归一化buffer满足 $v_{t+1}=\beta v_t+g_t$ 。对于 $g_t=(-1)^t c$ ，设稳态 $v_{t+1}=K(-1)^t$ ，则 $v_t=-K(-1)^t$ ，代入得到 $K=-\beta K+c$ ，即 $K=c/(1+\beta)$ 。 $\beta=1/2$ 时恒定输入增益2、交替输入幅度增益2/3。二者都不直接证明F单调。

6 二维状态递推和初值

对于H特征方向 q ，令 $e_t=q^T(\theta_t-\theta^*)$ ，方向位移为 e_t-e_{t-1} 。HB代入方向梯度 λe_t 得 $e_{t+1}=(1+\beta-\eta\lambda)e_t-\beta e_{t-1}$ ，因此 $A=1+\beta-\eta\lambda$ 、 $D=\beta$ 。

NAG预看误差为 $(1+\beta)e_t-\beta e_{t-1}$ ，从它减去 $\eta\lambda$ 倍自身，得 $A=(1+\beta)(1-\eta\lambda)$ 、 $D=\beta(1-\eta\lambda)$ 。两者均可写

$$\begin{pmatrix} e_{t+1} \\ e_t \end{pmatrix} = \begin{pmatrix} A & -D \\ 1 & 0 \end{pmatrix} \begin{pmatrix} e_t \\ e_{t-1} \end{pmatrix}.$$

$d_0=0$ 意味着 $e_{-1}=e_0$ ，非零 d_0 意味着 $e_{-1}=e_0-q^T d_0$ 。本例有两个特征方向，各自2维，合计4维状态。只存当前位置不够恢复一般动量轨迹。

7 稳定判据的证明和代入

设 $p(r)=r^2-Ar+D$ 。若两根均在单位圆内，则 $|D|<1$ ，且 $p(1)>0$ 、 $p(-1)>0$ 。共轭根时 $p(1)=|1-r|^2$ 、 $p(-1)=|1+r|^2$ ；实根时都是两个同号因子的乘积。

反过来，若根为共轭，则 $D=|r|^2$ ， $|D|<1$ 已经保证稳定。如果根为实数且有根 ≥ 1 ，那么 $p(1)>0$ 迫使另一根也 >1 ，违背 $|D|<1$ ；有根 ≤ -1 同理利用 $p(-1)>0$ 排除。因此三个严格不等式充分且必要。

HB代入得到 $|\beta|<1$ 、 $h>0$ 、 $2+2\beta-h>0$ ，故在 $0\leq\beta<1$ 下为 $0<h<2(1+\beta)$ 。NAG代入得到 $h>0$ 及 $1+(1+2\beta)(1-h)>0$ ；由此 $h<2(1+\beta)/(1+2\beta)$ 。当 $h\leq 1$ 时 $|\beta(1-h)|\leq\beta<1$ ；当 $h>1$ 时 $\beta(h-1)<\beta/(1+2\beta)<1$ ，所以第三个乘积约束也满足。

整个正定二次目标必须对所有特征方向满足，故上界可用 $\lambda=L$ 检查。零曲率会留下根1； $\beta=1$ 和时变参数不属于本题范围。

8 边界根与不衰减解

HB取 $\beta=1/2$ 、 $\eta\lambda=3$ ，得到 $A=-3/2$ 、 $D=1/2$ 。多项式 $r^2+(3/2)r+1/2=(r+1)(r+1/2)$ ，根为 -1 、 $-1/2$ 。 $e_{-1}=e_0=1$ 给 $e_1=-2$ 。写 $e_t=c(-1)^t+k(-1/2)^t$ ，由 $c+k=1$ 、 $-c-k/2=-2$ 解得 $c=3$ 、 $k=-2$ 。极限振幅为3，不趋于0。

NAG取 $\beta=1/2$ 、 $\eta\lambda=3/2$ ， $A=-3/4$ 、 $D=-1/4$ 。多项式 $(r+1)(r-1/4)$ ，根为 -1 、 $1/4$ 。 $e_1=-1/2$ ，由 $c+k=1$ 、 $-c+k/4=-1/2$ 解得 $c=3/5$ 、 $k=2/5$ 。极限交替振幅为 $3/5$ 。

这两个解都说明“没有爆炸”比“误差趋于0”弱。特定初值还可能把单位模根的系数设成0，因此严格稳定指所有有限初值，不是每个不稳定参数都让每个初值发散。

9 三种现象必须区分

$\Delta>0$ 表示两根为实数，不保证为正。例如NAG在 $\eta\lambda>1$ 且 $\beta>0$ 时 $D<0$ ，两实根异号，负根可导致交替。

$\Delta<0$ 时是共轭旋转； $\Delta=0$ 时常有 t 乘 r^t 的项，谱半径只描述渐近指数部分。

$\rho<1$ 保证固定线性状态最终衰减，但初期状态矩阵幂可能放大，当前位置的函数值也不是必然单调的势能。本讲HB手算路径的第二次目标从225/512升到309233/131072就是反例。

反过来，参数交替也可有目标单调下降：一维GD若倍率 $-1/2$ ， e_t 交替但平方误差每次乘 $1/4$ 。因此不能用一个“震荡”词混合参数符号、函数变化和稳定性。

10 三种参数选择

GD端点平衡解 $1-\eta\mu=-(1-\eta L)$ ，得到 $\eta=2/(L+\mu)=2/17$ ；两个方向倍率分别 $15/17$ 和 $-15/17$ ，最坏模 $15/17$ 。

HB设 $\beta=q^2$ ，让 $\lambda=\mu$ 和 $\lambda=L$ 的根分别合并在 q 和 $-q$ ，得到 $\eta\mu=(1-q)^2$ 、 $\eta L=(1+q)^2$ 。相除得 $q=(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)=3/5$ ， $\beta=9/25$ 、 $\eta=4/25$ 。状态谱半径 $3/5$ ；两端点重根不允许省略瞬态 t 因子。

标准强凸NAG取 $\eta=1/L=1/16$ 、 $\beta=(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)=3/5$ 。 $\lambda=1$ 时 $A=3/2$ 、 $D=9/16$ ，重根 $3/4$ ； $\lambda=16$ 时 $A=D=0$ ，根 0 、 0 。谱半径 $3/4$ 。HB的动量是 q^2 ，NAG的动量是 q ，直接拿相同 β 声称“公平理论调参”没有根据。

11 最优位置但非零速度的两轮

取 $\theta_0=(1,0)$ 、 $d_0=(1/4,0)$ 。初始四行预测 $(1,1,-1,-1)$ ，残差、损失贡献、局部 $r/4$ 和梯度贡献全为 0 。因此 $g_0=0$ ， $d_1=(1/8,0)$ ， $\theta_1=(9/8,0)$ 。

新预测 $(9/8,9/8,-9/8,-9/8)$ ，残差 $(1/8,1/8,-1/8,-1/8)$ 。每行损失 $1/512$ ，总 $F_1=1/128$ 。局部导数 $(1/32,1/32,-1/32,-1/32)$ ， a 梯度每行 $1/32$ ， b 梯度为 $(1/8,-1/8,-1/8,1/8)$ ，合计 $(1/8,0)$ 。

第二轮 $d_2=(1/16-1/128,0)=(7/128,0)$ ，同步更新 $\theta_2=(151/128,0)$ 。新预测 $(151/128,151/128,-151/128,-151/128)$ ，残差 $(23/128,23/128,-23/128,-23/128)$ 。每行损失 $529/131072$ ， $F_2=529/32768$ 。新 a 梯度每行 $23/512$ ， b 列相消，合计 $g_2=(23/128,0)$ 。两轮都离开最优位置，故恢复训练不能丢掉或随意初始化速度。

12 归一化buffer的步长换算

$v_{t+1}=\beta v_t+g_t$ 与 $m_{t+1}=\beta m_t+(1-\beta)g_t$ ，在零初值下归纳得到 $m_t=(1-\beta)v_t$ 。要使 $-am_{t+1}=-\eta v_{t+1}$ ，必须 $\alpha=\eta/(1-\beta)$ 。默认 $\eta=1/16$ 、 $\beta=1/2$ ，所以 $\alpha=1/8$ 。

例如第一步 $m_1=(-1/2,8)$ ，用 $\alpha=1/8$ 产生位移 $(1/16,-1)$ ，与HB一致。若错误地令 $\alpha=\eta=1/16$ ，位移只为 $(1/32,-1/2)$ ，更新幅度减半。第二步及以后是否相同还取决于第一步是否到同一参数，因此不能仅比较两个buffer的数值。

13 改变学习率后哪里不再等价

lr 在buffer外时， $v_{t+1}=\beta v_t+g_t$ ， $d_{t+1}=-\eta_t v_{t+1}$ 。若 $\eta_{t-1}>0$ ，由 $v_t=-d_t/\eta_{t-1}$ 代入得 $d_{t+1}=\beta(\eta_t/\eta_{t-1})d_t-\eta_t g_t$ 。

第一步 $\eta_0=1/16$ ， $\theta_1=(1/16,0)$ ， $v_1=(-1,16)$ 。第二步 $\eta_1=1/32$ ，旧点完整前向与题3相同， $g_1=(-15/16,0)$ 。库buffer $v_2=(-23/16,8)$ ，位移 $(23/512,-1/4)$ ， $\theta_2=(55/512,-1/4)$ 。新残差为 $(-969/512,55/512,-55/512,969/512)$ ，四行损失贡献为 $(938961,3025,3025,938961)/2097152$ ，总损失 $470993/524288$ ，新梯度 $(-457/512,-4)$ 。

固定 β 位移版则 $d_2=(1/32+15/512,-1/2)=(31/512,-1/2)$ ， $\theta_2=(63/512,-1/2)$ 。新残差为 $(-1473/512,575/512,-575/512,1473/512)$ 。该路线新损失 $1250177/524288$ ，新梯度 $(-449/512,-8)$ 。两条路线第二步使用同一旧梯度，差异来自旧位移系数 $\beta/2$ 与 β ；以后位置不同，梯度也会不同。实际计划测试逐步保存二者，不以文字声称等价。

14 Dampening特殊首步

PyTorch momentum >0 时，第一次buffer不存在，直接令 $\mathbf{v}_1=\mathbf{g}_0=(-1,16)$ ，不使用 $1-\tau$ 。所以 $\eta=1/16$ 的第一步为 $\theta_1=(1/16,0)$ ，新前向与题3完全相同。

$\tau=1/4$ 时，第二步才是 $\mathbf{v}_2=\beta\mathbf{v}_1+(3/4)\mathbf{g}_1$ 。由 $\mathbf{g}_1=(-15/16,0)$ ，得 $\mathbf{v}_2=(-77/64,8)$ ，位移 $(77/1024,-1/2)$ ， $\theta_2=(141/1024,-1/2)$ 。新预测为 $(-1907/1024,2189/1024,-2189/1024,1907/1024)$ ，新残差为 $(-2931/1024,1165/1024,-1165/1024,2931/1024)$ 。四行损失贡献为 $(8590761,1357225,1357225,8590761)/8388608$ ，总损失 $4973993/2097152$ ；梯度累积为 $(-883/1024,-8)$ 。

若错误地从零buffer对第一步也乘 $3/4$ ， $\mathbf{v}_1$ 会变为 $(-3/4,12)$ ，首步变成 $(3/64,1/4)$ 。该错误在第一步就能检测。Nesterov模式还要求 $\tau=0$ ；不能先假定库接受这个组合再比较曲线。

15 库Nesterov坐标映射的两步核验

固定 η 、 β ，令 $\mathbf{d}_t=-\eta\mathbf{v}_t$ 、 $\mathbf{z}_t=\theta_t+\beta\mathbf{d}_t$ 。库更新 $\mathbf{v}_{t+1}=\beta\mathbf{v}_t+\mathbf{g}(\mathbf{z}_t)$ ，所以 $\mathbf{d}_{t+1}=\beta\mathbf{d}_t-\eta\mathbf{g}(\mathbf{z}_t)$ 。库参数更新为 $\mathbf{z}_{t+1}=\mathbf{z}_t-\eta[\mathbf{g}(\mathbf{z}_t)+\beta\mathbf{v}_{t+1}]$ ，正好等于 $\theta_{t+1}+\beta\mathbf{d}_{t+1}$ 。因此恢复主点用 $\theta_t=\mathbf{z}_t+\eta\beta\mathbf{v}_t$ 。

第一轮从 $\mathbf{z}_0=\theta_0$ 开始，四行前向与题2相同， $\mathbf{v}_1=(-1,16)$ 。库 $\mathbf{z}_1=(3/32,-1/2)$ ，恢复 $\theta_1=(1/16,0)$ 。库第二轮在 $\mathbf{z}_1$ 的逐行前向就是题4的预看表， $\mathbf{g}(\mathbf{z}_1)=(-29/32,-8)$ 。

$\mathbf{v}_2=(-1/2,8)+(-29/32,-8)=(-45/32,0)$ 。库 $\mathbf{z}_2=(199/1024,0)$ ，恢复 $\theta_2=\mathbf{z}_2+(1/32)\mathbf{v}_2=(77/512,0)$ ，与手算一致。库新参数 $\mathbf{z}_2$ 的预测为 $(199/1024,199/1024,-199/1024,-199/1024)$ ，残差为 $(-825/1024,-825/1024,825/1024,825/1024)$ ；库新点每行损失 $680625/8388608$ 、总损失 $680625/2097152$ ，梯度 $(-825/1024,0)$ ；恢复主点的前向则使用题4的435/512残差。二者对应不同点，不能拿前者损失当成后者损失。

映射要求固定 η 和 β 、零dampening、匹配初始状态以及相同目标定义。学习率改变后需要重新分析，不得套用常数比例。

16 同步长压力组如何解释

$\eta=0.12$ 、 $\beta=0.9$ 、 $\lambda=L=16$ 给 $h=1.92$ 。HB要求 $h<2(1+\beta)=3.8$ ，满足；NAG要求 $h<2(1+\beta)/(1+2\beta)=19/14\approx 1.35714$ ，不满足。其高曲率根包含模大于1的根；默认初值激活该方向，实际曲线迅速增大。

这组NAG不采用 $\eta=1/L$ ，也没有满足本讲二次稳定上界，故不在标准强凸参数定理的适用范围内。它证明“相同 η 、 β 时NAG总是更稳定”不成立，不能用来反驳正确假设下的NAG加速保证。

17 哪些加速结论不能外推

$O(1/t^2)$ 的经典凸加速结论要求相应光滑凸函数类、最优点、精确梯度、正确的时间变化参数序列及初始化。仅给算法名称“Nesterov”或固定 $\beta=0.9$ 并不够。

标准强凸几何保证要求有效的 $\mu>0$ 与 L 、全空间光滑强凸、精确全梯度、匹配的 η 和 β 及零初始位移。给 μ 估得过大、 L 估得过小都会使所选参数失去依据。函数误差界、状态谱半径、距离界和硬件运行时间不是同一个对象。

HB二次最优参数只对固定正定二次谱模型有该最优谱结论；一般强凸非二次函数也可能不收敛。非凸、随机梯度、非平稳数据、约束投影或额外正则项需要各自的分析。本例没有检验它们。

18 正确识别浮点停滞

$a=\text{nextafter}(1,2)$ 、 $b=0$ 时， $a-1=2^{-52}$ 。 $\eta=10^{-8}$ 产生的梯度位移远小于 a 附近的一个ULP，所以更新 a 可能舍入不动。若 $d_0=(10^{-30},0)$ 、 $\beta=1/2$ ，则 $d_1=\beta d_0-\eta g$ 仍在改变，而 $\theta_1=\theta_0$ 。这不是完整系统的固定点。

停止规则应检查参数与velocity整个状态；即使二者都不变，也只标记floating_state_stagnation。已知最优位置且零速度才可报告本例可表示最优状态。还要单独检查目标阈值和预算。直接残差相消变0但 θ 不是已知最优点时，应报告forward_cancellation_limit；超过范围应报告numeric_range_limit，不写成收敛。

19 噪声方差的适用范围

在冻结位置、独立零均值 ξ_t 且 $\text{Var}\xi_t=\sigma^2$ 的模型中，buffer噪声为 $\Sigma\beta^k\xi_{t-k}$ 。展开平方，交叉项期望因独立和零均值而消失，对角项给 $\sigma^2\Sigma\beta^{2k}$ 。 $\beta<1$ 时极限为 $\sigma^2/(1-\beta^2)$ 。归一化EMA再乘 $(1-\beta)^2$ ，得到 $\sigma^2(1-\beta)/(1+\beta)$ 。

真实优化的参数由过去噪声决定，梯度随之改变，不能把“冻结位置独立输入”直接当作整个优化路径。若为了匹配位移把EMA学习率放大 $1/(1-\beta)$ ，看起来较小的buffer方差也不能直接转化成较小参数噪声。完整随机分析必须把抽样机制、条件期望、状态与目标耦合起来。

20 坏末字段与输出保护测试

在临时目录保存合法旧报告及其SHA256，复制配置并把schedule_rates末项改为true。先将--output指向旧报告，要求非零退出且摘要不变；再指向不存在的子目录中的report.json，要求非零退出且目录仍不存在。

再分别测试CSV最后一行多出EXTRA、末项NaN、JSON重复键。普通与python -O均须拒绝，证明保护不依赖assert。将更新入口替换为一调用就抛RuntimeError的哨兵，可检查坏末字段是否在任何计算前被拒绝。