

035 动量与加速方法

1 历史方向能解决什么 又会引入什么

第032讲中，一个步长同时服务平缓方向和陡峭方向：为了不在谷壁上发散，平缓方向往往只能缓慢前进。第034讲又提醒我们，梯度中的短期变化也可能来自抽样噪声。现在增加一个状态，把过去的方向带到下一步。持续同向的分量能够积累，交替分量可能部分抵消；代价是惯性、超调、额外初值和更复杂的稳定条件。

本讲的目标不是记住一个“默认动量值”，而是能回答四个可核验的问题：梯度在哪一个点计算？保存的状态是什么单位？二次目标的两个状态根在哪里？代码库里的参数是否就是论文里的参数？我们用同一组四行回归数据，把预测、残差、局部导数、梯度累积、同步更新和新前向连起来。

直接先修为第015、032、034讲。需要会看矩阵形状、特征值和逐样本梯度。本讲主要分析确定性全梯度；第19节单独说明它与随机梯度结论的边界。所有实验为原创小型合成机制实验，不评价真实预测任务或大规模训练耗时。

2 四行数据和两个参数

每行有两个无量纲特征。我们有意不加截距，因为标签就是第一个特征；这里 a 是第一个特征的系数，不是截距。模型为 $\hat{y}_i = x_{i1}a + x_{i2}b$ ，参数 $\theta = (a, b)^T \in \mathbb{R}^2$ ，数据矩阵 $X \in \mathbb{R}^{4 \times 2}$ 。

样本	x_1	x_2	y
S1	1	4	1
S2	1	-4	1
S3	-1	4	-1
S4	-1	-4	-1

残差统一取“预测减标签”，即 $r_i = \hat{y}_i - y_i$ 。目标与单行贡献定义为

$$F(\theta) = \frac{1}{2n} \sum_{i=1}^n r_i^2 = \sum_{i=1}^4 \ell_i, \quad n = 4, \quad \ell_i = \frac{r_i^2}{8}.$$

所以 F 是二分之一的均方误差，不是平方误差总和。若换成MSE，梯度和Hessian都乘2；原步长就不能直接照搬。




图1 同一四行数据产生狭长二次谷底。右图横轴a、纵轴b是参数，不是左图的输入特征；最优点为(1,0)。

两列的平方平均分别为1和16，交叉平均为0： $X^T X/4 = \text{diag}(1, 16)$ 。而 $X^T y/4 = (1, 0)^T$ 。因而

$$\theta^* = (1, 0)^T, \quad F^* = 0, \quad F(a, b) = \frac{1}{2}(a - 1)^2 + 8b^2.$$

例如展开残差 $x_{i1}(a - 1) + x_{i2}b$ 的平方，交叉项之和含 $\sum_i x_{i1}x_{i2} = 0$ ，所以恰好消失。这一步连接了数据目标和画图所用的二次式，并没有换一个目标。梯度为 $(a - 1, 16b)^T$ ，Hessian为 $\text{diag}(1, 16)$ ，强凸常数 $\mu=1$ 、光滑常数 $L=16$ 、条件数 $\kappa=16$ 。这里所有量无物理单位；实际有单位的数据必须先明确坐标尺度。

3 梯度不能从公式凭空跳出来

单行链条为参数→预测→残差→损失贡献。对 $j=1, 2$ ，局部导数是

$$\frac{\partial \hat{y}_i}{\partial \theta_j} = x_{ij}, \quad \frac{\partial r_i}{\partial \hat{y}_i} = 1, \quad \frac{\partial \ell_i}{\partial r_i} = \frac{r_i}{4}.$$

相乘得到第 i 行的梯度贡献 $(r_i x_{i1}/4, r_i x_{i2}/4)$ 。按行相加得到 $g = X^T r/4 \in \mathbb{R}^2$ 。这里每行贡献已经除4，总和后不能再除4。全部分量必须使用同一个旧参数或同一个lookahead点计算；更新 a 后再用新 a 计算 b 的梯度，会改变算法。

先固定 $\theta_0 = (0, 1)^T$ 。下面一张表把第一轮前向和反向全部展开。最后两列就是“ $r/4 \times 1 \times$ 相应特征”。

样本	预测	残差 r	损失 $r^2/8$	a梯度贡献	b梯度贡献
S1	4	3	$\frac{9}{8}$	$\frac{3}{4}$	3
S2	-4	-5	$\frac{25}{8}$	$-\frac{5}{4}$	5
S3	4	5	$\frac{25}{8}$	$-\frac{5}{4}$	5
S4	-4	-3	$\frac{9}{8}$	$\frac{3}{4}$	3

四行损失贡献相加得 $17/2$ ；两列梯度贡献分别相加得 -1 和 16 。检查对角表达式也得到 $F(0,1) = 1/2 + 8 = 17/2$ 。这两条计算路线以后还会用于发现因子或实现错误。

4 Heavy-ball 保存的是上一次位移

用 $d_t = \theta_t - \theta_{t-1}$ 表示上一轮位移；初值 $d_0 = 0$ 相当于设置 $\theta_{-1} = \theta_0$ 。给定步长 $\eta > 0$ 和动量系数 $0 \leq \beta < 1$ ，heavy-ball简称HB，更新为

$$d_{t+1} = \beta d_t - \eta \nabla F(\theta_t), \quad \theta_{t+1} = \theta_t + d_{t+1}.$$

d 与参数具有相同单位，梯度乘 η 后才变成位移。 $\beta=0$ 时退化为普通梯度下降。HB每步只需要一个新梯度，不是把旧梯度重新计算一次。它保存的是状态，因此断点恢复只保存 θ 而丢掉 d ，一般不能继续同一条轨迹。

为了看清历史，把递推展开： $d_1 = -\eta g_0$ ， $d_2 = -\eta(\beta g_0 + g_1)$ ，再代一次得到 $d_3 = -\eta(\beta^2 g_0 + \beta g_1 + g_2)$ 。一般地，常数 η 、 β 下

$$d_{t+1} = \beta^{t+1} d_0 - \eta \sum_{k=0}^t \beta^{t-k} g_k.$$

旧梯度按年龄指数衰减。若梯度恒为 g 且 $d_0=0$ ，有限几何和给 $d_{t+1} = -\eta g(1 - \beta^{t+1})/(1 - \beta)$ ，极限大小放大为 $\eta/(1-\beta)$ 。这只是恒定输入的响应，不意味着优化中可以把实际步长永久当成 $\eta/(1-\beta)$ ，因为 g 本身随位置变化。

若一维输入交替为 $g_t = (-1)^t c$ ，缓冲区 $b_{t+1} = \beta b_t + g_t$ 的稳态交替幅度是 $c/(1+\beta)$ ：代入 $b_{t+1} = K(-1)^t$ 得到 $K = -\beta K + c$ 。持续信号的增益 $1/(1-\beta)$ 与交替信号的增益 $1/(1+\beta)$ 不同，解释了方向积累与部分抵消的可能机制。




图2 左图是过去梯度的未归一化权重；右图给 $\beta=1/2$ 时恒定和交替输入的实际递推。它是滤波器响应，不是全目标每步下降的证明。

5 HB第一轮 从四行梯度到新的四行前向

手算统一取 $\eta=1/16$ 、 $\beta=1/2$ 、 $d_0=(0,0)$ 。第3节已由四行得到 $g_0=(-1,16)$ ，所以先算整个新位移，再同时加到两个参数：

$$d_1 = \frac{1}{2}(0,0) - \frac{1}{16}(-1,16) = (1/16, -1), \quad \theta_1 = (0,1) + d_1 = (1/16, 0).$$

第一坐标变为1/16时，第二坐标必须也使用旧梯度16更新为0。现在参数改变了，必须重新做四行前向：

样本	预测	残差r	损失 $r^2/8$	a梯度贡献	b梯度贡献
S1	$\frac{1}{16}$	$-\frac{15}{16}$	$\frac{225}{2048}$	$-\frac{15}{64}$	$-\frac{15}{16}$
S2	$\frac{1}{16}$	$-\frac{15}{16}$	$\frac{225}{2048}$	$-\frac{15}{64}$	$\frac{15}{16}$
S3	$-\frac{1}{16}$	$\frac{15}{16}$	$\frac{225}{2048}$	$-\frac{15}{64}$	$\frac{15}{16}$
S4	$-\frac{1}{16}$	$\frac{15}{16}$	$\frac{225}{2048}$	$-\frac{15}{64}$	$-\frac{15}{16}$

损失为 $4 \times (225/2048) = 225/512$ ，梯度为 $(-15/16, 0)$ 。虽然b方向梯度现在为0， d_1 的b分量仍为-1。动量系统还没忘记自己刚才的运动。

6 HB第二轮 为什么会穿过谷底

第二轮的旧点就是上表中的 θ_1 。四行残差仍是 $(-15/16, -15/16, 15/16, 15/16)$ ，局部损失导数为 $(-15/64, -15/64, 15/64, 15/64)$ 。乘相应特征后相加，得到 $g_1=(-15/16, 0)$ 。

$$d_{2,a} = \frac{1}{2} \frac{1}{16} - \frac{1}{16} \left(-\frac{15}{16} \right) = \frac{8}{256} + \frac{15}{256} = \frac{23}{256},$$

$$d_{2,b} = \frac{1}{2}(-1) - \frac{1}{16}(0) = -\frac{1}{2}, \quad \theta_2 = (39/256, -1/2).$$

这两个新坐标一起生效，然后重新前向。第1行预测为 $39/256 - 2 = -473/256$ ，减去标签1得到 $-729/256$ 。其余三行也不能沿用旧残差。

样本	预测	残差r	损失 $r^2/8$	a梯度贡献	b梯度贡献
S1	$-\frac{473}{256}$	$-\frac{729}{256}$	$\frac{531441}{524288}$	$-\frac{729}{1024}$	$-\frac{729}{256}$
S2	$\frac{551}{256}$	$\frac{295}{256}$	$\frac{87025}{524288}$	$\frac{295}{1024}$	$-\frac{295}{256}$
S3	$-\frac{551}{256}$	$-\frac{295}{256}$	$\frac{87025}{524288}$	$\frac{295}{1024}$	$-\frac{295}{256}$
S4	$\frac{473}{256}$	$\frac{729}{256}$	$\frac{531441}{524288}$	$-\frac{729}{1024}$	$-\frac{729}{256}$

四行损失贡献之和等于 $\frac{1}{2}(217/256)^2 + 8(1/2)^2 = 309233/131072$ ，约2.35926，比上一轮 $225/512 \approx 0.43945$ 更大。新梯度为 $(-217/256, -8)$ 。这不是程序错误：虽然该 η 、 β 在本二次目标上严格稳定，但当前位置的F没有逐步单调下降。旧位移带着参数从 $b=0$ 冲到了 $b=-1/2$ 。

7 Nesterov 在预看点计算梯度

本讲先定义明确的lookahead形式，简称NAG：

$$z_t = \theta_t + \beta d_t, \quad d_{t+1} = \beta d_t - \eta \nabla F(z_t), \quad \theta_{t+1} = \theta_t + d_{t+1}.$$

z 是本轮梯度评估点， θ 是本讲报告的主参数。两个都要记录。等价地， $\theta_{t+1} = z_t - \eta \nabla F(z_t)$ ：先按旧惯性预看，再从预看点做一次梯度修正。这里没有免费获得“未来梯度”；必须真的用 z 重新前向与求导。仍然是一轮一个新全梯度，旧点的目标若另外记录，就属于诊断成本。

初值 $d_0=0$ 使 $z_0=\theta_0$ 。第一轮逐样本预测、残差、局部导数和梯度全部等于第3节；同步更新仍得到 $d_1=(1/16, -1)$ 、 $\theta_1=(1/16, 0)$ ，新前向恰好是第5节的表。第一步相同不足以说明两个算法相同。

第二轮先记录旧点 θ_1 。旧点前向给 $F=225/512$ 、 $g=(-15/16, 0)$ ，但NAG不把这个梯度用于本轮更新。预看点是

$$z_1 = (1/16, 0) + \frac{1}{2}(1/16, -1) = (3/32, -1/2).$$

现在对同一四行数据在 z_1 重新计算：

样本	预测	残差r	损失 $r^2/8$	a梯度贡献	b梯度贡献
S1	$-\frac{61}{32}$	$-\frac{93}{32}$	$\frac{8649}{8192}$	$-\frac{93}{128}$	$-\frac{93}{32}$
S2	$\frac{67}{32}$	$\frac{35}{32}$	$\frac{1225}{8192}$	$\frac{35}{128}$	$-\frac{35}{32}$
S3	$-\frac{67}{32}$	$-\frac{35}{32}$	$\frac{1225}{8192}$	$\frac{35}{128}$	$-\frac{35}{32}$
S4	$\frac{61}{32}$	$\frac{93}{32}$	$\frac{8649}{8192}$	$-\frac{93}{128}$	$-\frac{93}{32}$

四个局部损失导数 $r/4$ 分别为 $-93/128$ 、 $35/128$ 、 $-35/128$ 、 $93/128$ 。梯度a列累积为 $(-93+35+35-93)/128=-29/32$ ；梯度b列累积为 $(-93-35-35-93)/32=-8$ 。预看点的损失是 $4937/2048$ ，约2.41064，不能误标成旧点损失。

8 NAG第二轮 完成修正和下一轮前向

把上述预看梯度代入，而不是把旧点的零b梯度代入：

$$d_{2,a} = \frac{1}{32} + \frac{29}{512} = \frac{45}{512}, \quad d_{2,b} = -\frac{1}{2} - \frac{1}{16}(-8) = 0.$$

同步更新得 $\theta_2 = (1/16 + 45/512, 0) = (77/512, 0)$ 。随后四行重新前向：

样本	预测	残差r	损失 $r^2/8$	a梯度贡献	b梯度贡献
S1	$\frac{77}{512}$	$-\frac{435}{512}$	$\frac{189225}{2097152}$	$-\frac{435}{2048}$	$-\frac{435}{512}$
S2	$\frac{77}{512}$	$-\frac{435}{512}$	$\frac{189225}{2097152}$	$-\frac{435}{2048}$	$\frac{435}{512}$
S3	$-\frac{77}{512}$	$\frac{435}{512}$	$\frac{189225}{2097152}$	$-\frac{435}{2048}$	$\frac{435}{512}$
S4	$-\frac{77}{512}$	$\frac{435}{512}$	$\frac{189225}{2097152}$	$-\frac{435}{2048}$	$-\frac{435}{512}$

新损失为 $\frac{1}{2}(435/512)^2 = 189225/524288$ ，新梯度为 $(-435/512, 0)$ 。这里b方向的预看梯度恰好抵消了惯性。原因是本例高曲率 $\lambda=16$ 且 $\eta\lambda=1$ ；换一个步长、曲率或动量，不能保证恰好抵消。




图3 同一第二轮的向量几何。虚线是惯性预看，蓝箭头是梯度修正；HB的梯度来自旧点，NAG的梯度来自预看点。两图都从 $(1/16, 0)$ 出发。




图4 同一 $\eta=1/16$ 、 $\beta=1/2$ 下的实际前八轮。HB第二轮目标上升而最终仍稳定；本例NAG高曲率方向在第一轮后保持为0。

9 为什么从一个误差变成两个状态

对一般严格凸二次函数 $F(\theta) = F^* + \frac{1}{2}(\theta - \theta^*)^T H(\theta - \theta^*)$ ，假定 H 为固定对称正定矩阵。取单位特征向量 q 满足 $Hq = \lambda q$ ， $\lambda > 0$ ；把误差投影到这个方向，记 $e_t = q^T(\theta_t - \theta^*)$ 。梯度在该方向就是 λe_t 。

HB消去位移 $d_t = \theta_t - \theta_{t-1}$ 后，逐项合并得到

$$e_{t+1} = e_t + \beta(e_t - e_{t-1}) - \eta\lambda e_t = (1 + \beta - \eta\lambda)e_t - \beta e_{t-1}.$$

NAG评估点的误差为 $e_t + \beta(e_t - e_{t-1})$ 。从它减去 η 乘其梯度，得到

$$e_{t+1} = (1 - \eta\lambda)[(1 + \beta)e_t - \beta e_{t-1}].$$

设 $h=\eta\lambda$ ，并统一写 $e_{t+1} = Ae_t - De_{t-1}$ 。则状态 $s_t = (e_t, e_{t-1})^T$ 满足

$$s_{t+1} = M_\lambda s_t, \quad M_\lambda = \begin{pmatrix} A & -D \\ 1 & 0 \end{pmatrix}.$$

HB用 $A=1+\beta-h$ 、 $D=\beta$ ；NAG用 $A=(1+\beta)(1-h)$ 、 $D=\beta(1-h)$ 。每一个参数方向对应一个二维状态；本例两个参数方向合起来是四维状态，而不是“原问题变成二维所以只有两个根”。初始 $d_0=0$ 给 $e_{-1}=e_0$ ，若 d_0 不为0，则 $e_{-1}=e_0 - q^T d_0$ 。

10 状态根 判别式和振荡

寻找形如 $e_t = r^t$ 的解。代入递推并消去共同因子后得到 $r^2 - Ar + D = 0$ ，也就是 $\det(rI - M_\lambda) = 0$ 。解为

$$r_{\pm} = \frac{A \pm \sqrt{A^2 - 4D}}{2}, \quad \Delta = A^2 - 4D.$$

当 $\Delta > 0$ 时有两个不同实根， $e_t = c_+ r_+^t + c_- r_-^t$ ，常数由两个初值决定。负根会导致交替符号，正根并不保证任意初值下误差单调。当 $\Delta < 0$ 时，两个根互为共轭；因乘积为 D ，模均为 $\sqrt{|D|}$ ，可以写成指数包络乘正弦、余弦。HB此时 $D=\beta$ ，所以包络模为 $\sqrt{\beta}$ 。

$\Delta=0$ 时要小心：重复根常产生 $(c_1 + c_2 t)r^t$ 。因此谱半径 $\rho < 1$ 意味着最终衰减，但不能不带常数或多项式因子就声称 $|e_t| \leq \rho^t |e_0|$ 。r=0的重根还可能使状态矩阵幂在有限步后归零，应直接检查递推。

NAG在 $h > 1$ 且 $\beta > 0$ 时 $D < 0$ ，两根一定异号且为实根。因此“ Δ 为正就不会震荡”也是错的。振荡、目标非单调、发散是三个不同概念：参数可交替而目标下降；目标可短暂上升而状态最终收敛。




图5 手算参数下，每个曲率方向的两个状态根。虚线单位圆内部对应严格稳定；两个参数方向的根必须一起检查。

11 稳定区域从三个不等式得到

这里稳定特指：对这一固定正曲率二次方向、任意有限两个初始状态，误差都趋于0。它不是“前十步看着没爆炸”，也不是“函数值逐轮下降”。二次实系数多项式 $r^2 - Ar + D$ 的两个根严格在单位圆内，当且仅当

$$|D| < 1, \quad 1 - A + D > 0, \quad 1 + A + D > 0.$$

为什么？若根为共轭， D 是根模平方，第一条保证模小于1，后两式分别为 $|1 - r|^2$ 和 $|1 + r|^2$ 。若根为实数，后两式分别是 $(1-r_+)(1-r_-)$ 和 $(1+r_+)(1+r_-)$ 。若某根 ≥ 1 ，前一个正数条件迫使另一根也 >1 ，乘积便 ≥ 1 ，矛盾； ≤ -1 同理。因此三个条件充分。反过来，两个根都在 $(-1,1)$ 时三个条件显然成立。这给出了本例所需的二阶Jury判据，不必先学习一般控制理论。

HB代入 A 、 D 后： $|\beta| < 1$ 已由 $0 \leq \beta < 1$ 保证；第二条是 $h > 0$ ；第三条是 $2 + 2\beta - h > 0$ 。所以

$$\text{HB: } 0 < \eta\lambda < 2(1 + \beta).$$

NAG的第二条仍为 $h > 0$ ，第三条变为 $1 + (1 + 2\beta)(1 - h) > 0$ ，即 $h < 2(1 + \beta)/(1 + 2\beta)$ 。在这个范围内， $|\beta(1 - h)| < 1$ 也成立： $h \leq 1$ 时绝对值 $\leq \beta < 1$ ； $h > 1$ 时 $\beta(h - 1) < \beta/(1 + 2\beta) < 1$ 。因此

$$\text{NAG: } 0 < \eta\lambda < \frac{2(1 + \beta)}{1 + 2\beta}.$$

整个正定二次目标要求每个 λ 都满足条件，故只需用最大特征值 L 约束上界。 $\beta = 0$ 时两者都回到 $0 < \eta L < 2$ 。 $\beta = 1$ 、零曲率、时变Hessian或时变超参数不在这里的结论范围内。




图6 开区域不包含边界。增加 β 扩大HB的正二次稳定步长区间，却缩小本讲NAG形式的区间；这不等于HB具有更好的普遍收敛定理。

边界也不是小细节。取 $\beta=1/2$ 、只激活 $\lambda=L=16$ 的方向，HB边界 $\eta=3/16$ 有根 -1 和 $-1/2$ 。初始 $e_{-1}=e_0=1$ 给 $e_1=-2$ ，解为 $3(-1)^t - 2(-1/2)^t$ ，不会趋于0。NAG边界 $\eta=3/32$ 有根 -1 和 $1/4$ ，同初值给 $e_1=-1/2$ ，解为 $(3/5)(-1)^t + (2/5)(1/4)^t$ ，同样不收敛。实验保存实际20步边界轨迹；解析式给出无限时间结论。




图7 $\beta=1/2$ 时的判别式和谱半径。左图描述根的类型，右图的 ρ 是否小于1才决定本节的严格稳定。

12 初值和非单调不能藏起来

如果从最优位置 $\theta_0=(1,0)$ 出发，但给 $d_0=(1/4,0)$ ，HB第一步梯度为0，仍有 $d_1=(1/8,0)$ 、 $\theta_1=(9/8,0)$ ，目标升到 $1/128$ 。相同 θ 、不同 d 会走出不同轨迹。对NAG，初始预看点也会因 d 不同而不同。比较算法必须同时记录位置、速度、缓冲区初始化和“第一步”的编号。

上述第一步仍然遵循同一四行链：最优点的预测为 $(1,1,-1,-1)$ ，残差和每行损失、梯度贡献全为0；更新后的预测为 $(9/8,9/8,-9/8,-9/8)$ ，残差为 $(1/8,1/8,-1/8,-1/8)$ ，每行损失 $1/512$ ，合计 $1/128$ ，梯度 $(1/8,0)$ 。它不是新的数据例子，只改变了初始状态。第二轮以刚才的新前向作为旧前向：局部导数为 $(1/32,1/32,-1/32,-1/32)$ ，a梯度贡献每行 $1/32$ ，b贡献为 $(1/8,-1/8,-1/8,1/8)$ ，合计 $(1/8,0)$ 。所以

$d_2=(1/16-1/128,0)=(7/128,0)$, $\theta_2=(151/128,0)$ 。再前向得预测
 $(151/128,151/128,-151/128,-151/128)$, 残差 $(23/128,23/128,-23/128,-23/128)$, 各行损失
 $529/131072$, 合计 $529/32768$, 新梯度 $(23/128,0)$ 。




图8 起点都在同一最优位置，非零初始速度仍会把参数带走。右图的上升不否认正定二次下最终稳定。

第033讲的梯度下降下降引理不能直接套到HB位移上：把位移换成 $\beta d - \eta g$ 后，一阶项中多出 $\beta g^T d$ ，二阶项也包含 d 。要证明某种动量方法的全局收敛，通常要把函数误差与状态组合成适当势能，不能仅把旧证明里的“ $-\eta g$ ”换一个名字。

13 以谱为目标选择参数

先考虑给定 $0 < \mu \leq \lambda \leq L$ 的正定二次目标、常数参数、精确梯度。GD最坏方向倍率为 $\max(|1-\eta\mu|, |1-\eta L|)$ 。平衡两个端点的相反误差，令 $1-\eta\mu=-(1-\eta L)$ ，得到 $\eta=2/(L+\mu)$ ，倍率 $(L-\mu)/(L+\mu)$ 。本例 $\eta=2/17$ ，倍率 $15/17$ 。

HB可以让中间曲率方向具有相同根模 q ，并让端点成为 $\pm q$ 的重根。取 $\beta=q^2$ ，要求

$$1 + q^2 - \eta\mu = 2q, \quad 1 + q^2 - \eta L = -2q.$$

整理为 $\eta\mu=(1-q)^2$ 、 $\eta L=(1+q)^2$ 。两式相除并取正平方根， $\sqrt{\kappa} = (1+q)/(1-q)$ ，所以

$$q = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, \quad \beta = q^2, \quad \eta = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}.$$

这是该谱区间上常系数HB的经典最坏方向谱半径最优设置。本节构造并核对其达到的 q ；更完整的最优性分析见来源[3]附录A。本例 $\eta=4/25$ 、 $\beta=9/25$ ， $q=3/5$ 。端点是重根，仍需第10节的 t 因子，不能把 q 当成每一步损失比。

NAG的标准强凸设置为 $\eta=1/L$ 、 $\beta = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ 。本例 $\eta=1/16$ 、 $\beta=3/5$ 。 $\lambda=1$ 方向的 $A=3/2$ 、 $D=9/16$ ，两个根都是 $3/4$ ； $\lambda=16$ 方向根均为0。因此本例的状态谱半径为 $3/4$ 。这与HB的 $\beta=9/25$ 不同：HB用了 q 的平方，NAG没有。名字相似不能用同一个数字代替推导。

14 实际同预算比较 看见加速也看见瞬态

全部方法从 $\theta_0=(0,1)$ 、 $d_0=0$ 出发，各申请80次全梯度更新，每步4个样本梯度，最多320次样本梯度计算。额外的初始与新状态完整前向单独记录。没有把更多函数诊断视为免费，也没有把梯度次数换成硬件秒数。

方法与设置	η	β	首次目标 $\leq 10^{-6}$ 的更新数
GD保守	1/16	0	80步内未达到
GD端点平衡	2/17	0	64
HB手算设置	1/16	1/2	42
NAG手算设置	1/16	1/2	47
HB二次谱调参	4/25	9/25	23
NAG标准强凸设置	1/16	3/5	31

这些数字由真实逐样本循环取得，不由谱半径公式替代实验。不同设置都有明确目的：手算组隔离梯度评估点差异，调参组比较各自的理论设置。不能只把各自最好的一条线拿来宣称“某算法在任何任务都更快”。




图9 同一狭长谷底。左图是各自调参后的前12步，右图是80步完整轨迹。目标由已存储参数处的稳定二次式计算；所有更新仍来自逐样本残差梯度。

HB谱调参的第一步从 $b=1$ 到 $-39/25=-1.56$ ，高曲率误差先被放大。完整目标从8.5升到19.8216，后续才快速衰减。初始阶段的大幅超调与渐近较小谱半径可以同时出现；对有约束、数值范围有限或中途必须可用的模型，瞬态本身就是重要指标。

再用同一个 $\eta=0.12$ 、 $\beta=0.9$ 比较两种方法。高曲率方向 $h=1.92$ ，HB上界是3.8，NAG上界是 $3.8/2.8 \approx 1.35714$ 。于是HB严格稳定，NAG不稳定。实际80步的目标约分别为 1.13768×10^{-4} 和 1.14402×10^{53} 。这直接反驳“Nesterov在任何相同步长下都更稳定”，但没有否定其在满足假设与参数规则时的加速保证。




图10 压力组使用相同数据、初值、步长和动量。左图放大早期b轨迹，右图显示完整有限预算中的目标数量级；不得把这组不合格NAG步长拿来评价其理论速率。

15 库里的momentum可能保存另一种量

本讲位移形式是 $d_{t+1} = \beta d_t - \eta g_t$ 。另一常见写法先存梯度缓冲区 $v_{t+1} = \beta v_t + g_t$ ，再更新 $\theta_{t+1} = \theta_t - \eta v_{t+1}$ 。固定 η 、匹配初值时，两者由 $d = -\eta v$ 等价。

还有归一化移动平均 $m_{t+1} = \beta m_t + (1 - \beta)g_t$ ，参数更新为 $\theta_{t+1} = \theta_t - \alpha m_{t+1}$ 。若 $m_0 = v_0 = 0$ ，则 $m = (1 - \beta)v$ ，匹配未归一化步长 η 必须令 $\alpha = \eta / (1 - \beta)$ 。若把相同 η 和 β 直接喂给两种定义，更新大小不同。本讲实际代码也用转换后的 α 逐步验证了等价关系。

学习率一旦变化，不能继续使用固定比例。对于“lr在缓冲区外”的版本，令 $d_t = -\eta_{t-1} v_t$ ，代入下一步得到

$$d_{t+1} = \beta \frac{\eta_t}{\eta_{t-1}} d_t - \eta_t g_t.$$

这与保持 β 不变的位移版不同。学习率减半时，等效旧位移系数也减半。若 $\eta_{t-1}=0$ ，上式除法无定义，应回到原始缓冲区方程。本讲输入要求正学习率，实际用1/16、1/32、1/32、1/64的计划展示差异。

16 PyTorch SGD的第一缓冲区和dampening

实际核对版本为PyTorch2.7.1+cpu；官方2.7文档与已安装2.7.1代码共同确定行为[4]。实验指定CPU、float64、单线程，foreach=False、fused=False、weight_decay=0、maximize=False、differentiable=False，每步先zero_grad，再从同一平方损失反向传播。

在momentum>0、缓冲区原先不存在时，第一步直接令 $v_1 = g_0$ 。以后才用 $v_{t+1} = \beta v_t + (1 - \tau)g_t$ ， τ 是dampening。 $\tau=0$ 时，它等价于从零缓冲区执行普通递推； $\tau \neq 0$ 时，不能假设第一步也乘了 $1-\tau$ 。

例如仍取 $\eta=1/16$ 、 $\beta=1/2$ 、 $\tau=1/4$ ，第一步仍到 $(1/16, 0)$ 。如果错误地把第一梯度也乘 $3/4$ ，则会到 $(3/64, 1/4)$ 。真实测试逐步读取optimizer.state中的momentum_buffer，并与从零实现的特殊首步核对。PyTorch还要求Nesterov使用正动量和零dampening；实际构造非零dampening的Nesterov优化器会抛出ValueError，实验确实执行了这个拒绝测试。

17 PyTorch的Nesterov参数其实对应预看点

记PyTorch保存的参数为 z_t 。固定 η 、 β ，零初始buffer，且dampening=weight_decay=0时，PyTorch执行

$$g_t = \nabla F(z_t), \quad v_{t+1} = \beta v_t + g_t, \quad z_{t+1} = z_t - \eta(g_t + \beta v_{t+1}).$$

与本讲lookahead形式的映射是

$$d_t = -\eta v_t, \quad z_t = \theta_t + \beta d_t, \quad \theta_t = z_t + \eta \beta v_t.$$

验证时不要跳步。把 z_t 与 d_t 代入，有 $d_{t+1} = \beta d_t - \eta g_t = -\eta v_{t+1}$ 。再由 $\theta_{t+1} = \theta_t + d_{t+1}$ ，得到新的预看点

$$\theta_{t+1} + \beta d_{t+1} = z_t - \eta g_t + \beta d_{t+1} = z_t - \eta(g_t + \beta v_{t+1}),$$

恰是库里的 z_{t+1} 。映射成立依赖固定 η 、 β 与一致状态；更一般计划需重新推导。

第一步库参数为 $z_1 = (0, 1) - (1/16)(1 + 1/2)(-1, 16) = (3/32, -1/2)$ 。论文主点却是 $\theta_1 = (1/16, 0)$ 。两者不相等完全正确，因为 z_1 就是 $\theta_1 + \beta d_1$ 。用 $v_1 = (-1, 16)$ 恢复 $\theta_1 = z_1 + \eta \beta v_1$ 即可。直接比较两者会错误报告“库实现不对”。

真实验证覆盖HB和NAG各12步，逐步比较评估点、autograd梯度、buffer、位移和恢复后的 θ ；最大绝对差为 1.11023×10^{-16} 。另有dampening特殊首步、学习率计划和归一化EMA转换测试。这里只验证指定版本、dtype、设置与数据，不意味着所有框架或未来版本行为相同。




图11 左图的库原始参数 z 与论文主点 θ 本就不同，恢复后才应相等。右图在学习率变化时展示两种缓冲区定义的真实差异。

18 加速保证究竟保证哪一个对象

“加速”必须同时写明函数类、信息来源、参数规则、误差量和预算。对全空间上 μ 强凸且 L 光滑的函数，精确全梯度、 $\mu > 0$ 、最优点存在，NAG标准设置 $\eta = 1/L$ 、 $\beta = (\sqrt{L/\mu} - 1)/(\sqrt{L/\mu} + 1)$ 、 $d_0 = 0$ 有几何型函数误差上界。按本讲 θ 编号，一个标准表述为[2]

$$F(\theta_t) - F^* \leq \frac{L + \mu}{2} \|\theta_0 - \theta^*\|^2 \left(1 - \sqrt{\mu/L}\right)^t.$$

$t=0$ 时右侧按初始常数理解； $\mu=L$ 时 $\beta=0$ 且 $\eta=1/L$ ，一步达到最优，不需要计算 θ^0 。该界来自适当势能或估计序列，本讲不以二次谱实验冒充其一般证明。本讲完整推导的是固定二次目标的状态递推和稳定条件；一般强凸结论在来源中有完整证明。界可以宽松，也不要求每一轮 F 单调。注意它是函数误差的保证，不是把某个状态谱半径直接当成函数值倍率。

对仅凸且 L 光滑的函数，经典 $O(1/t^2)$ 加速需要相应的随时间变化的系数序列和初始化；本讲固定 $\beta=0.5$ 或 0.9 的代码没有自动获得这条保证。对HB，正定二次上的最优谱调参也不能直接推广到所有光滑强凸函数。来源[3]给出光滑强凸非二次函数上HB二次最优参数出现极限环的反例。对非凸目标，更不能把这些函数差到全局最优点的保证照搬。

若声称一个实验“证明加速”，先问：比较的是 $F-F^*$ 、距离、梯度范数还是真实耗时？各方法是否用了相同数据、相同梯度预算和可比调参信息？是否只挑选一个初值或忽略了失败轨迹？这些问题比只画更陡的一条线重要。

19 与随机梯度的关系

动量能滤除一些高频变化，但“滤波”不等于“免费消除噪声”。在一个冻结位置、独立零均值噪声 ξ_t 、方差 σ^2 的简化标量模型中，未归一化buffer的噪声部分是 $\sum_{k=0}^t \beta^k \xi_{t-k}$ 。独立使交叉项期望为0，所以方差为 $\sigma^2 \sum_{k=0}^t \beta^{2k}$ ，极限 $\sigma^2/(1-\beta^2)$ 。

若换成归一化EMA，同一冻结模型的方差则乘 $(1-\beta)^2$ ，得到 $\sigma^2(1-\beta)/(1+\beta)$ 。然而要匹配原算法的位移又需要把学习率放大 $1/(1-\beta)$ ，因此不能只引用较小的EMA方差就宣称同效更新更安静。

真实训练中 θ 随过去噪声变化，梯度不是固定信号，状态与未来梯度的条件结构需要重新分析。第034讲的无偏抽样、batch大小和噪声底仍然重要。确定性二次目标的谱图没有证明随机动量拥有同一渐近精度，也没有证明数据重排后的条件无偏性。

20 浮点状态和实验的证据边界

运行报告区分budget_exhausted、represented_optimum_zero_velocity、floating_state_stagnation、forward_cancellation_limit、numeric_range_limit。预算耗尽只是停止原因，不表示已达到目标；first_target_t单独记录。存储 θ 恰为已知可表示最优点且 $d=0$ ，与仅仅一轮 θ 没有变化是两回事。

设 $a=\text{nextafter}(1,2)$ 、 $b=0$ 、 $\eta=10^{-8}$ 。 $a-1$ 仍可表示，但更新可能小于 a 处的舍入间隔，导致 a 不变。若初始 d 还有一个微小非零量，下一轮 d 可能继续改变。因此程序只有 θ 和 d 都不再变化时才报告整个状态停滞，不能只检查位置。




图12 同一实际浮点探针中，左图位置连续不变，右图隐藏速度仍然变化。这里的位置不动是舍入行为，不是一般意义下的精确驻点证明。

目标的逐行残差式与几何式在实数中相等，但接近最优时，预测减标签可能相消。报告保留原始前向loss与在存储参数处计算的geometric_gap；图中的极小目标使用后者。更新仍然使用逐行梯度，不暗中改成解析梯度。若实际求得零梯度但评估点不是这个已知最优点，程序标记forward_cancellation_limit并停止，防止把丢失的残差当成数学成功。大幅发散时，不同样本的梯度累积也会丢失较小方向；本讲不把这种浮点轨迹当成精确实数轨迹。

输入验证先检查原始类型与每个末字段，再开始数值计算。普通与python -O都运行同一显式校验；bool不能假装整数，字符串和非内置数值不能先转换再通过。CLI在完整计算与JSON序列化成功之后才创建输出目录，最后原子替换；失败保留旧报告。Notebook第一代码格先核对两份默认输入的完整字节，再输出任何数字或图。

21 自测题

1. 从四行数据推导F、梯度和Hessian，说明 $1/2$ 与 $1/n$ 各在哪里。
2. 独立重算初值 $\theta_0=(0,1)$ 的四行预测、损失和梯度贡献。
3. 用 $\eta=1/16$ 、 $\beta=1/2$ 写出HB两轮完整链，并指出目标上升发生在哪里。
4. 写出NAG第二轮旧点与预看点的全部前向，解释为何不能用旧点的零b梯度。
5. 展开 d_t 的历史权重，分别求恒定和交替输入的稳态响应。
6. 推出一个特征方向的HB与NAG状态矩阵，说明初始化 e_{-1} 如何确定。
7. 证明本讲二阶Jury判据，并推出两个开稳定区间。
8. 在 $\beta=1/2$ 的两种边界上求根和完整解，解释为何有界仍可能不收敛。
9. 为什么 $\Delta>0$ 不保证无震荡？为什么 $\rho<1$ 不保证逐轮下降？
10. 求本例GD、HB、标准强凸NAG的参数与谱半径，区分 β 是否平方。
11. HB从最优位置但非零速度出发会怎样？补做第二轮并重新前向。
12. 比较未归一化buffer与EMA，给出正确步长换算。
13. 推出学习率变化时位移递推中的 η_t/η_{t-1} ，核对前两步计划。
14. 解释PyTorch dampening第一步，并计算正确与错误首步。
15. 推导PyTorch Nesterov与lookahead形式的映射，核对第一步原始参数。
16. 检查 $\eta=0.12$ 、 $\beta=0.9$ 下两种方法的稳定性，说明这不否定NAG定理。
17. 哪些条件缺失时不能套用 $O(1/t^2)$ 或强凸加速界？
18. 构造位置不变但速度变化的状态，设计不会误报成功的停止规则。
19. 说明冻结位置噪声方差公式为何不能直接作为随机动量全程误差界。
20. 设计一个坏末字段CLI测试，验证旧输出保留且新目录不出现。

22 一手来源和核查范围

- [1] [Sutskever等（2013）原论文](#)。实际读取第2节式(1)至(4)，核对位移型HB和lookahead NAG。本讲四行数据、表格与机制图独立构造。
- [2] [Bubeck（2015）作者专著](#)。实际读取第3.7节、定理3.18及估计序列证明，核对强凸参数、函数误差保证，以及原文 x/y 与本讲 z/θ 的角色映射。
- [3] [Lessard、Recht、Packard（2016）作者修正版](#)。实际读取第2节、附录A和第4.6节，核对状态表示、二次谱分析及HB不可普遍外推的反例范围。
- [4] [PyTorch官方2.7 SGD文档](#)。结合安装环境2.7.1源码，核对buffer首步、dampening、lr放置、Nesterov限制与foreach/fused，且实际执行CPU对照。