

# 第036讲 练习详解

本册把20题连成同一条推理链：先固定四行目标，再从局部导数构造更新，最后检查实验比较、库语义与失败保护。所有主线参数按(a,b)排列，残差取预测减标签。 $\epsilon=1$ 仅为可读手算选择，不是大任务推荐值。

## 1 从数据展开目标并求最优点

令 $z=(-1,1,-1,1)$ ，则 $y=1+x+z/2$ 。把残差写成 $(a-1)+(b-1)x-z/2$ 。平方并对四行求平均，交叉项的系数分别为 $\Sigma x$ 、 $\Sigma z$ 与 $\Sigma xz$ ，它们都为0。又有 $\Sigma x^2=16$ ， $\Sigma z^2=4$ ，所以

$$F = \frac{1}{8} + \frac{1}{2}(a-1)^2 + 2(b-1)^2, \quad \nabla F = \begin{pmatrix} a-1 \\ 4(b-1) \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}.$$

两项非负平方同时在 $a=b=1$ 消失，最低目标是 $1/8$ 。不能把最低目标误写为0；四行含不能被这条直线完全解释的 $\pm 1/2$ 扰动。求解器仍逐行前向求梯度，闭式是验算依据。

## 2 AdaGrad累积哪些历史

单个坐标有 $s_1=g_1^2$ ， $s_2=g_1^2+g_2^2$ ， $s_3=g_1^2+g_2^2+g_3^2$ 。每个被加入的量非负，因此 $s$ 不减，且当本次 $g$ 非零时严格增加。对应系数 $\eta/(\sqrt{s+\epsilon})$ 不增，但实际步幅还乘 $g$ ，不能从系数不增推导位移不增。

若从某一步起 $g$ 一直为0， $s$ 会保持不变。若平方序列的无穷和有限，也不能保证 $s$ 趋无穷。因此“有效系数一定趋0”需要额外条件。AdaGrad的历史不遗忘与RMSProp的几何遗忘，应当从权重而非算法名字比较。

## 3 RMSProp的权重与半衰期

由 $v_0=0$ 反复代入，得到

$$v_t = (1 - \rho) \sum_{k=1}^t \rho^{t-k} g_k^2.$$

这些权重总和是 $1-\rho^t$ ，而不是1。对一项旧贡献，经过 $h$ 次更新其权重乘 $\rho^h$ 。 $0<\rho<1$ 时，半衰步数 $h=\log(1/2)/\log\rho$ ； $\rho=3/4$ 时约2.409步，经过3个整步后首次降到一半以下。 $1/(1-\rho)=4$ 是另一种记忆长度直觉，不等于精确半衰期。 $\rho=0$ 只保留当前平方， $\log\rho$ 无定义，需单独处理。

## 4 原始二阶矩、方差与曲率

若 $g$ 恒为2，修正权重的平方平均是4，而方差 $E[(g-Eg)^2]=0$ 。未修正RMSProp值则为 $4(1-\rho^t)$ ，也不是方差。Hessian是梯度对参数的导数，历史 $g^2$ 没有执行这一求导。

在本例a坐标，曲率恒为1，但不同位置的 $g_a=a-1$ 可以是0、1或100。因此 $g_a^2$ 会改变，而曲率不变。这同时反驳“原始二阶矩就是方差”和“平方梯度就是曲率”的混淆。

## 5 Adam的完整同步顺序

第t次更新由同一个旧 $\theta$ 计算所有四行预测、残差、局部导数与平均梯度 $g_t$ 。再用旧m、v形成新 $m_t$ 、 $v_t$ ，按t修正权重，形成分母，最后同时更新a与b，再做新前向。第一次t=1。

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2,$$

$$\theta_t = \theta_{t-1} - \eta \frac{m_t / (1 - \beta_1^t)}{\sqrt{v_t / (1 - \beta_2^t) + \epsilon}}.$$

不能更新a后用新a重算b梯度；那会变为另一套依赖顺序。 $m^2$ 和v也不能互换，因为先平均再平方与先平方再平均一般不同。

## 6 偏差修正的证明与限制

展开 $m_t$ ，几何权重和为 $(1 - \beta_1) \sum_{j=0}^{t-1} \beta_1^j = 1 - \beta_1^t$ 。除以该值后历史权重和为1，这个代数事实不依赖随机假设。如果每一步 $E[g_k] = \mu$ 相同，则 $E[m_t] = (1 - \beta_1^t) \mu$ ，所以 $E[\hat{m}_t] = \mu$ ；二阶矩在各步 $E[g_k^2]$ 相同时同理。

训练路径上 $g_k$ 在不同参数处计算，通常不具有相同均值，因而不能把 $\hat{m}_t$ 叫做“当前梯度的无偏估计”。更不能把 $E[\hat{m}/\sqrt{\hat{v}}]$ 拆成两个期望的比值。偏差修正不提供无条件收敛或逐步下降保证。

## 7 第一轮逐行完整链

$\theta_0 = (0, 0)$ ，所以所有预测为0。逐行损失是 $r^2/2$ ；局部导数链为 $r \times 1 \times (1, x)$ 。平均因子1/4放到每行完整梯度贡献中。

| 行  | x  | y    | 旧预测 | r    | $r^2/2$ | 对a贡献 | 对b贡献 |
|----|----|------|-----|------|---------|------|------|
| S1 | -2 | -3/2 | 0   | 3/2  | 9/8     | 3/8  | -3/4 |
| S2 | -2 | -1/2 | 0   | 1/2  | 1/8     | 1/8  | -1/4 |
| S3 | 2  | 5/2  | 0   | -5/2 | 25/8    | -5/8 | -5/4 |
| S4 | 2  | 7/2  | 0   | -7/2 | 49/8    | -7/8 | -7/4 |

求和给 $F_0 = 21/8$ ， $g_1 = (-1, -4)$ 。在 $\eta = 1/4$ 、 $\beta_1 = 1/2$ 、 $\beta_2 = 3/4$ 、 $\epsilon = 1$ 下： $m_1 = (-1/2, -2)$ ， $v_1 = (1/4, 4)$ ，修正后 $\hat{m}_1 = (-1, -4)$ ， $\hat{v}_1 = (1, 16)$ 。分母(2, 5)，系数(1/8, 1/20)，增量(1/8, 1/5)，所以 $\theta_1 = (1/8, 1/5)$ 。

| 行  | 新预测    | 新残差     | 新单行损失      | 下一轮对a贡献  | 下一轮对b贡献  |
|----|--------|---------|------------|----------|----------|
| S1 | -11/40 | 49/40   | 2401/3200  | 49/160   | -98/160  |
| S2 | -11/40 | 9/40    | 81/3200    | 9/160    | -18/160  |
| S3 | 21/40  | -79/40  | 6241/3200  | -79/160  | -158/160 |
| S4 | 21/40  | -119/40 | 14161/3200 | -119/160 | -238/160 |

新单行损失先求和再除4，得 $F_1=5721/3200=1.7878125$ 。此表既完成第一轮的新前向，又提供第二轮的旧梯度分项。

## 8 第二轮有理矩与无理根号

上表贡献求和得到 $g_2=(-7/8, -16/5)$ 。保留旧 $m$ 、 $v$ 并更新：

$$m_2 = \left(-\frac{11}{16}, -\frac{13}{5}\right), \quad v_2 = \left(\frac{97}{256}, \frac{139}{25}\right),$$

$$\hat{m}_2 = \left(-\frac{11}{12}, -\frac{52}{15}\right), \quad \hat{v}_2 = \left(\frac{97}{112}, \frac{2224}{175}\right).$$

修正分母分别为3/4和7/16。第二次参数不是简单有理数：

$$a_2 = \frac{1}{8} + \frac{11}{48(\sqrt{97/112} + 1)}, \quad b_2 = \frac{1}{5} + \frac{13}{15(\sqrt{2224/175} + 1)}.$$

得到 $a_2 \approx 0.2437004841250088$ ， $b_2 \approx 0.3898541226435905$ 。下表是独立100位Decimal计算的展示舍入，不回灌求解器。

| 行  | 新预测             | 新残差             | 单行损失           |
|----|-----------------|-----------------|----------------|
| S1 | -0.536007761162 | 0.963992238838  | 0.464640518270 |
| S2 | -0.536007761162 | -0.036007761162 | 0.000648279432 |
| S3 | 1.023408729412  | -1.476591270588 | 1.090160890188 |
| S4 | 1.023408729412  | -2.476591270588 | 3.066752160776 |

四项单行损失相加再除4得 $F_2 \approx 1.1555504621664184$ 。此处“精确有理矩→高精度根号→新参数→同四行新前向”与真实binary64路径分开记录；浮点结果只在容差内比较，不要求两种算术逐位相同。

## 9 三种“步长”不能混用

$d=\eta/(\sqrt{\hat{v}}+\varepsilon)$ 是乘历史方向 $\hat{m}$ 的系数， $\Delta\theta=-d \cdot \hat{m}$ 是实际参数位移， $\Delta\theta/g$ 是另外一个可能无定义的比值。第一轮 $d_a=1/8$ 大于 $d_b=1/20$ ，但位移 $a$ 为 $1/8$ ，小于 $b$ 的 $1/5$ ，因为 $\hat{m}_b$ 的绝对值更大。

若当前 $g=0$ 但旧 $m$ 非零，本轮 $m$ 仍可能非零，参数仍移动。若 $\hat{m}$ 与当前 $g$ 反向，位移可能沿当前梯度的上升方向。此时把 $\Delta\theta/g$ 称为正学习率会误导。报告中应分别列出当前梯度、历史方向、尺度与位移。

## 10 $\varepsilon$ 位置与整体缩放

若 $\hat{v}=4$ ,  $\varepsilon=1$ , 外置分母是3, 内置分母是 $\sqrt{5}$ , 两者不同。外置 $\varepsilon$ 与梯度同单位, 内置 $\varepsilon$ 与梯度平方同单位。因此相同数值 $\varepsilon$ 不能作为单位一致的对照。

对 $c>0$ 、无正则, 若历史参数路径一致, 则 $g'=cg$ 、 $m'=cm$ 、 $v'=c^2v$ 。当 $\varepsilon'=c\varepsilon$ 时,  $\hat{m}'/(\sqrt{\hat{v}'+\varepsilon'})=\hat{m}/(\sqrt{\hat{v}+\varepsilon})$ , 从相同初值可归纳出整条路径相同。保持 $\varepsilon$ 不变时, 等价于原问题使用 $\varepsilon/c$ , 通常改变路径。实验 $c=100$ 的匹配分支误差只反映有限精度; 这个结论不宣称对任意坐标重参数化不变。

## 11 同预算比较还有哪些未控制因素

四行全批每步4个样本梯度, 100步共400。主比较统一数据、 $\theta_0$ 、目标归一化、精度与训练梯度预算; 还单列诊断前向的额外工作。算法每次状态运算量不同, 所以同样本梯度数不等于同硬件耗时。

同一个 $\eta$ 也不等于各方法都已调到合理设置。预先声明 $\eta \in \{0.01, 0.05, 0.25, 1\}$ 与 $\varepsilon \in \{1, 10^{-8}\}$ , 报告全部候选, 并保留大步长失败。GD的 $\varepsilon$ 分支必然重合, 因为GD不使用 $\varepsilon$ 。这一控制重复可以检查网格实现。不能从单一合成训练目标推出测试泛化或普遍排名。

## 12 近最优超调的完整反例

使用同一数据,  $\theta=(1+10^{-6}, 1)$ 。理论旧预测为 $(-1+\delta, -1+\delta, 3+\delta, 3+\delta)$ ,  $\delta=10^{-6}$ ; 残差为 $(1/2+\delta, -1/2+\delta, 1/2+\delta, -1/2+\delta)$ 。逐行贡献相加给 $g=(\delta, 0)$ , 旧目标差 $\delta^2/2=5 \times 10^{-13}$ 。

以 $\eta=1/4$ 、 $\varepsilon=10^{-8}$ 、零历史启动Adam,  $m=(\delta/2, 0)$ ,  $v=(\delta^2/4, 0)$ , 修正后 $\hat{m}=(\delta, 0)$ 、 $\hat{v}=(\delta^2, 0)$ 。增量 $a$ 为 $-\delta/[4(\delta+\varepsilon)] \approx -0.24752475$ ,  $b$ 不动。新 $a$ 约0.7524762475, 已经越过最优 $a=1$ 。新残差为 $a-1$ 加 $\pm 1/2$ , 仍对这四行算新损失; 新目标差约0.030634, 远大于旧值。上述是符号精确算术。实际逐行binary64求和给 $b$ 约 $2.22 \times 10^{-16}$ 的残余梯度, 经很小 $\varepsilon$ 归一化后产生约 $-5.55 \times 10^{-9}$ 的微小位移, 所以表中左右预测差不是严格4。这不改变超调结论, 也说明精确纸笔链与浮点执行必须分别标注。实际执行如下。

| 行  | 旧预测          | 旧残差          | 新预测          | 新残差          | 新单行损失       |
|----|--------------|--------------|--------------|--------------|-------------|
| S1 | -0.999999000 | 0.500001000  | -1.247523741 | 0.252476259  | 0.031872131 |
| S2 | -0.999999000 | -0.499999000 | -1.247523741 | -0.747523741 | 0.279395872 |
| S3 | 3.000001000  | 0.500001000  | 2.752476236  | 0.252476236  | 0.031872125 |
| S4 | 3.000001000  | -0.499999000 | 2.752476236  | -0.747523764 | 0.279395889 |

这个例子证明这一设置下Adam可以增大目标, 不证明所有设置都失败, 也不反驳有附加假设的其他收敛结果。

## 13 L2与无动量GD等价的范围

$J=F+\lambda\theta^TP\theta/2$ ,  $P=\text{diag}(0,1)$ , 所以  $\nabla J=g_F+\lambda P\theta$ 。无动量GD有  $\theta^+=\theta-\eta(g_F+\lambda P\theta)=(I-\eta\lambda P)\theta-\eta g_F$ 。相同旧 $\theta$ 、同一 $\eta$ 及同一 $\lambda$ 约定下, 两式代数完全相同。

若论文把每步缩减本身记为 $\lambda_p$ , 则与本讲参数对应 $\lambda_p=\eta\lambda$ ;  $\eta$ 改变时不能保持两种符号数值不变还声称相同。带历史或坐标预条件时, 更新对正则梯度的处理已改变, 需要重新分析。

## 14 耦合L2改变两个状态

写  $h_t=g_t+\lambda P\theta$ 。  $m_t=\beta_1 m_{t-1}+(1-\beta_1)h_t$ ,  $v_t=\beta_2 v_{t-1}+(1-\beta_2)h_t^2$ 。逐坐标平方展开为  $g^2+2\lambda g(P\theta)+\lambda^2(P\theta)^2$ , 交叉项不能省略。

即使临时固定对角预条件D, 惩罚的更新是 $-\eta\lambda DP\theta$ , 已经与 $-\eta\lambda P\theta$ 不同。在Adam中D还随使用过的总梯度历史改变。因此耦合L2仍可解释为对J使用Adam, 但不能称为AdamW的另一种等价写法。

## 15 AdamW中的旧参数与顺序

AdamW只把数据g送入m和v, 更新 $\theta^+=(I-\eta\lambda P)\theta-\eta d$ , 其中 $d=\hat{m}/(\sqrt{\hat{v}}+\epsilon)$ 。先做自适应 $\theta'=\theta-\eta d$ , 再对新 $\theta'$ 衰减, 得到 $(I-\eta\lambda P)\theta-\eta d+\eta^2\lambda P d$ , 多了交叉项, 通常不是原式。

库先原地缩减旧参数, 再应用由旧梯度形成的步, 仍可与同步式等价。判断顺序时要追踪g在什么参数处计算, 而不能仅凭“先调用哪条赋值语句”。

## 16 非零初值的两步对照

取 $\theta_0=(1/2,-1/2)$ ,  $\lambda=0.1$ ,  $P=\text{diag}(0,1)$ 。旧预测 $(3/2,3/2,-1/2,-1/2)$ , 残差 $(3,2,-3,-4)$ ,  $F=19/4$ , 数据梯度 $(-1/2,-6)$ 。耦合梯度为 $(-1/2,-121/20)$ , AdamW仍使用 $(-1/2,-6)$ 。第一步修正后方向就是各自所用梯度, 平方统计就是其平方。

截距两者均更新到7/12。耦合斜率为 $-1/2+121/564\approx-0.285460993$ ; AdamW斜率为 $-39/80+3/14\approx-0.273214286$ 。这里 $-39/80$ 先来自旧斜率的 $(1-1/40)$ 缩减, 不能衰减更新后的斜率。

以下状态表按坐标分行, 所有展示保留六位小数; 计算仍使用未舍入值。

| 方法/步     | 坐标 | 所用g       | 新m        | 新v        | 新参数       |
|----------|----|-----------|-----------|-----------|-----------|
| AdamL2/1 | a  | -0.500000 | -0.250000 | 0.062500  | 0.583333  |
| AdamL2/1 | b  | -6.050000 | -3.025000 | 9.150625  | -0.285461 |
| AdamL2/2 | a  | -0.416667 | -0.333333 | 0.090278  | 0.659737  |
| AdamL2/2 | b  | -5.170390 | -4.097695 | 13.546202 | -0.077385 |
| AdamW/1  | a  | -0.500000 | -0.250000 | 0.062500  | 0.583333  |

| 方法/步    | 坐标 | 所用g       | 新m        | 新v        | 新参数       |
|---------|----|-----------|-----------|-----------|-----------|
| AdamW/1 | b  | -6.000000 | -3.000000 | 9.000000  | -0.273214 |
| AdamW/2 | a  | -0.416667 | -0.333333 | 0.090278  | 0.659737  |
| AdamW/2 | b  | -5.092857 | -4.046429 | 13.234298 | -0.058874 |

| 方法/步     | 新F       | 新F+L2    |
|----------|----------|----------|
| AdamL2/1 | 3.516625 | 3.520700 |
| AdamL2/2 | 2.504406 | 2.504705 |
| AdamW/1  | 3.453955 | 3.457687 |
| AdamW/2  | 2.425319 | 2.425492 |

第二步必须在各自新参数上重新做四行前向。两条路径的旧梯度已经不同，又有不同历史矩，因此不能只拿同一g代入两个分母。以下逐行表覆盖两个算法两步的完整前向，表中t=0是第一步旧状态、t=1是第一步新状态亦第二步旧状态、t=2是第二步新状态。

### AdamL2逐行重算

| t/行  | 预测        | 残差        | 单行损失     | 对a贡献      | 对b贡献      |
|------|-----------|-----------|----------|-----------|-----------|
| 0/S1 | 1.500000  | 3.000000  | 4.500000 | 0.750000  | -1.500000 |
| 0/S2 | 1.500000  | 2.000000  | 2.000000 | 0.500000  | -1.000000 |
| 0/S3 | -0.500000 | -3.000000 | 4.500000 | -0.750000 | -1.500000 |
| 0/S4 | -0.500000 | -4.000000 | 8.000000 | -1.000000 | -2.000000 |
| 1/S1 | 1.154255  | 2.654255  | 3.522536 | 0.663564  | -1.327128 |
| 1/S2 | 1.154255  | 1.654255  | 1.368280 | 0.413564  | -0.827128 |
| 1/S3 | 0.012411  | -2.487589 | 3.094049 | -0.621897 | -1.243794 |
| 1/S4 | 0.012411  | -3.487589 | 6.081637 | -0.871897 | -1.743794 |
| 2/S1 | 0.814507  | 2.314507  | 2.678472 | 0.578627  | -1.157254 |
| 2/S2 | 0.814507  | 1.314507  | 0.863965 | 0.328627  | -0.657254 |
| 2/S3 | 0.504968  | -1.995032 | 1.990077 | -0.498758 | -0.997516 |
| 2/S4 | 0.504968  | -2.995032 | 4.485110 | -0.748758 | -1.497516 |

## AdamW逐行重算

| t/行  | 预测        | 残差        | 单行损失     | 对a贡献      | 对b贡献      |
|------|-----------|-----------|----------|-----------|-----------|
| 0/S1 | 1.500000  | 3.000000  | 4.500000 | 0.750000  | -1.500000 |
| 0/S2 | 1.500000  | 2.000000  | 2.000000 | 0.500000  | -1.000000 |
| 0/S3 | -0.500000 | -3.000000 | 4.500000 | -0.750000 | -1.500000 |
| 0/S4 | -0.500000 | -4.000000 | 8.000000 | -1.000000 | -2.000000 |
| 1/S1 | 1.129762  | 2.629762  | 3.457824 | 0.657440  | -1.314881 |
| 1/S2 | 1.129762  | 1.629762  | 1.328062 | 0.407440  | -0.814881 |
| 1/S3 | 0.036905  | -2.463095 | 3.033419 | -0.615774 | -1.231548 |
| 1/S4 | 0.036905  | -3.463095 | 5.996514 | -0.865774 | -1.731548 |
| 2/S1 | 0.777486  | 2.277486  | 2.593471 | 0.569371  | -1.138743 |
| 2/S2 | 0.777486  | 1.277486  | 0.815985 | 0.319371  | -0.638743 |
| 2/S3 | 0.541989  | -1.958011 | 1.916904 | -0.489503 | -0.979006 |
| 2/S4 | 0.541989  | -2.958011 | 4.374915 | -0.739503 | -1.479006 |

报告的old/new forward还保留每个局部导数和梯度分项。F+L2仅是单独诊断；不应把AdamW原目标F与耦合目标J混作一条同名曲线。

## 17 mask与调度下纯衰减

本讲 $P=\text{diag}(0,1)$ 明确豁免截距。库不会知道哪个参数“应当”豁免；实验用显式参数组为a设置`weight_decay=0`，为b设置 $\lambda$ 。若两者都需要衰减，必须显式改mask。

没有自适应方向时，递推 $\theta_t = (I - \eta_t \lambda P) \theta_{t-1}$ 。对被选中的坐标连乘， $\theta_T = \prod_{t=1}^T (1 - \eta_t \lambda) \theta_0$ 。 $\eta$ 若变化，不能写成单一固定倍率的T次方。包含数据梯度时还有每次驱动项，不能把完整路径简化成纯衰减乘积。

## 18 真实库的零梯度与None

固定PyTorch2.7.1+cpu、float64、单线程，用初值-0.5、 $\eta=0.25$ 、 $\lambda=0.1$ 的单参数AdamW。显式零梯度张量触发一步更新，参数变为-0.4875，step=1，矩状态被创建。grad=None则跳过，参数仍-0.5，未创建状态。

另一次真实Adam实验先给梯度2走一步，再令当前梯度为0。参数从约0.3333333333继续变到0.2611616203， $m=0.5$ 、 $v=0.75$ 、 $step=2$ 。当前零梯度没有抹除历史。以上是明确版本、明确设置的实际接口核验，不把None解释为一个数学上的零向量。

## 19 完整恢复为什么接续同一轨迹

把一步写为确定映射 $S_t=\Phi(S_{t-1};\text{数据},\text{超参数})$ ， $S$ 含 $\theta$ 、必要矩和 $t$ 。相同状态、相同数据、相同超参数与操作顺序给相同下一状态，归纳可得后续路径相同。本例在第7步复制全部状态，再执行第8至100步，与连续运行的后93条完整trace逐字段一致。

只复制 $\theta$ 会将 $m$ 、 $v/s$ 与 $t$ 重置。除无历史GD外，一般从下一步就变为另一映射输入。恢复校验也要拒绝负 $v$ 、错形状、bool步数、非法算法及配置不匹配；不能为“能运行”而静默改正checkpoint。随机抽样或调度的完整恢复还要额外保存其状态，本讲固定全批问题没有这些因素。

## 20 怎样组合验收而不夸大结论

用Fraction验证首轮与第二轮有理量；用独立120位Decimal实现核对所有状态和新目标，而非调用同一个函数自测。再用随机有理网格数据和有限差分检查逐行梯度。真实PyTorch对比参数、step、 $m/v/s$ ，显式写明所有选项与容差；跨库不宣称逐位一致。

工程层面，在首次step前验证完整数据、完整配置和checkpoint；对坏尾字段插入哨兵，确保根本未更新。新进程普通与-O、两种工作目录、实际新内核的完整报告应一致。错误输入不得建立输出目录、覆盖旧报告或经链接改写教学资产。最后检查真实图像与每页PDF。这些证据支持已声明有限实现与示例的可信度，不能代替未证明的普遍收敛定理。