

第036讲 独立实验指南

1 问题、文件与运行准备

本实验回答四个问题：历史平方如何改变坐标系数；Adam偏差修正是否正确；同样weight_decay数值为什么可能产生不同算法；保存参数而漏掉历史是否能接续训练。只使用随单元提供的四行合成回归，没有训练/测试排名的含义。

需要Python3.12、NumPy2.3.5；Notebook绘图使用Matplotlib3.10.8。核心脚本不要求PyTorch，真实库核对放在独立可选文件library_check.py。用单元目录的requirements.txt或environment.yml准备环境，在终端进入本单元目录，运行：

```
python experiment.py --output-dir outputs
```

会生成完整outputs/report.json，并打印字节数和SHA256。再次运行会原子替换该报告；错误数据、配置或不安全目标会失败并保留旧文件。不要把旧报告、屏幕截图或只运行过最后一格当作完整执行。

Notebook须从本单元目录打开experiment.ipynb，重启内核后自第一格依序运行。首格在任何数值输出前校验两个默认输入的完整字节。修改数据后固定说明可能失效，首格将拒绝；自定义研究请用脚本的--data与--config，不要删除校验来继续沿用原图注。实际验收使用新进程内的真实IPython内核，逐格执行并保留6幅PNG；浏览器Jupyter界面、外部socket传输和本机Anaconda安装未做测试。

2 先把一轮算完整

模型是 $\hat{y}=a+bx$ ，残差 $r=\hat{y}-y$ ，单行损失 $\ell=r^2/2$ ，F是四行 ℓ 的平均。数据(x,y)依次为(-2,-1.5)、(-2,-0.5)、(2,2.5)、(2,3.5)。

在 $\theta_0=(0,0)$ 写四行表，列预测、r、 ℓ 、局部导数r、预测对a/b的导数1/x、平均梯度贡献(r/4,xr/4)。核对 $F_0=21/8$ ， $g_1=(-1,-4)$ 。再使用 $\eta=1/4$ 、 $\beta_1=1/2$ 、 $\beta_2=3/4$ 、 $\varepsilon=1$ ：

1. 从零历史得到 $m_1=(-1/2,-2)$ ， $v_1=(1/4,4)$ 。
2. 用t=1修正为 $\hat{m}_1=(-1,-4)$ ， $\hat{v}_1=(1,16)$ 。
3. 分母(2,5)，两坐标系数(1/8,1/20)，增量(1/8,1/5)。
4. 同时更新后，四行预测为(-11,-11,21,21)/40，新残差为(49,9,-79,-119)/40。
5. 新单行损失求和除4，核对 $F_1=5721/3200$ 。

从这些新残差重新算第二轮，不得沿用 g_1 。应得 $g_2=(-7/8,-16/5)$ ， $m_2=(-11/16,-13/5)$ ， $v_2=(97/256,139/25)$ 。修正后 $\hat{m}_2=(-11/12,-52/15)$ ， $\hat{v}_2=(97/112,2224/175)$ 。下一参数约(0.2437004841250088,0.3898541226435905)， F_2 约1.1555504621664184。

Notebook第1、2节分别用Fraction与100位Decimal打印所有四行，不只打印总损失。详解第7、8题给完整纸笔表。自查时追踪第一处不同的中间量：例如v正确而分母错误，优先检查 ϵ 的位置；第一步正确而第二步错误，检查是否重置了历史或错用t。

3 看懂实际报告，不只看曲线

methods下六条主路径保留每一步的old_forward、data_gradient、regularizer_gradient、used_gradient、old_state、new_state、direction、raw_scale_statistic、denominator、effective_coefficient、adaptive_delta、decay_delta、actual_delta、new_forward。GD、AdaGrad、RMSProp、Adam的 λ 均为0；AdamL2/AdamW用另一套显式非零初值与衰减mask。

对任一步执行以下对账：旧行损失求和除4等于data_loss；旧行梯度贡献相加等于data_gradient；new_state的t恰比旧值加1；参数位移等于自适应位移加衰减位移；新行预测来自新参数而非旧参数。跨库对照使用容差，本脚本/Notebook的同实现完整报告则应逐字节一致。

主比较100步每步四行，训练样本梯度预算400；额外新前向为诊断工作，单独计数。

raw_scale_statistic对AdaGrad是累积s，对RMSProp是未修正v，对Adam是修正 $\hat{v}$ ，不能把这些不同统计的名字混用。所有方法使用固定预算，不因一次参数未动就宣布收敛。若触发数值范围保护，status明确range_stop，保留完整有效步，并按实际尝试计费。

画稳定目标差时使用本默认数据的闭式 $(a-1)^2/2+2(b-1)^2$ ，而不是 $F-1/8$ 直接相减。

default_closed_form_gap对自定义数据为null，不能借用本例最优点。主学习率网格为0.01、0.05、0.25、1， ϵ 网格为1和 10^{-8} ；同时保留完整参数和目标轨迹。解释一个较好设置和一个失败设置，不进行未定义的“总体排名”。

4 五个机制实验

实验A：历史方向与幅度

查看Adam第二轮的g、 $\hat{m}$ 、 $d=\eta/(\sqrt{\hat{v}+\epsilon})$ 和实际位移。回答为什么d_a更大不代表a走得更多。再用恒定梯度2的纸笔例子算 $\hat{v}=4$ 、方差0，解释为何报告不把v叫做方差或Hessian。

实验B：目标缩放和 ϵ 位置

scale_probe同时给出目标 $\times 100$ 但 ϵ 不变、目标 $\times 100$ 且 $\epsilon \times 100$ 、以及 ϵ 改放根号内三个分支。把每轮参数减去原Adam路径。匹配 ϵ 分支应在浮点容差内重合，另两个分支一般不重合。推导 $m'=100m$ 、 $v'=10000v$ ；注意这里缩放整个损失生成的梯度，不能只把最后打印的损失乘100。

实验C：同一数据的近最优超调

near_declared_point_probe取 $(1+10^{-6}, 1)$ ， $\eta=0.25$ ， $\epsilon=10^{-8}$ 。记录全部旧行和新行，比较稳定目标差。旧差约 5×10^{-13} ，新差约0.030634；找出归一化后约0.2475的a位移从哪里来。该反例表明本设置不逐步下降，不代表Adam总会失败。

实验D：耦合L2与AdamW

两者统一 $\theta_0=(0.5,-0.5)$, $\lambda=0.1$, $\text{mask}=(0,1)$ 。第一步数据梯度 $(-0.5,-6)$ ；耦合梯度 $(-0.5,-6.05)$ 。AdamW的矩只接收数据梯度，斜率衰减位移为 $-\eta\lambda b=+0.0125$ 。完整比较前两步的旧/新行、m/v、方向、位移、F和F+L2。详解第16题的表可逐行核对。不要从全零初值的偶然同一步推出等价。

实验E：第7轮恢复

resume记录六种方法的完整状态续跑。每个identical_suffix应为true，指完整trace逐字段相同。parameter_only_restart重置历史与t，从同一参数走剩余93步。GD无历史，因此它是控制组；对自适应方法检查路径分叉。明确恢复的数据、超参数、精度和运算顺序也是契约的一部分。

5 可选真实PyTorch核对

本单元的library-result.json来自已执行的PyTorch2.7.1+cpu。为重跑，按PyTorch官方CPU包渠道在独立可选环境安装2.7.1，再执行python `library_check.py`。安装地址与固定依赖写在requirements-library.txt，不会由脚本自动下载。新版库运行需另建记录，不要覆盖原固定版本结论。

实际检查采用CPU float64、单线程、foreach=False，在支持的优化器上fused=False。AdaGrad明确lr_decay=0、initial_accumulator_value=0；RMSProp明确momentum=0、centered=False，且它没有fused参数。每个参数组显式设置weight_decay，避免AdamW默认衰减与Adam默认0混入比较。

五种库路径各三组设置、各30步，比较参数、step及m/v/s，容差rtol= 2×10^{-11} 、atol= 2×10^{-12} 。实际最大绝对差约 5.68×10^{-14} ；不同等价算术顺序允许数个ULP差异。另检验新参数零梯度张量与None：前者触发衰减与状态创建，后者跳过；有历史时当前零梯度也可移动。Notebook读取此已执行记录，并明确不冒充即时运行PyTorch。

6 故障注入与提交清单

先复制data文件，在副本的最后一项放True、非有限值或重复JSON键，用--data/--config运行。完整输入必须先校验，不能已走若干步才发现最后一项非法。对checkpoint复制后改负v、布尔t、错维度或不匹配配置，必须在第一步前拒绝。

故障试验先给输出目录放一个已知内容的report.json，运行非法输入后比较完整字节；再选择尚不存在的输出目录，失败后不应新建。输出文件若是链接到输入或教材资产，也必须拒绝。不要在正式教学文件上做破坏性实验。

提交：完整旧/新四行链、二轮Fraction/Decimal核对、六幅重新计算的图、所有预声明网格结果、两步衰减表、恢复比较、坏尾字段与旧输出保护记录，以及可选库报告。最后用自己的话回答：本实验检验了哪些有限命题，哪些泛化、速度和无条件收敛结论并未得到证明？