

# 第036讲 自适应优化与权重衰减


## 1 从同一步长走向每个坐标的更新规则

第034讲解释了抽样产生的梯度噪声，第035讲加入历史方向形成动量。现在观察另一个问题：两个参数的梯度长期尺度不同，同一个学习率是否让某一坐标走得过猛、另一坐标走得过慢？自适应方法保存梯度的历史幅度，为每个坐标构造不同分母，再把方向与幅度合成一次更新。

直接先修第034至035讲。还需会算逐元素平方、平方根、加权平均和链式法则。本讲从AdaGrad到RMSProp再到Adam，每次只增加必要状态。随后把L2惩罚放入梯度，与AdamW的独立参数缩减并列，说明相同的weight\_decay数字为什么不一定表达同一个算法。

我们始终使用同一四行线性回归数据，完整手算Adam前两次更新，再核对从零实现的全部状态与真实库实现。有限CPU实验只解释机制；没有真实测试集、泛化比较或“Adam总优于SGD”的结论。

### Direction and scale are different kinds of memory



v is a raw second moment, not variance and not a Hessian.

图1 当前梯度、历史一阶矩、历史二阶矩和参数更新分别扮演不同角色。

## 2 固定目标 数据与每个局部导数

四行特征 $x=(-2,-2,2,2)$ ，标签 $y=(-3/2,-1/2,5/2,7/2)$ ，模型预测 $\hat{y}_i = a + bx_i$ 。令 $\theta=(a,b)^T$ ，残差 $r_i = \hat{y}_i - y_i$ ，目标 $F = \sum_i r_i^2 / (2n)$ ， $n=4$ 。单行损失是 $r_i^2/2$ ，平均因子 $1/n$ 放在梯度累积时。

局部导数 $\partial \ell_i / \partial r_i = r_i$ ， $\partial r_i / \partial \hat{y}_i = 1$ ， $\partial \hat{y}_i / \partial a = 1$ ， $\partial \hat{y}_i / \partial b = x_i$ 。因此样本对完整梯度的贡献是 $(r_i/4, x_i r_i/4)$ 。在同一个旧 $\theta$ 处算完全部四行后相加，不能更新 $a$ 后再用新 $a$ 计算 $b$ 。

写 $z=(-1,1,-1,1)$ ，有 $y=1+x+z/2$ ，且 $\sum x=\sum z=\sum xz=0$ ， $\sum x^2=16$ ， $\sum z^2=4$ 。展开平方后交叉项消失，得到

$$F(a,b) = \frac{1}{8} + \frac{1}{2}(a-1)^2 + 2(b-1)^2, \quad \nabla F = (a-1, 4(b-1))^T.$$

最优点(1,1)，最低目标1/8，Hessian diag(1,4)。后面的求解器实际逐样本前向与求梯度；此闭式只作独立参照，不替代真实迭代。

### 3 AdaGrad保存到目前为止的平方和

令 $g_t$ 为第 $t$ 次更新前的梯度，时间从 $t=1$ 起，初始 $\theta_0$ ，累积 $s_0=0$ 。下式中的平方、平方根和除法全部逐元素进行：

$$s_t = s_{t-1} + g_t \odot g_t, \quad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{s_t} + \epsilon}.$$

坐标 $j$ 的历史梯度常常很大，就有更大的 $s_{t,j}$ ，分母更大。长期不活跃的坐标可能积累更少。但不要把“罕见特征必然更好”当成结论，更新仍依赖其实际梯度、数据和预算。

因为每次加上非负平方， $s_{t,j}$ 单调不减；当该坐标持续出现非零梯度，分母可能长期增大，使当前梯度前的系数降低。这是历史不会自动遗忘的代价。若梯度之后永久为0，累积量可以停止增长，不能无条件声称每种路径的有效系数都趋0。

本讲采用 $s_0=0$ 、全局 $\eta$ 固定、 $\epsilon$ 在平方根外；不加入额外学习率衰减。不同库或论文的初始累积、 $\epsilon$ 位置与额外计划可能不同，名字相同不代表逐步数值相同。




图2 AdaGrad不断累积平方，RMSProp用有限衰减权重保留近期幅度。

### 4 RMSProp改用指数加权平方平均

令 $v_0=0$ ， $0 \leq \rho < 1$ 。RMSProp把累积和改为

$$v_t = \rho v_{t-1} + (1 - \rho) g_t^2, \quad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{v_t} + \epsilon}.$$

展开 $v_t = \rho(1-\rho)g_1^2 + (1-\rho)g_2^2$ ，可见较早的平方每过一步再乘 $\rho$ 。一般第 $k$ 步梯度在第 $t$ 步的权重为 $(1-\rho)\rho^{t-k}$ 。 $\rho$ 越接近1，遗忘越慢，统计量越平滑但对新尺度反应更迟。常说的 $1/(1-\rho)$ 只是记忆长度直觉；精确半衰步数由 $\rho^h = 1/2$ 给 $h = \log(1/2)/\log \rho$ ， $\rho=0$ 需单独解释。

本讲使用最简单版本：不加momentum、不做centered修正，也不对v作偏差修正。centered版本会额外估计梯度均值并从二阶矩扣除平方，已经是另一套状态，不能默认与本式相同。

## 5 这个平方统计量不是Hessian 也不是方差

$g_{t,j}^2$ 描述在已走过的位置、已抽到的数据上，该坐标梯度的平方。它既受曲率影响，也受离最优多远、噪声、目标归一化和坐标单位影响；不能把sqrt(v)直接叫Hessian对角线。

二阶原始矩 $E[g^2]$ 与方差不同： $\text{Var}(g)=E[g^2]-(Eg)^2$ 。如果某坐标梯度恒为2，二阶原始矩4，方差却是0。RMSProp和Adam默认保存平方梯度的平均，没有减去均值平方；命名为second moment更准确。

因此“除以梯度的标准差”通常是不精确的解释。较合适的说法是用历史平方幅度构造坐标尺度。真正的二阶曲率方法在后续Newton单元讨论，不要从有平方和平方根就推断它已使用Hessian。

## 6 Adam同时保存方向与幅度

取 $m_0=v_0=0$ ， $0 \leq \beta_1, \beta_2 < 1$ 。Adam先计算

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2. \end{aligned}$$

m保存有正负的方向平均，v保存非负的平方幅度。两者形状与参数相同。相邻梯度符号相反时m可能相互抵消，v却不会因为符号变化而抵消。把 $m^2$ 当成v会得到不同算法。

初始状态为0导致早期权重总和不到1。Adam使用修正后的 $\hat{m}_t = m_t / (1 - \beta_1^t)$ 、 $\hat{v}_t = v_t / (1 - \beta_2^t)$ ，再同步更新

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}.$$

这里没有用新 $\theta$ 重新更新m或v。顺序是旧 $\theta$ 前向→完整g→新m和v→偏差修正→全部 $\theta$ 同步更新→新 $\theta$ 前向。把 $t=0$ 直接放进 $1-\beta^t$ 会除0，第一次更新应是 $t=1$ 。


**Adam update t: no new parameter enters an old gradient**

图3 Adam一步的依赖图，标清每个状态使用旧值还是本轮新值。

## 7 偏差修正到底修正了什么

展开一阶递推： $m_t = (1 - \beta_1) \sum_{k=1}^t \beta_1^{t-k} g_k$ 。若各步梯度的期望恰为同一向量 $\mu$ ，则 $E[m_t] = (1 - \beta_1^t) \mu$ ，除以权重总和后得到 $E[\hat{m}_t] = \mu$ 。二阶矩在相应平稳假设下同理。

即使没有平稳随机假设，除法仍有明确代数意义：把已有历史的几何权重归一化，使权重和成为1。但训练中参数不断变， $E[g_k]$ 通常也在变，所以不能说 $\hat{m}_t$ 无偏估计当前 $g_t$ 。它是不同历史位置的加权混合。更不能推断比值 $\hat{m}/\sqrt{\hat{v}}$ 是无偏的更新方向，因为分子分母相关，非线性比值的期望不能分拆。

若所有历史梯度恒等于 $g$ ，修正后 $\hat{m}=g$ 、 $\hat{v}=g^2$ ；未修正时两者分别带 $1-\beta_1^t$ 和 $1-\beta_2^t$ 。第一步因此最容易检查是否漏做修正。实现需要同时保存 $m$ 、 $v$ 与步数；只恢复参数会使下一步与连续训练不同。

## 8 第一轮逐行前向和梯度累积

为了手算易核验，使用 $\eta=1/4$ 、 $\beta_1=1/2$ 、 $\beta_2=3/4$ 、 $\varepsilon=1$ ，且 $\lambda=0$ 、 $\theta_0=(0,0)$ 。这些是演示值，尤其 $\varepsilon=1$ 不是实际大任务的推荐默认。

初始四行预测都是0，残差为 $(3/2, 1/2, -5/2, -7/2)$ 。单行损失 $r^2/2$ 依次 $9/8$ 、 $1/8$ 、 $25/8$ 、 $49/8$ ，合计 $21/2$ ，除4得 $F_0=21/8$ 。对截距的平均梯度分项为 $(3/8, 1/8, -5/8, -7/8)$ ，和-1；对斜率的分项为 $(-3/4, -1/4, -5/4, -7/4)$ ，和-4。每个分项都来自 $r \times 1 \times 1/4$ 或 $r \times 1 \times x/4$ 。

因此 $g_1=(-1, -4)$ 。 $m_1=(-1/2, -2)$ ， $v_1=(1/4, 4)$ 。除以 $1-\beta_1=1/2$ 、 $1-\beta_2=1/4$ ，得 $\hat{m}_1=(-1, -4)$ 、 $\hat{v}_1=(1, 16)$ 。平方根外加 $\varepsilon=1$ ，分母 $(2, 5)$ 。参数增量为 $(1/8, 1/5)$ ，同步得到 $\theta_1=(1/8, 1/5)$ 。

更新后对同一四行重新前向：预测 $(-11/40, -11/40, 21/40, 21/40)$ ，残差 $(49/40, 9/40, -79/40, -119/40)$ ，平方和 $22884/1600$ 。除8得到 $F_1=5721/3200=1.7878125$ 。第一轮至此才完整，不能在参数更新处停止而不检查新预测。

**First Adam step: every row survives the calculation**

| row | x  | y    | old r | g_a / row | g_b / row | new pred | new r   |
|-----|----|------|-------|-----------|-----------|----------|---------|
| S1  | -2 | -3/2 | 3/2   | 3/8       | -3/4      | -11/40   | 49/40   |
| S2  | -2 | -1/2 | 1/2   | 1/8       | -1/4      | -11/40   | 9/40    |
| S3  | 2  | 5/2  | -5/2  | -5/8      | -5/4      | 21/40    | -79/40  |
| S4  | 2  | 7/2  | -7/2  | -7/8      | -7/4      | 21/40    | -119/40 |

Sum g = (-1, -4) -> mhat = (-1, -4), vhat = (1, 16)

Denominator = (2, 5) -> theta = (1/8, 1/5) -> new F = 5721/3200

图4 同一四行数据的旧预测、残差、梯度分项、状态和新预测逐层对齐。

## 9 第二轮不能沿用旧梯度

在 $\theta_1=(1/8, 1/5)$ 处，上一节新残差正是本轮旧残差。对a的分项 $(49, 9, -79, -119)/160$ 相加得 $-7/8$ ；对b的分项 $(-98, -18, -158, -238)/160$ 相加得 $-16/5$ 。因此 $g_2=(-7/8, -16/5)$ 。

带入历史状态而非重新置零： $m_2=(-11/16, -13/5)$ ， $v_2=(97/256, 139/25)$ 。第二轮修正因子分别 $1-(1/2)^2=3/4$ 、 $1-(3/4)^2=7/16$ ，所以 $\hat{m}_2=(-11/12, -52/15)$ ， $\hat{v}_2=(97/112, 2224/175)$ 。平方根一般是无理数，不能为了表格好看把它们编成分数。

$$a_2 = \frac{1}{8} + \frac{11}{48(\sqrt{97/112} + 1)},$$

$$b_2 = \frac{1}{5} + \frac{13}{15(\sqrt{2224/175} + 1)}.$$

它们约为 $(0.2437004841250088, 0.3898541226435905)$ 。再以新参数对四行重算预测 $a_2-2b_2$ 、 $a_2-2b_2$ 、 $a_2+2b_2$ 、 $a_2+2b_2$ ，然后各减原始标签、平方、求平均。得到 $F_2 \approx 1.1555504621664184$ 。完整逐行小数表与高精度根号参照在实验和解答中给出。

这里只在展示时舍入；实际算法每一步使用存储浮点参数。精确Fraction可以核验第一轮、第二轮的有理矩，第二次平方根及后续轨迹再用Decimal独立检查。不能把展示到四位小数的参数反馈进程序还期待原路径逐位一致。

## 10 有效系数 不等于当前梯度乘一个数

对Adam定义坐标系数 $d_{t,j} = \eta/(\sqrt{\hat{v}_{t,j}} + \epsilon)$ ，更新为 $-d_{t,j}\hat{m}_{t,j}$ 。d描述本轮预条件尺度，但乘的是历史方向 $\hat{m}$ ，不是当前g。因此把 $\Delta\theta/g$ 叫“有效学习率”可能在 $g=0$ 时无定义，或在动量与当前梯度反向时出现负值。

报告同时记录原始 $g$ 、 $m$ 、 $v$ 、 $\hat{m}$ 、 $\hat{v}$ 、分母、 $d$ 与实际 $\Delta\theta$ 。只画 $d$ 很大不能断言参数步子很大；还要看被乘的 $\hat{m}$ 。零当前梯度也不一定意味着不移动，非零历史 $m$ 仍可能继续推动参数。

在主例第一步 $d=(1/8, 1/20)$ ，方向 $\hat{m}=(-1, -4)$ ，实际增量 $(1/8, 1/5)$ 。 $a$ 的系数更大，但 $b$ 的实际增量更大，这已经说明不能只看系数大小比较移动量。




图5 同一轮的梯度、方向平均、坐标系数与实际位移分开画，避免把一种量当成另一种。

## 11 $\epsilon$ 的位置和单位也会改变算法

$\sqrt{\hat{v}} + \epsilon$ 与 $\sqrt{\hat{v} + \epsilon}$ 通常不同，且 $\epsilon$ 的单位不同：前者与梯度同单位，后者与梯度平方同单位。若 $\hat{v}=0$ ，前者分母 $\epsilon$ ，后者分母 $\sqrt{\epsilon}$ ；当 $\epsilon$ 很小时差异可能很大。不要因为两种形式都防止除0就认为可以互换。

对无正则Adam，把整个目标乘正数 $c$ ，且比较同一参数路径上的梯度，有 $g'=cg$ 、 $m'=cm$ 、 $v'=c^2v$ 。因此若 $\epsilon'=c\epsilon$ ，归一化方向完全相同；若 $\epsilon$ 不变，等价于在原问题中使用 $\epsilon/c$ ，一般不会逐步相同。 $\epsilon=0$ 且分母非零时才有简单的尺度消去。

这种固定坐标下的整体梯度缩放，不等于任意参数坐标变换不影响算法，更不等于各种惩罚一起自动保持等价。实验用目标 $\times 100$ 分别保持 $\epsilon$ 和同步 $\times 100$ ，验证两个不同命题。

## 12 用同一目标比较四种优化器

主比较均令 $\lambda=0$ ，使用相同数据、初始 $\theta$ 、100次全批更新，每次处理4行，预算400次样本梯度。

AdaGrad、RMSProp、Adam与普通GD同时记录原目标和各自状态， $\epsilon$ 与各历史系数都显式给出。

$\eta$ 相同并不意味着实际位移相同，也不意味着调参公平已经解决。这个比较先控制一个机制变量；另用预先写入的有限学习率网格展示结果对 $\eta$ 敏感，不根据测试集或事后挑最漂亮曲线宣布赢家。无论哪条曲线最低，都只是这个数据、这个预算、这套候选参数的有限证据。

Adam也不能自动保证逐步下降。可以仍用同一数据，从接近最优的 $\theta=(1+10^{-6}, 1)$ 出发，另标记 $\epsilon=10^{-8}$ 、较大 $\eta$ ：第一步归一化后可能跨过最优很多，使原目标差增大。要从完整旧残差与 $g$ 重新计算这个反例，不能只画一个任意向量箭头。




图6 相同目标与梯度工作量下，优化器轨迹和学习率敏感性需要一起观察。

## 13 L2惩罚怎样进入梯度

取非负 $\lambda$ 和对角选择矩阵 $P$ ，本例 $P=\text{diag}(0,1)$ ，即只惩罚斜率。正则目标 $J(\theta)=F(\theta)+\lambda\theta^T P\theta/2$ ，其梯度 $g_J = g_F + \lambda P\theta$ 。对无动量普通GD，更新为

$$\theta^+ = \theta - \eta(g_F + \lambda P\theta) = (I - \eta\lambda P)\theta - \eta g_F.$$

所以在这个明确约定下，“把L2梯度加进去”与“同一步按 $1-\eta\lambda$ 缩减相应参数”完全一致。这个等式依赖更新是对总梯度线性乘同一个 $\eta$ ，不应未经证明推广到带历史或自适应分母的方法。

不同文章把每步缩减率直接记为 $\lambda$ ，而一些库把 $\lambda$ 记为乘学习率之前的系数，两者差一个 $\eta$ 。读公式时必须说明是哪一种；不能只比较参数名。这里所有AdamW式衰减采用库常见的 $1-\eta\lambda$ 约定。

## 14 在Adam里耦合L2会改变两个历史矩

耦合L2先形成 $g_J = g_F + \lambda P\theta$ ，再把它送入 $m$ 与 $v$ 。因此正则项不仅改变当前方向，也被历史一阶平均和平方幅度记住。由于平方含交叉项， $v(g_F + \lambda P\theta)$ 不是 $v(g_F)$ 加一个简单常数。

更一般地，即便只考虑已给定的对角预条件矩阵 $D$ ，更新 $-\eta D(g_F + \lambda P\theta)$ 中的缩减部分也是 $-\eta\lambda D P\theta$ 。只要 $D$ 不同坐标不等，就不是每个被选择参数同倍率的缩减。Adam的 $D$ 还随过去梯度变化，差异更多。

因此Adam中的L2惩罚仍有明确的正则目标含义，但它不等价于下面的AdamW更新。两者哪个好必须看任务与评估证据，不能把“不等价”写成“一定无效”。




图7 耦合L2进入m和v；解耦衰减绕过矩状态直接作用于旧参数。

## 15 AdamW把衰减与梯度预条件分开

AdamW用原数据梯度 $g_F$ 更新m、v和修正量，再按

$$\theta_t = (I - \eta_t \lambda P) \theta_{t-1} - \eta_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$$

更新。衰减使用旧参数，并且不进入m或v。若先做自适应更新，再对新参数整体乘缩减率，会额外缩小梯度步，与上述同步式不同。库可能先原地缩减参数再应用已由旧梯度计算的步，代数上仍对应同一公式，需核对梯度计算时刻。

实验的耦合与解耦对比从同一非零初值(1/2, -1/2)出发， $\lambda=0.1$ ，mask=(0,1)。这样第一步已能显露差异，而不是从全零点看第一步碰巧相同就误以为等价。记录各自原F、若考虑L2时的J、矩状态、衰减位移和自适应位移，避免把不同目标的数值混作一条损失。

未受惩罚的截距是本次显式选择，不是“AdamW自动不衰减bias”。参数分组需要研究者明确给出。若学习率随t变化，即使纯衰减也为 $\prod_t (1 - \eta_t \lambda) \theta_0$ ，不是与调度无关的一条固定指数。

## 16 零梯度 与没有梯度不是一回事

数学上的零向量梯度仍是一轮明确更新：历史矩可能衰减、非零m可能继续产生位移、AdamW还可能做权重缩减。库中的grad=None通常表示该参数没有参与本轮梯度计算，可跳过参数与状态更新。这是接口语义，不能把None当作已经算出精确0。

真实库对照会分别构造全零梯度张量和None，检查参数、步数与状态，不只比较最终损失。还会核对显式参数组的衰减mask。检查使用CPU float64、单线程、关闭foreach和fused等路径；不凭最新版文档默认值推断另一个已安装版本。

## 17 保存参数还不够 恢复全部状态

Adam的下一步依赖 $\theta$ 、 $m$ 、 $v$ 、 $t$ 和超参数；RMSProp依赖 $v$ ，AdaGrad依赖 $s$ 。中途保存 $\theta$ 后新建优化器，会重置历史与修正步数，即使数据顺序和 $\eta$ 不变，也可能产生另一条轨迹。

实验在第7次更新后保存所有状态，再从第8次继续，并与未中断100步逐状态比较；另做只恢复 $\theta$ 的反例。若学习率调度、抽样器或模型中还有随机性，还需要相应状态才能谈完整复现，本讲确定性全批任务把这些额外因素暂时排除。

不要把保存的 $v$ 任意改成负数、把 $t$ 改成True或漏掉某个坐标后继续。程序应在第一次更新之前验证完整状态的形状、原始类型、有限性和非负性，出错不写新结果。研究中的checkpoint首先是一份有语义的状态，不能只因为能JSON读取就当作合法。




图8 连续运行、完整状态恢复和只恢复参数三条路径的分叉说明优化器也有记忆。

## 18 收敛结论与实验结论的边界

这些更新公式本身不是无条件收敛定理。AdaGrad、Adam及其修正版的理论各自规定目标、随机性、步长计划、梯度范围和输出对象。已知工作还指出原始Adam某些收敛论证的问题，并提出保存更长期二阶统计的修正。这里把相关论文作为查证入口，不把一个简短口号当作所有实现的保证。

AMSGrad之类变体也必须明确 $\max$ 作用于哪个未修正或修正状态以及时间因子。不能随手把当前 $v$ 替换为最大值就宣称已严格复现特定库或论文。主实现聚焦已列四种方法及AdamW，不额外把未完整验证的变体纳入“已验收”列表。

对于科研比较，应先统一数据、训练目标、预算、精度和超参数选择规则，再报告多种合理设置、失败状态与复现条件。更低训练目标不自动意味着更好测试表现，自适应也不意味着无需学习率或预处理。


## 19 从手算到库实现的分层验收

第一层用Fraction核验主例全部逐样本梯度、第一步与第二步有理矩；用高精度Decimal计算根号、参数和新前向。第二层以独立标量循环重做向量实现，检验逐元素状态、偏差修正时间索引和同时更新，不能只测最终目标。

第三层在真实PyTorch2.7.1+cpu对照AdaGrad、RMSProp、Adam、Adam加L2和AdamW，显式写明 $\epsilon$ 位置、初始累积、momentum/centered关闭、衰减参数组、foreach与fused设置。比较参数及m/v/s等状态；容差考虑不同等价操作顺序，不要求不同库逐位相同。

第四层验证完整状态恢复、目标缩放与 $\epsilon$ 、零梯度/None、近最优超调和坏尾字段。所有输入先校验，完整运行和序列化成功后才原子替换输出。Notebook固定说明前检查全部默认输入的完整字节；新内核顺序执行，完整报告与脚本一致。最后人工查看每一PDF页及每张真实输出图。

### Each validation layer tests a different claim



Normal and -O new processes + fresh kernel + every PDF page and real plot

图9 数学参照、从零实现、真实库状态和文件保护各自提供不同证据。

## 20 自测与完整验收

1. 从四行数据推F、梯度、Hessian、最优点和最低目标。
2. 展开AdaGrad前三次平方累积，解释何时持续变大、何时不变。
3. 展开RMSProp的历史权重，并区分记忆长度直觉与精确半衰期。
4. 用恒定梯度说明二阶原始矩为何不是方差，也不是Hessian。
5. 写出Adam的一阶、二阶状态及完整同步更新顺序。
6. 从权重总和推偏差修正，说明平稳期望假设与非平稳限制。
7. 同组四行数据完整手算第一轮预测、局部导数、矩、参数和新前向。
8. 从新残差手算第二轮梯度、有理矩、修正量、根号更新和新目标。
9. 解释 $\eta/(\sqrt{\hat{v}}+\epsilon)$ 、 $\Delta\theta$ 与 $\Delta\theta/g$ 的区别，处理零当前梯度。
10. 比较 $\epsilon$ 放在平方根内外，并分析整体目标乘c时怎样匹配 $\epsilon$ 。

11. 在相同400次样本梯度预算下设计四种方法比较，指出尚未控制的调参因素。
12. 用同一数据的近最优初值构造Adam目标差增大的完整更新反例。
13. 从L2梯度推无动量GD与缩减的等价关系，说明 $\lambda$ 约定。
14. 展开耦合L2进入Adam的m和v，明确平方中的交叉项。
15. 推AdamW同步式，比较先更新再衰减新参数为何不同。
16. 从非零初值比较相同 $\lambda$ 的耦合与解耦两步，记录全部状态。
17. 解释显式衰减mask和学习率调度下的累计纯衰减。
18. 用真实库区分零梯度张量和None的参数/步数行为。
19. 证明完整状态恢复可接续同一迭代，并展示只存参数的差异。
20. 设计独立数值参照、库对照、原始类型/坏尾字段/输出保护的验收，区分有限检查与收敛定理。

下一讲处理L1尖点和参数约束。自适应分母没有消除不可微问题，普通光滑更新的假设不能直接搬过去。

## 来源与核查范围

- [Duchi等AdaGrad原始论文](#)：核对对角历史平方统计与其原始优化背景。本讲只实现明确写出的无约束简化形式。
- [Tieleman与Hinton课程讲义](#)：核对RMSProp近期平方平均的提出背景，不复制课件图。
- [Kingma与Ba Adam原始论文](#)：核对算法1和零初始化权重修正；不把论文早期收敛说法当作无限制保证。
- [Loshchilov与Hutter AdamW论文](#)：核对解耦机制与L2非等价，特别区分论文每步衰减和库乘 $\eta$ 的参数约定。
- [Reddi等On the Convergence of Adam and Beyond](#)：核对原始Adam收敛分析的限制及变体背景，不在本讲复用未经展开的保证。
- [PyTorch2.7 Adam与AdamW](#)：核对固定版本接口、衰减与状态；实际已安装版本另以真实运行核验。