

第037讲 练习详解

1 正交结构与目标展开

两特征平方和都为4，内积为 $1-1-1+1=0$ ，所以 $X^T X/4=I$ 。第一列与 y 内积为 $7/4+9/4+5/4+11/4=8$ ，除4得2；第二列与 y 内积为 $7/4-9/4-5/4+11/4=1$ ，除4得 $1/4$ 。

$z=(1,-1,-1,1)$ 与两列内积均0，平方和4。残差是 $(\theta_1-2)X_1+(\theta_2-1/4)X_2-z/2$ ，平方展开的交叉项全为0。因此 $\|r\|^2 = 4(\theta_1 - 2)^2 + 4(\theta_2 - 1/4)^2 + 1$ ，除8得 $f=1/8+(\theta_1-2)^2/2+(\theta_2-1/4)^2/2$ 。

这个常数 $1/8$ 来自无法由两列 X 解释的 $z/2$ ，不能因为它的梯度为0就从报告的实际数据损失中抹掉。

2 零点的次梯度区间

在 $u=0$ ，支撑不等式是 $|v| \geq sv$ 对所有实数 v 成立。 $v>0$ 时除以 v 得 $s \leq 1$ ； $v<0$ 时除以负数反向得 $s \geq -1$ 。必要条件是 $s \in [-1, 1]$ 。

反之，若 s 在此区间， $v \geq 0$ 时 $sv \leq v = |v|$ ； $v < 0$ 时 $s \geq -1$ 乘以 v 反向得 $sv \leq -v = |v|$ 。因此所有这些 s 都可用，既不能缩成 $\{0\}$ 也不能扩大成实数全体。左右导数分别 -1 与 1 ，普通导数不存在。

3 Lasso最优点怎样抵消非零梯度

$\theta^*=(3/2, 0)$ 给 $g=(-1/2, -1/4)$ 。第一坐标正数，因此 L_1 次梯度必须是1；第二坐标为0，允许区间 $[-1, 1]$ ，取 $1/2$ 。 $\lambda=1/2$ 乘后为 $(1/2, 1/4)$ ，恰好与 g 相抵。

由凸性，零属于总次微分就是全局最优。又因 $H=I$ 严格正定， f 严格凸，加凸惩罚后仍严格凸，所以本例参数解唯一。 $f=9/32$ ，惩罚 $3/4$ ， $J=33/32$ 。 g 本身不是零，因此把光滑梯度当Lasso终止标准会误判。

4 一个合法次梯度也可能上升

取 $J(u)=|u|$ 、当前 $u=0$ 、 $s=1 \in \partial J(0)$ 、 $\eta>0$ 。更新 $u^+=-\eta$ ， J 从0变 η 。它甚至从最优点离开。这不是次梯度定义失效，而是“所有负次梯度都是下降方向”这个推断错误。

若实现固定 $\text{sign}(0)=0$ ，这个特定起点会不动，但不推出别处不越过零点。例如 $u=0.1$ 、 $\eta=0.3$ ， $s=1$ ，更新到 -0.2 ，目标 0.1 变 0.2 。

5 盒投影与单纯形的差别

平方距离 $\sum_j (u_j - z_j)^2/2$ 与盒约束都按坐标分离。在第 j 坐标的区间 $[a, b]$ 内，无约束极小点 z 若可行就选 z ；若 z 小于 a ，整个区间位于抛物线递增侧，最小在 a ；若 z 大于 b ，最小在 b 。因此逐坐标clip。

单纯形要求非负且总和1。对 $z=(0.8,0.8)$ ，逐坐标clip到 $[0,1]$ 仍是 $(0.8,0.8)$ ，和1.6不满足约束；欧氏投影实际为 $(0.5,0.5)$ 。因此clip不是通用投影算法。

6 投影变分不等式的证明

设 p 最小化距离，任意 $u \in C$ 与 $t \in [0,1]$ 给 $p+t(u-p) \in C$ 。距离函数在 $t=0$ 的一侧导数必须非负，即 $(p-z)^T(u-p) \geq 0$ ，等价于 $(z-p)^T(u-p) \leq 0$ 。

反过来展开 $\|u - z\|^2 = \|p - z\|^2 + 2(p - z)^T(u - p) + \|u - p\|^2$ 。中间项非负，末项非负，故 p 距离不更大。若 $u \neq p$ ，末项严格正，证明唯一性。 C 非空闭凸是保证存在与这条线段论证成立的重要前提。

7 L1近端三个分支

标量问题 $\min_u (u - z)^2/2 + \tau|u|$ 的最优性是 $0 \in u - z + \tau\partial|u|$ 。 $u > 0$ 时 $u = z - \tau$ 且 $z > \tau$ ； $u < 0$ 时 $u = z + \tau$ 且 $z < -\tau$ ； $u = 0$ 时 $|z| \leq \tau$ 。二次项严格凸，满足条件的候选唯一。

$z = \tau$ 或 $z = -\tau$ 时，两边分支的极限都是0，零分支的闭区间必须包含边界。 $\tau = 0$ 时无论正负均得到 $u = z$ ， $z = 0$ 也得到0。本讲 $\tau = \eta\lambda$ ，不能漏掉 η 。高维L1与二次距离都可分离，因此逐坐标应用该解。

8 计算四个阈值结果

$\tau = 1/4$ 。 $z_1 = -3/4$ 小于 $-\tau$ ，所以加 τ 得 $-1/2$ ； $z_2 = -1/4$ 恰等于负边界，得0； $z_3 = 1/8$ 在区间内，得0； $z_4 = 3/8 > \tau$ ，减 τ 得 $1/8$ 。答案 $(-1/2, 0, 0, 1/8)$ 。

若得到 $(-3/4, 0, 0, 3/8)$ ，那是某种hard-threshold而不是L1近端；若第三项是 $-1/8$ ，说明错误地对所有正 z 一律减 τ ，没有核对分支条件。

9 第一轮完整局部导数链

每行都有 $\partial r / \partial \text{预测} = 1$ ， $\partial \text{预测} / \partial \theta = (x_1, x_2)$ ， $\partial \ell / \partial r = r$ 。因此每一项是 $r \times 1 \times x_j \times 1/4$ 。旧 $\theta = (0, 1/2)$ 。

行	预测	残差	半平方	梯度分项1	梯度分项2
s1	-1/2	5/4	25/32	-5/16	-5/16
s2	1/2	11/4	121/32	-11/16	11/16
s3	-1/2	-7/4	49/32	-7/16	7/16
s4	1/2	-9/4	81/32	-9/16	-9/16

两列求和为 $(-2, 1/4)$ 。 $z = (0, 1/2) - (1/2)(-2, 1/4) = (1, 3/8)$ 。 $\tau = 1/4$ ；两坐标都走正分支，同步得 $\theta^1 = (3/4, 1/8)$ 。注意第一坐标变动时不要修改第二坐标的旧残差。

行	预测	残差	半平方
s1	-7/8	7/8	49/128
s2	-5/8	13/8	169/128
s3	5/8	-5/8	25/128
s4	7/8	-15/8	225/128

旧半平方和69/8，除4为69/32；加 $1/4$ 得 $J_0 = 77/32$ 。新半平方和117/32，除4为117/128；加 $\lambda(3/4 + 1/8) = 7/16$ ，得 $J_1 = 173/128$ 。

10 第二轮完整局部导数链

本轮旧 $\theta = (3/4, 1/8)$ ，旧预测与上一题新预测严格对齐。

行	预测	残差	半平方	梯度分项1	梯度分项2
s1	-7/8	7/8	49/128	-7/32	-7/32
s2	-5/8	13/8	169/128	-13/32	13/32
s3	5/8	-5/8	25/128	-5/32	5/32
s4	7/8	-15/8	225/128	-15/32	-15/32

导数链中的 x_1 、 x_2 和 $1/4$ 不变，但 r 变了，所以 $g = (-5/4, -1/8)$ 。平滑点 $z = (11/8, 3/16)$ ， $\tau = 1/4$ 。第一坐标正分支为 $9/8$ ；第二坐标因为 $|3/16| \leq 1/4$ ，取0。产生精确零的位置是近端分支判断，不是浮点舍入。

行	预测	残差	半平方
s1	-9/8	5/8	25/128
s2	-9/8	9/8	81/128
s3	9/8	-1/8	1/128
s4	9/8	-13/8	169/128

$f_2 = 69/128$ ，惩罚 $9/16$ ， $J_2 = 141/128$ 。 $J^* = 33/32 = 132/128$ ，所以目标差 $9/128$ 。第二坐标满足零点KKT，第一坐标 $g_1 + \lambda = -7/8 + 1/2 = -3/8$ ，说明尚未最优。

11 KKT与gradient mapping不是同一向量

$\theta^1=(3/4, 1/8)$ 两个分量均正, $g=(-5/4, -1/8)$, 故最小范数总次梯度 (本处唯一) 是 $g+(1/2, 1/2)=(-3/4, 3/8)$ 。

$G\eta=(\theta^1-\theta^2)/\eta=[(3/4, 1/8)-(9/8, 0)]/(1/2)=(-3/4, 1/4)$ 。第二分量不同。原因是近端子问题用新点的L1次梯度; 它跨到了零区间, 不能拿旧点正分支次梯度代替它。

两者无穷范数在此恰好同为3/4, 并不代表向量相同。比较数值证据时要保留各坐标, 不能只看一个汇总范数。

12 近端映射零点的等价性

$G\eta(\theta)=0$ 当且仅当 $\theta=\text{prox}_{\eta}h(\theta-\eta g)$ 。近端最优性在新旧点相同时成为

$$0 \in \partial h(\theta) + (\theta - (\theta - \eta g))/\eta = \partial h(\theta) + g。$$

反向同样成立: 若0在此集合中, 则 θ 满足该强凸近端子问题的最优性, 必是其唯一解, 所以映射为零。凸 $f+h$ 的全局最优性由总次微分判定; 非凸问题即使有类似驻点条件, 也不自动是全局最优。

13 下降引理与近端下降式

设 $d=u-\theta$ 。微积分基本定理给 $f(u) - f(\theta) = \int_0^1 \nabla f(\theta + td)^\top d dt$ 。减去 $g^\top d$, 积分内绝对值被 $L\|d\|^2$ 界住, 积分得到 $L\|d\|^2/2$ 。

令 $s=-g-d/\eta \in \partial h(u)$ 。支撑不等式 $h(\theta) \geq h(u) + s^\top(\theta-u)$, 整理成 $h(u)-h(\theta) \leq -g^\top d - \|d\|^2/\eta$ 。相加得到 $J(u) - J(\theta) \leq -(1/\eta - L/2)\|d\|^2$ 。

若 $\eta \leq 1/L$, 则 $1/\eta - L/2 \geq 1/(2\eta) > 0$, 除固定点外精确算术下严格下降。前提包括L有效、梯度准确、h凸和近端准确求解, 不适用于把L1换成任意非凸惩罚后仍照搬。

14 过大步长反例

这是另标记设置 $\theta=(0,0)$ 、 $\eta=3$ 、 $\lambda=1/2$, 原始X与y不变。 $g=(-2, -1/4)$, $z=(6, 3/4)$, $\tau=3/2$, 因此 $\theta^*=(9/2, 0)$ 。旧目标69/32。

新 $f=1/8+(5/2)^2/2+(-1/4)^2/2=105/32$; 新惩罚 $(1/2)(9/2)=9/4=72/32$, 总目标177/32。增量108/32>0。 $\eta=3$ 不满足 $L=1$ 时的 $\eta \leq 1$ 充分条件, 此反例并不反驳有条件的下降定理。

15 三点式和目标误差界

凸性给 $f(\theta) - f(v) \leq g^\top(\theta - v)$; 下降引理给 $f(u) - f(\theta) \leq g^\top(u - \theta) + L\|u - \theta\|^2/2$ 。相加并用h在u处的支撑不等式 $h(u) - h(v) \leq s^\top(u - v)$, 得到

$$J(u) - J(v) \leq (g + s)^\top (u - v) + \frac{L}{2} \|u - \theta\|^2.$$

因 $g+s=(\theta-u)/\eta$ ，内积恒等式把右边变成 $[\|\theta - v\|^2 - \|u - v\|^2]/(2\eta) - (1/(2\eta) - L/2)\|u - \theta\|^2$ 。
 $\eta \leq 1/L$ 时可丢掉最后非正项；取 $v=\theta^*$ 即三点式。

从 $t=0$ 至 $k-1$ 求和，右侧 $\leq$ 初始距离平方/ (2η) 。左侧是 k 个目标差之和。由单调性每项 $\geq$ 最后目标差，因此 $k(J(\theta_k)-J^*) \leq$ 初始距离平方/ (2η) 。条件：凸可导 f 、 L -Lipschitz梯度、闭适当凸 h 、最优点存在、固定 $0 < \eta \leq 1/L$ 、精确计算。结论关于目标，不自动给参数误差。

16 坐标下降推导及零列

把其他坐标固定，定义 $a_i = y_i - \sum_{k \neq j} x_{ik} \theta_k$ 。平方项 $\sum (x_{ij} u - a_i)^2 / (2n)$ 展开为 $(q_j/2)u^2 - c_j u$ 加常数。
 $q_j = \sum x_{ij}^2 / n$ ， $c_j = \sum x_{ij} a_i / n$ 。 $q_j > 0$ 时用次梯度三分支，得 $S\lambda(c_j)/q_j$ 。

例如主数据 $q_1=q_2=1$ ， $c_1=2$ 、 $c_2=1/4$ ，不受另一坐标影响，所以一次扫描到 $(1.5, 0)$ 。若 $q_j=0$ ，所有 $x_{ij}=0$ ， $c_j=0$ ，子问题仅 $\lambda|u|$ 加常数； $\lambda > 0$ 唯一最小 $u=0$ ， $\lambda=0$ 所有 u 都最优。代码取0是一项约定，不是数学唯一性。

17 相关设计的两种顺序

$\rho=7/8$ 时第二列是 $(-1, -3/4, 3/4, 1)$ ，Gram为 $H = \begin{pmatrix} 1 & 7/8 \\ 7/8 & 25/32 \end{pmatrix}$ ， $X^T y/4 = (2, 57/32)$ 。仍从 $\theta=(0, 1/2)$ 开始， $\lambda=1/2$ 。

先坐标1： $c_1=2-(7/8)(1/2)=25/16$ ，soft后 $\theta_1=17/16$ 。随后 $c_2=57/32-(7/8)(17/16)=109/128$ ，soft后除 $25/32$ ， $\theta_2=(45/128)/(25/32)=9/20$ 。因此顺序 $[0, 1]$ 终点 $(17/16, 9/20)$ 。

反顺序先坐标2： $c_2=57/32$ ，soft后除 $25/32$ 得 $41/25$ ；再 $c_1=2-(7/8)(41/25)=113/200$ ，soft后 $\theta_1=13/200$ 。因此 $[1, 0]$ 终点 $(13/200, 41/25)$ 。不同顺序完全可以有不同中间路径。

同步近端用旧 θ 的 $g=(-25/16, -89/64)$ ， $\eta=1/2$ ， $z=(25/32, 153/128)$ ，阈值 $1/4$ ，得到 $(17/32, 121/128)$ 。
 这三种终点都来自同一压力数据、同一初值，差别来自算法顺序。压力例 L 约1.772，而 $\eta=1/2$ 仍小于 $1/L$ ；精确 L 由程序计算，不借显示舍入值更新。

18 盒约束的两步与最优性

最优点把无约束 $(2, 1/4)$ 投影到 $[0, 1]^2$ ，因 $H=I$ 此处恰为 $(1, 1/4)$ 。一般 H 非单位矩阵时，不能用欧氏投影无约束最小点来代替求整个约束问题。

初值 $(0, 1/2)$ 的 $g=(-2, 1/4)$ ，平滑步 $(1, 3/8)$ ，已可行。此点 $g=(-1, 1/8)$ ，下一平滑步 $(3/2, 5/16)$ ，第一维投影回1，得到 $(1, 5/16)$ 。在最优点 $g=(-1, 0)$ ，负梯度想出盒，投影后仍回原点。故投影映射0、光滑梯度范数1并不矛盾。

19 特征缩放与解释边界

令新列 cX_1 与新系数 β ，预测不变需要 $\theta_1 = c\beta$ 。相同数值 λ 的惩罚变为 $\lambda|\beta| = (\lambda/c)|\theta_1|$ ，所以目标函数在原预测坐标上改变了。若要保持原来的 $\lambda|\theta_1|$ ，新坐标应惩罚 $\lambda c|\beta|$ 。

主正交数据第一预测系数最优为 $\max(2 - \lambda/c, 0)$ 。 $\lambda = 1/2$ 、 $c = 2$ 时变成 $7/4$ ，而非原来的 $3/2$ 。曲线变化是问题改变的结果。系数为零只说明给定数据、尺度和 λ 下的正则最优解选择，不蕴含因果无效或独立关系。

20 会被一条损失曲线掩盖的错误

错误一：CSV末行 y 是字符串"NaN"，代码先运行求解再检查。捕获办法是完整原始输入验证与坏尾字段哨兵，要求前向函数一次也不能被调用；失败时旧报告字节不变。

错误二：只计算 f 而忽略 λL_1 。用 $J = f + \text{penalty}$ 逐轮对账，手算第一轮 $J_1 = 173/128$ ；稀疏模型可能提高 f 却降低 J ，不能只看 f 排序。

错误三：把极小但非零系数记为0，并把光滑梯度当KKT。捕获办法是保存原系数、阈值分支、严格零计数、完整KKT向量与gradient mapping；最优点 $g \neq 0$ 应被视为正确。

还应测试输出路径symlink/hardlink保护、Notebook默认SHA篡改、-O下不依赖assert的验证、自定义合法极端初值不会被内部默认范围意外拒绝。有限测试是证据集合，不是程序对所有输入正确的数学证明。