

第037讲 约束与非光滑优化

1 为什么普通梯度不再够用

直接先修：第016讲的向量与矩阵、第032至033讲的优化与梯度下降。上一讲讨论了如何利用梯度历史调整方向和尺度；本讲追问更基础的事：若目标在某处根本没有普通导数，或者梯度一步走出了允许的参数集合，应该更新什么？

目标有绝对值尖点时，不能随手给尖点安上一个普通导数，再沿用光滑目标的保证。参数有约束时，即使目标处处可导，最优点也未必满足梯度为零。我们会分别建立次梯度、投影和近端三种语言，再把它们放进同一份稀疏回归账本。

学完应能独立回答：为什么L1会产生精确的零；阈值为什么是学习率乘正则系数；怎样从每行残差组成更新；为什么光滑梯度、近端映射和KKT残差不是同一个量；为什么一次坐标扫描与一次同步近端更新也不是同一种工作。所有实验是原创小型合成数据上的优化机制检验，不是变量因果发现或泛化成绩。

2 先把形状 单位 与目标写完整

设样本数 n 、特征数 p ，矩阵 $X \in \mathbb{R}^{n \times p}$ 第 i 行是 $x_i^\top$ ，参数 $\theta \in \mathbb{R}^p$ ，标签 $y \in \mathbb{R}^n$ 。预测向量 $\hat{y} = X\theta$ ，残差 $r = X\theta - y$ 。没有额外截距列；本讲两个特征和标签均已中心化。用不带截距的模型，不能让库默尔再拟合一个截距。

$$f(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2, \quad h(\theta) = \lambda \|\theta\|_1, \quad J(\theta) = f(\theta) + h(\theta), \quad \lambda \geq 0.$$

这里单行损失 $\ell_i = r_i^2/2$ ，最后才除以 n 。光滑梯度 $g = \nabla f = X^\top r/n$ 形状 p ，Hessian $H = X^\top X/n$ 形状 $p \times p$ 。不要把 g 称为整个 J 的普通梯度。

合成例中的数值全部无物理单位。如果实际标签单位为 U 、特征无量纲，则 θ 单位为 U ， f 与 J 单位为 U^2 ， g 与 λ 单位为 U ， η 在该坐标约定下无量纲， $\eta\lambda$ 与 θ 同单位。若不同特征本身单位不同，就需要先定义坐标缩放或加权惩罚，不能不加说明地给不同单位的系数套同一个 λ 。范数 $\|\theta\|_1 = \sum_j |\theta_j|$ ，而不是各元素平方和。

3 一份贯穿全讲的四行数据

样本	x1	x2	y
s1	-1	-1	-7/4
s2	-1	1	-9/4
s3	1	-1	5/4
s4	1	1	11/4

记 $z=(1,-1,-1,1)^T$ ，则 $y = 2X_{:1} + X_{:2}/4 + z/2$ 。两列 X 及 z 相互正交，每列平方和4；因此 $n=4$ 、 $p=2$ 、 $X^T X/4 = I_2$ 、 $X^T y/4 = (2, 1/4)^T$ 。

直接展开平方，交叉项因正交消失，得到独立核验式

$$f(\theta) = \frac{1}{8} + \frac{1}{2}(\theta_1 - 2)^2 + \frac{1}{2}(\theta_2 - 1/4)^2, \quad g = (\theta_1 - 2, \theta_2 - 1/4)^T.$$

实际程序仍从每行预测、残差和导数求梯度，不用这个答案更新参数。默认 $\lambda=1/2$ 、 $\eta=1/2$ 、初值 $\theta^0=(0, 1/2)^T$ 。设计正交是为了手算透明，不是声称真实数据通常正交。第18节另标记相关设计压力例，不在主实验中暗换数据。

4 绝对值零点的次梯度是一个集合

对凸函数 h ，向量 s 是 h 在 u 处的次梯度，当且仅当对定义域中所有 v 成立

$$h(v) \geq h(u) + s^T(v - u).$$

右边是一张全局支撑平面，不是要求存在唯一切线。所有这样的 s 组成次微分 $\partial h(u)$ 。在可导凸函数处它恰好只有普通梯度一个元素，但“每个凸函数处处可导”是错的。

推导 $\partial|u|$ ：若 $u>0$ ，左右邻域都在正半轴，斜率只能为1；若 $u<0$ ，只能为-1。若 $u=0$ ，定义变成 $|v| \geq sv$ 。代 $v>0$ 得 $s \leq 1$ ；代 $v<0$ 得 $s \geq -1$ ；反过来任意 $s \in [-1, 1]$ 对两种符号均成立。因此

$$\partial|u| = \begin{cases} \{1\}, & u > 0, \\ [-1, 1], & u = 0, \\ \{-1\}, & u < 0. \end{cases}$$

设置 $\text{sign}(0)=0$ 是选了其中一个次梯度，绝不是证明零点普通导数等于0。图1中零点的橙色线段应看成一整个集合，不能当作一条函数曲线的单值。




图1 绝对值的支撑直线与次微分；零点允许一整段斜率。

5 从零次梯度得到Lasso最优性条件

凸函数 J 的全局最优 θ 满足且仅满足 $0 \in \partial J(\theta^*)$ 。充分性直接来自次梯度定义：取 $s=0$ ，则所有候选 v 都有 $J(v) \geq J(\theta)$ 。必要性也直接成立：若 θ^* 最优，零向量正好满足该定义。这里 J 是有限凸函数；本讲的光滑 f 与有限连续 $L1$ 允许次微分求和。

所以 $0 \in g(\theta) + \lambda \partial \|\theta\|_1$ ，逐坐标变成

$$\theta_j > 0 : g_j + \lambda = 0; \quad \theta_j < 0 : g_j - \lambda = 0; \quad \theta_j = 0 : |g_j| \leq \lambda.$$

零系数并不要求对应数据梯度为0。主例 $\theta=(3/2, 0)$ 的光滑梯度为 $(-1/2, -1/4)$ ，可取 $L1$ 次梯度 $(1, 1/2)$ ，两者抵消。这里 θ 唯一，因为 $H=I$ 给 f 严格凸；对于相关或秩亏 X ，Lasso系数未必唯一，不能从一个求解器返回一组系数推出唯一性。

代回得 $f(\theta^*) = 9/32$ 、 $L1$ 项 $3/4$ ，故 $J^* = 33/32$ 。这个最优值只属于这份 X 、 y 及 $\lambda=1/2$ 。更换数据后仍写 $33/32$ ，会制造虚假的“目标差”。

6 次梯度迭代为什么可能来回跳

一种直接方法是 $\theta^{t+1} = \theta^t - \eta_t(g(\theta^t) + \lambda s^t)$ ，其中 $s_j^t \in \partial |\theta_j^t|$ 。它确实可定义，但负次梯度不一定是当前点的下降方向。

最小反例取 $J(u)=|u|$ 、 $u=0$ 、选择合法 $s=1$ ，则任意 $\eta>0$ 都更新到 $-\eta$ ，目标由0增至 η 。即使固定选 $\text{sign}(0)=0$ ，靠近零点而不等于零时，也可能一步越过尖点再折返。固定步长不保证精确停在最优点。

若凸函数沿路径次梯度有界为 G ，最优点存在且初始距离 $\leq R$ ，把平方距离展开并应用支撑不等式可得

$$2\eta_t[J(\theta^t) - J^*] \leq \|\theta^t - \theta^*\|^2 - \|\theta^{t+1} - \theta^*\|^2 + \eta_t^2 G^2.$$

求和后，历史最好目标差不超过 $(R^2 + G^2 \sum_t \eta_t^2) / (2 \sum_t \eta_t)$ 。这解释了衰减步长的作用，但并非说任意常步长、任意无界路径都有保证，也不保证每轮下降。实验保留固定步长的振荡，不能悄悄只画历史最低点冒充每轮真实目标。

7 投影先解决可行性

设 C 是非空闭凸集合，欧氏投影定义为 $\Pi_C(z) = \arg \min_{u \in C} \|u - z\|^2/2$ 。闭集使连续距离在有界子水平集上取到最小值；二次距离严格凸而 C 凸，使最小点唯一。

令 $p = \Pi_C(z)$ 。沿任意可行线段 $p + t(u - p)$ 做一侧导数，得到 $(p - z)^\top (u - p) \geq 0$ 。反过来若此不等式对所有 $u \in C$ 成立，展开距离平方即可证明 p 最优。这是投影的变分刻画。

盒约束 $C = \prod_j [a_j, b_j]$ 可分离，逐坐标投影就是clip：小于下界抬到下界，大于上界压到上界，中间保持。投影到一般凸集合不等于逐坐标clip；例如单纯形还要满足总和为1，坐标间耦合。

投影梯度采用 $\theta^+ = \Pi_C(\theta - \eta \nabla f(\theta))$ 。它解决的是约束问题 $\min f$ over C 。本讲盒实验不额外加入L1，故它的目标值不能与Lasso的J直接排名。若初值不在盒内，程序明确记录原初值并先投影，再开始可行路径。

8 边界最优点的梯度可以不为零

约束问题的最优性条件为 $\nabla f(\theta^*)^\top (u - \theta^*) \geq 0$ 对所有 $u \in C$ 。把上一节投影不等式代入可知，这等价于固定点 $\theta^* = \Pi_C(\theta^* - \eta \nabla f(\theta^*))$ ，其中 $\eta > 0$ 。

主数据若 $C = [0, 1]^2$ ，最优点是 $(1, 1/4)$ 。光滑梯度是 $(-1, 0)$ 。第一维负梯度想继续往右走，但右边已不可行；非零梯度由边界反作用抵消。每次从此点先走到 $(1 + \eta, 1/4)$ ，再投影回原点，投影映射残差为0。

从 $(0, 1/2)$ 用 $\eta = 1/2$ ，第一次平滑试探 $(1, 3/8)$ ，投影仍为 $(1, 3/8)$ ；第二次平滑试探 $(3/2, 5/16)$ ，投影变为 $(1, 5/16)$ 。这与主L1路径 $(3/4, 1/8)$ 、 $(9/8, 0)$ 不同，因为问题本来就不同。




图6 光滑盒约束实验的轨迹、非零梯度与趋零投影残差。

9 用近端算子保留不光滑项

对适当、闭、凸 h 及 $\eta > 0$ ，近端算子定义为

$$\text{prox}_{\eta h}(z) = \arg \min_u \left\{ h(u) + \frac{1}{2\eta} \|u - z\|^2 \right\}.$$

“适当”指不恒为 $+\infty$ 且从不取 $-\infty$ ；“闭”在这里指下半连续。它们加上凸性让这个强凸子问题有唯一解。二次项限制偏离 z 的距离， h 则表达稀疏、约束或其他结构。

若 $h=0$ ，近端就是恒等映射。若 h 为集合 C 的指示函数 δ_C ，在 C 内为0、外为 $+\infty$ ，近端就是 Π_C 。注意这个凸分析指示函数不是概率论中取0或1的事件指示变量。

若 h 是一般可导函数，近端最优性写作 $u = z - \eta \nabla h(u)$ ，右侧在新 u 处评价，属于隐式关系。普通梯度步用旧 z 处的梯度，是另一种映射。这也是“先加梯度再裁一下”不能概括所有近端算法的原因。

10 完整推导L1的soft thresholding

令 $h(u)=\lambda \sum |u_j|$ ，近端目标可分离。乘上 η 后，每个坐标求解 $\min_u \{(u-z)^2/2 + \tau |u|\}$ ，其中 $\tau=\eta\lambda \geq 0$ 。用次梯度最优性： $0 \in u - z + \tau \partial |u|$ 。

第一种情形 $u>0$ ：方程 $u-z+\tau=0$ ，故 $u=z-\tau$ ；成立条件是 $z>\tau$ 。第二种 $u<0$ ： $u-z-\tau=0$ ，故 $u=z+\tau$ ；成立条件是 $z<-\tau$ 。第三种 $u=0$ ：需要 $0 \in -z+\tau[-1,1]$ ，即 $|z| \leq \tau$ 。三种情况穷尽实数，边界 $z=\pm\tau$ 均落到 $u=0$ 。

$$S_\tau(z) = \begin{cases} z - \tau, & z > \tau, \\ 0, & |z| \leq \tau, \\ z + \tau, & z < -\tau. \end{cases} \quad S_\tau(z) = \text{sign}(z) \max(|z| - \tau, 0).$$

$\lambda=0$ 时 $\tau=0$ ，映射恢复恒等； $\eta\lambda$ 才是本轮阈值，不能直接把 λ 当阈值。soft-threshold既收缩大系数，也把一个区间压成精确零。hard-threshold仅删除小系数、保留大系数原值，它不是此L1近端的解。

例如 $\tau=1/4$ ， $z=(-3/4, -1/4, 1/8, 3/8)$ 变成 $(-1/2, 0, 0, 1/8)$ 。阈值相等时也应得到零，不应因为实现中用了错误严格不等式而留下特殊边界。




图2 平滑试探值进入阈值区间后成为精确零；右图显示两个标量近端子问题。

11 近端梯度来自一个局部优化问题

把光滑 f 在旧 θ 处线性化，并用二次项控制步长，保留 h 的完整形状：

$$Q_{\eta}(u; \theta) = f(\theta) + g(\theta)^{\top}(u - \theta) + \frac{1}{2\eta} \|u - \theta\|^2 + h(u).$$

配方时，把与 u 无关的项剔除，得到 $\|u - (\theta - \eta g)\|^2/(2\eta) + h(u)$ 。因此

$$\theta^{t+1} = \text{prox}_{\eta h}(\theta^t - \eta g(\theta^t)) = S_{\eta\lambda}(\theta^t - \eta X^{\top}(X\theta^t - y)/n).$$

先算全部旧预测，再汇总全部 g ，形成全部 z ，逐坐标soft-threshold，最后同时替换全部 θ 。虽然阈值操作可逐坐标执行，每一坐标读的仍是同一轮旧参数构造的 z 。不能更新 θ_1 后再重新计算 g_2 并声称还是同步近端梯度。

12 第一次完整更新的逐行账本

旧 $\theta^0=(0,1/2)$ 。预测每行是 $\theta_1x_1+\theta_2x_2$ 。每行局部链均为： $\partial\ell_i/\partial r_i = r_i$ 、 $\partial r_i/\partial \hat{y}_i = 1$ 、 $\partial \hat{y}_i/\partial \theta_j = x_{ij}$ ，平均梯度分项为 $r_i x_{ij}/4$ 。

样本	预测	残差	单行损失 $r^2/2$	对 θ_1 的均值分项	对 θ_2 的均值分项
s1	-1/2	5/4	25/32	-5/16	-5/16
s2	1/2	11/4	121/32	-11/16	11/16
s3	-1/2	-7/4	49/32	-7/16	7/16
s4	1/2	-9/4	81/32	-9/16	-9/16

相加得 $g^0=(-2,1/4)$ 。平滑试探 $z^0 = \theta^0 - \frac{1}{2}g^0 = (1, 3/8)$ 。阈值 $\tau=\eta\lambda=1/4$ 。第一坐标 $1>1/4$ ，减去 $1/4$ 得 $3/4$ ；第二坐标 $3/8>1/4$ ，减去 $1/4$ 得 $1/8$ 。两坐标同步写入 $\theta^1=(3/4,1/8)$ 。

此时还没有完成本轮验收。必须用新 θ 对全部原始行重新前向，而不是沿用旧损失：

样本	预测	残差	单行损失 $r^2/2$
s1	-7/8	7/8	49/128
s2	-5/8	13/8	169/128
s3	5/8	-5/8	25/128
s4	7/8	-15/8	225/128

因此 $f_0=69/32$ 、 $L1_0=1/4$ 、 $J_0=77/32$ ； $f_1=117/128$ 、 $L1_1=7/16$ 、 $J_1=173/128$ 。只报告数据损失而遗漏惩罚，会误解Lasso优化的对象。

13 第二次更新产生精确零系数

上一节的新预测是这一轮的旧预测。局部链式法则没有变化，残差却必须重算或使用已核对的上一轮新前向，不能沿用第一轮 g^0 。

样本	预测	残差	单行损失 $r^2/2$	对 θ_1 的均值分项	对 θ_2 的均值分项
s1	-7/8	7/8	49/128	-7/32	-7/32
s2	-5/8	13/8	169/128	-13/32	13/32
s3	5/8	-5/8	25/128	-5/32	5/32
s4	7/8	-15/8	225/128	-15/32	-15/32

梯度分项相加为 $g^1=(-5/4, -1/8)$ 。平滑试探为

$z^1 = (3/4, 1/8) - (1/2)(-5/4, -1/8) = (11/8, 3/16)$ 。第一坐标减阈值得9/8；第二坐标3/16落在 $[-1/4, 1/4]$ 内，故直接赋值0，而不是减阈值得-1/16。同步新参数 $\theta^2=(9/8, 0)$ 。

样本	预测	残差	单行损失 $r^2/2$
s1	-9/8	5/8	25/128
s2	-9/8	9/8	81/128
s3	9/8	-1/8	1/128
s4	9/8	-13/8	169/128

新数据损失69/128，L1项9/16，总目标141/128。零系数数目由0变成1。此时还未最优：

$g^2=(-7/8, -1/4)$ ，第一个坐标KKT残差-3/8，第二个坐标因 $|-1/4| \leq 1/2$ 已满足零点条件。目标差是 $141/128 - 132/128 = 9/128$ 。

037 | two step ledger

Old theta = ['0', '1/2']

Old theta = ['3/4', '1/8']

	pred	resid	loss	x1*r/n	x2*r/n
s1	-0.5	1.25	0.7812	-0.3125	-0.3125
s2	0.5	2.75	3.781	-0.6875	0.6875
s3	-0.5	-1.75	1.531	-0.4375	0.4375
s4	0.5	-2.25	2.531	-0.5625	-0.5625

	pred	resid	loss	x1*r/n	x2*r/n
s1	-0.875	0.875	0.3828	-0.2188	-0.2188
s2	-0.625	1.625	1.32	-0.4062	0.4062
s3	0.625	-0.625	0.1953	-0.1562	0.1562
s4	0.875	-1.875	1.758	-0.4688	-0.4688

$g = [-2, 1/4]$
 $z = [1, 3/8] \rightarrow \theta = [3/4, 1/8]$

$g = [-5/4, -1/8]$
 $z = [11/8, 3/16] \rightarrow \theta = [9/8, 0]$

图3 两次更新分别从同一四行旧预测与局部导数出发，先汇总梯度再同步更新。

14 步长条件从哪里来

如果 f 的梯度满足 $\|\nabla f(u) - \nabla f(v)\| \leq L\|u - v\|$ ，沿线段积分并用Cauchy不等式得到下降引理： $f(\theta + d) \leq f(\theta) + g^\top d + L\|d\|^2/2$ 。对平方损失， L 是 $X^\top X/n$ 最大特征值；主数据 $L=1$ 。

近端解 $u=\theta+d$ 满足 $-g - d/\eta \in \partial h(u)$ 。由 h 在 u 处的支撑不等式， $h(u) - h(\theta) \leq -g^\top d - \|d\|^2/\eta$ 。与下降引理相加：

$$J(u) \leq J(\theta) - \left(\frac{1}{\eta} - \frac{L}{2}\right)\|d\|^2.$$

因此 $0 < \eta \leq 1/L$ 是简单充分条件，并给出至少 $\|d\|^2/(2\eta)$ 的理论下降量。这一结论要求凸 h 、准确求近端、准确梯度及精确算术；数值舍入下检查允许小容差。它不能照搬到随机梯度、随意选的次梯度或带惯性更新。

$\eta \leq 1/L$ 不是唯一可能稳定的范围。上式在 $\eta < 2/L$ 仍有正系数，但本讲收敛界采用更保守清楚的 $\eta \leq 1/L$ 。过大 η 的反例仍可用主数据： $\lambda=1/2$ 、 $\theta=(0,0)$ 、 $\eta=3$ ，得到 $z=(6,3/4)$ ，阈值 $3/2$ ， $\theta^+=(9/2,0)$ ，目标从 $69/32$ 升至 $177/32$ 。程序允许此类演示设置，不把不下降误报为代码成功证明。

15 从下降到有限步误差界还差一步

单调下降只说明目标序列有下界时会收敛到某个数，不自动说明这个数是最优值。还需利用凸性和近端最优性。若 θ^* 存在、 $0 < \eta \leq 1/L$ ，可把 f 在 θ^* 处的凸性下界与上节不等式合并，得到三点式

$$J(\theta^+) - J^* \leq \frac{\|\theta - \theta^*\|^2 - \|\theta^+ - \theta^*\|^2}{2\eta}.$$

推导关键是把 $g^\top(\theta^+ - \theta^*)$ 与近端次梯度的内积合并，再用 $2a^\top b = \|a\|^2 + \|b\|^2 - \|a - b\|^2$ ；剩余 $(1/(2\eta) - L/2)\|d\|^2$ 非负，故可丢弃。将 $t=0$ 至 $k-1$ 求和，右侧望远镜相消，再用目标单调性，得到

$$J(\theta^k) - J^* \leq \frac{\|\theta^0 - \theta^*\|^2}{2\eta k}.$$

这是凸复合问题的 $O(1/k)$ 目标界，不是每个参数的 $O(1/k)$ 误差，也不是非凸网络的一般结论。主例 $H=I$ 还具有更强结构：第二坐标进入零区间后保持0，第一坐标的误差每步乘 $1/2$ ；这个更快现象来自本例，不能拿来替代一般证明。

16 三种残差要分开报告

光滑梯度范数 $\|g\|_\infty$ 只适合作为无约束光滑最优性的一类诊断。主Lasso最优点仍有范数 $1/2$ ；盒最优点仍有范数1。把它们当作错误，会把正确求解器改坏。

近端gradient mapping定义为 $G_\eta(\theta) = [\theta - \text{prox}_{\eta h}(\theta - \eta g)]/\eta$ 。它的零点等价于复合最优性，但它不是通常意义上 J 的普通梯度，也不一般等于在当前 θ 处选的最小范数次梯度。

本讲Lasso KKT残差每坐标取 $g_j + \lambda$ ($\theta_j > 0$)、 $g_j - \lambda$ ($\theta_j < 0$)，或 $\text{sign}(g_j) \max(|g_j| - \lambda, 0)$ ($\theta_j = 0$)。这是集合 $g + \lambda \partial \|\theta\|_1$ 中绝对值最小的逐坐标元素。用其无穷范数停止，默认阈值 10^{-10} 。

例如 $\theta^1 = (3/4, 1/8)$ 处，KKT向量 $(-5/4 + 1/2, -1/8 + 1/2) = (-3/4, 3/8)$ ，而 $G\eta = (\theta^1 - \theta^2)/(1/2) = (-3/4, 1/4)$ 。两个向量明显不同，虽然其零点相同。盒问题另用投影映射与可行性违反量；报告中保留的Lasso残差不用于盒问题停止。

目标差 $J - J^*$ 需要知道最优值；实际大问题通常不知道。对偶间隙需要一个可行对偶点，和KKT残差也不是同一个量。真实库核对会记录库的`dual_gap`，不把该数字改名为本讲KKT残差。




图5 光滑梯度不趋零不代表Lasso失败；KKT、近端映射与目标差各有自己的含义。

17 坐标下降一次只解一个标量问题

固定其他坐标，定义不含第 j 项的部分响应 $r_i^{(-j)} = y_i - \sum_{k \neq j} x_{ik} \theta_k$ 。注意它的符号与前文残差 $X\theta - y$ 相反，不能混用。令 $q_j = \sum_i x_{ij}^2/n$ 、 $c_j = \sum_i x_{ij} r_i^{(-j)}/n$ ，子问题是 $q_j u^2/2 - c_j u + \lambda|u|$ 加常数。

当 $q_j > 0$ ，配方或次梯度三分支给出 $u = S_\lambda(c_j)/q_j$ ，等价于 $S_{\lambda/q_j}(c_j/q_j)$ 。本讲顺序固定为 $j=0$ 后 $j=1$ （代码从0编号）；更新第二坐标时读第一坐标的新值。一次sweep指两个坐标都处理一遍。

若列全为0， $q_j=0$ ，则 $c_j=0$ 。 $\lambda > 0$ 时此坐标最优为0； $\lambda=0$ 时任意值都不影响目标，程序约定取0，不能声称唯一。非零但极小的列可能使除法产生大系数，运行时有数值范围停止而不是假装收敛。

主正交数据 c_j 不依赖另一坐标，所以从任意初值一次完整扫描就到 $(3/2, 0)$ 。这说明本例坐标下降特别简单，不能推出“坐标下降总比近端快”。两个算法的步数单位不同，若比较效率还需计算内积、扫描次数及实际实现成本。

18 相关设计揭示同步与顺序的差别

压力例明确把第二列替换为 $\tilde{X}_{:2} = \rho X_{:1} + (1 - \rho) X_{:2}$ ， $\rho = 7/8$ ，第一列、 y 不变。这是新的设计矩阵，全部四行会随报告单独保存。其Gram非对角元 ρ ，第二对角元 $\rho^2 + (1 - \rho)^2 = 25/32$ ；不再能用主例的闭式最优参数与 $33/32$ 目标值。

近端梯度从同一旧 θ 算两个梯度；循环坐标下降先改 θ_1 ，随后 θ_2 的部分响应就变了。将顺序改成 $[1,0]$ 一般改变中间轨迹。每个精确标量最小化不会增加当前Lasso目标，但“任意不光滑凸函数上的坐标下降都成功”是错误推广；可分离L1的结构在这里很重要。

压力例的近端学习率取 $\min(\text{用户}\eta, 1/L_{\text{stress}})$ ，并显式记录。若派生步长超出公共教学API允许范围，只跳过该压力例且记录原因，不让合法主实验因隐藏的内部范围限制而失败。所有图必须说明这次改了什么，不许把压力数据的曲线画成原数据的重复验证。




图7 左图是正交主设计，右图是明确变换的相关压力设计；坐标扫描和同步近端路径不同。

19 稀疏不是自动发现真实因果

L1通过最优化结构产生精确零。它没有证明被删掉的特征与现实结果无关，更没有证明留下的特征是原因。相关特征可能互相替代；缩放、 λ 和采样扰动也可能改变支持集。

把第一列乘 $c>0$ ，并将其系数记作 β ，使预测系数 $\theta_1=c\beta$ 。若仍惩罚 $\lambda|\beta|$ ，则原坐标等价惩罚 $(\lambda/c)|\theta_1|$ ，因此预测问题本身变了。保持同一个惩罚问题需要同步用 $\lambda c|\beta|$ 。标准化应只从训练数据估计，不能借测试集选择缩放或 λ 。

精确零计数是实现与结构诊断。若把所有 $|\theta_j|<10^{-6}$ 都称零，会掩盖次梯度方法的小幅振荡；本实验同时保留原参数与严格 $\theta_j=0$ 计数。支持集什么时候识别、识别后是否保持，需要条件，不能由两步手算断言全局有限时间识别。




图9 原正交设计的 λ 路径与特征尺度变化；不同坐标惩罚并不自动等价。

20 数值实验应怎样验收

至少检查五件事：每轮原数据前向与目标是否一致；零系数是否来自阈值分支；选择正确的最优性残差；实际停机状态是达到容差、预算耗尽还是算术范围停止；自定义数据时是否错误套用默认最优解。状态和每一步参数必须完整保存，不能只留最终曲线。

本实验固定80次最大更新、容差 10^{-10} 。近端和循环坐标下降都检查Lasso KKT；固定次梯度路径可能耗完预算仍不合格；投影路径检查投影映射与盒可行性。容差已满足时可以提前停止，完成步数由程序真实记录。坐标下降的一次扫描不等同一次向量梯度的成本，图只比较机制而非硬件速度。




图4 同一主数据上总目标与精确零计数；横轴坐标下降单位为整次扫描。

输入验证必须先于求解：拒绝布尔冒充数值、字符串隐式转换、NaN/Inf、形状错误、未知或缺失字段、JSON重复键、十进制非零下溢、坏CSV尾行。Notebook首格还验证默认CSV和JSON的SHA；这样合法但不同的数据也不能被固定图注悄悄冒用。自定义实验走CLI，报告完整新配置。




图8 固定步长次梯度的第二坐标反复跨过零点，KKT残差没有因此消失。

21 练习 从纸笔到研究阅读

1. 逐项核验 $X^T X/4$ 、 $X^T y/4$ 与 z 的正交关系，并展开 f 。
2. 从支撑不等式证明绝对值在零点的次微分恰是 $[-1, 1]$ 。
3. 写出 $\theta=(3/2, 0)$ 的光滑梯度与一个使总次梯度为零的L1次梯度。

4. 给出负合法次梯度反而增大目标的最短反例。
5. 证明盒投影的clip表达式，并说明不能用于一般单纯形。
6. 证明投影变分不等式的必要性与充分性。
7. 推导L1近端的三个分支，单独处理阈值相等和 $\lambda=0$ 。
8. 对 $\tau=1/4$ 计算 $z=(-3/4, -1/4, 1/8, 3/8)$ 的soft-threshold。
9. 不借闭式梯度，重建第一轮四行所有局部导数、分项和新前向。
10. 重建第二轮，指出哪一步产生精确零，并计算 J_2-J^* 。
11. 在 θ^1 处分别计算KKT向量与近端gradient mapping。
12. 证明近端映射的零点等价于复合最优性。
13. 从梯度Lipschitz条件证明下降引理，并得到近端下降式。
14. 用主数据 $\eta=3$ 重算一次目标上升反例。
15. 推导三点式与 $O(1/k)$ 目标界，列出所需假设。
16. 推导坐标下降的qj、cj、soft更新，并处理零列。
17. 在 $\rho=7/8$ 压力设计上算一轮两种坐标顺序，并与同步近端对比。
18. 计算盒问题前两步与最优点，解释非零梯度。
19. 证明第一列缩放后惩罚怎样变化；讨论稀疏与因果的区别。
20. 设计三个能骗过只看损失的错误，并用输入、轨迹和残差检查抓住它们。

22 一手来源与继续阅读

以下只用于核对定义、算法和适用条件；正文、手算、数据与图均独立编写。来源详细读取范围和核对日期在source-checks.json。公开材料不代表取得转载整篇文字或图片的许可。

- Parikh与Boyd, [Proximal Algorithms](#): 定义、最优性、近端梯度、L1与投影；本讲采用相同的一类算子记号并自行推导。
- Boyd与Vandenberghe, [Convex Optimization](#): 凸函数一阶条件、约束最优性和投影所需基础。
- Boyd与Park, [Subgradient Methods](#): 非下降性、步长条件及距离递推。
- Ryan Tibshirani, [Proximal Gradient Descent and Acceleration](#): 保留不光滑项的局部模型、gradient mapping与收敛分析。
- Ryan Tibshirani, [Coordinate Descent](#): 循环坐标法、Lasso标量更新及可分离性条件。
- Friedman、Hastie与Tibshirani, [Regularization Paths for Generalized Linear Models via Coordinate Descent](#): 实际循环坐标路径算法的原论文摘要与算法背景；本讲不复制其计时结论。
- [scikit-learn 1.8.0 Lasso官方文档](#): $1/(2n)$ 缩放、alpha、截距、迭代次数、循环选择与dual_gap。实际安装版本与真实输出另存library-result.json。