

第038讲 Newton与拟Newton方法

1 曲率信息值得花多少钱

前几讲主要用梯度及其历史选择方向。现在的问题是：若已经知道各方向的曲率，能否直接选一条更合适的步子？Newton方法在每个旧参数处建立局部二次模型；拟Newton方法则用相邻梯度的变化逐步学习一个曲率近似。

直接先修第011、015、032至033讲。本讲需要解线性方程、梯度、Hessian、Taylor近似、正定矩阵与下降条件。我们先从同一四行回归的线性模型出发，再明确把模型改为一个含平方参数的非线性版本；数据与残差定义不变。这样既能看见精确二次的一步性质，也能看见二次近似失效、Hessian不正定以及线搜索的必要性。

“迭代少”不是“花费少”。实验同时记录函数、梯度、Hessian与线搜索评估次数、实际墙钟时间、算法工作数组及测量限制。所有例子是小CPU合成任务，不宣称Newton在一般机器学习中更快。




图1 梯度方向、Newton局部二次方向与实际接受的线搜索位移分开显示。

2 从二次模型推导Newton方程

在旧点 $\theta \in \mathbb{R}^d$ ，记 $g = \nabla F(\theta)$ 、 $H = \nabla^2 F(\theta)$ 。二次模型是

$$q(p) = F(\theta) + g^\top p + \frac{1}{2} p^\top H p.$$

若 H 对称正定，则 q 严格凸。对 p 求导并置零，得到 $g + Hp = 0$ ，即 $Hp = -g$ 。这是本讲的计算指令：解线性方程。写 $p = -H^{-1}g$ 可以帮助理解代数，但程序不先显式形成逆矩阵。

为什么正定很重要？当 $Hp = -g$ 且 $p \neq 0$ ，有 $g^\top p = -p^\top Hp < 0$ ，所以 p 是下降方向。这里只说明足够小的正步长可以下降，并不说明完整步 $\theta + p$ 一定下降。若 H 不正定，线性方程即便可解，也不代表解是二次模型的最小点。

3 同一四行数据上的线性基准

继续使用 $x = (-2, -2, 2, 2)$ 、 $y = (-3/2, -1/2, 5/2, 7/2)$ ，先取预测 $\hat{y}_i = a + bx_i$ ，残差 $r_i = \hat{y}_i - y_i$ ， $F = \sum_i r_i^2/8$ 。每行平均梯度贡献是 $(r_i/4, x_i r_i/4)$ ，Hessian贡献是

$$\frac{1}{4} \begin{pmatrix} 1 & x_i \\ x_i & x_i^2 \end{pmatrix}.$$

四行求和得 $F = 1/8 + (a-1)^2/2 + 2(b-1)^2$ ， $g = (a-1, 4(b-1))^\top$ ， $H = \text{diag}(1, 4)$ 。在 $(0, 0)$ ，四行残差为 $(3, 1, -5, -7)/2$ ， $F_0 = 21/8$ ， $g = (-1, -4)$ 。解 $Hp = -g$ 得到 $p = (1, 1)$ ，完整步到 $(1, 1)$ ；新预测为 $(-1, -1, 3, 3)$ ，新残差 $(1, -1, 1, -1)/2$ ，新目标 $1/8$ 。

这不是某种神奇的有限步普遍性质。此例的二次模型恰好就是原目标，因此其模型最小点等于原最小点。一般非线性目标只有局部近似，下一节便改变这一点。

Same four rows: form all OLD derivatives, then update together

row	x	y	old r	g_a row	g_b row	new pred	new r
S1	-2	-3/2	3/2	3/8	-3/4	-1	1/2
S2	-2	-1/2	1/2	1/8	-1/4	-1	-1/2
S3	2	5/2	-5/2	-5/8	-5/4	3	1/2
S4	2	7/2	-7/2	-7/8	-7/4	3	-1/2

`sum g = (-1, -4); sum H = diag(1, 4); solve H p = -g -> p = (1, 1)`

`theta = (0, 0) -> (1, 1); NEW F = 1/8; new gradient = 0, individual residuals are not.`

图2 线性四行回归中，逐行梯度/Hessian汇总后解方程，最后重新前向。

4 只改模型 显露真正的局部曲率

数据完全相同，但现在明确使用 $\hat{y}_i = a + b^2 x_i$ 。这是一个新的参数化问题，不是继续把 b 当作原线性斜率。真实斜率变成 b^2 ， $(a, b) = (1, 1)$ 和 $(1, -1)$ 给相同预测。

仍有单行损失 $\ell_i = r_i^2/2$ 。局部导数依次为 $\partial \ell_i / \partial r_i = r_i$ ， $\partial r_i / \partial \hat{y}_i = 1$ ， $\partial \hat{y}_i / \partial a = 1$ ， $\partial \hat{y}_i / \partial b = 2bx_i$ 。平均梯度为四行 $(r_i/4, 2bx_i r_i/4)$ 之和。

对梯度再求导时不能漏掉预测的二阶导数：

$$H = \frac{1}{4} \sum_i \left[\begin{pmatrix} 1 \\ 2bx_i \end{pmatrix} (1 \quad 2bx_i) + r_i \begin{pmatrix} 0 & 0 \\ 0 & 2x_i \end{pmatrix} \right].$$

第一项总是半正定，第二项却由残差及 x_i 决定符号。仅保留第一项是另一种近似，本讲不把它冒充完整Newton。独立展开得到

$$F = \frac{1}{8} + \frac{1}{2}(a-1)^2 + 2(b^2-1)^2, \quad g = \begin{pmatrix} a-1 \\ 8b(b^2-1) \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 24b^2-8 \end{pmatrix}.$$

5 第一轮非线性Newton逐行计算

取 $\theta_0 = (0, 3/2)$ 。预测 $(-9, -9, 9, 9)/2$ ，残差 $(-3, -4, 2, 1)$ 。单行损失分别 $9/2, 8, 2, 1/2$ ，平均为 $15/4$ 。此时预测对 b 的导数 $2bx$ 为 $(-6, -6, 6, 6)$ 。

截距梯度分项 $(-3, -4, 2, 1)/4$ 求和为 -1 ； b 梯度分项 $(18, 24, 12, 6)/4$ 求和为 15 。Hessian的aa项每行 $1/4$ ，总和 1 ；ab项相互抵消。bb项每行分别为 $(36+12)/4, (36+16)/4, (36+8)/4, (36+4)/4$ ，求和 46 。

于是 $H_0 = \text{diag}(1, 46)$ ，解方程得到 $p_0 = (1, -15/46)$ 。完整步新参数 $\theta_1 = (1, 27/23)$ 。重新前向：预测 $(-929, -929, 1987, 1987)/529$ ，残差 $(-271, -1329, 1329, 271)/1058$ 。单行平方再平均得到

$$F_1 = \frac{919841}{2238728} \approx 0.410876622797.$$

程序需要保留每行的残差、局部Jacobian、两部分Hessian贡献及求和；不能只打印一行总梯度。这里接受完整步的事实须用实际线搜索条件复核，不能根据结果看起来较小就跳过检查。




图3 非线性Hessian包含Jacobian外积与残差加权二阶导数两部分。

读图问题：图3中只画蓝色柱时，右侧会给出怎样错误的曲率判断？能否从每行橙色柱的符号追溯到残差和 x ？

6 第二轮必须重新计算Hessian

在 θ_1 ，新梯度为 $g_1 = (0, 43200/12167)$ ，新Hessian为 $\text{diag}(1, 13264/529)$ 。它已不是第一轮 $\text{diag}(1, 46)$ 。解 $H_1 p_1 = -g_1$ 得 $p_1 = (0, -2700/19067)$ ，故

$$\theta_2 = \left(1, \frac{19683}{19067}\right).$$

新预测分别为 $(-411290489, -411290489, 1138391467, 1138391467)/363550489$ ；残差为 $(268070489, -459030489, 459030489, -268070489)/727100978$ 。新目标为

$$F_2 = \frac{141285388452139121}{1057351664417112968}.$$

详解与Notebook需要列出四行新损失及梯度贡献，完整闭合“旧前向→梯度和Hessian→解方向→同步更新→新前向”。这些大分数不要求心算，但要求明白分母从哪一步产生。Fraction核验有理链，真实算法则使用实际存储浮点操作；二者不可混为逐位相同的轨迹。

7 方向与步长分工 线搜索检查什么

令 p 是满足 $g^\top p < 0$ 的方向。Armijo充分下降条件为

$$F(\theta + \alpha p) \leq F(\theta) + c_1 \alpha g^\top p, \quad 0 < c_1 < 1.$$

从 $\alpha = 1$ 试起，失败就乘 $\rho \in (0, 1)$ 。本讲默认 $c_1 = 10^{-4}$ 、 $\rho = 1/2$ ，设置最大尝试次数和最小可分辨步。由于可微性给 $F(\theta + \alpha p) = F(\theta) + \alpha g^\top p + o(\alpha)$ ，当 $g^\top p < 0$ 时，足够小的 α 能满足条件。这一存在说明不等于有限浮点循环必然成功。

记录每次试点、目标、右侧界和接受/拒绝理由。若试点越域、数值非有限、步长缩到无法改变参数或次数耗尽，报告失败并保留旧状态，不把最后尝试当作成功。只在接受后同时更新参数。




图4 实际目标曲线与Armijo直线决定接受步长；被拒绝的试点也保留。

读图问题：图4完整步虽已沿下降方向，为什么仍被拒绝？方向的局部结论与一次很长的有限位移有什么区别？

8 Hessian不正定时Newton可能向上走

仍用同一非线性模型，换初值 $(1, 1/4)$ 。此时 $F = 241/128$, $g = (0, -15/8)$, $H = \text{diag}(1, -13/2)$ 。原Newton解 $p = (0, -15/52)$ ，方向导数 $g^\top p = 225/416 > 0$ ，是上升方向。

完整步把 b 变为 $-1/26$ ，新目标 $242093/114244$ ，比旧目标更大。线性方程求解成功没有消除错误方向。更小正步在此点也首先向上，故不能指望只缩步长就自动救回任何不正定Newton方向。

在 $(1, 0)$ ，梯度恰为0但 b 曲率为 -8 ，它是驻点而非局部最小点。停止报告必须写清“梯度驻点”并给曲率信息，不能只看到梯度小就宣布找到最小值。

9 正定修正与缩步是两件事

一种清楚的修正是选择 $\lambda \geq 0$ ，令 $B = H + \lambda I$ 正定，再解 $Bp = -g$ 。它改变局部模型的二次项，不是把原训练目标永久加上同名正则化。之后仍对原 F 做线搜索。

在上一例，取 $\lambda = 8$ ，则 $B = \text{diag}(9, 3/2)$ ，修正方向 $p = (0, 5/4)$ 满足下降。完整步到 $b = 3/2$ 时 $F = 13/4$ ，仍不合格；半步到 $b = 7/8$ 时 $F = 481/2048$ ，满足默认Armijo。因此“修正方向”和“选择实际步长”缺一不可。

程序可按预声明的有限移位序列尝试Cholesky分解，直到正定且方向确实下降。失败不能偷偷改成未经说明的算法。实验保留原 H 、接受的 λ 、修正 B 、线性方程残差与最终 α ；这些量不能全叫作“阻尼系数”。




图5 原Newton上升、移位后的下降方向、再经回溯接受的半步形成三个不同对象。

10 局部二次收敛需要哪些假设

设 θ^* 为驻点，且在包含线段的邻域内 $H(\theta) \succeq mI$, $m > 0$, Hessian满足Lipschitz条件
 $\|H(u) - H(v)\| \leq L_H \|u - v\|$ 。记 $e = \theta - \theta^*$ 。梯度的积分表达是 $g(\theta) = \int_0^1 H(\theta^* + te) e dt$ 。

对完整Newton步，利用 $H(\theta)p = -g(\theta)$ ，得到

$$e^+ = H(\theta)^{-1} \int_0^1 [H(\theta) - H(\theta^* + te)] e dt.$$

由逆算子范数 $\leq 1/m$ 及Hessian Lipschitz条件，

$$\|e^+\| \leq \frac{L_H}{2m} \|e\|^2.$$

还必须把初值选得足够近，使新点留在该邻域。这个推导针对未被移位且接受 $\alpha=1$ 的局部阶段；不能直接套到任意初值、非正定Hessian或始终固定半步的路径。回溯算法最终接受完整步，需要相应邻域和参数条件，本讲不由一张曲线推断一般全局结论。

11 Newton减量与线性方程残差

正定时定义 $\nu^2 = -g^\top p = p^\top H p$ 。二次模型从 $p = 0$ 到最优 p 的预测下降是 $\nu^2/2$ 。它对精确二次目标等于当前目标差；一般非二次时只是模型量，不能无条件当真实误差的严格上界。

实际计算还应记录 $\|Hp + g\|$ ，并用 $\|H\|\|p\| + \|g\|$ 作尺度化参照；分母全零时单独定义。小线性方程残差不等于小参数误差，病态线性系统的敏感性在第011讲已经出现。使用solve避免显式求逆，也不能消灭浮点病态。

局部阶段可记录 $\|e_{k+1}\|/\|e_k\|^2$ 观察二次关系。 e 需已知真解，只能用于合成诊断；达到舍入极限后比值可能不稳定或无定义，要显示状态而非补画理想曲线。




图6 局部误差的平方关系与实际舍入终止分开呈现，不把一条直线当证明。

读图问题：图6最后一个存储点恰等于(1,1)，为什么没有把它补画成极小正数？误差平方比的有限稳定值能替代上一节证明吗？

12 为什么拟Newton只看梯度差也有信息

Newton每步可能需要构造并分解一个 $d \times d$ 矩阵。拟Newton不逐次计算完整Hessian，而用已经接受的位移 $s_k = \theta_{k+1} - \theta_k$ 及梯度差 $y_k = g_{k+1} - g_k$ 来约束近似矩阵。

若局部梯度变化近似线性，则 $y_k \approx H s_k$ 。因此希望新Hessian近似 B_{k+1} 满足割线方程 $B_{k+1} s_k = y_k$ 。只有一个方向上的约束，不能唯一确定整个矩阵，还需对称性、保留已有信息和正定性等原则。

本讲用C表示逆Hessian近似，避免把真Hessian H与近似混名；对应割线方程是 $C_{k+1} y_k = s_k$ 。 y_k 中的y是梯度差向量，和数据标签 y_i 处于不同索引语境，阅读代码时要明确区分。

13 BFGS更新及割线核验

给定正定对称C及 $s^\top y > 0$ ，令 $\tau = 1/(y^\top s)$ 。BFGS逆形式为

$$C^+ = (I - \tau s y^\top) C (I - \tau y s^\top) + \tau s s^\top.$$

把右边乘y： $(I - \tau y s^\top) y = 0$ ，而 $\tau s s^\top y = s$ ，因此 $C^+ y = s$ 。两个转置因子也保证对称性。这是可直接检查的代数性质，不要求相信一个黑箱优化器。

用线性模型的小例子： $\theta_0=(0,0)$ ， $g_0=(-1,-4)$ ， $C_0=I$ ， $p_0=(1,4)$ 。默认Armijo拒绝 $\alpha=1$ 而接受 $\alpha=1/2$ ，得到 $\theta_1=(1/2,2)$ ， $g_1=(-1/2,4)$ 。所以 $s=(1/2,2)$ ，梯度差 $y=(1/2,8)$ ， $y^\top s = 65/4$ 。精确更新给

$$C_1 = \frac{1}{4225} \begin{pmatrix} 4417 & -12 \\ -12 & 1057 \end{pmatrix}, \quad C_1 y = s.$$

这个 C_1 尚不是 $H^{-1}=\text{diag}(1,1/4)$ ，但已吸收实际走过的方向信息。不能因为满足一次割线方程就声称恢复了全Hessian。




图7 两点的位移与梯度差约束曲率，BFGS更新同时保留对称性和正定条件。

14 BFGS为什么能保持正定

令 $A = I - \tau y s^\top$ 。对任意非零 z ，有

$$z^\top C^+ z = (Az)^\top C(Az) + \tau (s^\top z)^2.$$

两项非负。若和为0，第二项迫使 $s^\top z = 0$ ；这又使 $Az = z$ ，第一项便是 $z^\top C z > 0$ ，矛盾。因此 C^+ 正定。证明需要 C 正定且 $\tau > 0$ ，也就是 $y^\top s > 0$ 。

有限精度中，极小正曲率可能导致巨大 τ ，误差被放大。工程策略可在预声明尺度阈值下跳过更新，或使用明确推导的阻尼修改。本讲从零版本采用显式skip策略，记录为什么跳过；库的damp_update是另一约定，不能只改一个字符串还声称逐步等价。

15 Armijo不自动保证BFGS曲率

仅要求目标下降不够保证 $y^\top s > 0$ 。弱Wolfe曲率条件写成

$$g(\theta + \alpha p)^\top p \geq c_2 g(\theta)^\top p, \quad 0 < c_1 < c_2 < 1.$$

右侧仍是负数，不能误加绝对值变成正数。于是 $y^\top s = \alpha(g_{\text{new}} - g_{\text{old}})^\top p \geq \alpha(c_2 - 1)g_{\text{old}}^\top p > 0$ 。强Wolfe另要求 $|g_{\text{new}}^\top p| \leq c_2 |g_{\text{old}}^\top p|$ ，它蕴含所需弱条件。

从零Armijo+skip的教学BFGS与使用Wolfe搜索的库BFGS可有不同逐步轨迹，这不一定是错误。对照应分别检查各自明确接受的条件、最终驻点残差与失败状态，不要求两个未对齐线搜索的轨迹逐位相同。


16 L-BFGS用短历史计算乘积

完整C需要 d^2 个数。L-BFGS只保存最近m对(s,y)，每对长度d，并以简单基矩阵 $C_{0,k} = \gamma_k I$ 开始，隐式应用这些更新。常见 $\gamma_k = (s^\top y)/(y^\top y)$ 必须建立在正曲率、非零分母与有限数值上；无有效历史时用预声明的正标量。

对当前g，先令 $q=g$ 。按历史从新到旧计算 $\alpha_i = \tau_i s_i^\top q$ 、 $q \leftarrow q - \alpha_i y_i$ ；再令 $r = \gamma_k q$ 。按历史从旧到新计算 $\beta_i = \tau_i y_i^\top r$ 、 $r \leftarrow r + s_i(\alpha_i - \beta_i)$ ，返回方向 $-r$ 。

这两个循环的顺序和符号都重要。保留窗口的最旧索引是 $\max(0, k-m)$ ，不是min。验算方法是在小维度从同一个 γI 显式重建同一窗口对应的C，再比较Cg与双循环返回量。改变窗口或 γ 后，不能拿全历史、不同初始化的BFGS矩阵当逐位参照。

L-BFGS: match the same window AND the same gamma



Reference: rebuild inverse BFGS from gamma I using exactly these retained pairs.

图8 双循环从新到旧剥离历史，再从旧到新重建乘积；只保存有限对向量。

17 理论存储、工作数组与实测内存

无结构稠密Newton通常需存H的 $O(d^2)$ 数，并为分解付出 $O(d^3)$ 工作；H的构造成本还取决于模型与样本量。完整BFGS更新和矩阵向量乘法通常为 $O(d^2)$ 。L-BFGS保存m对向量，存储及双循环工作为 $O(md)$ ；这没有计入原模型和数据本身。

实验分别报告算法状态数组的nbytes、临时数组的明确估算，以及单独测量运行中的内存观察。

Python的tracemalloc主要跟踪Python分配，不能无条件当作全部原生BLAS工作空间或进程峰值。

进程RSS还受解释器、库加载及分配器影响，也不能等同算法公式的字节数。

本教学BFGS为直观保留 $V^T C V$ 稠密乘法，并每次Cholesky检验正定；这些额外 $O(d^3)$ 操作都进入实测时间。它不是优化过的 $O(d^2)$ 秩二更新实现，不能把本次BFGS时长当成这类方法的最佳性能。不要用2维图里的几百字节差异外推出大模型结论。维度扩展实验使用另行标注的合成线性设计，统一目标、数据、初始化与停止标准；构建数据和计时预热是否计入必须写明。

18 如何进行诚实的墙钟比较

采用高分辨率单调计时器perf_counter，先预热，再多次重复并轮换方法顺序。记录所有原始时间、单位、重复数和汇总，不只挑最快的一次。计时与详细逐行trace分开运行，以免输出格式化淹没数值工作的差异。

同一停止阈值必须说明作用对象与尺度，例如梯度范数相对初值的阈值；并设统一最大工作限制。对于未达到阈值的方法，标明截断，不能将其较短用时记为成功速度。函数、梯度、Hessian、求解、线搜索各有成本；不把全部折成一个未定义的“迭代次数”。

二次回归的Hessian可预计算，研究者应分别报告一次性构造/分解与迭代开销，不暗中只对某方法提供缓存。在严格二次问题上直接最小二乘求解也是合理基准，本讲比较优化机制不代表排除了这种专用路线。实测时间受本机负载与BLAS影响，不要求跨进程字节相同。




图9 迭代、函数/导数评估、时间与内存是互补横轴，失败方法单独标识。

实际维度实验另造满秩线性设计，不与四行主数据混同： $d=8, 32, 64$ ， $n=2d$ ，固定seed3817，H谱由1到20。共同目标是梯度二范数不超过初始值的 10^{-6} ，预算2000更新。每法预热一次、五轮轮换顺序；本次60条计时记录全部达到目标，Newton均为一步，GD分别85、81、77步。后者为严格二次控制的结果，包含验证/正定检验/求解开销，不代表一般非线性任务的速度。全部原始纳秒值与范围保留在benchmark-result.json，重新运行允许改变。

读图问题：图9在 $d=8$ 时，L-BFGS保留数组为什么反而比BFGS更多？哪种读数能回答原生BLAS工作空间大小？若没有测量，应怎样如实回答？


19 从推导到代码的完整验收

纸笔层独立核对两轮非线性前向、Jacobian和Hessian每行贡献，以及不正定上升、 $\lambda=8$ 修正和半步接受。算法层检查每次 $g^T p$ 、方程残差、所有回溯试点、割线残差、对称性、正定性、跳过原因及有限内存窗口。

数值层用Fraction/高精度参照和独立方向差分，不把同一函数调用两次当独立核验。真实SciPy1.17.0对照明确区分minimize(method='BFGS')、BFGS更新策略类与L-BFGS-B；后者含边界处理，不等同任意自写无约束L-BFGS，即使本次没有设置边界。

工程层完整验证数据、配置、初始矩阵与历史，必须在任何回调/线性代数/输出前拒绝坏尾字段。首格校验默认输入字节，普通与-O、新进程和真实新内核的确定性报告一致；实际计时结果另存并明确不可逐字节复现。逐页PDF及每张真实图都检查，再交独立审阅。

Four independent questions before trusting the result



A small loss alone does not answer all four questions.

图10 科学链、线搜索与状态不变量、计时边界及文件保护分别提供证据。

20 自测题

1. 从二次模型推导 $H_p = -g$ ，并证明正定时方向下降。
2. 为什么代码使用线性方程求解而不先求逆？什么误差问题仍未消失？
3. 完整手算线性四行模型的Newton一步与新前向。
4. 对平方参数模型推导逐行梯度及Hessian的两项分解。
5. 从(0,3/2)完整重算第一轮四行、梯度、Hessian、方向与新目标。
6. 完整重算第二轮，解释为何不能沿用第一轮Hessian。
7. 推导Armijo小步存在的理由，并列出发点搜索可能失败的情况。
8. 在(1,1/4)验证原Newton是上升方向，并计算新目标。
9. 验证 $\lambda=8$ 修正、完整步拒绝、半步接受，区别 λ 与 α 。
10. 解释驻点(1,0)为什么不是局部最小点。
11. 在列明邻域条件下推导局部二次误差界。
12. 推出Newton减量与二次模型预测下降，说明非二次限制。
13. 从梯度差解释割线方程，并计算正文 C_1 与 C_{1y} 。

14. 完整证明BFGS逆更新的对称性、割线条件和正定性。
15. 用Wolfe条件推出正曲率，并说明Armijo为何不够。
16. 手动展开一对与两对历史的L-BFGS双循环，核对循环顺序。
17. 比较完整BFGS、有限窗口重建和不同 γ 初始化，指出何时可比较。
18. 设计含预热、轮换、原始时间和失败标记的GD/Newton计时实验。
19. 分开理论数组存储、Python跟踪内存和进程内存；解释各自遗漏。
20. 列出全部算法与文件保护不变量，设计坏尾字段、坏历史与旧输出保护试验。

来源与核查范围

- [Boyd与Vandenberghe无约束优化讲义](#)：查核Newton方向、回溯、局部假设及求解实现，不复制图例或其全局常数结论。
- [CMU拟Newton课程讲义](#)：查核割线/BFGS与有限记忆思想；其中Wolfe符号及历史窗口下标不能照抄，本讲按独立代数与官方接口校正。
- [Nocedal官方L-BFGS页面](#)：核对算法出处与原始文献入口；未下载或复用其代码。
- [SciPy1.17线搜索、BFGS求解器、BFGS策略类与L-BFGS-B](#)：核对具体接口、停止条件与失败返回。
- [NumPy2.3 solve](#)：核对方程求解而非显式求逆。
- [Python3.12计时与内存跟踪](#)：核对计时/内存测量各自含义。实际运行版本单独记录。