

第039讲 练习详解

以下解答对应讲义的16题。核心验收是可复算的因果链：逐行值决定梯度，梯度与步长决定候选，候选的新前向决定是否接受；数值检查必须针对明确的目标。小数仅用于阅读，能用精确分数时优先保留分数。

1 两轮完整更新

初值 $(b, w) = (0, 0)$ 。逐行预测为 $(0, 0, 0, 0)$ ，残差为 $(0, 0, -1, -1)$ 。半平方为 $(0, 0, 1/2, 1/2)$ ，平均目标中的逐行贡献为 $(0, 0, 1/8, 1/8)$ 。局部导数 $\partial \ell_i / \partial r_i$ 等于对应残差， $\partial r_i / \partial p_i = 1$ ，预测对参数导数依次为 $[1, -1], [1, 0], [1, 1], [1, 2]$ 。

四行的平均梯度贡献为 $(0, 0), (0, 0), (-1/4, -1/4), (-1/4, -1/2)$ 。所以 $F_0 = 1/4$ ， $g_0 = (-1/2, -3/4)$ 。同步减去一半梯度，得到 $\theta^{(1)} = (1/4, 3/8)$ 。

新的预测依次为 $(-1/8, 1/4, 5/8, 1)$ ，残差为 $(-1/8, 1/4, -3/8, 0)$ 。半平方为 $(1/128, 1/32, 9/128, 0)$ ；再除4为 $(1/512, 1/128, 9/512, 0)$ 。新的平均梯度贡献依次为 $(-1/32, 1/32), (1/16, 0), (-3/32, -3/32), (0, 0)$ 。其和为 $(-1/16, -1/16)$ ，目标为 $7/256$ 。

第二轮更新量为 $(1/32, 1/32)$ ，所以 $\theta^{(2)} = (9/32, 13/32)$ 。再次计算预测得到 $(-1/8, 9/32, 11/16, 35/32)$ ；残差为 $(-1/8, 9/32, -5/16, 3/32)$ ；半平方为 $(1/128, 81/2048, 25/512, 9/2048)$ 。平均损失贡献为 $(1/512, 81/8192, 25/2048, 9/8192)$ 。

第三张前向表的梯度贡献为 $(-1/32, 1/32), (9/128, 0), (-5/64, -5/64), (3/128, 3/64)$ 。截距分量之和为 $-1/64$ ；斜率分量为 $(2 - 5 + 3)/64 = 0$ ；目标为 $(16 + 81 + 100 + 9)/8192 = 103/4096$ 。斜率这一时刻为零不代表整个参数向量达到驻点。

2 改变归一化

原目标为 $F = (1/2n) \sum r_i^2$ ，新目标为 $J = \sum r_i^2 = 2nF = 8F$ 。因此 $\nabla J = 8\nabla F$ 。若要保持逐步更新完全相同，需要 $\eta_J = \eta_F/8 = 1/16$ ，而不是只除以样本数。

这个结论假设其余更新规则相同且没有另加正则项。若只缩放数据项而没有缩放正则项，就改变了两者相对权重，不能靠单个学习率恢复原任务。

3 广播目标与错误最优点

错误目标为 $\tilde{F} = (1/2n^2) \sum_{i,j} (p_i - y_j)^2$ 。对参数求导， j 方向求和给出 $\sum_j (p_i - y_j) = n(p_i - \bar{y})$ ，故

$$\nabla \tilde{F} = \frac{1}{n} \sum_i (p_i - \bar{y}) [1, x_i]^\top.$$

在这里 $\bar{y} = 1/2$ 。取 $b = 1/2, w = 0$ 使每个预测都等于 $1/2$ ，梯度为零；设计矩阵两列线性独立，所以它是唯一二次最优点。四个标签绕其均值的平方和为1，每行平均平方为 $1/8$ ，因此错误最小值为 $1/8$ 。

原配对目标的正规方程可直接写成

$$b + \frac{1}{2}w = \frac{1}{2}, \quad \frac{1}{2}b + \frac{3}{2}w = \frac{3}{4}.$$

第一式给 $b = 1/2 - w/2$ ，代入第二式得 $w = 2/5, b = 3/10$ 。残差为 $(-1/10, 3/10, -3/10, 1/10)$ ，目标为 $1/40$ 。初始所有预测都是零时，每个标签被重复同样次数；错误平均与正确平均都等于 $1/4$ ，因此这一点的损失相等没有鉴别力。

4 四种梯度检查

固定点为 $(0.2, -0.3)$ 。预测为 $(0.5, 0.2, -0.1, -0.4)$ ，配对残差为 $(0.5, 0.2, -1.1, -1.4)$ 。平均残差为 -0.45 ；斜率梯度为 $(-0.5 + 0 - 1.1 - 2.8)/4 = -1.1$ 。

广播梯度把标签换成均值 $1/2$ ，残差为 $(0, -0.3, -0.6, -0.9)$ 。截距梯度仍为 -0.45 ，斜率梯度为 $(0 + 0 - 0.6 - 1.8)/4 = -0.6$ 。

在 $h = 10^{-5}$ ，正确梯度与原目标中央差分的归一化差异约为 2.09×10^{-12} ；反号梯度与原目标的差异约为2；广播梯度相对原目标约为0.421；广播梯度相对自身函数约为 1.93×10^{-12} 。这四项共同说明有限差分验证的是“函数与导数是否相配”，不是“函数是否代表研究任务”。最后一项不能作为广播版正确的结论。

5 误差阶与步长

令 $\varphi(s) = F(\theta + se_j)$ 。Taylor 展开为

$\varphi(\pm h) = \varphi(0) \pm h\varphi'(0) + h^2\varphi''(0)/2 \pm h^3\varphi'''(0)/6 + \dots$ 。正负相减再除以 $2h$ ，常数项和偶次项消失，得到 $\varphi'(0) + h^2\varphi'''(0)/6 + \dots$ 。

有界三阶导数给出 $O(h^2)$ 截断误差；若要明确写下下一项为 $O(h^4)$ ，需要足够的更高阶光滑性。平方目标沿坐标最多二次，所以三阶导数为零，在精确算术中中央差分对任意非零 h 都精确。

浮点算式不是精确算术。函数值误差相减后再除以 h ，常呈 $O(\epsilon/h)$ 量级，与截断项形成取舍。对光滑非二次例子扫描多个 h ，观察稳定低误差区间；也记录实际扰动是否可表示。不能把一个特殊二次例子的无截断误差推广到神经网络。

6 绝对值的边界

在零点中央商是 $(|h| - |-h|)/(2h) = 0$ 。左侧差分是 $(|0| - |-h|)/h = -1$ ，右侧差分是 $(|h| - |0|)/h = 1$ 。左右不同，普通导数不存在。子梯度集合是 $[-1, 1]$ ，包含0，但“0是合法子梯度”是另一条数学陈述。

在 $u = 10^{-6} > 0$ ，普通导数为1。然而使用 $h = 10^{-4}$ 会跨过零点，中央商为

$$\frac{|0.000101| - |-0.000099|}{0.0002} = 0.01.$$

它与1差很远，不证明正半轴导数实现错误；扰动路径跨越了不光滑点。可在这个点选择足够小且可表示的 h 使两侧均为正，或明确作分支/单侧检查。若 h 过小又会进入舍入误差区间，两种限制都要考虑。

7 稳定公式之后还可能相消

实数算术下 $\text{softplus}(40) = 40 + \log(1 + e^{-40})$ ，尾项约 $4.2483542553 \times 10^{-18}$ 。在40附近，binary64相邻浮点数间距远大于这个尾项，结果可能舍入为40。于是稳定算出的softplus再减40仍为零。

$\text{softplus}(-40) = \log(1 + e^{-40})$ 直接保留小量，用 $\log1p$ 计算得到可表示的正数。对于二元标签1，应采用这个带符号形式。这里的零是可避免的消减，不是最小浮点数范围造成的下溢。到-1000时，实数尾项约 5.08×10^{-435} ，才真正小于float64最小正数。

8 极端错误预测仍应得到有限损失

同一四行、参数 $(0, -1000)$ 给出 $z = (1000, 0, -1000, -2000)$ 。符号 $1 - 2y$ 为 $(1, 1, -1, -1)$ ，因此 $t = (1000, 0, 1000, 2000)$ 。稳定每行损失近似为 $(1000, \log 2, 1000, 2000)$ ，平均为 $1000 + \log 2/4 \approx 1000.17328679514$ 。

局部导数 $\partial \ell / \partial z$ 近似为 $(1, 1/2, -1, -1)$ 。四行平均梯度贡献依次为 $(1/4, -1/4), (1/8, 0), (-1/4, -1/4), (-1/4, -1/2)$ ；总梯度为 $(-1/8, -1)$ 。这些值保持有限。

极小指数尾项在float64中舍入为零，使局部导数显示为精确的 ± 1 ，但这不破坏这里可表示的大损失。先求概率再取对数会把概率舍入到0或1，产生无穷，或者在零系数乘无穷时产生NaN。用 `nanmean` 跳过这些行会删除最重要的错例，不能作为修复。

9 log sum exp 的移位和轴

最大值为1001，移位向量为 $(-1, 0, -2)$ ，指数和为 $e^{-1} + 1 + e^{-2} \approx 1.5032147244$ 。最终结果为 $1001 + \log(1.5032147244) \approx 1001.4076059644$ 。

若把每行的两个项 $[0, t_i]$ 存成 $(n, 2)$ 矩阵，`axis=1` 消去“两个候选指数项”这一轴，保留样本轴，输出 $(n,)$ 。`keepdims=True` 则输出 $(n, 1)$ ，可用于后续明确广播。`axis=None` 会同时消去样本轴，变成所有行共同的log-sum-exp，数学对象已经改变。

若所有 $a_j = -\infty$ ，用 $M = -\infty$ 直接相减会产生未定义项；需要专门规则。本讲推导假定有限实数。若包含负权重，log内部可能不是正数，也需要额外符号语义，不能套用简单指数和解释。

10 用哪些诊断量区分原因

最低限度需要：预定目标与残差形状；相对预定目标的梯度检查； $\|g\|$ ；实际更新 $\Delta\theta$ 和其范数； $g^\top \Delta\theta$ ；新前向损失；有限性和停止原因。每项负责不同判断。

极小步长中，梯度检查通过、梯度仍大、相对更新很小。符号错中，检查失败且方向导数为正。大步长中，梯度检查通过、方向导数为负，但候选损失上升。广播错中，形状与行配对不对；对错误函数自身的检查可能通过，对预定函数的检查失败。

只有损失曲线无法区分这些情况。参数与数据也可能同时存在多个错误，实际调试要从最早发生的不一致开始修，修后重新跑完整回归，而不是看到某个典型信号就停止搜索。

11 成本不能用成功更新数代替

符号路径初始前向一次，错误候选的新前向一次，共2次目标与梯度例程调用、8个预测行、8个配对损失元素。尝试1步，提交0步；算成 $0 \times 4 = 0$ 会丢失全部已发生工作。

广播路径每次4个预测、16个交叉配对损失元素。30次提交加初始前向共31次调用，因此预测行数为124，损失元素数496。正确路径25次提交加初始前向共26次调用，预测行与损失元素均为104。

一次两参数中央差分共4次目标调用。本教学前向同时形成梯度账本，所以也计4次梯度例程；高效实现可只算函数值，但需据实记录。差分扫描、稳定性检查、最终按原目标重评的工作各自单列，不应隐藏在“训练花了25步”之后。

12 拒绝路径的通过条件

先将合法输入复制到临时目录，只破坏最后字段：例如标签 1e-999、NaN、布尔压力参数或多余列。预期入口抛出明确异常；回调、随机生成、线性代数或目标求值都不能已开始；标准输出为空，目标报告文件不存在。正常模式和 -o 均应如此。

重复JSON键应在解析时拒绝，不能让“后出现的值覆盖先出现的值”成为隐性配置规则。非标准NaN和Infinity也应拒绝。数字token 1e-999 要先用十进制语义识别其非零，再判断float64转换结果，不能转换成0后当作合法零。

Notebook完整性测试应对每个契约文件分别追加一个字节，启动新真实内核只运行第一格，确认抛出摘要错误且没有数值/图形输出；然后恢复原字节。只检查源码里存在hash字符串，不算完成篡改测试。摘要契约说明一致性而非授权或数据质量。

13 方向导数检查的收益和盲区

选择固定非零方向 v ，可先归一化，再比较 $g^T v$ 与 $[F(\theta + hv) - F(\theta - hv)]/(2h)$ 。无论参数维数多大，只需两次函数求值；逐坐标则需2d次。

盲区在于误差向量可能与 v 正交。若错误只发生在另一个方向，一次方向检查会碰巧通过；零梯度或特殊对称点也容易隐藏错误。应使用多个独立方向与参数点，重要模块还应逐坐标核对。随机方向必须固定种子并记录，否则很难复现失败。

14 三种停止理由

梯度小只说明当前所测目标的一阶驻点残差小。对本正定二次目标可进一步联系唯一最优点；一般非凸函数不能据此排除鞍点。梯度属于错误目标时，其小也无助于原任务。

步长小可能来自梯度小，也可能来自人为小学习率、饱和、数值量化或受限更新。要同时看实际参数差、梯度与目标变化。损失变化小也可能是数值分辨率不足或走到了平坦方向。

预算耗尽只说明达到资源上限。正确报告剩余梯度、目标与最后状态，让读者决定继续、换诊断或终止研究；不能把这个状态改名为“收敛”。默认审计的成功标签用于特定默认配置，自定义配置不一定出现相同终态。

15 一页故障报告示例

问题：原配对平方目标要求每个预测与同一行标签比较，但实现把预测改成列向量后减一维标签。环境为Python 3.12.14、NumPy 2.3.5，使用原始四行数据、初值零和学习率1/2。

证据：残差形状实际为 $(4, 4)$ ，不是 $(4,)$ ；初始损失虽仍为1/4，梯度斜率分量却从 $-3/4$ 变为 $-1/4$ ；第一步到 $(1/4, 1/8)$ 。在 $(0.2, -0.3)$ 、 h 为 10^{-5} 的检查中，对自身错误目标的归一化差异约 1.93×10^{-12} ，对预定配对目标则约0.421。路径最终接近 $(1/2, 0)$ ，而独立正规方程给出正确最优点 $(3/10, 2/5)$ 。

解释：广播引入所有预测与所有标签的交叉配对，消除了特征与标签的关联。这不是学习率问题，也不是NumPy偏离文档；它是使用者写错了目标。

修复：保持 prediction 与 y 都为一维，并在归约前要求残差形状严格等于 $(n,)$ 。恢复逐行贡献，核对两轮Fraction账本；在多个非特殊点扫描差分；再比较正确路径终点与正规方程。复测时保留原数据摘要和故障报告，不覆盖掉失败证据。

边界：该小数据只证明这些路径与检查点的行为，不代表任意形状或生产模型已无缺陷。修复后仍需大规模任务的输入检查、状态恢复、性能与泛化验证。

16 选做 优化器状态

带动量的参数更新取决于当前梯度和历史速度；Adam还依赖一阶、二阶累积量与时间索引。只恢复参数会把这些历史量重置，使下一次更新不同。即使数据和随机种子相同，也通常不能接上原来的训练轨迹。

应保存并恢复参数、全部优化器状态、学习率计划位置、必要的随机状态和数据游标；核对库的更新约定、dtype与版本。用一次保存前后的同一批数据比较全部状态和下一步更新，构造可复算的续跑测试。仅比较最终损失接近，无法证明状态恢复正确。本题依赖第035至036讲，此单元没有把未实测的优化器状态等价性列为完成项。