

第040讲 练习详解

以下始终使用讲义的四行共线设计。半平方损失已除以 $n=4$ ；手算无额外截距或标准化。所有分数由独立Fraction运算重算，不能把后面的340行选择实验混入手算。

1 形状、三个目标与截距

$X \in \mathbb{R}^{n \times d}$, $y, r, \text{预测} \in \mathbb{R}^n$, $\beta \in \mathbb{R}^d$. $F = r^T r / (2n)$. Ridge加 $\lambda \beta^T \beta / 2$; Lasso加 $\lambda \sum |\beta_j|$; Elastic Net加 $\lambda \rho \sum |\beta_j| + \lambda(1-\rho) \beta^T \beta / 2$. $\lambda \geq 0$, $\rho \in [0, 1]$.

有截距 a 时 $r = a1 + X\beta - y$; $\partial F / \partial a = \Sigma r_i / n = 0$, 故 $a = \bar{y} - \mu^T \beta$. 这个推导解释了为什么先用训练均值中心化就能单独求斜率；未惩罚的 a 不可当普通常数列与 β 一起收缩。验证预测仍使用训练 μ 与 $\bar{y}$ 。

2 从四行求H、c与OLS

两个平方列和分别为 4 与 $1+9/16+9/16+1=25/8$ ；交叉和为 $1+3/4+3/4+1=7/2$ 。除4后

$$H = \begin{pmatrix} 1 & 7/8 \\ 7/8 & 25/32 \end{pmatrix}, \quad \det H = 25/32 - 49/64 = 1/64.$$

第一列乘标签和为 $(7+9+5+11)/4=8$ ；第二列乘标签和为 $7/4+27/16+15/16+11/4=57/8$ ，故 $c=(2, 57/32)$ 。联立 $\beta_1+7\beta_2/8=2$ 与 $7\beta_1/8+25\beta_2/32=57/32$ ，从第二式减 $7/8$ 倍第一式得 $\beta_2/64=1/32$ ，所以 $\beta_2=2$ 、 $\beta_1=1/4$ 。

预测为 $(-9, -7, 7, 9)/4$ ，残差为 $(-1/2, 1/2, 1/2, -1/2)$ ，平方和1， $F=1/8$ 。残差不为零不代表没有解，它已正交于两列设计。

3 Ridge方程和唯一性

逐行链式法则给 $\partial F / \partial \beta_j = \Sigma r_i x_{ij} / n$ ，因此 $\nabla J = (H + \lambda I) \beta - c$ 。令梯度为零得到线性系统。

对 $v \neq 0$ ， $v^T (H + \lambda I) v = \|Xv\|^2 / n + \lambda \|v\|^2$ 。当 $\lambda > 0$ 时第二项严格正，故 $H + \lambda I$ 正定，目标严格凸且向无穷增长，有且只有一个最小点。 $\lambda = 0$ 且 X 秩亏时此证明失去严格正性；需要说明使用最小范数OLS约定，不能直接逆奇异矩阵。

4 $\lambda=1/4$ 的两元消元

系统为 $5\beta_1/4 + 7\beta_2/8 = 2$ 与 $7\beta_1/8 + 33\beta_2/32 = 57/32$ 。其行列式为 $(5/4)(33/32) - (7/8)^2 = (165 - 98) / 128 = 67/128$ 。

第一坐标分子为 $2 \times 33/32 - (7/8)(57/32) = 129/256$ ；第二坐标分子为 $(5/4)(57/32) - (7/8)^2 = 61/128$ 。分别除行列式得到 $\beta_1 = 129/134$ 、 $\beta_2 = 61/67$ 。将值代回两个方程是比“数值看着差不多”更可靠的核验。

增广系统堆叠 $X/\sqrt{4}$ 和 $\sqrt{(1/4)I}$ ；增广标签堆叠 $y/\sqrt{4}$ 和0。其法方程恰是上述系统。程序以solve、增广lstsq和真实Ridge三路核验，不形成显式逆。

5 SVD谱收缩与原坐标增大

在 $X=U\Sigma V^T$ 中令 $a=V^T\beta$ ，则每个可识别谱坐标的目标包含 $(\sigma_j a_j - u_j^T y)^2 / (2n) + \lambda a_j^2 / 2$ 。求导得到 $(\sigma_j^2 + n\lambda) a_j = \sigma_j u_j^T y$ 。

因此相对OLS的比例是 $\sigma_j^2 / (\sigma_j^2 + n\lambda)$ 。 σ_j 越小，固定 λ 下比例越小。回原坐标 $\beta = Va$ 是不同方向重新组合；它不保持每个 β_j 的绝对值排序。本例第一坐标由0.25变成约0.962687就反驳了逐坐标缩小说法。秩亏处 $\lambda > 0$ 的零奇异方向取零； $\lambda = 0$ 最小范数解要另设约定。

6 第一轮：逐样本完整链

$\beta^0 = (0, 0)$ ，所以每行预测0。对单行半平方 $\ell_i = r_i^2 / 2$ ， $\partial \ell_i / \partial r_i = r_i$ ， $\partial r_i / \partial \beta = x_i$ 。平均后梯度贡献为 $r_i x_i / 4$ 。

行	预测	残差/局部导数r	损失贡献 $r^2/8$	g_1 贡献	g_2 贡献
S1	0	7/4	49/128	-7/16	-7/16
S2	0	9/4	81/128	-9/16	-27/64
S3	0	-5/4	25/128	-5/16	-15/64
S4	0	-11/4	121/128	-11/16	-11/16

汇总 $F_0 = 69/32$ 、 g 数据 $= (-2, -57/32)$ 。 $\lambda \beta^0 = 0$ ，故 g 总相同。两个坐标都从旧值更新： $\beta^1 = (0, 0) - (1/2)(-2, -57/32) = (1, 57/64)$ 。不能先更新 β_1 再用新值重新算 β_2 梯度。

行	β^1 新预测	新残差	新损失贡献
S1	-121/64	-9/64	81/32768
S2	-427/256	149/256	22201/524288
S3	427/256	107/256	11449/524288
S4	121/64	-55/64	3025/32768

和为 $F_1 = 41673/262144$ 。 $P_1 = (1 + (57/64)^2) / 8 = 7345/32768$ ， $J_1 = 100433/262144$ 。惩罚只加一次；若把每行都加 $\lambda \beta$ 再不平均地求和，会把该项放大 n 倍。

7 第二轮：旧行梯度、同步更新、新前向

用上表的 β^1 残差，逐行乘旧 x 并除4：

行	g_1 贡献	g_2 贡献
S1	9/256	9/256
S2	-149/1024	-447/4096
S3	107/1024	321/4096
S4	-55/256	-55/256

和为 $(-113/512, -431/2048)$ 。惩罚梯度是 $(1/4, 57/256)$ ，总梯度是 $(15/512, 25/2048)$ 。所以 $\beta^2 = (1 - 15/1024, 57/64 - 25/4096) = (1009/1024, 3623/4096)$ 。下一轮前向如下，局部导数仍等于残差。

行	β^2 预测	β^2 残差	新损失贡献 $r^2/8$
S1	-7659/4096	-491/4096	241081/134217728
S2	-27013/16384	9851/16384	97042201/2147483648
S3	27013/16384	6533/16384	42680089/2147483648
S4	7659/4096	-3605/4096	12996025/134217728

新数据梯度分项为 $(491/16384, 491/16384)$ 、 $(-9851/65536, -29553/262144)$ 、 $(6533/65536, 19599/262144)$ 、 $(-3605/16384, -3605/16384)$ ，和为 $(-7887/32768, -29889/131072)$ 。再加 $\lambda\beta^2 = (1009/4096, 3623/16384)$ ，总梯度 $= (185/32768, -905/131072)$ ，尚未最优。

$F_2 = 175757993/1073741824$ ， $P_2 = 29415425/134217728$ ， $J_2 = 411081393/1073741824$ 。F从约0.158970上升至0.163687，J从约0.383121下降至0.382849。算法在优化J；只看F会误判第二步失败。这不是允许无条件忽略上升，而是首先核对究竟承诺下降的是哪一个目标。

8 固定设计偏差与协方差

写 $\hat{\beta} = AX^\top(X\beta^* + \epsilon)/n = AH\beta^* + AX^\top\epsilon/n$ ，其中 $A = (H + \lambda I)^{-1}$ 。因为 $AH = I - \lambda A$ ，取期望减真系数得 $\text{Bias} = -\lambda A\beta^*$ 。这里星号全部表示生成真值。

随机项的协方差逐步为

$$\text{Cov}(AX^\top\epsilon/n) = AX^\top(\sigma^2 I)XA^\top/n^2 = \frac{\sigma^2}{n}AHA.$$

最后用A对称、 $X^\top X = nH$ 。若遗漏除n，就会把本四行例方差放大4倍。推导假定固定X、零均值同方差独立噪声，没有估计截距；换设定必须重推。

9 三种误差的不同权重

令 $\delta = \text{估计} - \text{真值}$ ，则 $E \|\delta\|^2 = \|\text{Bias}\|^2 + \text{tr}(\text{Cov})$ ，这是系数MSE。固定 x_0 处无噪声预测误差是 $E(x_0^T \delta)^2 = (x_0^T \text{Bias})^2 + x_0^T \text{Cov} x_0$ 。再预测独立的新噪声标签才加 σ^2 。

如果在原固定 X 各行平均，无噪声误差是 $\text{Bias}^T H \text{Bias} + \text{tr}(H \text{Cov})$ 。 H 不是 I 时，这个量与系数MSE不同。Monte Carlo的每个 λ 都用同一批1000组噪声以减少比较噪声；这不改变每条曲线的期望。OLS理论系数MSE为7.125，实测约6.688040； $\lambda=.25$ 理论约.072956，实测约.070854。差异应保留，不能强行改到理论值，也不能用这个已知真值模拟去给340行实验选 λ 。

10 相关设计Lasso KKT

在 $\beta = (3/2, 0)$ ， $H\beta - c = (3/2 - 2, 21/16 - 57/32) = (-1/2, -15/32)$ 。第一坐标正，因此加 $\lambda \text{sign} = 1/2$ 后为零。第二坐标零，其次梯度可取 $15/16 \in [-1, 1]$ ，使 $-15/32 + (1/2)(15/16) = 0$ 。

所以每个坐标都满足 $0 \in \partial J$ 。凸性保证全局最优， H 正定保证本例唯一。KKT残差应把非零坐标的 $|g + \lambda \text{sign}|$ 与零坐标的 $\max(|g| - \lambda, 0)$ 分别计算；不能在零点机械套一个普通导数。

11 不能直接soft-threshold一般OLS

只有二次项在相应坐标中可分，且尺度已匹配时，才能各自阈值。 $H=I$ 时，目标可改写成 $\sum (\beta_j - c_j)^2 / 2 + \lambda |\beta_j|$ ，得到 $\text{soft}(c, \lambda)$ 。一般 H 有交叉项 $\beta_j H_{jk} \beta_k$ ，各坐标互相影响。

本例OLS $= (.25, 2)$ ，直接以.5阈值得 $(0, 1.5)$ 。其数据梯度第一坐标为 $21/16 - 2 = -11/16$ ，零坐标需要绝对值 $\leq .5$ 却不满足。因此一个直接代回KKT的反例就能否定该错误快捷法。

12 λ 与半径 t 的联系和退化

约束KKT包含 $\nabla F + \lambda \partial P \ni 0$ 、 $\lambda \geq 0$ 、 $P \leq t$ 、 $\lambda(P - t) = 0$ 。某个惩罚最优解可以对应 $t = P(\beta)$ ，但 λ 是乘子， t 是范数预算，二者单位与数值都不同。

若约束不活跃， $\lambda = 0$ 可对应多个足够大的 t ；若整段 λ 都让Lasso解为0，多个 λ 对应 $t = 0$ ；秩亏又可能让系数非唯一。不能声称两种表述在所有退化情况下都有唯一互逆参数映射。

13 Elastic Net正分支与历史约定

$\lambda = .5$ 、 $\rho = .5$ 时 $\lambda_1 = \lambda_2 = .25$ 。先猜两系数都正，于是次梯度都为1。方程 $(H + I/4)\beta = c - (1/4, 1/4) = (7/4, 49/32)$ 。行列式仍为67/128。

第一消元分子为 $(7/4)(33/32) - (7/8)(49/32) = 119/256$ ；第二为 $(5/4)(49/32) - (7/8)(7/4) = 49/128$ 。解为 $(119/134, 49/67)$ ，均正，符号假设自治。最终还须检验 $g + .25\beta + .25(1, 1) = 0$ 。

独立参照枚举9个符号/支持分支：非零块先解线性方程，再验符号；零块验次梯度区间；只接受完整KKT成立的分支。这不是适合高维的通用算法。现代库返回上述组合目标最小点；原论文标准化和未平均RSS记号下的事后重缩放是另一估计，不在本实现额外施加。

14 重复列的严格论证

若第j、k列完全相同，交换 β_j 、 β_k 不会改变预测；对称L1与L2惩罚也不变。正L2使解唯一，交换后的解必须等于原解，所以 $\beta_j = \beta_k$ 。此证明同时用到对称性与唯一性。

纯Lasso可把一个正的总系数任意拆成两个非负分量，预测不变且L1和不变，因而可能非唯一。真实循环坐标求解器偏向先更新的列不意味着第一列有更强因果作用。近似相关列只有倾向和条件性的界，不能直接套完全相同列的等式。

15 MAP对应中的尺度

Gaussian似然负对数为 $SSE/(2\sigma^2) + \text{常数}$ ，Gaussian先验为 $\Sigma \beta_j^2 / (2\tau^2) + \text{常数}$ 。乘 σ^2/n 后数据项恰成F，先验项成为 $[\sigma^2/(n\tau^2)] \|\beta\|^2/2$ ，故 $\lambda = \sigma^2/(n\tau^2)$ 。

Laplace先验密度按 $\exp(-|\beta|/b_0)$ 衰减，对数项 $\Sigma |\beta_j|/b_0$ ；同乘 σ^2/n 得 $\lambda = \sigma^2/(nb_0)$ 。注意n增大时保持同一先验尺度，对平均损失系数 λ 的对应会变化。MAP仅给后验众数；不能由零系数推导“该变量无效的后验概率”。

16 原单位映射与惩罚

$z_j = (x_j - \mu_j)/s_j$ ，标准化空间预测 $a_z + \Sigma \gamma_j z_j$ 。展开为 $(a_z - \Sigma \mu_j \gamma_j / s_j) + \Sigma (\gamma_j / s_j) x_j$ ，所以 $\beta_j = \gamma_j / s_j$ ， $a = a_z - \mu^T \beta$ 。

代回惩罚， $\Sigma \gamma_j^2 = \Sigma s_j^2 \beta_j^2$ ， $\Sigma |\gamma_j| = \Sigma s_j |\beta_j|$ 。预测可逐行相等，惩罚却不等同原坐标各系数统一加权。零方差列用 $s=1$ 、中心化值0；本实验训练常数列的回归系数取0，截距恢复仍使用训练均值。

17 反事实测试标签检查

先只调用`select_candidate(trainX, trainy, valX, valy, cfg)`，把完整选择及参数序列化为字节并取SHA256。再分别用原`testy`与`testy+100`调用`final_evaluate`。前后选择对象必须逐字节不变，而测试MSE发生变化。

此外改变验证特征整体均值不应改变训练`scaler`及任何训练拟合系数，但可以改变验证损失和赢家；改变验证标签也允许改变赢家，但不能断言任何小扰动都必须改变。生成真系数文件只在独立再生审计中读，选择函数既不接收它，也不接收测试数组。

18 三个alpha与复制样本

Ridge库目标是 $SSE + \alpha \|\beta\|^2$ 。本讲J乘 $2n$ 得到 $SSE + n\lambda \|\beta\|^2$ ，所以 $\alpha = n\lambda$ 。Lasso和Elastic Net库已经把平方损失除 $2n$ ，故 $\alpha = \lambda$ ，混合参数为 $l1_ratio = \rho$ 。

把每行复制两次时，SSE与 n 都加倍，平均F不变；本讲 λ 不变。Ridge库 α 必须翻倍，另两个保持不变。audit实际重拟合三种模型并比较系数和 α ，不只检查传参。svd的 $n_iter = \text{None}$ 表示不适用，不能写成“0步无成本”；tol对该求解器不生效。

19 两个最优性不等式

设 $0 \leq \lambda_a < \lambda_b$ ， β_a 与 β_b 分别最小化 $F + \lambda_a P$ 与 $F + \lambda_b P$ 。最优性给 $F_a + \lambda_a P_a \leq F_b + \lambda_a P_b$ 以及 $F_b + \lambda_b P_b \leq F_a + \lambda_b P_a$ 。相加移项得到 $(\lambda_b - \lambda_a)(P_b - P_a) \leq 0$ ，所以 $P_b \leq P_a$ 。第一式进一步给 $F_a - F_b \leq \lambda_a(P_b - P_a) \leq 0$ ，故 $F_a \leq F_b$ 。

成立对象是同一P、同一训练F的精确最优解；固定Elastic Net混合比例才保持P不变。它没有给单个原坐标、验证MSE或支持数的单调性，也不能直接用于未收敛数值输出。跨 λ 的J定义不同，不是共同的泛化评价标准。

20 边界、失败与诚实验收

数值边界包括 $\lambda = 0$ 最小范数、 $\rho = 0$ 与Ridge等价、 $\rho = 1$ 与Lasso等价、重复列正L2唯一、常数列 $scale = 1$ 、单行设计与满秩MC假设。坏类型、NaN/Inf、过小非零数、错维度、重复JSON键或重复样本ID，要在第一次数值求解、随机生成或写文件前拒绝。

真实短迭代Elastic Net返回ConvergenceWarning时保留诊断并排除；受控库异常记录`solver_error`；全候选不合格返回`selection_failed`，不能随便挑最小验证值冒充成功。输出先完整序列化再原子替换，拒绝指向教材输入的目标、符号链接和多硬链接，替换失败保留旧字节并清理新建空目录。

Notebook从零按序执行并验证五个教学契约文件；脚本与Notebook完整核心JSON相同。全部PDF页面与真实PNG逐个检查，只证明这些有限输入和运行经过审计，不表示浏览器Jupyter、所有操作系统或任意病态数据已经验证。