


第040讲 正则化与收缩估计

1 为什么主动接受一点偏差

第027讲认识了偏差方差，第029讲看到共线性会让系数对微小扰动极敏感。现在的问题不是怎样把训练残差再压低一点，而是：能否限制对数据噪声的过度响应，使新数据上的预测更稳定？正则化通过改变估计目标来表达这种取舍。

直接先修024、027、029。第037讲的近端和坐标下降可作为L1从零求解的延伸；本讲先核验成熟求解器，并自行推导目标、条件、手算和诊断，不把调用库当作原理。

本讲会明确分开：训练目标、预测误差、系数误差、稀疏性与数值稳定性。它们相关但不同。正则化不能保证每一个真实任务都变好，非零或零系数也不是因果结论。



训练 F、惩罚 P、总目标 J、验证/测试 MSE 分别记录；测试无返回箭头

图1 训练残差、惩罚、验证选择和最终测试各回答不同问题。

2 先把目标与归一化固定

设 X 为 $n \times d$ 训练设计， y 为长度 n 标签， β 为 d 维系数。先假定数据已用训练统计量中心化，无单独截距。残差 $r = X\beta - y$ ，数据损失为 $F(\beta) = \|r\|^2 / (2n)$ 。定义

$$J_R(\beta) = F(\beta) + \frac{\lambda}{2} \|\beta\|_2^2,$$

$$J_L(\beta) = F(\beta) + \lambda \|\beta\|_1,$$

$$J_E(\beta) = F(\beta) + \lambda \rho \|\beta\|_1 + \frac{\lambda(1-\rho)}{2} \|\beta\|_2^2.$$

其中 $\lambda \geq 0$ ， ρ 在 $[0,1]$ ， ρ 是Elastic Net的L1比例，不是相关系数。三个目标不能只用相同数值 λ 就称为“相同惩罚强度”：范数与混合比例不同。评价新样本通常用不含惩罚的MSE；不能把训练J与验证MSE混在同一列。

若含截距 a ，预测为 $a + X\beta$ ，默认只惩罚 β 。对 a 求导得 $a = \bar{y} - \mu^T \beta$ ，其中 $\bar{y}$ 与 μ 都来自训练集。除非明确改变先验或目标，不要把常数列一起惩罚。

3 同一四行共线设计

使用原创教学数据，第二列是第037讲压力设计的明确延续。主手算不做额外标准化：

行	x_1	x_2	y
S1	-1	-1	$-7/4$
S2	-1	$-3/4$	$-9/4$
S3	1	$3/4$	$5/4$
S4	1	1	$11/4$

两列和与标签和均为0。逐项算得

$$H = \frac{X^T X}{4} = \begin{pmatrix} 1 & 7/8 \\ 7/8 & 25/32 \end{pmatrix}, \quad c = \frac{X^T y}{4} = \begin{pmatrix} 2 \\ 57/32 \end{pmatrix}.$$

H行列式为1/64，正定但有明显弱曲率方向。最小二乘解 $\beta=(1/4, 2)$ ，残差来自设计列空间外的分量，最低 $F=1/8$ 。这个固定四行例只演示估计机制；后面的训练/验证/测试实验另行标记，不把这四行伪装为有统计代表性的数据集。




图2 共线设计的窄谷与弱曲率方向；惩罚改变估计点而不是修改观察值。

4 Ridge闭式解与存在条件

数据梯度为 $X^T(X\beta - y)/n = H\beta - c$ ，惩罚梯度为 $\lambda\beta$ 。所以

$$(H + \lambda I)\hat{\beta}_R = c.$$

当 $\lambda > 0$ ，任意非零 v 有 $v^T(H + \lambda I)v = \|Xv\|^2/n + \lambda \|v\|^2 > 0$ ，即使 X 不满秩也唯一。 $\lambda = 0$ 时需分别讨论满秩与不满秩；不满秩时最小二乘系数不唯一，SVD给出的最小范数解只是明确约定。

在本例 $\lambda = 1/4$ ， $H + \lambda I = [[5/4, 7/8], [7/8, 33/32]]$ ，行列式67/128。两元消元得到

$$\hat{\beta}_R = \left(\frac{129}{134}, \frac{61}{67} \right).$$

代码应解线性系统或用SVD，不显式形成逆矩阵。一个独立等价实现是增广最小二乘：上方 $X/\sqrt{n}$ 、下方 $\sqrt{\lambda}I$ ，标签上方 $y/\sqrt{n}$ 、下方0。三条路线要对齐同一个目标再核验。

5 Ridge不是把每个原坐标都变小

令 $X=U\Sigma V^T$ ，奇异值为 σ_j 。代入目标或把方程旋转到 V 基得到

$$\hat{\beta}_R = V \operatorname{diag} \left(\frac{\sigma_j}{\sigma_j^2 + n\lambda} \right) U^T y.$$

与满秩OLS相应谱方向相比，收缩因子为 $\sigma_j^2/(\sigma_j^2+n\lambda)$ ，处于 $(0,1]$ ；弱奇异方向收缩更多。这是在奇异向量坐标中的描述，不是原特征坐标逐项绝对值下降。

本例OLS第一系数 $1/4$ ，Ridge第一系数 $129/134$ 反而更大；第二系数由 2 变为 $61/67$ 。系数向量重新组合了被收缩的谱方向。因此“每个系数都按同一比例乘小”是错的。Ridge一般不产生由一整段阈值导致的稀疏性，但某些对称或零相关数据仍可得到恰为0的系数，不能写成绝不会出现0。




图3 奇异方向的收缩因子与原坐标路径不同，第一原系数可能增大。

6 用同一数据展开第一轮更新

闭式解方便核验，但不能省掉参数如何作用于每行的计算链。用 $\lambda=1/4$ 、 $\eta=1/2$ 、 $\beta^0=(0,0)$ 手算两轮Ridge梯度下降。局部链为： $r_i=\hat{y}_i-y_i$ ，单行半平方对 r 的导数 r ，预测对 β 的导数 x_i ，平均贡献 $r_i x_i/4$ 。

旧预测全为0，残差为 $(7,9,-5,-11)/4$ 。四行损失贡献为 $(49,81,25,121)/128$ ，和 $F_0=69/32$ 。梯度第一坐标分项为 $(-7,-9,-5,-11)/16$ ；第二坐标分项为 $(-28,-27,-15,-44)/64$ 。汇总 g 数据 $=(-2,-57/32)$ 。旧参数为0所以惩罚梯度也是0。

同时更新得 $\beta^1=\beta^0-\eta g=(1,57/64)$ 。重新前向如下：

行	新预测	新残差	新损失贡献 $r^2/8$
S1	-121/64	-9/64	81/32768
S2	-427/256	149/256	22201/524288
S3	427/256	107/256	11449/524288
S4	121/64	-55/64	3025/32768

新数据损失41673/262144；惩罚为7345/32768；总目标100433/262144。惩罚不是每个样本各加一次同样 $\lambda\beta^2$ ，否则会重复乘n。详解和Notebook逐行保留这三个量。

7 第二轮数据梯度与惩罚梯度分开

在 β^1 ，每行数据梯度分项为

行	对 β_1 的数据梯度贡献	对 β_2 的数据梯度贡献
S1	9/256	9/256
S2	-149/1024	-447/4096
S3	107/1024	321/4096
S4	-55/256	-55/256

数据梯度和为(-113/512, -431/2048)，惩罚梯度 $\lambda\beta^1=(1/4, 57/256)$ 。相加得总梯度(15/512, 25/2048)。同时更新

$$\beta^2 = \left(\frac{1009}{1024}, \frac{3623}{4096} \right).$$

新预测为(-30636, -27013, 27013, 30636)/16384；新残差为(-1964, 9851, 6533, -14420)/16384。重新平方汇总得 $F_2=175757993/1073741824$ ，惩罚 $29415425/134217728$ ， $J_2=411081393/1073741824$ 。

值得注意：第二轮数据损失比第一轮略高，但总正则目标略低。这不是实现必然错误，而是优化目标已经改变；必须把F、惩罚和J同时报告。这个例子不宣称固定 η 可适用于任意其他X或 λ 。




图4 两轮相同行的前向、数据梯度、惩罚梯度、同步更新与三项损失账本。

读图问题：若程序只画数据F，第二轮可能被误判成什么？若把 $\lambda\beta$ 加到每行后再错误求和，梯度会多出哪个因子？

8 从固定设计推偏差与方差

设生成模型 $y = X\beta^* + \varepsilon$ ， X 固定， $E\varepsilon = 0$ ， $\text{Cov}(\varepsilon) = \sigma^2 I$ 。这里星号表示真实生成系数，不是从数据算出的估计。记 $A_\lambda = (H + \lambda I)^{-1}$ ，Ridge为 $A_\lambda X^T y / n$ 。于是

$$E\hat{\beta}_R = A_\lambda H \beta^*, \quad \text{Bias} = -\lambda A_\lambda \beta^*,$$

$$\text{Cov}(\hat{\beta}_R) = \frac{\sigma^2}{n} A_\lambda H A_\lambda.$$

第二式由 $\text{Cov}(X^T \varepsilon / n) = \sigma^2 X^T X / n^2 = \sigma^2 H / n$ 得到。没有默认把噪声方差当成1，也没有忽略平均损失中的 n 。

在 H 特征方向特征值 $d_j > 0$ 时，偏差分量是 $-\lambda \beta_j^* / (d_j + \lambda)$ ，方差是 $\sigma^2 d_j / [n(d_j + \lambda)^2]$ 。 λ 增加会压低该方差，但引入偏差。系数均方误差为偏差平方和加协方差迹；它是否比OLS更小还取决于 β^* 、 σ^2 和 λ ，不能仅凭“存在收缩”推出改善。

9 预测误差不是系数误差

对新特征 x_0 ，预测均值为 $x_0^T \hat{\beta}$ 估计。若新标签有独立同方差噪声，条件预测MSE分解为

$$\sigma^2 + [x_0^T \text{Bias}]^2 + x_0^T \text{Cov}(\hat{\beta}) x_0.$$

第一项是新观察噪声；后两项来自估计。若只比较无噪声条件均值 $x_0^T \beta^*$ ，就不应再加 σ^2 。对很多测试行平均则用各自 x_0 权重，不能直接拿系数MSE代替预测MSE。

固定设计Monte Carlo可用预声明 λ 和独立噪声重复核验这些公式。重复数据的样本均值/方差会围绕理论值波动，有限样本不应被要求精确等于理论。该模拟中的已知 β^* 只是机制诊断；真实任务不能拿不可见真系数选择 λ 。




图5 固定设计下偏差平方、方差与总系数误差； $\lambda=0$ 时偏差为0不显示在对数轴。右图单列预测误差。

10 Lasso的尖点怎样产生精确零

L1在零点没有唯一普通导数。凸最优性为 $0 \in H\beta - c + \lambda \partial \|\beta\|_1$ 。逐坐标写成：正系数满足 $g_j + \lambda = 0$ ，负系数满足 $g_j - \lambda = 0$ ，零系数满足 $|g_j| \leq \lambda$ 。

若 $H=I$ ，各坐标独立，最优解是 $\text{sign}(c_j) \max(|c_j| - \lambda, 0)$ ，一个区间被映射到精确0。一般相关X没有这种逐坐标闭式解；不能先算OLS再直接对其各坐标soft-threshold就冒充Lasso。

本例 $\lambda=1/2$ 时 $\beta=(3/2, 0)$ 。数据梯度 $H\beta - c = (-1/2, -15/32)$ ，第一坐标与 $+\lambda$ 抵消，第二坐标绝对值 $15/32 \leq 1/2$ ，故满足KKT。H正定使此例唯一。这个KKT是在本相关设计重算的，不能直接复制第037讲正交主设计的第二梯度 $-1/4$ 。




图6 二次等高线与L1/L2约束形状；零点来自最优性区间，非人工截断。

11 惩罚形式与约束形式的关系

约束问题 $\min F(\beta)$ subject to $P(\beta) \leq t$ 与惩罚问题 $\min F(\beta) + \lambda P(\beta)$ 有拉格朗日联系。若某个约束最优点满足适当凸性和约束资格条件，就存在非负乘子 λ 使KKT一致。但 t 与 λ 的数值不相同，也不保证在退化、非唯一或约束不活跃时形成简单一对一映射。

几何图可以帮助理解L1边角常与等高线先接触，但它不是所有维度/退化设计上的完整定理。严格的零条件仍需前一节KKT；数值求解器返回很小系数与精确存储0也应分列。

12 Elastic Net的两个控制量

定义 $\lambda_1 = \lambda\rho$ 、 $\lambda_2 = \lambda(1-\rho)$ ，目标为 $F + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|^2/2$ 。若 $\lambda_2 > 0$ ，总目标强凸， X 不满列秩也有唯一系数解。它既保留L1尖点，又通过二次项稳定相关方向；是否更好预测仍由验证检验。

本四行例取 $\lambda = 1/2$ 、 $\rho = 1/2$ ，即 $\lambda_1 = \lambda_2 = 1/4$ 。在两个系数为正的分支，解 $(H+I/4)\beta = c - (1/4, 1/4)$ ，得 $\beta = (119/134, 49/67)$ 。两个数确实正，再代回KKT核验分支自治。这种先假设符号再验证仅适合本二维独立参照；高维主实验仍使用成熟求解器。

若两列完全相同且惩罚对称， $\lambda_2 > 0$ 的唯一解在交换两坐标下必须不变，故对应系数相等。纯Lasso可有非唯一的系数分配，其预测却相同。这个严格的重复列论证比“相关特征总成组入选”的泛泛口号更准确。




图7 完全同列时的系数分配；交换Lasso系数不改预测，正L2下分配对称。

13 名字一样的Elastic Net也可能约定不同

本讲采用现代scikit-learn目标，不额外给最终系数做事后统一放大。Zou与Hastie早期论文区分组合惩罚解与之后的重缩放估计；其列标准化与目标系数约定也不同。在原文列平方和为1、未除n的RSS记号中，组合惩罚解再乘 $(1 + \lambda_{2,paper})$ 才是其重缩放估计；原文系数并非本讲现代目标中的 $\lambda(1-\rho)$ ，不能直接拿本讲 λ_2 代入该因子。现代scikit-learn返回本讲组合目标的最小点，代码不实施那一步重缩放。不能看到“Elastic Net”名字就把一个版本的公式不加换算套在另一个库上。

同样，scikit-learn的l1_ratio与某些其他包的alpha可能对应同一混合比例；而scikit-learn的alpha通常指整体惩罚系数。研究复现实验至少要写目标公式、平均因子、L1比例、截距、尺度变换、求解器和版本，不能只写“alpha=0.1”。

14 MAP解释为何必须带上噪声尺度

假设独立Gaussian噪声方差 σ^2 已知，则忽略与 β 无关的常数，负对数似然为 $\|y - X\beta\|^2 / (2\sigma^2)$ 。若 β_j 独立服从零均值Gaussian先验、方差 τ^2 ，负对数先验为 $\|\beta\|^2 / (2\tau^2)$ 。两者相加乘 σ^2/n ，得到本讲Ridge形式，且

$$\lambda = \frac{\sigma^2}{n\tau^2}.$$

若先验为独立Laplace、尺度 b_0 ，负对数先验为 $\|\beta\|_1 / b_0$ ，则Lasso的 $\lambda = \sigma^2 / (nb_0)$ 。这些对应是MAP点估计，不是整个后验分布，也不意味着Lasso给出了非零系数的概率。

若 σ^2 、先验尺度或截距处理改变，对应关系也变。未惩罚截距可视为单独无惩罚参数；不要无说明给它套与斜率同样的收缩。把惩罚当先验有解释价值，但不能代替验证或保证模型设定正确。

15 标准化改变了惩罚坐标

只用训练集均值 μ_j 和标准差 s_j ，构造 $z_{ij} = (x_{ij} - \mu_j) / s_j$ 。在标准化空间拟合 γ 、截距 a_z ，回原单位有 $\beta_j = \gamma_j / s_j$ ， $a_{\text{原}} = a_z - \sum \mu_j \beta_j$ 。两空间预测应逐样本一致。

惩罚却不能混同： $\|\gamma\|^2 = \sum s_j^2 \beta_j^2$ ， $\|\gamma\|_1 = \sum s_j |\beta_j|$ 。因此“标准化前后用同一个 λ ”一般不是同一个原单位惩罚。图中应注明画的是 γ 还是 β 。零方差列需显式约定；StandardScaler的尺度处理可核查，但库允许某些缺失值不意味着本课程入口也应默许NaN。

所有 μ 、 s 都只拟合训练数据。验证/测试执行同一个transform，不能各自重新居中到自己的均值，否则预测规则变了。交叉验证时，尺度估计还必须在每一训练折内部重新拟合。




图8 标准化只在训练集学习，原系数与标准化系数不同但预测对应。

16 用训练与验证锁定选择

额外合成实验显式固定train/validation/test三种角色。预声明模型族、 λ 网格、Elastic Net比例和并列处理规则。每个候选只用训练集拟合预处理与系数，验证MSE决定候选。不得查看测试曲线后增加一个恰好有利的 λ ，或拿测试集决定稀疏度。

本讲最终选择函数的参数中不接受测试标签。测试字段可先做完整性、模式与数值范围校验；测试标签仅在选择结果、预处理摘要和候选表锁定后的评价阶段用于计算最终MSE。独立测试可以将全部测试标签替换成其他合法值，检查选择/训练参数逐字节不变；测试MSE改变是正确结果。

实际固定运行比较40个候选：Ridge与Lasso各8个，Elastic Net为 8×3 个。它们都满足本讲预声明的绝对KKT残差 $\leq 1e-7$ 且无ConvergenceWarning的准入门槛；该门槛是独立于库tol的验收约定，不是任意尺度的通用精度保证。验证赢家为Lasso $\lambda=0.03$ ，验证MSE约0.807542，训练MSE约0.751308，20个系数中恰有5个存储零。锁定后测试MSE约0.937357，预声明OLS基线约1.075616。这是单次合成划分上的观察，不是Lasso普遍胜出或正确找回真实支持的证据。

并列时先比精确验证MSE，再偏好较大的 λ 、固定模型族顺序Ridge/Lasso/Elastic Net、最后较大的 ρ ；不加事后近似并列容差。未收敛候选保留警告并排除，无合格候选则报告selection_failed。

本实验不在选择后用train+validation重新训练，避免把样本数、尺度及库alpha换算变化藏在结尾。实际项目若预先决定这样做，应重新拟合预处理、按新的n换算Ridge alpha，然后仅做一次最终测试。




图9 训练路径与验证曲线用于选择；测试只在锁定后出现，不参与回流。

17 与真实库对照需要换算什么

scikit-learn1.8的Ridge目标写 $SSE + \alpha \|\beta\|^2$ 。乘本讲J_R以2n，得 $SSE + n\lambda \|\beta\|^2$ ，所以必须 $\alpha_{\text{Ridge}} = n\lambda$ 。Lasso目标已经是 $SSE/(2n) + \alpha \|\beta\|_1$ ，因此 $\alpha_{\text{Lasso}} = \lambda$ 。ElasticNet同理 $\alpha = \lambda$ 、 $l1_ratio = \rho$ 。

本四行Ridge手算 $\lambda=1/4$ 对应库 $\alpha=1$ ，不是0.25。反过来，若复制同一数据每行两次，平均目标不变； λ 仍不变，但Ridge的库 α 要随 n 加倍，而Lasso/ElasticNet α 不用变。这个复制实验是最直接的归一化守卫。

库检查不仅比较训练损失，还应保留系数、预测、目标的各项、Ridge梯度或L1 KKT、迭代数、`dual_gap`以及收敛警告。Ridge的svd求解器不使用`tol`作迭代阈值，`n_iter_`为None不代表0次运算；不能把不存在的信息补成0。 $\lambda=0$ 端点单独使用最小二乘，不用Lasso($\alpha=0$)假装可靠端点。

18 正则路径能说什么 不能说什么

路径展示同一训练数据、同一尺度、不同预声明 λ 的系数。Ridge谱分量连续收缩；Lasso可能出现精确零与折点；Elastic Net受两种惩罚共同影响。有限离散网格上的折线只是计算结果，不是已经证明整条路径的全部解析性质。

训练未惩罚损失通常随惩罚加强而不减，惩罚范数在对应同一单参数惩罚问题下不增，可用两个最优性不等式相加说明。但单个原系数、验证MSE、支持集大小不必简单单调；尤其相关设计中变量可进入后再退出，不能据稀疏数看起来合理就跳过KKT。

不同 λ 下J的定义也在变，所以不能拿各自最小J数值直接排名泛化。必须在同一评价损失和同一验证数据上比较预测误差。路径记录必须保留失败/未收敛候选。本次图中各候选均通过KKT；若改配置导致失败，应明确画失败标记或标记，不能把缺口静默解释为正常路径。

19 科研验收与边界

纸笔层核对两轮相同四行计算、三种目标和库归一化映射。数值层用Fraction解二维方程、独立SVD/增广最小二乘和L1二维符号枚举，验证KKT。高维求解器要记录警告和状态，不以一次小loss断言成功。

研究流程层检查测试标签不影响选择、所有候选共享训练统计量、常数列处理一致、复制样本 n 变化的 α 换算、原/标准化预测逐样本等价、 $\lambda=0$ 与 ρ 端点、重复列和秩亏。工程层在任何随机生成、库拟合、前向或输出前验证全部原始输入，坏最后字段也要先拒绝。

这些是有限机制实验，不提供真实数据泛化保证，不等同变量选择后的统计显著性检验，更不证明被选中特征有因果作用。大幅调参后的验证误差本身也可能乐观，更严格的重复选择评估将在后续模型选择章节展开。

20 练习与研究阅读

1. 固定三种目标的平均因子，并写出有/无截距的变量形状。
2. 从四行原值算H、c、行列式和OLS解。
3. 推导Ridge方程，证明 $\lambda>0$ 时即使秩亏也唯一。
4. 消元重算 $\lambda=1/4$ 时的(129/134,61/67)。

5. 用SVD推导收缩因子，解释原坐标第一系数为什么会增大。
6. 不借用闭式梯度，完整重算第一轮逐样本链。
7. 完整重算第二轮，解释F略增而J降低。
8. 固定设计假设下推导Ridge偏差与协方差中的全部n因子。
9. 区分系数MSE、无噪声预测误差和带新噪声预测误差。
10. 用本相关数据核验Lasso(3/2,0)的每个KKT分量。
11. 解释为何不能对一般OLS系数直接soft-threshold。
12. 区分惩罚 λ 与约束半径t，列出退化映射的情形。
13. 验证Elastic Net正分支解(119/134,49/67)。
14. 用交换对称与唯一性证明重复列的二次惩罚系数相等。
15. 推导Gaussian/Laplace MAP与 λ 的噪声、样本数关系。
16. 推导标准化与原单位系数/截距映射以及惩罚变化。
17. 设计测试标签篡改不影响模型选择的可执行检查。
18. 推导三个库alpha映射，并验证复制所有训练行的行为。
19. 用两个最优性不等式证明惩罚范数单调，指出原坐标并不因此单调。
20. 设计秩亏、常数列、坏尾字段、未收敛库结果和输出保护检查。

一手来源与约定

- [scikit-learn1.8 Ridge、Lasso、ElasticNet](#)：核对目标、alpha、端点、求解器和停止诊断。
- [StandardScaler1.8与官方常见陷阱](#)：核对ddof=0、训练拟合与测试泄漏边界。
- [Tibshirani原Lasso论文入口](#)：本次仅核对摘要与书目信息，不声称读到付费全文。
- [Zou与Hastie作者版原论文](#)：核对组合惩罚、MAP联系及原论文重缩放约定；本讲明确采用现代库的目标，不借用未对齐的性能或极小极大结论。