

第041讲 练习完整解答

以下解答对应正文16题。所有数字来自本讲默认四行或固定合成协议；自定义数据必须重新核算。完成项目不等于证明任意输入或真实研究结论成立。每题除计算结果外，还要检查该结果允许说明什么。

1 原始数据与两个解析解

$X^T X$ 的四项依次为4、4、4、8，除以4得 $H = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$ 。 $X^T y = (6, 10)$ ，因此 $c = (3/2, 5/2)$ 。OLS方程第一行为 $w_1 + w_2 = 3/2$ ，第二行为 $w_1 + 2w_2 = 5/2$ ，相减得 $w_2 = 1$ 、 $w_1 = 1/2$ 。

OLS预测是 $(-5/2, -1/2, 1/2, 5/2)$ ，残差 $(-1/2, 1/2, 1/2, -1/2)$ 。平方和为1，所以平均方损失为1/8。逐项计算 $X^T r = 0$ ，既验证正规方程，也验证残差和设计列正交。

Ridge $\lambda=1/2$ 使H对角加1/2。方程乘2得到 $3w_1 + 2w_2 = 3$ 与 $2w_1 + 5w_2 = 5$ 。消元得 $w_1 = 5/11, w_2 = 9/11$ 。残差为 $(-1, 6, 5, -10)/11$ ，数据损失 $(1 + 36 + 25 + 100)/(8 \cdot 121) = 81/484$ ；惩罚为 $(25 + 81)/(4 \cdot 121) = 53/242$ ，相加为 $187/484 = 17/44$ 。

不能因为OLS的1/8小于Ridge的17/44就宣布OLS预测更好，二者比较的是不同训练目标。比较预测必须在相同未惩罚评价损失和相同数据上进行。

2 两次更新的完整账本

每行每轮的局部链都是： $\partial \ell_i / \partial r_i = r_i$ ， $\partial r_i / \partial p_i = 1$ ， $\partial p_i / \partial w = x_i$ 。四个x依次为 $(-1, -2)$ 、 $(-1, 0)$ 、 $(1, 0)$ 、 $(1, 2)$ 。平均梯度贡献是三个局部因子的乘积除以4，不能把平均因子遗漏或重复。

状态0: $w = (0, 0)$ 。

行	预测p	残差r及局部损失导数	半平方损失	平均损失	平均梯度贡献
1	0	2	2	1/2	$(-1/2, -1)$
2	0	1	1/2	1/8	$(-1/4, 0)$
3	0	0	0	0	$(0, 0)$
4	0	-3	9/2	9/8	$(-3/4, -3/2)$

数据梯度和为 $(-3/2, -5/2)$ ，惩罚梯度为零，总目标7/4。乘-1/4得到更新量 $(3/8, 5/8)$ ，同步更新得状态1。

状态1: $w = (3/8, 5/8)$ 。例如第4行 $p = 3/8 + 2(5/8) = 13/8$ ， $r = 13/8 - 3 = -11/8$ ；对第二系数的平均梯度贡献是 $(-11/8) \times 1 \times 2/4 = -11/16$ 。

行	预测p	残差r及局部损失导数	半平方损失	平均损失	平均梯度贡献
1	-13/8	3/8	9/128	9/512	$(-3/32, -3/16)$
2	-3/8	5/8	25/128	25/512	$(-5/32, 0)$
3	3/8	3/8	9/128	9/512	$(3/32, 0)$
4	13/8	-11/8	121/128	121/512	$(-11/32, -11/16)$

四行中间导数均为1，预测局部导数与状态0完全相同。数据损失41/128，惩罚17/128， $J=29/64$ 。数据梯度 $(-1/2, -7/8)$ 加惩罚梯度 $(3/16, 5/16)$ 得 $(-5/16, -9/16)$ 。更新量 $(5/64, 9/64)$ ，同步相加得到状态2： $(29/64, 49/64)$ 。

状态2的真正新前向如下，不可复用状态1残差。

行	预测p	残差r及局部损失导数	半平方损失	平均损失	平均梯度贡献
1	-127/64	1/64	1/8192	1/32768	$(-1/256, -1/128)$
2	-29/64	35/64	1225/8192	1225/32768	$(-35/256, 0)$
3	29/64	29/64	841/8192	841/32768	$(29/256, 0)$
4	127/64	-65/64	4225/8192	4225/32768	$(-65/256, -65/128)$

局部导数链仍保持相同结构。平均损失和为1573/8192，惩罚1621/8192，总目标1597/4096。数据梯度 $(-9/32, -33/64)$ ，惩罚梯度 $(29/128, 49/128)$ ，总梯度 $(-7/128, -17/128)$ 。因此迭代正在接近Ridge参照，而不是已经结束。

3 目标差恒等式与界

令 $w = w_* + e$ ，将它代入 $J(w) = w^\top H_\lambda w / 2 - c^\top w + C$ 。展开得到 $J(w_*) + e^\top H_\lambda w_* - c^\top e + e^\top H_\lambda e / 2$ 。由 $H_\lambda w_* = c$ ，中间两项相消，得到目标差 $e^\top H_\lambda e / 2$ ；梯度为 $H_\lambda e$ 。

将Hessian正交对角化，记特征值d。每项都有 $d^2/L \leq d \leq d^2/\mu$ 。乘 $e_j^2/2$ 后求和得到 $\|g\|^2/(2L) \leq J - J_* \leq \|g\|^2/(2\mu)$ 。又有 $\|g\|^2 = \sum d_j^2 e_j^2 \geq \mu^2 \|e\|^2$ ，开方得参数误差界。

$\mu=0$ 时不能除以 μ ，零空间中的e可以任意大而梯度不变。即便 μ 只是很小，上界也可能很宽。相对梯度还依赖所选坐标和归一化，因此要同时报告原始梯度、曲率和实际误差。

4 秩亏的两个不同系数

取 A 四行分别为 $(1, 1), (2, 2), (-1, -1), (-2, -2)$ ，标签 $(2, 4, -2, -4)$ 。 $w = (1, 1)$ 与 $w' = (4, -2)$ 都使两坐标和为2，故预测完全相同且损失0。差向量 $(3, -3)$ 落在零空间。

前者范数 $\sqrt{2}$ ，后者范数 $\sqrt{20}$ ，因此最小范数lstsq返回前者有明确理由。若待测算法返回后者，不能只凭系数不同判它未解最小二乘；应核验预测、目标和声明的解选择约定。如果算法声称最小范数却返回后者，则该额外主张不成立。

5 库归一化与遗漏n的反例

本讲目标乘2n后是 $\|y - Xw\|^2 + n\lambda\|w\|^2$ ，所以Ridge库alpha=nλ。四行λ=1/2应设alpha=2。若误设alpha=1/2，库实际对应本讲λ=1/8，解的是另一个收缩强度。

把全部行重复一次，n变为8，但平均数据损失不变。保持同一目标需要λ仍为1/2、库alpha变为4。如果错误地固定alpha=2，新的等效λ变为1/4。独立测试应比较重复前后的系数与逐行预测，不能只检查目标是否都下降。

6 多点差分与驻点盲区

每个坐标取 $[J(w + he_j) - J(w - he_j)]/(2h)$ ，逐点计算与解析梯度的归一化差异。本讲三个点和五个h完整保留在报告；正确梯度差异很小，反号梯度在非驻点差异接近2，而不是接近0。

若只在真正驻点检查，正确梯度和它的反号都为0，无法识别符号错误。某个分量恰为0时，该坐标也有相同盲区。多点、多方向与逐行账本可以覆盖更多错误，但有限测试仍不是对任意输入的形式证明。

平方目标沿坐标方向为二次多项式，中央差分在实数算术中完全准确；h太小时主要受到浮点相减与除以h的放大。不能由本图推断一般非二次函数没有截断误差。

7 对角预条件的推导

设D正对角， $w = D^{-1/2}u$ 。链式法则给 $\nabla_u J(D^{-1/2}u) = D^{-1/2}g$ ，Hessian变为 $D^{-1/2}H_\lambda D^{-1/2}$ 。u空间一步 $u^+ = u - D^{-1/2}g/L_D$ ，乘 $D^{-1/2}$ 得 $w^+ = w - D^{-1}g/L_D$ 。

这保留整个原目标，包括原惩罚。若只将X缩放并对新参数施加相同形式的各向同性惩罚，原目标通常改变，不能再说只是同一个问题的预条件。代码用正的对角下限处理退化尺度，但本次固定压力数据的对角项均正；它不制造统计可识别性。

8 Adam首步与小批量无偏性

初始m=v=0，故首步 $m_1 = 0.1g_1$ 、 $v_1 = 0.001g_1^2$ 。除以1-0.9与1-0.999后， $\hat{m}_1 = g_1$ 、 $\hat{v}_1 = g_1^2$ ，更新就是 $-0.04g_1/(|g_1| + 10^{-8})$ 。除非epsilon可忽略且梯度非零，不能机械写成每坐标恰好移动0.04。审计独立核对这一式。

对于等概率抽取m个不同索引的子集，令指示量 I_i 表示i入选，则 $E[I_i] = m/n$ 。所以 $E[(1/m) \sum I_i r_i x_i] = (1/n) \sum r_i x_i$ 。加上不随机的λw仍无偏。要求抽样机制相对当前w正确，不能根据标签或梯度大小抽样却不修正权重。

当前每轮8个16行独立子集，访问128行但可能重复，同一行也可能一次没被访问。因此轮次是记录单位，不是完整epoch遍历。400轮约3200次小批量更新，还包含每轮完整梯度监测。

9 诚实的优化比较段落

可以写：“在固定 120×6 的collinear OLS病例上，GD在400轮内未达到相对完整梯度 $1e-6$ ，最终残差约 $1.071e-5$ ，目标差约 $3.420e-5$ ，参数距离约6.224。Newton在本二次问题上一次更新后达到阈值，但额外构造和求解曲率系统。小批量方法同样耗尽预算。上述证据反映固定数据、种子、步长与预算下的行为，不支持通用算法排名。”

对应JSON的prediction_distance_rms约为0.00826985，应与参数距离6.224并列报告。参数误差沿弱奇异方向可以大，而训练预测差小。训练预测差也不等于未见分布预测风险。不能把“所有模型预测看着差不多”当成参数稳定的证据。

10 失败路径的完整成本

unsafe路径只提出一次更新，候选目标增加后被拒绝，最终保留初值。尝试=1、提交=0。参照评价、初始评价、候选评价共3次完整目标和梯度，每次120行，共各360行。初始及候选监测还各算预测距离，共240行。

此外有1次120行Gram构造、2次谱求解、1次增广最小二乘，增广行数 $120+6=126$ 。没有发生Newton方向线性求解，小批量梯度次数为0。操作种类不同，不能把这些数字相加当作准确FLOPs；但可以用它们发现“只按提交数收费”的漏记。

11 复杂度与实测的不同对象

稠密批量梯度主要为两次矩阵向量乘法，量级 $O(np)$ ；小批量 $O(mp)$ ，但它的完整停止监测仍是 $O(np)$ 。Gram是 $O(np^2)$ ，保存H需要 $O(p^2)$ ，一般稠密线性系统或谱操作约 $O(p^3)$ 。Adam增加 $O(p)$ 状态；本实现保存全部K个参数轨迹带来 $O(Kp)$ 额外存储。

Newton一步结果来自本固定二次函数，不说明任意非线性目标只需一步。即使都是一步，矩阵构造与求解可能比一次GD贵得多。实际计时包括本教学程序的全部诊断开销，不能把它外推为稀疏、GPU或分布式性能。

3次正式计时报告中位数和范围，1次暖机也保存。未达标运行的耗时是“花费了多少仍未达到标准”，不能算作达到同精度的时间，也不能从总体成本中删掉。

12 测试隔离与不好看的结果

保存原选择对象与摘要，在合法副本里只将测试标签加25，重复选择。应要求候选系数、预处理参数、验证MSE、选中 λ 及完整锁定对象逐字节相同；最终测试MSE应该改变。修改测试特征也不应改变锁。格式校验会读取测试原始字段，但校验不应把数值传回训练或排序。

本次选择 $\lambda=0.1$ ，测试MSE0.775054，OLS0.767754。应保留“验证所选Ridge在这次测试上略差于预声明OLS”的结果。不能再该测试决定候选入、预处理或最终报告哪个模型，否则测试成为新的验证。一次差异也没有足够依据宣称OLS总体优于Ridge。

13 区间推导的全部尺度

OLS误差是 $\hat{\beta} - \beta = (A^\top A)^{-1} A^\top \varepsilon$ 。由协方差变换，Cov为 $\sigma^2 (A^\top A)^{-1}$ 。乘新设计行 a_0 ，得到均值估计误差方差 $\sigma^2 h_0$ ，其中 $h_0 = a_0^\top (A^\top A)^{-1} a_0$ 。

新观测还有独立误差 ε_0 ，故 $Y_0 - \hat{m}_0 = \varepsilon_0 - a_0^\top (\hat{\beta} - \beta)$ ，交叉协方差为0，总方差 $\sigma^2(1 + h_0)$ 。若新噪声与训练相关或异方差，这一步不能照搬。

满秩A将n维Gaussian噪声分解为p维列空间投影与n-p维正交残差；两个正交Gaussian投影独立。因此残差平方和/ σ^2 为n-p自由度卡方，且与系数估计独立。以 $s^2 = RSS/(n - p)$ 替 σ^2 ，标准正态除以独立卡方均值平方根得到t分布。这里p包含截距，所以自由度32-2=30，不是31或32。

两类区间分别为 $\hat{m}_0 \pm t_{.975,30} s \sqrt{h_0}$ 与 $\hat{m}_0 \pm t_{.975,30} s \sqrt{1 + h_0}$ 。分位数是t分布的数值输入，不是单靠库返回的分布区间就能完成回归推断。

14 覆盖结果怎样解释

正确均值覆盖580/600，正确预测覆盖562/600。独立重复下，覆盖指示量为Bernoulli，样本比例方差约 $p(1-p)/600$ 。若 $p=0.95$ ，标准误约0.00890。因此0.9367与0.95相差约1.50个标准误，有限模拟波动足以解释，不应要求恰好570次覆盖。

误把均值区间用于未来观测只覆盖247/600，因为漏掉新观察的 σ^2 。未来SD由0.5变1.5，原预测区间只覆盖321/600，因为同分布/同方差假设破坏。后两者的差距远超上述名义Monte Carlo量级，但它们说明特定机制失败，不能自动提供未知真实数据的修复方案。

观察600次里面哪24次好看再画图会产生选择偏差。教材固定画前24次，完整600次不丢弃；所有计数可从rows中的布尔值重算。

15 选择后Ridge与因果边界

Ridge估计有依赖真实系数的收缩偏差，协方差也不是简单的OLS逆Gram。 λ 由同一组训练和验证选择时，还引入额外的数据依赖。把OLS的n-p残差自由度、无偏中心和t枢轴直接套上去，没有相同的精确覆盖证明。

若使用Bootstrap，应预先确定重采样单位和哪些训练、缩放、选择步骤重做，并区分估计均值与未来观察。若讨论conformal，应独立说明校准与交换性等条件；不能只更换区间名称就补上保证。

回归系数描述给定模型下的条件关联。未测混杂、反向作用或选择机制都可能使预测有效而干预结论错误。数值误差趋近零仅说明更精确地解了这个统计问题，并未增加随机化或识别条件。

16 工程验收与一个可证伪扩展

先把“坏输入必须早拒绝”写成哨兵测试：将最后一个标签改为bool、字符串、复数、NaN、Inf或过小非零数，将最终配置字段改为非法类型；把求解、RNG和回调替成一调用就报错的哨兵。预期只出现输入异常，哨兵调用为零。NumPy longdouble在转float前仍为非零、转后变0时也要拒绝；真正0保持合法。

输出测试包括输入路径、交付图、符号链接、符号链接父目录、多个硬链接。对常规旧报告注入os.replace异常和不可序列化非有限数，核验旧字节保留、临时文件清理。明确单用户本地原子保护的范范围，不作并发攻击安全声明。

新进程分别跑普通/-O/不同cwd，比较全部科学JSON，而不是仅看几个摘要。合法预算1、手算驻点初值、首步被拒绝也应成功输出正确状态。Notebook副本逐一改契约文件，第一格应在导入数值模块前失败，不能出现数值图或旧答案。

可证伪扩展可以是：“在固定 120×6 的scaled病例、原坐标Ridge目标和相同完整梯度阈值下，对角预条件在预先固定的20个独立数据种子上，达到标准所需的梯度行访问量中位数少于普通GD，且失败比例不增加。”预先固定种子、上限、并列与失败处理，保存所有路径；若多个种子上不成立或失败比例增加，就否定或收窄主张。计时另外重复测量，不把不同预算下的缺失结果删掉；测试集仍不参与选择研究结论。