

第041讲 回归与优化阶段项目


怎样证明自己的优化实现与回归结论都可信？本项目把“证明”拆成能独立检查的证据：在已知答案的小问题上核验数学与实现，在压力数据上记录达到什么精度、付出多少计算，再按训练与验证锁定预测规则，最后说明区间与因果解释的边界。程序成功退出只是起点。

本讲面向完成基础学习、希望独立开展研究的大学教师。直接先修为007可重现实验、025区间与Bootstrap、029多元回归、032多维梯度下降、034小批量方法、036自适应优化、039故障诊断及040正则化。第038讲不是隐藏先修：本讲会用二次函数直接推导所需的Newton一步公式。课程总范围为166单元，本阶段项目不提前替代后续模型选择、因果识别或大规模系统测量。

1 把研究结论拆成可以反驳的问题

假设同事拿来一条下降很顺的训练曲线，说“算法正确，而且模型可靠”。至少要追问四件事。它优化的是不是写在报告上的那个目标？它是否接近那个目标的最小点？对没有用于挑选方案的新数据，预测怎样？若声称某个因素产生了某种效果，干预解释依赖什么识别条件？四个问题需要不同证据。

本项目预先规定四个交付物。第一份是四行数据的精确账本。第二份是同一固定回归目标上五种求解路线的完整状态、残差、差距与成本。第三份是带选择锁的训练、验证、测试包。第四份是一个区间覆盖实验及其故意破坏假设后的失败。全部数据为原创合成数据，只用于有限机制核验，不据此宣称现实任务冠军。



Numerical correctness / Predictive evidence / Causal identification

Each needs its own assumptions. No arrow proves the next claim by itself.

图1 证据顺序从固定问题走向实现、数值与预测检验。数值正确、预测表现和因果识别是三种不同主张，不能互相替代。

开始运行前就固定候选、停止标准和失败处理。看到不合预期的结果后可以提出新实验，但要另存配置，并把原结果保留下来。尤其不能把未收敛运行删去以后，只在成功子集里平均耗时。

2 定义同一个标量目标

四行纸笔问题没有截距，所有列已中心化。令设计矩阵 $X \in \mathbb{R}^{n \times p}$ ，标签 $y \in \mathbb{R}^n$ ，参数 $w \in \mathbb{R}^p$ 。本例 $n = 4, p = 2$ ，所有量是无量纲教学刻度。行号只是索引，不是特征。

$$p_i = x_i^\top w, \quad r_i = p_i - y_i, \quad \ell_i = \frac{1}{2} r_i^2, \quad F(w) = \frac{1}{n} \sum_i \ell_i,$$

$$J_\lambda(w) = F(w) + \frac{\lambda}{2} w^\top w, \quad \lambda \geq 0.$$

OLS对应 $\lambda = 0$; Ridge对应 $\lambda > 0$ 。训练目标用平均方误差，验证和测试统一用普通MSE，即平均 r_i^2 ，不加惩罚。单位不同的真实特征必须额外说明系数和惩罚的量纲；本讲不能把无量纲阈值直接套到任意物理测量。

行号	x_{i1}	x_{i2}	y_i	$\partial p_i / \partial w$
1	-1	-2	-2	$(-1, -2)^\top$
2	-1	0	-1	$(-1, 0)^\top$
3	1	0	0	$(1, 0)^\top$
4	1	2	3	$(1, 2)^\top$

三列和均为零。若后续数据需要截距 a ，只惩罚斜率，先从训练数据求 $\bar{x}, \bar{y}$ ，再用 $a = \bar{y} - \bar{x}^\top w$ 恢复。不能在验证、测试上各自重算均值来改变预测器。

3 从逐行导数到解析参照

链式法则不是一句“调用梯度函数”。对于每一行、每一个旧状态，都有

$$\frac{\partial \ell_i}{\partial r_i} = r_i, \quad \frac{\partial r_i}{\partial p_i} = 1, \quad \frac{\partial p_i}{\partial w} = x_i, \quad c_i = \frac{r_i x_i}{4}.$$

c_i 是该行对平均数据目标的梯度贡献。惩罚对总目标只贡献一次 λw 。汇总得到

$$g_\lambda(w) = \sum_i c_i + \lambda w = H_\lambda w - c, \quad H_\lambda = \frac{X^\top X}{4} + \lambda I, \quad c = \frac{X^\top y}{4}.$$

逐元素核验： $H_{11} = (1 + 1 + 1 + 1)/4 = 1$, $H_{12} = (2 + 0 + 0 + 2)/4 = 1$,

$H_{22} = (4 + 0 + 0 + 4)/4 = 2$; $c_1 = (2 + 1 + 0 + 3)/4 = 3/2$, $c_2 = (4 + 0 + 0 + 6)/4 = 5/2$ 。

因此

$$H = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad c = \begin{pmatrix} 3/2 \\ 5/2 \end{pmatrix}.$$

令OLS梯度为零，得到 $w_1 + w_2 = 3/2$ 与 $w_1 + 2w_2 = 5/2$ 。后式减前式得 $w_2 = 1$ ，再代回得 $w_1 = 1/2$ 。残差为 $(-1/2, 1/2, 1/2, -1/2)$ ，故 $F_* = 1/8$ 。

Ridge取 $\lambda = 1/2$ ，方程为 $3w_1 + 2w_2 = 3$, $2w_1 + 5w_2 = 5$ 。第一式乘5、第二式乘2，相减得到 $11w_1 = 5$ ；代回得 $w_2 = 9/11$ 。所以 $w_R = (5/11, 9/11)$, $J_R = 17/44$ 。这两套参照对应不同目标，不能把它们的目标最小值直接作为预测排名。

$\lambda > 0$ 时, 任意非零 v 满足 $v^\top H_\lambda v = \|Xv\|^2/n + \lambda\|v\|^2 > 0$, 因此唯一极小点存在。OLS在满列秩时同样唯一; 秩亏时系数可能不唯一。NumPy的 `lstsq` 明确返回最小二范数解, 并报告数值秩与奇异值 [1]。这只是可重复的选择约定, 不是恢复真实系数的证据。

4 第一轮必须保留全部行

取 $w^{(0)} = (0, 0)$, $\eta = 1/4$, $\lambda = 1/2$ 。下表的 r_i 同时是局部导数 $\partial\ell_i/\partial r_i$; 中间导数 $\partial r_i/\partial p_i = 1$, 预测导数逐行固定为上一节数据表最后一列。全部行必须共享同一旧参数。

行	p_i	$r_i = \partial\ell_i/\partial r_i$	ℓ_i	$\ell_i/4$	c_{i1}	c_{i2}
1	0	2	2	1/2	-1/2	-1
2	0	1	1/2	1/8	-1/4	0
3	0	0	0	0	0	0
4	0	-3	9/2	9/8	-3/4	-3/2

例如第1行的两个梯度贡献分别是 $2 \times 1 \times (-1)/4 = -1/2$ 和 $2 \times 1 \times (-2)/4 = -1$ 。四行相加, 数据梯度为 $(-3/2, -5/2)$, 惩罚梯度为 $(0, 0)$, $F_0 = J_0 = 7/4$ 。

先求更新量, 再同时更新两个参数:

$$\Delta w^{(0)} = -\frac{1}{4} \begin{pmatrix} -3/2 \\ -5/2 \end{pmatrix} = \begin{pmatrix} 3/8 \\ 5/8 \end{pmatrix}, \quad w^{(1)} = (3/8, 5/8).$$

不能先改 w_1 再拿新 w_1 求本轮 w_2 的梯度。那已经变成另一种顺序算法。也不能把四行分别更新一次后称为“这一步批量GD”。

5 第二轮从真正的新前向开始

在 $w^{(1)}$ 处, 第1行的新预测是 $(-1)(3/8) + (-2)(5/8) = -13/8$, 残差是 $-13/8 - (-2) = 3/8$ 。它不是旧残差减去某个统一常数。

行	新 p_i	新 $r_i = \partial\ell_i/\partial r_i$	新 ℓ_i	新 $\ell_i/4$	新 c_{i1}	新 c_{i2}
1	-13/8	3/8	9/128	9/512	-3/32	-3/16
2	-3/8	5/8	25/128	25/512	-5/32	0
3	3/8	3/8	9/128	9/512	3/32	0
4	13/8	-11/8	121/128	121/512	-11/32	-11/16

这一轮四行的中间导数依然各为1, 预测局部导数依次为 $(-1, -2)$ 、 $(-1, 0)$ 、 $(1, 0)$ 、 $(1, 2)$ 。因此第二轮的链条也能逐行复核, 不能仅凭总梯度一致跳过行级核查。

数据梯度为 $(-1/2, -7/8)$ ；惩罚梯度为 $(3/16, 5/16)$ 。相加得到 $g_1 = (-5/16, -9/16)$ 。数据损失是 $41/128$ ，惩罚是 $17/128$ ，总目标为 $29/64$ 。

$$\Delta w^{(1)} = -\frac{1}{4} \begin{pmatrix} -5/16 \\ -9/16 \end{pmatrix} = \begin{pmatrix} 5/64 \\ 9/64 \end{pmatrix}, \quad w^{(2)} = (29/64, 49/64).$$

第二次更新之后，仍要再做完整新前向。以下既是第二轮的结果，也是若继续训练时第三轮的输入状态。

行	新 p_i	新 $r_i = \partial \ell_i / \partial r_i$	新 ℓ_i	新 $\ell_i/4$	新 c_{i1}	新 c_{i2}
1	$-127/64$	$1/64$	$1/8192$	$1/32768$	$-1/256$	$-1/128$
2	$-29/64$	$35/64$	$1225/8192$	$1225/32768$	$-35/256$	0
3	$29/64$	$29/64$	$841/8192$	$841/32768$	$29/256$	0
4	$127/64$	$-65/64$	$4225/8192$	$4225/32768$	$-65/256$	$-65/128$

数据梯度相加为 $(-9/32, -33/64)$ ，惩罚梯度为 $(29/128, 49/128)$ ，总梯度为 $(-7/128, -17/128)$ 。 $F_2 = 1573/8192$ ，惩罚为 $1621/8192$ ， $J_2 = 1597/4096 = 0.389892578125$ 。虽然已很接近 $17/44$ ，梯度还不为零。独立审计使用Fraction逐项核对三张表和两次更新，不把同一个梯度函数当作自己的答案。




图2 同一四行在三个状态下的预测及标签，与数据损失、惩罚和总目标同时展示。惩罚增大与总目标下降可以同时发生。

6 解析解与迭代解应当怎样比较

解析方程是参照，不意味着应显式计算逆矩阵。实际采用OLS的SVD最小二乘，以及Ridge的增广最小二乘：

$$\tilde{X} = \begin{pmatrix} X/\sqrt{n} \\ \sqrt{\lambda}I \end{pmatrix}, \quad \tilde{y} = \begin{pmatrix} y/\sqrt{n} \\ 0 \end{pmatrix}, \quad \min_w \frac{1}{2} \|\tilde{X}w - \tilde{y}\|^2.$$

展开右侧恰为 J_λ 。另一条独立库路线是scikit-learn的Ridge。其目标为SSE加 α 乘系数平方和，故本讲必须传 $\alpha=n*\lambda$ ，而非直接传 λ [2]。四行 $\lambda=1/2$ 对应 $\alpha=2$ 。复制每行两次后平均目标不变，但库 α 应变为4。




图3 OLS与Ridge具有不同最优点。两幅图中的蓝线都是本讲Ridge手算轨迹；左图故意把它放在OLS等高线上，提醒不能用错误目标判断是否解对。

比较时同时给出：目标公式、归一化、参数约定、独立参照的数值秩、参数距离、训练预测距离和梯度残差。在秩亏OLS中，沿零空间移动可以改变参数而不改变预测，所以只比系数可能错误判失败。相反，共线性很强时近似相同训练预测也不能证明系数稳定。

7 目标差与梯度残差之间缺少哪一个常数

令 w_* 为同一目标的最优点，误差 $e = w - w_*$ 。展开二次型并用 $H_\lambda w_* = c$ 消去交叉项：

$$J(w) = \frac{1}{2} w^\top H_\lambda w - c^\top w + C,$$

$$J(w) - J(w_*) = \frac{1}{2} e^\top H_\lambda e, \quad g = H_\lambda e.$$

若 $0 < \mu = \lambda_{\min}(H_\lambda) \leq \lambda_{\max}(H_\lambda) = L$ ，谱分解将它们写成 $\sum_j d_j e_j^2 / 2$ 与 $\sum_j d_j^2 e_j^2$ 。逐项使用 $\mu \leq d_j \leq L$ 得到

$$\frac{\|g\|^2}{2L} \leq J(w) - J(w_*) \leq \frac{\|g\|^2}{2\mu}, \quad \|e\| \leq \frac{\|g\|}{\mu}.$$

若 μ 极小，梯度很小也允许参数误差很大；若 $\mu=0$ ，后一组含 $1/\mu$ 的界不可使用。对奇异OLS可限制到有正曲率的列空间方向，零空间误差本来不可识别。不能把“梯度小”无条件翻译成“真实系数找到了”。




图4 一维特征方向的两个曲率例子。曲率为0.0001时，参数距离可以很大，而函数差和梯度都很小；尺度和强凸常数是证书的一部分。

程序同时保存直接相减的目标差与二次型差。靠近最优点，两个相近浮点数相减可能得到微小负值；二次型通常更适合展示非负差。但它仍依赖数值参照和Hessian，不能被称为精确实数证书。测试在多个点核验两者以及上下界，容差清楚记录。

8 梯度检查是一个有边界的实验

在三个非驻点 $(0.2, -0.4)$ 、 $(0.8, 0.1)$ 、 $(-0.3, 0.7)$ 上，沿每个坐标计算

$$d_j(h) = \frac{J(w + he_j) - J(w - he_j)}{2h}, \quad E(h) = \frac{\|g - d(h)\|_2}{\max(1, \|g\|_2)}.$$

e_j 是坐标基向量； h 是检查导数的扰动，不是学习率。本讲按 $10^{-2}, 10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$ 扫描。二次函数的中央差分没有三阶截断项，因此小 h 主要受到消减误差影响；不要把本图当作一般函数必有某种U形曲线的证明。




图5 三个非驻点上的正确梯度与故意反号梯度。差分变小不一定更准确；反号错误在非零梯度点有明显不一致。

检查通过只说明函数实现和梯度在这些点一致，不能保证行配对、任务、外部数据处理都正确。039讲的广播错误可以对自身通过差分；所以这里还要Fraction行账本、独立解析消元、库目标换算、复制样本不变性和随机有理数据测试。随机测试用独立种子生成32个小问题，不挑最好一个结果。

9 公平比较先固定算法定义

压力实验有regular、collinear、scaled三种固定设计，每种120行、6特征。标签由已说明的线性公式与Gaussian噪声生成。collinear第二列近似第一列，scaled则把原始列乘以不同尺度。三个病例分别生成，不能把跨病例变化全归因于单一因素；同病例内五种求解器共享完全相同数据和目标。

每个病例预声明 $\lambda=0$ 与0.1，共30条标准运行。每条以零参数开始，最多400个记录轮次。统一停止量为

$$\rho(w) = \frac{\|X^\top(Xw - y)/n + \lambda w\|_2}{\max(1, \|X^\top y/n\|_2)} \leq 10^{-6}.$$

该尺度是本教学数据内的明确约定，不具有任意坐标变换不变性。只有满足它才标记

gradient_tolerance；耗尽预算标记 budget_exhausted。对于小批量方法，每个记录轮次后重算完整梯度再判停止，不能用噪声恰好抵消的小批量梯度冒充证书。相同400轮也不代表等成本，因此后续必须同时给实际行数与计时。

五条路线如下。

- GD: $w^+ = w - g/L$ 。L由本固定二次目标Hessian最大特征值得到。此小实验显式计算谱信息，不声称大规模训练也免费拥有L。
- 对角预条件GD: 令 $D = \text{diag}(H_\lambda)$, $L_D = \lambda_{\max}(D^{-1/2}H_\lambda D^{-1/2})$, 使用 $w^+ = w - D^{-1}g/L_D$ 。
- 小批量SGD: 每步独立等概率抽16个不同索引，不是把整份数据打乱遍历。每个记录轮次做 $\lceil 120/16 \rceil = 8$ 步，故是128次样本访问，不保证覆盖全部120行。步长为 $0.2/[L(1 + 0.05(k - 1))]$, k为记录轮次。
- Adam: 使用完整梯度, $m_t = 0.9m_{t-1} + 0.1g_t$, $v_t = 0.999v_{t-1} + 0.001g_t^2$, 分别除以 $1 - 0.9^t$ 和 $1 - 0.999^t$, 再以 $0.04\hat{m}_t/(\sqrt{\hat{v}_t} + 10^{-8})$ 更新。初始两个状态为零，平方和除法逐坐标进行。这里只核对原论文Algorithm 1的更新定义 [3], 不借用普遍收敛或胜出结论。
- Newton参照: 解 $H_\lambda \Delta = -g$, 令 $w^+ = w + \Delta$ 。对非奇异精确二次目标，代入 $g = H_\lambda(w - w_*)$ 得 $\Delta = w_* - w$, 所以实数精确算术下一步到达最优点。实现用线性最小二乘求该方向，仍需检查浮点残差与成本。

SGD每步的梯度为 $X_B^\top(X_B w - y_B)/|B| + \lambda w$ 。等概率子集使数据项条件期望等于全数据梯度，惩罚项只加一次；它不是平均以后再乘n。Adam也把Ridge项放在梯度内，不是AdamW式解耦衰减。

10 真实结果包含十二条未达标运行




图6 OLS三病例在实际梯度行访问量上的轨迹。圆点表示达到统一梯度阈值，叉号表示400轮预算耗尽；所有路径都保留。展示下限 $1e-18$ 只是对数图地板，原JSON未截断数据。

默认30条标准运行中，18条达到阈值，12条耗尽预算。所有六条小批量路径都没有在当前计划内达到 10^{-6} ；这不说明SGD不能学到有用模型，只说明不能给这次运行贴上“已达同一数值精度”的标签。固定单种子也不是随机优化器优劣的总体证据。

regular的OLS，GD用16次更新达到阈值，Adam用263次。collinear的OLS，GD、对角GD、Adam都耗尽400轮；GD最终相对梯度约 1.071×10^{-5} ，目标差约 3.420×10^{-5} ，参数距离却约6.224。这个结果正是弱曲率方向的具体提醒。

scaled的OLS，GD耗尽预算，参数距离约22.544；对角GD在11次更新达到阈值，但参数距离仍约 2.788×10^{-4} 。不同参数单位使距离数值可比性也受限制。scaled的Ridge $\lambda=0.1$ ，对角GD在8次更新达标，Adam在229次达标，普通GD和小批量仍未达标。这些都是本配置观察，不能写成五种方法的通用排行榜。

本项目保存所有初始与监测状态，不先平滑曲线，也不把失败替换为最后一次成功运行。每个结论都能定位到JSON的case、lambda、method、status和final字段。

11 预条件与改变统计模型不是同一件事

令 $w = D^{-1/2}u$ ，把原目标写成 $\tilde{J}(u) = J(D^{-1/2}u)$ 。链式法则给出 $\nabla_u \tilde{J} = D^{-1/2}g$ 。在 u 空间按 $1/L_D$ 做GD再映回 w ，正好得到上一节的对角更新式。因此它改变路径，不改变原目标的极小点集合。




图11 对角预条件的梯度仍包含原坐标Ridge惩罚。同一个目标上轨迹明显改善，不代表惩罚已经换成标准化空间中的各向同性Ridge。

若把特征除以训练标准差后，直接给新系数加同一个各向同性 λ ，原坐标惩罚通常变成不同的加权惩罚。那是040讲的统计建模选择。不能将这种模型变化的预测收益全部记为优化器加速。本项目压力实验采用原坐标目标加对角预条件；下一节的模型选择则明确采用标准化系数的Ridge目标，两者分开记录。

12 失败案例也必须收费

额外故意设置scaled的Ridge步长为 $3/L$ 。固定二次GD误差沿最大特征方向乘 $1 - \eta L = -2$ ，违反 $|1 - \eta L| < 1$ 的稳定要求。本次第一候选实际增加目标，因此拒绝并停止，保存候选与最后已提交状态。




图12 错误步长产生一个真实升高的候选。提交数为0，尝试数为1，仍发生了参照、初始和候选三次完整目标与梯度计算。

本次账本是：1次尝试、0次提交；3次完整目标与梯度调用，各360行；2次监测预测距离计算，共240行；1次Gram构造，120行；2次谱求解；1次126行的增广参照最小二乘。参照那次调用的梯度虽不用于更新，也确实被代码计算，不能从账本中消失。

这是教学故障隔离，不是带保证的线搜索。正常Adam与SGD并未被强制要求逐步下降，不能把它们的所有上升一概判作错误。真正的失败解释应说清目标、局部方向、步长、停止策略和已发生的计算。

13 从操作量走到真实耗时

设 $n \geq p$ 且矩阵稠密。一次批量梯度需要 Xw 与 $X^T r$ ，主要工作量 $O(np)$ ；一批 m 行是 $O(mp)$ ，完整监测仍要 $O(np)$ 。Adam 额外状态与逐坐标算术是 $O(p)$ 。Gram 构造是 $O(np^2)$ ，存储 $O(p^2)$ ；常规稠密线性系统或谱分解是 $O(p^3)$ 。SVD/QR 最小二乘在这个尺寸关系下约为 $O(np^2)$ ，不同形状应重新说明。

这些是量级，不是墙钟时间。BLAS 实现、内存布局、线程、循环和记录开销都重要。本实现每条路线都额外构造 Gram、两个谱参照及独立最小二乘，用于教学诊断；还保存每个状态的长度 p 参数。因此它不是面向大 n 、 p 优化的生产实现，长轨迹存储也要 $O(Kp)$ 。




图7 scaled、 $\lambda=0.1$ 下的实际更新数与独立计时。计时包括诊断求解函数内的全部工作，误差线是三次实测的最小至最大；未达标运行仍显示耗时和FAIL。

使用Python `perf_counter_ns` 的单调高分辨率计时 [4]，每配置先做1次暖机并记录其时间，再做3次串行测量，BLAS线程固定为1。时间范围包括Gram、谱、参照、完整监测、失败尝试和轨迹构造；不含文件读取、中心化、模型选择、覆盖模拟、画图、JSON写入和Python启动。它只能叫“诊断求解调用耗时”，不能叫端到端训练耗时。

这一台Linux CPU上的scaled、 $\lambda=0.1$ 三次中位数约为：GD 10.886毫秒、对角GD 0.365毫秒、小批量 70.017毫秒、Adam 7.874毫秒、Newton 0.232毫秒。GD和小批量未达标，故不能把这些数字当成“达到相同精度的全部时间”。完整原始纳秒样本、暖机与min/max均在benchmark-result.json。换机器或再次运行数字会变化；计时与确定性科学JSON分开，避免既要求字节相同又声称实时测量。

14 训练与验证锁定后才打开测试

另一个独立的合成数据包含72行训练、48行验证、120行测试。六个特征带偏移、尺度差和相关性。它不复用压力实验标签，不使用生成真系数选参。候选为标准化空间的OLS及Ridge， λ 固定为0、0.001、0.01、0.1、1、10。

训练均值 μ 、标准差 s 和标签均值只用训练行拟合。常数 s 的 s 约定为1。每个候选在同一个训练变换上求解，通过完整梯度门槛后才进入验证排名。验证MSE最小者获选，完全相等时偏好较大的 λ ，不临时增加“近似并列”规则。不在选择后重训train+validation，避免悄悄改变数据量和模型。




图8 左图只有预声明候选的验证分数，右图标出数据权限方向。序列化选择记录并计算摘要以后，测试只用于评价已锁定的预测器。

本次 $\lambda=0.1$ 获选。锁定后测试MSE约0.775054，预声明OLS基线约0.767754，后者这次略低。不能因为测试上OLS略好就重新宣布它为“验证赢家”，或追加 λ 网格把Ridge调到刚好超过它。一个正当的验证过程不保证每一次测试都击败每个基线。

实现的选择函数只接受训练、验证数组。测试数据在入口会被校验格式与有限性，但标签不参与拟合和选参；先校验可用性不等于使用标签选择模型。选择对象完整序列化后再计算SHA-256，然后才建立测试数组。篡改测试标签或特征的独立测试确认锁定对象完全不变，而最终测试误差应改变。摘要提供一致性检查，不是不可篡改的数字签名。

15 预测区间究竟给谁画

到这里仍只有点预测。为解释区间，本项目另设一个没有模型选择的固定OLS模拟。 $A \in \mathbb{R}^{n \times p}$ 包含截距列， $n = 32, p = 2$ 。假设

$$y = A\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I), \quad \text{rank}(A) = p.$$

A 视为固定，模型形式正确；新观测噪声与训练独立、同方差。OLS为 $\hat{\beta} = (A^\top A)^{-1} A^\top y$ ，于是

$$\hat{\beta} - \beta = (A^\top A)^{-1} A^\top \varepsilon, \quad \text{Cov}(\hat{\beta}) = \sigma^2 (A^\top A)^{-1}.$$

对预先固定的新设计行 a_0 ，令 $m_0 = a_0^\top \beta$ ， $\hat{m}_0 = a_0^\top \hat{\beta}$ ， $h_0 = a_0^\top (A^\top A)^{-1} a_0$ 。条件均值估计误差方差为 $\sigma^2 h_0$ ；新观测 $Y_0 = m_0 + \varepsilon_0$ 的误差为 $Y_0 - \hat{m}_0$ ，独立性使方差变为 $\sigma^2(1 + h_0)$ 。

多出来的1代表新观测自身的噪声，不能通过把参数估计得更精确消除。均值区间与单个新观测区间回答不同对象；NIST官方说明也作此区分 [5,6]。

16 从方差到t区间的中间环节

用残差平方和估计未知噪声： $s^2 = \|y - A\hat{\beta}\|^2 / (n - p)$ 。满秩与Gaussian假设下，投影到列空间的分量和残差空间分量正交且独立， $(n - p)s^2 / \sigma^2$ 服从 χ_{n-p}^2 ；标准化预测误差为正态，并与s独立。因此正态除以独立卡方均值的平方根给出t枢轴量：

$$\frac{\hat{m}_0 - m_0}{s\sqrt{h_0}} \sim t_{n-p}, \quad \frac{Y_0 - \hat{m}_0}{s\sqrt{1 + h_0}} \sim t_{n-p}.$$

取t分布0.975分位数q，95%均值置信区间为 $\hat{m}_0 \pm qs\sqrt{h_0}$ ，单个新观测预测区间为 $\hat{m}_0 \pm qs\sqrt{1 + h_0}$ 。数值分位数用SciPy的 `t.ppf`，明确传30自由度 [7]；不能用 `t.interval` 的分布区间直接冒充完整回归区间。




图9 前24次训练重复的均值区间与单个新观测区间，不挑覆盖漂亮的重复。黑点在左图是真实均值，在右图是各自的新观测，红线表示该次未覆盖。

这里的95%是按同一机制反复收集训练数据、构造区间的长期覆盖率，不是“已经观察到的固定区间里，固定参数有95%概率”。对未来观测可给预测概率解释，但仍依赖模型与抽样假设，不自动保证任意子群或分布外个体。

17 让一个可信公式真正失败一次

模拟固定32个 $x \in [-2, 2]$ ，真实回归为 $1 + 0.8x$ ，训练噪声标准差0.5；在固定 $x_0 = 1.5$ 预测。每次重新抽取训练噪声、拟合OLS，并独立抽一个同分布新观测。600次完整重复保存全部参数相关量、区间宽度、目标与覆盖布尔值。

实际均值区间覆盖580/600，约0.9667；正确预测区间覆盖562/600，约0.9367。这与名义0.95并不要求严格相等。若每次独立，比例的Monte Carlo标准误约为 $\sqrt{0.95(1 - 0.95)/600} \approx 0.0089$ ；偏离名义值本身不能自动宣布公式错误。




图10 把均值置信区间误当预测区间，以及把未来噪声标准差从0.5改为1.5，都会破坏对应覆盖。右图明确指出改变的是未来噪声分布，训练机制未变。

把均值区间直接用于新观测，只覆盖247/600，约0.4117。另一个压力实验保留训练机制和同一个预测区间，但把未来噪声标准差改为1.5，仅覆盖321/600，即0.535。后一例不是优化失败，而是原来同方差、同分布的条件不再成立。

不能把这个OLS公式直接移到前面的验证选参Ridge。收缩偏差、有效自由度和数据驱动选择都改变推断问题。Bootstrap也要说清重采样单位、重新做哪些预处理和选择、目标是均值还是新观察；只重采样固定模型预测不自动覆盖训练与选择的不确定性。更完整的校准、选择后推断与分布偏移方法将在047、051和Q3继续。

18 科研报告要允许哪些结论

优化层可以说：在本固定输入、目标和dtype下，行账本、梯度、独立解析或库参照一致；某些路线在声明预算内达到数值阈值。统计层可以说：按固定数据协议选出的预测器，在这一次合成封存测试上得到某个MSE；在明确Gaussian设计下，区间重复覆盖接近理论或在压力条件下失败。两层都不能推出现实因果效应。

例如，两个变量同时受未观测因素影响，回归系数可能稳定且预测很好；主动改变其中一个变量后，另一个变量的响应仍未被识别。低损失、小梯度和窄区间都不是随机化、无混杂或可干预性的替代品。若研究问题是“改变某因素是否产生结果”，必须另列识别假设及可检验设计，不能在结论末尾顺手加一句因果解释。

19 让工程证据与数学证据同样可重跑

所有原始CSV字段和JSON配置必须在任何求解、随机抽样、回调或输出前完成校验，包括最后一行标签与最后配置字段。拒绝重复键、重复ID、错列数、错形状、布尔值冒充数字、API里的数值字符串或复数、NaN/Inf、超出声明范围以及绝对值小于 10^{-150} 的非零原始数字。CSV文本通过Decimal解析，检测转换时下溢；JSON不接受非标准常量。显式异常不会在 `python -0` 中消失。

Notebook第一格先用标准库验证数据与执行文件的字节摘要，之后才导入数值、绘图模块。篡改任何契约文件都必须在第一格拒绝，不能展示残留旧结果。摘要一致性仍只是契约的一层，不取代逐行计算和统计假设。

报告写入在同一目录生成临时完整严格JSON、刷新后原子替换；注入写入失败的测试证明原文件字节保留。输出不能覆盖输入和交付资产，也拒绝符号链接、符号链接父目录及多硬链接文件。这个约定针对单用户本地实验，不声称抵御恶意并发改换文件的竞争攻击。

普通模式、优化模式与不同工作目录的新Python进程产出完整一致的确定性JSON。实际Notebook由新进程中的真实InProcessKernel顺序运行，保留文本及PNG；这不等于测试了Jupyter浏览器UI、网络内核传输或Anaconda安装。所有PDF要按实际页数逐页目视，图像与公式不能仅靠文本提取验收。

20 项目练习与验收问题

1. 从原始四行独立算出H、c、OLS与 $\lambda=1/2$ 的Ridge参照，不调用矩阵求逆。
2. 重算两个完整更新及三个前向状态，列出每行局部导数与平均梯度贡献。
3. 证明二次型目标差恒等式及上下界，说明 $\mu=0$ 时哪一步失效。
4. 构造两个系数不同但预测相同的秩亏OLS解，区分不可识别与代码错误。
5. 解释Ridge的库alpha换算与样本复制实验，并设计一个遗漏n的反例。
6. 在三个非驻点做梯度扫描，解释为什么单一驻点不是足够的测试点。
7. 推导对角预条件与坐标变换的等价性，解释为何不等于直接换成标准化Ridge。
8. 逐项写出Adam首步与SGD无偏条件，指出当前SGD“轮次”不是完整遍历。
9. 用默认结果写一段优化比较，至少包含一条预算耗尽路径、参数误差和预测误差的差别。
10. 核算故障路径的成本，说明为什么0次提交不能记作0次计算。
11. 给出复杂度与计时边界；为什么Newton一次更新不能单凭次数宣布普遍更快？
12. 设计测试标签篡改检查；面对测试OLS略好于验证选中Ridge，应怎样报告？
13. 从OLS协方差推导均值区间与预测区间中的h和1+h，以及n-p自由度。
14. 用600次覆盖记录解释抽样波动、错用均值区间和未来噪声偏移三种现象。
15. 为什么不能给验证选择后的Ridge直接附上本讲OLS t区间，也不能凭回归系数作因果解释？
16. 制定能自动拒绝坏尾字段、输出覆盖、Notebook契约篡改的验收，并写下一项可证伪扩展研究。

一手来源与阅读边界

[1] [NumPy 2.3 lstsq](#): 最小范数、rcond、数值秩和返回残差的约定。

[2] [scikit-learn 1.8 Ridge](#): 目标、alpha与svd求解器；[官方数据泄漏说明](#): 训练变换与未见数据处理。

[3] [Kingma与Ba Adam原论文](#)：实际核对Algorithm 1的状态、偏差修正和epsilon位置。未将论文全部理论或实验结论作为本项目的保证。

[4] [Python 3.12 time](#)：计时接口。文档当前维护补丁版与本机Python3.12.14补丁号不完全相同，接口语义实际核对。

[5] [NIST Estimation](#)；[6] [NIST Prediction](#)：均值和未来测量的不确定性对象区别。

[7] [SciPy 1.17.0 t分布](#)：自由度、分位数与分布语义。来源于2026-10-04实际检查；推导、数据、图与教学代码独立编写，不附第三方全文。