

第042讲 练习详解

本详解使用本讲新主例 $x=(-2,-1,1,2)$ 、 $y=(0,1,0,1)$ 。参数顺序为 $\theta=(b,w)$ ，平均损失 $F=\Sigma \ell_i/4$ 。数据均为原创合成例。近似小数以 $\approx$ 标明；初始分数与后续超越数分开。

1 从odds到logit

对 $0 < p < 1$ ， $\text{odds}=p/(1-p) > 0$ 。若 $\log \text{odds}=b+x^T w$ ，指数化得 $p/(1-p)=\exp(z)$ 。两边乘 $1-p$ ，移项得 $p[1+\exp(z)]=\exp(z)$ ，所以 $p=1/(1+\exp(-z))$ 。

增加特征 x_j 一单位而其他量保持，使 $\log \text{odds}$ 增加 w_j ， odds 乘 $\exp(w_j)$ 。概率变化是 $\sigma(z+w_j)-\sigma(z)$ ，依赖原 z ，绝不是固定 w_j 。极小变化时偏导为 $w_j p(1-p)$ 。这些是模型中的条件关联，不是干预的因果效应；若换特征单位，系数也随之改变。

2 似然怎样变为损失

条件于 X ，假定各标签独立且 $y_i \in \{0,1\}$ ，单行质量 $p_i^{y_i}(1-p_i)^{1-y_i}$ 。联合似然是乘积，取 $\log$ 把乘积变成求和；负号把最大化似然转成最小化，再除以固定正数 n 不改变极值位置：

$$F = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

这要求所有分类任务都采用该模型。依赖标签、错设 $\log\text{-odds}$ 或有选择的采样会影响概率解释和统计推断。准确率是另一个含阈值的离散指标；不能用准确率代替这份连续似然目标做导数。

3 三段导数的完整消去

令单行 $\ell = -y \log p - (1-y) \log(1-p)$ 。在 $0 < p < 1$ 内， $\partial \ell / \partial p = -y/p + (1-y)/(1-p)$ ， $\partial p / \partial z = p(1-p)$ 。相乘得到 $-y(1-p) + (1-y)p = p - y$ 。最后 $\partial z / \partial b = 1$ 、 $\partial z / \partial w = x$ ，所以该行的平均梯度贡献为 $[(p-y)/n, (p-y)x/n]$ 。

数学链正确不代表按这三次浮点计算最稳。 p 舍入到1时，先求 $1/(1-p)$ 可能无穷，再乘0不安全。实现直接使用 $y=0$ 时 $\sigma(z)$ 、 $y=1$ 时 $-\sigma(-z)$ 。局部链在普通状态逐项展示；极端状态的不可表示局部倒数记null，稳定总导数仍可计算。

4 两种softplus表达的差异

数学上 $\log(1+e^z)-yz$ 等于 $\text{softplus}(-(2y-1)z)$ 。原始 $\exp(z)$ 在很大正 z 时溢出；即使改为稳定 $\text{softplus}(z)$ ，再减 z 也会把正确正类的小尾项相消。 $z=40$ 时真实损失 $\approx 4.248354255 \times 10^{-18}$ ， $\text{softplus}(40)-40$ 在binary64中可能为0。

signed表达先决定正确margin，再算 $\max(u,0)+\log 1p(\exp(-|u|))$ ，没有大数相减。正确 $z=1000$ 时真实尾项约 e^{-1000} ，binary64无法表示而下溢为0是另一回事。不能用相同“0”把提前相消和不可表示的极小尾项混为一类。

5 第一轮四行完整链

$\theta^0=(0,0)$ ，所以每行 $z=0$ 、 $p=1/2$ 、 $\ell=\log 2$ 、平均损失贡献 $\log 2/4$ 。局部 $dp/dz=1/4$ 。以下所有梯度贡献已除以4：

行	x,y	$d\ell/dp$	$d\ell/dz$	Jacobian	对b贡献	对w贡献
B1	-2,0	2	1/2	(1,-2)	1/8	-1/4
B2	-1,1	-2	-1/2	(1,-1)	-1/8	1/8
B3	1,0	2	1/2	(1,1)	1/8	1/8
B4	2,1	-2	-1/2	(1,2)	-1/8	-1/4

两列求和给 $g=(0,-1/4)$ ， $\eta=1/2$ ， $\theta^1=\theta^0-\eta g=(0,1/8)$ 。平均在梯度中只做一次，不能每行除4后汇总又除4。所有行用同一 θ^0 ；逐行立即改w是另一种更新算法。

6 第二轮总梯度与局部导数

令 $a=\sigma(1/4)\approx.5621765008857981$ ， $q=\sigma(1/8)\approx.5312093733737563$ 。四行 $p=(1-a,1-q,q,a)$ ，梯度残差 $(p-y)=(1-a,-q,q,a-1)$ 。截距贡献互相抵消。斜率平均贡献之和为

$$g_w = \frac{-2(1-a) + (-1)(-q) + q + 2(a-1)}{4} = a - 1 + \frac{q}{2}.$$

它约为 $-.17221881242732377$ 。四行局部 $d\ell/dp$ 分别为 $1/a$ 、 $-1/(1-q)$ 、 $1/(1-q)$ 、 $-1/a$ ； dp/dz 分别为 $a(1-a)$ 、 $q(1-q)$ 、 $q(1-q)$ 、 $a(1-a)$ 。逐行相乘正好得到上述稳定残差。

$F_1=[\text{softplus}(-1/4)+\text{softplus}(1/8)]/2\approx.6667692275980063$ 。因此 $w_2=1/8-g_w/2\approx.21110940621366188$ ， $b_2=0$ 。先计算旧梯度，再同时提交两个新参数。

7 第二轮之后的四行新前向

用新 w_2 重新计算，不复用旧p。下面为打印小数，内部110位参照和float计算有明示容差：

行	新z	新p	新 ℓ	新d ℓ /dz	对b平均贡献	对w平均贡献
B1	-.422218812	.395985930	.504157786	.395985930	.098996482	-.197992965
B2	-.211109406	.447417790	.804262467	-.552582210	-.138145552	.138145552
B3	.211109406	.552582210	.804262467	.552582210	.138145552	.138145552
B4	.422218812	.604014070	.504157786	-.395985930	-.098996482	-.197992965

局部d ℓ /dp依次为1/.604014070、-1/.447417790、1/.447417790、-1/.604014070。dp/dz为p乘稳定补概率：两端约.239181073，中间约.247235111。每行这些局部量相乘得到表中d ℓ /dz，再乘[1,x]/4。总 $F_2 \approx .6542101267359844$ ， $g_2 \approx (0, -.11969482505055372)$ ，没有到最优。

两个中间标签与正斜率相冲突，损失从log2上升；两端损失下降更多，所以均值下降。似然优化不承诺每个样本都同时受益。

8 Hessian的逐行外积

由 $\nabla F = \sum (p-y)a/n$ ，进一步微分时a和y不变，得 $H = \sum p(1-p)aa^T/n$ 。初始各行权重1/4、n=4，每行贡献 $aa^T/16$ ：

$$H_0 = \frac{1}{16} \left[\begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix} + \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} \right] = \begin{pmatrix} 1/4 & 0 \\ 0 & 5/8 \end{pmatrix}.$$

后续H不是常量。在b=0截面令 $u = \sigma(2w)\sigma(-2w)$ ， $v = \sigma(w)\sigma(-w)$ ，则 $H_{bb} = (u+v)/2$ 、 $H_{ww} = 2u+v/2$ 、 $H_{bw} = 0$ 。行级曲率权重不含y，但z取决于用标签拟合得到的参数，因此不能说整体拟合结果与标签无关。

9 凸性、严格凸与存在性

对任意方向h， $h^T H h = \sum p_i(1-p_i)(a_i^T h)^2/n \geq 0$ 。有限数学 θ 下权重全正；若A满列秩，则任意非零h至少有一个 $a_i^T h$ 非零，故 $h^T H h > 0$ 。于是F严格凸，至多存在一个有限极小点。

“至多一个”不等于“至少一个”。简单严格凸函数 e^{-w} 在实轴有下确界0但无有限最小点；本讲完全分离的logistic损失给更贴近任务的反例。若有限驻点已经找到，凸性才能把它提升为全局最小；满秩再给唯一性。

10 光滑上界与步长

因为 $0 < p(1-p) \leq 1/4$ ，对任何h有 $h^T H h \leq h^T A^T A h / (4n)$ ，即矩阵半正定次序 $H \leq A^T A / (4n)$ 。因此可取 $L = \lambda \max(A^T A / n) / 4$ 。本例 $A^T A / n = \text{diag}(1, 2.5)$ ， $L = .625$ ， $\eta = .5$ 小于 $1/L = 1.6$ ，满足常用保守下降条件。

下降引理给 $F(\theta - \eta g) \leq F(\theta) - \eta(1 - L\eta/2) \|g\|^2$ 。它是全局确定性梯度与所述范数下的结论；特征换尺度后 L 改变，不能把 .5 复制到任意问题。加入斜率 λ 时光滑上界需相应加入惩罚 Hessian，而不是沿用旧 L 不解释。

11 第一-Newton方向

解 $H_0 \delta = -g_0$ ，得到 $\delta_b = 0$ 、 $(5/8)\delta_w = 1/4$ ，即 $\delta_w = 2/5 = .4$ 。一次完整 Newton 候选 $\theta = (0, .4)$ 接近有限最优斜率 .4196，但不等于它。

原因是 Newton 只令当前位置二次近似的梯度为 0，真实 H 随 θ 改变。下一次仍要用新概率、新梯度和新 Hessian。代码解方程，不显式形成 H 逆；正定移位和回溯保证不盲目接受非下降方向。病态、秩亏或浮点饱和处要保留失败或停滞状态。

12 从三次方程独立确认有限MLE

主例对称使 $b=0$ 时 $g_b=0$ 。设 $t=e^w>0$ ，代入斜率方程：

$$\frac{t^2}{1+t^2} - 1 + \frac{t}{2(1+t)} = 0.$$

第一项减 1 等于 $-1/(1+t^2)$ 。移项并乘正分母得 $t(1+t^2)=2(1+t)$ ，即 $t^3-t-2=0$ 。在 $[1,2]$ 上，值从 -2 到 4，导数 $3t^2-1 \geq 2$ ，所以恰有一个根。 $t \leq 1$ 时原式为负，故正域没有遗漏的根。

110 位二分给 $w = \log t \approx .419617624991097899534$ 。将它和 $b=0$ 代回完整 g 确实为 0； A 满列秩和严格凸确认唯一有限全局最优。概率约 (.301696, .396608, .603392, .698304)，阈值 .5 仍只判对 B_1 、 B_4 。独立方程是存在证书，库系数只是对照。

13 完全分离的极限证明

另一个数据集标签是 $(0,0,1,1)$ 。取 $\theta_s = (0,s)$ ， $s>0$ ，各行正确 margin 为 $s|x|$ 。每个有限 s 的损失 $\log(1+\exp(-s|x|))$ 严格正。 $s \rightarrow \infty$ 时每项趋 0，有限项平均也趋 0。

因此 $F \geq 0$ 且下确界为 0，但没有任何有限 θ 能令所有单行 Bernoulli 负对数似然为 0，故不存在有限 MLE。不是“训练失败才不存在”；一个优化器可以在 $s=64$ 附近因梯度很小停止，仍不改变这个统计结论。参数范数、margin、Hessian 谱一起看，才能分清数值停止和存在性。

14 单类与斜率L2

$J = F + \lambda w^2/2$ 只惩罚 w 。若 y 全 1，取 $w=0$ 、 $b \rightarrow +\infty$ ，惩罚一直 0，损失趋 0；若 y 全 0，取 $b \rightarrow -\infty$ 同理。单独斜率正则不能阻止截距逃逸。

两类均出现、有限样本、 $\lambda > 0$ 时，斜率惩罚使 $|w|$ 不能沿有界目标序列无穷增大； w 有界后，若 $|b| \rightarrow \infty$ ，另一类至少一个样本的损失将无穷增大，所以目标的次水平集有界，连续性给有限最小点。这一存在论证用到两类和正 λ ，不能把它推广到任意未正则秩亏模型。拟合入口先拒绝单类，而`row_ledger`允许单行，用于数学测试。

15 代价阈值与并列

给定 p ，判1的风险是 $C_{FP}(1-p)$ ，判0的风险是 $C_{FN}p$ 。要求前者不大于后者，整理为 $C_{FP} \leq (C_{FP} + C_{FN})p$ 。当非负代价且和为正时， $p \geq C_{FP}/(C_{FP} + C_{FN})$ 。两者都为0时所有行动风险相同，公式0/0不适用。

$C_{FP}=1$ 、 $C_{FN}=4$ 时阈值.2；等代价才给.5。并列时本讲选正类是约定，不是似然推导的必要结论。真正部署还要求概率适用于当前人群和条件风险；分布偏移或失准会使计算出的风险不可靠。本实验没有用测试标签搜索阈值。

16 线性概率的OLS

x 均值0、 y 均值1/2，因此含截距OLS的 $b=1/2$ 。斜率 $\sum x_i(y_i - 1/2)/\sum x_i^2 = 1/10 = .1$ 。训练范围给(.3,.4,.6,.7)，看似与logit很接近，但 $x=10$ 预测1.5，超出概率范围。

把1.5裁到1改变输出规则；它不会让平方损失拟合自动成为Bernoulli最大似然，也不能直接继承logistic模型的方差公式。logit输出合法范围是形式约束，不是校准或泛化的证明。

17 n 、 λ 与 C 的换算

本讲 $J = F + \lambda w^2/2$ ，官方无权平均损失目标是 $F + w^2/(2nC)$ 。对齐系数得到 $\lambda = 1/(nC)$ ，即 $C = 1/(n\lambda)$ 。 $\lambda=0$ 的极限用 $C=np.inf$ ，不能除0。

$n=4$ 、 $\lambda=.25$ 给 $C=1$ 。复制所有样本使 n 变8， F 均值不变；要保持 $\lambda=.25$ 就用 $C=.5$ 。真实重复拟合已核对相同 θ 。若用`class_weight`或`sample_weight`，官方分母使用总权重 S ，必须重新核对 S 与归一化，不能继续盲用行数 n 。

18 类别列、截距与警告

本例`classes_`真实为 $[0,1]$ ，第二列`predict_proba`才对应1。`decision_function`应等于 $b + wx$ ，sigmoid后与正类概率一致。截距`fit_intercept=True`且`lbfgs`不惩罚截距；`liblinear`的合成特征约定另有区别，未实际测过的solver不能声称等价。

真实`sklearn`1.8运行未正则与 $\lambda=.25$ 两个模型，`n_iter_`均为4，重新计算本讲目标梯度约 10^{-13} 量级。 $C=np.inf$ 当前发出忽略 C 和`l1_ratio`的`UserWarning`，保存在结果中；它不等于`ConvergenceWarning`。本讲另外构造完全零`coef/intercept`的控制probe，库`predict`给0，而 $p \geq .5$ 给1；这不冒充拟合出的近零截距。

19 差分与极端尾项

在 $(.3, -.2)$ 、 $(-.4, .7)$ 、 $(.1, .4)$ 三个非驻点，分别对 b 、 w 使用 $[F(\theta+he_j)-F(\theta-he_j)]/(2h)$ ，扫描 $h=10^{-2}$ 至 10^{-6} 。Hessian-vector使用 $[\nabla F(\theta+hv)-\nabla F(\theta-hv)]/(2h)$ ， $v=(.6, -.8)$ 。大 h 截断误差、小 h 消减误差，所以不要求每缩小一次 h 都更好。

额外80个随机二进有理设计用110位Decimal独立指数/对数验证目标、 g 、 H 和PSD外积恒等式；整条默认GD路径69状态也逐行核对。极端 ± 40 、 ± 740 、 ± 1000 使用1100位参照。比较可表示的尾项时使用相对误差且不靠宽松绝对容差把错误0判对；当真实值转换到float后确为0，才认可表示范围内的下溢。

20 失败与运行契约

预算1有合法末状态但没有第二轮，`second_update=null`；初始驻点0次更新； $\eta=100$ 产生被拒绝候选，0次提交仍有初始和候选2次状态尝试。注入“内部已算完后抛异常”，尝试仍为2而成功返回为1，不能因trace短就抹去已发起的工作。

原始输入先拒绝bool、字符串、复数、非有限、过大/过小值、长double非零转float0、错误shape、非0/1或拟合单类。所有配置字段包括最后一个字段都验证，保护逻辑不依赖assert。CSV重复ID和JSON重复键也拒绝。内部合法迭代不会重新应用原始初始参数 ± 100 盒，因此从原始0更新到 $w=500$ 可作为数值状态记录。

JSON完整序列化后才创建目录和临时文件，最后`os.replace`提交；失败时旧文件不变，临时文件清理。禁止覆盖源码、输入、教材文件、符号链接及多重硬链接。真实Notebook首格逐文件篡改测试验证在数值导入和PNG前失败。普通/-O/不同cwd/新内核的科学JSON相同是已测试条件下的可重复证据，不是所有CPU、BLAS、操作系统都字节相同的承诺。