

第043讲 练习完整详解

1 互斥类别和多标签

一个互斥例子是把人工生成图形按预先定义的外轮廓分为圆、三角、四边形，每张图恰好一种轮廓。样本单位是一张图，类别必须覆盖本任务的合法图形，并排除同时符合两个类别的含混定义。三个条件概率和为1。

一个多标签例子是“含红色”“含文字”“有阴影”，同一图可以同时满足三项。边缘概率和可能大于1。分别做sigmoid只保证各概率在[0,1]；若把三个Bernoulli项相乘，是对联合条件分布的一种分解假设，不能自动表示标签依赖。先定义事件，再决定似然。

2 三个得分的手算

$z=(\log 2, 0, \log 3)$ ，指数为(2,1,3)，分母6，所以 $p=(1/3, 1/6, 1/2)$ 。真实类分别为甲、乙、丙时，单行负对数损失依次 $\log 3$ 、 $\log 6$ 、 $\log 2$ 。真实类乙的得分梯度为(1/3, -5/6, 1/2)，分量和0。

它的Jacobian对角为(2/9, 5/36, 1/4)，非对角 $J_{01}=-1/18$ 、 $J_{02}=-1/6$ 、 $J_{12}=-1/12$ ，矩阵对称。局部损失导数为(0, -6, 0)，乘Jacobian得到上面的得分梯度，这给出与直接p-t不同的核验路线。

3 平移与参照类

$\text{softmax}(z+c)$ 的分子为 $e^c e^{z_k}$ ，分母为 $e^c \sum_j e^{z_j}$ ，相约后不变。对概率比，分母再次相约， $p_k/p_r = e^{z_k - z_r}$ ，取log得差值。

若最后一类为r，令 $\tilde{\theta}_k = \theta_k - \theta_r$ ，则 $\tilde{\theta}_r = 0$ 。转成零和表示时，令 $\bar{\theta} = \sum_k \theta_k / K$ ，各列减去它。两者保留所有类间差值。若比较系数先不做这个对齐，就可能把同一预测器误判成不一致。

4 条件独立似然

每行one-hot t只在真实类位置为1，故 $\prod_k p_{ik}^{t_{ik}} = p_{i, y_i}$ 。给定X后独立，似然为所有行相乘。负log变成每行真实类负log之和，除n形成平均，得到正文目标。

相同x的行可合成计数，Multinomial组合系数计入排列数，但不依赖模型参数。它会改变完整概率质量或未省常数的数值，不改变对参数的梯度。不能把有不同输入的一批行先合并成一个总体类别直方图，再称为原条件模型的同一个似然。

5 局部链和矩阵形状

令分母S为所有指数之和。对自身得分求商法则给 $e^{z_k}(S - e^{z_k})/S^2 = p_k(1 - p_k)$ ；对另一类得分只有分母变化，给 $-e^{z_k}e^{z_j}/S^2 = -p_k p_j$ 。

真实类损失的导数 $-1/p_y$ 乘Jacobian的第 y 行，对真实类得 $-(1-p_y)$ ，对其他类得 p_j 。把得分对参数的导数 $\partial z_k / \partial \Theta_{rk} = a_r$ 接上，每行平均参数贡献为 $a_r(p_k - t_k)/n$ 。A.T形状 $(d+1, n)$ ，P-T形状 (n, K) ，结果 $(d+1, K)$ 与参数一致。

6 第一轮八行的全部平均梯度

初始每行损失 $\log 3$ ，贡献 $\log 3/8$ 。下表三个数以列顺序甲乙丙给出；表中的整数三元组统一除24。

行	截距梯度贡献乘24	斜率梯度贡献乘24
M1	(-2,1,1)	(2,-1,-1)
M2	(-2,1,1)	(2,-1,-1)
M3	(1,-2,1)	(-1,2,-1)
M4	(1,1,-2)	(-1,-1,2)
M5	(-2,1,1)	(-2,1,1)
M6	(1,-2,1)	(1,-2,1)
M7	(1,1,-2)	(1,1,-2)
M8	(1,1,-2)	(1,1,-2)

八行截距三元组之和为 $(-1, 2, -1)$ ，斜率之和为 $(3, 0, -3)$ ，分别除24即总梯度。减去 $3/5$ 倍梯度得到 $b^1 = (1/40, -1/20, 1/40)$ ， $w^1 = (-3/40, 0, 3/40)$ 。

重新前向 $x = -1$ 得到 $(4, -2, -2)/40$ ， $x = 1$ 得到 $(-2, -2, 4)/40$ 。前者减最大值后 $(0, -.15, -.15)$ ，其概率 (A, B, B) ，后者 (B, B, A) 。这一步不能还用原来的 $1/3$ 。

7 第二轮的符号汇总

对 b ，预测概率跨八行平均为 $((A+B)/2, B, (A+B)/2)$ ，标签频率为 $(3/8, 1/4, 3/8)$ 。因此首尾梯度为 $(A+B)/2 - 3/8$ 。利用 $A+2B=1$ 化成 $(1-4B)/8$ ，中间为 $B-1/4$ 。

对 w ，甲类的预测项是 $(B-A)/2$ 。标签项平均 $\sum_i x_i t_{i0} / 8 = (-2 + 1) / 8 = -1/8$ ，相减得到 $1/8 - (A-B)/2$ 。乙类预测项与标签项都为0；丙类由对称性取甲类相反数。

带入 $A \approx .367455772041282$ 、 $B \approx .316272113979359$ 得正文数值。第二轮更新后

$b^2 \approx (.0448816341938077, -.0897632683876154, .0448816341938077)$ ，

$w^2 \approx (-.134644902581423, 0, .134644902581423)$ 。每个坐标都使用第二轮旧参数及旧梯度，不在同一轮内混入刚更新的其他坐标。

8 第二轮新前向与逐行外积

两组新得分为 $(.179526536775231, -.0897632683876154, -.0897632683876154)$ 及首尾交换。相应 $A_2 \approx .395594083530423$ 、 $B_2 \approx .302202958234788$ 。每行局部损失导数是 y 位置的 $-1/A_2$ 或 $-1/B_2$ ，其他位置0；每行Jacobian按当前 p 的 $\text{diag}(p) - pp^T$ 计算。

例如M3真实类乙，局部向量为 $(0, -1/B_2, 0)$ 。其Jacobian的乙行是 $(-A_2 B_2, B_2(1-B_2), -B_2^2)$ ，乘后为 $(A_2, B_2 - 1, B_2)$ ，即 $(.395594083530423, -.697797041765212, .302202958234788)$ 。乘 $(1, -1)$ 的列外积并除8给下面M3整行。

行	新损失/8	截距平均贡献	斜率平均贡献
M1	.115920829	$(-.075550740, .037775370, .037775370)$	$(.075550740, -.037775370, -.037775370)$
M2	.115920829	$(-.075550740, .037775370, .037775370)$	$(.075550740, -.037775370, -.037775370)$
M3	.149582055	$(.049449260, -.087224630, .037775370)$	$(-.049449260, .087224630, -.037775370)$
M4	.149582055	$(.049449260, .037775370, -.087224630)$	$(-.049449260, -.037775370, .087224630)$
M5	.149582055	$(-.087224630, .037775370, .049449260)$	$(-.087224630, .037775370, .049449260)$
M6	.149582055	$(.037775370, -.087224630, .049449260)$	$(.037775370, -.087224630, .049449260)$
M7	.115920829	$(.037775370, .037775370, -.075550740)$	$(.037775370, .037775370, -.075550740)$
M8	.115920829	$(.037775370, .037775370, -.075550740)$	$(.037775370, .037775370, -.075550740)$

表格为九位显示近似，求和时使用完整数值。八行损失贡献和 1.062011537613334 ；截距和约 $(-.0261014791173942, .0522029582347884, -.0261014791173942)$ ，斜率和 $(.0783044373521826, 0, -.0783044373521826)$ 。与状态中的总梯度逐项核对，不能只比较范数。

第一状态的全部局部Jacobian同理： $x=-1$ 用 $p=(A, B, B)$ ， $x=1$ 用 $p=(B, B, A)$ ，取真实类对应行乘 $-1/p_y$ 。三个前向状态的24行完整矩阵及外积都在真实Notebook输出中保留。

9 方差证明与零方向

将 u 视为类别上取值 u_k 的随机变量，按 p 加权， $u^T(\text{diag}(p) - pp^T)u$ 就是 $E[u^2] - E[u]^2$ ，所以非负。如果所有 u_k 相同，方差0，对应共同平移方向。

均匀三类 J 等于 $I/3 - 11^T/9$ ，作用在1方向得0，作用在与1正交的任意向量上得该向量的 $1/3$ ，因此谱为 $(0, 1/3, 1/3)$ 。这是代数证书，不是仅看一次eigvalsh数值。有限 p 各项正时，除共同常数外的方向方差正；参数级还需检查设计矩阵秩。

10 有限最优点的构造

对 $x=-1$, $q^-= (1/2, 1/4, 1/4)$, $\log$ 概率为 $(-\log 2, -2\log 2, -2\log 2)$, 减三类均值后为 $(2\log 2/3, -\log 2/3, -\log 2/3)$ 。 $x=1$ 时首尾交换。

两组相加除2得到 $b=(\log 2/6, -\log 2/3, \log 2/6)$, 相减除2得到 $w=(-\log 2/2, 0, \log 2/2)$ 。数值约
 $b=(.115524530093324, -.231049060186648, .115524530093324)$,
 $w=(-.346573590279973, 0, .346573590279973)$ 。

两组交叉熵各至少为自己的熵；以上模型恰好同时实现两组频率，所以达到整个目标下界 $1.5\log 2$ 。概率唯一来自KL的等号条件；原参数可共同平移，零和表示才唯一。单纯有三类都出现不够证明任意特征设计有限MLE存在，本例还利用了每个相同 x 处三类都出现及可构造的线性表示。

11 怎样报告不成功状态

正确报告是：“默认GD85步满足完整梯度阈值；BFGS16次迭代返回precision loss且
 $\text{success}=\text{False}$ ，重算残差约 $7.52\text{e}-11$ ，概率与独立解析解接近。”不能删掉message，也不能把小残差当作库曾成功返回的证据。

若重算残差也大，应继续查归一化、形状、局部导数、停止预算与病态，而不是解释成正常。精度损失并不总无害，本例是因为还拥有完整解析证书，才有另一条明确的数值质量依据。训练准确率 $1/2$ 也保留，它与负对数似然达到最小不是矛盾。

12 对数底与步长

换底公式 $\log_2 t = \ln t / \ln 2$ ，所以以bit为单位的损失与梯度都是nat版本的 $1/\log 2$ 倍。如果想保留相同参数更新 $\theta - \eta g$ ，bit版本学习率应乘 $\log 2$ ；直接保持原学习率则不是同一条迭代路径。

模型最小点不受正常数缩放影响，但阈值、正则强度和停止条件可能受影响。若只缩放数据损失而不缩放惩罚，甚至整个最优目标也会改变。

13 信息论数值展开

$q=(.5,.3,.2)$ 时，熵为 $-.5 \log .5 - .3 \log .3 - .2 \log .2 \approx 1.029653014064574$ 。交叉熵将三个log内部改为 $(.7,.2,.1)$ ，仍用 q 作权重，约 1.121685864298405 。

正向KL为 $.5 \log(.5/.7) + .3 \log(.3/.2) + .2 \log(.2/.1)$ ，约 $.092032850233832$ 。第一项可以为负，KL非负是求和后的性质，不是每个原始 $q \log(q/p)$ 项都非负。

反向为 $.7 \log(.7/.5) + .2 \log(.2/.3) + .1 \log(.1/.2)$ ，约 $.085122825957222$ 。正反向不同，不能靠交换名称使它对称。交叉熵减熵与直接求和结果可能在末位稍有不同，验收使用明示容差。

14 非负性与熵上界

函数 $t-1-\log t$ 在 $t=1$ 取得唯一最小值0，故 $\log t \leq t-1$ 。在 $S=\{k:q_k>0\}$ 中若任何 $p_k=0$ ， $KL=+\infty$ ；否则将 $t=p_k/q_k$ 代入、乘 q_k 并求和，得到 $-D \leq \sum_S p-1 \leq 0$ 。

等号必须同时满足 $p_k=q_k$ 对 S 成立，且 p 在 S 外没有质量，所以全向量 $p=q$ 。 q 含零项时， $\sum_S p$ 不一定等于1，这一中间不等式不能漏掉。令 p 为均匀向量， $D=\log K-H(q)$ ，使得 $H(q) \leq \log K$ 与均匀取等。

15 零支持与输出表示

$q=(1,0,0)$ 、 $p=(0,.5,.5)$ 时，按 q 唯一会发生的甲类负log概率为 $+\infty$ 。把 p 甲设成epsilon后得到 $-\log \epsilon$ 是一个有限近似，而非原问题的有限值。程序通过null及infinite_cross_entropy_and_kl=True保存含义，保持严格JSON可读。

$q=p=(1,0,0)$ 时，唯一非零权重项为1乘log1，其余项按极限约定为0，故熵、交叉熵、KL都为0。这里不是把log0当0，也不是让数值库先计算0乘无穷再隐藏NaN。

16 软目标与未归一化权重

$\ell = -\sum_k q_k [z_k - \log \sum_j e^{z_j}]$ 。对 z_r 求导为 $-q_r + p_r \sum_k q_k$ 。 q 归一化时才简化为 $p_r - q_r$ 。

若 $q=(2,1,1)$ ，权重和4，那么导数为 $4p-q$ ，而不是 $p-q$ 。将 q 除4同时使损失除4，这是明确的目标缩放；它会影响学习率与正则相对强度。课堂API只接受本来就为1的分布，不会把任意计数偷偷当概率归一化。

17 三个常见数值与接口错误

错误轴：两个样本一起用axis=None，得到全表和为1，每行通常小于1。恢复axis=1后逐行概率和为1。错误log路线： $(1000,0,-1000)$ 的概率可能是 $(1,0,0)$ ，先log后两项变 $-\infty$ ；直接稳定log概率约 $(0,-1000,-2000)$ ，保留有限的错误类损失。

重复softmax： $p=(.8,.1,.1)$ 已经是概率，将它作为logits再次归一化后约 $(.5017,.2491,.2491)$ ，最大类未变，但置信度与对数损失明显变了。数值必须按实际函数重算，不能因为argmax相同就认定目标相同。

进一步尾项： $(0,-40,-40)$ 的正确损失为 $\log_{1p}(2e^{-40})$ ，约 $8.496708511e-18$ 。普通 $\log(\sum(\exp))$ 可能返回0。最大值平移解决溢出，不自动解决所有相消；采用 $\log_{1p}$ 的本讲路线和高精度参照可以发现这个差别。

18 分层验收清单

科学层先核对类别定义、Categorical似然、平均因子、参数形状、两轮同步账本、解析概率和支持集证明。数值层检查非驻点差分、独立高精度、概率行和、类别排列、共同平移、可表示尾项，并区分舍入与数学零值。

控制层检查输入最后一项、零/短预算、初始驻点、被拒绝候选及失败尝试成本。工程层检查普通与-O、新工作目录、新内核、原子输出和首格摘要契约。图像层逐页看最终PDF与实际PNG，文件存在或文本提取成功不证明图可读。

失败解释要具体：precision loss是成熟优化器的数值停止状态；训练准确率1/2来自当前模型和重叠标签；错误轴是实现错误；无穷KL来自预测支持缺失。四者不能全部写成“数据不好”。