

# 第043讲 多分类与信息论损失

## 1 本讲解决什么问题

第042讲把一个实数得分变成二分类概率。如果一次观察恰好属于甲、乙、丙之一，三个概率就必须共同分配同一份总量。我们需要同时回答：怎样归一化、怎样由标签形成似然、怎样把误差传给每一类的参数，以及损失为什么与熵和KL有关。

直接先修018至019、023、039、042。读者应能解释条件概率、期望、似然与负对数，认得向量的每个分量，并完成042的一次批量更新。偏导和矩阵链若不熟，可回看014。本讲会把局部求导重新展开，不把矩阵公式当作先修记忆题。

先完成三类纸笔计算，再运行八行原创数据，最后用有限最优点和高精度参照检查实现。这里的“独立参照”指另一条可检查的计算路线；它不同于使用未见数据评价泛化。本讲全部数据是教学机制例，不含现实个人记录，也不据此宣称真实任务性能。

## 2 互斥多类与多标签先分清

互斥多分类中，每行只有一个标签。例如我们先定义三种互不重叠的人工图形类别，标签编码0、1、2只是类别名字，不表示大小关系。标签为2不意味着它比0“大两倍”。条件概率需要满足  $p_k \geq 0$  且  $\sum_{k=0}^{K-1} p_k = 1$ 。

多标签则允许一张图同时有“圆形”“红色”“带文字”。这三个事件不互斥，边缘概率通常不需要相加为1。对每个标签分别使用Bernoulli模型是一种建模选择；把三个Bernoulli似然相乘还额外采用了给定输入后的条件独立分解，并非所有多标签依赖都被表达。




图1 相同得分分别经过softmax和三个sigmoid。右侧概率和大于1不是多标签模型的错误；若任务互斥，就不能把右侧直接当三类分布。

读图问题：如果允许一行同时具有甲、丙两个标签，左侧“只分一份概率质量”的解释还适用吗？反过来，把三个sigmoid再除以其和，是否仍在优化原来的Bernoulli似然？答案是否定的，输出规则与训练目标都要重新说明。

### 3 由得分到softmax

设一行有 $d$ 个实数特征，扩展行向量为  $\mathbf{a}^\top = (1, x_1, \dots, x_d)$ 。参数矩阵  $\Theta \in \mathbb{R}^{(d+1) \times K}$  的第 $k$ 列属于第 $k$ 类，第0行是各类截距。得分与概率为

$$z_k = \mathbf{a}^\top \theta_k, \quad p_k = \frac{e^{z_k}}{\sum_{j=0}^{K-1} e^{z_j}}.$$

指数保证每项正，除以同一个分母保证总和为1。数学上有限得分给严格正的的概率；浮点数可能把极小概率舍成0，后文会把这两件事分开。softmax输出不是“挑出最大项”的硬选择，所有类一般都有正概率。

先做不涉及训练的例子： $z = (\log 2, 0, \log 3)$ ，则指数为(2,1,3)，分母6，概率为(1/3, 1/6, 1/2)。若真实类是乙，即 $y=1$ ，单行负对数损失是  $-\log(1/6) = \log 6$ 。先写清类别列顺序，才能取对真实类的概率。

### 4 共同平移与参数不唯一

对同一行三个得分同时加 $c$ ，分子分母都乘  $e^c$ ，约去后概率不变。因而概率只反映类与类的得分差。取任意两类 $k$ 和 $r$ ，有

$$\log \frac{p_k}{p_r} = z_k - z_r = \mathbf{a}^\top (\theta_k - \theta_r).$$

若给所有参数列同时加一个向量 $\mathbf{v}$ ，每行得分共同增加  $\mathbf{a}^\top \mathbf{v}$ ，所有预测仍不变。因此不加约束的 $K$ 列参数没有唯一表示。可以把最后一类参数固定为0作为参照类，或令每个参数行的 $K$ 列和为0。本讲主GD从零开始，梯度的每个参数行理论和为0，所以保持零和表示；浮点末位可能有微小偏差。

参数相差一个共同向量不等于预测算法不同。与库对照时，要先对齐表示，或先比较概率、得分差与目标，不能直接把两套原系数相减后宣布错误。参照类为0与零和表示只改变坐标；若再加惩罚，必须检查惩罚是否也按同一统计目标转换。




图2 三类概率有一个和为1的约束，因此处于三角形内。右图共同平移前后各类柱高一致；三角形位置取决于概率而非原始得分的绝对零点。

读图问题：为什么三类概率只能在二维三角形里变化？把所有截距加1000会让模型更“自信”吗？共同平移不会，而只放大类间差异一般会。

## 5 Categorical似然怎样形成交叉熵

定义one-hot向量  $t_k = \mathbf{1}\{y = k\}$ 。一行只观察到一个类别，Categorical概率质量可以写成  $\prod_k p_k^{t_k}$ 。在给定所有输入X后假设各行标签条件独立，样本似然是各行概率质量相乘。负对数把乘法变加法，除以n得到平均目标

$$F(\Theta) = -\frac{1}{n} \sum_i \sum_k t_{ik} \log p_{ik} = -\frac{1}{n} \sum_i \log p_{i,y_i}.$$

这就是one-hot目标的交叉熵。这里不再加  $\log(n!)$ ：每一行的输入可能不同，观察是有行身份的独立Categorical结果。若把相同条件下的观察合并成类别计数，用Multinomial描述计数，出现的组合系数与参数无关，在拟合时才可以说明后省略。

同一正确类别，预测概率0.9的损失小于0.6；但若模型自信地给错误类别0.99，就会把真实类概率压得很低并承担较大损失。准确率只看最大概率类别，交叉熵还检查分给真实答案的概率大小，两者不能互相代替。

## 6 稳定计算必须沿正确的轴

一批得分Z有n行K列。每行先减自己的最大值  $m_i = \max_k z_{ik}$ 。于是

$$\log p_{ik} = (z_{ik} - m_i) - \log \sum_j e^{z_{ij} - m_i}.$$

减去最大值后指数的输入不大于0，避免巨大正指数溢出。必须沿类别轴逐行归一化；把整个  $n \times K$  矩阵当作一个向量，会让全表总和为1，却使一行概率和不为1。某些库默认axis=None，必须明确传axis=1。

还有一个细节：如果得分为(0,-40,-40)，普通计算  $\log(1 + 2e^{-40})$  可能先把括号舍入到1，给正确类损失0。代码选择一项最大指数1，将它移出和，再用log1p计算  $\log(1 + s)$ ，其中s是其余指数之和，保留可表示的小正损失。这不改变目标，只改代数求值顺序。

不要先计算可能下溢为0的概率再取log。比如(1000,0,-1000)的第三类log概率约为-2000，仍是有限可表示的数；概率本身可能下溢为0。也不要悄悄把p裁到epsilon：裁剪是一种不同数值规则，会改变损失以及在边界处的导数。

## 7 把局部导数逐条接起来

记  $S = \sum_j e^{z_j}$ 。商法则给同类导数

$$\frac{\partial p_k}{\partial z_k} = \frac{e^{z_k} S - e^{2z_k}}{S^2} = p_k(1 - p_k),$$


异类导数为  $\partial p_k / \partial z_j = -p_k p_j$ ，因为分子不随  $z_j$  变，分母会变。合起来的Jacobian为  $J_p = \text{diag}(p) - pp^\top$ 。矩阵第k行第j列表示“第j类得分变化怎样影响第k类概率”，不要把行列反过来。

一行损失  $\ell = -\log p_y$  只对真实类概率有导数： $\partial \ell / \partial p_y = -1/p_y$ ，其他分量为0。接上Jacobian：若  $j=y$ ，结果为  $-(1 - p_y) = p_y - 1$ ；若j不等于y，结果为  $p_j$ 。故

$$\delta = \frac{\partial \ell}{\partial z} = p - t, \quad \frac{\partial F}{\partial \Theta} = \frac{1}{n} \sum_i a_i \delta_i^\top = \frac{1}{n} A^\top (P - T).$$

形状检查： $a_i$ 为 $(d+1) \times 1$ ， $\delta_i^\top$ 为 $1 \times K$ ，外积为 $(d+1) \times K$ 。不能逐元素乘两个不同形状的数组靠广播猜答案。每一行贡献含 $1/n$ ，最后求和；或者先求和再除 $n$ ，两者只能选一种，不能漏除或除两次。

极端情况下  $-1/p_y$  可能超出浮点范围。代码用已经化简的导数，不实际相乘一个无穷局部导数与零Jacobian。为保留胜出真实类的小梯度，它把真实类分量写成负的其他类概率之和。Notebook把不可表示的局部导数记为null，并保留稳定导数，绝不把null当成数学上的0。



## 8 八行主例的第一轮旧前向

本讲用同一组八行贯穿全部手算。只有一个特征x，所有数据固定，不再做缩放；类别顺序甲、乙、丙对应0、1、2。参数两行为b和w，各有三个分量。令初始参数全0，学习率  $\eta = 3/5$ ，没有正则项。

| 行  | x  | y | 初始真实类概率 | 初始得分梯度 $\delta$ |
|----|----|---|---------|-----------------|
| M1 | -1 | 0 | 1/3     | $(-2, 1, 1)/3$  |
| M2 | -1 | 0 | 1/3     | $(-2, 1, 1)/3$  |
| M3 | -1 | 1 | 1/3     | $(1, -2, 1)/3$  |

| 行  | x  | y | 初始真实类概率 | 初始得分梯度 $\delta$ |
|----|----|---|---------|-----------------|
| M4 | -1 | 2 | 1/3     | (1,1,-2)/3      |
| M5 | 1  | 0 | 1/3     | (-2,1,1)/3      |
| M6 | 1  | 1 | 1/3     | (1,-2,1)/3      |
| M7 | 1  | 2 | 1/3     | (1,1,-2)/3      |
| M8 | 1  | 2 | 1/3     | (1,1,-2)/3      |

全部旧logit为(0,0,0)，概率为(1/3,1/3,1/3)，每行损失 $\log 3$ ，平均贡献 $\log 3/8$ 。局部损失导数是真实类位置的-3；共同Jacobian对角2/9，非对角-1/9。二者相乘恰好给表中 $\delta$ 。

每行截距贡献为 $\delta/8$ ，斜率贡献为 $x\delta/8$ 。例如M1分别为 $(-2,1,1)/24$ 与 $(2,-1,-1)/24$ ；M5截距相同，斜率符号相反。将八行分别相加得到

$$g_b^0 = (-1/24, 1/12, -1/24), \quad g_w^0 = (1/8, 0, -1/8).$$

截距梯度也可以由类别频率核验：三类频率是(3/8,1/4,3/8)，用(1/3,1/3,1/3)减它即得 $g_b^0$ 。同步更新所有参数得到

$$b^1 = (1/40, -1/20, 1/40), \quad w^1 = (-3/40, 0, 3/40).$$

“同步”意味着先让所有行用同一旧参数贡献梯度，再一次更新。逐行更新后再算下一行是另一种优化轨迹，不是本讲的full-batch手算。

## 9 第一次新前向与第二次梯度

在 $x=-1$ 处，新得分为(0.1,-0.05,-0.05)； $x=1$ 处为(-0.05,-0.05,0.1)。记

$$A = \frac{e^{0.15}}{e^{0.15} + 2} \approx 0.367455772041282, \quad B = \frac{1}{e^{0.15} + 2} \approx 0.316272113979359.$$

所以前四行概率(A,B,B)，后四行概率(B,B,A)，且 $A+2B=1$ 。下面的 $\delta$ 要再分别除8形成截距贡献、乘 $x/8$ 形成斜率贡献，每一行都参与汇总。

| 行  | 真实类概率 | 单行损失        | $\delta_0$   | $\delta_1$   | $\delta_2$   |
|----|-------|-------------|--------------|--------------|--------------|
| M1 | A     | 1.001152316 | -0.632544228 | 0.316272114  | 0.316272114  |
| M2 | A     | 1.001152316 | -0.632544228 | 0.316272114  | 0.316272114  |
| M3 | B     | 1.151152316 | 0.367455772  | -0.683727886 | 0.316272114  |
| M4 | B     | 1.151152316 | 0.367455772  | 0.316272114  | -0.683727886 |
| M5 | B     | 1.151152316 | -0.683727886 | 0.316272114  | 0.367455772  |

| 行  | 真实类概率 | 单行损失        | $\delta_0$  | $\delta_1$   | $\delta_2$   |
|----|-------|-------------|-------------|--------------|--------------|
| M6 | B     | 1.151152316 | 0.316272114 | -0.683727886 | 0.367455772  |
| M7 | A     | 1.001152316 | 0.316272114 | 0.316272114  | -0.632544228 |
| M8 | A     | 1.001152316 | 0.316272114 | 0.316272114  | -0.632544228 |

每行的局部损失导数仍只在y处为 $-1/p_y$ ；Jacobian用当前p重新构造，不能沿用初始的2/9和-1/9。比如M1的第一Jacobian行为  $(A(1-A), -AB, -AB)$ ，乘 $-1/A$ 得  $(A-1, B, B)$ ，与表一致。

八行中四行真实类概率A、四行B，因此  $F_1 = -(\log A + \log B)/2 \approx 1.076152315758658$ 。汇总可化简为

$$g_b^1 = ((1-4B)/8, B-1/4, (1-4B)/8),$$

$$g_w^1 = (1/8 - (A-B)/2, 0, (A-B)/2 - 1/8).$$

数值分别为 $(-0.033136056990, 0.066272113979, -0.033136056990)$ 和 $(0.099408170969, 0, -0.099408170969)$ 。用旧  $b^1, w^1$  同步减去0.6倍梯度，得到第二次新参数

$$b^2 \approx (0.044881634194, -0.089763268388, 0.044881634194),$$

$$w^2 \approx (-0.134644902581, 0, 0.134644902581).$$

## 10 第二次更新之后再算八行

$x=-1$ 的新得分约为 $(0.179526536775, -0.089763268388, -0.089763268388)$ ， $x=1$ 时首尾交换。新概率记为  $A_2 \approx 0.395594083530423$ 、 $B_2 \approx 0.302202958234788$ ，分别组成  $(A_2, B_2, B_2)$  与  $(B_2, B_2, A_2)$ 。

| 行  | 新损失         | $\delta_0^2$ | $\delta_1^2$ | $\delta_2^2$ | 斜率贡献          |
|----|-------------|--------------|--------------|--------------|---------------|
| M1 | 0.927366635 | -0.604405916 | 0.302202958  | 0.302202958  | $-\delta^2/8$ |
| M2 | 0.927366635 | -0.604405916 | 0.302202958  | 0.302202958  | $-\delta^2/8$ |
| M3 | 1.196656440 | 0.395594084  | -0.697797042 | 0.302202958  | $-\delta^2/8$ |
| M4 | 1.196656440 | 0.395594084  | 0.302202958  | -0.697797042 | $-\delta^2/8$ |
| M5 | 1.196656440 | -0.697797042 | 0.302202958  | 0.395594084  | $\delta^2/8$  |
| M6 | 1.196656440 | 0.302202958  | -0.697797042 | 0.395594084  | $\delta^2/8$  |
| M7 | 0.927366635 | 0.302202958  | 0.302202958  | -0.604405916 | $\delta^2/8$  |
| M8 | 0.927366635 | 0.302202958  | 0.302202958  | -0.604405916 | $\delta^2/8$  |

截距贡献始终为  $\delta^2/8$ ，各行平均损失贡献为表中损失/8。此时  $F_2 \approx 1.062011537613334$ ；总截距梯度约为  $(-0.026101479117, 0.052202958235, -0.026101479117)$ ，总斜率梯度约为  $(0.078304437352, 0, -0.078304437352)$ 。它们还不是0，不能把两次教学更新称为已经拟合完毕。

详解按八行给出第二状态的全部数值平均梯度，Notebook则保留三个状态的全部局部矩阵和行外积。文本表中小数只是显示近似；指数和对数产生的数不能因为打印了九位，就当成精确的九位有理数。




图4 两次同步更新和三个前向状态。四行损失降低，另四行反而升高，平均目标仍降低；同一x对应冲突标签，模型不能让每一行都获得概率1。

读图问题：如果只检查M3的一行损失，为什么会误判优化失败？如果忘了重新前向，右图会错误呈现怎样的三组柱？

## 11 曲率与零方向为何出现

单行损失对得分的Hessian也是  $J_p$ 。任意向量  $u$  有

$$u^\top J_p u = \sum_k p_k u_k^2 - \left( \sum_k p_k u_k \right)^2 \geq 0,$$

右边正是按类别分布  $p$  计算的  $u$  值方差，所以非负。由线性得分的复合，负对数似然对参数也是凸函数。但  $J_p \mathbf{1} = 0$ ，所有类共同变化的方向没有曲率，这正对应参数共同平移的不识别。

在均匀三类处，Jacobian 对角为  $2/9$ 、非对角为  $-1/9$ ，特征值为  $0$ 、 $1/3$ 、 $1/3$ 。并非出现零特征值就该给求解器随意加巨大惩罚；先检查是不是已知的冗余表示。固定参照类可以移除共同平移方向，但如果特征本身秩亏，仍可能有其他零方向。

凸性保证有限驻点是全局最小点，却不保证有限驻点存在。与042一样，完全分离数据可能让参数一直增大、损失逼近下确界。必须给当前例子单独的存在依据，不能把一次软件返回当成定理。




图5 均匀三类Jacobian及其谱。两个差异方向可以改变概率，共同平移方向不能；0特征值在这里是模型表示的性质。

## 12 用计数独立找出本例最优解

在 $x=-1$ 处四个标签的经验频率为  $q^- = (1/2, 1/4, 1/4)$ ； $x=1$ 处为  $q^+ = (1/4, 1/4, 1/2)$ 。对任意预测分布 $p$ ，每组平均负对数似然是相应的交叉熵。第15节将证明它至少为该组熵，且只有 $p=q$ 时取等。

现在直接构造能同时达到这两个分布的线性得分。把每组log概率减去它的三类平均，得到零和得分  $z^-, z^+$ ；用  $b = (z^+ + z^-)/2$ 、 $w = (z^+ - z^-)/2$ ，因为 $x$ 只取 $\pm 1$ ，两个条件都满足。整理得

$$b^* = (\log 2/6, -\log 2/3, \log 2/6), \quad w^* = (-\log 2/2, 0, \log 2/2).$$

所有参数有限，代回概率恰为两个经验频率。两组熵均为  $(3/2) \log 2$ ，故最小平均损失约为 1.039720770839918。这条路线没有使用GD终点，是独立证书。所有类别在每个 $x$ 处都有正计数，才能得到这组有限log概率。若某组频率为0，不能直接对0取log并继续声称有限解。

概率在两个观测 $x$ 处唯一；原参数因共同平移仍不唯一。零和约束与两个不同的 $x$ 一起确定本例的唯一零和表示。这里只证明这八行，不能把结论推广为任意多分类设计都存在有限MLE。

## 13 数值拟合与不成功状态一起报告

从零实现的GD在预声明学习率0.6、最多600步、梯度范数阈值  $10^{-10}$  下完成85次更新。完整保留86个前向状态，每个状态都有八行概率、损失、局部Jacobian与平均梯度贡献。最终概率与解析证书一致，误差处于声明数值容差内。

第二条数值路线把最后一类参数固定为0，用SciPy BFGS拟合同一平均目标，再转换成零和表示。实际返回success=False，消息为“Desired error not necessarily achieved due to precision loss.”，共16次迭代。重算完整梯度范数约  $7.52 \times 10^{-11}$ ，参数和概率接近解析证书。我们保留失败状态和这一独立残差，不把它改名成库成功，也不事后放宽库停止标准以制造漂亮记录。

训练预测对 $x=-1$ 选甲，对 $x=1$ 选丙，八行只对四行，训练准确率1/2；乙类在所有训练行都不是最大概率类。这个结果不是代码错误，经验频率本来就重叠。它也提醒我们，概率拟合、最大概率分类与每类召回回答不同问题。后续046会系统学习分类指标。




图6 平均损失接近解析最小值，梯度逐渐减小。右图保留BFGS非成功状态；一次不成功返回与具体数值接近可以同时存在。

## 14 熵是什么以及单位为何重要

若离散随机结果按 $q$ 发生，事件 $k$ 的信息量定义为 $-\log q_k$ ，稀有事件的信息量更大。熵是它的期望：

$$H(q) = - \sum_k q_k \log q_k.$$

我们全讲使用自然对数，单位是nat。改用以2为底的对数，所有熵、交叉熵、KL都除以 $\log 2$ ，单位为bit；最优概率不变，但损失和梯度整体缩放，若学习率不相应变化，迭代轨迹会变。

约定 $0 \log 0 = 0$ 来自极限 $u \log u \rightarrow 0$ 。这不是把 $\log 0$ 定义为0，而是该加权项的连续延拓。确定性分布如(1,0,0)熵为0；三类均匀分布熵为 $\log 3$ 。熵描述分布的不确定性，不是模型是否正确的评分：一个极自信但错误的模型自身熵很低。

本例两组经验分布熵为 $1.5 \log 2$ ，解释了最小平均损失为什么不为0。虽然每一条记录的one-hot标签熵为0，但同一 $x$ 出现冲突答案，单个预测函数必须给这些行共享同一个分布，无法逐行随意指定概率1。

## 15 交叉熵与KL的恒等式

假设真实抽样分布为 $q$ ，预测分布为 $p$ ，并且对所有 $q_k > 0$ 都有 $p_k > 0$ 。按 $q$ 抽样，却用 $p$ 评估信息量，其期望为交叉熵

$$H(q, p) = - \sum_k q_k \log p_k.$$

KL散度定义为

$$D_{\text{KL}}(q \| p) = \sum_{k: q_k > 0} q_k \log \frac{q_k}{p_k}.$$

把对数比拆成 $\log q - \log p$ ，得到  $D(q||p) = H(q, p) - H(q)$ 。因此 $q$ 固定时，优化交叉熵与优化正向KL只差一个与模型参数无关的常数。若 $q$ 也随参数变化，这个“常数”论证就不成立，不能机械丢掉 $H(q)$ 。

取  $q = (0.5, 0.3, 0.2)$ 、 $p = (0.7, 0.2, 0.1)$ ： $H(q)$ 约1.029653014，交叉熵约1.121685864，KL约0.092032850。注意期望权重是 $q$ ，不是 $p$ 。交换顺序后，既改变对数比也改变各类别权重。




图7 左侧直接展示交叉熵等于熵加KL。右侧两个分布的类别权重不同，两个方向的KL约0.092033与0.085123，不能称为对称距离。

## 16 不省略支持集的非负性证明

先证明  $\log t \leq t - 1$  对 $t > 0$ 成立。令  $f(t) = t - 1 - \log t$ ，导数  $1 - 1/t$  在 $t < 1$ 时负、 $t > 1$ 时正，故 $t=1$ 是全局最小值且值0。这也是严谨的证明链，不只是画图看到曲线在上方。

令 $S$ 为 $q$ 正概率的类别集合。若 $S$ 中有  $p_k = 0$ ，对应KL为正无穷，非负性立即成立。否则逐项使用不等式：

$$-D(q||p) = \sum_{k \in S} q_k \log \frac{p_k}{q_k} \leq \sum_{k \in S} (p_k - q_k) = \sum_{k \in S} p_k - 1 \leq 0.$$

所以KL非负。等号要求每个 $S$ 中的  $p_k/q_k = 1$ ，而且 $p$ 在 $S$ 外没有额外质量，因此 $q=p$ 。这里特意保留  $\sum_S p_k \leq 1$ ，不能在 $q$ 含零项时无理由把它写成必然等于1。

若 $p$ 取 $K$ 类均匀分布 $u$ ， $D(q||u) = \log K - H(q) \geq 0$ ，于是熵最多 $\log K$ ，只有均匀分布达到。取 $p=q$ 则交叉熵最小为 $H(q)$ ，这也补齐第12节的解析最优证书。

## 17 非对称性与零概率的后果

在上一节例子中， $D(q||p) \approx 0.092032850$ ，而  $D(p||q) \approx 0.085122826$ 。KL通常不对称，也不满足一般距离的三角不等式，因此称为“散度”更准确。我们不需要把它包装成几何距离，才能用它比较模型分布。

若  $q = (1, 0, 0)$  而  $p = (0, 1/2, 1/2)$ ，事件甲真实必发生，模型却给0概率，交叉熵和正向KL均为正无穷。程序输出null加明确的infinite标记，而不是把JSON写成非标准Infinity，也不会把0裁到epsilon后假装得到原始KL。

当q的某项为0，q加权的该项记0，不能计算0乘log0得到NaN后再用nanmean偷偷忽略。正向和反向对零支持的反应不同；有限KL也不保证所有现实上重要但q没有覆盖的事件都处理正确。经验分布没观察到某类别，不等于真实总体概率就是0。




图8 左图逐渐缩小p甲而保持q甲=0.5，正向KL不断增加，反向曲线不同。右图沿三类分布的一条切线验证熵上界，峰值在三类相等处。

读图问题：p甲精确为0时，左图正向曲线该填哪个有限值？不能填有限值；图只画正epsilon，边界要用“正无穷”单独说明。

## 18 软目标与多余的softmax

若目标是一条固定分布q而非one-hot，单行交叉熵为  $-\sum_k q_k \log p_k$ 。只要q非负且和为1，局部推导给  $\partial \ell / \partial z_j = p_j - q_j$ 。如果错误地把未归一化权重q直接代入，则导数变成  $p_j \sum_k q_k - q_j$ ，不再是  $p - q$ 。

标签平滑是把one-hot改成某个非退化分布，例如  $(1 - \epsilon)t + \epsilon u$ 。它改变目标和统计解释，不能把改后的训练损失直接与原one-hot损失当同一指标比较；测试时也要明确使用哪个评分。本讲只推这个关系，不把标签平滑效果当作已实验验证的结论。

还有常见错误：损失接口本来接受原始logits，却先手动softmax，再把概率当作新logits传进去。实际变成  $\text{softmax}(p)$ ，再次压缩类间差异，目标与梯度都变了。阅读API时必须分清接口要得分、log概率还是概率，不能只看名字里都有“交叉熵”。

## 19 怎样逐层核验实现

先用精确Fraction验证初始梯度和第一次同步更新。再用独立Decimal指数和对数核验完整GD路径的86个状态、每行概率、损失、局部Jacobian和平均梯度。它没有调用核心softmax来当自己的真值。

在两个非驻点做多个步长的中心差分，检查六个参数方向；只在最优点检查零梯度不够。另检查非方阵、单样本、2至7类实例、类别排列等价、概率行和、共同平移和Jacobian零方向。普通范围与SciPy softmax、log\_softmax、entropy交叉核对；极端尾项另用1000位Decimal，避免仅以宽松绝对容差把错误0当正确的小数。




图9 左图梯度差分扫描展示截断与消减的权衡；右图显示普通指数和的损失舍入先于指数下溢。图中不把0画成任意小正数。

代码明确接受有限教学范围：原始X和参数绝对值不超过100，非零原始数至少  $10^{-100}$ ；n为1至2000、d为1至20、K为2至20。独立softmax入口得分范围为 $\pm 10000$ 。内部合法迭代不重新套初始参数盒。概率函数要求输入本来就是分布，仅对不超过  $10^{-12}$  的求和舍入作显式归一化。极接近相等的KL可能有舍入误差，不能把接近机器精度的小差异解释为统计证据。

保护逻辑使用显式异常，python -O不会取消。坏末行、重复ID、重复JSON键、bool伪数字、非有限值都在开始拟合前拒绝。零预算、短预算、初始驻点、首步被拒绝分别记录；不存在第二轮就写null。故障前已尝试的前向算入成本，成本数字不冒充FLOPs或墙钟。

## 20 练习与下一步

1. 给一个互斥三类任务和一个多标签任务，说明样本单位与类别事件。
2. 手算(log2,0,log3)的softmax、三个真实类别各自的损失。
3. 证明共同平移不变性，推两类log概率比和参照类变换。
4. 从条件独立Categorical模型推平均损失，说明为何不随意加入组合系数。
5. 从商法则推Jacobian，再逐分量接上损失导数，得到p-t。
6. 完整重算初始八行梯度、第一次同步更新与新前向。
7. 从A、B表达式推第二轮汇总梯度，不只复制小数。
8. 重算第二次更新后的八行损失、局部导数与全部参数梯度。
9. 用方差解释Jacobian半正定，指出共同平移零方向。
10. 用两组经验频率构造有限最优点，区分概率唯一和参数唯一。

11. 解释GD达到阈值而BFGS返回precision loss时应该怎样报告。
12. 推自然对数与二进制对数的换算，说明学习率为什么也受缩放影响。
13. 手算给定 $q$ 、 $p$ 的熵、交叉熵和两个方向的KL。
14. 包含零支持的情况下证明KL非负及等号条件，再推熵上界。
15. 分析真实概率为正、预测为0时的损失以及JSON表示。
16. 推软目标 $p-q$ ，说明 $q$ 未归一化时需要改哪一项。
17. 复现错误轴、先取log概率和重复softmax三个错误。
18. 设计能够区分科学错误、数值错误、控制流错误的验收清单。

接下来的044把这些模型放进广义线性模型语言，045则从概率走向代价敏感决策。学会本讲不意味着所有多分类任务都适合线性得分，也不意味着训练交叉熵低就已校准；这些假设都要在新的数据与评价流程里继续检验。

## 一手来源与阅读范围

- Stanford CS229原课程讲义3.2.3节，印刷页30至34，核对互斥类别概率、参照类表示与softmax似然。八行数据、两轮账本与有限最优点推导为本讲原创。[课程讲义](#)
- SciPy 1.17.0官方softmax与log\_softmax文档，核对类别轴、平移稳定性和直接log概率接口。微小赢者尾项的本讲实现另以高精度核验，不声称与所有库余项逐bit相同。[softmax](#)；[log\\_softmax](#)
- SciPy 1.17.0 entropy文档，核对熵、相对熵、对数底与输入归一化约定；本讲分布入口的严格范围与该库接受任意非负权重的默认行为不同。[entropy](#)
- MIT 6.441原课程Lecture 2，核对Jensen、熵的凹性与均匀分布最大熵；本讲使用log不等式自行证明KL非负，没有据此宣称实现互信息、数据处理不等式或Fano界。[课程原讲义](#)