

第044讲 广义线性模型练习详解

本册对应正文20题，也给出实验中的关键判断。答案使用参数顺序 (b, w) ，均值 μ ，预测子 η ，学习率 $\alpha = 0.2$ 。所有小数为展示用近似，源代码与Notebook保留完整实际计算值。

1 观测与均值不是同一种对象

Poisson观测支持集是非负整数；有限log链接下条件均值在 $(0, \infty)$ ，预测子在数学上可为任意实数。实现把预测子限制为 $[-30, 30]$ ，那是数值支持范围，不能反过来写成概率模型的理论定义。

均值0.6次表示相同条件下反复观察的平均次数，不是说某次真的发生了0.6个事件。也不能据此只给0或1分配概率：Poisson均值0.6仍给2、3等更高次数非零概率。

Bernoulli则只允许观测0或1，均值是概率，范围为 $[0, 1]$ ，有限logit参数只取内点。Gaussian观测与均值都可以为任意实数。先区分这些范围，才能理解为什么三个响应函数不同。

2 链接与反链接

图1的三个响应函数分别为 $h(\eta) = \eta$ 、 $h(\eta) = 1/(1 + e^{-\eta})$ 、 $h(\eta) = e^\eta$ 。在 $\eta = 0$ 时均值为0、0.5、1。只有中间的Bernoulli均值直接是某个二元事件的概率。

Poisson链接为 $g(\mu) = \log \mu$ ，方向从正均值到实数；反链接为指数，方向从预测子到正均值。说“先对预测子取log得到均值”把方向弄反了。输出大于1在Poisson中正常，在Bernoulli中不合法。

3 Poisson的指数族形式

从 $p(y) = e^{-\mu} \mu^y / y!$ 取指数形式：

$$p(y) = \exp[y \log \mu - \mu - \log(y!)].$$

令 $\theta = \log \mu$ ，则 $\mu = e^\theta$ 。与通式逐项对应得 $A(\theta) = e^\theta$ ， $a(\phi) = 1$ ， $c(y, \phi) = -\log(y!)$ 。这里没有一个独立可调的Poisson离散参数 ϕ 。

支持集仍必须写为非负整数；只有代数形式而不写支持集，不能完整定义分布。 A 的作用是让所有整数概率之和为1，不是额外的自由拟合系数。

4 归一化怎样给均值和方差

固定 ϕ ，假设支持集不变且允许交换运算。由 $\sum_y p(y) = 1$ ，求导得到

$$0 = \sum_y p(y) \frac{y - A'(\theta)}{a(\phi)}.$$

因此 $E(Y) = A'(\theta)$ 。连续变量把求和换成积分，逻辑相同。

再对 $E(Y) = \sum_y yp(y)$ 求导：

$$\frac{dE(Y)}{d\theta} = \frac{1}{a} E[Y(Y - A')] = \frac{E(Y^2) - E(Y)^2}{a}.$$

左侧为 A'' ，于是 $\text{Var}(Y) = aA''$ 。Poisson中 $A' = A'' = e^\theta$ ，均值与方差都等于 μ 。若模型支持集依赖参数，不能不检查条件就照搬这段交换求导。

5 读离散概率图

$\mu = 0.5$ 时 $P(Y = 0) = e^{-0.5} \approx 0.606530660$ 。 $P(Y = 1) = 0.5e^{-0.5} \approx 0.303265330$ ，所以图中零次数柱最高。均值小于1并不意味着不可能有两次以上事件。

$\mu = 5$ 时方差为5，标准差为 $\sqrt{5} \approx 2.236068$ 。均值和标准差虽然都用“次”的量纲描述，方差是平方量纲。图中尾部被截到16，明确标出的尾概率提醒读者，有限图框没有改变理论上无限的支持集。

6 从似然到优化目标

条件独立给联合似然 $L = \prod_i e^{-\mu_i} \mu_i^{y_i} / y_i!$ 。log将乘积变为和，代入 $\log \mu_i = \eta_i$ 与 $\mu_i = e^{\eta_i}$ ，再取负并平均：

$$F = \frac{1}{n} \sum_i [e^{\eta_i} - y_i \eta_i + \log(y_i!)].$$

可以在求最优参数时去掉 $\log(y_i!)$ ，因为对固定观测它不含 β 。不能去掉 e^{η_i} ：它正是依赖参数的归一化项，去掉后会失去Poisson目标。除以 n 不改变无正则最优解，却改变梯度和适合的学习率尺度。

本讲报告完整负对数似然，所以保留log阶乘。若比较别人的去常数loss，要先补回常数并对齐求和或平均约定。

7 第一轮逐行和同步更新

初值 $(0, 0)$ 给三行 $\eta = 0, \mu = 1$ 。损失为 $(1, 1, 1 + \log 6)$ ，平均 $F_0 = 1.5972531564093515$ 。

局部导数 $\partial \ell / \partial \mu = (1, 0, -2)$ ， $\partial \mu / \partial \eta = (1, 1, 1)$ ；相乘仍为 $(1, 0, -2)$ 。每行再乘预测子导数 $(1, x)$ 并除以3，得到

$$c_1 = (1/3, -1/3), \quad c_2 = (0, 0), \quad c_3 = (-2/3, -2/3).$$

相加得 $g_0 = (-1/3, -1)$ 。同步更新为 $b_1 = 0 - 0.2(-1/3) = 1/15$ ， $w_1 = 0 - 0.2(-1) = 1/5$ 。这里两个更新都使用旧参数下的整批梯度。

如果先处理第1行就改参数，第2、3行用的就不是共同的旧状态，那是不同的随机或增量更新过程，不能拿它冒充本题整批梯度下降。

8 第二轮第三行与整批梯度

新参数下第三行 $\eta_3 = 1/15 + 1/5 = 4/15$, $\mu_3 = e^{4/15} = 1.305605172065$ 。

$$\ell_3 = e^{4/15} - 3(4/15) + \log 6 = 2.297364641293.$$

导数链为 $(1 - 3/\mu_3)\mu_3 = \mu_3 - 3 = -1.694394827935$; 第一因子约为-1.297785015094。预测子导数为 $(1, 1)$, 所以该行平均梯度贡献为 $(-0.564798275978, -0.564798275978)$ 。

另外两行为 $c_1 = (0.291724439681, -0.291724439681)$, $c_2 = (0.022979701916, 0)$ 。合计

$$g_1 = (-0.250094134382, -0.856522715659).$$

平均完整损失为1.3916034664721781。第二次同步更新为

$$\beta^{(2)} = (0.116685493543, 0.371304543132).$$

只重算第三行而沿用第一轮另外两行的梯度, 是混用了不同状态, 不能通过“最后平均一下”修正。

9 新前向与单行损失增加

第二次更新后, 预测均值约为 $(0.775211758956, 1.123765942461, 1.629038619250)$, 损失为 $(0.775211758956, 1.007080448918, 1.956827978454)$, 平均为1.246373395442681。

第二行观测为1, 在初值时预测恰好也是1。对这一行而言最小损失在 $\mu = 1$, 共享参数为了减小全体损失使它的均值升高, 所以其损失从1升到1.002272439, 再升到1.007080449。这是共享参数的折中, 不是总梯度公式出错。

新的梯度为 $(-0.157327893111, -0.715391046569)$, 不接近零。图3展示两次更新、三次前向, 不能把有三个状态误数成三次更新。

10 Hessian与有限解

从 $g = X^\top(\mu - y)/n$ 出发, $\partial\mu_i/\partial\beta = \mu_i\mathbf{x}_i$, 所以

$$H = \frac{1}{n} \sum_i \mu_i \mathbf{x}_i \mathbf{x}_i^\top.$$

对任意 v , 二次型等于非负平方和, 目标凸。若 X 满列秩且所有 $\mu_i > 0$, 非零 v 至少使一个 $\mathbf{x}_i^\top v \neq 0$, 二次型严格正, 因此有限驻点唯一。

反例是含截距且所有计数为0。损失为 $\sum_i e^{b+wx_i}/n$, 让 $b \rightarrow -\infty$ 就持续下降趋0, 没有有限最小点。严格凸函数也可能只在无穷远逼近下确界。对一般混合标签设计, 本实现并没有完整的MLE存在性算法。

11 主例的解析MLE

均值写为 $(a/t, a, at)$ ，得分方程要求预测总数等于观测总数4，预测带符号和等于观测带符号和3：

$$a(1/t + 1 + t) = 4, \quad a(t - 1/t) = 3.$$

因 $a, t > 0$ ，相除再乘分母可得 $4(t^2 - 1) = 3(t^2 + t + 1)$ 。整理为 $t^2 - 3t - 7 = 0$ ，负根不满足 $t = e^w > 0$ ，故

$$t = (3 + \sqrt{37})/2, \quad a = 4/(t + 1 + 1/t).$$

于是 $b_* \approx -0.364917136586$ ， $w_* \approx 1.513231209206$ 。代回两条得分方程可直接核验梯度为0；满列秩与正均值给正定Hessian，因而是唯一全局最小点。

这是一份与数值优化器不同的参照：先用代数获得答案，再比较优化输出，而不是把同一个函数算两次称为“独立”。

12 Newton与工作响应

Newton方程为 $(X^\top W X/n)\Delta = X^\top(\mu - y)/n$ ，满步新参数为 $\beta - \Delta$ 。左右乘回去并整理：

$$X^\top W X \beta_{\text{new}} = X^\top W X \beta + X^\top(y - \mu).$$

没有offset时 $X\beta = \eta$ ，设 $z = \eta + (y - \mu)/\mu$ ，使得 $X^\top W X \beta_{\text{new}} = X^\top W z$ 。带offset o 时 $X\beta = \eta - o$ ，因此右侧为 $X^\top W(z - o)$ 。

W 和 z 随参数改变，要每轮重算。代码用 `solve` 求Newton方向，再用回溯选步长；因此某轮接受半步时，不能说它等于一次完整的加权最小二乘解。

13 Deviance与零计数

饱和行均值为 y ，对数似然差中的log阶乘抵消。两倍差为

$$d = 2[y \log(y/\mu) - y + \mu].$$

对 $y = 0$ ，使用极限 $y \log(y/\mu) \rightarrow 0$ ，得到 $d = 2\mu$ ；所以 $y = 0, \mu = 2$ 时 $d = 4$ 。这里不是删除零观测，也不是给零加1后取log。

当 $y > 0$ 而 $\mu \rightarrow 0$ ，模型把已发生的正计数赋予趋零概率，deviance趋无穷。当 $y = 0$ ，饱和参考 $\mu = 0$ 在log链接有限参数之外，只能作边界极限。图4的边界点与实际可拟合的正均值曲线要区分。

14 与完整负对数似然的关系

对同一组 y ， $F_{\text{sat}} = -\log L_{\text{sat}}/n$ 是固定常数，因此

$$\bar{D} = D/n = 2(F - F_{\text{sat}}).$$

两个模型在同一数据上按 F 排序与按 $\bar{D}$ 排序完全一致。deviance为0不意味着完整负对数似然必为0，例如 $y = 1, \mu = 1$ 的概率是 e^{-1} ，完整loss为1，饱和deviance为0。

换数据后，样本数、观测难度、饱和参考都可能改变。总D会随样本数累积，不能将320行的D与240行的D直接作为模型质量比较；平均值虽去掉样本数尺度，仍不能忽略数据分布差异。不同分布族或离散尺度也需要明确比较定义。

15 曝光量变化与单位变化

物理观察时长从0.5变为2且x不变时， $\mu = e \exp(b + wx)$ ，所以均值乘4，率不变。遗漏曝光量模型不随e改变，图6表现为水平线。

若只是把计量单位改成原来的四分之一，同样时长的数值e变成4e。为保持次数预测不变，应使用 $b' = b - \log 4$ ，斜率不变：

$$4e \exp(b - \log 4 + wx) = e \exp(b + wx).$$

A改变物理曝光，B只改单位，方向不能混淆。若将 $\log e$ 的系数自由估计，就不再承诺“曝光四倍、均值四倍”的原假设。

16 为什么率拟合必须加权

令 $r = y/e$ ，率预测 $\lambda = e^{X\beta}$ 。曝光加权目标中依赖参数部分为

$$\frac{1}{\sum e_i} \sum_i e_i [\lambda_i - r_i \log \lambda_i].$$

展开 $e_i r_i = y_i$ ，得到与计数目标依赖参数部分同一个分子。计数完整目标还含 $-y_i \log e_i + \log(y_i!)$ ，这些对参数为常数。因此 $g_{\text{rate}} = (n / \sum e_i) g_{\text{count}}$ ，无正则驻点相同。

不加权则会出现每行 y_i/e_i 对梯度的直接作用，而不是同一个计数得分，曝光短且率噪声很大的记录会被赋予不同的相对影响。加正则时还须对齐归一化，不能仅设相同数字就认为两个问题完全相同。

17 线性基线该怎样评价

线性模型使用曝光校正设计 eX ，所以拥有与offset模型相同的可观察输入。但它把单位率设成直线，Poisson情景的拟合率为 $2.421065 + 2.064828x$ 。大致在 $x < -1.1725$ 时为负。测试中53个预测非正，不能作为合法Poisson均值。

仍应完整报告其MSE6.857005和MAE1.783257，deviance写“全测试集未定义”，不要删掉53行后与别人240行的指标比较。删行改变评分人群，并且恰好删除模型失败区域。

混合情景下线性MSE17.490457与带offset Poisson的17.081238较接近，也应如实报告。图5以率为纵轴，预测率和观察率都可为非整数；它没有把分数率误当原始计数标签。

18 原始方差大为何不足以判定过度离散

用全方差公式把随机性分成相同条件内的波动与条件均值之间的差异：

$$\text{Var}(Y) = E(\mu) + \text{Var}(\mu).$$

只要不同 x 、 e 带来不同均值，第二项就可能很大。Poisson情景的原始样本方差均值比约6.185，并不是“方差等于均值”假设失败，因为那个假设是条件性的。

拟合均值后，Pearson统计将每行残差平方除以其预测均值，再以 $n - p$ 校正自由度。训练结果约1.013523，与这一正确条件模型相容；但单个值接近1也不能排除所有模型错误，需结合残差结构与采样机制。

19 Gamma-Poisson混合与其他解释

条件于 U 时， $E(Y | U) = \mu U$ ， $\text{Var}(Y | U) = \mu U$ 。再消去 U ：

$$E(Y) = \mu E(U) = \mu,$$

$$\text{Var}(Y) = E(\mu U) + \text{Var}(\mu U) = \mu + \mu^2/2.$$

$\mu = 1, 4, 10$ 时，混合方差依次为1.5、12、60；Poisson则为1、4、10。均值越大，新增的二次项越显著。图7右侧就是这两个总体公式。

离散度偏大也可能来自遗漏重要均值特征、时间或群组相关、重复记录、录入错误、结构零等。2.355146不是“负二项已证明”的标签。这个实验知道Gamma-Poisson真机制，因为它由我们生成；真实数据通常没有这份答案。

均值形式正确并不挽救错误的Poisson方差或尾部概率。稳健标准误、准似然、负二项和依赖模型解决的问题不同，需要依据任务与采样机制另行选择。

20 四种证据不能互相代替

数值实现：逐行Decimal参照、有限差分、SciPy概率质量、sklearn真实拟合与offset不变性，检查代码是否实现了所写公式。它们不证明现实生成机制正确。

优化终止：`status`、真实更新数、最后梯度范数与固定阈值说明本次数值运行是否达到标准。图8四条曲线都达到各自的梯度阈值；这不是跨目标的速度测量，也不是任意数据有限MLE存在性证明。

统计假设：支持集、均值形式、曝光量含义、条件残差与依赖结构决定随机模型是否可信。本实验混合情景故意违反Poisson条件方差，优化再充分也不会把错误方差假设变成正确。

测试泛化：保留240行测试且不用于调参，报告全部固定候选的完整指标，说明这一次生成机制下未见数据表现。真实世界分布变动、观测偏差、因果解释与高影响决策都不由本模拟自动覆盖。

若预算用尽，应写 `max_updates` 并报告当前梯度和参数，不补一个虚假的“已收敛”。若PDF或Notebook未重建检查，也不能把数值测试通过当作文件交付验收。

实验关键结果速查

- 手算完整平均loss: 1.5972531564093515、1.3916034664721781、1.246373395442681
- 两次更新参数: (0,0) 到 (0.0666666666667, 0.2), 再到 (0.116685493543, 0.371304543132)
- 解析小例MLE: 约 (-0.364917136586, 1.513231209206)
- Poisson情景带offset: 约 (0.138831200987, 1.106201582392)
- 混合情景带offset: 约 (0.186082423344, 1.204491622597)
- 两种训练Pearson离散度: 1.013523239167、2.355146014355
- 两种线性测试非正预测数: 53、56; 对应全测试deviance均未定义

科学版本、检查方法和范围见实验与源码。速查数字是固定输入下的参考，不是让学习者跳过推导或修改数据来迎合答案。