

046 分类指标与排序评价实验

这是一份可单独操作的实验手册。你将先对固定的12行不平衡数据手算，再用真实 scikit-learn 核验，最后只改变阳性率，观察 ROC 与 PR 的不同反应。本实验不训练模型，不选择部署阈值，不通过换数据追求更好成绩。预计纸笔与代码各需约一小时，基础较弱时可以分两次完成。

1 交付物和运行环境

阅读材料为 lecture.pdf、本实验册 lab.pdf、answers.pdf，三者均有可编辑 Markdown。代码入口为 experiment.py；逐步交互版本为 experiment.ipynb；audit.py 给出独立精确参照；plots.py 重建 9 张图。固定数据位于 data/review_scores.csv。data_integrity.json 保存这份数据的 SHA256，避免实验中意外改变案例。

在解压后的 046 目录打开终端。推荐使用 Anaconda/Miniconda：

```
conda env create -f environment.yml
conda activate ml046-metrics
python -c "import sys, numpy, sklearn; print(sys.version); print(numpy.__version__,
sklearn.__version__)"
```

也可以在 Python 3.12 的独立虚拟环境中安装 requirements.txt。Notebook 浏览界面需要 JupyterLab；environment.yml 已列出它。无浏览界面时，随包 execute_notebook.py 可在新的 Python 进程中启动真实的进程内 IPython 内核，依次运行全部单元并保存输出，它没有测试浏览器或网络内核传输。

已验证数值版本为 Python 3.12.14、numpy 2.3.5、scipy 1.17.0、scikit-learn 1.8.0、matplotlib 3.10.8、nbformat 5.11.1、ipykernel 7.4.0。版本输出不同不必立即断言错误，但应先对照接口端点与结果，再决定能否沿用报告。

2 先不运行代码 完成纸笔记录

编号	标签	分数
A	1	0.95
B	0	0.90
C	1	0.80
D	0	0.80
E	0	0.70
F	0	0.60
G	1	0.55
H	0	0.50
I	0	0.40
J	0	0.30
K	0	0.20
L	0	0.10

实验题 L1：使用“分数大于等于阈值”的规则，在 0.80 和 0.55 两个阈值分别把每行归入 TP/FP/FN/TN。先写编号，再数格子。对每个阈值计算 accuracy、precision、recall、F1、FPR。不要用小数近似替代全部分数运算。

检查点：0.80 的四格应为 TP = 2、FP = 2、FN = 1、TN = 7。如果不符，先查 C、D 的等号，再查矩阵的行列方向。0.55 时预测阳性有 7 件，不能把 3/7 错写成 3/12。

实验题 L2：从正无穷开始，依次把阈值降到全部不同分数。每一步只写“新进入哪几行”，再更新四格。C、D 必须一起进入；不能在它们之间虚构一个阈值。表应有 12 行，其中一个起点和 11 个有限阈值。完整答案在答案册。

3 运行主实验并读懂输出

```
python experiment.py
```

默认产生 outputs/experiment-result.json 与 outputs/threshold-sweep.csv。不依赖调用者的当前工作目录；默认数据和输出位置由脚本自身位置确定。若希望把结果放在新目录，可传 --out：

```
python experiment.py --out ./outputs/run-a
python -O experiment.py --out ./outputs/run-optimized
```

-O 是 Python 优化模式，会去掉普通 assert；本讲输入检查和核验均未依赖 assert。从其他工作目录运行时，可对脚本给出你本机解压路径的绝对路径。程序不支持把输出目录指向课程根目录或其他源码子目录，避免覆盖课程正文和数据。

终端会给出 AUC、AP 与梯形 PR 面积。按本包固定数据，三者依次应为 0.7962962963、0.6428571429、0.6269841270。它们不是同一个量。JSON 包含完整曲线数组、每个阈值、四种平均方式、先验比例变化和立方变换。

实验题 L3：打开 threshold-sweep.csv，找到 0.70 和 0.60。解释 precision 为什么下降而 recall 不变。再看 0.60 到 0.55，解释 precision 为什么上升。这能反驳“降低阈值必然降低精确率”中的哪一个字？

4 直接调用库 不只看封装结果

下面代码是 Notebook 中的核心核验，使用真实 sklearn 接口。load_case() 返回固定数据，不进行拟合。

```
from experiment import load_case
from sklearn.metrics import (
    confusion_matrix, precision_recall_fscore_support,
    roc_curve, precision_recall_curve,
    roc_auc_score, average_precision_score, auc)
ids, y, s = load_case()
pred = s >= 0.80
print(confusion_matrix(y, pred, labels=[0, 1]))
print(precision_recall_fscore_support(
    y, pred, labels=[0, 1], pos_label=1,
    average='binary', zero_division=0))
fpr, tpr, roc_t = roc_curve(
    y, s, pos_label=1, drop_intermediate=False)
p, r, pr_t = precision_recall_curve(
    y, s, pos_label=1, drop_intermediate=False)
print(roc_auc_score(y, s))
print(average_precision_score(y, s, pos_label=1))
print(auc(r, p))
```

这里 pred 是布尔预测，s 是连续评分。混淆矩阵需要 pred；排序曲线和 AUC/AP 需要 s。若把已经阈值化的 pred 传给 AUC，得到的是一个仅有两种分数的退化排序，原本的细分顺序已丢失。

实验题 L4：打印三个 ROC 数组的长度和全部阈值，再打印三个 PR 数组。解释：为什么 ROC 第一个阈值是 inf？为什么 PR 的两个坐标数组比阈值多一个元素？为什么不能把 roc_t[i] 和 pr_t[i] 当作同一工作点？

该版本完整 ROC 三数组长度均为12。PR 的坐标数组长度为12，阈值数组长度为11。PR 有限阈值从 0.10 上升到 0.95，末尾坐标为 precision = 1、recall = 0，且没有对应阈值。记住这个点是画图约定，不是空警报精确率的统计测量。

5 独立精确参照

先运行快速主例核验，再运行完整的有限枚举：

```
python audit.py --quick --out ./outputs/quick
python audit.py --out ./outputs/full
python -O audit.py --out ./outputs/full-optimized
```

Fraction 直接从 CSV 的整数百分数建立精确比较，不通过先算浮点再转分数“伪装精确”。参照独立枚举每个阈值入选的记录；另枚举所有阳性阴性对，按胜1、平1/2、负0计数。曲线积分结果与配对结果要先精确一致，再对照真实库的浮点结果。

完整测试覆盖1134个4行小例子，包含所有同时有两类的标签向量和三级评分向量。为什么选择这个规模？因为本讲最容易出错的是相等评分、阈值端点和排序模式，小规模可穷举给出完整检查，而不是随机碰运气。它不证明任意输入规模都正确，也不证明目标总体的模型表现。

实验题 L5：不用看程序，列出 A、C、G 分别对9个阴性的胜、平、负数，得到 AUC 的分子。再解释全同分评分为什么 $AUC = 1/2$ ， $AP = 1/4$ 。单类评价集为什么被本包装函数拒绝？

6 改变阳性率 保持类内评分不变


在这个实验中不要删行、重排标签或重新抽样。只给两个真实类别施加各自统一的权重：

```
from experiment import prior_weights, library_metrics, counts_at
for pi in [0.10, 0.25, 0.50]:
    w = prior_weights(y, s, pi)
    curve = library_metrics(y, s, w)
    print(pi, counts_at(y, s, 0.80, w),
          curve['auc'], curve['ap'])
```

原阳性率为0.25；阳性权重为 $\pi/0.25$ ，阴性权重为 $(1 - \pi)/0.75$ 。这是明确指定新混合比例的加权评价。它不改变类内分数分布，因此 ROC 重合。若真实分布变化同时影响每类内部特征和分数，这个结论不能保证。

实验题 L6：当阳性率为0.10，写出每类权重、0.80阈值的加权四格和精确率。使用

$P = \pi a / [\pi a + (1 - \pi)b]$ 独立重算一次。找出三个增加召回率的步骤，算 $AP = 29/60$ 。解释为什么这不是模型“自动变差”的证据。



实验图1 阳性率变化的实际输出。ROC重合依赖类条件评分分布不变；PR显示同一误报率在不同人群混合比例下的警报可靠性。

7 比较平均方式和概率损失

```
from experiment import average_metrics
for name, values in average_metrics(y, s).items():
    print(name, values)
```

实验题 L7：对同一个0.80混淆矩阵，分别算阳性 F1、宏 F1、微 F1、支持度加权 F1。不要把宏 F1 写成宏 precision 与宏 recall 的调和平均。解释四个值分别回答什么问题。

实验题 L8：计算 s^{**3} 。比较原评分与变换后的 AUC、AP、固定0.80阈值的混淆矩阵，以及映射阈值 0.80³ 的混淆矩阵。再看 experiment-result.json 的 monotone 字段，它还包含把评分当作概率时的 log loss 和 Brier。解释为什么排序没变但概率损失会变。

本实验没有用这些损失训练模型，也没有声称原评分已经校准；“作为概率计算损失”是一个反例工具，说明 AUC 不检验概率数值。数值分数一旦被解释为概率，错误置信程度就会进入损失。

8 图像与真Notebook运行

```
python plots.py
jupyter lab experiment.ipynb
```

图像默认写入 outputs/figures，不会改动已交付的正文图。Notebook 中从上到下执行，不能只运行依赖旧内核变量的后半段。它会显示记录、完整扫描、库接口、精确参照、加权实验和9张实际图。打开时若已有输出，仍需用 Restart Kernel and Run All 检验自己环境，而不是把静态输出当成执行证明。

不使用浏览器也可运行：

```
python execute_notebook.py --out ./outputs/fresh-kernel.ipynb
python -0 execute_notebook.py --out ./outputs/fresh-kernel-opt.ipynb
```

这个命令创建新的真实进程内 IPython 内核，执行全部代码单元，收集文本和图像输出，并在失败时报告具体单元。它不覆盖源 Notebook，不测试 JupyterLab 浏览器、网络socket或扩展插件。

实验题 L9：逐张读9幅图，回答讲义 G1 至 G9。再核对图中的阈值、计数与 CSV。特别注意 ROC 的横轴分母是9、PR 的横轴是 recall，以及图9的面积指标越大越好而概率损失越小越好。

9 可选重建PDF

数值实验不需要 PDF 构建依赖。若要重建排版，另安装 build-requirements.txt 中的 Python 包，以及 Node.js 和 package.json 中的 MathJax。系统需提供 Pango、Noto Sans/Serif CJK 中文字体与 DejaVu Sans Mono。此流程不依赖 XeLaTeX。

```
python -m pip install -r build-requirements.txt
npm install
python build_pdf.py --directory ./outputs/pdf
```

build_pdf.py 在本机用 MathJax 生成公式 SVG，再用 WeasyPrint 排版中文。只处理可信课程 Markdown，不是用于接收任意外来 HTML/TeX 的安全沙箱。正文 .md、图像、CSS、公式脚本和依赖声明全部随包提供。构建后仍需把PDF逐页渲染检查，不能以生成成功代替视觉验证。

10 验收清单与排错

实验题 L10：提交一段不超过250字的中文报告，至少包括样本单位、阳性定义与数量、阈值规则、四格、阳性 P/R/F1、AUC/AP 的定义、平均方式以及不能外推的限制。给出一个会让该报告失效的协议改变，例如测试集选阈值或更换阳性率后直接比较 AP。

完成标准如下：

- 纸笔四格与程序一致，所有12行阈值记录无遗漏，同分成组
- $AUC = 43/54$ 、 $AP = 9/14$ 、梯形PR面积 = 79/126 三条精确锚点正确
- 0.80阈值的四种F1平均方式均解释清楚，而不只抄数
- 阳性率变化时明确类条件评分分布不变，重算出加权精确率和AP
- 正常进程与 -0 完整核验通过；Notebook在新内核按序执行无错误
- 报告不把12行合成例子说成真实泛化评估，不把AUC当单阈值成绩

遇到 fixed data hash mismatch，先核对 CSV 是否被意外修改，不要直接改哈希来消除错误。若故意做新实验，复制到独立文件并明确新协议。遇到单类输入错误，检查数据切分和类别定义；不能强行填造一个缺失类别。遇到数组长度不一致，优先查 PR 额外端点。遇到公式渲染依赖缺失，可以先完成数值实验；随包已有可读PDF与Markdown。