

第047讲 练习详解

校准与预测不确定性

本文件独立解释实验手册二十题。数值采用交付默认协议；小数用于阅读，源码和Notebook保存更完整精度。评价结果差异不能靠修改随机种子消除。

1. 三种对象

正类校准要求报告正类概率为 p 的人群中，正类比例也为 p ，理想式为 $E[Y | p(X)] = p(X)$ 。最高置信度校准要求置信度为 c 的人群中，所选类别正确率为 c 。预测区间覆盖关注新响应是否落入集合 $C(X)$ ，例如 $P\{Y \in C(X)\} \geq 0.9$ ；必须同时说明概率平均了校准数据和新点的随机性。

前两者是概率报告与频率的一致，第三者是集合包含事件。某个病例或某一天只能出现一个结果，不能用单次对错估计总体校准。

2. 初始正类ECE

低分箱有第1、2行，平均概率0.1，标签均值 $(0 + 1)/2 = 0.5$ ，权重 $2/4$ ，贡献 $0.5 \times 0.4 = 0.2$ 。高分箱有第3、4行，平均概率0.9，标签均值1，贡献 $0.5 \times 0.1 = 0.05$ 。相加0.25。

两个非空箱不是按类别标签分出来的，而是按预测分数分出来的。其余三个箱均无样本，不产生0点或额外权重。

3. 温度2的两种ECE

正类概率变为 $(0.25, 0.25, 0.75, 0.75)$ 。低分箱贡献 $\frac{1}{2}|0.25 - 0.5| = 0.125$ ，高分箱贡献 $\frac{1}{2}|0.75 - 1| = 0.125$ ，仍为0.25。

最高置信度均为0.75，四个预测中三个正确，箱内正确率0.75，所以最高置信度ECE为0。原先所有置信度0.9而正确率0.75，所以原值0.15。这证明有限样本的两个指标不等价，未证明任一总体已完美校准。




图1 两种可靠性对象不能互相替换。

4. Brier的适当性

给定真实概率 η ，有

$$\eta(p-1)^2 + (1-\eta)p^2 = p^2 - 2\eta p + \eta = (p-\eta)^2 + \eta(1-\eta).$$

第二项是给定 x 后伯努利标签的条件方差，不受报告 p 控制；第一项非负且只在 $p = \eta$ 时为0。故诚实报告最优。若 $\eta = 0.75$ ，最低期望Brier是0.1875而不是0。

总是报告总体正类率的模型可能在总体上校准，但无法区分个体概率差异。更丰富特征带来的分辨能力也会改善Brier，因此不能把Brier叫作“纯校准误差”。

5. 第2行的完整局部链

初始 $a = 1, z = -2 \log 3 = -2.197224577, y = 1$ 。先算 $u = -2.197224577, p = 0.1$ ，损失 $-\log 0.1 = 2.302585093$ 。

局部导数为 $\partial \ell / \partial p = -10, \partial p / \partial u = 0.1 \times 0.9 = 0.09, \partial u / \partial a = -2.197224577$ 。三者相乘是1.977502120，再除以4得到平均损失梯度贡献0.494375530。

它的Hessian贡献是 $z^2 \times 0.09 / 4 = 0.108625406$ 。其他三行Hessian贡献相同，故总Hessian为0.434501626。不能把局部导数-10本身当作逆温度梯度。

6. 第一次同步更新

初始四行梯度贡献依次为 $(-0.054930614, 0.494375530, -0.054930614, -0.054930614)$ ，相加 $g_0 = 0.329583687$ 。所以 $a_1 = 1 - 0.5g_0 = 0.835208157, T_1 \approx 1.197306315$ 。

行	新logit u	新正类概率p	新损失	对新平均梯度贡献
1	-1.835139889	0.137627104	0.148067508	-0.075599414

行	新logit u	新正类概率p	新损失	对新平均梯度贡献
2	-1.835139889	0.137627104	1.983207397	0.473706731
3	1.835139889	0.862372896	0.148067508	-0.075599414
4	1.835139889	0.862372896	0.148067508	-0.075599414

平均损失0.606852480，新梯度0.246908489。第1行标签0，概率从0.1升到0.1376使它的损失上升；但第2行的损失下降更大，所以总体改善。梯度下降不要求每一行都改善。

7. 第二次更新与第三次前向

$$a_2 = 0.835208157 - 0.5 \times 0.246908489 = 0.711753912, T_2 \approx 1.404979984.$$

行	新logit u	新p	新损失	对g贡献
1	-1.563883189	0.173090141	0.190059587	-0.095079478
2	-1.563883189	0.173090141	1.753942776	0.454226667
3	1.563883189	0.826909859	0.190059587	-0.095079478
4	1.563883189	0.826909859	0.190059587	-0.095079478

平均损失0.581030384，梯度0.168988233，Hessian0.691002148。梯度仍明显不为0，而且 $a_2 > 0.5$ ，所以还未达到已知解析最优点。表中一切都来自同一个 a_2 ，没有逐行偷改参数。

8. 解析最优温度

令 $q = \sigma(am)$ ，正确三行损失为 $-\log q$ ，错误一行是 $-\log(1 - q)$ 。故

$$L = -\frac{3}{4}\log q - \frac{1}{4}\log(1 - q), g = m(q - 3/4). \text{ 令导数为0得 } q = 3/4.$$

于是 $am = \log[q/(1 - q)] = \log 3$ ，而 $m = 2\log 3$ ，得到 $a^* = 1/2, T^* = 2$ 。最小NLL为 $-\frac{3}{4}\log(3/4) - \frac{1}{4}\log(1/4) = 0.562335145$ 。Brier为 $(0.0625 + 0.5625 + 0.0625 + 0.0625)/4 = 0.1875$ 。

这是四行受限温度族的经验最优，不是按两个分数组分别自由拟合概率的最优，更不是每个样本真实概率的证书。

9. 为什么准确率不变

有限 $T > 0$ 对所有logit除以同一个正数，不改变排序；二分类也不改变logit正负。因此使用同一 $\arg\max$ 和同一并列规则时预测类别不变。概率靠近0.5不等于类别改变。

当 $a = 0$ 即无限温度极限，所有分数都压为0，概率都为0.5。本实现并列判0，原来判1的样本可能改变，所以必须排除这一边界才能说准确率不变。若允许负温度，排序还会翻转，而本API明确不支持。

10. 稳定损失的理由

大正 u 时计算机可能得到 $\sigma(u) = 1$ ；对于负标签再取 $\log(1 - p)$ 会产生负无穷，尽管真实有限logit的损失仍有限。使用 $t = (2y - 1)u$ 及 $\max(-t, 0) + \log(1 + e^{-|t|})$ ，指数参数不大于0，可避免指数上溢。

同时对 $y = 1$ 直接计算 $-\sigma(-u)$ 作为对logit的导数，避免 $1 - 1$ 抵消。局部概率导数过大时可以记录不可表示，但不能把核心梯度也改成NaN。支持有限范围不等于支持任意浮点极限。

11. 评价标签变换测试

选择记录中的拟合结果、校准行ID、分箱方案以及choice_sha256应完全不变，因为拟合器没有接收评价标签或oracle真概率。评价NLL、Brier、准确率、可靠性统计可以变化。

如果温度随评价标签改变，就沿某条代码路径把评价信息用于选择。即使最终评价分数更好，也不是独立评价。这个定向变换测试比仅查看函数名是否叫“calibration”更有说服力。

12. 分箱图与空箱

没有计数无法知道一个点来自2行还是2000行，小样本比例的变化更容易受抽样影响。应一并给出分箱边界和权重。空箱无平均概率和标签率，应记录null并不画这个点。

本实验用固定等宽箱；箱内横坐标是实际平均预测，不是区间中点。ECE既受模型影响，也受箱数、样本量和分箱边界影响。它不是跨任意设计可比的总体上界。

13. 合法split conformal流程

训练集：拟合 b, w 并冻结。独立校准集：对冻结模型算 $s_i = |y_i - (b + wx_i)|$ ，取修正秩 q 。独立评价集：不改模型、阈值或组定义，只计算新响应是否位于 $[b + wx - q, b + wx + q]$ 。

对象是新的随机响应 Y ，包含不可约噪声，不只是未知均值 $f(x)$ 。在给定训练模型后，校准点与新点可交换是秩证明的关键。模型预测差可能使区间宽，却不会在这些条件成立时破坏边际覆盖下界。

14. 秩与无穷边界

$n = 99, \alpha = 0.1$: $k = \lceil 100 \times 0.9 \rceil = 90$ ，取99分数的第90小值，默认0.936792199。

$n = 9, \alpha = 0.05$: $k = \lceil 10 \times 0.95 \rceil = 10 > 9$ ，没有第10个校准分数，应取 $+\infty$ 。程序以infinite=True, quantile=None记录；区间为实数轴，宽度无限。取现有最大分数只能提供无并列时9/10的秩覆盖，达不到0.95。

15. $n+1$ 和并列

我们评价的是一个校准集之外的新点，所以在对称性论证中必须把 n 个校准分数与1个新分数放在一起，共 $n+1$ 个。无并列可交换时，新分数的每个秩概率为 $1/(n+1)$ ；前 k 个秩被覆盖，故概率 $k/(n+1)$ 。

若存在并列，闭区间把边界上的点一起覆盖，仍至少目标覆盖，但可能超过这个精确比率。若错误地使用严格小于而排除等号，离散分数的覆盖会改变，不能照搬证明。

16. 普通插值的具体失败

留出8时，校准排序为(0, 1, 2, 3, 4, 5, 6, 7, 9)，九个点的线性90%分位数位置为 $(9-1) \times 0.9 = 7.2$ ，采用从0开始计数的第7与第8位置，即7和9。插值为 $7 + 0.2(9-7) = 7.4$ ，小于新分数8，因而漏覆盖。

修正秩 $k = \lceil 10 \times 0.9 \rceil = 9$ 取最大值9，覆盖8。轮流均匀留出十个数，修正方案只漏9，普通插值漏8和9，所以分别覆盖9/10和8/10。这是完整有限枚举，不依赖随机种子。

17. higher并不总等于第 k 小值

$n=10, \alpha=0.2$ 时 $k = \lceil 11 \times 0.8 \rceil = 9$ ，直接取第9小值是9。若将 $q = k/n = 0.9$ 传给NumPy的higher，位置基于 $(10-1) \times 0.9 = 8.1$ ，向上取从0开始的第9位置，返回10。

这里返回10更保守，不是少覆盖反例；它只是说明某一配方与所声明的精确顺序统计量不一致。程序用`np.partition(scores, k-1)[k-1]`，并在之前处理 $k > n$ 。任何库函数都必须核对定义，不能仅凭方法名称想当然。

18. 重复层面的MCSE

对120个独立重复覆盖率 C_r 计算 $\bar{C} = \sum C_r / 120$ ， $s_C^2 = \sum (C_r - \bar{C})^2 / 119$ 。默认 $\bar{C} = 0.905958333$ 、 $s_C = 0.032865884$ 、 $s_C / \sqrt{120} = 0.003000231$ 。

独立单位是每次重新训练、重新校准、重新生成评价集的完整实验。每次内400个点共享拟合与校准随机性，不能当作400个独立完整实验。 ± 2 MCSE是重复均值的近似数值误差展示，不是对每次部署或分布改变的严格保证。

19. 总体、分组和分布改变

总体平均覆盖约0.906，低绝对值 x 组约0.980，高绝对值 x 组约0.832。这些组具有不同噪声水平，恒宽区间较容易覆盖低噪声组。定理保证在 x 分布上平均后的边际覆盖，并未要求所有组相同。

放大评价噪声2.5倍后，校准残差来自旧机制，新残差来自新机制，可交换性不再成立，所以原下界不适用。观察均值0.57860是这一压力测试的真实负面结果，不是用额外训练或重新校准后的效果。

20. 错误复用及合法修复

1近邻在每个互异校准输入处找到自身标签，因此校准残差为0。新点没有同样的记忆通道，连续噪声下恰好命中零宽度区间的概率为0。这使校准分数和新分数的生成角色不对称。

一种合法修复是保留独立训练集训练1近邻，冻结它，再用另一批没参与训练的校准标签计算分数，最后独立评价。修复后在可交换条件下恢复边际覆盖的适用前提，但不保证区间短、不保证每组90%、不保证噪声改变后仍然有效。合法程序也可能得到宽而不实用的区间，必须同时报告覆盖和宽度。

完整验收的判断方式

正确答案应能从四行数据重建两次更新，不混用两种ECE；能从秩的对称性解释 $n + 1$ 、无穷与并列；能区分估计噪声、统计前提与实际失效。代码测试通过并不意味着现实数据自动满足这些条件。