

第048讲练习详解 泛化误差与复杂度

使用说明

本文件独立给出20题完整解答与实验读图参考。符号D为训练数据，T为独立测试数据， $\hat{f}_D$ 为训练输出。平方损失没有1/2系数。三行纸笔例的噪声方差是1；Legendre主实验的噪声方差是0.1225。先核对题目属于哪个机制，再代数值。

1 三种风险

经验风险 $\hat{R}_D(f) = n^{-1} \sum_i (Y_i - f(X_i))^2$ 在一份已实现的数据D内平均。总体风险 $R(\hat{f}_D) = \mathbb{E}_{X_0, Y_0} [(Y_0 - \hat{f}_D(X_0))^2 \mid D]$ 固定这次训练结果，只平均独立新样本。平均总体风险 $\mathbb{E}_D R(\hat{f}_D)$ 还平均重新收集训练集的随机性。

三者的估计手段也不同：第一项直接在训练表算，第二项通常用独立测试估计，第三项需要重复完整训练过程或额外理论假设。固定一次D然后扩大测试集，只能更准确估计第二项，不能直接识别第三项的训练集变化。

2 三行常数模型计算链

预测全部为1/3。按预测减标签定义残差：H1为-2/3，H2为4/3，H3为-2/3。平方分别4/9、16/9、4/9，总平方误差为24/9=8/3。再除样本数3得到MSE=8/9。

若逐行先算对平均损失的贡献，得到4/27、16/27、4/27，相加就是8/9。这时已经除过3，不能再对贡献列取均值，否则得到8/27，等于误除两次样本量。它不是本讲定义的经验风险。

3 线性与二次解

线性A为三行(1,-1)、(1,0)、(1,1)，所以 $A^T A = \text{diag}(3, 2)$ ， $A^T y = (1, 0)^T$ 。解为截距1/3、斜率0，与常数模型相同。

二次预测写成 $c + bx + ax^2$ 。x=0给c=-1，另外两式为a-b=2与a+b=2，因此a=2、b=0。训练预测(1,-1,1)与标签完全相等，MSE=0。

总体评价固定已训练函数。常数信号误差为1/9，二次信号误差是

$$\frac{1}{2} \int_{-1}^1 (2x^2 - 1)^2 dx = 4/5 - 4/3 + 1 = 7/15.$$

各加一次新标签噪声1，风险分别10/9与22/15。二次减常数为 $(66 - 50)/45 = 16/45 > 0$ 。一次训练上损失更低，并不能反推总体风险更低。

4 Bayes预测与矩条件

令 $m(x) = \mathbb{E}[Y | X = x]$ 。把 $Y - a$ 写成 $(Y - m) + (m - a)$ ，平方并取条件期望。交叉项为 $2(m - a)\mathbb{E}[Y - m | X = x] = 0$ ，因此条件风险等于 $\text{Var}(Y | X = x) + (m - a)^2$ 。第一项固定，第二项在 $a = m$ 处最小。

需要条件均值存在，并为平方风险讨论要求 $\mathbb{E}[Y^2]$ 有限；比较的预测函数也需具有有限平方风险，且可测。若某些 x 处条件量只在几乎处处意义下定义，结论也按目标输入分布几乎处处理解。积分后最优风险为 $\mathbb{E}_X \text{Var}(Y | X)$ 。

最优性相对于给定特征与平方损失。换成绝对损失或改变可用输入，最优预测与不可约部分可能改变，不能直接搬用同一个条件均值答案。

5 三个交叉项逐个消去

固定 x ，令 $a = Y_0 - f^*(x)$ 、 $b = f^*(x) - \mu(x)$ 、 $c = \mu(x) - \hat{f}_D(x)$ 。 a^2 期望为 $\sigma^2(x)$ ， b^2 就是偏差平方， c^2 期望为训练预测方差。

$\mathbb{E}[ab] = b\mathbb{E}[a] = 0$ ，因为新标签噪声条件均值0。 $\mathbb{E}[bc] = b\mathbb{E}[c] = 0$ ，因为 μ 是对训练随机性的平均。 $\mathbb{E}[ac] = 0$ 需要新标签噪声与训练预测适当独立或至少零协方差；给定 x 的独立性和 $\mathbb{E}[a] = 0$ 足以保证。

因此六项展开只余三项。对 X 再积分时须保证相关平方量可积；若无穷风险存在，不能照搬有限值的加减操作推一个可用于数值估计的等式。主实验的有限数组恒等式不自动证明无限训练分布的矩存在。

6 无噪评价和依赖噪声

若评价目标是 $f^*(x)$ ，误差 $f^*(x) - \hat{f}_D(x) = b + c$ ，平方平均只含偏差平方加预测方差。原来的 a 项不再存在，不能加 $\sigma^2(x)$ 。这对应主实验 risk 减 0.1225 后的信号误差。

若新标签噪声与训练预测相关，则 $E[ac] = -E[(Y_0 - f^*)\hat{f}_D(x)]$ 不一定为0，展开还需要保留交叉项。例如训练数据中泄漏了该测试标签，预测可以利用同一个噪声，所谓独立测试条件已被破坏。不能把比噪声下限更低的测试结果直接当作突破不可约误差。

7 常数模型八种数据的期望

三个独立噪声均值0、方差1。常数估计是它们平均，因此均值0、方差1/3，且预测不依赖新输入 x 。真均值也是0，偏差平方0。积分预测方差仍1/3，加新标签方差1得到4/3。

八个标签组合等概率，所以全枚举平均恰是此训练分布期望。平均训练 MSE 可从

$n^{-1} \sum_i (\epsilon_i - \bar{\epsilon})^2 = n^{-1} \sum_i \epsilon_i^2 - \bar{\epsilon}^2$ 得到 $1 - 1/3 = 2/3$ 。训练风险 2/3 低于总体风险 4/3，正体现用同一噪声选均值与独立新标签评价之间的区别。

8 线性模型的方差

固定设计使截距为 $(\varepsilon_1 + \varepsilon_2 + \varepsilon_3)/3$ ，斜率为 $(\varepsilon_3 - \varepsilon_1)/2$ 。均值均为0。独立性给 $\text{Var}(c)=3/9=1/3$ ， $\text{Var}(b)=2/4=1/2$ 。

协方差逐项为 $E[cb] = (-E\varepsilon_1^2 + E\varepsilon_3^2)/6 = 0$ ，其余乘积期望为0。于是 $\text{Var}(c+bx)=1/3+x^2/2$ 。对 $U[-1,1]$ 输入积分，得到 $1/3+(1/2)(1/3)=1/2$ ，加噪声得 $3/2$ 。

平均训练MSE为 $1/3$ 。也可利用固定满列秩OLS投影：残差空间维度 $n-p=1$ ，独立同方差单位噪声的期望残差平方和为1，除以 $n=3$ 。这里说的是训练设计点上的残差，不是均匀新输入的风险。

9 二次插值权重与积分

通过-1的基函数要在-1为1、0和1为0，因此 $L_-(x) = x(x-1)/2$ 。通过0的基函数为 $L_0(x) = 1 - x^2$ 。通过1的基函数为 $L_+(x) = x(x+1)/2$ 。将噪声分别乘对应函数相加，得到二次插值解。

三个噪声独立方差1，所以点态方差为 $L_-^2 + L_0^2 + L_+^2$ ，没有协方差交叉项。两端平方积分分别为 $(EX^4 + EX^2)/4 = 2/15$ ，因为奇次矩0；中间为 $1 - 2EX^2 + EX^4 = 8/15$ 。

总积分方差 $12/15=4/5$ 。均值函数0，偏差0，平均总体风险 $1+4/5=9/5$ ，训练插值风险为0。这个无U形的精确例子反驳“每条复杂度曲线必须先降后升”。

10 嵌套假设类证明

若 $\mathcal{H}_p \subseteq \mathcal{H}_{p+1}$ ，较小类最优函数也是较大类可行函数。因此 $\inf_{f \in \mathcal{H}_{p+1}} \hat{R}_D(f) \leq \inf_{f \in \mathcal{H}_p} \hat{R}_D(f)$ 。若极小值存在，可以把inf换成min。证明只用集合包含关系，不需要正态噪声或偏差方差分解。

前提可能因以下改变失效：换训练数据；换损失或平均尺度；两个模型的可行函数类不嵌套；只给较大类一个未收敛的近似解。增加正则项也改变目标，原始训练MSE与惩罚目标需要分别讨论。更重要的是，证明从未对总体风险作同样声明。

11 近似误差与偏差平方

近似误差为 $\inf_{f \in \mathcal{H}} R(f) - R^*$ ，属于假设类相对于目标分布的限制。偏差平方为 $E_X(\mathbb{E}_D \hat{f}_D(X) - f^*(X))^2$ ，还依赖样本量、训练算法和抽样协议。

三行二次类包含零函数，近似误差为0；全枚举平均预测也是零，所以偏差平方也为0。但预测方差 $4/5$ 使平均风险 $9/5$ 高于噪声1。这个例子说明零近似误差、零偏差都不保证有限样本学习风险低。

两项数值同时为0不是一般等价性证明。若另用一个固定返回错误常数的算法，类仍包含真函数，近似误差仍0，算法偏差平方却可为正。定义中的对象不同才是关键。

12 两种优化差的反例

三行例中零函数训练风险1，二次ERM训练风险0，所以零函数相对经验最优的优化误差为1。零函数总体风险1，二次ERM总体风险22/15，故相对ERM的总体风险差为 $1 - 22/15 = -7/15$ 。

一个算法没有将经验目标最小化，并不必然使总体表现更差。这里无需把零函数称为特定早停算法，只用它证明风险层面的差可能负。若把-7/15误当成非负的优化误差，就混淆了两个评价目标。

13 上界的每一步

从 $R(\tilde{f}) \leq \hat{R}_D(\tilde{f}) + \Delta_D$ 起。经验优化误差定义保证 $\hat{R}_D(\tilde{f}) \leq \hat{R}_D(f_{\mathcal{H}}^*) + \epsilon_{opt}$ 。再用 $\hat{R}_D(f_{\mathcal{H}}^*) \leq R(f_{\mathcal{H}}^*) + \Delta_D$ 。三式接起来、两边减 R^* ，得到近似误差加 $2\Delta_D + \epsilon_{opt}$ 。

需要输出属于该类，经验优化差定义有效，以及 Δ 有限。若平方损失配无界系数类使统一偏差无穷，这个式子虽在形式上仍可写“ $\leq$ 无穷”，却不提供可用保证。进一步理论需要限制函数或参数、尾部和复杂度等条件。本讲没有为随机多项式主实验计算一个数值泛化上界。

14 正交系数和近似误差

真系数从j=0起为1、0.6、0.4、-0.25，其后0。p列模型允许j=0至p-1。其余系数必须补0，才能在一个9维正交坐标中比较函数。

p=1遗漏0.6、0.4、-0.25，近似误差0.36+0.16+0.0625=0.5825。p=2遗漏0.4、-0.25，误差0.2225。p=3仅遗漏-0.25，误差0.0625。p $\geq$ 4包含全部非零真项，近似误差0。

公式来自 $E(\sum_j d_j \phi_j)^2 = \sum_{jk} d_j d_k E\phi_j \phi_k = \sum_j d_j^2$ 。如果换未经归一化的单项式基底，同一个系数平方和通常不再等于函数积分，必须加入总体Gram矩阵。

15 四个预测值的ddof计算

四个值为-1、0、1、2，均值0.5，真值0，当前平均预测偏差平方0.25。各值到均值的偏差为-1.5、-0.5、0.5、1.5，平方和5。

分母4给 $V_0=1.25$ ；分母3给 $s^2=5/3$ 。平均平方预测误差为(1+0+1+4)/4=1.5，等于0.25+1.25。如果错误地加0.25+5/3，得到23/12，不是1.5。

修正偏差平方估计为 $0.25 - (5/3)/4 = -1/6$ 。它与ddof=1方差相加为-1/6+5/3=3/2，再次等于1.5。负值是估计器可能出现的结果，真实偏差平方当然非负。这里数值未包含新标签噪声；若要预测含噪标签且已知独立噪声方差，还需只加一次该方差。

16 标准差和标准误

$p=9$ 的400个真实风险有样本标准差约4.4343，它描述这400次训练结果风险的离散程度。除以 $\sqrt{400}=20$ 得0.2217，是在相应独立重复与矩条件下用于描述均值蒙特卡洛不确定性的常用标准误估计。

不能把0.2217说成“一个新训练结果通常只偏离平均0.2217”。新训练结果的波动尺度与风险分布本身有关。10%至90%带描述个体训练集风险的中心80%，也不是平均的置信区间。高阶随机设计存在近奇异尾部，本讲没有为所有配置证明总体风险方差有限；有限样本SD和SD/ $\sqrt{B}$ 可报告，但不能单凭数值给出无条件CLT覆盖保证。

17 学习曲线下限和数值残差

$p=2$ 的类近似误差0.2225，加新噪声0.1225得到总体类内最优风险0.345。固定这个类时再多数据也不能表示遗漏的二次和三次项。 $n=256$ 平均风险0.348252距离该下限还有估计成分。

$p=8$ 、 $n=16$ 的某些设计在输入覆盖不足处使拟合极敏感。它们可有极小训练残差或正规方程残差，同时产生很大的新输入风险。当前全部10800次拟合的最大平均正规方程残差约 $6.81e-14$ ，独立求解器和积分路径也对齐。由此不能把巨大risk笼统归为“没训练够”。

小残差也不是任何病态系统的完美精度证书；仍需条件数、独立预测对照与原输入。这里所有结果原样保留，无以风险大小决定删除或换种子的步骤。

18 三种重复实验

固定D、重启随机初始化：主要考察给定数据的算法随机性，无法直接测训练样本改变导致的波动。重新从总体抽D并重新训练：考察学习过程对训练抽样的变化，若算法也随机则还混合算法随机性，需进一步分层。

固定已训练函数、重新抽T：考察有限评估集的波动，不改变预测函数。主实验每次D和T都重抽，所以test的跨重复波动同时包含函数风险变化和测试评估误差；risk字段通过已知机制积分隔离了后者。

同一个真实数据集重复随机划分不等于拥有400份独立总体训练样本；划分之间共享观察，不能不加说明地当独立重复。必须写清抽样层级和依赖关系。

19 不利用最终测试集选复杂度

先明确采样单位与目标分布，把最终测试集封存。仅在训练开发部分划分训练和验证，或进行合适的交叉验证；每个候选 p 的预处理和拟合只读取相应训练折。按预声明验证指标选择 p ，并决定最终重训流程。完成所有选择后，只对最终规则使用封存测试集报告性能与不确定性。

若查看测试后又改 p ，该测试已参与开发，需要诚实说明，不能仍称为完全未见的最终评估。样本中若存在同人重复、组结构或时间顺序，划分必须与部署场景一致。

本讲把全部 p 的风险画出用于机制解释，并利用已知真函数做分解，不是现实模型选择流程。它能展示一个协议下的复杂度与样本量作用，不能把 $p=4$ 当作未知现实问题的最优值，也不能证明U形适用于所有模型。

20 第86次 p 等于9的核查

rep字段从0开始。复杂度结果 $p=9$ 、rep=86的真实含噪风险约76.177279235，独立256行测试MSE约61.389492904。测试减真实约-14.787786330，即这一次测试明显低估真实风险。

真正的总体风险来自该次9维系数减真系数的平方和再加0.1225，已知输入分布允许精确函数积分。训练MSE约0.117665010，设计条件数约92.8119，正规方程平均残差约 $2.08e-15$ 。训练拟合并未标记失败。

不能因结果不好就删除：这个训练集由预声明机制产生，并且输入和计算有效。删除会把研究问题改成“条件于没有出现坏结果的训练表现”，人为压低尾部与均值。若事先定义了实际部署拒绝规则，必须把拒绝概率、拒绝后的动作和新协议一并评价，不能事后偷偷过滤。

读图补充A 同一次与全部训练数据

图1固定三行标签(1,-1,1)，只对新输入和新噪声取总体平均；图2还对八种可能训练标签取平均。因此图1常数风险10/9与图2常数平均风险4/3不矛盾。前者是一种具体实现，后者平均了所有实现。

读图补充B 中心带和尾部

图3的10%至90%带不告诉你最大10%的风险能多大。 $p=9$ 有少量值远高于常见范围，使平均风险被抬高。图7的对数直方图保留全部重复和最大值位置，帮助发现长尾。它仍不是未来尾部的完整保证，因为400次未必充分采到极罕见事件。

读图补充C 无偏结论的范围

$p=4$ 当前MC偏差平方很小只说明这400次平均预测接近本机制真函数。正确设定的线性最小二乘在固定满秩设计与条件零均值噪声下具有条件无偏性，可以另作理论论证；这不涵盖所有分布、模型选择、正则化或算法。一个图不能替代条件列表。

读图补充D 对数轴

$p=8$ 、 $n=16$ 的风险与其他点相差数千倍。使用线性轴会把低风险曲线压在底部，对数轴让全部量级可见，但视觉上会缩小绝对差距。因此正文必须同时给平均805.824574、最大118455.527851等真实数值，不能只用“略高”描述。

读图补充E 两种波动

图6固定横坐标 x ，沿不同 D 比较 $\hat{f}_D(x)$ ，对应点态预测方差。图9每个点先固定 D ，把 $R(\hat{f}_D)$ 与 $\hat{R}_T(\hat{f}_D)$ 对照；它们差异来自独立有限 T 。两图中的“散开”不属于同一个随机变量，不可用同一个标准差解释。

读图补充F 训练设计

图8两个协议 n 都为40， p 、真函数、噪声和评价分布也相同。差别是固定网格与随机训练输入覆盖方式。尤其高阶模型可能对随机留下的间隙敏感，所以总体输入分布相同不意味着条件于某次训练设计的风险相同。

实验数值核对摘要

核对项目	本次作者计算
完整拟合次数	10800
独立分数全枚举风险	4/3、3/2、9/5
15组独立积分最大差	约9.99e-16
15组SciPy枢轴QR最大系数差	约4.66e-15
15组scikit-learn最大预测差	0.0
全部平均正规方程残差最大值	约6.80e-14
有限重复分解恒等式最大残差	约5.46e-14

另对27个配置各自的最大风险样本重算函数积分与枢轴QR。最大风险118455.527851的求积绝对差约1.03e-9、按风险尺度归一化差约8.72e-15；全部27例中QR预测尺度化差最大约3.22e-14。绝对误差应结合量级判断，不能把1e-9在任意尺度上都叫同样严重。

这些是当前平台上的作者复核，不是现实应用的性能保证，也不替代独立课程验收。精确风险和近似浮点结果已分别标注，跨平台重算应使用合理容差，不要求最后一位字节相同。