

第049讲 练习详解

学习理论的第一组保证

以下二十二题对应独立实验手册。小数用于阅读，精确分数、计数与完整随机重复记录在数据和结果JSON中。概率界是带前提的结论，不能靠只报告一个漂亮数字代替前提。

1. 三个风险

总体风险 $R(h) = E[\ell(h(X), Y)]$ 对数据分布取期望。经验风险 $\hat{R}_S(h) = n^{-1} \sum_i \ell(h(x_i), y_i)$ 是当前样本平均。选中规则的超额风险是 $R(\hat{h}) - \min_{h \in \mathcal{H}} R(h)$ ，比较的是两个总体风险。

经验风险并不等于优化误差。优化误差比较当前经验目标和可达到的最小经验目标；本例完整枚举所以优化误差为0，但选中规则仍可能有正超额风险。

2. 精确总体风险

H2在 $(-2, 1), (-1, 1), (1, 0), (2, 0)$ 四个结果上出错，概率相加为 $(1 + 6 + 6 + 1)/64 = 14/64 = 7/32$ 。

H1在 $x = -1$ 预测1，错误结果换成 $(-1, 0)$ ，于是风险 $(1 + 18 + 6 + 1)/64 = 26/64 = 13/32$ 。两者相差 $12/64 = 3/16$ 。这来自真实分布权重，不是观察样本时错了几次。

3. 六行完整账本

行(x,y)	五个预测 H0...H4	五个损失 H0...H4
$(-2, 0)$	1,0,0,0,0	1,0,0,0,0
$(-1, 1)$	1,1,0,0,0	0,0,1,1,1
$(-1, 0)$	1,1,0,0,0	1,1,0,0,0
$(1, 1)$	1,1,1,0,0	0,0,0,1,1
$(2, 1)$	1,1,1,1,0	0,0,0,0,1
$(2, 0)$	1,1,1,1,0	1,1,1,1,0

逐列求和 $(3, 2, 2, 3, 3)$ ，除以6得到 $(1/2, 1/3, 1/3, 1/2, 1/2)$ 。并列集合H1、H2；按声明顺序选H1。不要把“两个最小值相同”理解为两规则预测完全相同。

4. 追加整批后的选择与下一前向

新增 $(-1, 0)$ 对五规则的损失是 $(1, 1, 0, 0, 0)$ ；新增 $(1, 1)$ 是 $(0, 0, 0, 1, 1)$ 。两者加到旧计数得到 $(4, 3, 2, 4, 4)$ ，除以8为 $(1/2, 3/8, 1/4, 1/2, 1/2)$ ，唯一最优H2。

选中模型对四个输入 $(-2, -1, 1, 2)$ 的预测从H1的 $(0, 1, 1, 1)$ 变成H2的 $(0, 0, 1, 1)$ 。真实风险从 $13/32$ 变成 $7/32$ 。这里新增标签用于训练，不是允许在封存评价集上随意更新。

5. 没有梯度，但有完整计算链

参数空间是五个命名规则的有限列表，目标为按行比较标签得到的0-1损失。算法完整算出五个总损失后取最小值，不需要可微性，也不存在一个被代码执行的梯度步骤。

每行对平均风险的贡献是损失除以当前样本数。第2行对H2贡献 $1/6$ ，追加后相同旧行贡献 $1/8$ 。分母变化也是重新求平均的一部分。完整科学链可以是前向→损失→汇总→有限选择→下一次前向，不应伪造导数。

6. 固定规则界的前提

第一，当前评价样本没有参与选择这个规则，或已条件于与当前样本独立的训练过程。第二，当前观测是独立同分布的。第三，损失在 $[0, 1]$ 。

概率对整份随机样本 S 而言：反复抽样时，经验风险偏离固定总体风险超过 ϵ 的概率不超过 $2e^{-2n\epsilon^2}$ 。不是对单个标签正确性的概率，也不是给真实风险指定一个后验分布。

7. 指数矩到Hoeffding

对 $Z \in [0, 1]$ ，中心化对数矩母函数 $K(\lambda) = \log Ee^{\lambda(Z-EZ)}$ 满足 $K(0) = K'(0) = 0$ 。其二阶导是指数倾斜分布下的方差；范围仍为 $[0, 1]$ ，所以 $K'' \leq 1/4$ 。两次积分得 $K \leq \lambda^2/8$ 。

Markov不等式给出 $P\{\sum(Z_i - EZ_i) > n\epsilon\} \leq e^{-\lambda n\epsilon} Ee^{\lambda \sum(Z_i - EZ_i)}$ 。**独立性**允许把最后期望写成各项期望乘积，再以指数矩上界控制为 $e^{-\lambda n\epsilon + n\lambda^2/8}$ 。

对 λ 求最小值， $-\lambda n\epsilon + n\lambda^2/8 = 0$ 得 $\lambda = 4\epsilon$ ，代回为 $e^{-2n\epsilon^2}$ 。对负偏差重复，再将两个尾部相加，系数变成2。

8. Union bound不用规则独立

对任意事件 $A_1, \dots, A_M$ ，逐个结果检查可得 $1\{\cup_j A_j\} \leq \sum_j 1\{A_j\}$ 。取期望后为 $P(\cup_j A_j) \leq \sum_j P(A_j)$ 。事件可以强烈相关，甚至完全相同；那样界可能很松，但仍成立。

独立性要求在Hoeffding对每个规则的观测损失序列中使用，而不是在这一步要求不同规则之间独立。本讲五个阈值损失相关，却可使用union bound。

9. 同时半径的代数

将单个坏事件上界相加得 $2Me^{-2n\epsilon^2}$ 。希望它不超过 δ ，先取对数： $\log(2M) - 2n\epsilon^2 \leq \log \delta$ 。移项为 $2n\epsilon^2 \geq \log(2M/\delta)$ ，取非负平方根得到

$$\epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

使用这个半径时，所有规则同时满足偏差界的概率至少 $1-\delta$ ；因此选择类中的任意规则也被保护。若类是在看过这份数据后任意构造的，还需要额外分析。

10. ERM三项分解

插入两个经验风险： $R(\hat{h}) - R(h^*) = [R(\hat{h}) - \hat{R}(\hat{h})] + [\hat{R}(\hat{h}) - \hat{R}(h^*)] + [\hat{R}(h^*) - R(h^*)]$ 。

同时好事件控制第一与第三项各不超过 ϵ 。精确ERM让第二项不大于0，所以超额风险不大于 2ϵ 。若经验优化误差超过 ζ ，则第二项最多 ζ ，得到 $2\epsilon + \zeta$ 。

这不是 $R(\hat{h}) \leq 2\epsilon$ ，因为还必须加上类内最小总体风险。默认最小风险为 $7/32$ ，不能在代数中丢掉。

11. 两个半径

$n = 20, \delta = 0.05$ 时， $\log(2/\delta) = \log 40$ ，固定模型半径 $\sqrt{\log 40/40} \approx 0.303680731$ 。

$M = 512$ 时， $\log(2M/\delta) = \log 20480$ ，同时半径 $\sqrt{\log 20480/40} \approx 0.498176778$ ，精确读数以 Notebook 为准。它明显更宽，因为要保护更多候选。不能因为最终输出一条规则就事后把512改成1。

12. 松但有效的界

$n = 8, \epsilon = 1/2$ 时，精确同时坏事件概率约0.003492207，而 $2Me^{-2n\epsilon^2} = 10e^{-4} \approx 0.183156389$ 。相差约0.179664182，但前者确实不超过后者。

界只利用有界性、 n 与 M ，未利用具体质量分配或规则间关系，所以不必紧。这是“分布无关的保守保证”与“已知特定分布下精确计算”之间的区别，不能把上界当实际概率的预测值。

13. 序列与组合

八种结果每次选一种， $n=4$ 有 $8^4 = 4096$ 个有序序列。非负计数 $c_1 + \dots + c_8 = 4$ 有 $\binom{11}{7} = 330$ 种。

同一计数对应 $4! / \prod c_i!$ 个不同顺序；每个顺序的概率都是 $\prod p_i^{c_i}$ 。因此组合概率是二者乘积。不是给330种组合平均权重 $1/330$ 。全部组合概率精确加和应为1。

14. 非单调尾概率

固定 ϵ 后，事件由经验风险格点决定。 n 变化时，格点 k/n 与阈值 $R \pm \epsilon$ 的相对位置会跳变，某个格点可能突然进入坏事件。因此某个尾概率不一定对每个整数 n 单调。

默认 H_2 在 $\epsilon=1/8$ 时， $n=6$ 尾概率约0.350621， $n=8$ 约0.384492。理论上界仍随 n 下降，整体集中趋势也仍可成立。不要把平滑直觉强加到离散事件上。

15. 512个候选的误用界失败

$K \leq 3$ 的概率为 $(1 + 20 + 190 + 1140)/2^{20} = 1351/1048576 = q$ 。任一候选达到这个低错误数，选中最小值也达到。其概率 $1 - (1 - q)^{512}$ 。


双侧失败还包括最小值至少17，即所有候选都至少17错，概率 q^{512} 。相加约0.483196884，超过 $\delta=0.05$ 。实测2000次为0.4800，差异属于Monte Carlo波动，没有为逼近解析值改种子。

对 $M=1$ ，两侧都重要，所以概率为 $2q$ ，而不是 q 。对 $M=512$ ，上侧项极小但推导中不能概念性丢掉。

16. 最小值分布与选择偏差

令单个CDF为 $F(k)$ 。所有候选错误数都大于 k 的概率为 $[1 - F(k)]^M$ ，所以 $P(K_{\min} > k) = [1 - F(k)]^M$ 。相邻生存概率之差给出 $P(K_{\min} = k)$ 。

M 越大，训练最小值倾向变小；但每个规则在新数据上仍有一半错误。被选择的是样本上的运气，不是新增的总体预测信息。图中点的连线是离散概率质量的视觉辅助，不是连续密度。



图D 更多候选使最小训练误差分布左移，但真实风险仍全部为 $1/2$ 。

17. 独立留出评价

条件于训练集，选中的索引已固定。新留出集与训练集独立，所以留出损失满足对这个固定规则的IID假设，可以用留出样本数计算单模型半径。

若再根据留出分数挑选候选、调整特征或阈值，留出集成为选择过程的一部分，不能沿用固定规则保证。一个选择摘要能够检查代码是否接收留出反馈，但摘要本身不能证明现实抽样独立。

18. 复制20次的失败概率

所有损失都是同一个公平位B。平均仍为B，取0或1各概率1/2。真实均值0.5，因此偏差始终0.5，大于误套的0.303680731，失败概率为1。

每行边缘分布相同没有问题；问题在于它们完全相关。不能通过复制文件行数来增加有效独立样本量。

19. 零次违约的上限

若真实违约概率为 p ，2000次独立重复均未违约的概率为 $(1 - p)^{2000}$ 。令该概率等于0.05，解得 $p = 1 - 0.05^{1/2000} \approx 0.001496745$ 。

这是零次观测情况下单侧95%上限的构造，不代表真实 p 等于此数。观察到零也不能替代概率界的证明；若重复实验相关，此公式也不能直接用。

20. 两种充分样本数

一般有噪声ERM：要求 $2\sqrt{\log(2M/\delta)/(2n)} \leq \epsilon$ ，整理得 $n \geq 2\log(2M/\delta)/\epsilon^2$ ，再向上取整。

可实现且返回一致规则时，真实风险超过 ϵ 的固定坏规则训练全对概率不超过 $e^{-n\epsilon}$ ，对 M 个候选相加；令 $Me^{-n\epsilon} \leq \delta$ ，得 $n \geq \log(M/\delta)/\epsilon$ 。

默认总体有随机标签且最小风险 $7/32 > 0$ ，所以一般公式适用，可实现公式的额外前提不成立。两个公式都只是充分样本量，没有保证搜索巨大候选类的计算效率。

21. VC维

固定向右阈值能给一个点标0或1，故至少能打散1点；任意两个有序不同点 $x_1 < x_2$ 都无法实现10，故不能打散2点，VC维1。

区间在两个点上能实现00（空覆盖）、10（只覆盖左点）、01（只覆盖右点）、11（覆盖两点），故VC维至少2。任意三个有序不同点都不能实现101，故VC维不超过2，因此等于2。

一般定义要求存在某个 m 点集可打散才能证明下界；证明上界要说明所有更大点集都有某种标签做不到。本例实数排序结构使任意不同点的讨论特别简单，但不能把这一特殊性推广到任意几何类。

22. 两个合法方案

方案一：在看样本之前固定整个有限候选类，使用同时界保护所有候选，然后允许数据依赖地选择类内规则。模型之间可以相关；观测的IID与损失范围前提仍要成立。

方案二：用训练/验证过程完成全部选择并冻结，再在完全独立且不反馈调参的最终留出集上使用单模型评价界。最终只输出一个模型并不能洗掉同一数据中的筛选过程。

任何方案都不能自动处理群组依赖、时间漂移、无界损失或任意事后创造的候选类。先说明评价对象与信息流，才能知道公式保护了什么。